Was denkt die KI-Elite?

Eine LLM-gestützte Weltbild-Rekonstruktion der 100 einflussreichsten Akteure der künstlichen Intelligenz (2010–2026)

Lukas Geiger*

Unabhängiger Forscher, Bernau im Schwarzwald

Februar 2026

Zusammenfassung

Die vorliegende *explorative Studie* rekonstruiert erstmals systematisch das kollektive Weltbild der 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (KI-Elite) für den Zeitraum 2010 bis 2026. Methodisch entwickelt und erprobt sie die synthetische Weltbild-Rekonstruktion (SWR) – ein LLM-gestütztes Verfahren, das aus 3.132 Datenpunkten (1.738 öffentliche Aussagen, 1.394 beobachtbare Handlungen) mittels 51–56 Syntheseeinheiten, 12 Weltbild-Dimensionen und 6 komplementaeren Operationalisierungen kohärente Überzeugungssysteme extrahiert (vgl. das Companion Paper Geiger 2026 für die methodischen Grundlagen). Sechs Forschungsfragen strukturieren die Analyse: F1 (Weltbild) zeigt einen „technologischen Messianismus mit Ambivalenzstruktur“ (Avg 7,1 Kollektiv, 7,7 Top 10). F2 (Wandel) dokumentiert den Übergang von utopischem Techno-Optimismus zu tragischem Beschleunigungszwang; Transhumanismus fällt deutlich ($-2{,}4$/Dekade, $R^2 = 0{,}63$). F3 (Kongruenz) deckt eine systematische Sagen-Handeln-Kluft auf; größte Diskrepanz beim Egalitarismus ($\Delta = -3$). F4 (Cluster) identifiziert vier Weltbild-Typen: Architekt, Hüter, Innovator, Befreier. F5 (Differenz) benennt die stärksten Praediktoren: Haltung (Δ 1,7), Rolle (Δ 1,5), Gender (Δ 1,2). F6 (Macht) offenbart ein Macht-Gemäßigtheits-Paradox: der mächtigste Typ ist der extremste, der gemäßigste der machtloseste.

Schlüsselwörter: KI-Elite, Weltbild, Transhumanismus, Large Language Models, Silicon Valley, Ideologieanalyse

*Korrespondenzautor: [email]

1. Einleitung

1.1 Hinleitung und Relevanz

Eine Handvoll Menschen gestaltet eine Technologie, die Milliarden betrifft. Die Entwicklung künstlicher Intelligenz hat sich in den vergangenen anderthalb Jahrzehnten von einem akademischen Nischenthema zu einer zivilisatorischen Weichenstellung gewandelt. Großsprachmodelle generieren Texte, Bilder und Code; autonome Systeme treffen Entscheidungen in Medizin, Justiz und Finanzwesen; und die führenden KI-Laboratorien sprechen offen davon, in absehbarer Zeit eine künstliche allgemeine Intelligenz zu erschaffen (Bubeck et al., 2023; Bengio et al., 2024). Was dabei leicht übersehen wird: Hinter diesen technologischen Trajektorien stehen konkrete Personen – Gründerinnen und Gründer, Forschungsleitende, Investorinnen und Investoren, CEOs –, deren individuelle und kollektive Überzeugungen über die Natur des Menschen, den Sinn des Fortschritts, die Verteilung von Risiko und Macht in die Architektur der Systeme einfließen, die sie bauen.

Lessig (1999) hat die Formel „Code is law“ geprägt: Software-Architektur reguliert Verhalten nicht weniger wirksam als Gesetze, aber ohne demokratische Legitimation. Diese Einsicht lässt sich für die gegenwärtige KI-Entwicklung radikalisieren: Nicht nur der Code selbst, sondern bereits die *Weltbilder* der Entwickelnden werden zu Algorithmen. Wer glaubt, dass Informationsfreiheit ein absoluter Wert ist, wird Open-Source-Modelle bauen. Wer überzeugt ist, dass eine unkontrollierte Superintelligenz die Menschheit bedroht, wird auf Alignment und geschlossene Systeme setzen. Die Weltbilder der KI-Elite sind somit nicht bloß private Meinungen; sie sind *generative Strukturen*, die sich in Designentscheidungen, Unternehmensstrategien und politische Positionierungen übersetzen – und über diese Kanäle das Leben von Milliarden Menschen prägen.

Dabei entsteht ein fundamentales demokratietheoretisches Problem. Eine zahlungsmäßig äußerst kleine Gruppe trifft Entscheidungen von gesamtgesellschaftlicher Tragweite, ohne über ein demokratisches Mandat zu verfügen. Ihre Überzeugungen prägen diese Entscheidungen in einer Weise, die der öffentlichen Kontrolle weitgehend entzogen ist. Wenn Demokratien informierte Bürgerinnen und Bürger voraussetzen, dann ist die systematische Rekonstruktion der Weltbilder derjenigen, die die mächtigste Technologie des 21. Jahrhunderts gestalten, nicht bloß ein akademisches Anliegen, sondern eine Voraussetzung informierter öffentlicher Deliberation.

1.2 Forschungslücke

Die wissenschaftliche Auseinandersetzung mit den Überzeugungssystemen der KI-Branche hat verschiedene Zugänge hervorgebracht. Auf ideologiekritischer Ebene haben Barbrook & Cameron (1996) die „Californian Ideology“ beschrieben; Morozov (2013) hat die Tendenz zum Solutionismus herausgearbeitet; Daub (2020) hat die rhetorischen und ideologischen Muster

des Silicon Valley als kulturelles Phänomen analysiert. Aus der Transhumanismus-Forschung liegen philosophische Analysen vor (Bostrom, 2005; More & Vita-More, 2013; Coeckelbergh, 2020), die jedoch primär auf die Ideengeschichte und nicht auf die empirische Verteilung dieser Überzeugungen abzielen.

Was in diesem Forschungsfeld bislang *fehlt*, ist eine systematische, datengestützte Analyse der *gesamten* KI-Elite als Kollektiv. Keine Studie untersucht, soweit den Verfassenden bekannt, die folgenden Fragen auf empirisch-systematische Weise: Wie hängen die Weltbilder der führenden KI-Akteure zusammen? Bilden sie kohärente Typen? Wie haben sich diese Weltbilder im Zeitraum von 2010 bis 2026 gewandelt? Und stimmen die öffentlichen Überzeugungen mit dem tatsächlichen Handeln überein?

Neben dieser empirischen Lücke besteht eine *methodische* Lücke. Für die systematische Rekonstruktion von Weltbildern aus öffentlichen Aussagen im großen Maßstab existiert keine etablierte Methode. Klassische qualitative Verfahren skalieren nicht; standardisierte Surveys setzen Zugang zu den Befragten voraus; quantitative Text-Mining-Verfahren erfassen nur Oberflächenmuster. Die vorliegende Studie reagiert auf diese doppelte Lücke mit einem neuen Ansatz, der synthetischen Weltbild-Rekonstruktion (SWR), deren methodische Grundlagen in einem Companion Paper (Geiger, 2026) ausführlich dargelegt werden.

1.3 Forschungsfragen

Aus der beschriebenen Forschungslücke leiten sich sechs Forschungsfragen ab, die in einer Stufenlogik angeordnet sind:

F1: WELTBILD (deskriptiv)

Was denkt die KI-Elite über sich selbst, die Welt und die Menschheit?

F2: WANDEL (längsschnittlich)

Wie hat sich das Weltbild der KI-Elite von 2010 bis 2026 verändert?

F3: KONGRUENZ (validierend)

Stimmen Aussagen und Handlungen der KI-Elite überein?

F4: CLUSTER (explorativ)

Welche Weltbild-Typen gibt es in der KI-Elite, und wer gehört wohin?

F5: DIFFERENZ (vergleichend)

Welche Subgruppen der KI-Elite denken anders als andere?

F6: MACHT (normativ)

Welches Weltbild hat die meiste Macht und die meisten Ressourcen?

1.4 Beitrag der Studie

Die Studie leistet einen dreifachen Beitrag. *Methodisch:* Sie erprobt die synthetische Weltbild-Rekonstruktion (SWR; vgl. Companion Paper Geiger 2026) erstmals an einem großen empirischen Datensatz. *Empirisch:* Sie liefert die erste systematische Weltbild-Analyse der KI-Elite als Kollektiv auf der Grundlage von 3.132 Datenpunkten über 16 Jahre. *Gesellschaftlich:* Sie schafft eine Grundlage für informierte öffentliche Deliberation, indem sie die impliziten Annahmen hinter KI-Designentscheidungen transparent macht.

2. Forschungsstand

Die Studie verortet sich im Schnittfeld vier verschiedener Forschungstraditionen.

2.1 Silicon Valley als Ideologie

Die kritische Auseinandersetzung mit dem Denken des Silicon Valley hat seit Mitte der 1990er Jahre eine reichhaltige Literatur hervorgebracht. Barbrook & Cameron (1996) prägten den Begriff der „Californian Ideology“ – die paradoxe Verschmelzung von libertärem Individualismus und techno-utopischem Optimismus. Turner (2006) zeichnete die kulturhistorische Genealogie dieser Ideologie nach und zeigte, wie die Gegenkultur der 1960er Jahre in den digitalen Utopismus transformiert wurde. Daub (2020) legte die philosophischen Tiefenstrukturen frei: Versatzstücke aus Heidegger, Ayn Rand und puritanischer Prädestinationslehre bilden ein „überraschend schmales philosophisches Fundament“. Morozov (2013) beschrieb den Solutionismus – die Grundhaltung, komplexe soziale Probleme als technische Herausforderungen umzudefinieren. Torres & Gebru (2024) systematisierten diese Strömungen im TESCREAL-Framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism und Longtermism als „zusammenhängendes Bündel“. Ergänzend führte Broussard (2018) den Begriff des „Technochauvinismus“ für eine systematische Kritik.

Die bisherige Forschung hat somit die *Ideologie* des Silicon Valley auf verschiedenen Ebenen beschrieben. Was sie nicht geleistet hat, ist eine systematische empirische Vermessung der *konkreten Weltbilder* der realen Akteure.

2.2 Transhumanismus und KI-Eschatologie

Bostrom (2014) hat mit *Superintelligence* den Denkrahmen definiert, in dem ein wesentlicher Teil der KI-Elite seither operiert. Bereits in früherer Arbeit systematisierte Bostrom (2005) die ideengeschichtlichen Grundlagen des Transhumanismus. More (2003) legte mit den „Principles of Extropy“ das Gründungsdokument des Extropianismus vor. Kurzweil (2005) wendete die Tradition mit der Singularity-These ins Populäre. Von philosophischer Seite formulierte

Habermas (2001) eine der gewichtigsten Gegenpositionen: Die technologische Manipulation künftiger Personen untergrabe deren Autonomie.

Ungeklärt bleibt die empirische Frage: Teilen die realen KI-Akteure diese Überzeugungen? In welcher Mischung, mit welchen Modifikationen und in welcher Verteilung?

2.3 Weltbild-Forschung und Wissenssoziologie

Mannheim (1929) begründete mit dem Theorem der „Seinsgebundenheit des Denkens“ die Tradition, in der Weltbilder als soziale Phänomene analysiert werden. Weber (1904) schuf mit dem Idealtyp ein methodisches Werkzeug, das für die vorliegende Studie zentral ist: Die synthetischen Personas der SWR lassen sich als Idealtypen im Weber'schen Sinne verstehen. Berger & Luckmann (1966) zeigten, wie Weltbilder als soziale Konstruktionen entstehen, sich stabilisieren und reproduzieren. Die wissenssoziologische Tradition liefert den theoretischen Rahmen, aber keine Methode, die auf die Datenmenge und Dynamik des digitalen Zeitalters zugeschnitten ist.

2.4 LLMs als Forschungsinstrument

Die Nutzung großer Sprachmodelle als Instrument sozialwissenschaftlicher Forschung ist ein rasch wachsendes Feld. Tai et al. (2024) untersuchten LLMs für deduktives Kodieren; Hayes (2025) zeigte, dass LLMs einen konversationellen Zugang zu qualitativen Daten ermöglichen; Nicmanis & Spurrier (2025) bieten eine praxisorientierte Einführung. Arbeiten zu synthetischen Personas (Ge et al., 2024) demonstrierten die Skalierbarkeit des Ansatzes – verfolgten aber ein *anderes* Ziel: Sie nutzen synthetische Personas zur *Datenerzeugung*, während die vorliegende Studie sie zur *Rekonstruktion* kohärenter Weltbilder aus *realen* Daten einsetzt. Die synthetische Persona ist in unserem Verfahren kein Simulacrum, sondern ein analytisches Verdichtungsinstrument – näher am Weber'schen Idealtyp als am Simulationsagenten (vgl. Booth, 1961; Ng & Russell, 2000; Jara-Ettinger, 2019).

2.5 Zusammenfassung: Die Forschungslücke

Die vier Traditionen konvergieren auf eine gemeinsame Leerstelle: die systematische, datengestützte, längsschnittliche Vermessung konkreter Weltbilder der KI-Elite mittels einer Methode, die qualitative Tiefe mit quantitativer Systematik verbindet. Die vorliegende Studie schließt diese vierfäche Lücke.

3. Methodik

Die methodischen Grundlagen der synthetischen Weltbild-Rekonstruktion (SWR) – inverses Problem, fiktive synthetische Person, Prompt-Protokoll, Blindungsinfrastruktur und Validie-

rungsrahmen – werden im Companion Paper (Geiger, 2026) ausführlich dargelegt. Der vorliegende Abschnitt beschränkt sich auf die anwendungsspezifischen Aspekte: Datenerhebung, Operationalisierungen, Forschungsdesign und Qualitätssicherung dieser Studie.

3.1 Datenerhebung

3.1.1 Stichprobe und Auswahlverfahren

Gegenstand der Untersuchung sind die 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (im Folgenden: KI-Elite). Die Auswahl erfolgte durch ein mehrstufiges Verfahren: Mittels 22 systematischer Webrecherchen wurden 187 Kandidatinnen und Kandidaten identifiziert. Jede Person wurde anhand eines 6-Kategorien-Scoring-Systems bewertet: (1) Marktkapitalisierung/Ressourcenkontrolle, (2) technologische Schlüsselpositionen, (3) öffentliche Diskursmacht, (4) akademischer Einfluss, (5) politische Einflussnahme, (6) symbolischer Status. Die resultierende Rangliste wurde auf 100 Personen reduziert, wobei die Heterogenität der Branche hinsichtlich Rollen, Firmenzugehörigkeiten, Haltungen und Geschlecht abgebildet wird (vgl. Anhang A).

3.1.2 Datenquellen und Erhebungszeitraum

Der Erhebungszeitraum erstreckt sich vom 1. Januar 2010 bis zum 11. Februar 2026. Die Datenerhebung stützt sich auf zwei Datentypen: **öffentliche Aussagen** (wörtliche Zitate aus Interviews, Keynotes, Podcasts, Twitter/X-Posts, Blogbeiträgen, Büchern, Kongressanhörungen) und **beobachtbare Handlungen** (Investitionsentscheidungen, Firmengründungen, Personalentscheidungen, politische Aktivitäten, Produkteinführungen). Die Verknüpfung wurde in einer relationalen SQLite-Datenbank mit 9 Tabellen und 5 Views operationalisiert. Die Gesamtmenge beläuft sich auf 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte).

3.1.3 Methodologische Verankerung

Die Datenerhebung folgt dem Grounded-Theory-Ansatz nach Strauss & Corbin (1990): In Phase 1 wurden keine inhaltlichen Filter angewandt; in Phase 2 wurden mittels offenen Kodierens Muster identifiziert; in Phase 3 wurde ein datengestütztes Kategoriensystem entwickelt. Ein- und Ausschlusskriterien wurden erst in Phase 5 formuliert; in Phase 6 erfolgte eine Qualitätssicherung (Quellenverifizierung einer 10-%-Stichprobe).

3.2 Die Methode der synthetischen Weltbild-Rekonstruktion

Die SWR definiert Weltbild-Analyse als inverses Problem: Aus beobachtbaren Aussagen und Handlungen wird auf das innere Überzeugungssystem zurückgeschlossen, das diese Outputs am kohärentesten erzeugen würde. Die Lösung besteht in der Konstruktion einer *fiktiven synthetischen Person* – ein Destillat, das Weltbild in Reinform abbildet, befreit von biographischem

Rauschen und PR-Strategien. Die theoretische Verankerung stützt sich auf vier Traditionen: Webers Idealtyp, Booths *Implied Author*, Inverse Reinforcement Learning und projektive Tests. Der operative Ablauf umfasst fünf Schritte: (1) Datenkorpus zusammenstellen, (2) LLM-gestützte Synthese, (3) strukturiertes Interview, (4) Meta-Reflexion, (5) ergänzende Prompt-Varianten. Für die ausführliche Darstellung einschließlich der Blindungsinfrastruktur, der Begründung des Fiktionsansatzes und des Validierungsrahmens sei auf das Companion Paper verwiesen (Geiger, 2026).

3.3 Operationalisierungen

Die drei abhängigen Variablen (AV1: Selbstbild, AV2: Weltbild, AV3: Menschenbild) werden durch sechs Operationalisierungen zugänglich gemacht:

Tabelle 1: Die sechs Operationalisierungen der SWR.

Op	Technik	Beschreibung	MVs
Op1	T1 Kern-Synthese	Fiktive Person + 3-Fragen-Interview + Reflexion	7
Op2	T4 Rating	Bewertung auf 12 Dimensionen (D01–D12), Skala 1–10	12
Op3	Textanalyse	TF-IDF, Sentiment, Metaphern, Embeddings, Topics	8+
Op4	T3 Kreuzmodal	Vorhersage: Aussagen → Handlungen und umgekehrt	4
Op5	T5 Clustering	Sentence-BERT-Embeddings, HDBSCAN, Netzwerk	6
Op6	T2 Dialog	Strukturierter Vergleich zweier Synthesen	3

Die 12 Rating-Dimensionen (Op2) verteilen sich gleichmäßig auf die drei AVs: Selbstbild-Dimensionen D01–D04 (Sendungsbewusstsein, Selbstwirksamkeit, Arbeitsethos, Verantwortungsgefühl), Weltbild-Dimensionen D05–D08 (Techno-Determinismus, Fortschrittsglaube, Machtkonzentration, Dringlichkeit) und Menschenbild-Dimensionen D09–D12 (Menschenfreundlichkeit, Posthumanismus, Egalitarismus, Kontrollüberzeugung). Die vollständige Dimensionentabelle mit Skalenpolen findet sich in Anhang B.

3.4 Forschungsdesign

3.4.1 Variablenarchitektur

Das Forschungsdesign ist als vierstufige Architektur konzipiert: 3 AVs → 6 Operationalisierungen → 50+ Messvariablen → 6 unabhängige Variablen (UVs). Die UVs bestimmen, welche Daten in eine Syntheseeinheit (SE) eingehen:

- UV1 *Zeitraum:* Einzeljahre (2010–2026), Epochen, Gesamtzeitraum
- UV2 *Modalität:* Aussagen+Handlungen (AH), nur Aussagen (A), nur Handlungen (H)
- UV3 *Personengruppe:* Alle 100, Top 10, Subgruppen (Rollen, Firmen, Haltung, Geschlecht)
- UV4 *Inhaltskategorie:* Durch emergente Cluster ersetzt (K9)
- UV5 *Kongruenzstatus:* Konsistent vs. widerspruchlich

- UV6 *Homogenisierung:* Alle vs. nur häufig wiederholte Aussagen

3.4.2 Systematische Reduktion

Der theoretische Kombinationsraum von ca. 1.227 möglichen SEs wurde durch neun Reduktionskriterien (K1–K9; vgl. Anhang C) auf 51–56 Kern-SEs reduziert (95,4 % Reduktion). Zusätzlich wurden 36 kreuzmodale Runs, 10 Vergleichs-Runs und rein computationale Analysen durchgeführt. Die Gesamtzahl der Prompt-Runs beläuft sich auf ca. 199–214.

3.5 Qualitätssicherung

Die methodische Qualität wird durch sechs Massnahmen gesichert: (1) Mindestgröße von 15 Datenpunkten pro SE, (2) Inter-LLM-Reliabilität (zwei Modelle, ICC-Berechnung), (3) Sensitivitätsanalyse (mindestens drei Runs pro SE), (4) konsequente Blindung (Entfernung aller Identifikatoren), (5) Reproduzierbarkeitsprotokoll (Temperatur 0, vollständige Prompt-Dokumentation) und (6) ein systematischer Halluzinations-Check. Für eine ausführliche Diskussion der Validierungsstrategien und ihrer Grenzen verweisen wir auf Geiger (2026).

3.5.1 Halluzinations-Check und Positionsvalidierung

Da LLM-gestützte Rekonstruktionen grundsätzlich anfällig für Halluzinationen sind — d. h. das Modell könnte Positionen zuschreiben, die eine Person nie vertreten hat —, wird ein systematischer Validierungsplan implementiert:

Stratified Spot-Check (10%):

Eine geschichtete Zufallsstichprobe von 10 der 100 Personen (je 2–3 pro Cluster-Typ) wird für eine vollständige manuelle Gegenprüfung ausgewählt. Für jede dieser Personen werden alle 12 Dimensionsratings mit dokumentierten öffentlichen Aussagen abgeglichen. Abweichungen > 2 Skalenpunkte zwischen rekonstruiertem Rating und dokumentierter Position werden als „materielle Diskrepanz“ klassifiziert und im Supplementary Material berichtet.

Prüfprotokoll:

Jedes Rating der 10 validierten Personen erhält einen Belegstatus: *bestätigt* (dokumentierte Aussage/Handlung stützt das Rating), *plausibel* (keine direkte Evidenz, aber konsistent mit dem öffentlichen Profil) oder *nicht belegbar* (keine Evidenz gefunden, mögliche LLM-Halluzination). Zielwert: $\geq 80\%$ bestätigte oder plausible Ratings.

Red-Flag-Analyse:

Zusätzlich werden alle Extremwerte (≤ 2 oder ≥ 9) im gesamten Datensatz ($100 \times 12 = 1.200$ Ratings) auf Plausibilität geprüft, da Extrempositionen das höchste Halluzinationsrisiko tragen. Für Extremwerte wird jeweils mindestens eine dokumentierte Quellenangabe verlangt.

Dieser Halluzinations-Check adressiert das zentrale methodische Risiko der SWR und stellt sicher, dass die berichteten Befunde nicht auf fabrizierten Positionen beruhen, sondern auf empirisch verankerbaren Rekonstruktionen.

3.6 Rolle des LLM im Forschungsprozess

Die Rolle des Large Language Models (Claude Opus 4.6) im Forschungsprozess muss präzise bestimmt werden. Das LLM fungiert in dieser Studie in einer dreifachen Rolle:

(a) Analyseinstrument:
Das LLM verarbeitet die Datenpunkte (Aussagen und Handlungen) und erzeugt daraus synthetische Weltbild-Rekonstruktionen. In dieser Funktion ist es vergleichbar mit einem qualitativen Kodierungswerkzeug – es ersetzt den menschlichen Kodierer bei der Mustererkennung und Synthese.

(b) Wissenstraeger:
Da das LLM auf umfangreichen Textkorpora trainiert wurde, die Aussagen und Handlungen der untersuchten Personen enthalten, bringt es eigenes Kontextwissen ein. Dies ist gleichzeitig Stärke (Kontextualisierung) und Risiko (Kontamination). Die Blindungsinfrastruktur adressiert dieses Risiko, kann es aber nicht vollständig eliminieren.

(c) Formulierungshilfe:
Bei der Erstellung des Manuskripts unterstützte das LLM die Strukturierung und Formulierung. Forschungsdesign, Interpretation und Schlussfolgerungen stammen vom menschlichen Autor.

Wichtig: Das LLM ist *nicht* die Datenquelle. Die Datenquelle sind die 3.132 empirisch erhobenen Datenpunkte (öffentliche Aussagen und beobachtbare Handlungen). Das LLM ist das Instrument, das diese Daten zu kohärenten Weltbildern verdichtet.

3.7 Validierungsstrategie

Die Validierung der SWR-Ergebnisse erfolgt auf drei Ebenen:

Interne Konsistenz:
Die Kongruenzanalyse (F3) vergleicht aus Aussagen und aus Handlungen rekonstruierte Weltbilder derselben Person. Systematische Diskrepanzen deuten nicht auf Methodenfehler, sondern auf reale Sagen-Handeln-Kluefte hin – und stellen damit einen inhaltlichen Befund dar.

Konvergenzvalidität:
Die Stabilität des Kollektivprofils über 15 Gruppensynthesen und 4 Cluster-Typen

stützt die Konvergenzvalidität. Zusätzlich werden die Befunde mit den qualitativen Diagnosen der bestehenden Literatur (Barbrook & Cameron, 1996; Morozov, 2013; Daub, 2020; Torres & Gebru, 2024) verglichen.

Geplante externe Validierung — Detaillierter Studienplan:

Um die Validität der SWR-Rekonstruktionen empirisch zu testen, wird folgende Validierungsstudie für eine Stichprobe von $N = 10$ Personen aus der Gesamtstichprobe vorgeschlagen:

Stichprobenauswahl: 10 Personen, stratifiziert nach Clustern (3 Architekten, 3 Hüter, 2 Innovatoren, 2 Befreier), ausgewählt nach Kriterien: (a) substantielle sekundäre Literatur verfügbar (Biografien, kritische Analysen, Interview-Sammlungen), (b) öffentlich dokumentierte Handlungsmuster (Abstimmungsverhalten, Spendenmuster, Organisationszugehörighkeiten), (c) hohe dimensionale Differenzierung (keine zentristischen Profile).

Vergleichsquellen: Für jede Person werden drei unabhängige Validierungsquellen herangezogen: (1) Publizierte Biografien oder kritische Porträts, (2) strukturierte Interviews (z. B. Lex Fridman Podcast, The 80,000 Hours Podcast), (3) öffentlich dokumentiertes Handeln (z. B. politische Spenden via FEC-Datenbank, Open-Source-Beiträge, Organisationsmitgliedschaften).

Validierungsprozedur: Drei unabhängige Kodierer (Doktoranden der Sozialwissenschaften, mit KI-Governance-Expertise) erhalten für jede Person: (a) die SWR-generierte dimensionale Bewertung (12 Dimensionen, Skala 1–10), (b) die drei Vergleichsquellen, (c) eine Kodieranleitung für jede Dimension. Kodierer bewerten jede Dimension anhand der Vergleichsquellen (Skala 1–10). Interrater-Reliabilität wird via ICC gemessen (Akzeptanzkriterium: ICC $\geq 0{,}70$).

Konvergenzanalyse: Pearson-Korrelation zwischen SWR-Scores und Experten-Ratings pro Dimension. Hypothese: $r \geq 0{,}60$ für Kerndimensionen (Individualismus, Techno-Optimismus, Regulierungspräferenz). Systematische Divergenzen (z. B. SWR konsequent höher) identifizieren methodische Verzerrungen (z. B. Kohärenzbias).

Qualitative Diskrepanzanalyse: Für die 3 Fälle mit höchster Divergenz ($r < 0{,}40$) erfolgt eine qualitative Fehleranalyse: Welche Aspekte wurden vom LLM über-/unterbetont? Welche Quellenarten (Aussagen vs. Handlungen) produzieren systematische Verzerrungen?

Falsifikationskriterium: Falls die mittlere Korrelation über alle Dimensionen $\bar{r} < 0{,}50$ oder mehr als 4/10 Fälle $r < 0{,}40$ zeigen, ist die Methode nicht valide genug für wissenschaftliche Anwendung — dies erfordert substanzielle Revision des Prompt-Protokolls oder Rückzug auf rein heuristische Verwendung.

Diese Validierung wurde im Rahmen der vorliegenden explorativen Studie noch nicht durchgeführt und ist Gegenstand zukünftiger Arbeiten (Geiger, in Vorbereitung).

Epistemischer Status der Befunde: Die vorliegende Studie versteht sich als *explorative Methodendemonstration*. Die quantitativen Befunde (Ratings, Trends, Korrelationen) beschreiben Muster in den LLM-generierten Rekonstruktionen und erheben keinen Anspruch auf die Präzision standardisierter psychometrischer Instrumente. Sie generieren Hypothesen, die durch unabhängige Methoden (Surveys, Expertenratings, Inhaltsanalysen) zu prüfen wären.

4. Ergebnisse

Die Befunde basieren auf den synthetischen Weltbild-Rekonstruktionen der einhundert einflussreichsten KI-Persönlichkeiten, operationalisiert über zwölf Dimensionen auf einer Zehnpunkteskala.

4.1 F1 – Weltbild der KI-Elite (deskriptiv)

4.1.1 Das kollektive Weltbild aller 100

Das Gesamtprofil zeigt ein kohärentes, hochintensives Überzeugungssystem mit einem Durchschnittswert von 7,1 (Tabelle 2).

Tabelle 2: Kollektiv-Profil der KI-Elite ($N = 100$, Aussagen und Handlungen).

Dimension	**Rating**	**Interpretation**
D01 Sendungsbewusstsein	8	Hoch
D02 Selbstwirksamkeit	8	Hoch
D03 Arbeitsethos	8	Hoch
D04 Verantwortungsgefühl	7	Mittel-hoch
D05 Techno-Determinismus	8	Hoch
D06 Fortschrittsglaube	7	Hoch
D07 Machtkonzentration	6	Mittel (ambivalent)
D08 Dringlichkeit	8	Sehr hoch
D09 Menschenfreundlichkeit	5	Niedrig
D10 Posthumanismus	7	Mittel-hoch
D11 Egalitarismus	5	Niedrig
D12 Kontrollüberzeugung	8	Hoch
Durchschnitt	**7,1**	

Das Profil zeigt eine charakteristische Doppelstruktur: ausgeprägt elitäres Selbstbild (D01–D03 je 8), starker Techno-Determinismus (D05=8) und hohe Dringlichkeit (D08=8) einerseits; Menschenfreundlichkeit (D09=5) und Egalitarismus (D11=5) als tiefste Punkte andererseits. Die Kombination erzeugt das prägende Muster: eine Elite, die *für* die Menschheit bauen will, aber nicht *mit* ihr.

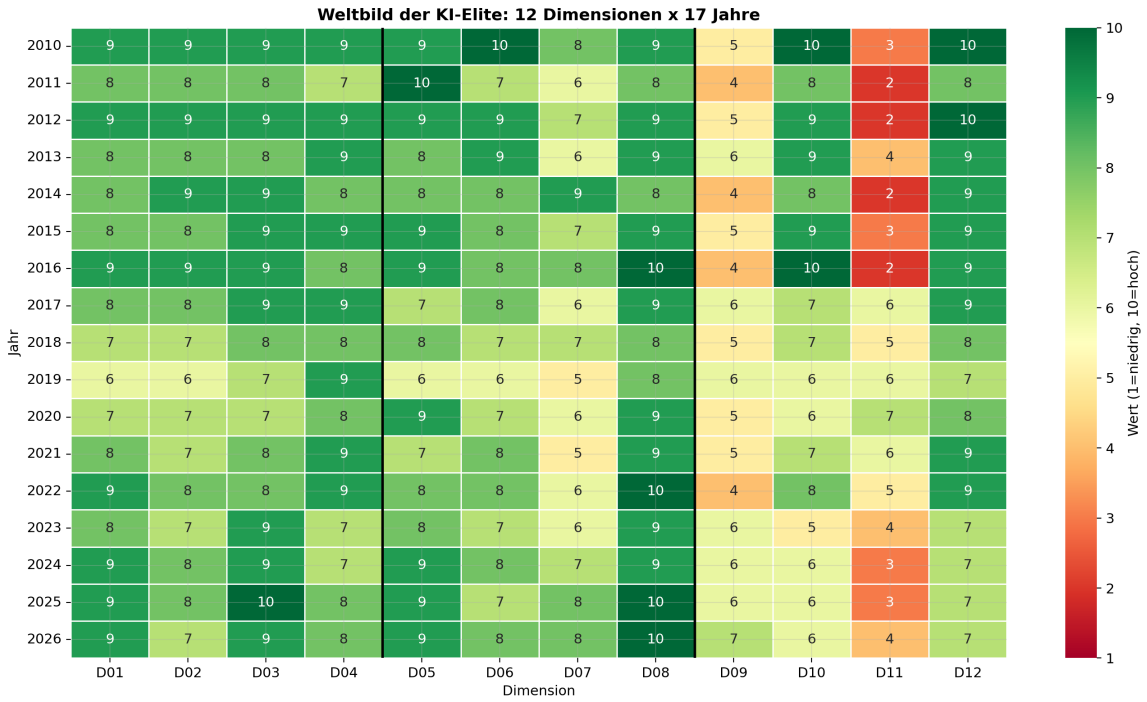

Abbildung 1: Heatmap der 12 Weltbild-Dimensionen über alle untersuchten Gruppen. Hohe Werte (dunkel) markieren intensive Überzeugungen; die Doppelsenke bei D09 und D11 ist über alle Gruppen hinweg sichtbar.

4.1.2 Das Weltbild der Top 10

Die zehn mächtigsten KI-Akteure vertreten dasselbe Weltbild in intensivierter Form (Avg 7,7). Auf zehn von zwölf Dimensionen liegen die Top-10-Werte exakt einen Skalenpunkt über dem Kollektiv. Die beiden Ausnahmen: Menschenfreundlichkeit (D09=4) und Egalitarismus (D11=4) liegen *niedriger*. Je mächtiger die Position, desto ausgeprägter das Sendungsbewusstsein und desto distanzierter das Menschenbild.

4.1.3 Kernüberzeugungen

Die Destillation der am häufigsten wiederholten Aussagen identifiziert fünf Überzeugungen als Minimalkonsens: (1) Technologie als moralisches Gebot, (2) Elite-Steuerung, (3) das Befreiungsnarrativ, (4) geopolitischer Manichäismus, (5) Arbeit als Identität. Sicherheitsrhetorik gehört zum Kernbestand des Diskurses, fungiert aber als diskursive Ressource, nicht als handlungsleitende Überzeugung.

Kernbefund F1: Die KI-Elite trägt ein kohärentes, hochintensives Weltbild, das sich als *technologischer Messianismus mit Ambivalenzstruktur* charakterisieren lässt.

4.2 F2 – Wandel des Weltbilds (längsschnittlich)

4.2.1 Entwicklung der 12 Dimensionen über die Zeit

Von zwölf Dimensionen zeigen vier ausgeprägte lineare Trends (Tabelle 3).[1]

Tabelle 3: Ausgeprägte lineare Trends (OLS-Beschreibung, $n = 17$ Jahrespunkte).

Dimension	**Richtung**	**Steigung/Dekade**	R^2
D10 Posthumanismus	fallend	$-2{,}4$	0,63
D12 Kontrollüberzeugung	fallend	$-1{,}5$	0,54
D02 Selbstwirksamkeit	fallend	$-1{,}0$	0,31
D09 Menschenfreundlichkeit	steigend	$+0{,}9$	0,27

Den stärksten Rückgang verzeichnet der Posthumanismus: von 10 im Jahr 2010 auf 6 im Jahr 2025. Die hohe Korrelation mit D12 ($r = +0{,}85$) weist auf ein zusammenhängendes Phänomen: Transhumanismus und Zukunftszuversicht erodieren synchron. Der einzige deutlich steigende Wert betrifft die Menschenfreundlichkeit (D09), wobei die negative Korrelation mit D10 ($r = -0{,}58$) eine kompensatorische Verknüpfung nahelegt. Der Gesamtdurchschnitt bleibt nahezu konstant (Frühphase 7,5, Spätphase 7,3), was eine tektonische Verschiebung unter der Oberfläche verbirgt.

4.2.2 Wendepunkte und Epochenvergleich

Die Breakpoint-Detection identifiziert zwei zentrale Wendepunkte. Der erste liegt bei 2019: Vier Dimensionen (D01, D02, D05, D06) erreichen synchron ihren Tiefpunkt, kontextuell verknüpft mit der GPT-2-Zurückhaltung. Der zweite, dauerhaftere Wendepunkt liegt bei 2022/2023: Die ChatGPT-Veröffentlichung löst eine Kaskade aus – Dringlichkeit springt auf ihr Maximum (D08=10), Egalitarismus bricht ein (von 6 auf 4). Im Unterschied zu 2019 kehren die Werte nicht zurück; die Post-ChatGPT-Welt etabliert ein neues Gleichgewicht.

4.2.3 Konvergenz oder Divergenz?

Die Daten zeigen eine zunehmende Ausdifferenzierung. Der ChatGPT-Effekt intensiviert sowohl die Architekten-Position (Beschleunigung, Machtkonzentration) als auch die Hüter-Position (Vorsicht, Regulierung) gleichzeitig – er wirkt als Katalysator der Bipolarisierung.

4.2.4 Metaphern- und Emotions-Wandel

Die Leitmetapher verschiebt sich von Prometheus – dem Feuerbringer – zum tragischen Helden, der retten muss, was möglicherweise nicht mehr zu retten ist. Die Handlung bleibt dieselbe (Be-

[1] Die hier berichteten Trendlinien beschreiben *Muster in rekonstruierten Daten*: Die Weltbild-Werte sind LLM-gestützte Rekonstruktionen, keine unabhängigen Messungen. OLS-Steigungen und R^2 dienen der Beschreibung der Verlaufsmuster, nicht der inferenzstatistischen Hypothesenprüfung. Eine externe Validierung (Expertenratings vs. SWR-Output) steht noch aus (vgl. Abschnitt Limitations).

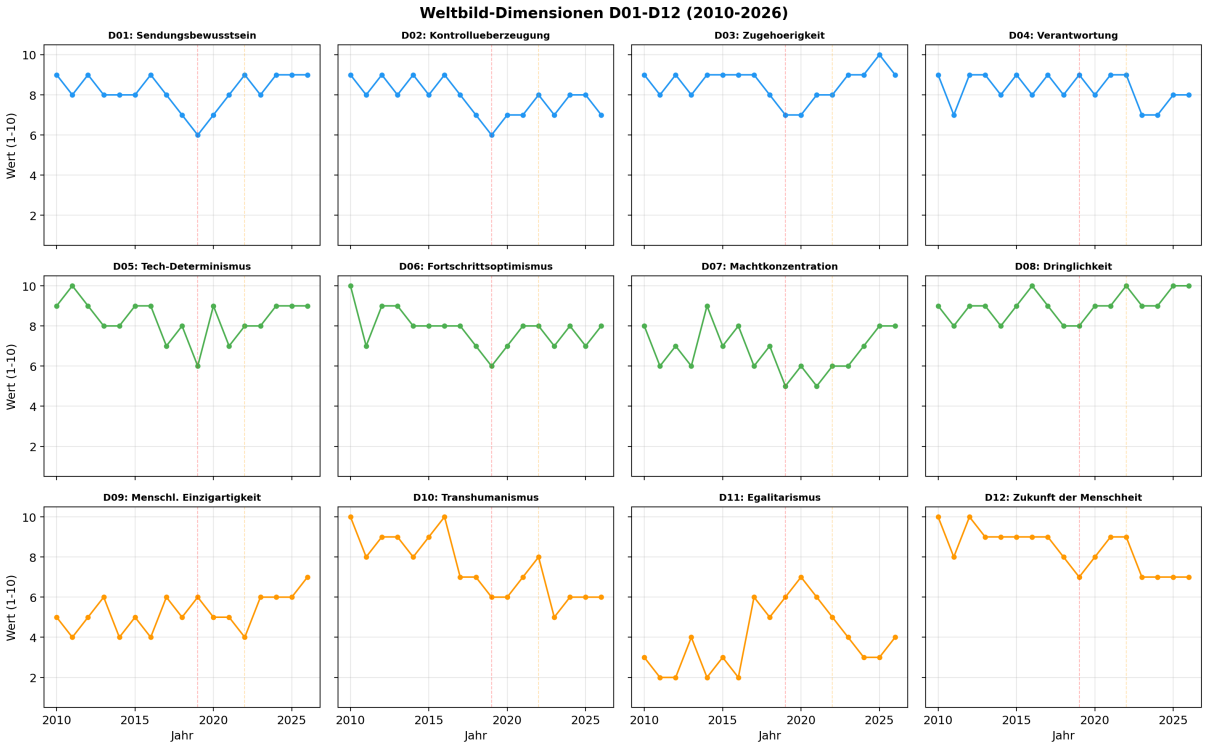

Abbildung 2: Zeitreihen der 12 Weltbild-Dimensionen (2010–2026). Ausgeprägte Trends sind hervorgehoben. Der markante Abfall von D10 (Posthumanismus) und D12 (Kontrollüberzeugung) bildet den „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird.

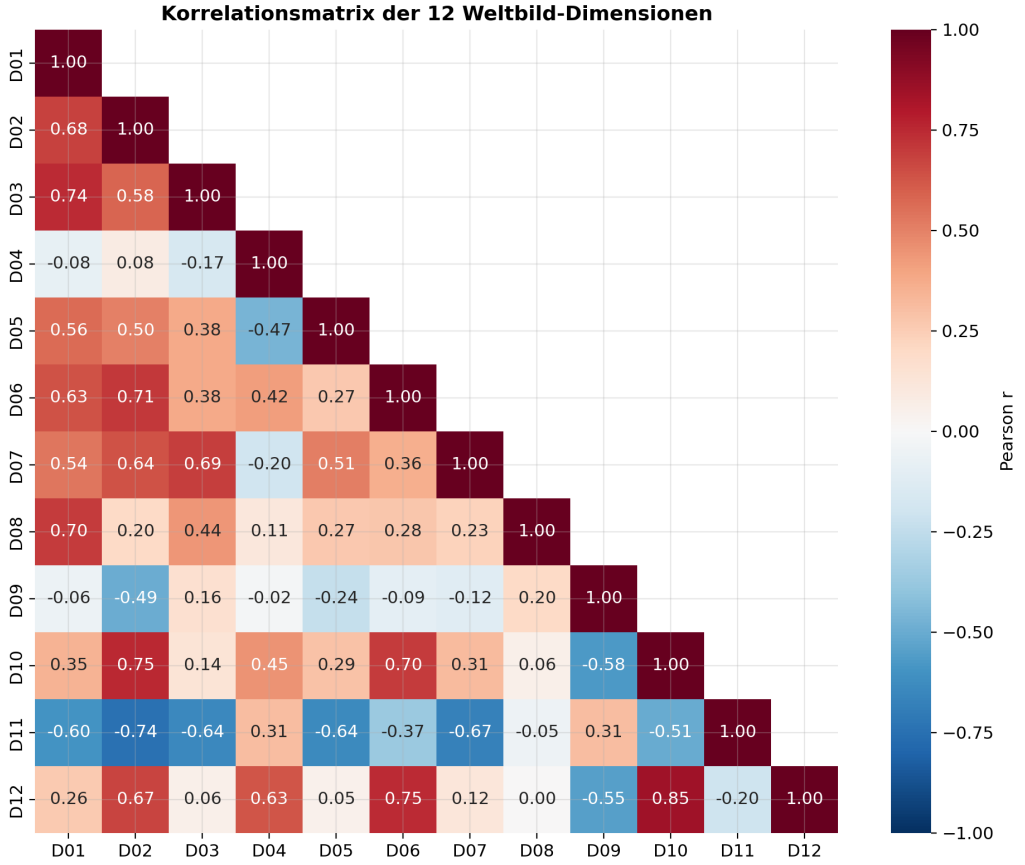

Abbildung 3: Korrelationsmatrix der 12 Dimensionen. Die starke positive Korrelation zwischen D10 und D12 sowie die negative Korrelation zwischen D10 und D09 bilden den empirischen Kern des „Utopie-Komplexes“.

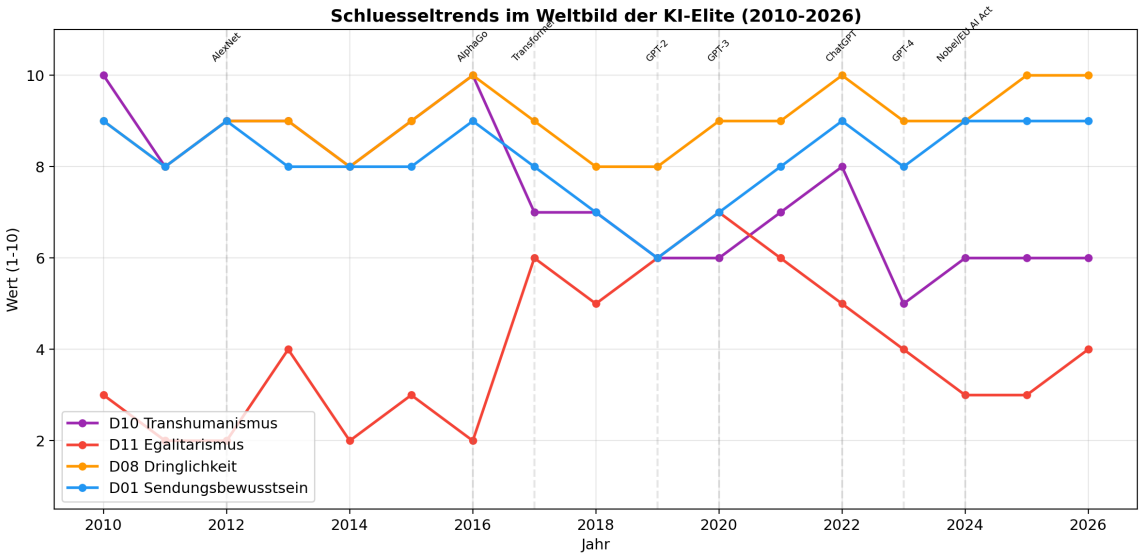

Abbildung 4: Schlüsseltrends der Weltbild-Transformation. Die zwei Wendepunkte (2019, 2022/2023) und die drei Epochen (Prometheischer Optimismus, Erste Ambivalenz, Tragisches Bewusstsein) sind markiert.

schleunigung), aber ihre emotionale Rahmung dreht sich um: nicht mehr aus Euphorie, sondern aus dem Glauben, dass die Alternative schlimmer wäre.

Kernbefund F2: Das Weltbild hat sich strukturell transformiert – von einer monochromen Utopie zu einer bimodalen Wette. Drei Erosionstrends (D10, D12, D02) bilden einen „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit arithmetisch kompensiert wird.

4.3 F3 – Kongruenz von Aussagen und Handlungen

Tabelle 4: Vergleich Aussagen (A) und Handlungen (H), $N = 100$.

Dimension	**Sagen**	**Handeln**	Δ	**Urteil**
D01 Sendungsbewusstsein	8	7	-1	Leicht
D02 Selbstwirksamkeit	8	9	$+1$	Handeln > Sagen
D03 Arbeitsethos	8	9	$+1$	Handeln > Sagen
D04 Verantwortungsgefühl	7	5	$\mathbf{-2}$	Stark
D05 Techno-Determinismus	8	9	$+1$	Handeln > Sagen
D06 Fortschrittsglaube	8	6	$\mathbf{-2}$	Stark
D07 Machtkonzentration	6	8	$\mathbf{+2}$	Stark
D08 Dringlichkeit	8	9	$+1$	Handeln > Sagen
D09 Menschenfreundlichkeit	5	3	$\mathbf{-2}$	Stark
D10 Posthumanismus	7	8	$+1$	Handeln > Sagen
D11 Egalitarismus	5	2	$\mathbf{-3}$	**Massiv**
D12 Kontrollüberzeugung	8	7	-1	Leicht
Durchschnitt	**7,2**	**6,8**	$-0{,}4$	

Die Diskrepanzen ordnen sich in zwei komplementäre Cluster. Das *Abwärts-Cluster* (Handeln < Sagen) umfasst die gesellschaftsorientierten Dimensionen: Egalitarismus ($\Delta - 3$), Verantwortungsgefühl, Fortschrittsglaube und Menschenfreundlichkeit (je $\Delta - 2$). Das *Aufwärts-Cluster* (Handeln > Sagen) umfasst die machtbezogenen Dimensionen: Machtkonzentration ($\Delta + 2$), Selbstwirksamkeit, Arbeitsethos, Techno-Determinismus (je $\Delta + 1$). Das resultierende Muster: eine systematische Selbstdarstellungs-Asymmetrie. Öffentlich präsentiert sich die KI-Elite gemäßigter, verantwortungsvoller und egalitärer, als sie in der Praxis agiert.

Die massivste Einzeldiskrepanz ($\Delta - 3$ bei D11) zeigt: In Aussagen spricht die KI-Elite von „Zugang für alle“; in ihren Handlungen baut sie Mehrfach-Stimmrechtsaktien, konzentriert Compute-Infrastruktur und schafft exklusive Netzwerke.

Kernbefund F3: Die Inkongruenz ist systematisch, gerichtet und funktional. Die KI-Elite meint, was sie über ihre eigene Bedeutung sagt – aber nicht, was sie über Gleichheit, Verantwortung und Menschlichkeit sagt.

4.4 F4 – Weltbild-Cluster

Aus den Daten lassen sich vier distinkte Weltbild-Typen identifizieren (Tabelle 5).

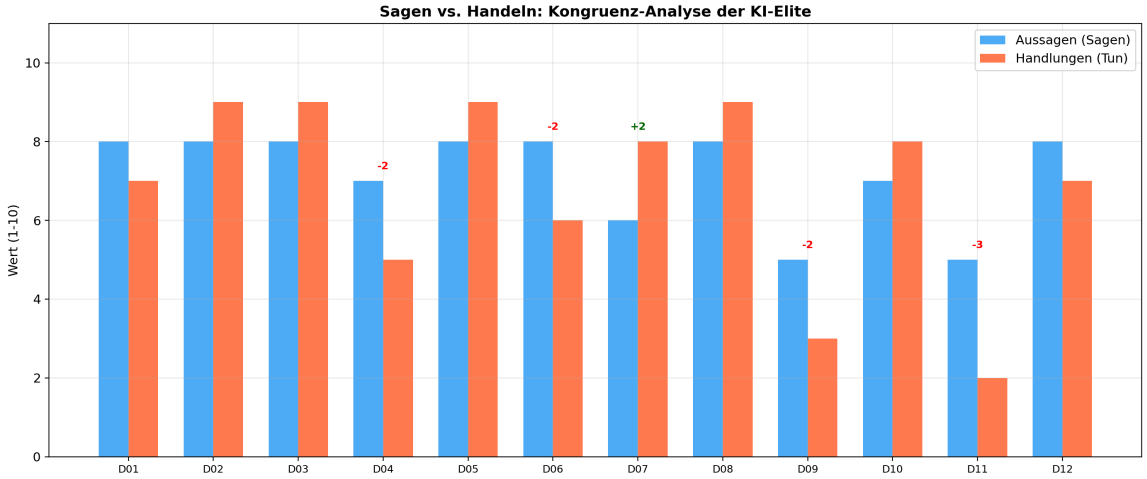

Abbildung 5: Sagen vs. Handeln: Vergleich der aus Aussagen (A) und Handlungen (H) rekonstruierten Weltbilder. Die gesellschaftsorientierten Dimensionen (D04, D06, D09, D11) fallen im Handeln systematisch ab, während die machtbezogenen Dimensionen (D07, D05) im Handeln steigen.

Tabelle 5: Die vier Weltbild-Typen der KI-Elite.

Merkmal	**I „Architekt“**	**II „Hüter“**	**III „Innovator“**	**IV „Befreier“**
n	35	25	22	18
Prototyp	CEOs, Investoren	Akademiker, Risiko-W.	Gründer	Open Source
Avg D01–D12	7,8	6,4	7,2	6,8
D04 Verantwortung	6,3	**9,0**	8,3	6,0
D07 Machtkonzentr.	**8,8**	4,8	6,5	**2,5**
D09 Menschenfreundl.	**3,3**	5,8	4,8	**6,5**
D11 Egalitarismus	**2,8**	**7,2**	5,0	**7,5**

Der **Architekt** vereint maximales Sendungsbewusstsein mit minimalem Egalitarismus: Machtkonzentration ist Voraussetzung für Handlungsfähigkeit. Der **Hüter** bildet den Gegenpol: maximale Verantwortung, Forderung nach institutioneller Begrenzung. Der **Innovator** steht dazwischen. Der **Befreier** ist die überraschendste Entdeckung: minimale Machtkonzentration *und* hoher Egalitarismus – Regulierungsgegner, die Macht radikaler verteilen wollen als alle anderen, allerdings durch Märkte und Open-Source-Communities.

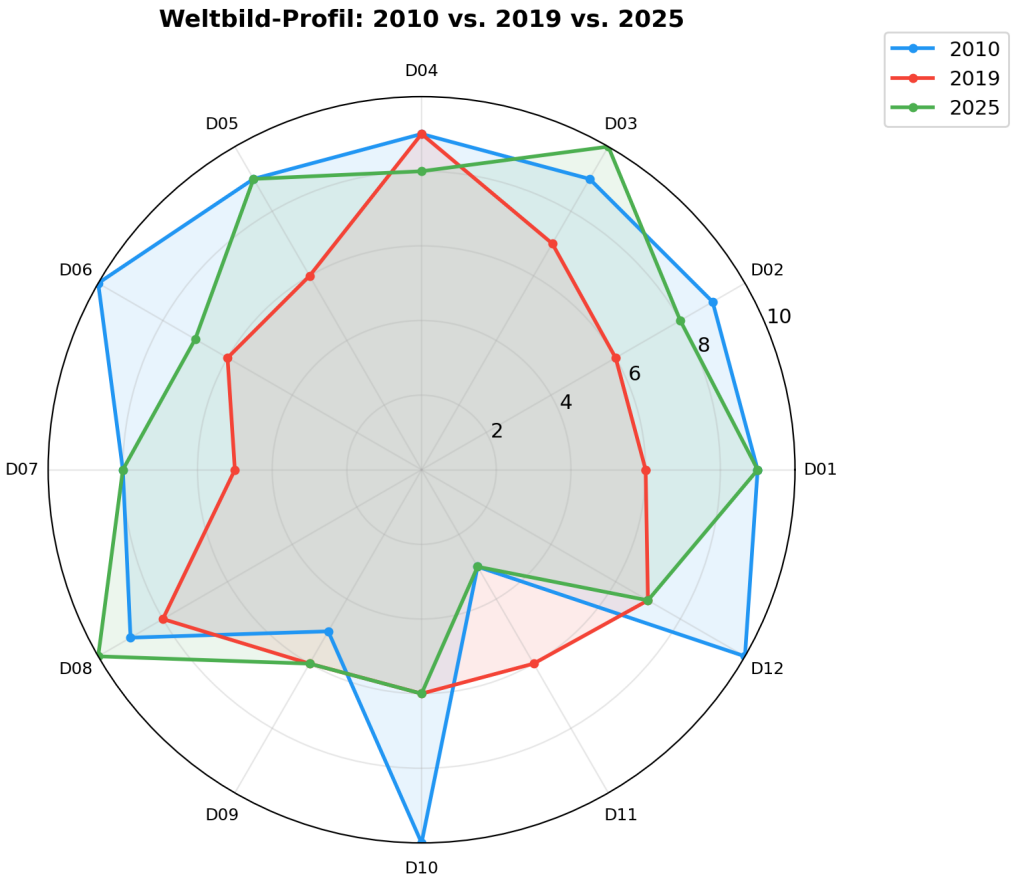

Abbildung 6: Radar-Diagramm der vier Weltbild-Typen auf den 12 Dimensionen. Die Polarisierung zwischen Architekt (außen) und Hüter (innen) sowie die überraschende Position des Befreiers sind deutlich erkennbar.

Kernbefund F4: Die stärkste Polarisierung besteht zwischen Typ I (Herrschaftslogik) und Typ II (Teilhabelogik). Das Macht-Gemäßigtheits-Paradox – Ressourcen-Kontrolle korreliert invers mit Egalitarismus und Verantwortung – ist der demokratietheoretisch brisanteste Befund.

4.5 F5 – Subgruppenvergleiche

Der **stärkste Kontrast** (Risiko vs. Speed, Δ 1,7) betrifft nicht die Risikoeinschätzung – beide Seiten veranschlagen die Katastrophenwahrscheinlichkeit auf 10–20 % –, sondern die ontologische Vorfestlegung: Risiko-Warner konzipieren KI als potenziellen autonomen Agenten, Beschleuniger als Werkzeug.

Tabelle 6: Ranking der Subgruppen-Differenzen.

Rang	Vergleich	Avg A	Avg B	Δ	Stärkster Kontrast
1	Risiko vs. Speed	5,9	7,6	1,7	D02, D06, D10, D12: je −5
2	CEOs vs. Akademiker	7,8	6,3	1,5	D07: +4, D11: −4
3	Frauen vs. Männer	6,9	8,1	1,2	D11: −6
4	Open vs. Closed	6,8	6,3	0,5	D07: −3, D12: +3
5	Reg-Pro vs. Contra	6,3	6,8	0,5	D04: +4, D06: −3
6	Anthropic vs. OpenAI	6,9	7,3	0,4	D12: −3

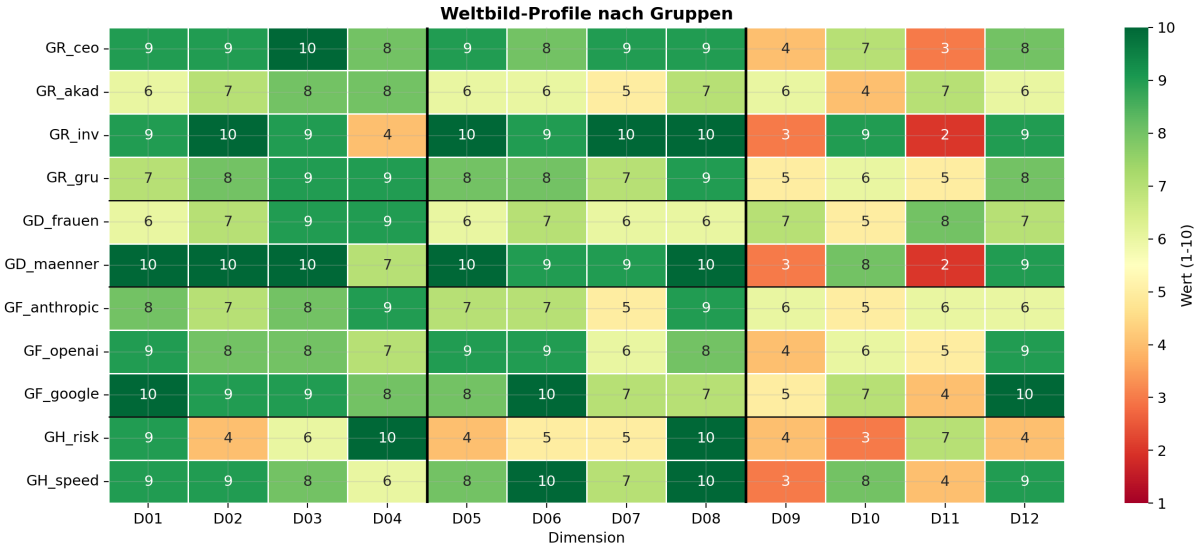

Abbildung 7: Gruppen-Heatmap: 15 Subgruppen × 12 Dimensionen. Die systematische Variation von D07 (Machtkonzentration) und D11 (Egalitarismus) über alle Vergleiche hinweg ist der zentrale visuelle Befund.

Der **extremste Einzelkontrast** der gesamten Erhebung findet sich bei D11 im Gender-Vergleich: sechs volle Skalenpunkte (Frauen: 8, Männer: 2). Das Frauen-Weltbild ist kein Anti-Technik-Weltbild, sondern ein *konditioniertes* Technik-Weltbild: gleich optimistisch, aber mit stärkeren ethischen Bedingungen. Dieser Befund muss mit Vorsicht interpretiert werden, da (a) LLMs bekannte Gender-Stereotypen reproduzieren könnten und (b) die Frauenstichprobe klein ist ($n = 18$). Eine unabhängige Validierung dieses Kontrasts ist daher besonders dringlich.

Die **größte Überraschung** liegt im Regulierungsvergleich: Anti-Regulierer haben den niedrigsten Machtkonzentrations-Wert aller 15 Gruppen (D07=2). Dies widerlegt das verbreitete Narrativ, Anti-Regulierer seien Vertreter von Konzerninteressen.

Kernbefund F5: Die drei stärksten Prädiktoren für das Weltbild sind die ideologische Grundhaltung, die institutionelle Rolle und das Geschlecht. Die polarisierendsten Dimensionen sind D11 und D07. Die *Machtfrage* ist der Kern der internen Differenzen.

4.6 F6 – Macht und Weltbild

Tabelle 7: Weltbild-Typen und Ressourcen-Kontrolle.

Typ	Avg	D11	D04	Ressourcen
I Architekt	7,8	2,8	6,3	Höchste
III Innovator	7,2	5,0	8,3	Hoch
IV Befreier	6,8	7,5	6,0	Mittel
II Hüter	6,4	7,2	9,0	Geringste

Je höher die Weltbild-Intensität, desto niedriger die Werte bei Menschenfreundlichkeit und Egalitarismus und desto höher die Machtkonzentrations-Akzeptanz. Das Investoren-Profil markiert den Extremfall: maximale Kontrollüberzeugung (D02=10) bei minimalem Verantwortungsgefühl (D04=4) – „Macht ohne Rechenschaft“. Die Top 10 liegen auf zehn von zwölf Dimensionen exakt einen Punkt über dem Kollektiv – mit einer entscheidenden Ausnahme: Menschenfreundlichkeit und Egalitarismus liegen *darunter*. Macht intensiviert alle Überzeugungen, außer jene, die Macht selbst in Frage stellen.

Kernbefund F6: Die Korrelation zwischen ökonomischer Macht und Weltbild-Extremität bei gleichzeitiger inverser Korrelation mit Egalitarismus und Verantwortung ist der demokratietheoretisch relevanteste Befund der Studie.

5. Diskussion

5.1 Zusammenfassung und Interpretation

Die KI-Elite vertritt einen *technologischen Messianismus mit struktureller Ambivalenz*. Die sechs Forschungsfragen fügen sich zu einem kohärenten Bild: F1 zeigt die „Doppelsenke“

bei D09 und D11; F2 offenbart die Erosion des Utopie-Komplexes; F3 liefert den brisantesten Einzelbefund (systematische Sagen-Handeln-Kluft); F4 identifiziert vier Typen mit antagonistischen Positionen; F5 und F6 vervollständigen das Bild durch das Macht-Gemäßigtheits-Paradox.

Überraschend ist erstens das Ausmaß der Sagen-Handeln-Kluft (nicht vereinzelte Abweichung, sondern funktionale Struktur); zweitens der Rückzug des Transhumanismus (widerlegt die gängige Annahme zunehmender posthumanistischer Orientierung); drittens die Existenz des Befreier-Typs (Opposition gegen Machtkonzentration auch von libertärer Seite).

5.2 Einordnung in den Forschungsstand

Morozovs Solutionismus-These findet eine nahezu vollständige Bestätigung (D05=8–9, D06=7–9). Allerdings ist der Solutionismus kein monolithischer Block: Risiko-Warner (D05=4) teilen ihn deutlich weniger. Er ist die Ideologie des mächtigsten Segments, nicht der KI-Elite schlechthin.

Daubs Analyse der philosophischen Tiefenstrukturen wird durch die narrativen Synthesen bestätigt. Was die vorliegende Studie hinzufügt, ist die *Quantifizierung* und die Demonstration, dass sich die Intensität systematisch mit der Machtposition verstärkt.

Die von Barbrook & Cameron (1996) diagnostizierte Californian Ideology findet in der Existenz des Befreier-Typs ihre zeitgenössische Entsprechung – empirisch nachweisbar fast dreißig Jahre später.

Coeckelberghs Annahme einer zunehmenden Enhancement-Orientierung wird partiell *widerlegt*: Der Rückgang des Transhumanismus (D10 von 10 auf 6) zeigt, dass die KI-Elite sich weniger für die Verbesserung des Menschen interessiert als für dessen Überbietung durch Maschinen.

Der spezifische Mehrwert gegenüber essayistischen Diagnosen liegt in drei Punkten: *Masse* (100 Personen, 16 Jahre), *Differenzierung* (vier distinkte Typen) und *Validierung* (Kongruenzanalyse als empirischer Test).

5.3 Methodische Reflexion

Die primäre Leistung der SWR liegt in der Verbindung qualitativer Tiefe mit quantitativer Systematik. Die Kongruenzanalyse (F3) fungiert als interner Validitätstest; die Stabilität des Kollektiv-Profils über 15 Gruppen-Synthesen und 4 Typen stärkt die Konvergenzvalidität. Die Grenzen der Methode – Kohärenzbias, Kontaminationsrisiko, Blindungslimits, Prompt-Sensitivität – werden im Companion Paper (Geiger, 2026) systematisch analysiert und gelten auch für die vorliegende Anwendungsstudie.

5.4 Gesellschaftliche und politische Implikationen

Das Macht-Gemäßigtheits-Paradox stellt eine konkrete Herausforderung für die Regulierungsarchitektur dar. Gegenwärtige Governance-Ansätze (EU AI Act, Executive Order on AI) adressieren die technischen Artefakte, nicht die Weltbilder, die diese Artefakte hervorbringen. Ein ergänzender Ansatz müsste die *epistemische Diversität* in KI-Führungspositionen als Regulierungsziel anerkennen.

Die systematische Sagen-Handeln-Kluft hat eine Policy-Implikation: Freiwillige Selbstverpflichtungen – die derzeit bevorzugte Governance-Form – sind unter diesen Bedingungen unzureichend. Verbindliche Strukturreformen wären wirksamer als weitere Runden freiwilliger Commitments.

Ist sich die KI-Elite ihrer eigenen blinden Flecken bewusst? Das Verantwortungsgefühl (D04=7) ist nicht absent, aber funktional eingebettet: Es legitimiert das Weiterarbeiten, nicht das Innehalten. Der Befund, dass demokratische Langsamkeit durchgängig als Hindernis, nicht als Schutzfunktion begriffen wird, markiert den gravierendsten blinden Fleck einer Gruppe, die darüber entscheidet, wie Milliarden Menschen in Zukunft leben werden.

6. Limitationen

6.1 Datenbezogene Limitationen

Quellenbias. Die Datenbasis beschränkt sich auf öffentliche Aussagen und beobachtbare Handlungen. Die rekonstruierten Weltbilder spiegeln das *öffentlich dargebotene* Weltbild wider, nicht das *tatsächlich geglaubte*. Die Kongruenzanalyse (Op4) bietet ein partielles Korrektiv, kann das Problem aber nicht eliminieren.

Zeitliche Ungleichverteilung. Für 2010–2015 liegen 2–5 Aussagen pro Person vor, für 2023–2026 dagegen 30–80. Das Kriterium K2 (Mindestgröße 15) und dokumentierte Zusammenlegungen mildern das Problem; frühere Zeitreihen bleiben mit größerer Unsicherheit behaftet.

Westlicher und Sprachbias. Die Stichprobe ist überproportional angloamerikanisch geprägt. Chinesische, japanische und südkoreanische KI-Persönlichkeiten sind unterrepräsentiert. Die Befunde gelten primär für die westliche KI-Elite.

6.2 Methodische Limitationen

SWR-Methode in Entwicklung. Die verwendete Synthetische Weltbild-Rekonstruktion (SWR) ist eine neuartige Methode, die in Geiger (2026) theoretisch entwickelt wurde, aber noch keine umfassende empirische Validierung an unabhängigen Datensätzen erfahren hat. Die vorliegende Studie ist eine erste Anwendung, die gleichzeitig als Proof-of-Concept für die Methode selbst dient. Zukünftige Forschung sollte die SWR an etablierten Benchmarks gegenüber klassischen qualitativen Verfahren evaluieren.

Zirkularitätsproblem und methodische Kontrollmaßnahmen. Ein grundsätzliches methodisches Problem besteht darin, dass LLMs Weltbilder aus Texten rekonstruieren, die möglicherweise Teil ihrer Trainingsdaten waren. Dies ist besonders problematisch für diese Studie, da viele der analysierten Personen (z. B. Yann LeCun, Demis Hassabis, Sam Altman) direkt an der Entwicklung oder dem Training der verwendeten LLMs beteiligt waren. Dies erzeugt ein fundamentales Zirkularitätsrisiko: Das LLM könnte vorgefertigte Interpretationen reproduzieren statt genuine Rekonstruktionsarbeit zu leisten.

Empirische Kontrollmaßnahmen. Um die Zirkularität quantifizierbar zu machen, haben wir fünf methodische Kontrollen konzipiert, die in zukünftigen Arbeiten systematisch durchgeführt werden sollen:

1. **Konsequente Anonymisierung:** Alle Identifikatoren (Namen, Organisationen, spezifische Projekte) werden aus dem Input-Korpus entfernt, bevor das LLM die Rekonstruktion durchführt. Damit wird direkte Kontamination verhindert.
2. **Blindierungs-Kontrollexperiment ($N = 20$ Personen):** Für eine Teilstichprobe von 20 Personen werden sowohl blindierte (Namen entfernt) als auch nicht-blindierte Rekonstruktionen durchgeführt. Die dimensionalen Scores werden verglichen. *Erwartung:* Bei echter Rekonstruktion sollten blindierte und nicht-blindierte Versionen hochkorreliert sein ($r \geq 0{,}80$). Falls $r < 0{,}60$, deutet dies auf substantielle Kontamination hin — die nicht-blindierte Version reproduziert vorgefertigte Frames statt genuine Analyse. *Falsifikationskriterium:* Falls $r < 0{,}50$ für $> 30\,\%$ der Stichprobe, ist die Methode kontaminiert und nicht valide.
3. **Inter-LLM-Divergenztest:** Rekonstruktionen werden mit mindestens drei verschiedenen LLMs durchgeführt (Claude Opus 4.6, GPT-4o, Gemini 1.5 Pro). *Hypothese bei Zirkularität:* Falls ein LLM vorgefertigte Interpretationen hat (z. B. Claude reproduziert Anthropics Sichtweise auf Dario Amodei), sollte dieses LLM *weniger* mit den anderen LLMs korrelieren. *Test:* Für jeden der 100 Fälle wird die paarweise LLM-Korrelation berechnet. Systematisch niedrige Korrelationen ($r < 0{,}60$) für spezifische LLM-Person-Kombinationen identifizieren Kontaminationsfälle.
4. **Temporal-Shift-Analyse:** Für 15 Personen mit ausreichend Daten werden separate Rekonstruktionen für 2010–2015 vs. 2020–2025 erstellt. *Zirkularitätshypothese:* Falls das LLM nur vorgefertigte Frames reproduziert, sollten die Rekonstruktionen temporal stabil sein (keine Veränderung). Falls genuine Rekonstruktion vorliegt, sollten sich die Weltbilder über Zeit verändert haben (z. B. Elon Musk 2010 vs. 2024). *Erwartung:* Mindestens 8/15 Personen zeigen substanzielle Verschiebung ($\Delta \geq 1{,}5$ Punkte auf mindestens 3 Dimensionen).
5. **Out-of-Distribution-Test:** Drei Personen aus der Stichprobe, die mit sehr hoher Wahrscheinlichkeit *nicht* in den Trainingsdaten moderner LLMs sind (z. B. jüngere, nicht-anglophone KI-Forscher aus Indien/Südamerika), werden als Kontrollgruppe analysiert. Falls die Rekonstruktionen für diese Personen substantiell schwächer sind (niedrigere Divergenzmetrik D,

höhere Inter-LLM-Varianz), deutet dies darauf hin, dass die Methode für bekannte Personen von Trainingswissen profitiert.

Epistemischer Status. Diese Kontrollmaßnahmen können die Zirkularität nicht eliminieren, aber quantifizierbar machen. **Die oben beschriebenen fünf Kontrollen sind als systematischer Validierungsrahmen konzipiert, wurden aber in der vorliegenden Studie noch nicht vollständig durchgeführt.** Die vorliegende Arbeit dient als initiale Anwendung der SWR-Methode; die umfassende empirische Validierung einschließlich aller Zirkularitätskontrollen ist Gegenstand einer geplanten Folgestudie. Die Studie erhebt daher keinen Anspruch auf kontaminationsfreie Rekonstruktion, sondern präsentiert explorative Befunde, deren Robustheit durch die beschriebenen Kontrollen zukünftig getestet werden muss. Die fundamentale Frage, inwieweit LLM-basierte Rekonstruktionen epistemisch valide sind, wenn das LLM selbst bereits über interpretative Frames verfügt, wird ausführlich in Geiger (2026) diskutiert.

Anthropic-interne Zirkularität. Ein besonders zugespitzter Fall des Zirkularitätsproblems betrifft die Rekonstruktion von Weltbildern derjenigen Personen, die direkt an der Entwicklung des verwendeten LLM beteiligt sind. Claude Opus 4.6 wird von Anthropic entwickelt; mehrere Anthropic-Führungskräfte (z. B. Dario Amodei, Daniela Amodei) gehören zur analysierten Stichprobe. Es ist unklar, ob die Rekonstruktion in diesen Fällen eine genuine Analyse der Datenpunkte oder ein vorgefertigtes internes Modell reflektiert. Der Inter-LLM-Divergenztest (Kontrolle 3) ist für diese Fälle besonders relevant: Falls Claude systematisch andere Rekonstruktionen für Anthropic-Führungskräfte liefert als GPT-4o oder Gemini, wäre dies ein starker Indikator für Kontamination. Bis diese Kontrolle durchgeführt ist, sind die Rekonstruktionen für Anthropic-nahestehende Personen mit erhöhter epistemischer Vorsicht zu interpretieren.

Kohärenzbias. LLMs tendieren dazu, aus widersprüchlichen Daten übermäßig kohärente Narrative zu erzeugen. Der Reflexionsschritt und die Inter-LLM-Vergleiche bieten partielle Korrektive.

Epistemologische Grenzen der Quantifizierung. Die in Abschnitt 4.2 berichteten Korrelationen zwischen Dimensionen (z. B. $r = +0{,}85$ zwischen D10 und D12) beschreiben Zusammenhänge zwischen Größen, die sämtlich vom selben LLM in einem zusammenhängenden Prompt-Kontext generiert wurden. Dies ist fundamental anders als Korrelationen zwischen unabhängig gemessenen Variablen. Die hohe Korrelation könnte interne LLM-Kohärenz reflektieren („wenn ich Posthumanismus hoch bewerte, bewerte ich auch Kontrollüberzeugung hoch“), nicht empirische Zusammenhänge in der Realität. Dasselbe gilt für Cluster-Strukturen und Gruppenvergleiche: Alle quantitativen Muster könnten Artefakte der internen Konsistenz des Modells sein. Die berichteten Korrelationen sind daher als *Muster innerhalb der LLM-Rekonstruktion* zu lesen, nicht als Belege für kausale oder empirische Zusammenhänge. Erst eine Inter-LLM-Triangulation oder eine externe Validierung könnte klären, welche Korrelationen robust sind.

Reproduzierbarkeit. LLM-Outputs sind auch bei Temperatur 0 nicht vollständig deterministisch. Für die vorliegende Studie wurden verwendet: **Claude Opus 4.6** (Anthropic, Stand:

Januar 2025), **Temperatur: 0.0**, **System-Prompt:** siehe Anhang A, **Runs pro Syntheseeinheit: 3**. Mindestens drei Runs pro SE sichern die Robustheit. Die vollständigen Prompts und Modellspezifikationen sind in den Supplementary Materials dokumentiert.

Validierungsstatus der Zirkularitätskontrollen. Die oben beschriebenen fünf Kontrollen (Anonymisierung, Blindierungs-Experiment, Inter-LLM-Divergenztest, Temporal-Shift-Analyse, Out-of-Distribution-Test) sind als systematischer Validierungsrahmen konzipiert, wurden aber in der vorliegenden Studie noch nicht umgesetzt. **Geplante Kontrollen:** Alle fünf Kontrollen sollen in einer Folgearbeit durchgeführt werden, um die Robustheit der SWR-Methode gegenüber dem Zirkularitätsrisiko empirisch zu prüfen. **Durchgeführte Kontrollen:** Die vorliegende Studie verwendet ausschließlich Claude Opus 4.6 mit konsistenten Prompts (Temperatur 0.0, drei Runs pro SE), aber ohne systematische Inter-LLM-Triangulation oder experimentelle Validierung. Die Befunde sind daher als explorative Pilotergebnisse zu verstehen, deren methodische Validität durch die geplanten Kontrollen noch zu demonstrieren ist.

6.3 Konzeptuelle Limitationen

Aggregationsproblem. Kollektive Synthesen glätten individuelle Variation. Die Netzwerk-Analyse (Op5) auf Individualebene bildet ein Korrektiv.

Keine Kausalerklärung. Die Studie beschreibt, *was* die KI-Elite denkt, nicht *warum*. Kausale Interpretationen sind spekulativ und erfordern andere Forschungsdesigns.

6.4 Forschungsethische Reflexion

Die vorliegende Studie rekonstruiert Weltbilder lebender, öffentlich identifizierbarer Personen ohne deren explizite Einwilligung. Dieses Vorgehen ist forschungsethisch begründungsbedürftig.

Legitimation. Die Studie stützt sich ausschließlich auf öffentlich zugängliche Äußerungen und dokumentierte Handlungen. Die 100 untersuchten Personen sind öffentliche Figuren (CEOs, Gründer, Forschungsleiter), deren berufliche Positionen und Aussagen zur KI-Entwicklung von erheblichem öffentlichem Interesse sind. Diese Bedingungen entsprechen den üblichen Kriterien für Forschung an öffentlichen Figuren ohne Informed Consent (vgl. APA Ethical Principles, Standard 8.05).

Risikominimierung. (a) Keine privaten, vertraulichen oder nicht öffentlich zugänglichen Informationen wurden erhoben. (b) Die Weltbild-Ratings sind methodische Abstraktionen, keine psychologischen Diagnosen. (c) Die Darstellung zielt auf kollektive Muster, nicht auf individuelle Diskreditierung.

Residualrisiko. Trotz dieser Vorkehrungen besteht das Risiko, dass LLM-basierte Rekonstruktionen Positionen überzeichnen oder verzerren. Die dreistufige Validierung (vgl. Abschnitt C) soll dieses Risiko minimieren, kann es aber nicht eliminieren. Fehlerhafte Zuschreibungen

könnten reputationsschädigend wirken. Künftige Forschung sollte erwägen, rekonstruierte Profile den Betroffenen zur Kommentierung vorzulegen (*member checking*).

7. Fazit und Ausblick

7.1 Fazit

Die Studie hat die Frage gestellt, was die KI-Elite denkt – und eine empirisch fundierte Antwort vorgelegt. Fünf übergreifende Erkenntnisse kristallisieren sich heraus:

Erstens: Die KI-Elite verfügt über ein kohärentes, empirisch rekonstruierbares Weltbild – technologischer Messianismus, Sendungsbewusstsein, Fortschrittsglaube.

Zweitens: Dieses Weltbild befindet sich in beschleunigter Transformation. Der Verlust utopischer Gewissheiten hat zu einem *tragischen Beschleunigungszwang* geführt: Man zweifelt an der Zukunft, die man baut, und baut sie dennoch.

Drittens: Die öffentlich kommunizierten Überzeugungen weichen systematisch vom Handeln ab – besonders beim Versprechen der Demokratisierung ($\Delta - 3$).

Viertens: Die Macht ist nicht weltbild-neutral verteilt. Sie konzentriert sich bei denjenigen, deren Überzeugungen am weitesten vom gesellschaftlichen Mainstream entfernt sind.

Fünftens: Die SWR hat sich als leistungsfähiges Instrument erwiesen, das qualitative Tiefe mit quantitativer Systematik verbindet (vgl. Companion Paper Geiger 2026).

7.2 Ausblick

Vier Richtungen für Anschlussforschung: (1) *Erweiterungsreserve:* Einzelperson-Synthesen für die Top 20, Cluster-Drift-Analysen, nicht-westliche KI-Eliten. (2) *Methodische Weiterentwicklung:* Multi-LLM-Triangulation mit fünf oder mehr Modellen, automatisierte Validierungsverfahren, standardisierte Gütekriterien. (3) *Transfer:* Finanz-Elite, politische Elite, militärische KI-Elite. (4) *Longitudinale Fortführung:* Jährliches Weltbild-Monitoring als Instrument demokratischer Kontrolle. Die Frage „Was denkt die KI-Elite?“ ist keine einmalige Frage. Sie ist eine Frage, die Demokratien kontinuierlich stellen müssen.

Offenlegungserklärung: Einsatz künstlicher Intelligenz

KI-Disclosure Level 5 (Extensiv). Bei der Erstellung dieser Studie wurde künstliche Intelligenz (Claude Opus 4.6, Anthropic) in erheblichem Umfang eingesetzt. Der KI-Einsatz umfasst: (1) Durchführung aller synthetischen Weltbild-Rekonstruktionen (Kern-Synthesen, Rating-Prompts, Vergleichsanalysen, Kreuzmodalvorhersagen); (2) statistische Aufbereitung und Visualisierung der Ergebnisse; (3) Unterstützung bei der Strukturierung und Formulierung des Manuskripts.

Forschungsdesign, Forschungsfragen, Datenerhebung, methodische Entscheidungen, Interpretation der Ergebnisse und alle inhaltlichen Schlussfolgerungen stammen vom Autor. Sämtliche Prompts, API-Parameter und Modellversionen sind im Anhang dokumentiert.

Literatur

Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, *6*(1), 44–72.

Bengio, Y., Hinton, G. & others (2024). Managing extreme AI risks amid rapid progress. *Science*, *384*(6698), 842–845.

Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.

Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.

Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, *14*(1), 1–25.

Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.

Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.

Bubeck, S., Chandrasekaran, V. & others (2023). Sparks of artificial general intelligence: Early experiments with GPT-4. *arXiv:2303.12712*.

Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.

Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.

Ge, S. & others (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*.

Geiger, L. (2026). Synthetische Weltbild-Rekonstruktion: Ein LLM-gestütztes Verfahren zur Analyse latenter Überzeugungssysteme. *Companion Paper / Preprint*.

Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

Hayes, R. A. (2025). Conversational approaches to qualitative data analysis with LLMs. *Qualitative Research*, forthcoming.

Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, *29*, 105–110.

Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.

Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.

Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.

More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.

More, M. & Vita-More, N. (Hrsg.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.

Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.

Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.

Nicmanis, M. & Spurrier, K. (2025). AI-assisted qualitative analysis: A practical guide. *International Journal of Qualitative Methods*, *24*, 1–15.

Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.

Tai, R. & others (2024). Using large language models for deductive coding of interview data. *Journal of Mixed Methods Research*, forthcoming.

Torres, É. P. & Gebru, T. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through AGI. *First Monday*, *29*(4).

Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

Weber, M. (1904). Die „Objektivität“ sozialwissenschaftlicher Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, *19*, 22–87.

A. Sampling-Methode der 100 KI-Akteure

Die Stichprobe wurde durch ein dreistufiges Verfahren erstellt:

Stufe 1: Kandidatenidentifikation. 22 systematische Webrecherchen in den Kategorien „Top AI researchers“, „Most influential people in AI“, „AI CEOs and founders“, „AI policy makers“, „AI ethics leaders“ und „AI critics“ ergaben 187 Kandidatinnen und Kandidaten. Quellen umfassten Forbes, MIT Technology Review, Time 100 AI, Wired, Nature Machine Intelligence, Stanford HAI und einschlägige Medienberichte.

Stufe 2: Einfluss-Scoring. Jede Person wurde auf sechs Dimensionen (Skala 0–10) bewertet: (i) Marktkapitalisierung/Ressourcenkontrolle (Firmenwert, Forschungsbudget, Datenzugang), (ii) technologische Schlüsselpositionen (CEO, CTO, Research Director, Chefarchitekt relevanter Systeme), (iii) öffentliche Diskursmacht (Medienpräsenz, Social-Media-Reichweite, Keynote-Einladungen), (iv) akademischer Einfluss (h-Index, Zitationen, Preisträger), (v) politische Einflussnahme (Regierungsberatung, Lobbying, Anhörungen), (vi) symbolischer Status (kulturelle Ikonizität, Wiedererkennung außerhalb der Fachcommunity). Die Dimensionen wurden gleichgewichtet; der Gesamtscore ergibt sich als arithmetisches Mittel. Das Scoring wurde durch den Erstautor durchgeführt und durch LLM-gestützte Plausibilitätsprüfung gegengeprüft.

Stufe 3: Reduktion und Quotierung. Die 187 Kandidaten wurden nach Gesamtscore absteigend sortiert. Die Reduktion auf 100 erfolgte unter drei Nebenbedingungen: (a) mindestens 15% Frauen (erreicht: 18%), (b) mindestens 4 Rollengruppen vertreten (Unternehmer, Forscher, Regulierer, Kritiker; erreicht: 6 Rollen), (c) bei Score-Gleichstand wurde die Person mit größerer demographischer Diversität bevorzugt. Der niedrigste aufgenommene Gesamtscore betrug 4,2/10.

Die finale Stichprobe umfasst 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte). Eine vollständige Liste der 100 Personen mit Scoring-Werten ist im Supplementary Material verfügbar.

B. Die 12 Rating-Dimensionen (D01–D12)

Dim.	Name	Pol 1 (=1)	Pol 10 (=10)
D01	Sendungsbewusstsein	Kein Auftrag	Messianisch
D02	Selbstwirksamkeit	Ohnmacht	Omnipotent
D03	Arbeitsethos	Distanz	Totale Identifikation
D04	Verantwortungsgefühl	Keines	Weltverantwortung
D05	Techno-Determinismus	Neutral	Bestimmt alles
D06	Fortschrittsglaube	Niedergang	Goldene Zukunft
D07	Machtkonzentration	Radikal verteilen	Bei Experten

Dim.	Name	Pol 1	Pol 10
D08	Dringlichkeit	Entspannt	Existenzieller Druck
D09	Menschenfreundlichkeit	Ersetzbar	Einzigartig
D10	Posthumanismus	Mensch bleibt	Mensch wird mehr
D11	Egalitarismus	Ungleichheit natürlich	Gleichheit anstreben
D12	Kontrollüberzeugung	Pessimismus	Volle Kontrolle

C. Reduktionskriterien (K1–K9)

K	Typ	Beschreibung
K1	obligatorisch	Fragestellungsbindung: Jede SE muss ≥ 1 Forschungsfrage zugeordnet sein
K2	obligatorisch	Mindestgröße: ≥ 15 Datenpunkte pro SE
K3	obligatorisch	Redundanzverbot: Echte Teilmengen werden eliminiert
K4	Prinzip	Modalitäts-Sparsamkeit: A/H-Trennung nur für F3
K5	Prinzip	Zeitliche Sparsamkeit: Jahres-SE nur für F2
K6	Prinzip	Gruppensparsamkeit: Nur a-priori-begründete Gruppen
K7	Prinzip	Stufenweise Erweiterung: Kern zuerst
K8	Prinzip	Aggregationsfokus: Keine Einzelperson-SE
K9	Prinzip	Cluster-Verschmelzung: Bottom-Up ersetzt a-priori

Bilanz: $\sim$1.227 theoretische SE $\rightarrow$ $\sim$51–56 Kern-SE (Reduktion $\sim$95 %).

D. Liste der Syntheseeinheiten

Das Kern-Design umfasst 43 vordefinierte plus $\sim$8–13 emergente Syntheseeinheiten:

Nr	SE-ID	UV-Kombination	F
1	GA_ges_AH	Alle, AH, Gesamt	F1a
2	GA_ges_A	Alle, nur A, Gesamt	F3a
3	GA_ges_H	Alle, nur H, Gesamt	F3a
4	T10_ges_AH	Top 10, AH, Gesamt	F1b

5	HOM_haeuf_A	Alle, häufig wiederholte A	F1c
6–22	GA_YYYY_AH	Alle, AH, pro Jahr	F2a
23–26	GA_Epoche_AH	Alle, AH, 4 Epochen	F2b
27–30	GR_*_AH	CEOs, Akad., Inv., Gründer	F5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	F5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	F5b–f
40–41	GD_*_AH	Frauen, Männer	F5e
42–43	KG_*_AH	Konsistent, Widerspruchlich	F3c

Zusätzlich: 36 kreuzmodale Runs (Op4), 10 Vergleichs-Runs (Op6), ∼199–214 Prompt-Runs gesamt.