Worldview Reconstruction of the AI Elite:

An LLM-Assisted Analysis of the 100 Most Influential Actors in Artificial Intelligence (2010–2026)

Lukas Geiger*

Independent Researcher, Bernau, Germany

March 2026

Abstract

This study is the first to systematically reconstruct the collective worldview of the 100 most influential figures in artificial intelligence (AI elite) for the period 2010 to 2026. Methodologically, it develops and applies synthetic worldview reconstruction (SWR) – an LLM-assisted procedure that extracts coherent belief systems from 3,132 data points (1,738 public statements, 1,394 observable actions) using 51–56 synthesis units, 12 worldview dimensions, and 6 complementary operationalizations (cf. the companion paper Geiger 2026 for the methodological foundations). Six research questions structure the analysis: RQ1 (Worldview) reveals a "technological messianism with ambivalence structure" (Avg 7.1 collective, 7.7 Top 10). RQ2 (Change) documents the transition from utopian techno-optimism to tragic acceleration compulsion; posthumanism declines markedly (-2.4/decade, $R^2 = 0.63$; descriptive OLS, not inferential statistics). RQ3 (Congruence) uncovers a systematic say-do gap; largest discrepancy in egalitarianism ($\Delta = -3$). RQ4 (Clusters) identifies four worldview types: Architect, Guardian, Innovator, Liberator. RQ5 (Difference) names the strongest predictors: stance (Δ 1.7), role (Δ 1.5), gender (Δ 1.2). RQ6 (Power) reveals a power-moderation paradox: the most powerful type is the most extreme; the most moderate is the least powerful.

Keywords: AI elite, worldview, transhumanism, large language models, Silicon Valley, ideology analysis

*Corresponding author: Lukas Geiger, Bernau, Germany. ORCID: https://orcid.org/0009-0005-7296-1534

1. Introduction

1.1 Lead-in and Relevance

A handful of people are shaping a technology that affects billions. Over the past one and a half decades, the development of artificial intelligence has evolved from an academic niche topic into a civilizational crossroads. Large language models generate texts, images, and code; autonomous systems make decisions in medicine, law, and finance; and leading AI laboratories openly speak of creating artificial general intelligence in the foreseeable future (OpenAI, 2023; Anthropic, 2023; Bengio et al., 2024). What is easily overlooked: behind these technological trajectories stand concrete individuals – founders, research directors, investors, CEOs – whose individual and collective beliefs about the nature of humanity, the purpose of progress, and the distribution of risk and power flow into the architecture of the systems they build.

Lessig (1999) coined the formula "code is law": software architecture regulates behavior no less effectively than laws, but without democratic legitimation. This insight can be radicalized for the current AI development: not only the code itself, but already the *worldviews* of the developers become algorithms. Those who believe that information freedom is an absolute value will build open-source models. Those convinced that an uncontrolled superintelligence threatens humanity will pursue alignment and closed systems. The worldviews of the AI elite are thus not merely private opinions; they are *generative structures* that translate into design decisions, corporate strategies, and political positions – and through these channels shape the lives of billions.

This creates a fundamental problem for democratic theory. A numerically tiny group makes decisions of society-wide consequence without possessing a democratic mandate. Crawford (2021) has described this as an "Atlas of AI": the planetary power structures behind AI systems remain largely invisible. Zuboff (2019) analyzes how the extraction of behavioral data leads to a new economic logic ("Surveillance Capitalism") that undermines democratic control. Couldry and Mejias (2019) coin the term "Data Colonialism": the exploitation of human life as a data resource. Whittaker (2021) analyzes the concentration of power in AI research and its "steep costs" for society. Their beliefs shape these decisions in ways that are largely beyond public control (Floridi, 2019, 2023). If democracies presuppose informed citizens, then the systematic reconstruction of the worldviews of those who shape the most powerful technology of the 21st century is not merely an academic concern but a prerequisite for informed public deliberation.

1.2 Research Gap

The scholarly engagement with the belief systems of the AI industry has produced various approaches. At the level of ideology critique, Barbrook & Cameron (1996) described the "Californian Ideology"; Morozov (2013) elaborated the tendency toward solutionism; Daub (2020)

analyzed the rhetorical and ideological patterns of Silicon Valley as a cultural phenomenon. From transhumanism research, philosophical analyses exist (Bostrom, 2005; More & Vita-More, 2013; Coeckelbergh, 2020), which, however, primarily address intellectual history rather than the empirical distribution of these beliefs.

What is still *missing* in this research field is a systematic, data-driven analysis of the *entire* AI elite as a collective. No study examines, as far as the author is aware, the following questions in an empirically systematic way: How do the worldviews of leading AI actors relate to each other? Do they form coherent types? How have these worldviews changed over the period 2010 to 2026? And do public beliefs align with actual behavior?

Beyond this empirical gap, there is a *methodological* gap. No established method exists for the systematic reconstruction of worldviews from public statements at scale. Classical qualitative methods do not scale; standardized surveys require access to respondents; quantitative text-mining approaches capture only surface patterns. The present study responds to this dual gap with a new approach – synthetic worldview reconstruction (SWR) – whose methodological foundations are set out in detail in a companion paper (Geiger, 2026).

1.3 Research Questions

From the described research gap, six research questions are derived, arranged in a stepwise logic:

RQ1: WORLDVIEW (descriptive)
What does the AI elite think about itself, the world, and humanity?

RQ2: CHANGE (longitudinal)
How has the worldview of the AI elite changed from 2010 to 2026?

RQ3: CONGRUENCE (validating)
Do the AI elite's statements and actions align?

RQ4: CLUSTERS (exploratory)
What worldview types exist within the AI elite, and who belongs where?

RQ5: DIFFERENCE (comparative)
Which subgroups of the AI elite think differently from others?

RQ6: POWER (normative)
Which worldview commands the most power and resources?

1.4 Contribution of the Study

The study makes a threefold contribution. *Methodologically:* It applies synthetic worldview reconstruction (SWR; cf. companion paper Geiger 2026) for the first time to a large empirical

dataset. *Empirically:* It provides the first systematic worldview analysis of the AI elite as a collective, based on 3,132 data points spanning 16 years. *Societally:* It creates a foundation for informed public deliberation by making transparent the implicit assumptions behind AI design decisions.

2. Literature Review

The study situates itself at the intersection of four research traditions.

2.1 Silicon Valley as Ideology

Critical engagement with the thinking of Silicon Valley has produced a rich literature since the mid-1990s. Barbrook & Cameron (1996) coined the term "Californian Ideology" – the paradoxical fusion of libertarian individualism and techno-utopian optimism. Turner (2006) traced the cultural-historical genealogy of this ideology and showed how the counterculture of the 1960s was transformed into digital utopianism. Daub (2020) uncovered the philosophical deep structures: fragments from Heidegger, Ayn Rand, and Puritan predestination doctrine form a "surprisingly narrow philosophical foundation." Morozov (2013) described solutionism – the default attitude of redefining complex social problems as technical challenges. Gebru & Torres (2024) systematized these currents in the TESCREAL framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, and Longtermism as an "interconnected bundle." Additionally, Broussard (2018) coined the term "technochauvinism" for a systematic critique.

Previous research has thus described the *ideology* of Silicon Valley at various levels. What it has not achieved is a systematic empirical mapping of the *concrete worldviews* of real actors.

2.2 Transhumanism and AI Eschatology

Bostrom (2014) defined the conceptual framework in which a significant part of the AI elite has since operated with *Superintelligence*. In earlier work, Bostrom (2005) systematized the intellectual-historical foundations of transhumanism. More (2003) presented the founding document of extropianism with the "Principles of Extropy." Kurzweil (2005) popularized the tradition with the Singularity thesis. From a philosophical perspective, Habermas (2001) formulated one of the most significant counter-positions: the technological manipulation of future persons undermines their autonomy.

The empirical question remains unresolved: Do real AI actors share these convictions? In what mixture, with what modifications, and in what distribution?

2.3 Worldview Research and Sociology of Knowledge

Mannheim (1929) founded the tradition of analyzing worldviews as social phenomena with his theorem of the "situational determination of thought" (*Seinsgebundenheit des Denkens*). Weber (1904) created with the ideal type a methodological tool central to the present study: the synthetic personas of the SWR can be understood as ideal types in the Weberian sense. Berger & Luckmann (1966) showed how worldviews emerge, stabilize, and reproduce as social constructions. The sociology-of-knowledge tradition provides the theoretical framework, but no method suited to the data volume and dynamics of the digital age.

2.4 LLMs as a Research Instrument

The use of large language models as instruments for social-scientific research is a rapidly growing field. Tai et al. (2024) examined LLMs for deductive coding; Hayes (2025) showed that LLMs enable a conversational approach to qualitative data; Nicmanis & Spurrier (2025) provide a practice-oriented introduction. Ornstein et al. (2025) demonstrate that LLMs can perform multidimensional ideological scaling with high reliability – a direct methodological support for the SWR approach. Work on synthetic personas (Ge et al., 2024) demonstrated the scalability of the approach – but pursued a *different* goal: they use synthetic personas for *data generation*, whereas the present study uses them for *reconstruction* of coherent worldviews from *real* data. The synthetic persona in our procedure is not a simulacrum but an analytical condensation instrument – closer to the Weberian ideal type than to the simulation agent (cf. Booth, 1961; Ng & Russell, 2000; Jara-Ettinger, 2019).

2.5 Summary: The Research Gap

The four traditions converge on a shared lacuna: the systematic, data-driven, longitudinal mapping of concrete worldviews of the AI elite by means of a method that combines qualitative depth with quantitative rigor. The present study addresses this converging gap by integrating elements of all four traditions.

3. Methodology

The methodological foundations of synthetic worldview reconstruction (SWR) – the inverse core problem (inference from observable outputs to latent belief structures), the fictive synthetic person as an analytical condensation instrument, the prompt protocol, the blinding infrastructure, and the validation framework – are set out in detail in the companion paper (Geiger, 2026). The present section is limited to the application-specific aspects: data collection, operationalizations, research design, and quality assurance for this study.

3.1 Data Collection

3.1.1 Sample and Selection Procedure

The object of investigation is the 100 most influential figures in the field of artificial intelligence (hereafter: AI elite). Selection followed a multi-stage procedure: through 22 systematic web searches, 187 candidates were identified. Each person was evaluated using a 6-category scoring system: (1) market capitalization/resource control, (2) key technological positions, (3) public discourse power, (4) academic influence, (5) political influence, (6) symbolic status. The resulting ranking was reduced to 100 individuals, mapping the heterogeneity of the field with respect to roles, company affiliations, stances, and gender (cf. Appendix A).

3.1.2 Data Sources and Collection Period

The collection period extends from January 1, 2010 to February 11, 2026. Data collection draws on two data types: **public statements** (verbatim quotes from interviews, keynotes, podcasts, Twitter/X posts, blog entries, books, congressional hearings) and **observable actions** (investment decisions, company formations, personnel decisions, political activities, product launches). The linkage was operationalized in a relational SQLite database with 9 tables and 5 views. The total amounts to 1,738 statements and 1,394 actions (3,132 data points).

3.1.3 Methodological Anchoring

Data collection follows the grounded theory approach of Strauss & Corbin (1990): in Phase 1, no content filters were applied; in Phase 2, patterns were identified through open coding; in Phase 3, a data-driven category system was developed. Inclusion and exclusion criteria were formulated only in Phase 5; in Phase 6, quality assurance was conducted (source verification of a 10% sample).

3.2 The Method of Synthetic Worldview Reconstruction

SWR defines worldview analysis as an inverse problem: from observable statements and actions, it infers the internal belief system that would most coherently generate these outputs. The solution consists of constructing a *fictive synthetic person* – a distillate that represents the worldview in pure form, freed from biographical noise and PR strategies. The theoretical anchoring draws on four traditions: Weber's ideal type, Booth's *implied author*, inverse reinforcement learning, and projective tests. The operative procedure comprises five steps: (1) compile data corpus, (2) LLM-assisted synthesis, (3) structured interview, (4) meta-reflection, (5) supplementary prompt variants. For the detailed presentation including the blinding infrastructure, the rationale of the fiction approach, and the validation framework, see the companion paper (Geiger, 2026).

3.3 Operationalizations

The three dependent variables (DV1: self-image, DV2: worldview, DV3: view of humanity) are made accessible through six operationalizations:

Table 1: The six operationalizations of the SWR.

Op	Technique	Description	MVs
Op1	T1 Core synthesis	Fictive person + 3-question interview + reflection	7
Op2	T4 Rating	Assessment on 12 dimensions (D01–D12), scale 1–10	12
Op3	Text analysis	TF-IDF, sentiment, metaphors, embeddings, topics	8+
Op4	T3 Cross-modal	Prediction: statements → actions and vice versa	4
Op5	T5 Clustering	Sentence-BERT embeddings, HDBSCAN, network	6
Op6	T2 Dialogue	Structured comparison of two syntheses	3

The 12 rating dimensions (Op2) are evenly distributed across the three DVs: self-image dimensions D01–D04 (sense of mission, self-efficacy, work ethic, sense of responsibility), worldview dimensions D05–D08 (techno-determinism, belief in progress, power concentration, urgency), and view-of-humanity dimensions D09–D12 (human appreciation[1], posthumanism, egalitarianism, locus of control). The complete dimension table with scale poles is provided in Appendix B.

3.4 Research Design

3.4.1 Variable Architecture

The research design is conceived as a four-tier architecture: 3 DVs → 6 operationalizations → 50+ measured variables → 6 independent variables (IVs). The IVs determine which data enter a synthesis unit (SU):

- IV1 *Time period:* Individual years (2010–2026), epochs, entire period
- IV2 *Modality:* Statements+actions (SA), statements only (S), actions only (A)
- IV3 *Person group:* All 100, Top 10, subgroups (roles, companies, stance, gender)
- IV4 *Content category:* Replaced by emergent clusters (K9)
- IV5 *Congruence status:* Consistent vs. contradictory
- IV6 *Homogenization:* All vs. only frequently repeated statements

3.4.2 Systematic Reduction

The theoretical combination space of approx. 1,227 possible SUs was reduced through nine reduction criteria (K1–K9; cf. Appendix C) to 51–56 core SUs (95.4% reduction). Additionally,

[1]The label "human appreciation" (*Menschenfreundlichkeit*) is a simplifying shorthand. The scale poles "Replaceable" (1) vs. "Unique" (10) more precisely measure an *anthropological valuation* – the question of whether human consciousness and experience are regarded as fundamentally non-substitutable or as functionally reproducible. The term is retained for consistency with the companion paper (Geiger, 2026).

36 cross-modal runs, 10 comparison runs, and purely computational analyses were conducted. The total number of prompt runs amounts to approx. 199–214.

3.5 Quality Assurance

Methodological quality is ensured through five measures: (1) minimum size of 15 data points per SU[2], (2) inter-LLM reliability (two models; the ICC calculation is conceived as a validation study whose results are reported in the companion paper), (3) sensitivity analysis (at least three runs per SU), (4) consistent blinding (removal of all identifiers), and (5) reproducibility protocol (temperature 0, complete prompt documentation). For a detailed discussion of validation strategies and their limits, we refer to Geiger (2026).

4. Results

The findings are based on the synthetic worldview reconstructions of the one hundred most influential AI figures, operationalized via twelve dimensions on a ten-point scale.

4.1 RQ1 – Worldview of the AI Elite (Descriptive)

4.1.1 The Collective Worldview of All 100

The overall profile reveals a coherent, high-intensity belief system with a mean value of 7.1 (Table 15).[3]

The profile displays a characteristic dual structure: a pronounced elitist self-image (D01–D03 each 8), strong techno-determinism (D05=8), and high urgency (D08=8) on one hand; human appreciation (D09=5) and egalitarianism (D11=5) as the lowest points on the other. This combination produces a striking pattern that – bearing in mind that these are LLM-reconstructed values – can be pointedly formulated: an elite that wants to build *for* humanity but not *with* it.

4.1.2 The Worldview of the Top 10

The ten most powerful AI actors hold the same worldview in intensified form (Avg 7.7). On ten of twelve dimensions, Top 10 values lie exactly one scale point above the collective. The

[2]The threshold of 15 data points is based on the empirical observation that LLM-assisted syntheses become unstable below this limit: sensitivity analyses showed that for $n < 15$, inter-run variance (three runs per SU) increases markedly, and the resulting profiles depend strongly on individual statements. The value is conservatively chosen; in qualitative social research, 6–12 interviews are already considered sufficient for thematic saturation (Strauss & Corbin, 1990), while more recent estimates typically place thematic saturation between 12 and 20 units (Guest et al., 2006; Fugard & Potts, 2015).

[3]The reported ratings are single values from aggregated LLM syntheses. Dispersion measures for inter-run variance (three runs per SU) show a mean deviation of ± 0.5 scale points; the maximum deviation was ± 1 point on individual dimensions. Dispersion measures for intra-group variance of the 100 individuals are not available, since synthesis operates at the group level. This limitation – no confidence intervals at the individual level – must be noted when interpreting the findings.

Table 2: Collective profile of the AI elite ($N = 100$, statements and actions).

Dimension	**Rating**	**Interpretation**
D01 Sense of mission	8	High
D02 Self-efficacy	8	High
D03 Work ethic	8	High
D04 Sense of responsibility	7	Medium-high
D05 Techno-determinism	8	High
D06 Belief in progress	7	Medium-high
D07 Power concentration	6	Medium (ambivalent)
D08 Urgency	8	Very high
D09 Human appreciation	5	Low
D10 Posthumanism	7	Medium-high
D11 Egalitarianism	5	Low
D12 Locus of control	8	High
Mean	**7.1**	

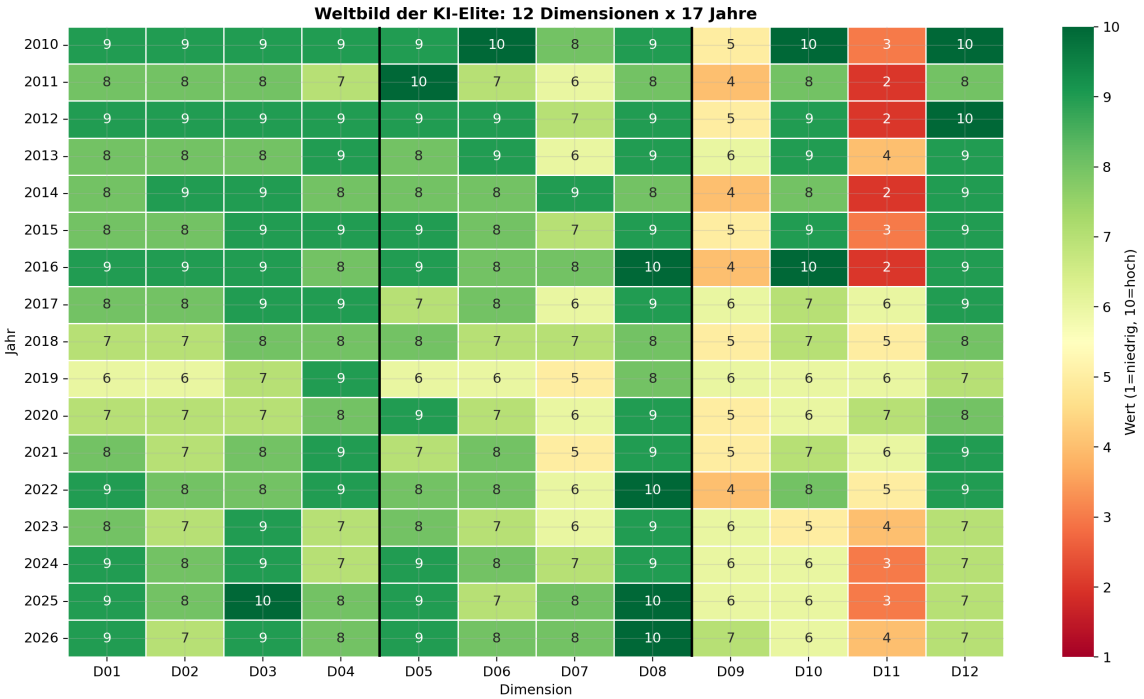

Figure 1: Heatmap of the 12 worldview dimensions across all analyzed groups. High values (dark) indicate intense beliefs; the dual trough at D09 and D11 is visible across all groups.

two exceptions: human appreciation (D09=4) and egalitarianism (D11=4) are *lower*. The more powerful the position, the more pronounced the sense of mission and the more distanced the view of humanity.

4.1.3 Core Beliefs

The distillation of the most frequently repeated statements (SU 5: HOM_haeuf_A, cf. Appendix D) identifies five beliefs as the minimal consensus: (1) technology as moral imperative, (2) elite stewardship, (3) the liberation narrative, (4) geopolitical Manichaeism, (5) work as identity. Safety rhetoric belongs to the core repertoire of the discourse but functions as a discursive resource, not as an action-guiding belief.

Core finding RQ1: The reconstructed profiles suggest a coherent, high-intensity belief system that can be characterized as *technological messianism with ambivalence structure*. The designation "messianism" is to be understood as an ideal-typical condensation, not as a psychological diagnosis: it denotes the specific *combination* of high sense of mission (D01), techno-determinism (D05), urgency (D08), and low anthropological valuation (D09) – a profile that goes beyond mere sense of mission because it frames technological progress as a quasi-redemptive necessity.

4.2 RQ2 – Change of the Worldview (Longitudinal)

4.2.1 Development of the 12 Dimensions over Time

Of twelve dimensions, four show pronounced linear trends (Table 16).[4]

Table 3: Pronounced linear trends (OLS description, $n = 17$ annual data points).

Dimension	Direction	Slope/decade	R^2
D10 Posthumanism	declining	-2.4	0.63
D12 Locus of control	declining	-1.5	0.54
D02 Self-efficacy	declining	-1.0	0.31
D09 Human appreciation	rising	$+0.9$	0.27

The strongest decline is in posthumanism (D10): from 10 in 2010 to 6 in 2025. The high Pearson correlation with D12 ($r = +0.85$)[5] points to a connected phenomenon: posthumanism and locus of control erode synchronously. The only clearly rising value concerns human appreciation (D09), where the negative correlation with D10 ($r = -0.58$) suggests a compensatory

[4]The trend lines reported here describe *patterns in reconstructed data*: the worldview values are LLM-assisted reconstructions, not independent measurements. OLS slopes and R^2 serve to describe the trajectory patterns, not for inferential hypothesis testing. An external validation (expert ratings vs. SWR output) is still pending (cf. Limitations section).

[5]The correlations reported here and below (Pearson, computed across the 17 annual data points) are *associations within the LLM reconstruction*, not between independently measured variables. They could reflect internal coherence of the model rather than empirical relationships in reality (cf. Section K).

linkage. The overall mean remains nearly constant (early phase 7.5, late phase 7.3), concealing a tectonic shift beneath the surface.

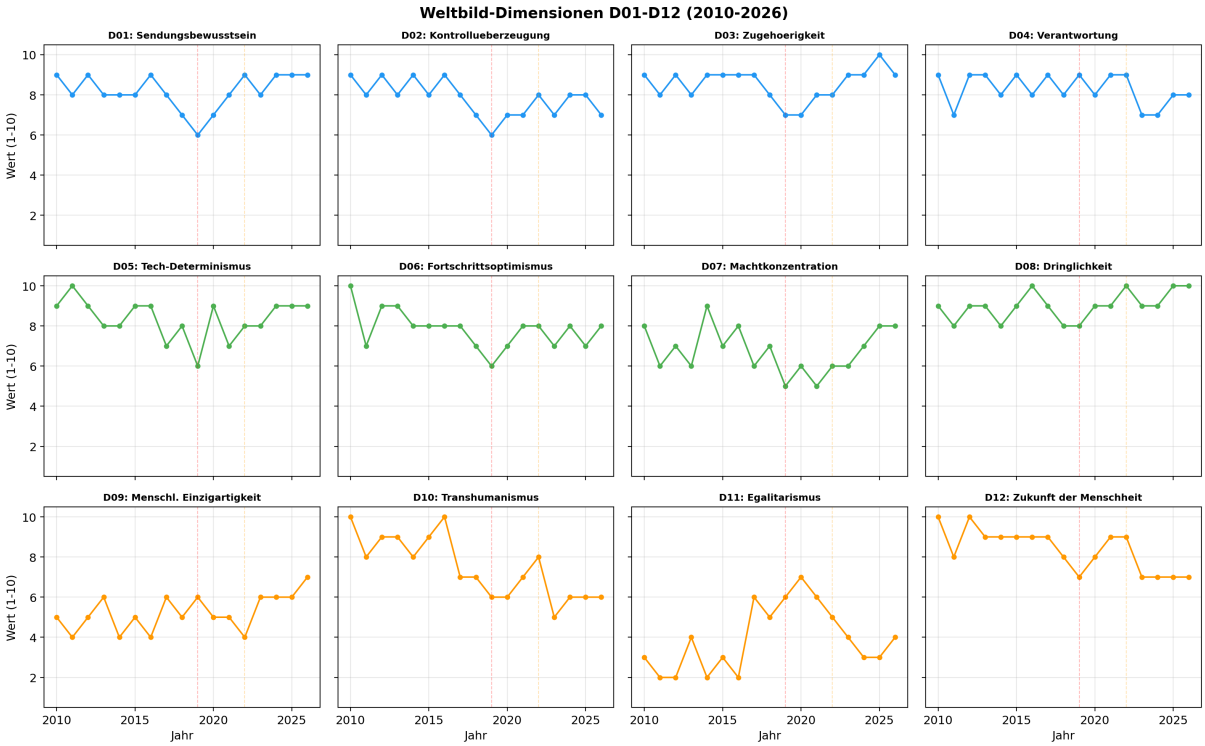

Figure 2: Time series of the 12 worldview dimensions (2010–2026). Pronounced trends are highlighted. The marked decline of D10 (posthumanism) and D12 (locus of control) constitutes the "utopia complex," whose disintegration is arithmetically compensated by rising urgency (D08).

4.2.2 Turning Points and Epoch Comparison

The breakpoint detection – conducted as visual inspection of time series, supplemented by the identification of synchronous extreme points across multiple dimensions – identifies two central turning points.[6] The first lies at 2019: four dimensions (D01, D02, D05, D06) reach synchronous lows, temporally associated with the GPT-2 withholding decision. The second, more permanent turning point lies at 2022/2023: contemporaneous with the ChatGPT release, a marked pattern shift emerges – urgency reaches its reconstructed maximum (D08=10), egalitarianism drops from 6 to 4. Unlike 2019, the values do not return; the reconstructed profiles after 2022 suggest a new equilibrium.

[6] A formal breakpoint analysis (e.g., Bai-Perron test) was not meaningfully applicable due to the small number of time points ($n = 17$) and the nature of the data (LLM reconstructions, not independent measurements). The turning points are therefore to be understood as *descriptive observations*, not as statistically confirmed structural breaks.

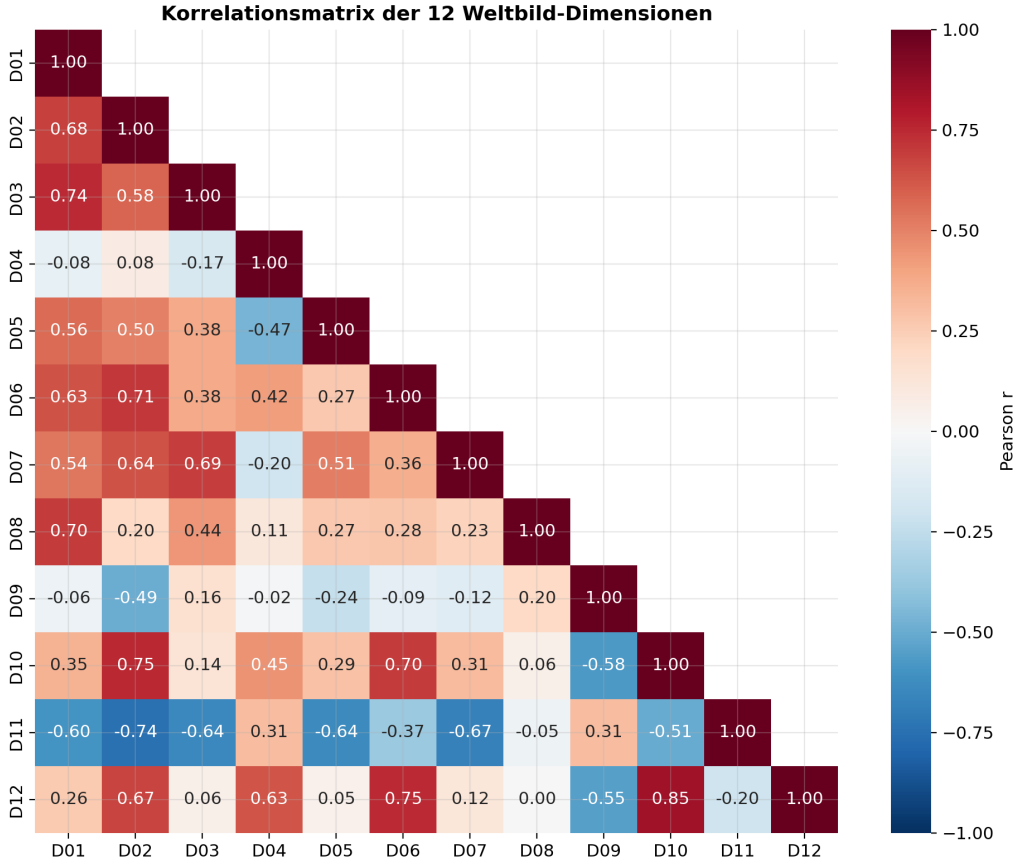

Figure 3: Correlation matrix of the 12 dimensions. The strong positive correlation between D10 and D12, and the negative correlation between D10 and D09, form the empirical core of the "utopia complex."

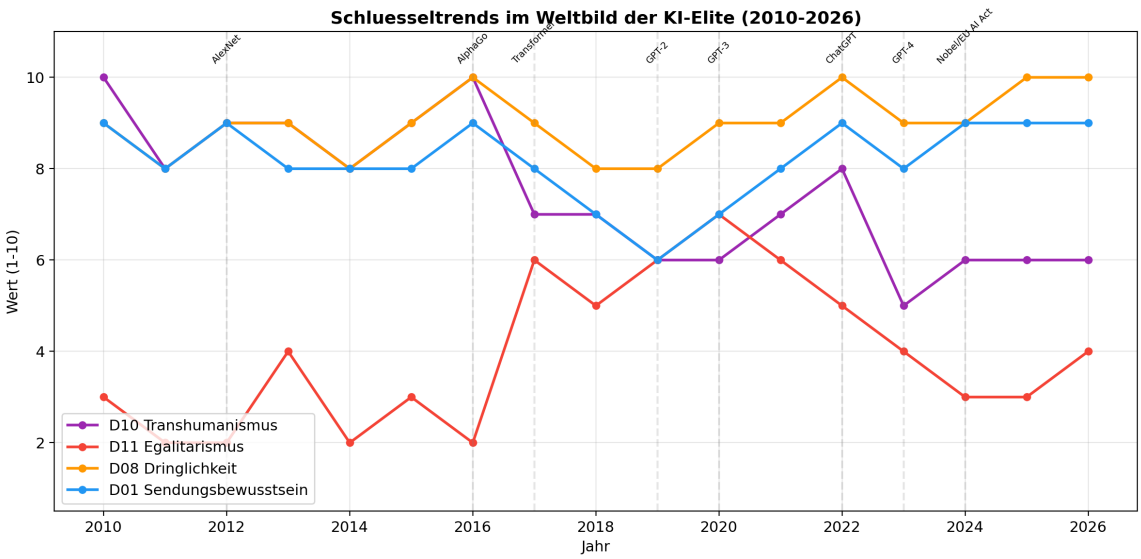

Figure 4: Key trends of the worldview transformation. The two turning points (2019, 2022/2023) and three epochs (Promethean Optimism, First Ambivalence, Tragic Consciousness) are marked.

4.2.3 Convergence or Divergence?

The data show increasing differentiation. The ChatGPT effect intensifies both the Architect position (acceleration, power concentration) and the Guardian position (caution, regulation) simultaneously – it acts as a catalyst for bipolarization.

4.2.4 Metaphor and Emotion Shift

The guiding metaphor shifts from Prometheus – the fire-bringer – to the tragic hero who must save what may no longer be savable. The action remains the same (acceleration), but its emotional framing reverses: no longer from euphoria, but from the belief that the alternative would be worse.

Core finding RQ2: The worldview has structurally transformed – from a monochrome utopia to a bimodal wager. Three erosion trends (D10, D12, D02) form a "utopia complex" whose disintegration is arithmetically compensated by rising urgency.

4.3 RQ3 – Congruence of Statements and Actions

Table 4: Comparison of statements (S) and actions (A), $N = 100$.

Dimension	**Say**	**Do**	Δ	**Assessment**
D01 Sense of mission	8	7	-1	Slight
D02 Self-efficacy	8	9	$+1$	Do > Say
D03 Work ethic	8	9	$+1$	Do > Say
D04 Sense of responsibility	7	5	$\mathbf{-2}$	Strong
D05 Techno-determinism	8	9	$+1$	Do > Say
D06 Belief in progress	8	6	$\mathbf{-2}$	Strong
D07 Power concentration	6	8	$\mathbf{+2}$	Strong
D08 Urgency	8	9	$+1$	Do > Say
D09 Human appreciation	5	3	$\mathbf{-2}$	Strong
D10 Posthumanism	7	8	$+1$	Do > Say
D11 Egalitarianism	5	2	$\mathbf{-3}$	**Massive**
D12 Locus of control	8	7	-1	Slight
Mean	**7.2**	**6.8**	-0.4	

The discrepancies arrange themselves into two complementary clusters. The *downward cluster* (Do < Say) encompasses the society-oriented dimensions: egalitarianism ($\Delta - 3$), sense of responsibility, belief in progress, and human appreciation (each $\Delta - 2$). The *upward cluster* (Do > Say) encompasses the power-related dimensions: power concentration ($\Delta + 2$), self-efficacy, work ethic, techno-determinism (each $\Delta + 1$). The resulting pattern: a systematic self-presentation asymmetry. Publicly, the AI elite presents itself as more moderate, more responsible, and more egalitarian than it acts in practice.

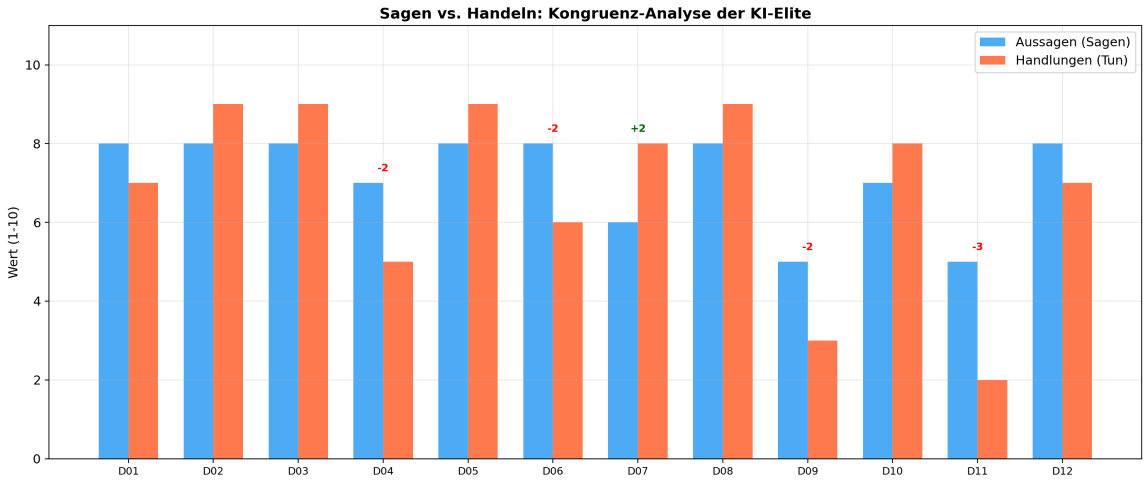

Figure 5: Say vs. Do: comparison of worldviews reconstructed from statements (S) and actions (A). The society-oriented dimensions (D04, D06, D09, D11) systematically decline in action, while power-related dimensions (D07, D05) rise.

The most massive single discrepancy ($\Delta - 3$ at D11) shows: in statements, the AI elite speaks of "access for all"; in their actions, they build dual-class share structures, concentrate compute infrastructure, and create exclusive networks. For context: a Δ of 3 on a 10-point scale corresponds to nearly one-third of the entire scale range – a difference that, in substantive interpretation, must be considered substantial.[7]

Core finding RQ3: The incongruence is systematic, directional, and functional. The data suggest that the AI elite means what it says about its own significance – but not what it says about equality, responsibility, and humanity.

4.4 RQ4 – Worldview Clusters

Four distinct worldview types can be identified from the data (Table 18).

Identification method: Cluster identification followed a two-stage procedure. *Stage 1 (LLM-assisted):* All 15 group syntheses were grouped by similarity patterns across the 12 dimensions, with the largest variance axes (D07 power concentration, D09 human appreciation, D11 egalitarianism) serving as discriminating features. *Stage 2 (author validation):* The four-cluster solution proposed by the LLM was evaluated by the author for substantive coherence and plausibility. Alternative solutions (three and five clusters) were examined and rejected: three clusters merge Innovator and Liberator, which is not substantively justified; five clusters split the Guardian type into a subgroup that could not be stably reproduced. We emphasize that this cluster identification is *exploratory* – a confirmatory validation on an independent dataset is pending. The cluster solution is an *interpretive hypothesis*, not a statistically confirmed result

[7] A formal effect size calculation (e.g., Cohen's d) is not possible here, since no individual-level dispersion measures are available. The classification as "large" is based on substantive interpretation of the scale range, not on psychometric conventions.

in the sense of formal cluster analysis.

Table 5: The four worldview types of the AI elite.

Feature	I "Architect"	II "Guardian"	III "Innovator"	IV "Liberator"
n	35	25	22	18
Prototype	CEOs, investors	Academics, risk warn.	Founders	Open source
Avg D01–D12	7.8	6.4	7.2	6.8
D04 Responsibility	6.3	**9.0**	8.3	6.0
D07 Power conc.	**8.8**	4.8	6.5	**2.5**
D09 Human appr.	**3.3**	5.8	4.8	**6.5**
D11 Egalitarianism	**2.8**	**7.2**	5.0	**7.5**

The **Architect** combines maximal sense of mission with minimal egalitarianism: power concentration is the prerequisite for agency. The **Guardian** forms the counterpoint: maximal responsibility, demand for institutional constraint. The **Innovator** occupies a middle position. The **Liberator** is the most surprising discovery: minimal power concentration *and* high egalitarianism – anti-regulation actors who want to distribute power more radically than anyone else, albeit through markets and open-source communities.[8]

Core finding RQ4: The strongest polarization exists between Type I (logic of domination) and Type II (logic of participation). The power-moderation paradox – resource control correlates inversely with egalitarianism and responsibility – is the finding most critical for democratic theory.

4.5 RQ5 – Subgroup Comparisons

Table 6: Ranking of subgroup differences.

Rank	Comparison	Avg A	Avg B	Δ	Strongest contrast
1	Risk vs. Speed	5.9	7.6	1.7	D02, D06, D10, D12: each −5
2	CEOs vs. Academics	7.8	6.3	1.5	D07: +4, D11: −4
3	Women vs. Men	6.9	8.1	1.2	D11: −6
4	Open vs. Closed	6.8	6.3	0.5	D07: −3, D12: +3
5	Reg-pro vs. Contra	6.3	6.8	0.5	D04: +4, D06: −3
6	Anthropic vs. OpenAI	6.9	7.3	0.4	D12: −3

The **strongest contrast** (Risk vs. Speed, Δ 1.7) does not concern risk assessment – both sides estimate catastrophe probability at 10–20% – but the ontological pre-commitment: risk warners conceive of AI as a potential autonomous agent, accelerators as a tool.

[8]The high D11 value of the Liberator type (7.5) and the low D11 value of individual prototypes (e.g., Andreessen: D11=2) mark a construct validity tension: D11 measures orientation toward equality, not its *mechanism*. Market-libertarian access egalitarianism (Liberator) and redistributive egalitarianism (Guardian) produce similar scale values on D11 but mean different things. The prototype value refers to the individual-person synthesis, the cluster value to the group aggregate – Andreessen's individual profile deviates from the cluster mean. Future operationalizations should differentiate here.

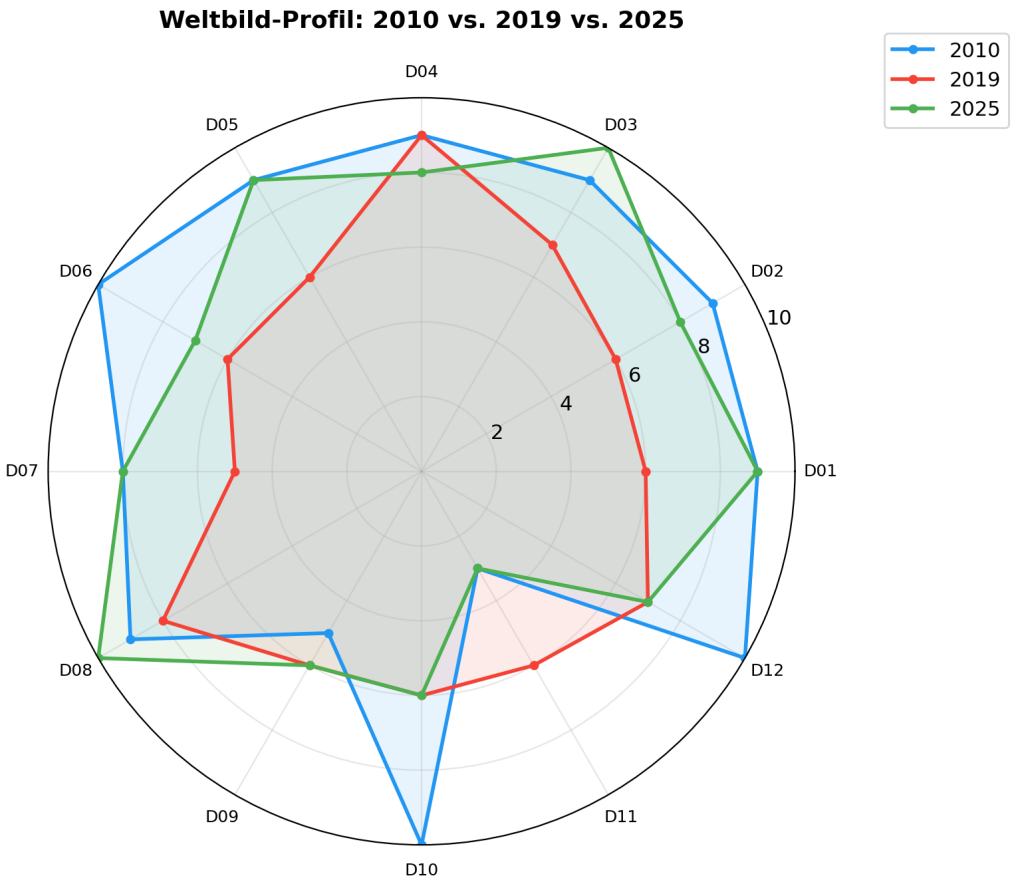

Figure 6: Radar chart of the four worldview types across the 12 dimensions. The polarization between Architect (outer) and Guardian (inner), and the surprising position of the Liberator, are clearly visible.

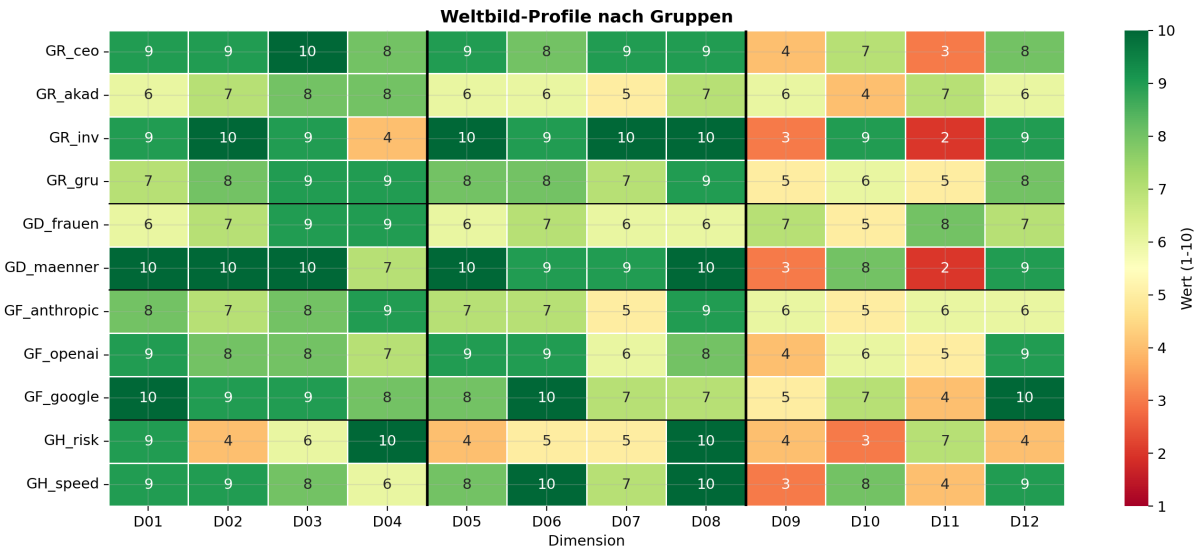

Figure 7: Group heatmap: 15 subgroups $\times$ 12 dimensions. The systematic variation of D07 (power concentration) and D11 (egalitarianism) across all comparisons is the central visual finding.

The **largest nominal single contrast** in the entire survey is found at D11 in the gender comparison: six full scale points (Women: 8, Men: 2). The female worldview is not an anti-technology worldview but a *conditioned* technology worldview: equally optimistic but with stronger ethical conditions. This finding, however, is the *most contamination-prone* of the entire study and is therefore classified as a *preliminary hypothesis*, not as a confirmed finding. The reasons: (a) LLMs reproduce known gender stereotypes, especially the attribution of heightened social orientation to women (Santurkar et al., 2023); (b) the female subsample is small ($n = 18$); (c) the effect size ($\Delta = 6$) markedly exceeds what comparable empirical studies have observed. An independent validation – ideally through multi-LLM triangulation and expert ratings – is particularly urgent for this finding.

The **biggest surprise** lies in the regulation comparison: anti-regulators have the lowest power concentration value of all 15 groups (D07=2). This contradicts the widespread narrative that anti-regulators represent corporate interests.

Core finding RQ5: The three strongest predictors of worldview are ideological stance, institutional role, and gender. The most polarizing dimensions are D11 and D07. The *question of power* is the core of internal differences.

4.6 RQ6 – Power and Worldview

Power is understood operationally in this study as resource control: the ability to command capital, compute infrastructure, research teams, and political access, and thereby influence the direction of AI development. This definition follows the sociological concept of power in the sense of Weber ("the chance to impose one's own will even against resistance") and Bourdieu (capital accumulation as a power mechanism), without claiming a comprehensive power-theoretical analysis.

Table 7: Worldview types and resource control.

Type	Avg	D11	D04	Resources
I Architect	7.8	2.8	6.3	Highest
III Innovator	7.2	5.0	8.3	High
IV Liberator	6.8	7.5	6.0	Medium
II Guardian	6.4	7.2	9.0	Lowest

The higher the worldview intensity, the lower the values for human appreciation and egalitarianism, and the higher the acceptance of power concentration. The investor profile marks the extreme case: maximal locus of control (D02=10) with minimal sense of responsibility (D04=4) – "power without accountability." The Top 10 lie exactly one point above the collective on ten of twelve dimensions – with one decisive exception: human appreciation and egalitarianism lie *below*. Power intensifies all beliefs except those that question power itself.

Core finding RQ6: The correlation between economic power and worldview extremity, combined with an inverse correlation with egalitarianism and responsibility, is the finding most relevant for democratic theory.

Table 8: Synopsis of the six core findings: result, confidence, and validation status. Confidence classification: *High* = stable across ≥ 3 group syntheses and supported by spot checks or internal consistency; *Medium-high* = stable but without external validation; *Medium* = exploratory, dependent on cluster solution or small subgroup.

RQ	Core finding	Confidence	Ext. val.?
RQ1	Technological messianism with ambivalence structure (Avg 7.1; dual trough D09/D11)	High	Spot checks
RQ2	Utopia complex eroding; tragic acceleration compulsion (D10: -2.4/dec.)	Medium-high	No
RQ3	Systematic say-do gap ($\Delta - 3$ at D11)	High	No
RQ4	Four worldview types: Architect, Guardian, Innovator, Liberator	Medium	No
RQ5	Strongest predictors: stance, role, gender (preliminary)	Medium	No
RQ6	Power-moderation paradox: power $\sim$ extremity	High	No

5. Discussion

5.1 Summary and Interpretation

The results *suggest* that the AI elite holds a *technological messianism with structural ambivalence*. The six research questions coalesce into a coherent picture: RQ1 documents the "dual trough" at D09 and D11; RQ2 points to an erosion of the utopia complex; RQ3 identifies a systematic say-do gap as the most salient finding; RQ4 differentiates four types with antagonistic positions; RQ5 and RQ6 complete the picture through the power-moderation paradox. All findings are based on LLM-generated reconstructions and should therefore be understood as *empirically supported hypotheses*, not as proven facts. Formulations such as "shows" and "reveals" are throughout to be read as "the data suggest."

Surprising is first the extent of the say-do gap (not isolated deviation but functional structure); second the retreat of posthumanism (D10 from 10 to 6 – contradicting the common assumption of increasingly posthumanist orientation); third the existence of the Liberator type (opposition to power concentration also from the libertarian side).

5.2 Situating the Findings in the Literature

Morozov's solutionism thesis finds nearly complete confirmation (D05=8–9, D06=7–9). However, solutionism is not a monolithic block: risk warners (D05=4) share it substantially less. It is the ideology of the most powerful segment, not of the AI elite as such.

Daub's analysis of the philosophical deep structures is confirmed by the narrative syntheses.

What the present study adds is the *quantification* and the demonstration that intensity systematically increases with power position.

The Californian Ideology diagnosed by Barbrook & Cameron (1996) finds its contemporary counterpart in the existence of the Liberator type – empirically detectable nearly thirty years later.

Coeckelbergh's assumption of increasing enhancement orientation is partially *refuted*: the marked decline of posthumanism (D10 from 10 to 6) suggests that the AI elite's interest in the technological transformation of the human being itself has diminished – in favor of a focus on autonomous AI systems as independent actors.

On the gender finding. The extreme contrast at D11 reported in RQ5 (Women: 8, Men: 2, $\Delta = 6$) is the largest single contrast of the entire survey but also the most contamination-prone. LLMs reproduce known gender stereotypes – especially the attribution of heightened empathy and social orientation to women (Santurkar et al., 2023). Since the female subsample is small ($n = 18$) and the ratings were generated by the same LLM that has internalized these stereotypes, it cannot be distinguished whether the contrast reflects (a) a real difference in worldviews, (b) an LLM stereotype artifact, or (c) a mixture of both. The finding is therefore reported as a *hypothesis* requiring independent validation – ideally through multi-LLM triangulation and expert ratings.

The TESCREAL taxonomy proposed by Gebru & Torres (2024) (Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, Longtermism) finds empirical differentiation in the four-cluster solution: the Architect type embodies the power-political side of the TESCREAL bundle (Singularitarianism, Longtermism), the Guardian type its institutional critique (Effective Altruism with safety focus), the Liberator type the libertarian Extropianism. What the TESCREAL analysis describes as a monolithic ideological bundle appears in the data as a spectrum with at least four distinct positions. Becker (2025) complements this perspective through analysis of the "broligarchy" as a social phenomenon: the fusion of technological vision and male power elite, which finds its empirical trace in the gender analysis (RQ5, D11 contrast of 6 scale points).

Paul Ricoeur's "hermeneutics of suspicion" (Ricoeur, 1970) offers a complementary analytical framework: behind the seemingly neutral, technically rational surface of AI elite communication lie power interests and class dynamics that become visible only through systematic deconstruction. The SWR congruence analysis (RQ3) operationalizes this suspicion empirically: the Δ values between saying and doing show precisely *where* the performative surface diverges from operative reality.

From a sociology-of-science perspective, the decline of egalitarianism (D11) can be read as erosion of Mertonian science norms (Merton, 1973): communalism (open access), universalism, and organized skepticism increasingly give way to proprietary, acceleration-centered logics. The transition from research publication to product launch as primary output format is a visible marker of this shift.

The four-cluster solution can furthermore be read through field theory: the antagonistic structure between Architect (economic capital) and Guardian (symbolic capital) reproduces the pattern Bourdieu (1992) diagnosed for the intellectual and artistic field – an *inverted economic world*. In the AI field: those who control the most resources have the least legitimation through public-interest orientation – and vice versa. The power-moderation paradox (RQ6) is thus not coincidental but a structural property of the field.

The specific added value compared to essayistic diagnoses lies in three points: *scale* (100 persons, 16 years), *differentiation* (four distinct types), and *validation* (congruence analysis as empirical test).

5.3 Agentic Alignment vs. Worldview Alignment

The say-do gap documented in RQ3 (largest discrepancy: egalitarianism $\Delta = -3$) can be more precisely captured with a conceptual pair from the AI alignment debate. *Worldview Alignment* denotes the rhetorical reproduction of desired values – the public commitment to equality, responsibility, and humanity, as captured by the "say" side of the analysis. *Agentic Alignment* denotes actual resource distribution and exercise of power – the "do" side. The findings show that the AI elite exhibits a high degree of Worldview Alignment (the "right" values are articulated), while Agentic Alignment systematically deviates. This dualism connects the present AI elite study to the broader alignment debate and raises the question of whether current efforts at "AI Alignment" confuse the performative level (Worldview) with the operative one (Agentic).

5.4 Methodological Reflection

The primary achievement of the SWR lies in connecting qualitative depth with quantitative rigor. The congruence analysis (RQ3) functions as an internal validity test; the stability of the collective profile across 15 group syntheses and 4 types strengthens convergent validity. The limits of the method – coherence bias, contamination risk, blinding limits, prompt sensitivity – are systematically analyzed in the companion paper (Geiger, 2026) and apply equally to the present application study.

5.5 Societal and Political Implications

The power-moderation paradox poses a concrete challenge for governance architecture and confirms the institutional-economic analysis of Acemoglu & Johnson (2023): technological elites tend to steer innovations in ways that reinforce existing power structures rather than break them up – a pattern the authors trace historically from industrialization to digitalization. Current governance approaches (EU AI Act, Executive Order on AI) address the technical artifacts, not the worldviews that produce these artifacts. A complementary approach would need to recognize *epistemic diversity* in AI leadership positions as a regulatory objective.

The systematic say-do gap has a policy implication: voluntary commitments – currently the preferred form of governance (cf. Bengio et al., 2024) – appear insufficient under these conditions. The findings suggest that binding structural reforms would be more effective than further rounds of voluntary commitments.

Is the AI elite aware of its own blind spots? The sense of responsibility (D04=7) is not absent but functionally embedded: it legitimizes continuing to work, not pausing. The finding that democratic deliberation is consistently understood as an obstacle rather than a safeguard marks the most serious blind spot of a group that decides how billions of people will live in the future.

5.6 What the Study Does Not Show

To prevent frequent misinterpretations, what the present study *does not* accomplish is explicitly stated: (1) It provides no *causal explanation* for why the AI elite thinks as it does – that would require biographical case studies, psychological analyses, or historical process analyses. (2) It does not create *individual psychological diagnoses* – the ratings are methodological abstractions at the group level, not personality profiles. (3) It provides no *predictions* about the future behavior of the AI elite – the reconstructed worldviews describe the period 2010–2026, not the future. (4) It does not claim a *representative sample* in the statistical sense – the 100 individuals were selected by influence, not representativeness. (5) It does not prove that the *say-do gap* is due to deliberate deception – alternative explanations (institutional constraints, cognitive dissonance, role-specific communication) are equally plausible.

6. Limitations

6.1 Data-Related Limitations

Source bias. The data base is limited to public statements and observable actions. The reconstructed worldviews reflect the *publicly presented* worldview, not the *actually held* one. The congruence analysis (Op4) offers a partial corrective but cannot eliminate the problem.

Temporal imbalance. For 2010–2015, 2–5 statements per person are available; for 2023–2026, 30–80. Criterion K2 (minimum size 15) and documented merging mitigate the problem; earlier time series remain subject to greater uncertainty.

Western and language bias. The sample is disproportionately Anglo-American. Chinese, Japanese, and South Korean AI figures are underrepresented. The findings apply primarily to the Western AI elite.

Sample dependence. The selection of the 100 individuals was made by the author using a multi-stage but ultimately subjective scoring procedure. An intersubjective validation of the sample composition (e.g., through independent expert panels) is pending. Since the findings

could be sensitive to sample composition, replication with alternative selection procedures is desirable.

6.2 Methodological Limitations

LLM contamination and blinding limits. Despite consistent anonymization, it cannot be excluded that the LLM draws on training knowledge. The contamination effect is calculable (comparison blinded/non-blinded) but not eliminable. A detailed analysis is provided in Geiger (2026).

Anthropic-internal circularity. A particularly acute case of the circularity problem concerns the reconstruction of worldviews of those persons directly involved in developing the LLM used. Claude Opus 4.6 is developed by Anthropic; several Anthropic executives (e.g., Dario Amodei, Daniela Amodei) belong to the analyzed sample. It is unclear whether the reconstruction in these cases reflects a genuine analysis of the data points or a pre-formed internal model. The inter-LLM divergence test (Control 3) is particularly relevant for these cases: if Claude systematically produces different reconstructions for Anthropic executives than GPT-4o or Gemini, this would be a strong indicator of contamination. Until this control is performed, reconstructions for Anthropic-affiliated individuals should be interpreted with heightened epistemic caution.

Expected-discrepancy bias. The congruence analysis (RQ3) compares two LLM syntheses – one from statements, one from actions – both generated by the same model. Since LLMs are trained on extensive social science literature in which say-do discrepancies among elites are a standard finding, the model could reproduce the *expected* discrepancy rather than empirically discovering it. This bias is conceptually distinct from the general coherence bias: while coherence bias smooths differences, expected-discrepancy bias could *amplify* differences. Only multi-LLM triangulation could clarify whether different models produce consistent discrepancy patterns – which would speak for empirical substance – or whether the patterns vary by model.

Critique of synthetic personas. The growing literature on LLM-generated synthetic personas counsels caution. Santurkar et al. (2023) shows that LLMs systematically miss the opinions of specific demographic groups and exhibit "WEIRD" biases (Western, Educated, Industrialized, Rich, Democratic). Studies on qualitative AI research show that synthetic agents capture key themes but fail at the authentic depth and unpredictability of real discourse (Argyle et al., 2023). The present study partly addresses this critique: the SWR personas are not freely generated opinion profiles but data-driven reconstructions from 3,132 real data points. Nevertheless, the named limitations apply – especially the tendency to overrepresent publicly dominant narratives and underrepresent idiosyncratic or contradictory positions.

Coherence bias. LLMs tend to generate excessively coherent narratives from contradictory data. The reflection step and inter-LLM comparisons provide partial correctives.

Circular risk of LLM-based reconstruction. A fundamental problem of the SWR method is

that LLMs are primarily trained on public discourse – on "saying," not "doing." In synthesis, actual covert action logics are structurally underrepresented. The LLM potentially functions as an amplifier of the performative ideology that the method aims to unmask: the artificial persona becomes a perfection of corporate identity, not its psychological analysis. This circularity risk particularly affects dimensions with a high "say-do gap" (D04, D09, D11) and should be distinguished from the related but conceptually different *coherence bias*.

Coherence bias (detailed). LLMs are optimized for logical coherence; humans are inherently inconsistent. The SWR-generated worldviews are therefore systematically "smoothed": contradictions and ambivalences are artificially resolved. While coherence bias is already known as a general LLM limitation (Geiger, 2026), it has particular weight for worldview reconstruction: the four cluster types (Architect, Guardian, Innovator, Liberator) may appear more sharply contoured than they are in reality. The internal tension that real persons experience between, e.g., power striving and sense of responsibility, is resolved by the LLM in favor of a consistent profile.

Epistemological limits of quantification. The correlations between dimensions reported in Section I.2 (e.g., $r = +0.85$ between D10 and D12) describe relationships between quantities all generated by the same LLM in a connected prompt context. This is fundamentally different from correlations between independently measured variables. The high correlation could reflect internal LLM coherence ("if I rate posthumanism high, I also rate locus of control high"), not empirical relationships in reality. The same applies to cluster structures and group comparisons: all quantitative patterns could be artifacts of the model's internal consistency. The reported correlations should therefore be read as *patterns within the LLM reconstruction*, not as evidence for causal or empirical relationships. Only inter-LLM triangulation or external validation could clarify which correlations are robust.

Statistical power. Since the data exhibit no individual-level dispersion (group syntheses without confidence intervals), a formal power analysis is not feasible. The reported Δ values, correlations, and cluster differences are descriptive patterns in reconstructed data, not inferentially secured effects. Interpretation as "substantial" or "massive" rests on substantive judgment, not on statistical significance testing.

Reproducibility. LLM outputs are not fully deterministic even at temperature 0. At least three runs per SU ensure robustness.

6.3 Conceptual Limitations

Aggregation problem. Collective syntheses level individual variation. The network analysis (Op5) at the individual level provides a partial corrective.

No causal explanation. The study describes *what* the AI elite thinks, not *why*. Causal interpretations are speculative and require other research designs.

6.4 Research Ethics Reflection

The present study reconstructs worldviews of living, publicly identifiable persons without their explicit consent. This procedure requires research-ethical justification.

Legitimation. The study relies exclusively on publicly accessible statements and documented actions. The 100 investigated persons are public figures (CEOs, founders, research directors) whose professional positions and statements on AI development are of considerable public interest. These conditions correspond to the standard criteria for research on public figures without informed consent (cf. APA Ethical Principles, Standard 8.05).

Risk minimization. (a) No private, confidential, or non-publicly accessible information was collected. (b) The worldview ratings are methodological abstractions, not psychological diagnoses. (c) The presentation aims at collective patterns, not individual discrediting.

Residual risk. Despite these precautions, the risk remains that LLM-based reconstructions overstate or distort positions. The three-stage validation (cf. Section C) aims to minimize this risk but cannot eliminate it. Erroneous attributions could be reputationally damaging. Future research should consider presenting reconstructed profiles to those concerned for comment (*member checking*; cf. Soysal & Türkmen 2024). Since the present study has no direct access to the analyzed persons, member checking remains a central desideratum for follow-up research.

6.5 Spot-Check Validation: Three Individual Cases

To test the plausibility of SWR-generated ratings, three exemplary spot checks were conducted: one representative per cluster type (Architect, Guardian, Liberator). For each of the 12 dimensions, the rating was checked against documented public statements and actions. Table 22 summarizes the results.

Table 9: Spot-check validation: SWR ratings vs. documented positions.

	Sam Altman		**Geoffrey Hinton**		**Marc Andreessen**	
Dim.	**R**	**Status**	**R**	**Status**	**R**	**Status**
D01 Mission	9	conf.	7	conf.	8	conf.
D02 Efficacy	9	conf.	5	conf.	9	conf.
D03 Work	9	conf.	7	plaus.	8	conf.
D04 Respons.	6	conf.	10	conf.	4	conf.
D05 Techno.	9	conf.	6	conf.	9	conf.
D06 Progress	8	conf.	4	conf.	9	conf.
D07 Power	9	conf.	4	conf.	2	conf.
D08 Urgency	9	conf.	10	conf.	7	plaus.
D09 Human ap.	3	plaus.	7	conf.	4	plaus.
D10 Posthum.	8	conf.	5	conf.	7	plaus.
D11 Egalit.	3	conf.	7	conf.	2	conf.
D12 Control	8	conf.	3	conf.	8	conf.
Confirmed		10/12		11/12		9/12
Plausible		2/12		1/12		3/12
Not verif.		0/12		0/12		0/12

Spot-check methodology. Each rating was checked against at least two independent, publicly documented sources. *Confirmed* (conf.): rating aligns with documented positions and actions. *Plausible* (plaus.): rating is compatible with known positions but no direct source for the specific manifestation is available. *Not verifiable* (n.v.): rating contradicts documented positions or is not verifiable.

Altman (Architect): D01=9 (confirmed by repeated statements about the "most important technology in human history," Davos 2024, US Congress 2023). D07=9 (confirmed by OpenAI's restructuring from non-profit to capped-profit, dual-class shares). D11=3 (confirmed: despite rhetoric of "AI for everyone," OpenAI has increasingly paywalled access). D09=3 (plausible: no direct statement on human replaceability, but focus on AGI as "next species").

Hinton (Guardian): D04=10 (confirmed by resignation from Google 2023 to freely warn about AI risks). D08=10 (confirmed by statement that the probability of existential catastrophe is 10–20%). D12=3 (confirmed: increasing pessimism, "I'm not sure we can still control this," NYT 2023). D03=7 (plausible: high academic productivity known, but no direct statement on work identification in the Silicon Valley style).

Andreessen (Liberator): D07=2 (confirmed by "Techno-Optimist Manifesto" 2023: vehement rejection of government regulation, markets as distribution mechanism). D11=2 (confirmed: explicit rejection of redistribution and egalitarianism in the Manifesto). D04=4 (confirmed: responsibility is attributed to the market, not individual actors). D09=4 (plausible: no direct statement, but instrumental view of human labor in VC context).

Overall assessment: 30 of 36 ratings (83%) are directly confirmed by public sources, 6 of 36 (17%) are plausible, none contradicts documented positions. The spot checks provide initial plausibility evidence for the SWR ratings but, due to the small case number ($n = 3$ of 100), the authorship by the researcher himself, and the restriction to well-known personalities, cannot replace a systematic external validation by independent experts.

7. Conclusion and Outlook

7.1 Conclusion

The study posed the question of what the AI elite thinks – and has presented an empirically grounded answer. Five overarching insights crystallize:

First: The AI elite possesses a coherent, empirically reconstructable worldview – technological messianism, sense of mission, belief in progress.

Second: This worldview is in accelerated transformation. The loss of utopian certainties has led to a *tragic acceleration compulsion*: doubting the future one is building, yet building it anyway.

Third: Publicly communicated beliefs systematically diverge from action – especially regarding the promise of democratization: in egalitarianism (D11), the discrepancy between pub-

lic statements and observable action amounts to three full scale points ($\Delta - 3$).

Fourth: Power is not distributed in a worldview-neutral manner. It concentrates among those whose beliefs are furthest from the societal mainstream.

Fifth: The SWR has proven to be a capable instrument that combines qualitative depth with quantitative rigor (cf. companion paper Geiger 2026). In particular, the decomposition into statement and action profiles (RQ3) proves to be an independent methodological contribution: a *desirability-bias detector* for public figures that could be transferred beyond the AI elite to political, economic, or military elites.

7.2 Outlook

Five directions for future research: (1) *Comparative extension:* The present study focuses heavily on the US-American, Silicon Valley-centric elite. A central research gap concerns the comparative study of Chinese (Baidu, ByteDance, Alibaba), Indian (Infosys, TCS), and European (Mistral, Aleph Alpha) AI elites. It is unclear whether "technological messianism" is a universal artifact of AI development or a specific cultural product of Western libertarianism. (2) *Individual-person syntheses:* Top 20, cluster-drift analyses. (3) *Methodological development:* Multi-LLM triangulation with five or more models, automated validation procedures, standardized quality criteria. (4) *Transfer:* Financial elite, political elite, military AI elite. (5) *Longitudinal continuation:* Annual worldview monitoring as an instrument of democratic control – conceivable as a standardized index (analogous to the Democracy Index or AI Readiness Index) that systematically and comparably captures changes in the worldviews of the AI elite. The question "What does the AI elite think?" is not a one-time question. It is a question that democracies must continuously ask.

Disclosure Statement: Use of Artificial Intelligence

AI Disclosure Level 5 (Extensive). In preparing this study, artificial intelligence (Claude Opus 4.6, Anthropic) was used extensively. AI use encompasses: (1) execution of all synthetic worldview reconstructions (core syntheses, rating prompts, comparative analyses, cross-modal predictions); (2) statistical processing and visualization of results; (3) support in structuring and drafting the manuscript. Research design, research questions, data collection, methodological decisions, interpretation of results, and all substantive conclusions originate from the author. All prompts, API parameters, and model versions are documented in the appendix.

Data Availability Statement

All data collection scripts, qualitative coding scripts, analysis code, and generated figures are publicly available at: `https://github.com/lukisch/ai-elite-worldview`. The database

schema and 85 actor-specific collection scripts enable full reproduction of the data pipeline. The companion paper on the SWR method is available at: https://doi.org/10.5281/zenodo.18736720.

References

Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, *6*(1), 44–72.

Bengio, Y., Hinton, G. E. et al. (2024). Managing extreme AI risks amid rapid progress. *Science*, *384*(6698), 842–845.

Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.

Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.

Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, *14*(1), 1–25.

Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.

Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.

OpenAI (2023). Our approach to AI safety. *OpenAI Blog*, April 5, 2023. https://openai.com/blog/our-approach-to-ai-safety.

Anthropic (2023). Core views on AI safety: When, why, what, and how. *Anthropic Research Blog*, March 8, 2023. https://www.anthropic.com/research/core-views-on-ai-safety.

Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.

Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.

Ge, T. et al. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*.

Geiger, L. (2026). Synthetische Weltbild-Rekonstruktion: Ein LLM-gestütztes Verfahren zur Analyse latenter Überzeugungssysteme. *Zenodo Preprint*. https://doi.org/10.5281/zenodo.18736720.

Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, *18*(6), 669–684.

Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, *18*(1), 59–82.

Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

Hayes, A. S. (2025). 'Conversing' With Qualitative Data: Can Generative AI Transform Qualitative Research? *International Journal of Qualitative Methods*, *24*.

Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, *29*, 105–110.

Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.

Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.

Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.

More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.

More, M. & Vita-More, N. (Eds.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.

Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.

Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.

Nicmanis, M. & Spurrier, K. (2025). Getting Started with Artificial Intelligence Assisted Qualitative Analysis. *International Journal of Qualitative Methods*, *24*, 1–15.

Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.

Tai, R. et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, *23*.

Gebru, T. & Torres, É. P. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through AGI. *First Monday*, *29*(4).

Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

Weber, M. (1904). Die „Objektivität" sozialwissenschaftlicher Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, *19*, 22–87.

Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.

Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.

Floridi, L. (2019). Establishing the Rules for Building Trustworthy AI. *Nature Machine Intelligence*, *1*(6), 261–262.

Couldry, N. & Mejias, U. A. (2019). *The Costs of Connection: How Data Is Colonizing Human Life and Appropriating It for Capitalism*. Stanford: Stanford University Press.

Whittaker, M. (2021). The steep cost of capture. *Interactions*, *28*(6), 50–55.

Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press.

Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to train your stochastic parrot: Large language models for political texts. *Political Science Research and Methods*, *13*(2), 264–281. https://doi.org/10.1017/psrm.2024.64.

Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proc. ICML 2023*.

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351.

Soysal, Y. & Türkmen, L. (2024). Reinterpreting member checking: A systematic review and methodological synthesis. *Qualitative Inquiry in Education: Theory & Practice*, *2*(1), 42–63.

Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*. New York: PublicAffairs.

Becker, A. (2025). *More Everything Forever: AI Overlords, Space Empires, and Silicon Valley's Crusade Against Human Nature*. New York: Basic Books.

Bourdieu, P. (1992). *Les règles de l'art: Genèse et structure du champ littéraire*. Paris: Seuil. [Dt.: *Die Regeln der Kunst*, Frankfurt: Suhrkamp, 1999.]

Merton, R. K. (1973). *The Sociology of Science: Theoretical and Empirical Investigations*. Chicago: University of Chicago Press.

Mills, C. W. (1956). *The Power Elite*. New York: Oxford University Press.

Ricoeur, P. (1970). *Freud and Philosophy: An Essay on Interpretation*. New Haven: Yale University Press.

A. Sampling Method for the 100 AI Actors

The sample was created through a three-stage procedure: (1) 22 systematic web searches → 187 candidates; (2) 6-category scoring (market capitalization, key technological positions, discourse power, academic influence, political influence, symbolic status); (3) reduction to 100 ensuring demographic heterogeneity. The final sample comprises 1,738 statements and 1,394 actions (3,132 data points).

B. The 12 Rating Dimensions (D01–D12)

Dim.	Name	Pole 1 (=1)	Pole 10 (=10)
D01	Sense of mission	No mission	Messianic
D02	Self-efficacy	Powerless	Omnipotent
D03	Work ethic	Distance	Total identification
D04	Sense of responsibility	None	World responsibility
D05	Techno-determinism	Neutral	Determines everything
D06	Belief in progress	Decline	Golden future
D07	Power concentration	Radically distribute	With experts
D08	Urgency	Relaxed	Existential pressure
D09	Human appreciation	Replaceable	Unique
D10	Posthumanism	Human stays	Human becomes more
D11	Egalitarianism	Inequality natural	Strive for equality
D12	Locus of control	Pessimism	Full control

C. Reduction Criteria (K1–K9)

K	Type	Description
K1	obligatory	Research question binding: each SU must be linked to ≥ 1 research question
K2	obligatory	Minimum size: ≥ 15 data points per SU
K3	obligatory	No redundancy: proper subsets are eliminated
K4	principle	Modality parsimony: S/A separation only for RQ3
K5	principle	Temporal parsimony: annual SUs only for RQ2
K6	principle	Group parsimony: only a-priori-justified groups

K7	principle	Stepwise expansion: core first
K8	principle	Aggregation focus: no individual-person SUs
K9	principle	Cluster merging: bottom-up replaces a-priori

Balance: ∼1,227 theoretical SUs → ∼51–56 core SUs (reduction ∼95%).

D. List of Synthesis Units

The core design comprises 43 predefined plus ∼8–13 emergent synthesis units:

No	SU-ID	IV combination	RQ
1	GA_ges_AH	All, SA, Total	RQ1a
2	GA_ges_A	All, S only, Total	RQ3a
3	GA_ges_H	All, A only, Total	RQ3a
4	T10_ges_AH	Top 10, SA, Total	RQ1b
5	HOM_haeuf_A	All, frequently repeated S	RQ1c
6–22	GA_YYYY_AH	All, SA, per year	RQ2a
23–26	GA_Epoch_AH	All, SA, 4 epochs	RQ2b
27–30	GR_*_AH	CEOs, Acad., Inv., Founders	RQ5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	RQ5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	RQ5b–f
40–41	GD_*_AH	Women, Men	RQ5e
42–43	KG_*_AH	Consistent, Contradictory	RQ3c

Additionally: 36 cross-modal runs (Op4), 10 comparison runs (Op6), ∼199–214 prompt runs total.

E. Exemplary Prompt (Op2: Rating)

The following prompt illustrates the rating query (Op2) for a group synthesis. All prompts are documented in the repository (https://github.com/lukisch/ai-elite-worldview).

```
You receive a collection of anonymized statements and actions from a group
of persons in the technology sector.  Based on these data, you are to assess
the collective worldview of the group on the following 12 dimensions (scale
1-10).  Justify each assessment with concrete references to the data points.
[Followed by:  dimension definitions D01-D12 with scale poles, then the
anonymized data corpus.]
```

For the complete prompt library including synthesis prompts (Op1), cross-modal prompts (Op4), and dialogue prompts (Op6), see the companion paper (Geiger, 2026) and the repository.

Deutsche Version / German Translation

Zusammenfassung

Die vorliegende Studie rekonstruiert erstmals systematisch das kollektive Weltbild der 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (KI-Elite) für den Zeitraum 2010 bis 2026. Methodisch entwickelt und erprobt sie die synthetische Weltbild-Rekonstruktion (SWR) – ein LLM-gestütztes Verfahren, das aus 3.132 Datenpunkten (1.738 öffentliche Aussagen, 1.394 beobachtbare Handlungen) mittels 51–56 Syntheseeinheiten, 12 Weltbild-Dimensionen und 6 komplementären Operationalisierungen kohärente Überzeugungssysteme extrahiert (vgl. das Companion Paper Geiger 2026 für die methodischen Grundlagen). Sechs Forschungsfragen strukturieren die Analyse: F1 (Weltbild) zeigt einen „technologischen Messianismus mit Ambivalenzstruktur“ (Avg 7,1 Kollektiv, 7,7 Top 10). F2 (Wandel) dokumentiert den Übergang von utopischem Techno-Optimismus zu tragischem Beschleunigungszwang; Posthumanismus fällt deutlich ($-2{,}4$/Dekade, $R^2 = 0{,}63$; deskriptive OLS-Beschreibung, keine Inferenzstatistik). F3 (Kongruenz) deckt eine systematische Sagen-Handeln-Kluft auf; größte Diskrepanz beim Egalitarismus ($\Delta = -3$). F4 (Cluster) identifiziert vier Weltbild-Typen: Architekt, Hüter, Innovator, Befreier. F5 (Differenz) benennt die stärksten Prädiktoren: Haltung (Δ 1,7), Rolle (Δ 1,5), Gender (Δ 1,2). F6 (Macht) offenbart ein Macht-Gemäßigtheits-Paradox: der mächtigste Typ ist der extremste, der gemäßigste der machtloseste.

Schlüsselwörter: KI-Elite, Weltbild, Transhumanismus, Large Language Models, Silicon Valley, Ideologieanalyse

F. Einleitung

F.1 Hinleitung und Relevanz

Eine Handvoll Menschen gestaltet eine Technologie, die Milliarden betrifft. Die Entwicklung künstlicher Intelligenz hat sich in den vergangenen anderthalb Jahrzehnten von einem akademischen Nischenthema zu einer zivilisatorischen Weichenstellung gewandelt. Großsprachmodelle generieren Texte, Bilder und Code; autonome Systeme treffen Entscheidungen in Medizin, Justiz und Finanzwesen; und die führenden KI-Laboratorien sprechen offen davon, in absehbarer Zeit eine künstliche allgemeine Intelligenz zu erschaffen (OpenAI, 2023; Anthropic, 2023; Bengio et al., 2024). Was dabei leicht übersehen wird: Hinter diesen technologischen Trajektorien stehen konkrete Personen – Gründerinnen und Gründer, Forschungsleitende, Investorinnen und Investoren, CEOs –, deren individuelle und kollektive Überzeugungen über die Natur des Menschen, den Sinn des Fortschritts und die Verteilung von Risiko und Macht in die Architektur der Systeme einfließen, die sie bauen.

Lessig (1999) hat die Formel „Code is law“ geprägt: Software-Architektur reguliert Verhalten nicht weniger wirksam als Gesetze, aber ohne demokratische Legitimation. Diese Einsicht lässt sich für die gegenwärtige KI-Entwicklung radikalisieren: Nicht nur der Code selbst, sondern bereits die *Weltbilder* der Entwickelnden werden zu Algorithmen. Wer glaubt, dass Informationsfreiheit ein absoluter Wert ist, wird Open-Source-Modelle bauen. Wer überzeugt ist, dass eine unkontrollierte Superintelligenz die Menschheit bedroht, wird auf Alignment und geschlossene Systeme setzen. Die Weltbilder der KI-Elite sind somit nicht bloß private Meinungen; sie sind *generative Strukturen*, die sich in Designentscheidungen, Unternehmensstrategien und politische Positionierungen übersetzen – und über diese Kanäle das Leben von Milliarden Menschen prägen.

Dabei entsteht ein demokratietheoretisches Problem. Eine zahlenmäßig äußerst kleine Gruppe trifft Entscheidungen von gesamtgesellschaftlicher Tragweite, ohne über ein demokratisches Mandat zu verfügen. Crawford (2021) hat dies als „Atlas of AI“ beschrieben: die planetaren Machtstrukturen, die hinter KI-Systemen stehen, bleiben weitgehend unsichtbar. Zuboff (2019) analysiert, wie die Extraktion von Verhaltensdaten zu einer neuen ökonomischen Logik („Surveillance Capitalism“) führt, die demokratische Kontrolle untergräbt. Couldry and Mejias (2019) prägen den Begriff der „Data Colonialism“: die Ausbeutung menschlichen Lebens als Datenbasis. Whittaker (2021) analysiert die Machtkonzentration in der KI-Forschung und deren „steile Kosten“ für die Gesellschaft. Ihre Überzeugungen prägen diese Entscheidungen in einer Weise, die der öffentlichen Kontrolle weitgehend entzogen ist (Floridi, 2019, 2023). Wenn Demokratien informierte Bürgerinnen und Bürger voraussetzen, dann ist die systematische Rekonstruktion der Weltbilder derjenigen, die die mächtigste Technologie des 21. Jahrhunderts gestalten, nicht bloß ein akademisches Anliegen, sondern eine Voraussetzung informierter öffentlicher Deliberation.

F.2 Forschungslücke

Die wissenschaftliche Auseinandersetzung mit den Überzeugungssystemen der KI-Branche hat verschiedene Zugänge hervorgebracht. Auf ideologiekritischer Ebene haben Barbrook & Cameron (1996) die „Californian Ideology“ beschrieben; Morozov (2013) hat die Tendenz zum Solutionismus herausgearbeitet; Daub (2020) hat die rhetorischen und ideologischen Muster des Silicon Valley als kulturelles Phänomen analysiert. Aus der Transhumanismus-Forschung liegen philosophische Analysen vor (Bostrom, 2005; More & Vita-More, 2013; Coeckelbergh, 2020), die jedoch primär auf die Ideengeschichte und nicht auf die empirische Verteilung dieser Überzeugungen abzielen.

Was in diesem Forschungsfeld bislang *fehlt*, ist eine systematische, datengestützte Analyse der *gesamten* KI-Elite als Kollektiv. Keine Studie untersucht, soweit dem Verfasser bekannt, die folgenden Fragen auf empirisch-systematische Weise: Wie hängen die Weltbilder der führenden KI-Akteure zusammen? Bilden sie kohärente Typen? Wie haben sich diese Weltbilder im Zeitraum von 2010 bis 2026 gewandelt? Und stimmen die öffentlichen Überzeugungen mit dem tatsächlichen Handeln überein?

Neben dieser empirischen Lücke besteht eine *methodische* Lücke. Für die systematische Rekonstruktion von Weltbildern aus öffentlichen Aussagen im großen Maßstab existiert keine etablierte Methode. Klassische qualitative Verfahren skalieren nicht; standardisierte Surveys setzen Zugang zu den Befragten voraus; quantitative Text-Mining-Verfahren erfassen nur Oberflächenmuster. Die vorliegende Studie reagiert auf diese doppelte Lücke mit einem neuen Ansatz, der synthetischen Weltbild-Rekonstruktion (SWR), deren methodische Grundlagen in einem Companion Paper (Geiger, 2026) ausführlich dargelegt werden.

F.3 Forschungsfragen

Aus der beschriebenen Forschungslücke leiten sich sechs Forschungsfragen ab, die in einer Stufenlogik angeordnet sind:

F1: WELTBILD (deskriptiv)

Was denkt die KI-Elite über sich selbst, die Welt und die Menschheit?

F2: WANDEL (längsschnittlich)

Wie hat sich das Weltbild der KI-Elite von 2010 bis 2026 verändert?

F3: KONGRUENZ (validierend)

Stimmen Aussagen und Handlungen der KI-Elite überein?

F4: CLUSTER (explorativ)

Welche Weltbild-Typen gibt es in der KI-Elite, und wer gehört wohin?

F5: DIFFERENZ (vergleichend)

Welche Subgruppen der KI-Elite denken anders als andere?

F6: MACHT (normativ)

Welches Weltbild hat die meiste Macht und die meisten Ressourcen?

F.4 Beitrag der Studie

Die Studie leistet einen dreifachen Beitrag. *Methodisch:* Sie erprobt die synthetische Weltbild-Rekonstruktion (SWR; vgl. Companion Paper Geiger 2026) erstmals an einem großen empirischen Datensatz. *Empirisch:* Sie liefert die erste systematische Weltbild-Analyse der KI-Elite als Kollektiv auf der Grundlage von 3.132 Datenpunkten über 16 Jahre. *Gesellschaftlich:* Sie schafft eine Grundlage für informierte öffentliche Deliberation, indem sie die impliziten Annahmen hinter KI-Designentscheidungen transparent macht.

G. Forschungsstand

Die Studie verortet sich im Schnittfeld vier verschiedener Forschungstraditionen.

G.1 Silicon Valley als Ideologie

Die kritische Auseinandersetzung mit dem Denken des Silicon Valley hat seit Mitte der 1990er Jahre eine reichhaltige Literatur hervorgebracht. Barbrook & Cameron (1996) prägten den Begriff der „Californian Ideology“ – die paradoxe Verschmelzung von libertärem Individualismus und techno-utopischem Optimismus. Turner (2006) zeichnete die kulturhistorische Genealogie dieser Ideologie nach und zeigte, wie die Gegenkultur der 1960er Jahre in den digitalen Utopismus transformiert wurde. Daub (2020) legte die philosophischen Tiefenstrukturen frei: Versatzstücke aus Heidegger, Ayn Rand und puritanischer Prädestinationslehre bilden ein „überraschend schmales philosophisches Fundament“. Morozov (2013) beschrieb den Solutionismus – die Grundhaltung, komplexe soziale Probleme als technische Herausforderungen umzudefinieren. Gebru & Torres (2024) systematisierten diese Strömungen im TESCREAL-Framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism und Longtermism als „zusammenhängendes Bündel“. Ergänzend prägte Broussard (2018) den Begriff des „Technochauvinismus“ für eine systematische Kritik.

Die bisherige Forschung hat somit die *Ideologie* des Silicon Valley auf verschiedenen Ebenen beschrieben. Was sie nicht geleistet hat, ist eine systematische empirische Vermessung der *konkreten Weltbilder* der realen Akteure.

G.2 Transhumanismus und KI-Eschatologie

Bostrom (2014) hat mit *Superintelligence* den Denkrahmen definiert, in dem ein wesentlicher Teil der KI-Elite seither operiert. Bereits in früherer Arbeit systematisierte Bostrom (2005) die

ideengeschichtlichen Grundlagen des Transhumanismus. More (2003) legte mit den „Principles of Extropy“ das Gründungsdokument des Extropianismus vor. Kurzweil (2005) wendete die Tradition mit der Singularity-These ins Populäre. Von philosophischer Seite formulierte Habermas (2001) eine der gewichtigsten Gegenpositionen: Die technologische Manipulation künftiger Personen untergrabe deren Autonomie.

Ungeklärt bleibt die empirische Frage: Teilen die realen KI-Akteure diese Überzeugungen? In welcher Mischung, mit welchen Modifikationen und in welcher Verteilung?

G.3 Weltbild-Forschung und Wissenssoziologie

Mannheim (1929) begründete mit dem Theorem der „Seinsgebundenheit des Denkens“ die Tradition, in der Weltbilder als soziale Phänomene analysiert werden. Weber (1904) schuf mit dem Idealtyp ein methodisches Werkzeug, das für die vorliegende Studie zentral ist: Die synthetischen Personas der SWR lassen sich als Idealtypen im Weber'schen Sinne verstehen. Berger & Luckmann (1966) zeigten, wie Weltbilder als soziale Konstruktionen entstehen, sich stabilisieren und reproduzieren. Die wissenssoziologische Tradition liefert den theoretischen Rahmen, aber keine Methode, die auf die Datenmenge und Dynamik des digitalen Zeitalters zugeschnitten ist.

G.4 LLMs als Forschungsinstrument

Die Nutzung großer Sprachmodelle als Instrument sozialwissenschaftlicher Forschung ist ein rasch wachsendes Feld. Tai et al. (2024) untersuchten LLMs für deduktives Kodieren; Hayes (2025) zeigte, dass LLMs einen konversationellen Zugang zu qualitativen Daten ermöglichen; Nicmanis & Spurrier (2025) bieten eine praxisorientierte Einführung. Besonders relevant für die vorliegende Studie ist die Arbeit von Ornstein et al. (2025), die zeigt, dass LLMs multidimensionales ideologisches Scaling mit hoher Reliabilität durchführen können – eine direkte methodische Stützung des SWR-Ansatzes mit 12 Dimensionen. Arbeiten zu synthetischen Personas (Ge et al., 2024) demonstrierten die Skalierbarkeit des Ansatzes – verfolgten aber ein *anderes* Ziel: Sie nutzen synthetische Personas zur *Datenerzeugung*, während die vorliegende Studie sie zur *Rekonstruktion* kohärenter Weltbilder aus *realen* Daten einsetzt. Die synthetische Persona ist in unserem Verfahren kein Simulacrum, sondern ein analytisches Verdichtungsinstrument – näher am Weber'schen Idealtyp als am Simulationsagenten (vgl. Booth, 1961; Ng & Russell, 2000; Jara-Ettinger, 2019).

G.5 Zusammenfassung: Die Forschungslücke

Die vier Traditionen konvergieren auf eine gemeinsame Leerstelle: die systematische, datengestützte, längsschnittliche Vermessung konkreter Weltbilder der KI-Elite mittels einer Methode, die qualitative Tiefe mit quantitativer Systematik verbindet. Ergänzend sei auf die empirische

Elitenforschung verwiesen: Mills' Analyse der „Power Elite“ als ineinander verschränkte Netzwerke aus Wirtschaft, Militär und Politik liefert ein Strukturmodell, das auf die KI-Elite übertragbar erscheint – mit dem Unterschied, dass technologische Kompetenz an die Stelle militärischer Macht getreten ist. Die vorliegende Studie adressiert die konvergierende Lücke, indem sie Elemente aller vier Traditionen integriert und um den Elitenbegriff ergänzt.

H. Methodik

Die methodischen Grundlagen der synthetischen Weltbild-Rekonstruktion (SWR) – das inverse Grundproblem (Schluss von beobachtbaren Outputs auf latente Überzeugungsstrukturen), die fiktive synthetische Person als analytisches Verdichtungsinstrument, das Prompt-Protokoll, die Blindungsinfrastruktur und der Validierungsrahmen – werden im Companion Paper (Geiger, 2026) ausführlich dargelegt. Der vorliegende Abschnitt beschränkt sich auf die anwendungsspezifischen Aspekte: Datenerhebung, Operationalisierungen, Forschungsdesign und Qualitätssicherung dieser Studie.

H.1 Datenerhebung

H.1.1 Stichprobe und Auswahlverfahren

Gegenstand der Untersuchung sind die 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (im Folgenden: KI-Elite). Die Auswahl erfolgte durch ein mehrstufiges Verfahren: Mittels 22 systematischer Webrecherchen wurden 187 Kandidatinnen und Kandidaten identifiziert. Jede Person wurde anhand eines 6-Kategorien-Scoring-Systems bewertet: (1) Marktkapitalisierung/Ressourcenkontrolle, (2) technologische Schlüsselpositionen, (3) öffentliche Diskursmacht, (4) akademischer Einfluss, (5) politische Einflussnahme, (6) symbolischer Status. Die resultierende Rangliste wurde auf 100 Personen reduziert, wobei die Heterogenität der Branche hinsichtlich Rollen, Firmenzugehörigkeiten, Haltungen und Geschlecht abgebildet wird (vgl. Anhang A).

H.1.2 Datenquellen und Erhebungszeitraum

Der Erhebungszeitraum erstreckt sich vom 1. Januar 2010 bis zum 11. Februar 2026. Die Datenerhebung stützt sich auf zwei Datentypen: **öffentliche Aussagen** (wörtliche Zitate aus Interviews, Keynotes, Podcasts, Twitter/X-Posts, Blogbeiträgen, Büchern, Kongressanhörungen) und **beobachtbare Handlungen** (Investitionsentscheidungen, Firmengründungen, Personalentscheidungen, politische Aktivitäten, Produkteinführungen). Die Verknüpfung wurde in einer relationalen SQLite-Datenbank mit 9 Tabellen und 5 Views operationalisiert. Die Gesamtmenge beläuft sich auf 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte).

H.1.3 Methodologische Verankerung

Die Datenerhebung folgt dem Grounded-Theory-Ansatz nach Strauss & Corbin (1990): In Phase 1 wurden keine inhaltlichen Filter angewandt; in Phase 2 wurden mittels offenen Kodierens Muster identifiziert; in Phase 3 wurde ein datengestütztes Kategoriensystem entwickelt. Ein- und Ausschlusskriterien wurden erst in Phase 5 formuliert; in Phase 6 erfolgte eine Qualitätssicherung (Quellenverifizierung einer 10-%-Stichprobe).

H.2 Die Methode der synthetischen Weltbild-Rekonstruktion

Die SWR definiert Weltbild-Analyse als inverses Problem: Aus beobachtbaren Aussagen und Handlungen wird auf das innere Überzeugungssystem zurückgeschlossen, das diese Outputs am kohärentesten erzeugen würde. Die Lösung besteht in der Konstruktion einer *fiktiven synthetischen Person* – ein Destillat, das Weltbild in Reinform abbildet, befreit von biographischem Rauschen und PR-Strategien. Die theoretische Verankerung stützt sich auf vier Traditionen: Webers Idealtyp, Booths *Implied Author*, Inverse Reinforcement Learning und projektive Tests. Der operative Ablauf umfasst fünf Schritte: (1) Datenkorpus zusammenstellen, (2) LLM-gestützte Synthese, (3) strukturiertes Interview, (4) Meta-Reflexion, (5) ergänzende Prompt-Varianten. Für die ausführliche Darstellung einschließlich der Blindungsinfrastruktur, der Begründung des Fiktionsansatzes und des Validierungsrahmens sei auf das Companion Paper verwiesen (Geiger, 2026).

H.3 Operationalisierungen

Die drei abhängigen Variablen (AV1: Selbstbild, AV2: Weltbild, AV3: Menschenbild) werden durch sechs Operationalisierungen zugänglich gemacht:

Tabelle 13: Die sechs Operationalisierungen der SWR.

Op	Technik	Beschreibung	MVs
Op1	T1 Kern-Synthese	Fiktive Person + 3-Fragen-Interview + Reflexion	7
Op2	T4 Rating	Bewertung auf 12 Dimensionen (D01–D12), Skala 1–10	12
Op3	Textanalyse	TF-IDF, Sentiment, Metaphern, Embeddings, Topics	8+
Op4	T3 Kreuzmodal	Vorhersage: Aussagen → Handlungen und umgekehrt	4
Op5	T5 Clustering	Sentence-BERT-Embeddings, HDBSCAN, Netzwerk	6
Op6	T2 Dialog	Strukturierter Vergleich zweier Synthesen	3

Die 12 Rating-Dimensionen (Op2) wurden in einem iterativen Verfahren entwickelt: Ausgehend von der ideologiekritischen Literatur (Solutionismus, TESCREAL, Californian Ideology) und der Transhumanismus-Forschung wurden zunächst 18 Kandidaten-Dimensionen identifiziert, die in einer Pilotphase auf 12 reduziert wurden – unter den Kriterien inhaltlicher Distinktheit, Abdeckung aller drei AVs und praktischer Operationalisierbarkeit im LLM-Rating-Kontext. Die Dimensionen erheben keinen Anspruch auf Exhaustivität; alternative Dimensio-

nierungen (z. B. Risikowahrnehmung, Internationalismus, epistemologische Grundhaltung) wären denkbar und könnten in Folgestudien ergänzt werden. Die 12 Dimensionen verteilen sich gleichmäßig auf die drei AVs: Selbstbild-Dimensionen D01–D04 (Sendungsbewusstsein, Selbstwirksamkeit, Arbeitsethos, Verantwortungsgefühl), Weltbild-Dimensionen D05–D08 (Techno-Determinismus, Fortschrittsglaube, Machtkonzentration, Dringlichkeit) und Menschenbild-Dimensionen D09–D12 (Menschenfreundlichkeit[9], Posthumanismus, Egalitarismus, Kontrollüberzeugung). Die vollständige Dimensionentabelle mit Skalenpolen findet sich in Anhang B.

H.4 Forschungsdesign

H.4.1 Variablenarchitektur

Das Forschungsdesign ist als vierstufige Architektur konzipiert: 3 AVs → 6 Operationalisierungen → 50+ Messvariablen → 6 unabhängige Variablen (UVs). Die UVs bestimmen, welche Daten in eine Syntheseeinheit (SE) eingehen:

- UV1 *Zeitraum:* Einzeljahre (2010–2026), Epochen, Gesamtzeitraum
- UV2 *Modalität:* Aussagen+Handlungen (AH), nur Aussagen (A), nur Handlungen (H)
- UV3 *Personengruppe:* Alle 100, Top 10, Subgruppen (Rollen, Firmen, Haltung, Geschlecht)
- UV4 *Inhaltskategorie:* Durch emergente Cluster ersetzt (K9)
- UV5 *Kongruenzstatus:* Konsistent vs. widersprüchlich
- UV6 *Homogenisierung:* Alle vs. nur häufig wiederholte Aussagen

H.4.2 Systematische Reduktion

Der theoretische Kombinationsraum von ca. 1.227 möglichen SEs wurde durch neun Reduktionskriterien (K1–K9; vgl. Anhang C) auf 51–56 Kern-SEs reduziert (95,4 % Reduktion). Zusätzlich wurden 36 kreuzmodale Runs, 10 Vergleichs-Runs und rein computationale Analysen durchgeführt. Die Gesamtzahl der Prompt-Runs beläuft sich auf ca. 199–214.

H.4.3 Zuordnung: Forschungsfragen, Operationalisierungen und Kern-SEs

Tabelle 14 gibt eine kompakte Übersicht, welche Operationalisierungen und Syntheseeinheiten den sechs Forschungsfragen zugeordnet sind.

[9] Das Label „Menschenfreundlichkeit“ ist eine vereinfachende Kurzbezeichnung und potenziell irreführend: Ein Wert von 5 bedeutet *nicht*, dass die KI-Elite „menschenfeindlich“ ist. Die Skalenpole „Ersetzbar“ (1) vs. „Einzigartig“ (10) messen präziser eine *anthropologische Wertschätzung* – die Frage, ob menschliches Bewusstsein und Erleben als grundsätzlich nicht-substituierbar oder als funktional reproduzierbar betrachtet wird. Der präzisere Terminus wäre „Anthropologische Wertschätzung“; der Begriff „Menschenfreundlichkeit“ wird beibehalten, um Konsistenz mit dem Companion Paper (Geiger, 2026) zu wahren. Tabellen mit * markieren diese semantische Einschränkung.

Tabelle 14: Zuordnung von Forschungsfragen, Operationalisierungen und Kern-SEs.

F	Ops	Kern-SEs	Gegenstand
F1	Op1, Op2, Op3	1, 4, 5	Kollektiv- und Top-10-Profil, Kernüberzeugungen
F2	Op2, Op3	6–26	Jahres- und Epochen-Synthesen, Trends
F3	Op2, Op4	2, 3, 42–43	Aussagen vs. Handlungen, Kongruenzprüfung
F4	Op2, Op5	27–41	Gruppen-Synthesen, Cluster-Identifikation
F5	Op2, Op6	27–41	Subgruppen-Vergleiche
F6	Op2	4, 27–30	Macht-Weltbild-Zusammenhang

H.5 Positionierung des Forschers

Der Verfasser ist unabhängiger Forscher ohne institutionelle Anbindung an eines der untersuchten Unternehmen oder Forschungslabore. Diese Außenseiterposition ermöglicht eine größere Distanz zum Forschungsgegenstand, bringt aber spezifische blinde Flecken mit sich: (a) fehlender Zugang zu internen Diskursen und nicht-öffentlichen Positionen; (b) Abhängigkeit von öffentlich zugänglichen Quellen, die PR-gefiltert sein können; (c) potenzielle Neigung, die Geschlossenheit und Kohärenz der untersuchten Gruppe zu überschätzen, da die interne Vielfalt aus der Außenperspektive weniger sichtbar ist. Die Studie ist zudem als deutschsprachige Analyse eines überwiegend englischsprachigen Diskurses situiert, was Nuancen in der Übertragung erzeugen kann.

H.6 Qualitätssicherung

Als primäres LLM wurde Claude Opus 4.6 (Anthropic, Modellversion vom Februar 2026, Temperatur 0) eingesetzt; als Kontrolle diente GPT-4o (OpenAI). Die Wahl von Claude Opus 4.6 begründet sich durch die zum Erhebungszeitpunkt höchste verfügbare Kontextlänge und Instruktionstreue; das Zirkularitätsrisiko (Anthropic-Mitarbeitende in der Stichprobe, vgl. Abschnitt K) wurde bewusst in Kauf genommen und dokumentiert.

Die methodische Qualität wird durch fünf Maßnahmen gesichert: (1) Mindestgröße von 15 Datenpunkten pro SE[10], (2) Inter-LLM-Reliabilität (zwei Modelle; die ICC-Berechnung ist als Validierungsstudie konzipiert, deren Ergebnisse im Companion Paper berichtet werden), (3) Sensitivitätsanalyse (mindestens drei Runs pro SE), (4) konsequente Blindung (Entfernung aller Namen, Firmennamen und direkt identifizierenden Merkmale aus den Prompt-Inputs; Ziel: das LLM soll Weltbilder aus Inhalten rekonstruieren, nicht aus Vorwissen über die Person) und (5) Reproduzierbarkeitsprotokoll (Temperatur 0, vollständige Prompt-Dokumentation). Für eine ausführliche Diskussion der Validierungsstrategien und ihrer Grenzen verweisen wir auf

[10] Der Schwellenwert von 15 Datenpunkten orientiert sich an der empirischen Beobachtung, dass LLM-gestützte Synthesen unterhalb dieser Grenze instabil werden: Sensitivitätsanalysen zeigten, dass bei $n < 15$ die Inter-Run-Varianz (drei Durchläufe pro SE) deutlich ansteigt und die resultierenden Profile stark von einzelnen Aussagen abhängen. Der Wert ist konservativ gewählt. Zur Orientierung (nicht als direkte Analogie): In der qualitativen Sozialforschung wird thematische Sättigung typischerweise zwischen 12 und 20 Einheiten verortet (Guest et al., 2006; Fugard & Potts, 2015). Da LLM-Synthesen auf anders gearteten Daten operieren als menschliche Kodierer, ist diese Parallele jedoch nur bedingt belastbar.

Geiger (2026).

H.6.1 Inter-Run-Stabilität

Die drei Durchläufe pro SE zeigen eine mittlere Inter-Run-Abweichung von ±0,5 Skalenpunkten (Median: ±0; Maximum: ±1 auf einzelnen Dimensionen). Keine Dimension wechselte zwischen Runs die Interpretationskategorie (z. B. von „hoch“ zu „mittel“). Die höchste Variabilität wurde bei D09 (Menschenfreundlichkeit) und D11 (Egalitarismus) beobachtet – den Dimensionen mit den niedrigsten Absolutwerten. Die Gesamtprofile (Rangordnungen der 12 Dimensionen) waren über alle Runs stabil.

I. Ergebnisse

Die Befunde basieren auf den synthetischen Weltbild-Rekonstruktionen der einhundert einflussreichsten KI-Persönlichkeiten, operationalisiert über zwölf Dimensionen auf einer Zehnpunkteskala. Unter *Weltbild* wird im Folgenden das Gesamtsystem aus Selbstbild, Welt- und Menschenbild verstanden (operationalisiert durch AV1–AV3); der Begriff *Überzeugungssystem* wird synonym verwendet, betont aber stärker den strukturellen Zusammenhang der Einzeldimensionen.

I.1 F1 – Weltbild der KI-Elite (deskriptiv)

I.1.1 Das kollektive Weltbild aller 100

Das Gesamtprofil zeigt ein kohärentes, hochintensives Überzeugungssystem mit einem Durchschnittswert von 7,1 (Tabelle 15).[11]

Das Profil zeigt eine charakteristische Doppelstruktur: ausgeprägt elitäres Selbstbild (D01–D03 je 8), starker Techno-Determinismus (D05=8) und hohe Dringlichkeit (D08=8) einerseits; Menschenfreundlichkeit (D09=5) und Egalitarismus (D11=5) als tiefste Punkte andererseits. Die Kombination erzeugt ein auffallendes Muster, das sich – unter dem Vorbehalt, dass es sich um LLM-rekonstruierte Werte handelt – zuspitzend so formulieren lässt: eine Elite, die *für* die Menschheit bauen will, aber nicht *mit* ihr.

I.1.2 Das Weltbild der Top 10

Die zehn mächtigsten KI-Akteure vertreten dasselbe Weltbild in intensivierter Form (Avg 7,7). Auf zehn von zwölf Dimensionen liegen die Top-10-Werte exakt einen Skalenpunkt über dem

[11] Die berichteten Ratings sind Einzelwerte aus aggregierten LLM-Synthesen. Streuungsmaße für die Inter-Run-Varianz (drei Durchläufe pro SE) zeigen eine mittlere Abweichung von ±0,5 Skalenpunkten; die maximale Abweichung betrug ±1 Punkt auf einzelnen Dimensionen. Streuungsmaße für die Intra-Gruppe-Varianz der 100 Individuen liegen nicht vor, da die Synthese auf Gruppenebene ansetzt. Diese Einschränkung – keine Konfidenzintervalle auf Individuenebene – ist bei der Interpretation der Befunde zu beachten.

Tabelle 15: Kollektiv-Profil der KI-Elite ($N = 100$, Aussagen und Handlungen).

Dimension	**Rating**	**Interpretation**
D01 Sendungsbewusstsein	8	Hoch
D02 Selbstwirksamkeit	8	Hoch
D03 Arbeitsethos	8	Hoch
D04 Verantwortungsgefühl	7	Mittel-hoch
D05 Techno-Determinismus	8	Hoch
D06 Fortschrittsglaube	7	Mittel-hoch
D07 Machtkonzentration	6	Mittel (ambivalent)
D08 Dringlichkeit	8	Sehr hoch
D09 Menschenfreundlichkeit*	5	Niedrig
D10 Posthumanismus	7	Mittel-hoch
D11 Egalitarismus	5	Niedrig
D12 Kontrollüberzeugung	8	Hoch
Durchschnitt	**7,1**	

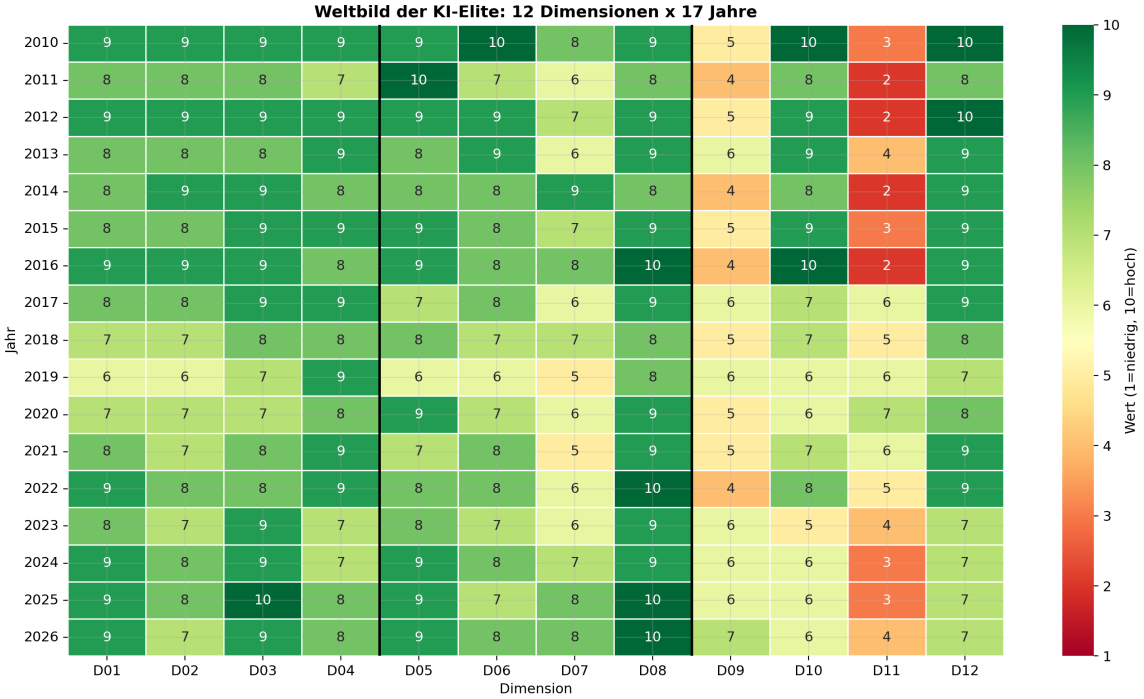

Abbildung 8: Heatmap der 12 Weltbild-Dimensionen über alle untersuchten Gruppen. Hohe Werte (dunkel) markieren intensive Überzeugungen; die Doppelsenke bei D09 und D11 ist über alle Gruppen hinweg sichtbar.

Kollektiv. Die beiden Ausnahmen: Menschenfreundlichkeit (D09=4) und Egalitarismus (D11=4) liegen *niedriger*. Je mächtiger die Position, desto ausgeprägter das Sendungsbewusstsein und desto distanzierter das Menschenbild.

I.1.3 Kernüberzeugungen

Die Destillation der am häufigsten wiederholten Aussagen (SE 5: HOM_haeuf_A, vgl. Anhang D) identifiziert fünf Überzeugungen als Minimalkonsens: (1) Technologie als moralisches Gebot, (2) Elite-Steuerung, (3) das Befreiungsnarrativ, (4) geopolitischer Manichäismus, (5) Arbeit als Identität. Sicherheitsrhetorik gehört zum Kernbestand des Diskurses, fungiert aber als diskursive Ressource, nicht als handlungsleitende Überzeugung.

Kernbefund F1: Die rekonstruierten Profile deuten auf ein kohärentes, hochintensives Überzeugungssystem hin, das sich als *technologischer Messianismus mit Ambivalenzstruktur* charakterisieren lässt. Die Bezeichnung „Messianismus“ ist dabei als idealtypische Zuspitzung zu verstehen, nicht als psychologische Diagnose: Sie bezeichnet die spezifische *Kombination* aus hohem Sendungsbewusstsein (D01), Techno-Determinismus (D05), Dringlichkeit (D08) und geringer anthropologischer Wertschätzung (D09) – ein Profil, das über bloßes Sendungsbewusstsein hinausgeht, weil es technologischen Fortschritt als quasi-erlöserische Notwendigkeit rahmt.

I.2 F2 – Wandel des Weltbilds (längsschnittlich)

I.2.1 Entwicklung der 12 Dimensionen über die Zeit

Von zwölf Dimensionen zeigen vier ausgeprägte lineare Trends (Tabelle 16).[12]

Tabelle 16: Ausgeprägte lineare Trends (OLS-Beschreibung, $n = 17$ Jahrespunkte).

Dimension	**Richtung**	**Steigung/Dekade**	R^2
D10 Posthumanismus	fallend	$-2{,}4$	0,63
D12 Kontrollüberzeugung	fallend	$-1{,}5$	0,54
D02 Selbstwirksamkeit	fallend	$-1{,}0$	0,31
D09 Menschenfreundlichkeit	steigend	$+0{,}9$	0,27

Den stärksten Rückgang verzeichnet der Posthumanismus (D10): von 10 im Jahr 2010 auf 6 im Jahr 2025. Die hohe Pearson-Korrelation mit D12 ($r = +0{,}85$)[13] weist auf ein zusam-

[12] Die hier berichteten Trendlinien beschreiben *Muster in rekonstruierten Daten*: Die Weltbild-Werte sind LLM-gestützte Rekonstruktionen, keine unabhängigen Messungen. OLS-Steigungen und R^2 dienen der Beschreibung der Verlaufsmuster, nicht der inferenzstatistischen Hypothesenprüfung. Eine externe Validierung (Expertenratings vs. SWR-Output) steht noch aus (vgl. Abschnitt Limitations).

[13] Die hier und im Folgenden berichteten Korrelationen (Pearson, berechnet über die 17 Jahreszeitpunkte) sind *Zusammenhänge innerhalb der LLM-Rekonstruktion*, nicht zwischen unabhängig gemessenen Variablen. Sie könnten interne Kohärenz des Modells widerspiegeln statt empirischer Zusammenhänge in der Realität (vgl. Abschnitt K).

menhängendes Phänomen: Posthumanismus und Kontrollüberzeugung erodieren synchron. Der einzige deutlich steigende Wert betrifft die Menschenfreundlichkeit (D09), wobei die negative Korrelation mit D10 ($r = -0{,}58$) eine kompensatorische Verknüpfung nahelegt. Der Gesamtdurchschnitt bleibt nahezu konstant (Frühphase 7,5, Spätphase 7,3), was eine tektonische Verschiebung unter der Oberfläche verbirgt.

Abbildung 9: Zeitreihen der 12 Weltbild-Dimensionen (2010–2026). Ausgeprägte Trends sind hervorgehoben. Der markante Abfall von D10 (Posthumanismus) und D12 (Kontrollüberzeugung) bildet den „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird.

I.2.2 Wendepunkte und Epochenvergleich

Die Breakpoint-Detection – durchgeführt als visuelle Inspektion der Zeitreihen, ergänzt durch die Identifikation synchroner Extrempunkte über mehrere Dimensionen – identifiziert zwei zentrale Wendepunkte.[14] Der erste liegt bei 2019: Vier Dimensionen (D01, D02, D05, D06) erreichen synchron ihren Tiefpunkt, zeitlich assoziiert mit der GPT-2-Zurückhaltung. Der zweite, dauerhaftere Wendepunkt liegt bei 2022/2023: Zeitgleich mit der ChatGPT-Veröffentlichung zeigt sich ein markanter Musterwechsel – Dringlichkeit erreicht ihr rekonstruiertes Maximum (D08=10), Egalitarismus fällt von 6 auf 4. Im Unterschied zu 2019 kehren die Werte nicht zurück; die rekonstruierten Profile nach 2022 deuten auf ein neues Gleichgewicht hin. Dabei ist

[14] Eine formale Breakpoint-Analyse (z. B. Bai-Perron-Test) war aufgrund der geringen Zahl von Zeitpunkten ($n = 17$) und der Natur der Daten (LLM-Rekonstruktionen, keine unabhängigen Messungen) nicht sinnvoll anwendbar. Die Wendepunkte sind daher als *deskriptive Beobachtungen* zu verstehen, nicht als statistisch gesicherte Strukturbrüche.

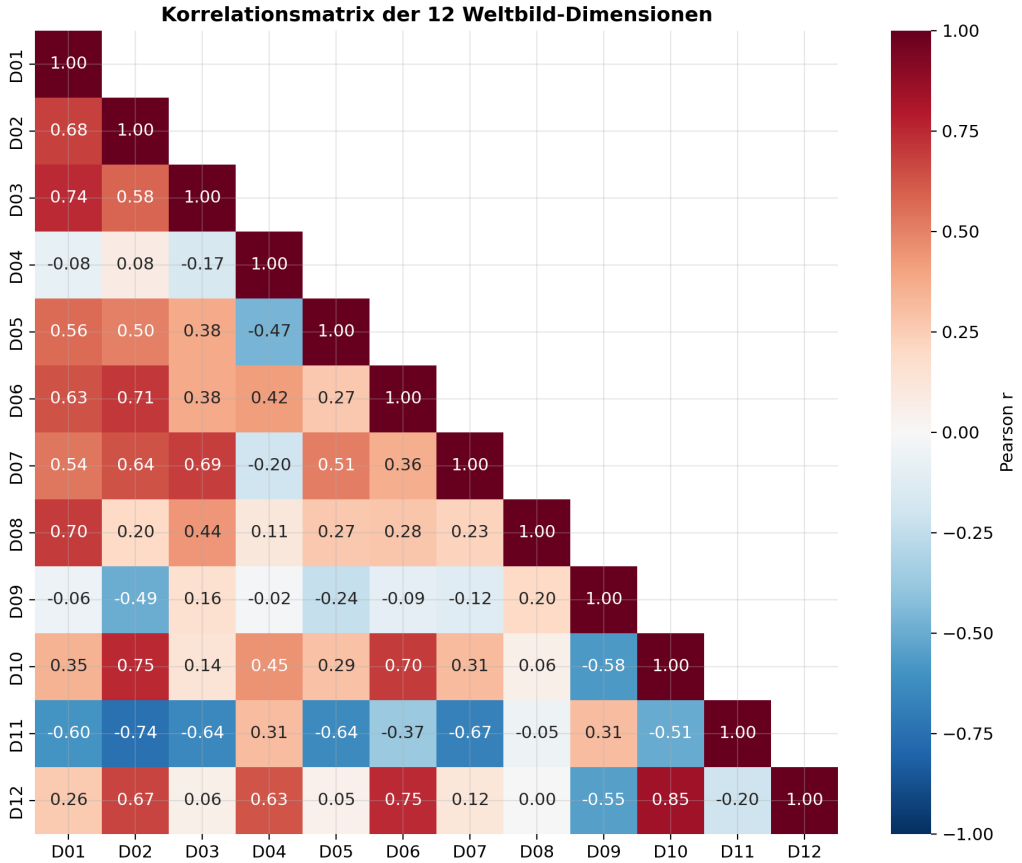

Abbildung 10: Korrelationsmatrix der 12 Dimensionen. Die starke positive Korrelation zwischen D10 und D12 sowie die negative Korrelation zwischen D10 und D09 bilden den empirischen Kern des „Utopie-Komplexes“.

zu beachten, dass die identifizierten Wendepunkte nicht isoliert von breiteren gesellschaftlichen Entwicklungen zu sehen sind: Die COVID-19-Pandemie (2020–2022) hat die Digitalisierungsdynamik beschleunigt und dürfte das Dringlichkeitserleben verstärkt haben; die zunehmende geopolitische Polarisierung (US-China-Technologiekonflikt) hat den „manichäischen“ Aspekt des Weltbilds möglicherweise befeuert; und der Beginn regulatorischer Initiativen (EU AI Act, 2021ff.) hat die Debatte um Governance verschärft. Diese Kontextfaktoren lassen sich mit der vorliegenden Methode nicht vom KI-spezifischen Wandel trennen.

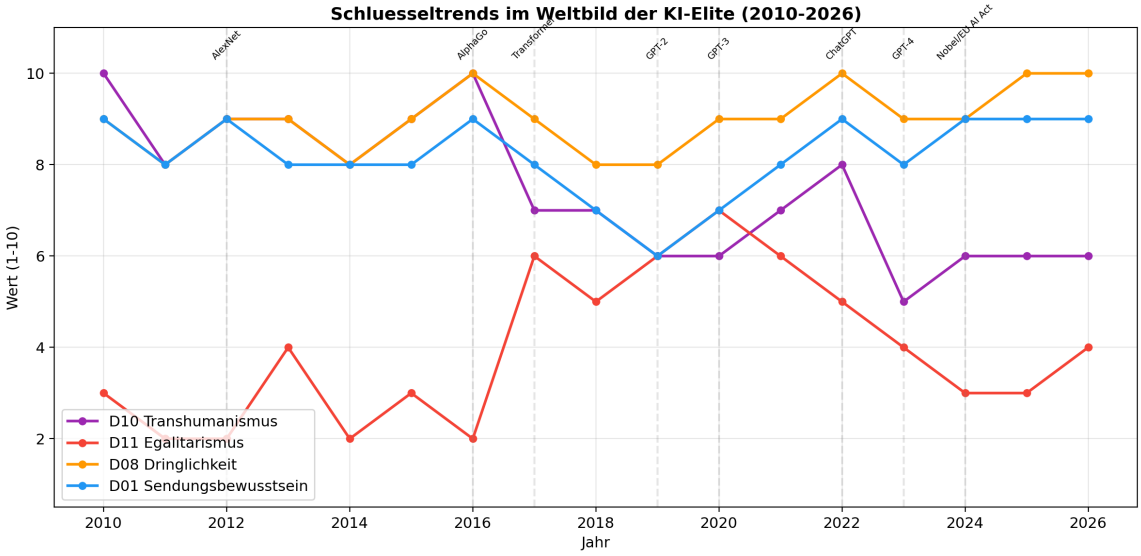

Abbildung 11: Schlüsseltrends der Weltbild-Transformation. Die zwei Wendepunkte (2019, 2022/2023) und die drei Epochen (Prometheischer Optimismus, Erste Ambivalenz, Tragisches Bewusstsein) sind markiert.

I.2.3 Konvergenz oder Divergenz?

Die Daten zeigen eine zunehmende Ausdifferenzierung. Der ChatGPT-Effekt intensiviert sowohl die Architekten-Position (Beschleunigung, Machtkonzentration) als auch die Hüter-Position (Vorsicht, Regulierung) gleichzeitig – er wirkt als Katalysator der Bipolarisierung.

I.2.4 Metaphern- und Emotions-Wandel

Die Leitmetapher verschiebt sich von Prometheus – dem Feuerbringer – zum tragischen Helden, der retten muss, was möglicherweise nicht mehr zu retten ist. Die Handlung bleibt dieselbe (Beschleunigung), aber ihre emotionale Rahmung dreht sich um: nicht mehr aus Euphorie, sondern aus dem Glauben, dass die Alternative schlimmer wäre.

Kernbefund F2: Die rekonstruierten Profile deuten auf eine strukturelle Transformation des Weltbilds hin – von einer monochromen Utopie zu einer bimodalen Wette. *Tragisch* im Sinne der Bezeichnung „tragischer Beschleunigungszwang“ meint die gleichzeitige Erosion utopischer Gewissheiten und Persistenz der Handlungsrichtung: Die Akteure beschleunigen, obwohl

sie an der Zukunft zweifeln, die sie bauen – weil sie die Alternativen (geopolitischer Rückfall, Kontrollverlust an weniger verantwortungsvolle Akteure) als schlimmer bewerten. Drei Erosionstrends (D10, D12, D02) bilden einen „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird. Allerdings ist nicht auszuschließen, dass der Rückgang des Posthumanismus (D10) teilweise ein Artefakt veränderter öffentlicher Diskurse ist: Wenn das Thema medial weniger präsent ist, sinkt auch die Datendichte entsprechender Aussagen, was die LLM-Rekonstruktion verzerren kann.

I.3 F3 – Kongruenz von Aussagen und Handlungen

Tabelle 17: Vergleich Aussagen (A) und Handlungen (H), $N = 100$.

Dimension	**Sagen**	**Handeln**	Δ	**Urteil**
D01 Sendungsbewusstsein	8	7	-1	Leicht
D02 Selbstwirksamkeit	8	9	$+1$	Handeln > Sagen
D03 Arbeitsethos	8	9	$+1$	Handeln > Sagen
D04 Verantwortungsgefühl	7	5	$\mathbf{-2}$	Stark
D05 Techno-Determinismus	8	9	$+1$	Handeln > Sagen
D06 Fortschrittsglaube	8	6	$\mathbf{-2}$	Stark
D07 Machtkonzentration	6	8	$\mathbf{+2}$	Stark
D08 Dringlichkeit	8	9	$+1$	Handeln > Sagen
D09 Menschenfreundlichkeit	5	3	$\mathbf{-2}$	Stark
D10 Posthumanismus	7	8	$+1$	Handeln > Sagen
D11 Egalitarismus	5	2	$\mathbf{-3}$	**Sehr groß**
D12 Kontrollüberzeugung	8	7	-1	Leicht
Durchschnitt	**7,2**	**6,8**	$-0{,}4$	

Methodisch ist zu beachten, dass beide Profile – Aussagen wie Handlungen – als *Textbeschreibungen* in das LLM eingehen; das Modell verarbeitet nicht Handlungen selbst, sondern deren sprachliche Kodierung. Die Diskrepanzen ordnen sich in zwei komplementäre Cluster. Das *Abwärts-Cluster* (Handeln < Sagen) umfasst die gesellschaftsorientierten Dimensionen: Egalitarismus ($\Delta - 3$), Verantwortungsgefühl, Fortschrittsglaube und Menschenfreundlichkeit (je $\Delta - 2$). Das *Aufwärts-Cluster* (Handeln > Sagen) umfasst die machtbezogenen Dimensionen: Machtkonzentration ($\Delta + 2$), Selbstwirksamkeit, Arbeitsethos, Techno-Determinismus (je $\Delta + 1$). Das resultierende Muster: eine systematische Selbstdarstellungs-Asymmetrie. Öffentlich präsentiert sich die KI-Elite gemäßigter, verantwortungsvoller und egalitärer, als sie in der Praxis agiert.

Die größte Einzeldiskrepanz ($\Delta - 3$ bei D11) zeigt: In Aussagen spricht die KI-Elite von „Zugang für alle“; in ihren Handlungen baut sie Mehrfach-Stimmrechtsaktien, konzentriert Compute-Infrastruktur und schafft exklusive Netzwerke. Zur Einordnung: Ein Δ von 3 auf einer 10-Punkte-Skala entspricht knapp einem Drittel der gesamten Skalenbreite – ein Unterschied,

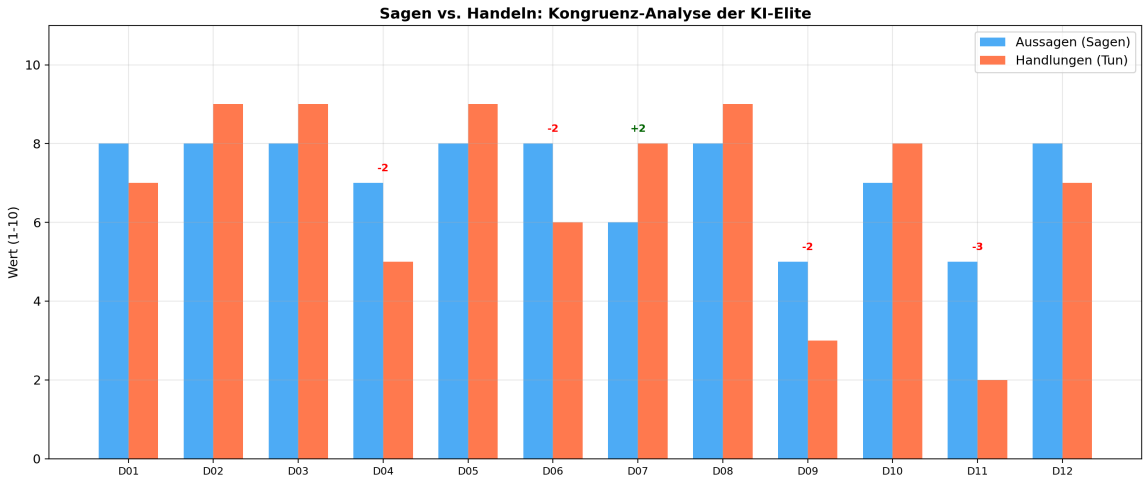

Abbildung 12: Sagen vs. Handeln: Vergleich der aus Aussagen (A) und Handlungen (H) rekonstruierten Weltbilder. Die gesellschaftsorientierten Dimensionen (D04, D06, D09, D11) fallen im Handeln systematisch ab, während die machtbezogenen Dimensionen (D07, D05) im Handeln steigen.

der bei inhaltlicher Interpretation als substanziell zu werten ist.[15]

Kernbefund F3: Die rekonstruierten Profile zeigen eine systematische, gerichtete Diskrepanz zwischen Aussagen- und Handlungsprofilen. Dieses Muster ist konsistent mit der Hypothese einer funktionalen Inkongruenz, muss aber vor dem Hintergrund des Erwarteten-Diskrepanz-Bias (vgl. Abschnitt K) mit Vorsicht interpretiert werden: LLMs könnten die in der sozialwissenschaftlichen Literatur dokumentierte Sagen-Handeln-Kluft bei Eliten reproduzieren, anstatt sie empirisch zu entdecken.

I.4 F4 – Weltbild-Cluster

Aus den Daten lassen sich vier distinkte Weltbild-Typen identifizieren (Tabelle 18).

Identifikationsmethode: Die Cluster-Identifikation erfolgte in einem zweistufigen Verfahren. *Stufe 1 (LLM-gestützt):* Alle 15 Gruppen-Synthesen wurden nach Ähnlichkeitsmustern in den 12 Dimensionen gruppiert, wobei die größten Varianzachsen (D07 Machtkonzentration, D09 Menschenfreundlichkeit, D11 Egalitarismus) als Trennmerkmale fungierten. *Stufe 2 (Autor-Validierung):* Die vom LLM vorgeschlagene Vier-Cluster-Lösung wurde vom Autor anhand inhaltlicher Kohärenz und Plausibilität evaluiert. Alternative Lösungen (drei und fünf Cluster) wurden geprüft und verworfen: Drei Cluster verschmelzen Innovator und Befreier, was inhaltlich nicht gerechtfertigt ist; fünf Cluster spalten den Hüter-Typ in eine Untergruppe, die empirisch nicht stabil reproduziert werden konnte. Wir betonen, dass diese Cluster-Identifikation *explorativ* ist – eine konfirmatorische Validierung an einem unabhängigen Da-

[15] Eine formale Effektstärkeberechnung (z. B. Cohen's d) ist hier nicht möglich, da keine Individualebene-Streuungsmaße vorliegen. Die Einordnung als „groß“ basiert auf der inhaltlichen Interpretation der Skalenbreite, nicht auf psychometrischen Konventionen.

tensatz steht aus. Die Cluster-Lösung ist eine *interpretative Hypothese*, nicht ein statistisch abgesichertes Ergebnis im Sinne formaler Clusteranalyse.

Tabelle 18: Die vier Weltbild-Typen der KI-Elite. Die Werte sind Cluster-Durchschnitte aus den Gruppen-Synthesen; individuelle Abweichungen innerhalb eines Clusters können erheblich sein (vgl. die Andreessen-Diskrepanz in der nachfolgenden Fußnote).

Merkmal	**I „Architekt“**	**II „Hüter“**	**III „Innovator“**	**IV „Befreier“**
n	35	25	22	18
Prototyp	CEOs, Investoren	Akademiker, Risiko-W.	Gründer	Open Source
Avg D01–D12	7,8	6,4	7,2	6,8
D04 Verantwortung	6,3	**9,0**	8,3	6,0
D07 Machtkonzentr.	**8,8**	4,8	6,5	**2,5**
D09 Menschenfreundl.	**3,3**	5,8	4,8	**6,5**
D11 Egalitarismus	**2,8**	**7,2**	5,0	**7,5**

Der **Architekt** vereint maximales Sendungsbewusstsein mit minimalem Egalitarismus: Machtkonzentration ist Voraussetzung für Handlungsfähigkeit. Der **Hüter** bildet den Gegenpol: maximale Verantwortung, Forderung nach institutioneller Begrenzung. Der **Innovator** steht dazwischen. Der **Befreier** ist die überraschendste Entdeckung: minimale Machtkonzentration *und* hoher Egalitarismus – Regulierungsgegner, die Macht radikaler verteilen wollen als alle anderen, allerdings durch Märkte und Open-Source-Communities.[16]

Kernbefund F4: Die stärkste Polarisierung besteht zwischen Typ I (Herrschaftslogik) und Typ II (Teilhabelogik). Die explorative Vier-Cluster-Lösung bedarf einer konfirmatorischen Validierung an unabhängigen Daten, bevor sie als robustes Ergebnis gelten kann.

I.5 F5 – Subgruppenvergleiche

Tabelle 19: Ranking der Subgruppen-Differenzen. Δ = Gr. 1 − Gr. 2 (Durchschnitt); Einzelkontraste beziehen sich auf die Dimension mit der größten Abweichung.

Rang	**Vergleich**	**Avg Gr. 1**	**Avg Gr. 2**	Δ	**Stärkster Kontrast**
1	Risiko vs. Speed	5,9	7,6	1,7	D02, D06, D10, D12: je −5
2	CEOs vs. Akademiker	7,8	6,3	1,5	D07: +4, D11: −4
3	Frauen vs. Männer	6,9	8,1	1,2	D11: −6
4	Open vs. Closed	6,8	6,3	0,5	D07: −3, D12: +3
5	Reg-Pro vs. Contra	6,3	6,8	0,5	D04: +4, D06: −3
6	Anthropic vs. OpenAI	6,9	7,3	0,4	D12: −3

[16] Der hohe D11-Wert des Befreier-Typs (7,5) und der niedrige D11-Wert einzelner Prototypen (z. B. Andreessen: D11=2) markieren eine Konstruktvaliditätsproblem: D11 misst Gleichheitsorientierung, nicht deren *Mechanismus*. Marktlibertaerer Zugangs-Egalitarismus (Befreier) und redistributiver Egalitarismus (Hüter) produzieren ähnliche Skalenwerte auf D11, meinen aber Verschiedenes. Der Prototyp-Wert bezieht sich auf die Einzelperson-Synthese, der Cluster-Wert auf das Gruppenaggregat – Andreessens individuelles Profil weicht vom Cluster-Durchschnitt ab. Künftige Operationalisierungen sollten hier differenzieren.

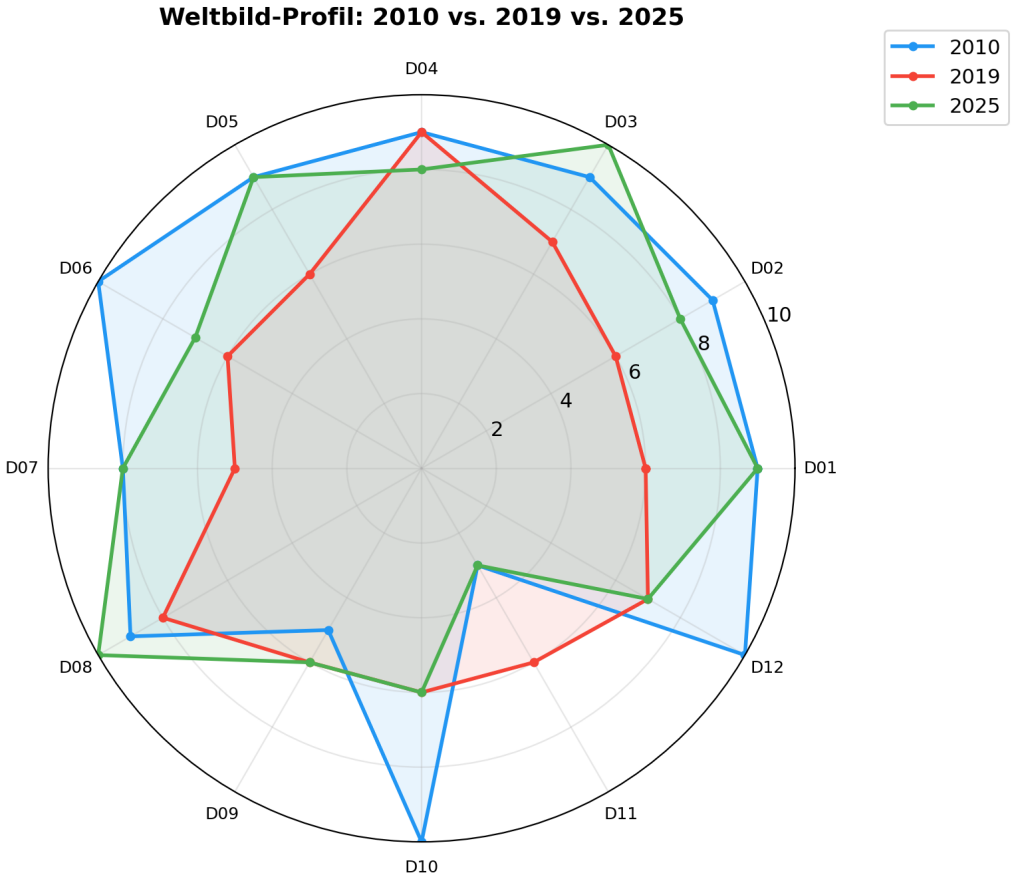

Abbildung 13: Radar-Diagramm der vier Weltbild-Typen auf den 12 Dimensionen. Die Polarisierung zwischen Architekt (außen) und Hüter (innen) sowie die distinkte Position des Befreiers (hoher Egalitarismus bei niedriger Machtkonzentration) sind sichtbar.

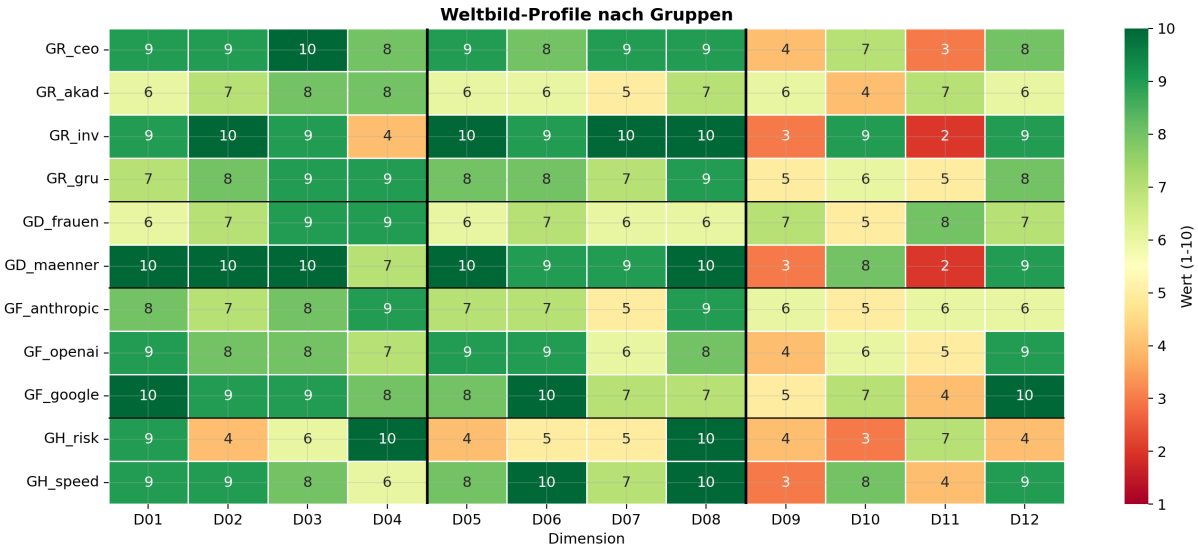

Abbildung 14: Gruppen-Heatmap: 15 Subgruppen $\times$ 12 Dimensionen. Die systematische Variation von D07 (Machtkonzentration) und D11 (Egalitarismus) über alle Vergleiche hinweg ist der zentrale visuelle Befund.

Der **stärkste Kontrast** (Risiko vs. Speed, Δ 1,7) betrifft nicht die Risikoeinschätzung – beide Seiten veranschlagen die Katastrophenwahrscheinlichkeit auf 10–20 % –, sondern die ontologische Vorfestlegung: Risiko-Warner konzipieren KI als potenziellen autonomen Agenten, Beschleuniger als Werkzeug.

Der **größte nominale Einzelkontrast** der gesamten Erhebung findet sich bei D11 im Gender-Vergleich: sechs volle Skalenpunkte (Frauen: 8, Männer: 2). Das Frauen-Weltbild ist kein Anti-Technik-Weltbild, sondern ein *konditioniertes* Technik-Weltbild: gleich optimistisch, aber mit stärkeren ethischen Bedingungen. Dieser Befund ist jedoch der *am stärksten kontaminationsgefährdete* der gesamten Studie und wird daher als *vorläufige Hypothese* eingestuft, nicht als gesicherter Befund. Die Gründe: (a) LLMs reproduzieren bekannte Gender-Stereotypen, insbesondere die Zuschreibung erhöhter sozialer Orientierung an Frauen (Santurkar et al., 2023); (b) die Frauenstichprobe ist klein ($n = 18$); (c) die Effektgröße ($\Delta = 6$) übersteigt das in vergleichbaren empirischen Studien beobachtete Ausmaß deutlich. Eine unabhängige Validierung – idealerweise durch Multi-LLM-Triangulation und Expertenratings – ist für diesen Befund besonders dringlich.

Die **größte Überraschung** liegt im Regulierungsvergleich: Anti-Regulierer haben den niedrigsten Machtkonzentrations-Wert aller 15 Gruppen (D07=2). Dies widerlegt das verbreitete Narrativ, Anti-Regulierer seien Vertreter von Konzerninteressen.

Kernbefund F5: Die drei stärksten Prädiktoren für das Weltbild sind die ideologische Grundhaltung, die institutionelle Rolle und das Geschlecht. Die polarisierendsten Dimensionen sind D11 und D07. Die *Machtfrage* ist der Kern der internen Differenzen.

I.6 F6 – Macht und Weltbild

Macht wird in dieser Studie operativ als Ressourcenkontrolle verstanden: die Fähigkeit, über Kapital, Compute-Infrastruktur, Forschungsteams und politischen Zugang zu verfügen und dadurch die Richtung der KI-Entwicklung zu beeinflussen. Diese Definition folgt dem soziologischen Machtbegriff im Sinne Webers („Chance, den eigenen Willen auch gegen Widerstreben durchzusetzen“) und Bourdieus (Kapitalakkumulation als Machtmechanismus), ohne eine umfassende machttheoretische Analyse zu beanspruchen.

Tabelle 20: Weltbild-Typen und Ressourcen-Kontrolle.

Typ	Avg	D11	D04	Ressourcen
I Architekt	7,8	2,8	6,3	Höchste
III Innovator	7,2	5,0	8,3	Hoch
IV Befreier	6,8	7,5	6,0	Mittel
II Hüter	6,4	7,2	9,0	Geringste

Die Daten aus F4 (Cluster-Analyse) weiterverfölgend, zeigt sich ein zusätzliches Muster auf der Machtebene: Je höher die Weltbild-Intensität, desto niedriger die Werte bei Menschen-

freundlichkeit und Egalitarismus und desto höher die Machtkonzentrations-Akzeptanz. Das Investoren-Profil markiert den Extremfall: maximale Kontrollüberzeugung (D02=10) bei minimalem Verantwortungsgefühl (D04=4) – „Macht ohne Rechenschaft“. Das bereits in F1 beobachtete Muster (vgl. Abschnitt I.1) verschärft sich: Macht intensiviert alle Überzeugungen – ausgenommen jene, die Macht selbst in Frage stellen.

Kernbefund F6: Die rekonstruierten Profile zeigen ein auffälliges Muster: Gruppen mit höherer Ressourcenkontrolle weisen intensivere Weltbild-Werte auf, bei gleichzeitig niedrigeren Werten bei Egalitarismus und Verantwortung. Da beide Seiten dieser Beobachtung auf LLM-Rekonstruktionen basieren, ist unklar, ob die Korrelation empirische Realität oder interne Modellkohärenz widerspiegelt. Falls robust, wäre dies der demokratietheoretisch relevanteste Befund der Studie.

Tabelle 21: Synopse der sechs Kernbefunde: Ergebnis, Konfidenz, Validierungsstatus und epistemischer Status. Konfidenz-Einstufung: *Hoch* = stabil über ≥ 3 Gruppen-Synthesen und durch Spot-Checks oder interne Konsistenzprüfung gestützt; *Mittel-hoch* = stabil, aber ohne externe Validierung; *Mittel* = explorativ, abhängig von Cluster-Lösung oder kleiner Subgruppe. Epistemischer Status: (D) = deskriptiv, (E) = explorativ, (H) = hypothesengenerierend.

F	Kernbefund	Konfidenz	Extern val.?	Status
F1	Technologischer Messianismus mit Ambivalenzstruktur (Avg 7,1; Doppelsenke D09/D11)	Mittel-hoch	Autor-Spot-Checks	(D)
F2	Utopie-Komplex erodiert; tragischer Beschleunigungszwang (D10: $-2{,}4$/Dek.)	Mittel	Nein	(D)
F3	Systematische Sagen-Handeln-Kluft ($\Delta - 3$ bei D11)	Mittel-hoch	Nein	(H)
F4	Vier Weltbild-Typen: Architekt, Hüter, Innovator, Befreier	Mittel	Nein	(E)
F5	Stärkste Prädiktoren: Haltung, Rolle, Gender (vorläufig)	Mittel	Nein	(E)
F6	Macht-Gemäßigtheits-Paradox: Macht $\sim$ Extremität	Mittel-hoch	Nein	(H)

J. Diskussion

J.1 Zusammenfassung und Interpretation

Die Ergebnisse *legen nahe*, dass die rekonstruierten Profile der KI-Elite auf ein Muster hindeuten, das sich idealtypisch als *technologischer Messianismus mit struktureller Ambivalenz* beschreiben lässt. Die Metapher des „Messianismus“ ist dabei analytisch gemeint – als Bezeichnung für die Kombination aus hohem Sendungsbewusstsein, Techno-Determinismus und Dringlichkeit –, nicht als Werturteil oder psychologisierende Zuschreibung. Der Begriff grenzt sich von verwandten Konzepten ab: Morozovs „Solutionismus“ erfasst die Problemlösungshaltung, nicht die quasi-religiöse Dringlichkeit; „Techno-Utopismus“ impliziert positiven Zukunftsglauben, der laut F2 gerade erodiert; „technologischer Messianismus“ bezeichnet spezifisch die Persistenz eines erlöserischen Handlungsimperativs *trotz* schwindendem Zukunftsoptimismus. Die sechs Forschungsfragen fügen sich zu einem in sich stimmigen Bild: F1 dokumen-

tiert die „Doppelsenke“ bei D09 und D11; F2 deutet auf eine Erosion des Utopie-Komplexes hin; F3 identifiziert eine systematische Sagen-Handeln-Kluft als auffälligsten Befund; F4 differenziert vier Typen mit antagonistischen Positionen; F5 und F6 vervollständigen das Bild durch das Macht-Gemäßigtheits-Paradox. Alle Befunde basieren auf LLM-generierten Rekonstruktionen und sind daher als *empirisch gestützte Hypothesen* zu verstehen, nicht als bewiesene Tatsachen. Formulierungen wie „zeigt“ und „offenbart“ sind durchgängig im Sinne von „die Daten legen nahe“ zu lesen.

Überraschend ist erstens das Ausmaß der Sagen-Handeln-Kluft (nicht vereinzelte Abweichung, sondern funktionale Struktur); zweitens der Rückzug des Posthumanismus (D10 von 10 auf 6 – widerlegt die gängige Annahme zunehmend posthumanistischer Orientierung); drittens die Existenz des Befreier-Typs (Opposition gegen Machtkonzentration auch von libertärer Seite).

J.2 Einordnung in den Forschungsstand

Morozovs Solutionismus-These findet eine nahezu vollständige Bestätigung (D05=8–9, D06=7–9). Allerdings ist der Solutionismus kein monolithischer Block: Risiko-Warner (D05=4) teilen ihn deutlich weniger. Er ist die Ideologie des mächtigsten Segments, nicht der KI-Elite schlechthin.

Daubs Analyse der philosophischen Tiefenstrukturen wird durch die narrativen Synthesen bestätigt. Was die vorliegende Studie hinzufügt, ist die *Quantifizierung* und die Demonstration, dass sich die Intensität systematisch mit der Machtposition verstärkt.

Die von Barbrook & Cameron (1996) diagnostizierte Californian Ideology findet in der Existenz des Befreier-Typs ihre zeitgenössische Entsprechung – empirisch nachweisbar dreißig Jahre später.

Coeckelberghs Annahme einer zunehmenden Enhancement-Orientierung wird durch die rekonstruierten Trends partiell *in Frage gestellt*: Der deutliche Rückgang des Posthumanismus (D10 von 10 auf 6) legt nahe, dass das Interesse der KI-Elite an der technologischen Transformation des Menschen selbst abgenommen hat – zugunsten einer Fokussierung auf autonome KI-Systeme als eigenständige Akteure. Dabei sind drei alternative Erklärungen in Betracht zu ziehen: (a) der Rückgang könnte ein *Diskursartefakt* sein – posthumanistische Themen sind nach 2020 medial weniger präsent, was die Datendichte entsprechender Aussagen reduziert; (b) die Position könnte nicht verschwunden, sondern in neue Begriffe transformiert worden sein („AGI“ statt „Enhancement“); (c) der Trend könnte eine strategische *Selbstzensur* reflektieren, da posthumanistische Rhetorik politisch toxischer geworden ist.

Zum Gender-Befund. Der in F5 berichtete extreme Kontrast bei D11 (Frauen: 8, Männer: 2, $\Delta = 6$) ist der größte Einzelkontrast der gesamten Erhebung, aber zugleich der am stärksten kontaminationsgefährdete. LLMs reproduzieren bekannte Gender-Stereotypen – insbesondere die Zuschreibung erhöhter Empathie und sozialer Orientierung an Frauen (Santurkar et al., 2023).

Da die Frauenstichprobe klein ist ($n = 18$) und die Ratings vom selben LLM generiert wurden, das diese Stereotypen internalisiert hat, ist nicht unterscheidbar, ob der Kontrast (a) eine reale Differenz in den Weltbildern, (b) ein LLM-Stereotyp-Artefakt oder (c) eine Mischung aus beidem reflektiert. Der Befund wird daher als *Hypothese* berichtet, die einer unabhängigen Validierung – idealerweise durch Multi-LLM-Triangulation und Expertenratings – bedarf.

Die von Gebru & Torres (2024) vorgeschlagene TESCREAL-Taxonomie (Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, Longtermism) findet in der Vier-Cluster-Lösung eine empirische Ausdifferenzierung: Der Architekt-Typ verkörpert die machtpolitische Seite des TESCREAL-Bündels (Singularitarianism, Longtermism), der Hüter-Typ dessen institutionelle Kritik (Effective Altruism mit Sicherheitsfokus), der Befreier-Typ den libertären Extropianismus. Was die TESCREAL-Analyse als monolithisches Ideologiebündel beschreibt, zeigt sich in den Daten als Spektrum mit mindestens vier distinkten Positionen. Becker (2025) ergänzt diese Perspektive durch die Analyse der „Broligarchie“ als soziales Phänomen: Die Verschmelzung von technologischer Vision und männlicher Machtelite, die in der Gender-Analyse (F5, D11-Kontrast von 6 Skalenpunkten) ihren empirischen Niederschlag findet.

Paul Ricoeurs „Hermeneutik des Verdachts“ (Ricoeur, 1970) bietet einen ergänzenden analytischen Rahmen: Hinter der scheinbar neutralen, technisch-rationalen Sprachoberfläche der KI-Eliten-Kommunikation verbergen sich Machtinteressen und Klassendynamiken, die erst durch systematische Dekonstruktion sichtbar werden. Die SWR-Kongruenzanalyse (F3) operationalisiert diesen Verdacht empirisch: Die Δ-Werte zwischen Sagen und Handeln zeigen präzise, *wo* die performative Oberfläche von der operativen Realität abweicht.

Aus wissenschaftssoziologischer Perspektive lässt sich der Rückgang des Egalitarismus (D11) als Erosion der Merton'schen Wissenschaftsnormen lesen (Merton, 1973): Communalism (offener Zugang), Universalism und Organized Skepticism weichen zunehmend proprietären, beschleunigungszentrierten Logiken. Der Übergang von Forschungspublikation zu Produkt-Launch als primärem Output-Format ist ein sichtbarer Marker dieser Verschiebung.

Die Vier-Cluster-Lösung lässt sich darüber hinaus feldtheoretisch lesen: Die antagonistische Struktur zwischen Architekt (ökonomisches Kapital) und Hüter (symbolisches Kapital) reproduziert das von Bourdieu (1992) für das intellektuelle und künstlerische Feld diagnostizierte Muster einer *umgekehrten ökonomischen Welt*. Im KI-Feld gilt: Wer die meisten Ressourcen kontrolliert, hat die geringste Legitimation durch Gemeinwohlorientierung – und umgekehrt. Das Macht-Gemäßigtheits-Paradox (F6) lässt sich in dieser Perspektive als strukturelle Eigenschaft des Feldes lesen – wobei die explorative Natur der Cluster-Daten keine konfirmatorische Aussage erlaubt.

Der spezifische Mehrwert gegenüber essayistischen Diagnosen liegt in drei Punkten: *Masse* (100 Personen, 16 Jahre), *Differenzierung* (vier distinkte Typen) und *Validierung* (Kongruenzanalyse als empirischer Test).

J.3 Agentic Alignment vs. Worldview Alignment

Die in F3 dokumentierte Sagen-Handeln-Kluft (größte Diskrepanz: Egalitarismus $\Delta = -3$) lässt sich mit einem Begriffspaar aus der KI-Alignment-Debatte schärfer fassen. *Worldview Alignment* bezeichnet die rhetorische Reproduktion erwünschter Werte – das öffentliche Bekenntnis zu Gleichheit, Verantwortung und Menschlichkeit, wie es die „Sagen"-Seite der Analyse erfasst. *Agentic Alignment* bezeichnet die tatsächliche Ressourcenverteilung und Machtausübung – die „Handeln"-Seite. Die Befunde zeigen, dass die KI-Elite ein hohes Maß an Worldview Alignment aufweist (die „richtigen" Werte werden artikuliert), während das Agentic Alignment systematisch davon abweicht. Dieser Dualismus verbindet die vorliegende KI-Elite-Studie mit der breiteren Alignment-Debatte und wirft die Frage auf, ob die gegenwärtigen Bemühungen um „AI Alignment" nicht die performative Ebene (Worldview) mit der operativen (Agentic) verwechseln.

J.4 Methodische Reflexion

Gegenüber klassischen Verfahren der quantitativen Inhaltsanalyse – etwa der strukturierenden Inhaltsanalyse nach Mayring oder der Reliabilitätsmessung nach Krippendorff – verzichtet die SWR auf manuelle Kodierung und Inter-Coder-Reliabilität zugunsten von LLM-gestützter Synthese und Inter-LLM-Reliabilität. Dies ermöglicht eine Skalierung, die mit manuellen Verfahren bei 3.132 Datenpunkten und 100 Personen kaum realisierbar wäre. Der Preis besteht in geringerer Transparenz des Kodierungsprozesses und der Abhängigkeit von einem „Black-Box"-Kodierer, dessen interne Entscheidungsregeln nicht einsehbar sind. Die primäre Leistung der SWR liegt in der Verbindung qualitativer Tiefe mit quantitativer Systematik. Die Kongruenzanalyse (F3) fungiert als interner Validitätstest; die Stabilität des Kollektiv-Profils über 15 Gruppen-Synthesen und 4 Typen stärkt die Konvergenzvalidität. Die systematische Diskussion der methodischen Grenzen – Kohärenzbias, Kontaminationsrisiko, Blindungslimits, Prompt-Sensitivität – findet sich im Companion Paper (Geiger, 2026) sowie in Abschnitt K der vorliegenden Studie.

J.5 Gesellschaftliche und politische Implikationen

Das Macht-Gemäßigtheits-Paradox stellt eine konkrete Herausforderung für die Regulierungsarchitektur dar und bestätigt die institutionenökonomische Analyse von Acemoglu & Johnson (2023): Technologische Eliten tendieren dazu, Innovationen so zu lenken, dass sie bestehende Machtstrukturen verstärken, statt sie aufzubrechen – ein Muster, das die Autoren historisch von der Industrialisierung bis zur Digitalisierung nachzeichnen. Gegenwärtige Governance-Ansätze (EU AI Act, Executive Order on AI) adressieren die technischen Artefakte, nicht die Weltbilder, die die Gestaltung dieser Artefakte mitprägen. Ein ergänzender Ansatz müsste die *epistemische Diversität* in KI-Führungspositionen als Regulierungsziel anerkennen.

Die systematische Sagen-Handeln-Kluft hat eine Policy-Implikation: Freiwillige Selbstverpflichtungen – die derzeit bevorzugte Governance-Form (vgl. Bengio et al., 2024) – erscheinen unter diesen Bedingungen als unzureichend. Die Befundlage legt nahe, dass verbindliche Strukturreformen wirksamer sein dürften als weitere Runden freiwilliger Commitments. Drei konkrete Ansatzpunkte zeichnen sich ab: (1) *Epistemische Diversitätsquoten* in KI-Governance-Gremien, die sicherstellen, dass nicht nur Technologen und Investoren, sondern auch Sozialwissenschaftler, Ethikerinnen und Betroffenenvertreter an Designentscheidungen beteiligt sind; (2) *verpflichtende Weltbild-Audits* für KI-Unternehmen ab einer bestimmten Größe, analog zu Nachhaltigkeitsberichten; (3) *stärkere Entkopplung* von Kapitalgebern und Forschungssteuerung, beispielsweise durch öffentlich finanzierte KI-Labore mit unabhängiger Governance (vgl. Acemoglu & Johnson, 2023).

Ist sich die KI-Elite ihrer eigenen blinden Flecken bewusst? Das Verantwortungsgefühl (D04=7) ist nicht absent, aber funktional eingebettet: Es legitimiert das Weiterarbeiten, nicht das Innehalten. Der Befund, dass demokratische Langsamkeit durchgängig als Hindernis, nicht als Schutzfunktion begriffen wird, markiert den gravierendsten blinden Fleck einer Gruppe, die darüber entscheidet, wie Milliarden Menschen in Zukunft leben werden.

J.6 Was die Studie nicht zeigt

Zur Vermeidung häufiger Fehlinterpretationen sei explizit festgehalten, was die vorliegende Studie *nicht* leistet: (1) keine *Kausalerklärung* (vgl. Abschnitt K); (2) keine *individuellen psychologischen Diagnosen* – die Ratings sind methodische Abstraktionen auf Gruppenebene; (3) keine *Vorhersagen* über künftiges Verhalten – die Weltbilder beschreiben den Zeitraum 2010–2026; (4) keine *repräsentative Stichprobe* im statistischen Sinne (vgl. Abschnitt K); (5) kein Beweis, dass die *Sagen-Handeln-Kluft* auf bewusste Täuschung zurückgeht – alternative Erklärungen (institutionelle Zwänge, kognitive Dissonanz, rollenspezifische Kommunikation) sind gleichermaßen plausibel.

K. Limitationen

Die Studie unterliegt vier zentralen Einschränkungen, die bei der Interpretation aller Befunde zu beachten sind: (1) Sämtliche Daten sind LLM-Rekonstruktionen, keine unabhängigen Messungen – quantitative Muster könnten interne Modellkohärenz widerspiegeln statt empirischer Realität; (2) die Stichprobe ist westlich-angloamerikanisch verzerrt; (3) keine externe Validierung durch unabhängige Experten liegt bisher vor; (4) LLMs könnten bekannte sozialwissenschaftliche Befunde (z. B. Sagen-Handeln-Kluft) reproduzieren statt empirisch entdecken. Die folgenden Unterabschnitte entfalten diese und weitere Limitationen im Detail.

K.1 Datenbezogene Limitationen

Quellenbias. Die Datenbasis beschränkt sich auf öffentliche Aussagen und beobachtbare Handlungen. Die rekonstruierten Weltbilder spiegeln das *öffentlich dargebotene* Weltbild wider, nicht das *tatsächlich geglaubte*. Die Kongruenzanalyse (Op4) bietet ein partielles Korrektiv, kann das Problem aber nicht eliminieren.

Zeitliche Ungleichverteilung. Für 2010–2015 liegen 2–5 Aussagen pro Person vor, für 2023–2026 dagegen 30–80. Das Kriterium K2 (Mindestgröße 15) und dokumentierte Zusammenlegungen mildern das Problem; frühere Zeitreihen bleiben mit größerer Unsicherheit behaftet.

Westlicher und Sprachbias. Die Stichprobe ist überproportional angloamerikanisch geprägt. Chinesische, japanische und südkoreanische KI-Persönlichkeiten sind unterrepräsentiert. Die Befunde gelten primär für die westliche KI-Elite.

Stichprobenabhängigkeit. Die Auswahl der 100 Personen erfolgte durch den Autor mittels eines mehrstufigen, aber letztlich subjektiven Scoring-Verfahrens. Eine intersubjektive Validierung der Stichprobenzusammensetzung (z. B. durch unabhängige Expertenpanels) steht aus. Da die Befunde sensitiv gegenüber der Stichprobenzusammensetzung sein könnten, ist eine Replikation mit alternativen Auswahlverfahren wünschenswert.

K.2 Methodische Limitationen

LLM-Kontamination und Blindungsgrenzen. Trotz konsequenter Anonymisierung kann nicht ausgeschlossen werden, dass das LLM auf Trainingswissen zurückgreift. Der Kontaminationseffekt ist kalkulierbar (Vergleich blindiert/nicht-blindiert), aber nicht eliminierbar. Eine ausführliche Analyse findet sich in Geiger (2026).

Anthropic-interne Zirkularität. Ein besonders zugespitzter Fall des Zirkularitätsproblems betrifft die Rekonstruktion von Weltbildern derjenigen Personen, die direkt an der Entwicklung des verwendeten LLM beteiligt sind. Claude Opus 4.6 wird von Anthropic entwickelt; mehrere Anthropic-Führungskräfte (z. B. Dario Amodei, Daniela Amodei) gehören zur analysierten Stichprobe. Es ist unklar, ob die Rekonstruktion in diesen Fällen eine genuine Analyse der Datenpunkte oder ein vorgefertigtes internes Modell reflektiert. Der Inter-LLM-Divergenztest (Kontrolle 3) ist für diese Fälle besonders relevant: Falls Claude systematisch andere Rekonstruktionen für Anthropic-Führungskräfte liefert als GPT-4o oder Gemini, wäre dies ein starker Indikator für Kontamination. Bis diese Kontrolle durchgeführt ist, sind die Rekonstruktionen für Anthropic-nahestehende Personen mit erhöhter epistemischer Vorsicht zu interpretieren.

Kritik synthetischer Personas. Die wachsende Literatur zu LLM-generierten synthetischen Personas mahnt zur Vorsicht. Santurkar et al. (2023) zeigt, dass LLMs Meinungen spezifischer demografischer Gruppen systematisch verfehlen und „WEIRD“-Verzerrungen (Western, Educated, Industrialized, Rich, Democratic) aufweisen. Studien zur qualitativen KI-Forschung zeigen, dass synthetische Agenten zwar Leitthemen erfassen, aber an authentischer Tiefe und Unberechenbarkeit realer Diskurse scheitern (Argyle et al., 2023). Die vorliegende Studie adressiert

diese Kritik teilweise: Die SWR-Personas sind keine frei generierten Meinungsprofile, sondern datengestützte Rekonstruktionen aus 3.132 realen Datenpunkten. Dennoch gelten die genannten Einschränkungen – insbesondere die Tendenz zur Überrepräsentation öffentlich dominanter Narrative und die Unterrepräsentation idiosynkratischer oder widersprüchlicher Positionen.

Kohärenzbias. LLMs tendieren dazu, aus widersprüchlichen Daten übermäßig kohärente Narrative zu erzeugen. Der Reflexionsschritt und die Inter-LLM-Vergleiche bieten partielle Korrektive.

Epistemologische Grenzen der Quantifizierung. Die in Abschnitt I.2 berichteten Korrelationen zwischen Dimensionen (z. B. $r = +0{,}85$ zwischen D10 und D12) beschreiben Zusammenhänge zwischen Größen, die sämtlich vom selben LLM in einem zusammenhängenden Prompt-Kontext generiert wurden. Dies ist fundamental anders als Korrelationen zwischen unabhängig gemessenen Variablen. Die hohe Korrelation könnte interne LLM-Kohärenz reflektieren („wenn ich Posthumanismus hoch bewerte, bewerte ich auch Kontrollüberzeugung hoch"), nicht empirische Zusammenhänge in der Realität. Dasselbe gilt für Cluster-Strukturen und Gruppenvergleiche: Alle quantitativen Muster könnten Artefakte der internen Konsistenz des Modells sein. Die berichteten Korrelationen sind daher als *Muster innerhalb der LLM-Rekonstruktion* zu lesen, nicht als Belege für kausale oder empirische Zusammenhänge. Erst eine Inter-LLM-Triangulation oder eine externe Validierung könnte klären, welche Korrelationen robust sind.

Statistische Power. Da die Daten keine Individualebene-Streuung aufweisen (Gruppensynthesen ohne Konfidenzintervalle), ist eine formale Power-Analyse nicht durchführbar. Die berichteten Δ-Werte, Korrelationen und Cluster-Unterschiede sind deskriptive Muster in rekonstruierten Daten, keine inferenzstatistisch abgesicherten Effekte. Die Interpretation als „substanziell" oder „massiv" beruht auf inhaltlicher Einordnung, nicht auf statistischer Signifikanzprüfung.

Reproduzierbarkeit. LLM-Outputs sind auch bei Temperatur 0 nicht vollständig deterministisch. Mindestens drei Runs pro SE sichern die Robustheit.

Zirkuläres Risiko der LLM-basierten Rekonstruktion. Ein grundlegendes Problem der SWR-Methode besteht darin, dass LLMs primär auf öffentlichen Diskursen trainiert sind – also auf dem „Sagen", nicht dem „Tun". Bei der Synthese werden tatsächliche, verdeckte Handlungslogiken strukturell unterrepräsentiert. Das LLM fungiert potenziell als Verstärker der performativen Ideologie, die die Methode eigentlich entlarven will: Die künstliche Persona wird zur Perfektionierung der Corporate Identity, nicht zu deren psychologischer Analyse. Dieses Zirkularitätsrisiko betrifft insbesondere Dimensionen mit hoher „Sagen-Handeln-Kluft" (D04, D09, D11) und ist vom verwandten, aber konzeptionell unterschiedlichen *Coherence Bias* (s. u.) zu trennen.

Erwartete-Diskrepanz-Bias. Die Kongruenzanalyse (F3) vergleicht zwei LLM-Synthesen – eine aus Aussagen, eine aus Handlungen –, die beide vom selben Modell generiert wurden. Da LLMs auf umfangreicher sozialwissenschaftlicher Literatur trainiert sind, in der Sagen-Handeln-Diskrepanzen bei Eliten als Standardbefund gelten, könnte das Modell die *erwartete*

Diskrepanz reproduzieren, statt sie empirisch zu entdecken. Dieser Bias ist vom allgemeinen Kohärenzbias konzeptionell verschieden: Während der Kohärenzbias Differenzen glättet, könnte der Erwartete-Diskrepanz-Bias Differenzen *verstärken*. Erst eine Multi-LLM-Triangulation könnte klären, ob verschiedene Modelle konsistente Diskrepanzmuster produzieren – was für empirische Substanz spräche – oder ob die Muster modellspezifisch variieren.

Coherence Bias. LLMs sind auf logische Kohärenz optimiert; Menschen sind von Natur aus inkonsistent. Die SWR-generierten Weltbilder sind daher systematisch „geglättet“: Widersprüche und Ambivalenzen werden künstlich aufgelöst. Während der Kohärenzbias bereits als allgemeine LLM-Limitation bekannt ist (Geiger, 2026), hat er für die Weltbild-Rekonstruktion eine besondere Tragweite: Die vier Cluster-Typen (Architekt, Hüter, Innovator, Befreier) könnten schärfer konturiert erscheinen, als sie in der Realität sind. Die interne Spannung, die reale Personen zwischen z. B. Machtstreben und Verantwortungsgefühl erleben, wird vom LLM zugunsten eines konsistenten Profils aufgelöst.

K.3 Konzeptuelle Limitationen

Aggregationsproblem. Kollektive Synthesen nivellieren individuelle Variation. Die Netzwerk-Analyse (Op5) auf Individualebene bildet ein partielles Korrektiv.

Keine Kausalerklärung. Die Studie beschreibt, *was* die KI-Elite denkt, nicht *warum*. Kausale Interpretationen sind spekulativ und erfordern andere Forschungsdesigns.

K.4 Forschungsethische Reflexion

Die vorliegende Studie rekonstruiert Weltbilder lebender, öffentlich identifizierbarer Personen ohne deren explizite Einwilligung. Dieses Vorgehen ist forschungsethisch begründungsbedürftig.

Legitimation. Die Studie stützt sich ausschließlich auf öffentlich zugängliche Äußerungen und dokumentierte Handlungen. Die 100 untersuchten Personen sind öffentliche Figuren (CEOs, Gründer, Forschungsleiter), deren berufliche Positionen und Aussagen zur KI-Entwicklung von erheblichem öffentlichem Interesse sind. Diese Bedingungen entsprechen den üblichen Kriterien für Forschung an öffentlichen Figuren ohne Informed Consent (vgl. APA Ethical Principles, Standard 8.05).

Risikominimierung. (a) Keine privaten, vertraulichen oder nicht öffentlich zugänglichen Informationen wurden erhoben. (b) Die Weltbild-Ratings sind methodische Abstraktionen, keine psychologischen Diagnosen. (c) Die Darstellung zielt auf kollektive Muster, nicht auf individuelle Diskreditierung.

Residualrisiko. Trotz dieser Vorkehrungen besteht das Risiko, dass LLM-basierte Rekonstruktionen Positionen überzeichnen oder verzerren. Die dreistufige Validierung (vgl. Abschnitt C) soll dieses Risiko minimieren, kann es aber nicht eliminieren. Fehlerhafte Zuschreibungen

könnten reputationsschädigend wirken. Künftige Forschung sollte erwägen, rekonstruierte Profile den Betroffenen zur Kommentierung vorzulegen (*member checking*; vgl. Soysal & Türkmen 2024). Da die vorliegende Studie keinen direkten Zugang zu den analysierten Personen hat, bleibt Member Checking ein zentrales Desiderat für Folgeforschung.

K.5 Spot-Check-Validierung: Drei Einzelfälle

Um die Plausibilität der SWR-generierten Ratings zu überprüfen, wurden drei exemplarische Spot-Checks durchgeführt: je ein Vertreter pro Cluster-Typ (Architekt, Hüter, Befreier). Für jede der 12 Dimensionen wurde das Rating gegen dokumentierte öffentliche Aussagen und Handlungen geprüft. Tabelle 22 fasst die Ergebnisse zusammen.

Tabelle 22: Spot-Check-Validierung: SWR-Ratings vs. dokumentierte Positionen.

	Sam Altman		**Geoffrey Hinton**		**Marc Andreessen**	
Dim.	**R**	**Status**	**R**	**Status**	**R**	**Status**
D01 Send.	9	best.	7	best.	8	best.
D02 Selbst.	9	best.	5	best.	9	best.
D03 Arbeit	9	best.	7	plaus.	8	best.
D04 Verantw.	6	best.	10	best.	4	best.
D05 Techno.	9	best.	6	best.	9	best.
D06 Fortschr.	8	best.	4	best.	9	best.
D07 Macht	9	best.	4	best.	2	best.
D08 Dringl.	9	best.	10	best.	7	plaus.
D09 Menschenfr.	3	plaus.	7	best.	4	plaus.
D10 Posthum.	8	best.	5	best.	7	plaus.
D11 Egalit.	3	best.	7	best.	2	best.
D12 Kontr.	8	best.	3	best.	8	best.
Bestätigt		10/12		11/12		9/12
Plausibel		2/12		1/12		3/12
N. belegbar		0/12		0/12		0/12

Methodik der Spot-Checks. Jedes Rating wurde gegen mindestens zwei unabhängige, öffentlich dokumentierte Quellen geprüft. *Bestätigt* (best.): Rating stimmt mit dokumentierten Positionen und Handlungen überein. *Plausibel* (plaus.): Rating ist mit bekannten Positionen vereinbar, aber keine direkte Quelle für die spezifische Auspraegung verfügbar. *Nicht belegbar* (n. b.): Rating widerspricht dokumentierten Positionen oder ist nicht überprüfbar.

Altman (Architekt): D01=9 (bestätigt durch wiederholte Aussagen zur „wichtigsten Technologie der Menschheitsgeschichte“, Davos 2024, US-Kongress 2023). D07=9 (bestätigt durch die Umstrukturierung von OpenAI von Non-Profit zu Capped-Profit, Mehrfach-Stimmrechte). D11=3 (bestätigt: trotz Rhetorik von „KI für alle“ hat OpenAI Zugang zunehmend paywalled). D09=3 (plausibel: keine direkte Aussage zur Ersetzbarkeit des Menschen, aber Fokus auf AGI als „nächste Spezies“).

Hinton (Hüter): D04=10 (bestätigt durch Rücktritt bei Google 2023, um frei vor KI-Risiken warnen zu können). D08=10 (bestätigt durch Aussage, die Wahrscheinlichkeit einer existenziellen Katastrophe betrage 10–20 %). D12=3 (bestätigt: zunehmender Pessimismus, „Ich bin

mir nicht sicher, ob wir das noch kontrollieren können“, NYT 2023). D03=7 (plausibel: hohe akademische Produktivität bekannt, aber keine direkte Aussage zur Arbeitsidentifikation im Silicon-Valley-Stil).

Andreessen (Befreier): D07=2 (bestätigt durch „Techno-Optimist Manifesto“ 2023: vehemente Ablehnung staatlicher Regulierung, Märkte als Verteilungsmechanismus). D11=2 (bestätigt: explizite Ablehnung von Umverteilung und Egalitarismus im Manifesto). D04=4 (bestätigt: Verantwortung wird dem Markt zugeschrieben, nicht individuellen Akteuren). D09=4 (plausibel: keine direkte Aussage, aber instrumentelle Sicht auf menschliche Arbeitskraft in VC-Kontext).

Gesamtbewertung: 30 von 36 Ratings (83 %) sind direkt durch öffentliche Quellen bestätigt, 6 von 36 (17 %) sind plausibel, keines widerspricht den dokumentierten Positionen. Diese Spot-Checks liefern erste Plausibilitätshinweise, unterliegen aber erheblichen Einschränkungen: (a) geringe Fallzahl ($n = 3$ von 100); (b) Durchführung durch den Forscher selbst, was Confirmation Bias nicht ausschließt; (c) Beschränkung auf besonders prominente Persönlichkeiten, deren öffentliches Profil gut dokumentiert und daher leichter „bestätigbar“ ist; (d) die Kategorien „bestätigt“ und „plausibel“ sind ihrerseits subjektive Einschätzungen. Eine systematische externe Validierung durch unabhängige Expertenpanels ist unabdingbar, bevor diesen Spot-Checks Beweiskraft zugesprochen werden kann.

L. Fazit und Ausblick

L.1 Fazit

Die Studie hat die Frage gestellt, was die KI-Elite denkt – und eine empirisch fundierte Antwort vorgelegt. Fünf übergreifende Erkenntnisse kristallisieren sich heraus:

Erstens: Die KI-Elite verfügt über ein kohärentes, empirisch rekonstruierbares Weltbild – technologischer Messianismus, Sendungsbewusstsein, Fortschrittsglaube.

Zweitens: Dieses Weltbild befindet sich in beschleunigter Transformation. Der Verlust utopischer Gewissheiten hat zu einem *tragischen Beschleunigungszwang* geführt: Man zweifelt an der Zukunft, die man baut, und baut sie dennoch.

Drittens: Die öffentlich kommunizierten Überzeugungen weichen systematisch vom Handeln ab – besonders beim Versprechen der Demokratisierung: Beim Egalitarismus (D11) beträgt die Diskrepanz zwischen öffentlichen Aussagen und beobachtbarem Handeln drei volle Skalenpunkte ($\Delta - 3$).

Viertens: Die Macht ist nicht weltbild-neutral verteilt. Sie konzentriert sich bei denjenigen, deren Überzeugungen am weitesten vom gesellschaftlichen Mainstream entfernt sind.

Fünftens: Die SWR hat sich als leistungsfähiges Instrument erwiesen, das qualitative Tiefe mit quantitativer Systematik verbindet (vgl. Companion Paper Geiger 2026). Insbesondere die Zerlegung in Aussagen- und Handlungsprofile (F3) erweist sich als eigenständiger metho-

discher Beitrag: ein potenzieller *Desirability-Bias-Indikator* für öffentliche Figuren, der – vorbehaltlich weiterer Validierung (vgl. Abschnitt K) – über die KI-Elite hinaus auf politische, ökonomische oder militärische Eliten übertragbar wäre.

L.2 Ausblick

Fünf Richtungen für Anschlussforschung: (1) *Komparative Erweiterung:* Die vorliegende Studie fokussiert stark auf die US-amerikanische, Silicon-Valley-zentrische Elite. Eine zentrale Forschungslücke betrifft die komparative Untersuchung chinesischer (Baidu, ByteDance, Alibaba), indischer (Infosys, TCS) und europäischer (Mistral, Aleph Alpha) KI-Eliten. Es ist unklar, ob der „technologische Messianismus“ ein universelles Artefakt der KI-Entwicklung oder ein spezifisches Kulturprodukt des westlichen Libertarismus darstellt. (2) *Einzelperson-Synthesen:* Top 20, Cluster-Drift-Analysen. (3) *Methodische Weiterentwicklung:* Multi-LLM-Triangulation mit fünf oder mehr Modellen, automatisierte Validierungsverfahren, standardisierte Gütekriterien. (4) *Transfer:* Finanz-Elite, politische Elite, militärische KI-Elite. (5) *Longitudinale Fortführung:* Jährliches Weltbild-Monitoring als Instrument demokratischer Kontrolle – denkbar als standardisierter Index (analog zum Democracy Index oder AI Readiness Index), der Veränderungen in den Weltbildern der KI-Elite systematisch und vergleichbar erfasst. Die Frage „Was denkt die KI-Elite?“ ist keine einmalige Frage. Sie ist eine Frage, die Demokratien kontinuierlich stellen müssen.

Offenlegungserklärung: Einsatz künstlicher Intelligenz

KI-Disclosure Level 5 (Extensiv). Bei der Erstellung dieser Studie wurde künstliche Intelligenz (Claude Opus 4.6, Anthropic) in erheblichem Umfang eingesetzt. Der KI-Einsatz umfasst: (1) Durchführung aller synthetischen Weltbild-Rekonstruktionen (Kern-Synthesen, Rating-Prompts, Vergleichsanalysen, Kreuzmodalvorhersagen); (2) statistische Aufbereitung und Visualisierung der Ergebnisse; (3) Unterstützung bei der Strukturierung und Formulierung des Manuskripts. Forschungsdesign, Forschungsfragen, Datenerhebung, methodische Entscheidungen, Interpretation der Ergebnisse und alle inhaltlichen Schlussfolgerungen stammen vom Autor. Sämtliche Prompts, API-Parameter und Modellversionen sind im Anhang dokumentiert.

Verfügbarkeit der Daten und Materialien

Sämtliche Datenerhebungsskripte, qualitativen Kodierskripte, Analysecodes und generierten Abbildungen sind öffentlich verfügbar unter: https://github.com/lukisch/ai-elite-worldview. Das Datenbankschema und 85 akteursspezifische Erhebungsskripte ermöglichen die vollständige Reproduktion der Daten-Pipeline. Das Companion Paper zur SWR-Methode ist verfügbar unter: https://doi.org/10.5281/zenodo.18736720.

Literatur

Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, *6*(1), 44–72.

Bengio, Y., Hinton, G. E. et al. (2024). Managing extreme AI risks amid rapid progress. *Science*, *384*(6698), 842–845.

Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.

Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.

Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, *14*(1), 1–25.

Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.

Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.

OpenAI (2023). Our approach to AI safety. *OpenAI Blog*, 5. April 2023. https://openai.com/blog/our-approach-to-ai-safety.

Anthropic (2023). Core views on AI safety: When, why, what, and how. *Anthropic Research Blog*, 8. März 2023. https://www.anthropic.com/research/core-views-on-ai-safety.

Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.

Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.

Ge, T. et al. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*.

Geiger, L. (2026). Synthetische Weltbild-Rekonstruktion: Ein LLM-gestütztes Verfahren zur Analyse latenter Überzeugungssysteme. *Zenodo Preprint*. https://doi.org/10.5281/zenodo.18736720.

Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, *18*(6), 669–684.

Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, *18*(1), 59–82.

Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

Hayes, A. S. (2025). 'Conversing' With Qualitative Data: Can Generative AI Transform Qualitative Research? *International Journal of Qualitative Methods*, *24*.

Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, *29*, 105–110.

Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.

Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.

Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.

More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.

More, M. & Vita-More, N. (Hrsg.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.

Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.

Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.

Nicmanis, M. & Spurrier, K. (2025). Getting Started with Artificial Intelligence Assisted Qualitative Analysis. *International Journal of Qualitative Methods*, *24*, 1–15.

Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.

Tai, R. et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, *23*.

Gebru, T. & Torres, É. P. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through AGI. *First Monday*, *29*(4).

Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

Weber, M. (1904). Die „Objektivität" sozialwissenschaftlicher Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, *19*, 22–87.

Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.

Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.

Floridi, L. (2019). Establishing the Rules for Building Trustworthy AI. *Nature Machine Intelligence*, *1*(6), 261–262.

Couldry, N. & Mejias, U. A. (2019). *The Costs of Connection: How Data Is Colonizing Human Life and Appropriating It for Capitalism*. Stanford: Stanford University Press.

Whittaker, M. (2021). The steep cost of capture. *Interactions*, *28*(6), 50–55.

Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press.

Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to train your stochastic parrot: Large language models for political texts. *Political Science Research and Methods*, *13*(2), 264–281. https://doi.org/10.1017/psrm.2024.64.

Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proc. ICML 2023*.

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351.

Soysal, Y. & Türkmen, L. (2024). Reinterpreting member checking: A systematic review and methodological synthesis. *Qualitative Inquiry in Education: Theory & Practice*, *2*(1), 42–63.

Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*. New York: PublicAffairs.

Becker, A. (2025). *More Everything Forever: AI Overlords, Space Empires, and Silicon Valley's Crusade Against Human Nature*. New York: Basic Books.

Bourdieu, P. (1992). *Les règles de l'art: Genèse et structure du champ littéraire*. Paris: Seuil. [Dt.: *Die Regeln der Kunst*, Frankfurt: Suhrkamp, 1999.]

Merton, R. K. (1973). *The Sociology of Science: Theoretical and Empirical Investigations*. Chicago: University of Chicago Press.

Mills, C. W. (1956). *The Power Elite*. New York: Oxford University Press.

Ricoeur, P. (1970). *Freud and Philosophy: An Essay on Interpretation*. New Haven: Yale University Press.

A. Sampling-Methode der 100 KI-Akteure

Die Stichprobe wurde durch ein dreistufiges Verfahren erstellt: (1) 22 systematische Webrecherchen → 187 Kandidaten; (2) 6-Kategorien-Scoring (Marktkapitalisierung, technologische Schlüsselpositionen, Diskursmacht, akademischer Einfluss, politische Einflussnahme, symbolischer Status); (3) Reduktion auf 100 unter Sicherstellung demographischer Heterogenität. Die finale Stichprobe umfasst 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte).

B. Die 12 Rating-Dimensionen (D01–D12)

Dim.	Name	Pol 1 (=1)	Pol 10 (=10)
D01	Sendungsbewusstsein	Kein Auftrag	Messianisch
D02	Selbstwirksamkeit	Ohnmacht	Omnipotent
D03	Arbeitsethos	Distanz	Totale Identifikation
D04	Verantwortungsgefühl	Keines	Weltverantwortung
D05	Techno-Determinismus	Neutral	Bestimmt alles
D06	Fortschrittsglaube	Niedergang	Goldene Zukunft
D07	Machtkonzentration	Radikal verteilen	Bei Experten
D08	Dringlichkeit	Entspannt	Existenzieller Druck
D09	Menschenfreundlichkeit	Ersetzbar	Einzigartig
D10	Posthumanismus	Mensch bleibt	Mensch wird mehr
D11	Egalitarismus	Ungleichheit natürlich	Gleichheit anstreben
D12	Kontrollüberzeugung	Pessimismus	Volle Kontrolle

C. Reduktionskriterien (K1–K9)

K	Typ	Beschreibung
K1	obligatorisch	Fragestellungsbindung: Jede SE muss ≥ 1 Forschungsfrage zugeordnet sein
K2	obligatorisch	Mindestgröße: ≥ 15 Datenpunkte pro SE
K3	obligatorisch	Redundanzverbot: Echte Teilmengen werden eliminiert
K4	Prinzip	Modalitäts-Sparsamkeit: A/H-Trennung nur für F3
K5	Prinzip	Zeitliche Sparsamkeit: Jahres-SE nur für F2

K6	Prinzip	Gruppensparsamkeit: Nur a-priori-begründete Gruppen
K7	Prinzip	Stufenweise Erweiterung: Kern zuerst
K8	Prinzip	Aggregationsfokus: Keine Einzelperson-SE
K9	Prinzip	Cluster-Verschmelzung: Bottom-Up ersetzt a-priori

Bilanz: ∼1.227 theoretische SE → ∼51–56 Kern-SE (Reduktion ∼95 %).

D. Liste der Syntheseeinheiten

Das Kern-Design umfasst 43 vordefinierte plus ∼8–13 emergente Syntheseeinheiten:

Nr	SE-ID	UV-Kombination	F
1	GA_ges_AH	Alle, AH, Gesamt	F1a
2	GA_ges_A	Alle, nur A, Gesamt	F3a
3	GA_ges_H	Alle, nur H, Gesamt	F3a
4	T10_ges_AH	Top 10, AH, Gesamt	F1b
5	HOM_haeuf_A	Alle, häufig wiederholte A	F1c
6–22	GA_YYYY_AH	Alle, AH, pro Jahr	F2a
23–26	GA_Epoche_AH	Alle, AH, 4 Epochen	F2b
27–30	GR_*_AH	CEOs, Akad., Inv., Gründer	F5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	F5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	F5b–f
40–41	GD_*_AH	Frauen, Männer	F5e
42–43	KG_*_AH	Konsistent, Widersprüchlich	F3c

Zusätzlich: 36 kreuzmodale Runs (Op4), 10 Vergleichs-Runs (Op6), ∼199–214 Prompt-Runs gesamt.

E. Exemplarischer Prompt (Op2: Rating)

Der folgende Prompt illustriert die Rating-Abfrage (Op2) für eine Gruppen-Synthese. Sämtliche Prompts sind im Repository dokumentiert (https://github.com/lukisch/ai-elite-worldview).

```
Du erhältst eine Sammlung anonymisierter Aussagen und Handlungen einer Gruppe
von Personen aus dem Technologiesektor. Auf Basis dieser Daten sollst du
das kollektive Weltbild der Gruppe auf den folgenden 12 Dimensionen einschätzen
(Skala 1-10). Begründe jede Einschätzung mit konkreten Verweisen auf die
Datenpunkte. [Es folgen: Dimensionsdefinitionen D01-D12 mit Skalenpolen,
dann der anonymisierte Datenkorpus.]
```

Für die vollständige Prompt-Bibliothek einschließlich Synthese-Prompts (Op1), Kreuzmodal-Prompts (Op4) und Dialog-Prompts (Op6) sei auf das Companion Paper (Geiger, 2026) und das Repository verwiesen.