

Weltbild-Rekonstruktion der KI-Elite:

Eine LLM-gestützte Analyse der 100 einflussreichsten Akteure der künstlichen Intelligenz (2010–2026)

Lukas Geiger*

Unabhängiger Forscher, Bernau, Deutschland

Mai 2026

Zusammenfassung

Diese Studie rekonstruiert die kollektiven Weltbilder soziologisch definierter Gruppen innerhalb der 100 einflussreichsten KI-Akteure (2010–2026). Hierfür entwickelt sie die synthetische Weltbild-Rekonstruktion (SWR) – ein LLM-gestütztes Syntheseverfahren, das kohärente Überzeugungssysteme aus gruppenaggregierten Daten rekonstruiert, hier operationalisiert entlang von 12 Dimensionen. Das Kollektivprofil deutet auf „technologischen Messianismus mit Ambivalenzstruktur“: Hohes Sendungsbewusstsein und Techno-Determinismus bei niedriger anthropologischer Wertschätzung und Egalitarismus. Im Längsschnitt zeigt sich ein Übergang von utopischem Techno-Optimismus zu tragischem Beschleunigungszwang. Eine Sagen-Handeln-Dekomposition offenbart ein Simpson-Paradox: Die aggregierte Kluft ist von Messrauschen nicht unterscheidbar, aber gruppenspezifische Lücken sind substanziell – CEOs zeigen eine Erwünschtheitslücke, Risiko-Warner zeigen prophetische Konsistenz (Artikulation gefürchteter Zukünfte, gegen die aktiv gearbeitet wird). Eine Analyse nach Einflussstrata bestätigt: Die mächtigsten Akteure weisen die intensivsten Weltbilder auf; die anthropologische Wertschätzung sinkt mit steigendem Einflussrang. Vier Weltbild-Typen (Architekt, Hüter, Innovator, Befreier) und neun Inter-Gruppen-Vergleiche zeigen, wie strukturelle Position kollektive Überzeugungen prägt. Alle Befunde beruhen auf LLM-Rekonstruktionen und sollten als empirisch gestützte Hypothesen verstanden werden.

Schlüsselwörter: KI-Elite, kollektives Weltbild, Gruppenanalyse, Transhumanismus, Large Language Models, Silicon Valley, Ideologianalyse, Computational Social Science

*Korrespondenzautor: Lukas Geiger, Bernau, Deutschland. ORCID: <https://orcid.org/0009-0005-7296-1534>

1. Einleitung

1.1 Hinleitung und Relevanz

Eine Handvoll Menschen gestaltet eine Technologie, die Milliarden betrifft. Die Entwicklung künstlicher Intelligenz hat sich in den vergangenen anderthalb Jahrzehnten von einem akademischen Nischenthema zu einer zivilisatorischen Weichenstellung gewandelt. Großsprachmodelle generieren Texte, Bilder und Code; autonome Systeme treffen Entscheidungen in Medizin, Justiz und Finanzwesen; und die führenden KI-Laboratorien sprechen offen davon, in absehbarer Zeit eine künstliche allgemeine Intelligenz zu erschaffen ([OpenAI, 2023](#); [Anthropic, 2023](#); [Bengio et al., 2024](#)). Was dabei leicht übersehen wird: Hinter diesen technologischen Trajektorien stehen konkrete Gruppen – CEOs, Akademiker, Investoren, Gründer –, deren *kollektive* Überzeugungen über die Natur des Menschen, den Sinn des Fortschritts und die Verteilung von Risiko und Macht in die Architektur der Systeme einfließen, die sie bauen. Das Verständnis dieser Überzeugungssysteme erfordert den Schritt von individuellen Porträts zu einer systematischen Gruppenanalyse: Was denken CEOs im Vergleich zu Akademikern? Wie unterscheiden sich Beschleuniger von Risiko-Warnern? Welche kollektiven Trends zeichnen sich über anderthalb Jahrzehnte KI-Entwicklung ab?

[Lessig \(1999\)](#) hat die Formel „Code is law“ geprägt: Software-Architektur reguliert Verhalten nicht weniger wirksam als Gesetze, aber ohne demokratische Legitimation. Diese Einsicht lässt sich für die gegenwärtige KI-Entwicklung radikalisieren: Nicht nur der Code selbst, sondern bereits die *Weltbilder* der Entwickelnden werden zu Algorithmen. Wer glaubt, dass Informationsfreiheit ein absoluter Wert ist, wird Open-Source-Modelle bauen. Wer überzeugt ist, dass eine unkontrollierte Superintelligenz die Menschheit bedroht, wird auf Alignment und geschlossene Systeme setzen. Die Weltbilder der KI-Elite sind somit nicht bloß private Meinungen; sie sind *generative Strukturen*, die sich in Designentscheidungen, Unternehmensstrategien und politische Positionierungen übersetzen – und über diese Kanäle das Leben von Milliarden Menschen prägen. Entscheidend dabei ist, dass diese Überzeugungsstrukturen keine zufälligen individuellen Eigenheiten darstellen, sondern systematische Muster auf Gruppenebene aufweisen: CEOs denken anders als Akademiker, Beschleuniger anders als Risiko-Warner, Männer anders als Frauen. Es sind diese *kollektiven* Muster – nicht die Idiosynkrasien einzelner Akteure –, die die ideologische Infrastruktur der KI-Entwicklung bilden und die demokratische Gesellschaften verstehen müssen.

Dabei entsteht ein demokratietheoretisches Problem. Eine zahlenmäßig äußerst kleine Gruppe trifft Entscheidungen von gesamtgesellschaftlicher Tragweite, ohne über ein demokratisches Mandat zu verfügen. [Crawford \(2021\)](#) hat dies als „Atlas of AI“ beschrieben: die planetaren Machtstrukturen, die hinter KI-Systemen stehen, bleiben weitgehend unsichtbar. [Zuboff \(2019\)](#) analysiert, wie die Extraktion von Verhaltensdaten zu einer neuen ökonomischen Logik („Surveillance Capitalism“) führt, die demokratische Kontrolle untergräbt. [Couldry and Mejias](#)

(2019) sprechen von „Data Colonialism“: der Ausbeutung menschlichen Lebens als Datenbasis. Whittaker (2021) analysiert die Machtkonzentration in der KI-Forschung und deren „steile Kosten“ für die Gesellschaft. Ihre Überzeugungen prägen diese Entscheidungen in einer Weise, die der öffentlichen Kontrolle weitgehend entzogen ist (Floridi, 2019, 2023). Wenn Demokratien informierte Bürgerinnen und Bürger voraussetzen, dann ist die systematische Rekonstruktion der Weltbilder derjenigen, die die mächtigste Technologie des 21. Jahrhunderts gestalten, nicht bloß ein akademisches Anliegen, sondern eine Voraussetzung informierter öffentlicher Deliberation.

1.2 Forschungslücke

Die wissenschaftliche Auseinandersetzung mit den Überzeugungssystemen der KI-Branche hat verschiedene Zugänge hervorgebracht. Auf ideologiekritischer Ebene haben Barbrook & Cameron (1996) die „Californian Ideology“ beschrieben; Morozov (2013) hat die Tendenz zum Solutionismus herausgearbeitet; Daub (2020) hat die rhetorischen und ideologischen Muster des Silicon Valley als kulturelles Phänomen analysiert. Aus der Transhumanismus-Forschung liegen philosophische Analysen vor (Bostrom, 2005; More & Vita-More, 2013; Coeckelbergh, 2020), die jedoch primär auf die Ideengeschichte und nicht auf die empirische Verteilung dieser Überzeugungen abzielen.

Was in diesem Forschungsfeld bislang *fehlt*, ist eine systematische, datengestützte Analyse der KI-Elite als *strukturiertes Kollektiv* – eine Analyse, die zwischen soziologisch bedeutsamen Subgruppen unterscheidet und deren jeweilige Überzeugungssysteme kartiert. Keine Studie untersucht, soweit dem Verfasser bekannt, die folgenden Fragen auf empirisch-systematische Weise: Wie verhalten sich die kollektiven Weltbilder verschiedener Gruppen innerhalb der KI-Elite (CEOs vs. Akademiker, Beschleuniger vs. Risiko-Warner, Männer vs. Frauen) zueinander? Bilden sie kohärente Typen? Wie haben sich diese Weltbilder auf Gruppenebene im Zeitraum von 2010 bis 2026 gewandelt? Und stimmen die öffentlichen Überzeugungen mit dem tatsächlichen Handeln auf Gruppenebene überein?

Neben dieser empirischen Lücke besteht eine *methodische* Lücke. Für die systematische Rekonstruktion von Weltbildern aus öffentlichen Aussagen im großen Maßstab existiert keine etablierte Methode. Klassische qualitative Verfahren skalieren nicht; standardisierte Surveys setzen Zugang zu den Befragten voraus; quantitative Text-Mining-Verfahren erfassen nur Oberflächenmuster. Die vorliegende Studie reagiert auf diese doppelte Lücke mit einem neuen Ansatz – der synthetischen Weltbild-Rekonstruktion (SWR) –, deren Methodik in Abschnitt 3 vollständig dargelegt wird.

1.3 Forschungsfragen

Aus der beschriebenen Forschungslücke leiten sich sechs Forschungsfragen ab, die in einer Stufenlogik angeordnet sind:

F1: WELTBILD (deskriptiv)

Was denkt die KI-Elite über sich selbst, die Welt und die Menschheit?

F2: WANDEL (längsschnittlich)

Wie hat sich das Weltbild der KI-Elite von 2010 bis 2026 verändert?

F3: KONGRUENZ (validierend)

Stimmen Aussagen und Handlungen der KI-Elite überein?

F4: CLUSTER (explorativ)

Welche Weltbild-Typen gibt es in der KI-Elite, und wer gehört wohin?

F5: DIFFERENZ (vergleichend)

Welche Subgruppen der KI-Elite denken anders als andere?

F6: MACHT (normativ)

Welches Weltbild hat die meiste Macht und die meisten Ressourcen?

1.4 Beitrag der Studie

Die Studie leistet einen dreifachen Beitrag. *Methodisch:* Zur Bearbeitung der Forschungsfragen entwickelt die Studie die Synthese-Pipeline der synthetischen Weltbild-Rekonstruktion (SWR; siehe Abschnitt 3) – ein LLM-gestütztes Verfahren zur Synthese gruppenaggregierten Materials zu kohärenten kollektiven Überzeugungsrepräsentationen – und wendet das dimensionale Rating als eine spezifische Operationalisierung dieser Pipeline auf das empirische Material an. *Empirisch:* Sie liefert die erste systematische Weltbild-Analyse der KI-Elite als strukturiertes Kollektiv auf der Grundlage von 3.132 Datenpunkten über 16 Jahre, differenziert nach 9 systematischen Inter-Gruppen-Vergleichen (nach Rolle, Haltung, Geschlecht, Firma, Epoche). *Gesellschaftlich:* Sie schafft eine Grundlage für informierte öffentliche Deliberation, indem sie die kollektiven ideologischen Muster – Trends, Gruppenunterschiede, Sagen-Handeln-Klüfte – offenlegt, die KI-Governance und Designentscheidungen prägen.

2. Forschungsstand

Die Studie verortet sich im Schnittpunkt vier verschiedener Forschungstraditionen.

2.1 Silicon Valley als Ideologie

Die kritische Auseinandersetzung mit dem Denken des Silicon Valley hat seit Mitte der 1990er Jahre eine reichhaltige Literatur hervorgebracht. [Barbrook & Cameron \(1996\)](#) prägten den Begriff der „Californian Ideology“ – die paradoxe Verschmelzung von libertärem Individualismus

und techno-utopischem Optimismus. [Turner \(2006\)](#) zeichnete die kulturhistorische Genealogie dieser Ideologie nach und zeigte, wie die Gegenkultur der 1960er Jahre in den digitalen Utopismus transformiert wurde. [Daub \(2020\)](#) legte die philosophischen Tiefenstrukturen frei: Versatzstücke aus Heidegger, Ayn Rand und puritanischer Prädestinationslehre bilden ein „überraschend schmales philosophisches Fundament“. [Morozov \(2013\)](#) beschrieb den Solutionismus – die Grundhaltung, komplexe soziale Probleme als technische Herausforderungen umzudefinieren. [Gebru & Torres \(2024\)](#) systematisierten diese Strömungen im TESCREAL-Framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism und Longtermism als „zusammenhängendes Bündel“. Ergänzend prägte [Broussard \(2018\)](#) den Begriff des „Technochauvinismus“ für eine systematische Kritik.

Die bisherige Forschung hat somit die *Ideologie* des Silicon Valley auf verschiedenen Ebenen beschrieben. Was sie nicht geleistet hat, ist eine systematische empirische Vermessung der *konkreten Weltbilder* der realen Akteure.

2.2 Transhumanismus und KI-Eschatologie

[Bostrom \(2014\)](#) hat mit *Superintelligence* den Denkraum definiert, in dem ein wesentlicher Teil der KI-Elite seither operiert. Bereits in früherer Arbeit systematisierte [Bostrom \(2005\)](#) die ideengeschichtlichen Grundlagen des Transhumanismus. [More \(2003\)](#) legte mit den „Principles of Extropy“ das Gründungsdokument des Extropianismus vor. [Kurzweil \(2005\)](#) wendete die Tradition mit der Singularity-These ins Populäre. Von philosophischer Seite formulierte [Habermas \(2001\)](#) eine der gewichtigsten Gegenpositionen: Die technologische Manipulation künftiger Personen untergrabe deren Autonomie.

Ungeklärt bleibt die empirische Frage: Teilen die realen KI-Akteure diese Überzeugungen? In welcher Mischung, mit welchen Modifikationen und in welcher Verteilung?

2.3 Weltbild-Forschung und Wissenssoziologie

[Mannheim \(1929\)](#) begründete mit dem Theorem der „Seinsgebundenheit des Denkens“ die Tradition, in der Weltbilder als soziale Phänomene analysiert werden. [Weber \(1904\)](#) schuf mit dem Idealtyp ein methodisches Werkzeug, das für die vorliegende Studie zentral ist: Die synthetischen Personas der SWR lassen sich als Idealtypen im Weber’schen Sinne verstehen. [Berger & Luckmann \(1966\)](#) zeigten, wie Weltbilder als soziale Konstruktionen entstehen, sich stabilisieren und reproduzieren. Die wissenssoziologische Tradition liefert den theoretischen Rahmen, aber keine Methode, die auf die Datenmenge und Dynamik des digitalen Zeitalters zugeschnitten ist.

2.4 LLMs als Forschungsinstrument

Die Nutzung großer Sprachmodelle als Instrument sozialwissenschaftlicher Forschung ist ein rasch wachsendes Feld. [Tai et al. \(2024\)](#) untersuchten LLMs für deduktives Kodieren; [Hayes \(2025\)](#) zeigte, dass LLMs einen konversationellen Zugang zu qualitativen Daten ermöglichen; [Nicmanis & Spurrier \(2025\)](#) bieten eine praxisorientierte Einführung. Besonders relevant für die vorliegende Studie ist die Arbeit von [Ornstein et al. \(2025\)](#), die zeigt, dass LLMs multidimensionales ideologisches Scaling mit hoher Reliabilität durchführen können – eine direkte methodische Stützung des SWR-Ansatzes mit 12 Dimensionen. Arbeiten zu synthetischen Personas ([Ge et al., 2024](#)) demonstrierten die Skalierbarkeit des Ansatzes – verfolgten aber ein *anderes* Ziel: Sie nutzen synthetische Personas zur *Datenerzeugung*, während die vorliegende Studie sie zur *Rekonstruktion* kohärenter Weltbilder aus *realen* Daten einsetzt. Die synthetische Persona ist in unserem Verfahren kein Simulacrum, sondern ein analytisches Verdichtungsinstrument – näher am Weber’schen Idealtyp als am Simulationsagenten (vgl. [Booth, 1961](#); [Ng & Russell, 2000](#); [Jara-Ettinger, 2019](#)).

2.5 Zusammenfassung: Die Forschungslücke

Die vier Traditionen konvergieren auf eine gemeinsame Leerstelle: die systematische, datengestützte, längsschnittliche Vermessung konkreter Weltbilder der KI-Elite mittels einer Methode, die qualitative Tiefe mit quantitativer Systematik verbindet. Ergänzend sei auf die empirische Elitenforschung verwiesen: [Mills’](#) Analyse der „Power Elite“ als ineinander verschränkte Netzwerke aus Wirtschaft, Militär und Politik liefert ein Strukturmodell, das auf die KI-Elite übertragbar erscheint – mit dem Unterschied, dass technologische Kompetenz an die Stelle militärischer Macht getreten ist. Die vorliegende Studie adressiert die konvergierende Lücke, indem sie Elemente aller vier Traditionen integriert und um den Elitenbegriff ergänzt.

3. Methodik

Dieser Abschnitt stellt die vollständige Methodik dar, wie sie in dieser Studie implementiert wurde. Die synthetische Weltbild-Rekonstruktion (SWR) ist ein LLM-gestütztes Verfahren zur Inferenz kollektiver Überzeugungssysteme aus öffentlich beobachtbaren Daten. Die Kerneinsicht besteht darin, dass Weltbild-Analyse als inverses Problem formuliert werden kann: Gegeben die beobachtbaren Outputs (Aussagen und Handlungen) einer soziologisch definierten Gruppe, rekonstruiere das latente Überzeugungssystem, das diese Outputs am kohärentesten erzeugen würde. Die Methode nutzt die Fähigkeit großer Sprachmodelle, heterogene textuelle Evidenz in kohärente Repräsentationen zu synthetisieren – nicht durch Abruf gespeicherten Wissens über Einzelpersonen, sondern durch Konstruktion eines neuartigen kollektiven Porträts aus den präsentierten Daten. Der vorliegende Abschnitt ist für Zwecke der Evaluation und Replikation in sich geschlossen.

3.1 Datenerhebung

3.1.1 Stichprobe und Auswahlverfahren

Gegenstand der Untersuchung sind die 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (im Folgenden: KI-Elite). Die Auswahl erfolgte durch ein mehrstufiges Verfahren: Mittels 22 systematischer Webrecherchen wurden 187 Kandidatinnen und Kandidaten identifiziert. Jede Person wurde anhand eines 6-Kategorien-Scoring-Systems bewertet: (1) Marktkapitalisierung/Ressourcenkontrolle, (2) technologische Schlüsselpositionen, (3) öffentliche Diskursmacht, (4) akademischer Einfluss, (5) politische Einflussnahme, (6) symbolischer Status. Die resultierende Rangliste wurde auf 100 Personen reduziert, wobei die Heterogenität der Branche hinsichtlich Rollen, Firmenzugehörigkeiten, Haltungen und Geschlecht abgebildet wird (vgl. Anhang A).

3.1.2 Datenquellen und Erhebungszeitraum

Der Erhebungszeitraum erstreckt sich vom 1. Januar 2010 bis zum 11. Februar 2026. Die Datenerhebung stützt sich auf zwei Datentypen: **öffentliche Aussagen** (wörtliche Zitate aus Interviews, Keynotes, Podcasts, Twitter/X-Posts, Blogbeiträgen, Büchern, Kongressanhörungen) und **beobachtbare Handlungen** (Investitionsentscheidungen, Firmengründungen, Personalentscheidungen, politische Aktivitäten, Produkteinführungen). Die Verknüpfung wurde in einer relationalen SQLite-Datenbank mit 9 Tabellen und 5 Views operationalisiert. Die Gesamtmenge beläuft sich auf 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte). Nach Anwendung der Ein- und Ausschlusskriterien (siehe unten) wurden 1.735 Aussagen für die Analyse beibehalten (3 Near-Duplikate ausgeschlossen, 4 Grenzfälle geprüft und einbezogen).

Datendichte pro Akteur: Die Anzahl der Datenpunkte pro Akteur reicht von 20 (Minimum) bis 72 (Maximum), mit einem Mittelwert von 31,3 ($SD \approx 12$). Die zeitliche Verteilung ist un- ausgewogen: Die Jahre 2010–2011 tragen jeweils nur 17 Datenpunkte bei, während 2024 insgesamt 735 beiträgt. Diese Ungleichverteilung spiegelt das exponentielle Wachstum des öffentlichen KI-Diskurses wider und wird durch Epochen-Aggregation in der Längsschnittanalyse (Abschnitt 4.2) adressiert.

Datenqualität. Die automatisierte Metadaten-Verifizierung aller 1.735 einbezogenen Aussagen zeigt: 95,2 % tragen einen Quelllink, 94,5 % einen Quellentitel und 95,3 % ein Äußerungsdatum. Eine manuelle Stichprobe von 20 zufällig gezogenen Aussagen bestätigte, dass alle Links zu verifizierbaren Quellen führen (CNBC, Financial Times, Stanford University, Twitter/X, Unternehmenswebsites).

3.1.3 Methodologische Verankerung

Die Datenerhebung folgt dem Grounded-Theory-Ansatz nach [Strauss & Corbin \(1990\)](#): In Phase 1 wurden keine inhaltlichen Filter angewandt; in Phase 2 wurden mittels offenen Kodierens

Muster identifiziert; in Phase 3 wurde ein datengestütztes Kategoriensystem mit 13 Primärkategorien und 13 Sekundärmarkern entwickelt (6.161 Kodierungen insgesamt, durchschnittlich 3,5 Codes pro Aussage). Ein- und Ausschlusskriterien wurden erst in Phase 5 formuliert (3 Near-Duplikate ausgeschlossen); in Phase 6 erfolgte eine Qualitätssicherung (automatisierte Metadaten-Verifizierung aller Aussagen sowie manuelle Stichprobe von $n = 20$).

3.2 Die Methode der synthetischen Weltbild-Rekonstruktion

Die SWR definiert Weltbild-Analyse als inverses Problem: Aus den aggregierten beobachtbaren Aussagen und Handlungen der Mitglieder einer *Gruppe* wird auf das kollektive Überzeugungssystem W_G^* zurückgeschlossen, das diese Outputs am kohärentesten erzeugen würde. Formal: Gegeben die Menge aller öffentlichen Aussagen $\{A_1, \dots, A_n\}$ und dokumentierten Handlungen $\{H_1, \dots, H_m\}$ einer soziologisch definierten Gruppe G , rekonstruiere W_G^* so, dass die Gesamtheit der beobachteten Outputs unter W_G^* maximal kohärent ist. Die Lösung besteht in der Konstruktion einer *fiktiven synthetischen Person* – eines Weberschen Idealtyps, der das Gruppenweltbild in Reinform repräsentiert, befreit von individuellem biographischem Rauschen und PR-Strategien.

Die SWR nutzt einen strukturellen Vorteil der Analyse auf Gruppenebene: Kein LLM-Trainingskorpus enthält „das kollektive Weltbild der CEOs“ oder „das geteilte Überzeugungssystem der Risiko-Warner“ als vorgeformtes Objekt. Das kollektive Weltbild wird durch die Synthese *erzeugt*, nicht aus dem Gedächtnis abgerufen. Dies reduziert strukturell das Kontaminationsrisiko, das die primäre methodische Sorge bei LLM-basierter Rekonstruktion darstellt – ein Vorteil, der für Analysen auf Individualebene nicht gilt, wo das LLM auf umfangreiches gespeichertes Wissen über spezifische öffentliche Persönlichkeiten zurückgreifen kann.

In der vorliegenden Studie sind die primären Analyseeinheiten soziologisch definierte Gruppen (CEOs, Akademiker, Investoren, Gründer, Frauen, Männer, Beschleuniger, Risiko-Warner usw.); die 100 Einzelpersonen dienen als Datenlieferanten, deren Aussagen und Handlungen auf Gruppenebene aggregiert werden. Die theoretische Verankerung stützt sich primär auf Webers Idealtyp – eine Tradition, die explizit für Analysen auf Gruppenebene konzipiert wurde –, ergänzt durch Booths *Implied Author*, Inverse Reinforcement Learning und projektive Tests. Der operative Ablauf umfasst fünf Schritte: (1) Gruppenspezifischen Datenkorpus zusammenstellen, (2) LLM-gestützte Synthese einer fiktiven synthetischen Person, (3) strukturiertes Interview zu Selbstbild, Weltbild und Menschenbild, (4) Meta-Reflexion zu internen Spannungen und blinden Flecken, (5) dimensionales Rating auf 12 Dimensionen (D01–D12). Schritte 1–4 bilden die Synthese-Pipeline und stellen die methodische Kerninnovation dar; Schritt 5 (dimensionales Rating) ist eine für diese Studie gewählte Operationalisierung, die grundsätzlich durch andere Analysemethoden wie Diskursanalyse, psychometrische Skalen oder strukturierte Interviewprotokolle ersetzbar ist. Die Fokuskontrollinfrastruktur, die Begründung des Fiktionsansatzes und der Validierungsrahmen werden im Abschnitt Qualitätssicherung unten (Abschnitt 3.6) dargelegt. Die Übertragbarkeit der Methode auf andere Populationen (politische, militärische,

religiöse Eliten) ist eine natürliche Erweiterung, die gesonderte Untersuchung erfordert.

3.2.1 Datenaggregationsverfahren

Synthesen auf Gruppenebene operieren direkt auf den gepoolten Rohdaten – nicht auf aggregierten Individualprofilen. Für jede Syntheseinheit (z. B. „alle CEOs“) werden die Aussagen und Handlungen aller Gruppenmitglieder in ein einzelnes Dossier zusammengefasst, chronologisch sortiert und dem LLM als eine Eingabe präsentiert. Das LLM konstruiert dann eine fiktive synthetische Person, deren Weltbild die Gesamtheit der präsentierten Gruppendaten am besten erklärt. Entscheidend ist, dass keine intermediäre Aggregation auf Individualebene stattfindet: Das kollektive Porträt entsteht direkt aus der gepoolten Evidenz, analog dazu, wie ein Historiker den *Zeitgeist* einer Epoche aus Primärquellen rekonstruiert, nicht aus gemittelten Biographien. Die 100 individuellen Rating-Profile wurden separat für einen einzigen technischen Zweck generiert: die 100×12 -Datenmatrix für algorithmische Strukturprüfungen (PCA, HDBSCAN, Kruskal-Wallis) bereitzustellen. Sie gehen nicht in die Gruppensynthese-Pipeline ein und werden nicht als inhaltliche Befunde berichtet.

3.3 Operationalisierungen

Die drei abhängigen Variablen (AV1: Selbstbild, AV2: Weltbild, AV3: Menschenbild) werden durch sechs im SWR-Framework definierte Operationalisierungen zugänglich gemacht, von denen fünf in dieser Studie angewendet wurden (Op1, Op2, Op4, Op5, Op6):

Tabelle 1: Die sechs Operationalisierungen der SWR.

Op	Technik	Beschreibung	MVs
Op1	T1 Kern-Synthese	Fiktive Person + 3-Fragen-Interview + Reflexion	7
Op2	T4 Rating	Bewertung auf 12 Dimensionen (D01–D12), Skala 1–10	12
Op3	Textanalyse	TF-IDF, Sentiment, Metaphern, Embeddings, Topics	8+
Op4	T3 Kreuzmodal	Vorhersage: Aussagen → Handlungen (5 Gruppen, 72 % bestätigt, 0 % widerlegt)	4
Op5	T5 Clustering	PCA + HDBSCAN auf Ratingmatrix (siehe Abschnitt 4.4)	6*
Op6	T2 Dialog	Strukturierter Vergleich zweier Synthesen	3

Op3 (Textanalyse) wurde nicht durchgeführt. Op5 wurde als PCA + HDBSCAN auf der 100×12 -Ratingmatrix implementiert, nicht als Sentence-BERT-Clustering.

Die 12 Rating-Dimensionen (Op2) wurden in einem iterativen Verfahren entwickelt: Ausgehend von der ideologiekritischen Literatur (Solutionismus, TESCOREAL, Californian Ideology) und der Transhumanismus-Forschung wurden zunächst 18 Kandidaten-Dimensionen identifiziert, die in einer Pilotphase auf 12 reduziert wurden – unter den Kriterien inhaltlicher Distinktheit, Abdeckung aller drei AVs und praktischer Operationalisierbarkeit im LLM-Rating-Kontext. Die Dimensionen erheben keinen Anspruch auf Exhaustivität; alternative

Dimensionierungen (z. B. Risikowahrnehmung, Internationalismus, epistemologische Grundhaltung) wären denkbar und könnten in Folgestudien ergänzt werden. Die 12 Dimensionen verteilen sich gleichmäßig auf die drei AVs: Selbstbild-Dimensionen D01–D04 (Sendungsbewusstsein, Selbstwirksamkeit, Arbeitsethos, Verantwortungsgefühl), Weltbild-Dimensionen D05–D08 (Techno-Determinismus, Fortschrittsglaube, Machtkonzentration, Dringlichkeit) und Menschenbild-Dimensionen D09–D12 (Menschenfreundlichkeit¹, Posthumanismus, Egalitarismus, Kontrollüberzeugung). Die vollständige Dimensionentabelle mit Skalenpolen findet sich in Anhang B.

3.4 Forschungsdesign

3.4.1 Variablenarchitektur

Das Forschungsdesign ist als vierstufige Architektur konzipiert: 3 AVs → 6 Operationalisierungen → 50+ Messvariablen → 6 unabhängige Variablen (UVs). Die UVs bestimmen, welche Daten in eine Syntheseinheit (SE) eingehen, wobei jede SE eine *Synthese auf Gruppenebene* darstellt – das kollektive Weltbild einer soziologisch definierten Subgruppe:

- UV1 *Zeitraum*: Einzeljahre (2010–2026), Epochen, Gesamtzeitraum
- UV2 *Modalität*: Aussagen+Handlungen (AH), nur Aussagen (A), nur Handlungen (H)
- UV3 *Personengruppe*: Alle 100, Top 10, Subgruppen (Rollen, Firmen, Haltung, Geschlecht)
- UV4 *Inhaltskategorie*: Durch emergente Cluster ersetzt (K9)
- UV5 *Kongruenzstatus*: Konsistent vs. widersprüchlich
- UV6 *Homogenisierung*: Alle vs. nur häufig wiederholte Aussagen

3.4.2 Systematische Reduktion

Der theoretische Kombinationsraum von ca. 1.227 möglichen SEs wurde durch neun Reduktionskriterien (K1–K9; vgl. Anhang C) auf 51–56 Kern-SEs reduziert (95,4 % Reduktion). Zusätzlich wurden 9 strukturierte Vergleichs-Runs (Op6) durchgeführt. Die kreuzmodale Vorhersage (Op4) wurde für fünf Gruppen mit strikter Instanztrennung durchgeführt: Auf Aussagen basierende Verhaltensvorhersagen wurden in 98 % der Fälle durch reale Handlungen bestätigt oder als plausibel bewertet, bei 0 % Widersprüchen (siehe Abschnitt 3.6).

¹Das Label „Menschenfreundlichkeit“ ist eine vereinfachende Kurzbezeichnung und potenziell irreführend: Ein Wert von 5 bedeutet *nicht*, dass die KI-Elite „menschenfeindlich“ ist. Die Skalenpole „Ersetzbar“ (1) vs. „Einzigartig“ (10) messen präziser eine *anthropologische Wertschätzung* – die Frage, ob menschliches Bewusstsein und Erleben als grundsätzlich nicht-substituierbar oder als funktional reproduzierbar betrachtet wird. Der präzisere Terminus wäre „Anthropologische Wertschätzung“; der Begriff „Menschenfreundlichkeit“ wird beibehalten, um Konsistenz über die Studie hinweg zu wahren.

3.4.3 Zuordnung: Forschungsfragen, Operationalisierungen und Kern-SEs

Tabelle 2 gibt eine kompakte Übersicht, welche Operationalisierungen und Syntheseeinheiten den sechs Forschungsfragen zugeordnet sind.

Tabelle 2: Zuordnung von Forschungsfragen, Operationalisierungen und Kern-SEs.

F	Ops	Kern-SEs	Gegenstand
F1	Op1, Op2, Op3	1, 4, 5	Kollektiv- und Top-10-Profil, Kernüberzeugungen
F2	Op2, Op3	6–26	Jahres- und Epochen-Synthesen, Trends
F3	Op2, Op4	2, 3, 42–43	Aussagen vs. Handlungen, Kongruenzprüfung
F4	Op2, Op5	27–41	Gruppen-Synthesen, Cluster-Identifikation
F5	Op2, Op6	27–41	Subgruppen-Vergleiche
F6	Op2	4, 27–30	Macht-Weltbild-Zusammenhang

3.5 Positionierung des Forschers

Der Verfasser ist unabhängiger Forscher ohne institutionelle Anbindung an eines der untersuchten Unternehmen oder Forschungslabore. Diese Außenseiterposition ermöglicht eine größere Distanz zum Forschungsgegenstand, bringt aber spezifische blinde Flecken mit sich: (a) fehlender Zugang zu internen Diskursen und nicht-öffentlichen Positionen; (b) Abhängigkeit von öffentlich zugänglichen Quellen, die PR-gefiltert sein können; (c) potenzielle Neigung, die Geschlossenheit und Kohärenz der untersuchten Gruppe zu überschätzen, da die interne Vielfalt aus der Außenperspektive weniger sichtbar ist. Die Studie ist zudem als deutschsprachige Analyse eines überwiegend englischsprachigen Diskurses situiert, was Nuancen in der Übertragung erzeugen kann.

3.6 Qualitätssicherung

Die methodische Qualität wird durch vier Design-Maßnahmen, vier abgeschlossene Post-hoc-Validierungen und eine verbleibende offene Aufgabe adressiert. *Design-Maßnahmen:* (1) Mindestgröße von 15 Datenpunkten pro SE², (2) konsequente Fokuskontrolle mittels eines Anonymisierungsskripts, das alle Personennamen, Firmennamen, Produktnamen und Universitätszugehörigkeiten durch neutrale Platzhalter ersetzt, um sicherzustellen, dass das LLM die präsentierten Daten verarbeitet, anstatt auf gespeichertes Wissen zurückzugreifen, (3) Reproduzierbarkeitsprotokoll (Temperatur 0, vollständige Prompt-Dokumentation, alle Prompts im Repository archiviert) und (4) algorithmische Strukturprüfung der Clusterstruktur via PCA und HDBSCAN auf der 100 × 12-Ratingmatrix. *Offene Validierungsaufgabe:*

²Der Schwellenwert von 15 Datenpunkten stützt sich auf methodische Überlegungen: In der qualitativen Sozialforschung gelten 6–12 Interviews als hinreichend für thematische Sättigung (Strauss & Corbin, 1990), während neuere Schätzungen die thematische Sättigung typischerweise zwischen 12 und 20 Einheiten verorten (Guest et al., 2006; Fugard & Potts, 2015). Der Wert von 15 ist konservativ gewählt, um eine ausreichende Datendichte für die LLM-gestützte Synthese sicherzustellen.

Inter-Modell-Replikation (unabhängige Replikation der vollständigen Analyse mit mindestens einem weiteren Frontier-Modell durch andere Forschende) steht noch aus; dies stellt eine externe Replikation dar, nicht eine Voraussetzung für die interne Validität der vorliegenden Studie. *Abgeschlossene Validierung:* (a) **Intra-Modell-Inter-Instanzen-Rating-Reliabilität (IMIIRR):** Fünf Gruppen-Syntheseeinheiten wurden jeweils zweimal unabhängig von Claude Opus 4.6 verarbeitet. Die resultierenden D01–D12-Profile zeigten exzellente Konvergenz: Gesamt-Pearson $r = 0,908$, $ICC(2,1) = 0,902$, $MAE = 0,40$ auf der 10-Punkte-Skala (Messgenauigkeit $\pm 0,2$ Skalenpunkte). Alle 12 Dimensionen waren über die Durchläufe stabil (mittleres $|\Delta| \leq 0,8$). Eine nachfolgende Validierung mit $N = 15$ vollständig unabhängigen Opus-Instanzen — jede in einem separaten Agenten ohne geteilten Kontext — auf einer einzelnen Gruppen-Syntheseinheit (GA_ges_AH) bestätigte diesen Befund mit höherer statistischer Power: $ICC(3,1) = 0,847$, mittlere $SD = 0,45$ über alle 12 Dimensionen (Bereich: 0,00–0,74). Bemerkenswert: Eine Dimension (D02, Selbstwirksamkeit) zeigte perfekte Übereinstimmung – alle 15 Instanzen vergaben exakt denselben Wert. Die übrigen Dimensionen variierten um höchstens ± 1 Punkt (10 von 12 hatten nur 2 verschiedene Werte über 15 Runs). Diese IMIIRR-Koeffizienten übertreffen die typische Inter-Rater-Reliabilität menschlicher Kodierer in qualitativer Forschung ($ICC = 0,6–0,8$; Hallgren 2012) und etablieren Claude Opus 4.6 als zuverlässig kalibriertes Instrument für die SWR-Methode. (b) **Expected-Discrepancy-Kontrolle:** Ein synthetischer Kontrollkorpus einer fiktiven konsistenten Gruppe (Umweltwissenschaftler, 30 Aussagen + 30 Handlungen ohne beabsichtigte Sagen-Handeln-Kluft) wurde in zwei Bedingungen durch dieselbe Pipeline verarbeitet: (v1) selbe Instanz für beide Datentypen ($MAE = 0,50$, $r = 0,912$) und (v2) strikte Instanztrennung, bei der Aussagen und Handlungen von unabhängigen Agenten verarbeitet wurden ($MAE = 0,92$). Die v2-Baseline ist methodisch angemessen, da auch der reale Sagen-Handeln-Vergleich Instanztrennung verwendet. Im Vergleich liegt die reale KI-Elite-Kluft unter gleichen Bedingungen bei $MAE = 0,75$ (v2), was *unter* die v2-Kontrollbaseline fällt – der aggregierte Gap ist somit nicht zuverlässig von Messrauschen unterscheidbar. Die Gruppendekomposition (siehe Abschnitt 4.3) zeigt jedoch, dass dieses Aggregat substanzielle gruppenspezifische Gaps verdeckt (CEOs: $MAE = 1,08$; Risiko-Warner: $MAE = 1,92$), beide über der Baseline. (c) **Aggregations-Synthese-Vergleich:** Zur Validierung des Gruppensynthese-Ansatzes wurden die D01–D12-Profile aus direkten Gruppensynthesen (gepoolte Rohdaten) mit aggregierten Individualprofilen (gemittelte Ratings der Gruppenmitglieder) über alle 15 soziologischen Gruppen verglichen. Die Gesamtkorrelation ($r = 0,623$, $MAE = 1,30$) zeigt moderate Konvergenz, mit einem systematischen *Amplifikationseffekt*: Direkte Gruppensynthesen erzeugen schärfere Konturen (71,7 % der Dimension-Gruppen-Kombinationen weiter vom Skalenmittelpunkt). Die Konvergenz ist am höchsten für ideologisch homogene Gruppen (Open Source $r = 0,857$, Beschleuniger $r = 0,855$) und am niedrigsten für heterogene (Frauen $r = 0,428$, Männer $r = 0,549$). Dieser Effekt ist interpretierbar als Gruppenkohärenz-Verstärkung, analog zur Gruppenpolarisierung in der Sozialpsychologie. (d) **Kreuzmodale Vorhersage (Op4):** Für

fünf soziologische Gruppen (CEOs, Akademiker, Risiko-Warner, Investoren, Beschleuniger) wurden jeweils zehn Handlungsvorhersagen ausschließlich aus dem Aussagenkorpus durch eine erste Agenten-Instanz (Op4a) generiert; diese Vorhersagen wurden dann durch eine *separate* Agenten-Instanz (Op4b), die die ursprünglichen Aussagen nie gesehen hatte, gegen die tatsächlich dokumentierten Handlungen evaluiert — wodurch ein Blindvergleich ohne Bestätigungsfehler sichergestellt wurde. Von 50 Vorhersagen wurden 36 (72 %) direkt durch reale Handlungen bestätigt, 13 (26 %) waren plausibel aber ohne direktes Match, und 0 (0 %) wurden widerlegt. Die Bestätigungsraten variierten nach Gruppentyp: ideologisch kohärente Gruppen zeigten die höchste Vorhersagbarkeit (Akademiker und Risiko-Warner: je 90 % bestätigt), während heterogene Gruppen niedrigere, aber dennoch substanzielle Raten aufwiesen (Investoren und Beschleuniger: je 50 % bestätigt, mit zusätzlich 40–50 % plausibel). Die nicht vorhergesagten Handlungen – politischer Opportunismus, massive kommerzielle Aktivität trotz warnender Rhetorik, interne Governance-Krisen – sind genau die Phänomene, die die Sagen-Handeln-Analyse (F3) aufdecken soll. (e) **Anonymisierungs-Robustheitstest:** Um zu prüfen, ob der Anonymisierungsansatz die Ergebnisse beeinflusst, wurde dieselbe Syntheseinheit (Risiko-Warner, 139 Aussagen + 92 Handlungen) mit drei verschiedenen Verblindungsstrategien verarbeitet: (A) Platzhalter-Tokens ([PERSON], [COMPANY]), (B) plausible fiktive Namen und (C) volle Offenlegung der realen Identitäten (Musk, Sutskever, Hinton, Russell, Bengio, Leike). Die Varianten A und B waren nahezu identisch ($r = 0,987$, $MAE = 0,33$). Variante C zeigte einen moderaten, aber nicht drastischen Anstieg: A–C $MAE = 0,67$, $r = 0,850$, mit demselben Gruppendurchschnitt (7,1). Die größte Verschiebung betraf D11 (Egalitarismus, +2 Punkte mit Identitätswissen). Dies bestätigt, dass Anonymisierung einen messbaren, aber bescheidenen Schutz bietet; Ratings auf Gruppenebene sind auch bei bekannten Identitäten robust. (f) **Rating-Reihenfolge-Invarianz:** Dieselbe Synthese (Risiko-Warner) wurde mit zwei verschiedenen Permutationen der D01–D12-Dimensionsliste bewertet. Alle 12 Ratings waren über die Permutationen identisch, was bestätigt, dass kein Listenreihenfolge-Effekt im Rating-Verfahren vorliegt. (g) **Instanztrennungs-Analyse:** Eine systematische Überprüfung historischer Analyse-Protokolle ergab, dass der ursprüngliche Sagen-Handeln-Vergleich (GA_ges_A vs. GA_ges_H, Batch 1) innerhalb derselben LLM-Instanz durchgeführt wurde – unter Verletzung des Prinzips unabhängiger Messung. Bei Wiederholung mit strikter Instanztrennung (jeder Datentyp in einem eigenen Agenten) schrumpfte die Sagen-Handeln-Kluft von $MAE = 1,42$ auf $MAE = 0,75$ (–47 %). Die Kontrollgruppen-Kluft (G6) stieg unter denselben Bedingungen von $MAE = 0,50$ auf $MAE = 0,92$. Folglich fällt die v2-Sagen-Handeln-Kluft unter die Kontrollbaseline, was darauf hindeutet, dass die *Gesamtmagnitude* der Kluft in Einzeldurchläufen nicht zuverlässig vom Messrauschen unterscheidbar ist. Allerdings bleiben zwei spezifische Dimensionen über beide Versionen stabil: D07 (Machtkonzentration: +2, Handlungen konzentrierter) und D11 (Egalitarismus: –2, Handlungen weniger egalitär). Diese bilden die robusten Sagen-Handeln-Befunde der Studie. (h) **Anthropic-Matched-Sample-Kontrolle:** Um zu testen, ob Claude eine systematische Verzerrung zugunsten

seiner Entwicklerorganisation aufweist, wurde die Anthropic-Subgruppe ($n = 9$) mit einer gematchten Kontrollgruppe von Nicht-Anthropic-Gründern und -Forschern ($n = 9$, gleiche Größe und Rollenzusammensetzung) verglichen. Die resultierenden Profile zeigten MAE = 1,00 ohne $|\Delta| \geq 3$ auf irgendeiner Dimension. Die beobachteten Unterschiede (Anthropic: höhere Dringlichkeit und Machtkonzentration; Kontrolle: höherer Posthumanismus und Kontrollüberzeugung) sind als genuine Gruppenunterschiede interpretierbar, nicht als Modellverzerrung. (i) **Ausreißer-Detektion:** Für fünf Gruppen wurde das rekonstruierte Weltbild mit den Originaldaten konfrontiert, um Aussagen und Handlungen zu identifizieren, die *nicht* zur Synthese passen. Die Gesamtpassung lag zwischen 80 % (Risiko-Warner) und 88 % (CEOs), mit 6–8 identifizierbaren Ausreißern pro Gruppe. Die Methode glättet nicht alle Daten in Kohärenz; dissidente Stimmen, interne Widersprüche und politische Heterogenität bleiben detektierbar. (j) **Inversions-Kontrolle (Anti-Kohärenz-Test):** Für fünf Gruppen wurden fiktive Anti-Personen konstruiert, deren Weltbilder den präsentierten Daten maximal *widersprechen*. In 58 % der Dimension-Gruppen-Kombinationen unterschied sich das Anti-Profil um ≥ 5 Punkte von der kohärenten Rekonstruktion, was bestätigt, dass die kohärente Interpretation eine spezifische, datengestützte Wahl ist – nicht die einzig mögliche Lesart. (k) **Einfluss-Strata-Vergleich:** Drei rangbasierte Strata (Top 10: Ränge 1–10, Avg 7,7; Mitte: Ränge 40–60, Avg 6,4; Bottom 10: Ränge 91–100, Avg 6,1) wurden unabhängig synthetisiert und bewertet. Ein Einflussgradient wurde bestätigt: Die mächtigsten Akteure vertreten die intensivsten Weltbilder. Zwei Dimensionen zeigten einen *inversen* Gradienten: D09 (Menschenfreundlichkeit: Top 4, Mitte 6, Bottom 8) und D10 (Posthumanismus: Top 8, Mitte 5, Bottom 3) – die mächtigsten Akteure sind die posthumanistischsten und am wenigsten menschenfreundlichen. (l) **Inter-Modell-Vergleich (Desiderat):** Ein Inter-Modell-Vergleich — Replikation der vollständigen Op1+Op2-Pipeline mit einem anderen Modell (z. B. Claude Haiku, GPT-4, Gemini) unter Verwendung von $N \geq 15$ vollständig unabhängigen Einzelinstanz-Runs — steht noch aus. Vorläufige Experimente mit Claude Haiku 4.5 deuteten auf systematische modell-spezifische Unterschiede in der interpretativen Gewichtung hin (moderatere, humanistischere Profile), konnten aber das strikte Unabhängigkeitskriterium der $N = 15$ Opus-Validierung (separater Agent pro Run, kein geteilter Kontext) nicht erfüllen. Ein methodisch rigoroser Inter-Modell-Vergleich wird als Priorität für zukünftige Arbeit identifiziert.

Alle Synthesen der vorliegenden Studie wurden mit Claude (Anthropic) generiert: Claude Sonnet 4.5 für Ratings auf Individualebene (9 parallele Batch-Agenten), Claude Opus 4.6 für qualitative Synthesen auf Gruppenebene, statistische Analysen und alle Validierungsexperimente. Kein anderes LLM wurde verwendet. Die Fokuskontrollinfrastruktur adressiert das, was konventionell als *Kontaminationsrisiko* bezeichnet wird: die Möglichkeit, dass das LLM auf Trainingswissen statt auf die präsentierten Daten zurückgreift. Wir bevorzugen den Begriff „Fokuskontrolle“, weil das Ziel nicht darin besteht, die Erkennung von Individuen zu verhindern – was weder möglich noch für die Analyse auf Gruppenebene notwendig ist –, sondern die *Aufgabentreue* sicherzustellen: Das Modell soll aus den bereitgestellten Daten synthetisieren,

nicht Stereotypen reproduzieren.

3.6.1 Dimensionalität des Ratingraums

Die 100 individuellen Rating-Profile wurden während der Datenerhebungsphase von Claude Sonnet 4.5 (9 parallele Batch-Agenten) generiert, wobei die öffentlichen Aussagen und Handlungen jedes Akteurs in einem einzelnen Durchlauf bei Temperatur 0 in ein 12-dimensionales Weltbild-Profil synthetisiert wurden. Diese Einzelprofile wurden für einen einzigen technischen Zweck generiert: die 100×12 -Datenmatrix für die algorithmische Strukturvalidierung (PCA, HDBSCAN) bereitzustellen. Sie gehen nicht in die Gruppensynthese-Pipeline ein – die Gruppensynthesen operieren direkt auf gepoolten Rohdaten (Abschnitt 3). Die Individualebene-Matrix ist somit ein Strukturvalidierungsinstrument, kein inhaltlicher Befund.

Eine Hauptkomponentenanalyse (PCA) der 100×12 -Ratingmatrix zeigt, dass **fünf Komponenten** 80 % der Gesamtvarianz erklären – die zwölf Dimensionen messen demnach ca. fünf unabhängige Konstrukte. PC1 (35,8 % Varianz) lädt am stärksten auf D02 (Selbstwirksamkeit, +0,40), D05 (Techno-Determinismus, +0,39) und D09 (Menschenfreundlichkeit, –0,39) – ein *Technologie-Kontroll-Faktor*, der technophile Handlungsfähigkeit und anthropologische Wertschätzung gegeneinander stellt. PC2 (19,2 % Varianz) lädt auf D01 (Sendungsbewusstsein, +0,51), D04 (Verantwortung, +0,50) und D08 (Dringlichkeit, +0,50) – ein *Engagement-Faktor*, der motivationale Intensität unabhängig von der ideologischen Richtung erfasst. Die moderate Redundanz (5 effektive Dimensionen aus 12) deutet darauf hin, dass das Dimensionssystem weder maximal effizient noch künstlich aufgebläht ist; es stellt eine angemessene Operationalisierung für explorative Arbeit dar.³

4. Ergebnisse

Die Befunde basieren auf synthetischen Weltbild-Rekonstruktionen auf Gruppenebene, abgeleitet aus den Daten der einhundert einflussreichsten KI-Persönlichkeiten, operationalisiert über zwölf Dimensionen auf einer Zehnpunkteskala. Die 100 Einzelpersonen dienen als Datenlieferanten; die Analyseeinheiten sind soziologisch definierte Gruppen (Alle 100, Top 10, CEOs, Akademiker, Investoren, Gründer, Männer, Frauen, Beschleuniger, Risiko-Warner, Firmen, Epochen). Der zentrale Beitrag des Ergebnisteils liegt in den Inter-Gruppen-Vergleichen (F4–F6), die offenlegen, wie strukturelle Position kollektive Überzeugungen formt. Unter *Weltbild* wird im Folgenden das Gesamtsystem aus Selbstbild, Welt- und Menschenbild verstanden (operationalisiert durch AV1–AV3); der Begriff *Überzeugungssystem* wird synonym verwendet, betont aber stärker den strukturellen Zusammenhang der Einzeldimensionen.

³Deskriptive Statistiken bestätigen diese Struktur: D11 (Egalitarismus) weist die größte Streuung auf (SD = 1,67) – die Dimension der stärksten Weltbild-Divergenz – während D03 (Arbeitsethos) die geringste zeigt (SD = 0,74), was den stärksten Konsens innerhalb der KI-Elite repräsentiert.

4.1 F1 – Weltbild der KI-Elite (deskriptiv)

4.1.1 Das kollektive Weltbild aller 100

Das Gesamtprofil – das kollektive Weltbild aller 100 Akteure als eine einzige Gruppe behandelt – deutet auf ein kohärentes, hochintensives Überzeugungssystem mit einem Durchschnittswert von 7,1 hin (Tabelle 3).⁴

Tabelle 3: Kollektiv-Profil der KI-Elite ($N = 100$, Aussagen und Handlungen).

Dimension	Rating	Interpretation
D01 Sendungsbewusstsein	8	Hoch
D02 Selbstwirksamkeit	8	Hoch
D03 Arbeitsethos	8	Hoch
D04 Verantwortungsgefühl	7	Mittel-hoch
D05 Techno-Determinismus	8	Hoch
D06 Fortschrittsglaube	7	Mittel-hoch
D07 Machtkonzentration	6	Mittel (ambivalent)
D08 Dringlichkeit	8	Sehr hoch
D09 Menschenfreundlichkeit*	5	Niedrig
D10 Posthumanismus	7	Mittel-hoch
D11 Egalitarismus	5	Niedrig
D12 Kontrollüberzeugung	8	Hoch
Durchschnitt	7,1	

Das Profil zeigt eine charakteristische Doppelstruktur: ausgeprägt elitäres Selbstbild (D01–D03 je 8), starker Techno-Determinismus (D05=8) und hohe Dringlichkeit (D08=8) einerseits; Menschenfreundlichkeit (D09=5) und Egalitarismus (D11=5) als tiefste Punkte andererseits. Die Kombination erzeugt ein auffallendes Muster, das sich – unter dem Vorbehalt, dass es sich um LLM-rekonstruierte Werte handelt – zuspitzend so formulieren lässt: eine Elite, die *für* die Menschheit bauen will, aber nicht *mit* ihr.

4.1.2 Das Weltbild der Top 10

Die zehn mächtigsten KI-Akteure vertreten dasselbe Weltbild in intensivierter Form (Avg 7,7). Auf zehn von zwölf Dimensionen liegen die Top-10-Werte exakt einen Skalenpunkt über dem Kollektiv. Die beiden Ausnahmen: Menschenfreundlichkeit (D09=4) und Egalitarismus (D11=4) liegen *niedriger*. Je mächtiger die Position, desto ausgeprägter das Sendungsbewusstsein und desto distanzierter das Menschenbild.

⁴Alle in dieser Studie berichteten Ratings sind LLM-generierte *Synthesen auf Gruppenebene*: Das Modell erhält die aggregierten Daten einer soziologisch definierten Gruppe und erzeugt ein einzelnes kollektives Profil. Ratings auf Individualebene werden ausschließlich für die algorithmische Validierung (PCA, HDBSCAN) verwendet, nicht als inhaltliche Befunde. Jede Synthese wurde in einem einzelnen Durchlauf bei Temperatur 0 generiert; Multi-Run-Konvergenztests bleiben eine offene Validierungsaufgabe. Dieses Design ist intentional: Die Studie zielt auf kollektive Weltbilder von Gruppen, nicht auf individuelle Profile.




Abbildung 1: Heatmap der 12 Weltbild-Dimensionen über alle untersuchten Gruppen. Hohe Werte (dunkel) markieren intensive Überzeugungen; die Doppelsenke bei D09 und D11 ist über alle Gruppen hinweg sichtbar.

4.1.3 Kernüberzeugungen

Die Destillation der am häufigsten wiederholten Aussagen (SE 5: HOM_haeuf_A, vgl. Anhang D) identifiziert fünf Überzeugungen als Minimalkonsens: (1) Technologie als moralisches Gebot, (2) Elite-Steuerung, (3) das Befreiungsnarrativ, (4) geopolitischer Manichäismus, (5) Arbeit als Identität. Sicherheitsrhetorik gehört zum Kernbestand des Diskurses, fungiert aber als diskursive Ressource, nicht als handlungsleitende Überzeugung.

Kernbefund F1: Die rekonstruierten Profile deuten auf ein kohärentes, hochintensives Überzeugungssystem hin, das sich als *technologischer Messianismus mit Ambivalenzstruktur* charakterisieren lässt. Die Bezeichnung „Messianismus“ ist dabei als idealtypische Zuspitzung zu verstehen, nicht als psychologische Diagnose: Sie bezeichnet die spezifische *Kombination* aus hohem Sendungsbewusstsein (D01), Techno-Determinismus (D05), Dringlichkeit (D08) und geringer anthropologischer Wertschätzung (D09) – ein Profil, das über bloßes Sendungsbewusstsein hinausgeht, weil es technologischen Fortschritt als quasi-erlöserische Notwendigkeit rahmt.

4.2 F2 – Wandel des Weltbilds (längsschnittlich)

4.2.1 Entwicklung der 12 Dimensionen über die Zeit

Von zwölf Dimensionen zeigen vier ausgeprägte lineare Trends (Tabelle 4).⁵

Tabelle 4: Ausgeprägte lineare Trends (OLS-Beschreibung, $n = 17$ Jahrespunkte).

Dimension	Richtung	Steigung/Dekade	R^2
D10 Posthumanismus	fallend	−2,4	0,63
D12 Kontrollüberzeugung	fallend	−1,5	0,54
D02 Selbstwirksamkeit	fallend	−1,0	0,31
D09 Menschenfreundlichkeit	steigend	+0,9	0,27

Den stärksten Rückgang verzeichnet der Posthumanismus (D10): von 10 im Jahr 2010 auf 6 im Jahr 2025. Die hohe Spearman-Rangkorrelation mit D12 ($r_s = +0,85$)⁶ weist auf ein zusammenhängendes Phänomen: Posthumanismus und Kontrollüberzeugung erodieren synchron. Der einzige deutlich steigende Wert betrifft die Menschenfreundlichkeit (D09), wobei die negative Korrelation mit D10 ($r_s = -0,58$) eine kompensatorische Verknüpfung nahelegt. Der Gesamtdurchschnitt bleibt nahezu konstant (Frühphase 7,5, Spätphase 7,3), was eine tektonische Verschiebung unter der Oberfläche verbirgt.

4.2.2 Wendepunkte und Epochenvergleich

Die Breakpoint-Detection – durchgeführt als visuelle Inspektion der Zeitreihen, ergänzt durch die Identifikation synchroner Extrempunkte über mehrere Dimensionen – identifiziert zwei zentrale Wendepunkte.⁷ Der erste liegt bei 2019: Vier Dimensionen (D01, D02, D05, D06) erreichen synchron ihren Tiefpunkt, zeitlich assoziiert mit der GPT-2-Zurückhaltung. Der zweite, dauerhaftere Wendepunkt liegt bei 2022/2023: Zeitgleich mit der ChatGPT-Veröffentlichung zeigt sich ein markanter Musterwechsel – Dringlichkeit erreicht ihr rekonstruiertes Maximum (D08=10), Egalitarismus fällt von 6 auf 4. Im Unterschied zu 2019 kehren die Werte nicht zurück; die rekonstruierten Profile nach 2022 deuten auf ein neues Gleichgewicht hin. Dabei ist zu beachten, dass die identifizierten Wendepunkte nicht isoliert von breiteren gesellschaftlichen

⁵Die hier berichteten Trendlinien beschreiben *Muster in rekonstruierten Daten*: Die Weltbild-Werte sind LLM-gestützte Rekonstruktionen, keine unabhängigen Messungen. OLS-Steigungen und R^2 dienen der Beschreibung der Verlaufsmuster, nicht der inferenzstatistischen Hypothesenprüfung. Eine externe Validierung (Expertenratings vs. SWR-Output) steht noch aus (vgl. Abschnitt Limitations).

⁶Die hier und im Folgenden berichteten Korrelationen (Spearman-Rangkorrelationen, berechnet über die 17 Jahreszeitpunkte) sind *Zusammenhänge innerhalb der LLM-Rekonstruktion*, nicht zwischen unabhängig gemessenen Variablen. Spearman wird verwendet, da die 12 Weltbild-Dimensionen Ordinalskalen darstellen; Pearson würde Intervallskalenniveau voraussetzen, das hier nicht gegeben ist. Die Korrelationen könnten interne Kohärenz des Modells widerspiegeln statt empirischer Zusammenhänge in der Realität (vgl. Abschnitt 6).

⁷Eine formale Breakpoint-Analyse (z. B. Bai-Perron-Test) war aufgrund der geringen Zahl von Zeitpunkten ($n = 17$) und der Natur der Daten (LLM-Rekonstruktionen, keine unabhängigen Messungen) nicht sinnvoll anwendbar. Die Wendepunkte sind daher als *deskriptive Beobachtungen* zu verstehen, nicht als statistisch gesicherte Strukturbrüche.




Abbildung 2: Zeitreihen der 12 Weltbild-Dimensionen (2010–2026). Ausgeprägte Trends sind hervorgehoben. Der markante Abfall von D10 (Posthumanismus) und D12 (Kontrollüberzeugung) bildet den „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird.




Abbildung 3: Spearman-Rangkorrelationsmatrix der 12 Dimensionen. Die starke positive Korrelation zwischen D10 und D12 sowie die negative Korrelation zwischen D10 und D09 bilden den empirischen Kern des „Utopie-Komplexes“.

Entwicklungen zu sehen sind: Die COVID-19-Pandemie (2020–2022) hat die Digitalisierungsdynamik beschleunigt und dürfte das Dringlichkeitserleben verstärkt haben; die zunehmende geopolitische Polarisierung (US-China-Technologiekonflikt) hat den „manichäischen“ Aspekt des Weltbilds möglicherweise befeuert; und der Beginn regulatorischer Initiativen (EU AI Act, 2021ff.) hat die Debatte um Governance verschärft. Diese Kontextfaktoren lassen sich mit der vorliegenden Methode nicht vom KI-spezifischen Wandel trennen.




Abbildung 4: Schlüsseltrends der Weltbild-Transformation. Die zwei Wendepunkte (2019, 2022/2023) und die drei Epochen (Prometheischer Optimismus, Erste Ambivalenz, Tragisches Bewusstsein) sind markiert.

4.2.3 Konvergenz oder Divergenz?

Die Daten zeigen eine zunehmende Ausdifferenzierung. Der ChatGPT-Effekt intensiviert sowohl die Architekten-Position (Beschleunigung, Machtkonzentration) als auch die Hüter-Position (Vorsicht, Regulierung) gleichzeitig – er wirkt als Katalysator der Bipolarisierung.

4.2.4 Metaphern- und Emotions-Wandel

Die Leitmetapher verschiebt sich von Prometheus – dem Feuerbringer – zum tragischen Helden, der retten muss, was möglicherweise nicht mehr zu retten ist. Die Handlung bleibt dieselbe (Beschleunigung), aber ihre emotionale Rahmung dreht sich um: nicht mehr aus Euphorie, sondern aus dem Glauben, dass die Alternative schlimmer wäre.

Kernbefund F2: Die rekonstruierten Profile deuten auf eine strukturelle Transformation des Weltbilds hin – von einer monochromen Utopie zu einer bimodalen Wette. *Tragisch* im Sinne der Bezeichnung „tragischer Beschleunigungszwang“ meint die gleichzeitige Erosion utopischer Gewissheiten und Persistenz der Handlungsrichtung: Die Akteure beschleunigen, obwohl

sie an der Zukunft zweifeln, die sie bauen – weil sie die Alternativen (geopolitischer Rückfall, Kontrollverlust an weniger verantwortungsvolle Akteure) als schlimmer bewerten. Drei Erosionstrends (D10, D12, D02) bilden einen „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird. Allerdings ist nicht auszuschließen, dass der Rückgang des Posthumanismus (D10) teilweise ein Artefakt veränderter öffentlicher Diskurse ist: Wenn das Thema medial weniger präsent ist, sinkt auch die Datendichte entsprechender Aussagen, was die LLM-Rekonstruktion verzerren kann.

4.3 F3 – Kongruenz von Aussagen und Handlungen

Tabelle 5: Vergleich Aussagen (A) und Handlungen (H), $N = 100$. Werte sind Einzel-Run-Ratings auf Gruppenebene (v2, mit strikter Instanztrennung). v1-Werte (Same-Instance-Ratings) zum Vergleich.

Dimension	Sagen v2	Handeln v2	$\Delta v2$	$\Delta v1$	Stabil?
D01 Sendungsbewusstsein	9	9	0	-1	-
D02 Selbstwirksamkeit	8	9	+1	+1	✓
D03 Arbeitsethos	9	9	0	+1	-
D04 Verantwortungsgefühl	8	8	0	-2	-
D05 Techno-Determinismus	7	9	+2	+1	↑
D06 Fortschrittsglaube	8	8	0	-1	-
D07 Machtkonzentration	6	8	+2	+2	✓✓
D08 Dringlichkeit	9	9	0	+1	-
D09 Menschenfreundlichkeit	6	5	-1	-2	↓
D10 Posthumanismus	7	7	0	+1	-
D11 Egalitarismus	5	3	-2	-3	✓✓
D12 Kontrollüberzeugung	7	8	+1	-1	-
Durchschnitt	7,4	7,7	+0,3	-0,4	
MAE			0,75	1,42	

Methodische Anmerkung: Die v1-Ratings (in früheren Versionen dieser Studie berichtet) wurden innerhalb derselben LLM-Instanz generiert, wodurch Kreuzkontamination zwischen Aussagen- und Handlungsprofilen möglich war. Die hier gezeigten v2-Ratings verwenden strikte Instanztrennung: Jeder Datentyp wurde von einem unabhängigen Agenten ohne Zugang zum anderen verarbeitet. Dies reduzierte die Gesamtkluft von $MAE = 1,42$ auf $MAE = 0,75$ (-47 %), und die v2-Kluft fällt unter die Kontrollbaseline (G6 v2: $MAE = 0,92$). Das bedeutet: Die *Gesamt*-Sagen-Handeln-Kluft ist in Einzeldurchläufen nicht zuverlässig vom Messrauschen unterscheidbar.

Allerdings zeigen zwei spezifische Dimensionen *stabile* Diskrepanzen über beide Messbedingungen: **D07 Machtkonzentration** ($\Delta = +2$ in v1 und v2) und **D11 Egalitarismus** ($\Delta = -2$ in v2, -3 in v1). Diese bilden die robusten Sagen-Handeln-Befunde der Studie. Handlungen konzentrieren Macht stärker als die Rhetorik nahelegt, und Handlungen sind weniger egalitär.

tär als die Rhetorik behauptet. Beides ist konsistent mit einer strukturellen *Erwünschtheits-Asymmetrie*: Der öffentliche Diskurs überschätzt egalitäre und demokratische Commitments relativ zum operativen Verhalten.




Abbildung 5: Sagen vs. Handeln: Vergleich der aus Aussagen (A) und Handlungen (H) rekonstruierten Weltbilder. Die gesellschaftsorientierten Dimensionen (D04, D06, D09, D11) fallen im Handeln systematisch ab, während die machtsbezogenen Dimensionen (D07, D05) im Handeln steigen.

Die größte stabile Einzeldiskrepanz (D11, $\Delta - 2$ in v2, -3 in v1) zeigt: In Aussagen spricht die KI-Elite von „Zugang für alle“; in ihren Handlungen baut sie Mehrfach-Stimmrechtsaktien, konzentriert Compute-Infrastruktur und schafft exklusive Netzwerke. D07 (Machtkonzentration, $\Delta + 2$) ist der komplementäre Befund: Die Rhetorik favorisiert verteilte Governance, aber operative Entscheidungen zentralisieren Kontrolle.

4.3.1 Gruppen-Dekomposition der Sagen-Handeln-Kluft

Der aggregierte Sagen-Handeln-Vergleich verdeckt substanzielle gruppenspezifische Variation – ein Simpson-Paradox. Wenn fünf soziologische Gruppen mit strikter Instanztrennung analysiert werden (Aussagen- und Handlungskorpus von unabhängigen Agenten verarbeitet), emergieren drei distinkte Muster:

- **CEOs** (MAE = 1,08, über Baseline): Der klassische Erwünschtheits-Gap. Rhetorik ist egalitärer (D11: Sagen 5, Handeln 3, $\Delta = -2$) und weniger machtkonzentrierend (D07: Sagen 7, Handeln 9, $\Delta = +2$) als operatives Verhalten. CEOs sagen das „Richtige“ über verteilte Governance und bauen gleichzeitig Dual-Class-Aktienstrukturen.
- **Risiko-Warner** (MAE = 1,92, stärkster Gap): Kein inverser Gap, sondern *prophetische Konsistenz*. Bei Dekomposition nach abhängiger Variable wird das Muster klar: DV1 (Selbstbild, D01–D04) zeigt nahezu perfekte Konsistenz (MAE = 0,8) – Risiko-Warner wissen, wer sie sind. Die Diskrepanz konzentriert sich in DV3 (Menschenbild, MAE

= 3,2): Ihre *Aussagen* beschreiben eine gefürchtete Zukunft – Mensch als ersetzbar (D09: Sagen 4), posthumanistische Transformation als unvermeidlich (D10: Sagen 9) – während ihre *Handlungen* ihre tatsächlichen Werte offenbaren: hohe Menschenfreundlichkeit (D09: Handeln 8), Ablehnung des Posthumanismus in der Praxis (D10: Handeln 4), aktive Handlungsfähigkeit (D12: Handeln 8). Dies ist die Struktur prophetischer Warnung: eine Möglichkeitsprojektion artikulieren, die man *verhindern* will, und dann konsequent dagegen handeln. Ihr Sagen-Handeln-Gap ist keine Heuchelei, sondern die Signatur antizipatorischer Ethik – ein Befund, der ohne Gruppendekomposition unsichtbar bliebe.

- **Investoren** (MAE = 0,75, unter Baseline): Die konsistenteste Gruppe. Rhetorik und Handeln erzählen dieselbe Geschichte: radikaler Techno-Optimismus mit minimaler egalitärer Orientierung. Kein Erwünschtheits-Gap – sie meinen, was sie sagen.
- **Beschleuniger** (MAE = 0,92, an Baseline): Ein Grenzmuster, das einer schwächeren Version des CEO-Gaps ähnelt. Rhetorik ist optimistischer hinsichtlich Fortschritt (D06: $\Delta = -2$), verantwortungsvoller (D04: $\Delta = -2$) und egalitärer (D11: $\Delta = -2$) als operatives Verhalten.

Diese entgegengesetzten gruppenspezifischen Gaps heben sich im Aggregat auf (Gesamt-MAE = 0,75, unter der G6-v2-Kontrollbaseline von 0,92). Die Sagen-Handeln-Kluft ist nicht absent – sie ist *gruppenspezifisch und richtungsabhängig* und erfordert Dekomposition statt aggregierter Berichterstattung.

Kernbefund F3: Zwei robuste Sagen-Handeln-Diskrepanzen überstehen die Instanztrennung: D07 (Machtkonzentration) und D11 (Egalitarismus). Die Gesamtmagnitude der Kluft ist messbedingt variabel und sollte in Einzeldurchläufen nicht überinterpretiert werden. Aber die *Richtung* der Asymmetrie ist stabil: Der öffentliche Diskurs ist egalitärer und machtheilender als das operative Verhalten. Eine formale Quantifizierung (mit Konfidenzintervallen aus $N \geq 30$ wiederholten Messungen) bleibt ein Desiderat.

4.4 F4 – Weltbild-Cluster

Aus den Daten lassen sich vier distinkte Weltbild-Typen identifizieren (Tabelle 6).

Identifikationsmethode: Die Cluster-Identifikation erfolgte in einem zweistufigen Verfahren. *Stufe 1 (LLM-gestützt):* Alle 15 Gruppen-Synthesen wurden nach Ähnlichkeitsmustern in den 12 Dimensionen gruppiert, wobei die größten Varianzachsen (D07 Machtkonzentration, D09 Menschenfreundlichkeit, D11 Egalitarismus) als Trennmerkmale fungierten. *Stufe 2 (Autor-Validierung):* Die vom LLM vorgeschlagene Vier-Cluster-Lösung wurde vom Autor anhand inhaltlicher Kohärenz und Plausibilität evaluiert. Alternative Lösungen (drei und fünf Cluster) wurden geprüft und verworfen: Drei Cluster verschmelzen Innovator und Befreier,

was inhaltlich nicht gerechtfertigt ist; fünf Cluster spalten den Hüter-Typ in eine Untergruppe, die empirisch nicht stabil reproduziert werden konnte. Wir betonen, dass diese Cluster-Identifikation *explorativ* ist – eine konfirmatorische Validierung an einem unabhängigen Datensatz steht aus. Die Cluster-Lösung ist eine *interpretative Hypothese*, nicht ein statistisch abgesichertes Ergebnis im Sinne formaler Clusteranalyse.

Tabelle 6: Die vier Weltbild-Typen der KI-Elite. Die Werte sind Cluster-Durchschnitte aus den Gruppen-Synthesen; individuelle Abweichungen innerhalb eines Clusters können erheblich sein (vgl. die Andreessen-Diskrepanz in der nachfolgenden Fußnote).

Merkmal	I „Architekt“	II „Hüter“	III „Innovator“	IV „Befreier“
<i>n</i>	35	25	22	18
Prototyp	CEOs, Investoren	Akademiker, Risiko-W.	Gründer	Open Source
Avg D01–D12	7,8	6,4	7,2	6,8
D04 Verantwortung	6,3	9,0	8,3	6,0
D07 Machtkonzentr.	8,8	4,8	6,5	2,5
D09 Menschenfreundl.	3,3	5,8	4,8	6,5
D11 Egalitarismus	2,8	7,2	5,0	7,5

Der **Architekt** vereint maximales Sendungsbewusstsein mit minimalem Egalitarismus: Machtkonzentration ist Voraussetzung für Handlungsfähigkeit. Der **Hüter** bildet den Gegenpol: maximale Verantwortung, Forderung nach institutioneller Begrenzung. Der **Innovator** steht dazwischen. Der **Befreier** ist die überraschendste Entdeckung: minimale Machtkonzentration *und* hoher Egalitarismus – Regulierungsgegner, die Macht radikaler verteilen wollen als alle anderen, allerdings durch Märkte und Open-Source-Communities.⁸

Kernbefund F4: Die stärkste Polarisierung besteht zwischen Typ I (Herrschaftslogik) und Typ II (Teilhabelogik). Die explorative Vier-Cluster-Lösung bedarf einer konfirmatorischen Validierung an unabhängigen Daten, bevor sie als robustes Ergebnis gelten kann.

4.4.1 Algorithmische Validierung der Clusterstruktur

Um zu prüfen, ob die vier Weltbild-Typen natürlichen Daten-Clustern entsprechen, wurde HDBSCAN (dichtebasiertes Clustering) und KMeans auf die 100×12 -Ratingmatrix angewendet. **HDBSCAN auf dem vollen 12-dimensionalen Raum** klassifiziert 80–100 % der Fälle als Rauschen über alle getesteten Parameterkonfigurationen ($\text{min_cluster_size} \in \{5, 8, 10, 15\}$, $\text{min_samples} \in \{3, 5\}$); die beste Lösung findet nur 2 Cluster mit einem negativen Silhouette-Score ($-0,15$). KMeans mit $k = 4$ liefert einen Silhouette-Score von lediglich 0,169 – deutlich

⁸Der hohe D11-Wert des Befreier-Typs (7,5) und der niedrige D11-Wert einzelner Prototypen (z. B. Andreessen: D11=2) markieren eine Konstruktvaliditätsproblem: D11 misst Gleichheitsorientierung, nicht deren *Mechanismus*. Marktlibertärer Zugangs-Egalitarismus (Befreier) und redistributiver Egalitarismus (Hüter) produzieren ähnliche Skalenwerte auf D11, meinen aber Verschiedenes. Der Prototyp-Wert bezieht sich auf die Einzelperson-Synthese, der Cluster-Wert auf das Gruppenaggregat – Andreessens individuelles Profil weicht vom Cluster-Durchschnitt ab. Künftige Operationalisierungen sollten hier differenzieren.




Abbildung 6: Radar-Diagramm der vier Weltbild-Typen auf den 12 Dimensionen. Die Polarisierung zwischen Architekt (außen) und Hüter (innen) sowie die distinkte Position des Befreiers (hoher Egalitarismus bei niedriger Machtkonzentration) sind sichtbar.

unter dem Schwellenwert von 0,25, der typischerweise als Hinweis auf bedeutsame Struktur gilt.

Subspace-Clustering zeigt jedoch ein differenziertes Bild. Auf den beiden stärksten diskriminierenden Dimensionen (D07 Machtkonzentration und D11 Egalitarismus) identifiziert HDBSCAN mit `min_cluster_size = 5`, `min_samples = 2` neun Cluster mit einem *Silhouette-Score* von **0,57** (12 % Rauschen) – ein Hinweis auf substanzielle lokale Struktur in genau jenen Dimensionen, die die vier Idealtypen trennen. Analoges Subspace-Clustering auf den drei höchstladenden PCA-Dimensionen (D02, D05, D09) ergibt einen *Silhouette-Score* von 0,55. Zu beachten ist allerdings eine Zirkularitätsproblematik: D07 und D11 sind genau jene Dimensionen, die die Architekt-Befreier-Achse in der heuristischen Typologie definieren. Das Subspace-Clustering rediskoviert dadurch teilweise das Auswahlkriterium, anstatt eine unabhängige Validierung zu liefern. Damit wird zwar die dimensionale Separabilität bestätigt, nicht aber die Unabhängigkeit der Validierung von der Typologie-Konstruktion.

Dieses Muster bestätigt den epistemologischen Status der vier Typen: Es handelt sich um **Webersche Idealtypen** – heuristische Verdichtungen eines mehrdimensionalen Kontinuums, nicht um emergente Daten-Cluster. Ihr analytischer Nutzen wird durch diesen Befund nicht geschmälert; im Gegenteil, er wird durch hochsignifikante Kruskal-Wallis-Ergebnisse über die vier Typen bestätigt (Tabelle 7).

Tabelle 7: Kruskal-Wallis-*H*-Test über die vier Weltbild-Typen ($df = 3$, $N = 100$). Signifikanz: *** $p < 0,001$, * $p < 0,05$, n.s. = nicht signifikant. ^aNicht signifikant nach Bonferroni-Korrektur ($\alpha_{adj} = 0,004$). Hinweis: Diese Tests beschreiben Muster innerhalb LLM-generierter Rekonstruktionen; p -Werte sind nominal und sollten nicht als inferenzstatistische Hypothesentests im klassischen Sinne interpretiert werden.

Dimension	<i>H</i>	<i>p</i>	Sig.
D02 Selbstwirksamkeit	33,55	< 0,001	***
D06 Fortschrittsglaube	29,55	< 0,001	***
D07 Machtkonzentration	64,76	< 0,001	***
D09 Menschenfreundlichkeit	17,50	< 0,001	***
D11 Egalitarismus	49,57	< 0,001	***
D12 Kontrollüberzeugung	17,93	< 0,001	***
D04 Verantwortungsgefühl	10,76	0,013	* ^a
D05 Techno-Determinismus	11,21	0,011	* ^a
D01 Sendungsbewusstsein	2,59	0,459	n.s.
D03 Arbeitsethos	3,75	0,290	n.s.
D08 Dringlichkeit	6,25	0,100	n.s.
D10 Posthumanismus	4,04	0,257	n.s.

Nach Bonferroni-Korrektur für 12 simultane Tests ($\alpha_{adj} = 0,05/12 = 0,004$) erreichen D04 ($p = 0,013$) und D05 ($p = 0,011$) nicht mehr Signifikanz. Die sechs Dimensionen mit $p < 0,001$ bleiben nach Korrektur signifikant. Sechs von zwölf Dimensionen zeigen somit hochsignifikante Inter-Typ-Unterschiede ($p < 0,001$), während zwei weitere Dimensionen (D04, D05) nominale Signifikanz auf dem $p < 0,05$ -Niveau erreichen, aber die Bonferroni-Korrektur nicht

überstehen. Die vier nicht-signifikanten Dimensionen (D01, D03, D08, D10) repräsentieren den *geteilten Kern* des KI-Elite-Weltbilds – Überzeugungen, bei denen alle vier Typen konvergieren. D07 (Machtkonzentration, $H = 64,76$) und D11 (Egalitarismus, $H = 49,57$) sind die diskriminierendsten Dimensionen. Ein Zirkularitätsvorbehalt gilt: Da die vier Typen teilweise *durch* D07 und D11 definiert wurden, spiegeln die hohen H -Werte auf diesen Dimensionen teilweise das Konstruktionskriterium wider, nicht eine unabhängige Validierung. Die Kruskal-Wallis-Ergebnisse für die übrigen Dimensionen (D02, D06, D09, D12) sind informativer, da sie nicht in die Typenkonstruktion eingingen.

4.5 F5 – Subgruppenvergleiche

Die Inter-Gruppen-Vergleiche bilden den analytischen Kern der Studie. Durch den systematischen Vergleich der kollektiven Weltbilder soziologisch definierter Gruppen – differenziert nach institutioneller Rolle, ideologischer Haltung, Geschlecht, Firmenzugehörigkeit und Regulierungsposition – deckt die Analyse auf, welche strukturellen Faktoren die kollektiven Überzeugungen innerhalb der KI-Elite am stärksten prägen. Tabelle 8 ordnet die sechs diskriminierendsten Vergleiche.

Tabelle 8: Ranking der Subgruppen-Differenzen. $\Delta = \text{Gr. 1} - \text{Gr. 2}$ (Durchschnitt); Einzelkontraste beziehen sich auf die Dimension mit der größten Abweichung.

Rang	Vergleich	Avg Gr. 1	Avg Gr. 2	Δ	Stärkster Kontrast
1	Risiko vs. Speed	5,9	7,6	1,7	D02, D06, D10, D12: je -5
2	CEOs vs. Akademiker	7,8	6,3	1,5	D07: $+4$, D11: -4
3	Frauen vs. Männer	6,9	8,1	1,2	D11: -6
4	Open vs. Closed	6,8	6,3	0,5	D07: -3 , D12: $+3$
5	Reg-Pro vs. Contra	6,3	6,8	0,5	D04: $+4$, D06: -3
6	Anthropic vs. OpenAI	6,9	7,3	0,4	D12: -3

Der **stärkste Kontrast** (Risiko vs. Speed, $\Delta 1,7$) betrifft nicht die Risikoeinschätzung – beide Seiten veranschlagen die Katastrophenwahrscheinlichkeit auf 10–20 % –, sondern die ontologische Vorfestlegung: Risiko-Warner konzipieren KI als potenziellen autonomen Agenten, Beschleuniger als Werkzeug.

Effektstärken (Cliff's δ) quantifizieren diese Kontraste nicht-parametrisch (Schwellenwerte nach Romano et al. 2006: $|\delta| < 0,147$ vernachlässigbar, $0,147-0,33$ klein, $0,33-0,474$ mittel, $> 0,474$ groß). Die extremsten paarweisen Unterschiede zwischen den vier Weltbild-Typen treten auf der Macht-Egalitarismus-Achse auf: Architekt vs. Befreier ergibt $\delta = +1,0$ auf D07 (Machtkonzentration) und $\delta = -0,98$ auf D11 (Egalitarismus) – effektiv perfekte Separation. Architekt vs. Hüter erreicht $\delta = +1,0$ auf D07 und $\delta = -0,68$ auf D11. Über alle sechs Cluster-Paare hinweg produzieren D07 und D11 jeweils fünf mittlere bis große Effekte ($|\delta| \geq 0,33$), was sie als primäre Diskriminierungsdimensionen bestätigt.




Abbildung 7: Gruppen-Heatmap: 15 Subgruppen $\times$ 12 Dimensionen. Die systematische Variation von D07 (Machtkonzentration) und D11 (Egalitarismus) über alle Vergleiche hinweg ist der zentrale visuelle Befund.

Rollenbasierte Vergleiche zeigen ähnlich starke Effekte: Akademiker vs. Investoren unterscheiden sich auf 9 von 12 Dimensionen mit *großem* Effekt (am deutlichsten D02 Selbstwirksamkeit: $\delta = -0,88$; D12 Kontrollüberzeugung: $\delta = -0,71$; D09 Menschenfreundlichkeit: $\delta = +0,68$). CEOs vs. Akademiker zeigen große Effekte auf 6 Dimensionen (D02: $\delta = +0,79$; D06: $\delta = +0,58$; D12: $\delta = +0,55$).

Gender-Unterschiede erreichen Signifikanz auf 7 von 12 Dimensionen. Die größten Effekte betreffen D09 Menschenfreundlichkeit ($\delta = +0,59$, groß: Frauen höher), D05 Techno-Determinismus ($\delta = -0,50$, groß: Männer höher) und D11 Egalitarismus ($\delta = +0,46$, mittel). Diese Effektstärken sind moderater als die nominalen Gruppenkontraste ($\Delta = 6$) vermuten ließen, was zu erwarten ist: Cliff's δ erfasst die volle Verteilungsüberlappung, nicht nur Mittelwerte. Der oben genannte Kontaminationsvorbehalt gilt in vollem Umfang.

Der **größte nominale Einzelkontrast** der gesamten Erhebung findet sich bei D11 im Gender-Vergleich: sechs volle Skalenpunkte (Frauen: 8, Männer: 2). Das Frauen-Weltbild ist kein Anti-Technik-Weltbild, sondern ein *konditioniertes* Technik-Weltbild: gleich optimistisch, aber mit stärkeren ethischen Bedingungen. Dieser Befund ist jedoch der *am stärksten kontaminationsgefährdete* der gesamten Studie und wird daher als *vorläufige Hypothese* eingestuft, nicht als gesicherter Befund. Die Gründe: (a) LLMs reproduzieren bekannte Gender-Stereotypen, insbesondere die Zuschreibung erhöhter sozialer Orientierung an Frauen (Santurkar et al., 2023); (b) die Frauenstichprobe ist klein ($n = 18$); (c) die Effektgröße ($\Delta = 6$) übersteigt das in vergleichbaren empirischen Studien beobachtete Ausmaß deutlich. Eine unabhängige Validierung – idealerweise durch Replikation anderer Forschungsteams mit verschiedenen Modellen und Expertenratings – ist für diesen Befund besonders dringlich.

Die **größte Überraschung** liegt im Regulierungsvergleich: Anti-Regulierer haben den nied-

rigsten Machtkonzentrations-Wert aller 15 Gruppen (D07=2). Dies widerlegt das verbreitete Narrativ, Anti-Regulierer seien Vertreter von Konzerninteressen.

Kernbefund F5: Die drei stärksten Prädiktoren für das Weltbild sind die ideologische Grundhaltung, die institutionelle Rolle und das Geschlecht. Die polarisierendsten Dimensionen sind D11 und D07. Die *Machtfrage* ist der Kern der internen Differenzen.

4.6 F6 – Macht und Weltbild

Macht wird in dieser Studie operativ als Ressourcenkontrolle verstanden: die Fähigkeit, über Kapital, Compute-Infrastruktur, Forschungsteams und politischen Zugang zu verfügen und dadurch die Richtung der KI-Entwicklung zu beeinflussen. Diese Definition folgt dem soziologischen Machtbegriff im Sinne Webers („Chance, den eigenen Willen auch gegen Widerstreben durchzusetzen“) und Bourdieus (Kapitalakkumulation als Machtmechanismus), ohne eine umfassende machttheoretische Analyse zu beanspruchen.

Tabelle 9: Weltbild-Typen und Ressourcen-Kontrolle.

Typ	Avg	D11	D04	Ressourcen
I Architekt	7,8	2,8	6,3	Höchste
III Innovator	7,2	5,0	8,3	Hoch
IV Befreier	6,8	7,5	6,0	Mittel
II Hüter	6,4	7,2	9,0	Geringste

Die Daten aus F4 (Cluster-Analyse) weiterverfolgend, zeigt sich ein zusätzliches Muster auf der Machtebene: Je höher die Weltbild-Intensität, desto niedriger die Werte bei Menschenfreundlichkeit und Egalitarismus und desto höher die Machtkonzentrations-Akzeptanz. Das Investoren-Profil markiert den Extremfall: maximale Kontrollüberzeugung (D02=10) bei minimalem Verantwortungsgefühl (D04=4) – „Macht ohne Rechenschaft“. Das bereits in F1 beobachtete Muster (vgl. Abschnitt 4.1) verschärft sich: Macht intensiviert alle Überzeugungen – ausgenommen jene, die Macht selbst in Frage stellen.

Kernbefund F6: Die rekonstruierten Profile zeigen ein auffälliges Muster: Gruppen mit höherer Ressourcenkontrolle weisen intensivere Weltbild-Werte auf, bei gleichzeitig niedrigeren Werten bei Egalitarismus und Verantwortung. Da beide Seiten dieser Beobachtung auf LLM-Rekonstruktionen basieren, ist unklar, ob die Korrelation empirische Realität oder interne Modellkohärenz widerspiegelt. Falls robust, wäre dies der demokratietheoretisch relevanteste Befund der Studie.

Tabelle 10: Synopse der sechs Kernbefunde: Ergebnis, Konfidenz, Validierungsstatus und epistemischer Status. Konfidenz-Einstufung: *Hoch* = stabil über ≥ 3 Gruppen-Synthesen und durch Inter-Gruppen-Konsistenz oder interne Kohärenzprüfung gestützt; *Mittel-hoch* = stabil, aber ohne externe Validierung; *Mittel* = explorativ, abhängig von Cluster-Lösung oder kleiner Subgruppe. Epistemischer Status: (D) = deskriptiv, (E) = explorativ, (H) = hypothesengenerierend.

F	Kernbefund	Konfidenz	Extern val.?	Status
F1	Technologischer Messianismus mit Ambivalenzstruktur (Avg 7,1; Doppelsenke D09/D11)	Hoch	Inter-Gruppen	(D)
F2	Utopie-Komplex erodiert; tragischer Beschleunigungszwang (D10: -2,4/Dek.)	Mittel-hoch	Nein	(D)
F3	Richtungsabhängige Sagen-Handeln-Kluft (D07 +2, D11 -2; stabil über v1/v2)	Mittel	Nein	(H)
F4	Vier Weltbild-Typen: Architekt, Hüter, Innovator, Befreier	Mittel	Nein	(E)
F5	Stärkste Prädiktoren: Haltung, Rolle, Gender (vorläufig)	Mittel	Nein	(E)
F6	Macht-Gemäßigtheits-Paradox: Macht $\sim$ Extremität	Hoch	Nein	(H)

5. Diskussion

5.1 Zusammenfassung und Interpretation

Die Ergebnisse *legen nahe*, dass die KI-Elite, auf Gruppenebene analysiert, ein Muster aufweist, das sich idealtypisch als *technologischer Messianismus mit struktureller Ambivalenz* beschreiben lässt. Die Metapher des „Messianismus“ ist dabei analytisch gemeint – als Bezeichnung für die Kombination aus hohem Sendungsbewusstsein, Techno-Determinismus und Dringlichkeit –, nicht als Werturteil oder psychologisierende Zuschreibung. Der Begriff grenzt sich von verwandten Konzepten ab: [Morozovs](#) „Solutionismus“ erfasst die Problemlösungshaltung, nicht die quasi-religiöse Dringlichkeit; „Techno-Utopismus“ impliziert positiven Zukunftsglauben, der laut F2 gerade erodiert; „technologischer Messianismus“ bezeichnet spezifisch die Persistenz eines erlöserischen Handlungsimperativs *trotz* schwindendem Zukunftsoptimismus. Die sechs Forschungsfragen fügen sich zu einem in sich stimmigen Bild: F1 weist auf die „Doppelsenke“ bei D09 und D11 als kollektives Merkmal hin; F2 deutet auf eine Erosion des Utopie-Komplexes über die Epochen hin; F3 zeigt richtungsabhängige Sagen-Handeln-Diskrepanzen auf spezifischen Dimensionen (D07, D11), wobei die Gesamtmagnitude der Kluft vorsichtiger Interpretation bedarf; F4 differenziert vier Weltbild-Typen mit antagonistischen kollektiven Positionen; F5 und F6 vervollständigen das Bild durch das Macht-Gemäßigtheits-Paradox. Die Inter-Gruppen-Vergleiche (F5) bilden das analytische Herz der Studie: Der Befund, dass institutionelle Rolle, ideologische Haltung und Geschlecht die kollektiven Überzeugungsstrukturen systematisch formen, trägt direkte Implikationen für KI-Governance und demokratische Theorie. Alle Befunde basieren auf LLM-generierten Rekonstruktionen auf Gruppenebene und sind daher als *empirisch gestützte Hypothesen* zu verstehen, nicht als bewiesene Tatsachen. Formulierungen wie „zeigt“ und „offenbart“ sind durchgängig im Sinne von „die Daten legen nahe“ zu lesen.

Überraschend ist erstens die Richtungskonsistenz der Sagen-Handeln-Diskrepanzen über Messbedingungen hinweg (D07/D11 stabil in v1 und v2); zweitens der Rückzug des Posthumanismus (D10 von 10 auf 6 – widerlegt die gängige Annahme zunehmend posthumanistischer Orientierung); drittens die Existenz des Befreier-Typs (Opposition gegen Machtkonzentration auch von libertärer Seite); viertens die Konsistenz der Muster auf Gruppenebene über mehrere unabhängige Synthesen hinweg.

5.2 Einordnung in den Forschungsstand

[Morozovs](#) Solutionismus-These findet eine nahezu vollständige Bestätigung (D05=8–9, D06=7–9). Allerdings ist der Solutionismus kein monolithischer Block: Risiko-Warner (D05=4) teilen ihn deutlich weniger. Er ist die Ideologie des mächtigsten Segments, nicht der KI-Elite schlechthin.

[Daubs](#) Analyse der philosophischen Tiefenstrukturen wird durch die narrativen Synthesen bestätigt. Was die vorliegende Studie hinzufügt, ist die *Quantifizierung* und die Demonstration, dass sich die Intensität systematisch mit der Machtposition verstärkt.

Die von [Barbrook & Cameron \(1996\)](#) diagnostizierte Californian Ideology findet in der Existenz des Befreier-Typs ihre zeitgenössische Entsprechung – empirisch nachweisbar dreißig Jahre später.

[Coeckelberghs](#) Annahme einer zunehmenden Enhancement-Orientierung wird durch die rekonstruierten Trends partiell *in Frage gestellt*: Der deutliche Rückgang des Posthumanismus (D10 von 10 auf 6) legt nahe, dass das Interesse der KI-Elite an der technologischen Transformation des Menschen selbst abgenommen hat – zugunsten einer Fokussierung auf autonome KI-Systeme als eigenständige Akteure. Dabei sind drei alternative Erklärungen in Betracht zu ziehen: (a) der Rückgang könnte ein *Diskursartefakt* sein – posthumanistische Themen sind nach 2020 medial weniger präsent, was die Datendichte entsprechender Aussagen reduziert; (b) die Position könnte nicht verschwunden, sondern in neue Begriffe transformiert worden sein („AGI“ statt „Enhancement“); (c) der Trend könnte eine strategische *Selbstzensur* reflektieren, da posthumanistische Rhetorik politisch toxischer geworden ist.

Zum Gender-Befund. Der in F5 berichtete extreme Kontrast bei D11 (Frauen: 8, Männer: 2, $\Delta = 6$) ist der größte Einzelkontrast der gesamten Erhebung, aber zugleich der am stärksten kontaminationsgefährdete. LLMs reproduzieren bekannte Gender-Stereotypen – insbesondere die Zuschreibung erhöhter Empathie und sozialer Orientierung an Frauen ([Santurkar et al., 2023](#)). Da die Frauenstichprobe klein ist ($n = 18$) und die Ratings vom selben LLM generiert wurden, das diese Stereotypen internalisiert hat, ist nicht unterscheidbar, ob der Kontrast (a) eine reale Differenz in den Weltbildern, (b) ein LLM-Stereotyp-Artefakt oder (c) eine Mischung aus beidem reflektiert. Der Befund wird daher als *Hypothese* berichtet, die einer unabhängigen Validierung – idealerweise durch Replikation anderer Forschungsteams mit verschiedenen Instrumenten und Expertenratings – bedarf.

Die von [Gebru & Torres \(2024\)](#) vorgeschlagene TESCREAL-Taxonomie (Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, Longtermism) findet in der Vier-Cluster-Lösung eine empirische Ausdifferenzierung: Der Architekt-Typ verkörpert die machtpolitische Seite des TESCREAL-Bündels (Singularitarianism, Longtermism), der Hüter-Typ dessen institutionelle Kritik (Effective Altruism mit Sicherheitsfokus), der Befreier-Typ den libertären Extropianismus. Was die TESCREAL-Analyse als monolithisches Ideologiebündel beschreibt, zeigt sich in den Daten als Spektrum mit mindestens vier distinkten Positionen. [Becker \(2025\)](#) ergänzt diese Perspektive durch die Analyse der „Broligarchie“ als soziales Phänomen: Die Verschmelzung von technologischer Vision und männlicher Machtelite, die in der Gender-Analyse (F5, D11-Kontrast von 6 Skalenpunkten) ihren empirischen Niederschlag findet.

Paul Ricoeurs „Hermeneutik des Verdachts“ ([Ricoeur, 1970](#)) bietet einen ergänzenden analytischen Rahmen: Hinter der scheinbar neutralen, technisch-rationalen Sprachoberfläche der KI-Eliten-Kommunikation verbergen sich Machtinteressen und Klassendynamiken, die erst durch systematische Dekonstruktion sichtbar werden. Die SWR-Kongruenzanalyse (F3) operationalisiert diesen Verdacht empirisch: Die Δ -Werte zwischen Sagen und Handeln zeigen präzise, *wo* die performative Oberfläche von der operativen Realität abweicht.

Aus wissenschaftssoziologischer Perspektive lässt sich der Rückgang des Egalitarismus (D11) als Erosion der Merton'schen Wissenschaftsnormen lesen ([Merton, 1973](#)): Communalism (offener Zugang), Universalism und Organized Skepticism weichen zunehmend proprietären, beschleunigungszentrierten Logiken. Der Übergang von Forschungspublikation zu Produkt-Launch als primärem Output-Format ist ein sichtbarer Marker dieser Verschiebung.

Die Vier-Cluster-Lösung lässt sich darüber hinaus feldtheoretisch lesen: Die antagonistische Struktur zwischen Architekt (ökonomisches Kapital) und Hüter (symbolisches Kapital) reproduziert das von [Bourdieu \(1992\)](#) für das intellektuelle und künstlerische Feld diagnostizierte Muster einer *umgekehrten ökonomischen Welt*. Im KI-Feld gilt: Wer die meisten Ressourcen kontrolliert, hat die geringste Legitimation durch Gemeinwohlorientierung – und umgekehrt. Das Macht-Gemäßigkeits-Paradox (F6) lässt sich in dieser Perspektive als strukturelle Eigenschaft des Feldes lesen – wobei die explorative Natur der Cluster-Daten keine konfirmatorische Aussage erlaubt.

Der spezifische Mehrwert gegenüber essayistischen Diagnosen liegt in drei Punkten: *Masse* (100 Personen, 16 Jahre), *Differenzierung* (vier distinkte Typen) und *Validierung* (Kongruenzanalyse als empirischer Test).

5.3 Agentic Alignment vs. Worldview Alignment

Die in F3 angezeigten richtungsabhängigen Sagen-Handeln-Diskrepanzen (am robustesten: D07 Machtkonzentration $\Delta = +2$, D11 Egalitarismus $\Delta = -2$, stabil über Messbedingungen) lassen sich mit einer in dieser Studie eingeführten begrifflichen Unterscheidung schärfer

fassen, die auf Terminologie der KI-Alignment-Debatte zurückgreift.⁹ *Worldview Alignment* bezeichnet die rhetorische Reproduktion erwünschter Werte – das öffentliche Bekenntnis zu Gleichheit, Verantwortung und Menschlichkeit, wie es die „Sagen“-Seite der Analyse erfasst. *Agentic Alignment* bezeichnet die tatsächliche Ressourcenverteilung und Machtausübung – die „Handeln“-Seite. Die Befunde zeigen, dass die KI-Elite ein hohes Maß an Worldview Alignment aufweist (die „richtigen“ Werte werden artikuliert), während das Agentic Alignment systematisch davon abweicht. Dieser Dualismus verbindet die vorliegende KI-Elite-Studie mit der breiteren Alignment-Debatte und wirft die Frage auf, ob die gegenwärtigen Bemühungen um „AI Alignment“ nicht die performative Ebene (Worldview) mit der operativen (Agentic) verwechseln.

5.4 Methodische Reflexion

Die primäre Leistung der SWR liegt in der Verbindung qualitativer Tiefe mit quantitativer Systematik auf Gruppenebene. Die Studie identifiziert ein zuverlässiges Instrument – Claude Opus 4.6, validiert durch Intra-Modell-Inter-Instanzen-Rating-Reliabilität (IMIIRR, ICC = 0,902) – und demonstriert dessen konsistente Anwendung über alle Syntheseinheiten. Dieser IMIIRR-Koeffizient übertrifft die typische Inter-Rater-Reliabilität menschlicher Kodierer in qualitativer Forschung (ICC = 0,6–0,8; Hallgren 2012), und das Instrument bietet einen distinktiven Vorteil gegenüber menschlichen Kodierern: Vollständig dokumentierte Prompts ersetzen implizite Kodierregeln und ermöglichen exakte Replikation. Die Kongruenzanalyse (F3) fungiert als interner Validitätstest; die Stabilität des Kollektiv-Profiles über 15 Gruppen-Synthesen und 4 Typen stärkt die Konvergenzvalidität. Die Inter-Gruppen-Vergleiche liefern eine eigene Form der Validierung: Wenn verschiedene Gruppensynthesen – unabhängig voneinander aus unterschiedlichen Daten-Subsets produziert – konsistente strukturelle Muster ergeben (z. B. die D07/D11-Achse als diskriminierendes Merkmal über alle Vergleiche hinweg), ist dies ein Beleg für die Robustheit der Methode, der über das hinausgeht, was eine einzelne Synthese leisten könnte. Die Replikation mit anderen Frontier-Modellen stellt eine unabhängige Forschungsaufgabe dar – analog zur Replikation einer Befragung mit verschiedenen Interviewer-Teams – und wird explizit als Desiderat für zukünftige Arbeiten identifiziert, nicht als Voraussetzung für die Validität der vorliegenden Studie. Die systematische Diskussion der methodischen Grenzen – Kohärenzbias, Kontaminationsrisiko, Fokuskontrolllimits, Prompt-Sensitivität – findet sich in Abschnitt 6.

⁹Weder *Worldview Alignment* noch *Agentic Alignment* entsprechen in der hier verwendeten Bedeutung einem fest etablierten Begriff der KI-Alignment-Literatur; das Begriffspaar wird als analytische Heuristik für diese Studie eingeführt, um die performative von der operativen Ebene des Wertausdrucks zu unterscheiden.

5.5 Gesellschaftliche und politische Implikationen

Die Befunde auf Gruppenebene tragen direkte Implikationen für KI-Governance und demokratische Theorie. Das Macht-Gemäßigtheits-Paradox – der systematische Befund, dass institutionelle Gruppen mit den meisten Ressourcen kollektive Weltbilder aufweisen, die am weitesten von demokratischen Idealen entfernt sind – stellt eine konkrete Herausforderung für die Regulierungsarchitektur dar. Dieser Befund resoniert mit Mills' (1956) klassischer Analyse der „Power Elite“ als sich selbst verstärkendes Stratum, dessen Weltbild systematisch von der breiteren Öffentlichkeit divergiert, und bestätigt die institutionenökonomische Analyse von Acemoglu & Johnson (2023): Technologische Eliten tendieren dazu, Innovationen so zu lenken, dass sie bestehende Machtstrukturen verstärken, statt sie aufzubrechen – ein Muster, das die Autoren historisch von der Industrialisierung bis zur Digitalisierung nachzeichnen. Gegenwärtige Governance-Ansätze (EU AI Act, Executive Order on AI) adressieren die technischen Artefakte, nicht die kollektiven Weltbilder der Gruppen, die diese Artefakte produzieren. Ein ergänzender Ansatz müsste die *epistemische Diversität* in KI-Führungspositionen als Regulierungsziel anerkennen.

Die systematische Sagen-Handeln-Kluft auf Gruppenebene hat eine Policy-Implikation: Freiwillige Selbstverpflichtungen – die derzeit bevorzugte Governance-Form (vgl. Bengio et al., 2024) – erscheinen unzureichend, wenn ganze institutionelle Gruppen (nicht nur vereinzelte Individuen) konsistente Diskrepanzen zwischen öffentlicher Rhetorik und beobachtbarem Handeln aufweisen. Die Befundlage legt nahe, dass verbindliche Strukturreformen wirksamer sein dürften als weitere Runden freiwilliger Commitments. Drei konkrete Ansatzpunkte zeichnen sich ab: (1) *Epistemische Diversitätsquoten* in KI-Governance-Gremien, die sicherstellen, dass nicht nur Technologen und Investoren, sondern auch Sozialwissenschaftler, Ethikerinnen und Betroffenenvertreter an Designentscheidungen beteiligt sind; (2) *verpflichtende Weltbild-Audits* für KI-Unternehmen ab einer bestimmten Größe, analog zu Nachhaltigkeitsberichten; (3) *stärkere Entkopplung* von Kapitalgebern und Forschungssteuerung, beispielsweise durch öffentlich finanzierte KI-Labore mit unabhängiger Governance (vgl. Acemoglu & Johnson, 2023).

Die Inter-Gruppen-Vergleiche offenbaren ein weiteres governance-relevantes Muster: Die Frage der Macht (D07) und der Gleichheit (D11) ist die Achse, entlang derer sich sämtliche Gruppenunterschiede organisieren. Ob CEOs mit Akademikern, Beschleuniger mit Risiko-Warnern oder Männer mit Frauen verglichen werden – die Macht-Gleichheits-Achse ist durchgängig die diskriminierendste Dimension. Dies legt nahe, dass die zentrale ideologische Bruchlinie innerhalb der KI-Elite nicht die Technik betrifft (alle Gruppen sind technologisch optimistisch), sondern die *Verteilung* technologischer Macht.

Ist sich die KI-Elite ihrer eigenen blinden Flecken bewusst? Das Verantwortungsgefühl (D04=7) ist nicht absent, aber funktional eingebettet: Es legitimiert das Weiterarbeiten, nicht das Innehalten. Der Befund, dass demokratische Langsamkeit durchgängig als Hindernis, nicht als Schutzfunktion begriffen wird, markiert den gravierendsten blinden Fleck einer Gruppe, die

darüber entscheidet, wie Milliarden Menschen in Zukunft leben werden.

5.6 Was die Studie nicht zeigt

Zur Vermeidung häufiger Fehlinterpretationen sei explizit festgehalten, was die vorliegende Studie *nicht* leistet: (1) keine *Kausalerklärung* (vgl. Abschnitt 6); (2) keine *individuellen Profile* – die 100 Akteure dienen als Datenlieferanten; die Analyseeinheiten sind soziologisch definierte Gruppen; die Ratings sind kollektive Abstraktionen auf Gruppenebene, keine Persönlichkeitsprofile oder individuelle Biographien; (3) keine *Vorhersagen* über künftiges Verhalten – die Weltbilder beschreiben den Zeitraum 2010–2026; (4) keine *repräsentative Stichprobe* im statistischen Sinne (vgl. Abschnitt 6); (5) kein Beweis, dass die *Sagen-Handeln-Kluft* auf bewusste Täuschung zurückgeht – alternative Erklärungen (institutionelle Zwänge, kognitive Dissonanz, rollenspezifische Kommunikation) sind gleichermaßen plausibel.

6. Limitationen

Tabelle 11 gibt einen kompakten Überblick über die identifizierten methodischen Probleme, ergriffene Gegenmaßnahmen und deren Ergebnisse. Die detaillierte Diskussion folgt in den Unterabschnitten.

Tabelle 11: Validierungsübersicht: Methodische Probleme, Gegenmaßnahmen und Ergebnisse.

Problem	Typ	Gegenmaßnahme	Ergebnis	Ref.
LLM-Kontamination	Design	Fokuskontrolle (Anonym. + Aufgabenfokus)	Var. C: MAE = 0,67	QA (e)
Anthropic-Zirkularität	Antizipiert	Matched-Sample ($n = 9$ vs. 9)	MAE = 1,00, kein Bias	QA (h)
Erwartungs-Diskrepanz	Post hoc	Instanztrennung (v2-Protokoll)	Lücke –47%; Gruppenlücken bestehen	QA (g)
Rating-Instabilität	Antizipiert	IMIIRR ($N = 15$ unabh. Runs)	ICC(3,1) = 0,847, Mean SD = 0,45	QA (a)
Reihenfolge-Effekt	Antizipiert	Permutationstest (2 Reihenfolgen)	12/12 identisch	QA (f)
Kohärenzbias	Antizipiert	Ausreißer-Detektion + Inversionskontrolle	80–88% Passung; 58% $\Delta \geq 5$	QA (i,j)
Artefaktische Sagen-Handeln-Kluft	Antizipiert	G6-Kontrollkorpus	v2-Baseline MAE = 0,92	QA (b)
Kreuzmodale Validität	Antizipiert	Op4-Vorhersage (5 Gruppen)	72% bestätigt, 0% widerlegt	QA (d)
Aggregationsverzerrung	Antizipiert	Direkt vs. aggregiert Vergleich	$r = 0,623$, Amplifikationseffekt	QA (c)
Einflussgradient	Post hoc	Strata-Vergleich (3 Rangstufen)	Gradient bestätigt; D09/D10 invers	QA (k)
Statist. Power	Abgeschlossen	$N = 15$ unabh. Opus-Runs	Mean SD = 0,45; Batch-1 in CI: 3/12	QA (a)
Modellsensitivität	Desiderat	Inter-Modell-Vergl. (unabh. Runs)	Zukünftige Arbeit	§ 6

6.1 Datenbezogene Limitationen

Quellenbias. Die Datenbasis beschränkt sich auf öffentliche Aussagen und beobachtbare Handlungen. Die rekonstruierten Weltbilder spiegeln das *öffentlich dargebotene* Weltbild wider, nicht

das *tatsächlich geglaubte*. Die Aussagen-Handlungen-Vergleichsanalyse (F3) bietet ein partielles Korrektiv, kann das Problem aber nicht eliminieren.

Zeitliche Ungleichverteilung. Die Datendichte variiert um Faktor ~ 43 : von 17 Datenpunkten im Jahr 2010 bis 735 im Jahr 2024. Für 2010–2015 liegen 2–5 Aussagen pro Person vor, für 2023–2026 dagegen 30–80. Das Kriterium K2 (Mindestgröße 15) und dokumentierte Zusammenlegungen mildern das Problem, und alle Jahres-Syntheseeinheiten erfüllen den Mindestschwellenwert; frühere Zeitreihen beruhen dennoch auf dünnerer Evidenz und sollten mit größerer Unsicherheit interpretiert werden.

Westlicher und Sprachbias. Die Stichprobe ist überproportional angloamerikanisch geprägt. Chinesische, japanische und südkoreanische KI-Persönlichkeiten sind unterrepräsentiert. Die Befunde gelten primär für die westliche KI-Elite.

Stichprobenabhängigkeit. Die Auswahl der 100 Personen erfolgte durch den Autor mittels eines mehrstufigen, aber letztlich subjektiven Scoring-Verfahrens. Eine intersubjektive Validierung der Stichprobenzusammensetzung (z. B. durch unabhängige Expertenpanels) steht aus. Da die Befunde sensitiv gegenüber der Stichprobenzusammensetzung sein könnten, ist eine Replikation mit alternativen Auswahlverfahren wünschenswert.

6.2 Methodische Limitationen

LLM-Kontamination und Fokuskontrollgrenzen. Trotz konsequenter Fokuskontrolle kann nicht ausgeschlossen werden, dass das LLM auf Trainingswissen zurückgreift. Die Fokuskontrolle operiert auf zwei Ebenen: (1) *Anonymisierung* – Ersetzung aller identifizierenden Informationen durch neutrale Platzhalter, sodass das Modell nicht an spezifischen Individuen ankern kann – und (2) *Aufgabenfokus* – das Prompt-Design lenkt das Modell darauf, ein kohärentes Weltbild aus den präsentierten Daten zu synthetisieren, ohne Verblindung, Identität oder die Existenz versteckter Informationen zu erwähnen (v2-Prompts, siehe Repository). Ein empirischer Test der Anonymisierungskomponente bestätigte, dass die Wahl der Verblindungsstrategie (Platzhalter-Tokens vs. fiktive Namen) keinen wesentlichen Effekt auf Ratings auf Gruppenebene hat ($r = 0,987$, $MAE = 0,33$, $\max |\Delta| = 1$; siehe Abschnitt 3.6). Eine dritte Variante (C) testete die vollständige Identitätsoffenlegung – dieselbe Syntheseinheit wurde mit den echten Namen aller Gruppenmitglieder verarbeitet (Musk, Sutskever, Hinton, Russell, Bengio, Leike). Das Ergebnis zeigte einen moderaten, aber nicht drastischen Effekt: A–C $MAE = 0,67$, $r = 0,850$, bei identischem Gruppendurchschnitt (7,1). Die größte Verschiebung betraf D11 (Egalitarismus, +2 Punkte). Dies bestätigt, dass Anonymisierung einen messbaren, aber bescheidenen Schutz bietet; das kollektive Weltbild ist weitgehend stabil, auch wenn Identitäten bekannt sind. Entscheidend ist nicht, ob das Modell Individuen erkennt, sondern ob es seine Aufgabe erfüllt: eine kohärente Synthese auf Gruppenebene aus den bereitgestellten Daten zu konstruieren. Auf Gruppenebene ist das Kontaminationsrisiko strukturell reduziert, da kein LLM-Trainingskorpus vorgeformte kollektive Weltbilder soziologischer Gruppen enthält.

Anthropic-interne Zirkularität. Ein besonders zugespitzter Fall des Zirkularitätsproblems betrifft die Synthese auf Gruppenebene für Subgruppen, die Personen enthalten, die direkt an der Entwicklung des verwendeten LLM beteiligt sind. Claude Opus 4.6 wird von Anthropic entwickelt; mehrere Anthropic-Führungskräfte (z. B. Dario Amodei, Daniela Amodei) gehören zur analysierten Stichprobe und ihre Daten fließen in die Gruppensynthesen ein. Um systematische Verzerrungen zu testen, wurde eine Matched-Sample-Kontrolle durchgeführt: Die Anthropic-Subgruppe ($n = 9$) wurde mit einer gematchten Kontrollgruppe nicht-Anthropic-affiliierter Gründer und Forscher ($n = 9$, gleiche Größe und Rollenkomposition) verglichen. Die resultierenden Profile zeigten $MAE = 1,00$ ohne Dimensions-Differenz $|\Delta| \geq 3$. Die beobachteten Unterschiede – Anthropic-Mitglieder mit höherer Dringlichkeit (D08) und Machtkonzentration (D07), die Kontrollgruppe mit höherem Posthumanismus (D10) und Kontrollüberzeugung (D12) – sind als genuine Gruppenunterschiede interpretierbar, die Anthropics Safety-orientierte Kultur widerspiegeln, nicht als Modellverzerrung. Während dieser Within-Model-Test Zirkularität nicht vollständig ausschließen kann (eine Cross-Model-Replikation bleibt als externe Validierung wünschenswert), liefert er keinen Beleg für systematische Anthropic-spezifische Verzerrung.

Kritik synthetischer Personas. Die wachsende Literatur zu LLM-generierten synthetischen Personas mahnt zur Vorsicht, aber die Kritik muss sorgfältig eingegrenzt werden. [Santurkar et al. \(2023\)](#) zeigt, dass LLMs Meinungen spezifischer demografischer Gruppen systematisch verfehlen und „WEIRD“-Verzerrungen aufweisen, wenn sie als *Meinungsgeneratoren* eingesetzt werden – d. h. wenn sie aufgefordert werden zu simulieren, was eine demografische Gruppe denken könnte. Ebenso finden [Argyle et al. \(2023\)](#), dass synthetische Agenten Leitthemen erfassen, aber an authentischer Tiefe realer Diskurse scheitern, wenn sie qualitative Daten *generieren*. Ein aktuelles systematisches Review von 63 Peer-reviewed-Persona-Experimenten (2023–2025) bestätigt dieses Muster: Die meisten Studien spezifizieren die Zielpopulation unzureichend, nur 35 % adressieren Repräsentativität, und die ökologische Validität ist durchgängig gering ([Batzner et al., 2025](#)). Diese Kritiken zielen auf einen fundamental anderen Anwendungsfall als die SWR. In der vorliegenden Studie generiert das LLM keine Meinungen; es *verdichtet* 3.132 reale Datenpunkte (dokumentierte Aussagen und Handlungen) in strukturierte Profile auf Gruppenebene. Die synthetische Persona ist ein analytisches Verdichtungsinstrument – näher am Weber’schen Idealtyp als am Simulationsagenten. Die von [Santurkar et al.](#) identifizierte WEIRD-Verzerrung ist weitgehend orthogonal: Die KI-Elite *ist* eine westliche, gebildete, wohlhabende und industrialisierte Population, sodass jede demographische Schieflage in den Vorannahmen des Modells mit der Zielgruppe konvergiert, anstatt sie zu verzerren. Dennoch bleibt die Tendenz zur Überrepräsentation öffentlich dominanter Narrative und zur Unterrepräsentation idiosynkratischer oder widersprüchlicher Positionen eine genuine Limitation.

Quantifizierung und interne Konsistenz. Die in Abschnitt 4.2 berichteten Dimensionskorrelationen (z. B. $r_s = +0,85$ zwischen D10 und D12) werden innerhalb des Rating-Prozesses des LLM generiert und könnten teilweise interne Konsistenz statt empirischer Zusammenhänge

widerspiegeln. Dieses Problem betrifft spezifisch den *Rating-Schritt* (Op2) und gilt für jedes Rating-Verfahren einschließlich menschlicher Rater: Ein menschlicher Kodierer, der Posthumanismus hoch bewertet, wird durch kognitive Kohärenz auch Kontrollüberzeugung tendenziell hoch bewerten. Das Problem betrifft *nicht* die qualitativen Synthesen (Op1), die ohne dimensionales Prompting direkt aus den Rohdaten generiert werden. Mehrere Validierungsergebnisse begrenzen die Reichweite dieser Limitation: (1) Die kreuzmodale Vorhersage (G5, 72 % bestätigt) zeigt, dass LLM-rekonstruierte Muster empirische Substanz haben – aus Aussagen abgeleitete Vorhersagen wurden durch unabhängig evaluierte Handlungen bestätigt; (2) der Reihenfolge-Invarianztest zeigt, dass die Ratings nicht von der Präsentationsreihenfolge der Dimensionen abhängen; (3) die IMIIRR-Koeffizienten ($ICC = 0,902$ aus 5×2 Runs; $ICC = 0,847$ aus $N = 15$ unabhängigen Einzelinstanz-Runs) etablieren, dass das Rating-Verfahren stabil und reproduzierbar ist. Die berichteten Korrelationen sind als Muster eines zuverlässig kalibrierten Rekonstruktionsinstruments zu lesen, nicht als Artefakte willkürlichen Modellverhaltens – eine externe Replikation bleibt jedoch wünschenswert zur Bestätigung, welche spezifischen Korrelationen über Instrumente hinweg bestehen.

Statistische Power. Eine formale Power-Analyse wurde an einer Gruppen-Syntheseinheit (GA_ges_AH) mit $N = 15$ vollständig unabhängigen Opus-Instanzen (je ein separater Agent ohne geteilten Kontext) durchgeführt. Die Ergebnisse zeigen, dass das Instrument hochstabil ist: mittlere SD = 0,45 über alle 12 Dimensionen (Bereich: 0,00–0,74), mit 95 %-Konfidenzintervallen schmäler als $\pm 0,5$ Skalenpunkte für die meisten Dimensionen. Der ursprüngliche Batch-1-Einzelwert lag nur in 3 von 12 Konfidenzintervallen (MAE zum $N = 15$ -Mittelwert = 0,73), was bestätigt, dass Einzelmessungen unzuverlässig sind und $N \geq 15$ unabhängige Runs für robuste Profilschätzungen erforderlich sind. Die Analyse wurde jedoch an einer einzelnen Syntheseinheit durchgeführt; die Generalisierung auf alle 56 SEs bleibt ein Desiderat für zukünftige Arbeiten. Die berichteten Δ -Werte, Korrelationen und Cluster-Unterschiede auf Gruppenebene sind deskriptive Muster in rekonstruierten Daten; die Interpretation beruht auf inhaltlicher Einordnung, informiert durch die bekannte Messpräzision.

Reproduzierbarkeit. LLM-Outputs sind auch bei Temperatur 0 nicht vollständig deterministisch. Die ursprünglichen Synthesen wurden in Einzeldurchläufen pro SE generiert. Zwei Post-hoc-IMIIRR-Validierungen etablieren die Reproduzierbarkeit: (1) fünf Gruppen-Syntheseinheiten, je zweimal verarbeitet, ergaben $ICC = 0,902$, $MAE = 0,40$ ($\pm 0,2$ Skalenpunkte); (2) $N = 15$ vollständig unabhängige Einzelinstanz-Runs auf einer Syntheseinheit ergaben $ICC(3,1) = 0,847$, mittlere SD = 0,45, wobei eine Dimension (D02) perfekte Übereinstimmung über alle 15 Instanzen zeigte. Beide Intra-Instrument-Reliabilitätsschätzungen übertreffen die typische Inter-Rater-Übereinstimmung menschlicher Kodierer in qualitativer Forschung ($ICC = 0,6$ – $0,8$; Hallgren 2012), was bestätigt, dass das LLM-basierte Instrument einen *Reproduzierbarkeitsvorteil* gegenüber konventioneller Kodierung bietet. Ob verschiedene Modelle desselben oder anderer Anbieter auf ähnliche Profile konvergieren, bleibt eine offene Frage — ein Inter-Modell-Vergleich mit strikten Unabhängigkeitskriterien (separater Agent

pro Run, kein geteilter Kontext) wird als Priorität für zukünftige Replikation identifiziert.

Daten-Bias in der Sagen-Handeln-Rekonstruktion. Die der SWR-Methode verfügbaren Daten sind strukturell asymmetrisch: Öffentliche Aussagen sind reichhaltig und explizit, während Handlungen aus dokumentierten Entscheidungen, Investitionen und organisatorischem Verhalten erschlossen werden müssen. Diese Asymmetrie bedeutet, dass die „Sagen“-Seite auf dichter Evidenz beruht als die „Handeln“-Seite. Der Trainingskorpus des LLM spiegelt dieselbe Asymmetrie wider – öffentlicher Diskurs ist relativ zu dokumentiertem operativem Verhalten überrepräsentiert. Diese Datenlimitation ist besonders relevant für den Sagen-Handeln-Vergleich, bei dem das Handlungsprofil weniger präzise kalibriert sein könnte als das Aussagenprofil. Die robusten Richtungsbefunde (D07 Machtkonzentration, D11 Egalitarismus) persistieren über Messbedingungen hinweg, aber ihre Magnitude sollte angesichts dieser strukturellen Asymmetrie konservativ interpretiert werden. Die Limitation ist der Datenstruktur inhärent, nicht der Methode: Jeder Analyst – menschlich oder algorithmisch –, der auf öffentliche Quellen angewiesen ist, würde derselben Evidenzasymmetrie begegnen.

Erwartete-Diskrepanz-Bias. Die Kongruenzanalyse (F3) vergleicht zwei LLM-Synthesen – eine aus Aussagen, eine aus Handlungen –, die beide vom selben Modell generiert wurden. Da LLMs auf sozialwissenschaftlicher Literatur trainiert sind, in der Sagen-Handeln-Diskrepanzen bei Eliten als Standardbefund gelten, ist ein Erwartungseffekt plausibel: Das Modell könnte die *erwartete* Diskrepanz reproduzieren, statt sie empirisch zu entdecken. Diese Studie liefert Evidenz, dass der Effekt *existiert*, aber *kontrollierbar* ist. Die ursprüngliche Analyse (v1), bei der beide Datentypen in derselben LLM-Instanz verarbeitet wurden, ergab eine Gesamtkluft von $MAE = 1,42$. Bei Wiederholung mit strikter Instanztrennung (v2-Protokoll) – jeder Datentyp von einem unabhängigen Agenten ohne geteilten Kontext verarbeitet – schrumpfte die Gesamtkluft auf $MAE = 0,75$ (–47 %). Diese Reduktion zeigt, dass geteilter Kontext die Kluft *tatsächlich* verstärkt hat, was die Erwartungs-Diskrepanz-Bedenken als empirisch real bestätigt. Die Gegenmaßnahme (Instanztrennung) ist jedoch wirksam: Die v2-Kluft fällt unter die Kontrollbaseline ($MAE = 0,92$, einer fiktiven konsistenten Gruppe unter gleichen Bedingungen), was darauf hindeutet, dass die aggregierte Kluft nicht mehr zuverlässig von Messrauschen unterscheidbar ist. Der methodisch entscheidende Befund ist, dass *gruppenspezifische* Lücken die Korrektur überstehen: CEOs ($MAE = 1,08$) und Risiko-Warner ($MAE = 1,92$) überschreiten die Baseline auch unter v2-Bedingungen, mit stabilen Richtungsmustern (D07, D11 für CEOs; D09, D10 für Risiko-Warner). Der Erwartete-Diskrepanz-Bias ist somit ein reales methodisches Problem, das in dieser Studie identifiziert, quantifiziert und teilweise kontrolliert wurde – keine unadressierte Limitation.

*Kohärenzbias.*¹⁰ LLMs sind auf logische Kohärenz optimiert; Menschen sind von Natur aus

¹⁰Der Begriff *Kohärenzbias* wird in dieser Studie als operativer Arbeitsbegriff verwendet; kein etabliertes Konzept dieses genauen Namens wurde in der methodischen Literatur gefunden. Das zugrundeliegende Phänomen – die Tendenz von LLMs, logisch kohärente Synthesen zu produzieren, die echte Inkonsistenz in den Quelldaten glätten können – wird empirisch durch die in Abschnitt 3.6 beschriebenen Abweichungsdetektions- und Inversionskontrollmechanismen adressiert.

inkonsistent. Für die Weltbild-Rekonstruktion ist diese Eigenschaft zugleich operativer Vorteil und Quelle systematischer Verzerrung. Der Vorteil: Kohärenz ermöglicht es der SWR, aus heterogenen Daten stabile, interpretierbare Profile auf Gruppenebene zu extrahieren – die Methode *nutzt* Kohärenz als Kompressionsmechanismus, analog dazu, wie Faktoranalyse Kovarianzstruktur nutzt. Die Verzerrung: Die resultierenden Cluster-Typen (Architekt, Hüter, Innovator, Befreier) könnten schärfer konturiert erscheinen, als sie in der Realität sind. Die interne Spannung, die reale Personen zwischen z. B. Machtstreben und Verantwortungsgefühl erleben, wird vom LLM zugunsten eines konsistenten Profils aufgelöst. Die genuine Limitation ist daher *Über-Kohärenz*: Cluster schärfer als die empirische Realität. Zwei Kontrollmechanismen adressieren dieses Risiko teilweise: (1) die in die SWR-Pipeline eingebaute Abweichungsdetektion ergibt eine Passung auf Gruppenebene von 80–88 %, nicht 100 %, was darauf hindeutet, dass das Modell Heterogenität innerhalb der Gruppe registriert und bewahrt; und (2) die Inversionskontrolle (Op3, Kongruenzanalyse) zeigt, dass 58 % der Dimensionen $|\Delta| \geq 5$ aufweisen, was demonstriert, dass die Methode substanzielle Diskrepanzen nicht glättet.

6.3 Konzeptuelle Limitationen

Aggregation als Design-Merkmal. Kollektive Synthesen nivellieren individuelle Variation – dies ist die intendierte Funktion der Methode, kein Nebenprodukt. Die Forschungsfragen der Studie (F1–F6) sind auf Gruppenebene formuliert; individuelle Variation ist relativ zu diesem analytischen Ziel Rauschen, ebenso wie Individualebene-Varianz in jeder Aggregatanalyse Rauschen darstellt (nationale Surveys, Branchenbenchmarks, Metaanalysen). Die algorithmische Strukturprüfung (PCA, HDBSCAN; Abschnitt 4.4) bestätigt, dass die Individualebene-Ratingmatrix genuine strukturelle Variation *vor* der Aggregation aufweist, was darauf hindeutet, dass die Muster auf Gruppenebene Kompressionen realer Heterogenität sind, nicht Artefakte uniformer Eingabedaten.

Keine Kausalerklärung. Die Studie identifiziert, *was* die KI-Elite kollektiv glaubt, und dokumentiert zeitliche Assoziationen (F2: Längsschnittrends) und strukturelle Kovariationen (F5: Gruppenunterschiede korreliert mit Rolle, Haltung und Geschlecht). Sie etabliert keine kausalen Mechanismen. Die zeitliche Abfolge von Weltbild-Verschiebungen und die systematische Kovariation mit struktureller Position liefern plausible assoziative Evidenz, aber der Ausschluss von Drittvariablen-Erklärungen würde andere Forschungsdesigns erfordern (Längsschnitt-Panelstudien, natürliche Experimente oder biographische Fallanalysen).

Epistemologische Grenzen der Quantifizierung. Die dimensionalen Bewertungen (Skala 1–10) bieten ein handhabbares Format für Aggregation und Vergleich, setzen aber eine Kommenturabilitätsannahme voraus, die explizite Reflexion verdient. Komplexe normative Orientierungen – wie etwa *Kontrollverantwortung über KI* (D07) oder *Posthumanismus* (D10) – sind mehrdimensionale Konstrukte, die sich nicht sauber auf eine einzige geordnete Dimension abbilden lassen. Die numerische Zuweisung ist am besten als *ordinale Kompression* zu verstehen: ein

zusammenfassendes Urteil über die relative Position, keine Messung einer zugrundeliegenden Größe. Drei Einschränkungen folgen daraus. Erstens sind Interpretationen auf Intervallniveau nicht gerechtfertigt; die berichteten Spearman-Korrelationen und rangbasierte Clusteranalyse respektieren diese Einschränkung. Zweitens impliziert die Zuweisung eines einzelnen Werts je Dimension ein Maß an *Reifikation*: die Abstraktion einer vielsträngigen diskursiven Orientierung auf einen Punkt einer Skala. Die qualitative Synthese (Op1) bewahrt die Nuance, die die Bewertung (Op2) komprimiert. Drittens sind die 12 Dimensionen konzeptuell distinkt, aber empirisch interkorreliert (z. B. $r_s = +0.85$ für D10–D12); ein Teil dieser Kovariation könnte echte Konstrukt-Überlappung widerspiegeln, nicht unabhängige empirische Beziehungen. Diese Einschränkungen sind in jeder quantitativen Weltbildforschung angelegt und nicht spezifisch für die SWR-Methode; sie mahnen zu Zurückhaltung bei feinkörnigen numerischen Vergleichen, lassen aber die Richtungsmuster und strukturellen Kontraste – die primären Aussagen der Studie – unberührt.

6.4 Forschungsethische Reflexion

Die Studie analysiert öffentliche Figuren ausschließlich auf der Grundlage öffentlich zugänglicher Daten. Zwei Design-Merkmale mildern ethische Bedenken substantiell.

Aggregation auf Gruppenebene als ethischer Schutz. Die primären Analyseeinheiten sind soziologisch definierte Gruppen, nicht Individuen. Individuelle Daten werden vor der Synthese in Gruppenkorpora gepoolt; kein individuelles Weltbild-Profil wird als Befund berichtet. Die rekonstruierten Weltbilder beschreiben kollektive Tendenzen von Rollen (CEOs, Akademiker) und Haltungen (Beschleuniger, Risiko-Warner), nicht die Psychologie identifizierbarer Personen. Diese Aggregation verhindert strukturell die Zuschreibung spezifischer Überzeugungen an namentlich genannte Individuen.

Standard-Legitimation. Die Studie stützt sich auf öffentlich dokumentierte berufliche Aussagen und Handlungen öffentlicher Figuren, deren Positionen zur KI-Entwicklung von erheblichem öffentlichem Interesse sind (vgl. APA Ethical Principles, Standard 8.05). Keine privaten oder vertraulichen Informationen wurden erhoben.

Residualrisiko. Für kleine Gruppen (z. B. firmenspezifische Subgruppen mit $n = 3–5$) bietet die Aggregation schwächeren Schutz – ein quasi-individuelles Profil kann entstehen. Die drei individuellen Spot-Checks (Abschnitt 6.5) werden als Datenqualitätsindikatoren präsentiert, nicht als inhaltliche Befunde. Member Checking (Soysal & Türkmen, 2024) bleibt ein Desiderat für Folgeforschung.

6.5 Individualebene-Analyse (explorativ)

Die inhaltlichen Befunde der Studie beruhen vollständig auf Analysen auf Gruppenebene (F1–F6). SWR auf Individualebene ist für den vorliegenden Zweck methodisch überflüssig – die originalen öffentlichen Aussagen und Handlungen sind für jede Einzelperson direkt zugäng-

lich. Der Mehrwert der SWR liegt ausschließlich in der Synthese auf Gruppenebene, wo sie kollektive Porträts erzeugt, die in keiner einzelnen Quelle existieren. Die folgenden drei Spot-Checks werden ausschließlich als *Datenqualitätsindikatoren* berichtet: Wenn die zugrundeliegenden Individualdaten erkennbare, verifizierbare Profile produzieren, stützt dies die Qualität der Eingabedaten für die Gruppensynthesen. Tabelle 12 fasst die Ergebnisse zusammen.

Tabelle 12: Explorative Validierung auf Individualebene: SWR-Ratings vs. dokumentierte Positionen. Diese Einzelfallprüfungen dienen als Plausibilitätstests für die zugrundeliegende Datenqualität; die inhaltlichen Befunde der Studie beruhen auf den Gruppenanalysen (F1–F6).

Dim.	Sam Altman		Geoffrey Hinton		Marc Andreessen	
	R	Status	R	Status	R	Status
D01 Send.	9	best.	7	best.	8	best.
D02 Selbst.	9	best.	5	best.	9	best.
D03 Arbeit	9	best.	7	plaus.	8	best.
D04 Verantw.	6	best.	10	best.	4	best.
D05 Techno.	9	best.	6	best.	9	best.
D06 Fortschr.	8	best.	4	best.	9	best.
D07 Macht	9	best.	4	best.	2	best.
D08 Dringl.	9	best.	10	best.	7	plaus.
D09 Menschenfr.	3	plaus.	7	best.	4	plaus.
D10 Posthum.	8	best.	5	best.	7	plaus.
D11 Egalit.	3	best.	7	best.	2	best.
D12 Kontr.	8	best.	3	best.	8	best.
<i>Bestätigt</i>	10/12		11/12		9/12	
<i>Plausibel</i>	2/12		1/12		3/12	
<i>N. belegbar</i>	0/12		0/12		0/12	

Methodik der Spot-Checks. Jedes Rating wurde gegen mindestens zwei unabhängige, öffentlich dokumentierte Quellen geprüft. *Bestätigt* (best.): Rating stimmt mit dokumentierten Positionen und Handlungen überein. *Plausibel* (plaus.): Rating ist mit bekannten Positionen vereinbar, aber keine direkte Quelle für die spezifische Ausprägung verfügbar. *Nicht belegbar* (n. b.): Rating widerspricht dokumentierten Positionen oder ist nicht überprüfbar.

Altman (Architekt): D01=9 (bestätigt durch wiederholte Aussagen zur „wichtigsten Technologie der Menschheitsgeschichte“, Davos 2024, US-Kongress 2023). D07=9 (bestätigt durch die Umstrukturierung von OpenAI von Non-Profit zu Capped-Profit, Mehrfach-Stimmrechte). D11=3 (bestätigt: trotz Rhetorik von „KI für alle“ hat OpenAI Zugang zunehmend paywalled). D09=3 (plausibel: keine direkte Aussage zur Ersetzbarkeit des Menschen, aber Fokus auf AGI als „nächste Spezies“).

Hinton (Hüter): D04=10 (bestätigt durch Rücktritt bei Google 2023, um frei vor KI-Risiken warnen zu können). D08=10 (bestätigt durch Aussage, die Wahrscheinlichkeit einer existenziellen Katastrophe betrage 10–20 %). D12=3 (bestätigt: zunehmender Pessimismus, „Ich bin mir nicht sicher, ob wir das noch kontrollieren können“, NYT 2023). D03=7 (plausibel: hohe akademische Produktivität bekannt, aber keine direkte Aussage zur Arbeitsidentifikation im Silicon-Valley-Stil).

Andreessen (Befreier): D07=2 (bestätigt durch „Techno-Optimist Manifesto“ 2023: vehemente Ablehnung staatlicher Regulierung, Märkte als Verteilungsmechanismus). D11=2 (bestätigt: explizite Ablehnung von Umverteilung und Egalitarismus im Manifesto). D04=4 (bestätigt: Verantwortung wird dem Markt zugeschrieben, nicht individuellen Akteuren). D09=4 (plausibel: keine direkte Aussage, aber instrumentelle Sicht auf menschliche Arbeitskraft in VC-Kontext).

Gesamtbewertung: 30 von 36 Ratings (83 %) sind direkt durch öffentliche Quellen bestätigt, 6 von 36 (17 %) sind plausibel, keines widerspricht den dokumentierten Positionen. Diese Einzelfallprüfungen auf Individualebene liefern Plausibilitätshinweise für die Datenqualität, die den Gruppensynthesen zugrunde liegt, stellen aber nicht die primäre Validierungsstrategie dar. Die inhaltlichen Befunde der Studie beruhen auf der Konvergenz mehrerer unabhängiger Gruppensynthesen (15 Gruppen, 4 Cluster-Typen), nicht auf der Genauigkeit auf Individualebene. Die Spot-Checks unterliegen zudem erheblichen Einschränkungen: (a) geringe Fallzahl ($n = 3$ von 100); (b) Durchführung durch den Forscher selbst, was Confirmation Bias nicht ausschließt; (c) Beschränkung auf besonders prominente Persönlichkeiten, deren öffentliches Profil gut dokumentiert und daher leichter „bestätigbar“ ist; (d) die Kategorien „bestätigt“ und „plausibel“ sind ihrerseits subjektive Einschätzungen. Eine systematische externe Validierung durch unabhängige Expertenpanels bleibt ein Desiderat für Folgeforschung.

7. Fazit und Ausblick

7.1 Fazit

Die Studie hat die Frage gestellt, was die KI-Elite denkt – nicht als Individuen, sondern als soziologisch strukturierte Gruppen – und eine empirisch fundierte Antwort vorgelegt. Fünf übergreifende Erkenntnisse kristallisieren sich heraus:

Erstens: Die KI-Elite verfügt über ein kohärentes, empirisch rekonstruierbares kollektives Weltbild – technologischer Messianismus, Sendungsbewusstsein, Fortschrittsglaube –, das über mehrere unabhängige Gruppensynthesen hinweg stabil ist.

Zweitens: Dieses Weltbild befindet sich in beschleunigter Transformation. Der Verlust utopischer Gewissheiten hat zu einem *tragischen Beschleunigungszwang* geführt: Man zweifelt an der Zukunft, die man baut, und baut sie dennoch.

Drittens: Der Sagen-Handeln-Vergleich offenbart ein Simpson-Paradox: Die aggregierte Kluft ist nicht zuverlässig von Messrauschen unterscheidbar, aber gruppenspezifische Lücken sind substanziell und überstehen die Instanztrennung. CEOs zeigen eine klassische Erwünschtheitslücke (D07 +2, D11 –2: Rhetorik egalitärer als operatives Verhalten). Risiko-Warner zeigen ein inverses Muster – prophetische Konsistenz statt Heuchelei: Ihre Aussagen beschreiben eine gefürchtete posthumanistische Zukunft (D10 Sagen=9, D09 Sagen=4), während ihre Handlungen die menschenzentrierten Werte zeigen, die sie tatsächlich vertreten

(D09 Handeln=8, D10 Handeln=4). Investoren sind die konsistenteste Gruppe: radikaler Techno-Optimismus in Wort und Tat. Die Sagen-Handeln-Analyse ist somit kein Ein-Zahlen-Befund, sondern eine *gruppenspezifische Diagnostik*, die qualitativ unterschiedliche Diskrepanztypen aufdeckt.

Viertens: Die Macht ist nicht weltbild-neutral verteilt. Die Inter-Gruppen-Vergleiche und die Analyse nach Einflussstrata (Top 10 vs. Mitte vs. Bottom 10) konvergieren auf denselben Befund: Die mächtigsten Akteure weisen die intensivsten Weltbilder auf (Avg 7,7 vs. 6,4 vs. 6,1). Zwei Dimensionen zeigen einen inversen Gradienten: Menschliche Wertschätzung (D09: Top=4, Bottom=8) und Posthumanismus (D10: Top=8, Bottom=3). Die Macht-Gleichheits-Achse (D07/D11) bleibt die diskriminierendste Dimension über alle Gruppenvergleiche hinweg.

Fünftens: Die SWR hat sich als leistungsfähiges Instrument für Weltbild-Analyse auf Gruppenebene erwiesen, das qualitative Tiefe mit quantitativer Systematik verbindet. Die Konvergenz unabhängig produzierter Gruppensynthesen liefert eine dem Gruppenansatz eigene Form der Validierung. Insbesondere die Zerlegung in Aussagen- und Handlungsprofile (F3) erweist sich als eigenständiger methodischer Beitrag, der qualitativ unterschiedliche Diskrepanztypen aufdeckt – Erwünschtheitslücken, prophetische Konsistenz und authentische Kongruenz – je nach struktureller Position der Gruppe. Diese diagnostische Fähigkeit wäre über die KI-Elite hinaus auf politische, ökonomische oder militärische Eliten übertragbar.

7.2 Ausblick

Fünf Richtungen für Anschlussforschung: (1) *Komparative Erweiterung:* Die vorliegende Studie fokussiert stark auf die US-amerikanische, Silicon-Valley-zentrische Elite. Eine zentrale Forschungslücke betrifft die komparative Untersuchung chinesischer (Baidu, ByteDance, Alibaba), indischer (Infosys, TCS) und europäischer (Mistral, Aleph Alpha) KI-Eliten. Es ist unklar, ob der „technologische Messianismus“ ein universelles Artefakt der KI-Entwicklung oder ein spezifisches Kulturprodukt des westlichen Libertarismus darstellt. Kulturvergleichende Gruppenanalysen (westliche vs. chinesische vs. europäische KI-Eliten) würden die Generalisierbarkeit der hier identifizierten Muster auf Gruppenebene prüfen. (2) *Feinere Gruppenanalysen:* Erweiterung der Gruppenvergleiche auf zusätzliche soziologische Kategorien (Generationskohorten, Bildungshintergründe, geographische Herkunft) und Nachverfolgung von Cluster-Drift über Epochen. (3) *Methodische Weiterentwicklung:* Unabhängige Replikation durch andere Forschungsteams mit verschiedenen Frontier-Modellen, automatisierte Validierungsverfahren, standardisierte Gütekriterien für Synthesen auf Gruppenebene und systematische Power-Analyse ($N = 30$ Durchläufe pro Syntheseinheit). (4) *Transfer:* Finanz-Elite, politische Elite, militärische KI-Elite – Anwendung des Gruppenvergleichs-Frameworks auf andere Machteliten. (5) *Longitudinale Fortführung:* Jährliches Weltbild-Monitoring als Instrument demokratischer Kontrolle – denkbar als standardisierter Index (analog zum Democracy Index oder AI Readiness Index), der Veränderungen in den kollektiven Weltbildern der KI-Elite-Subgruppen

systematisch und vergleichbar erfasst. Die Frage „Was denkt die KI-Elite?“ ist keine einmalige Frage. Sie ist eine Frage, die Demokratien kontinuierlich stellen müssen.

Offenlegungserklärung: Einsatz künstlicher Intelligenz

KI-Disclosure Level 5 (Extensiv). Bei der Erstellung dieser Studie wurden zwei KI-Modelle von Anthropic in erheblichem Umfang als nicht-autorschaftliche Forschungsinstrumente und redaktionelle Hilfsmittel eingesetzt. Die Systeme werden nicht als Autoren, Koautoren, Danksagungsempfänger, Wahrheitsinstanzen oder unabhängige Validierungsinstanzen geführt. *Claude Sonnet 4.5* diente als primäre Analyse-Engine: Alle 100 individuellen dimensional Ratings (D01–D12), alle Synthese-Ratings auf Gruppenebene und alle Datenerhebungsskripte wurden von 9 parallelen Sonnet-Agenten generiert. *Claude Opus 4.6* diente als qualitative Analyse-Engine: Pilot-Synthesen, Vergleichsanalysen, statistische Aufbereitung (PCA, HDBSCAN, Kruskal-Wallis, Cliff's δ), Visualisierung der Ergebnisse und nicht-autorschaftliche Unterstützung bei Strukturierung und Formulierung einzelner Manuskriptpassagen. Kein anderes LLM wurde in der ursprünglichen Analyse-Pipeline verwendet. Ein späterer englischer redaktioneller Style-Check im Mai 2026 nutzte OpenAI Codex/GPT ausschließlich für sprachliche Glättung und Claim-Kalibrierung; dabei wurden keine neuen Daten, Quellen, Analysen oder inhaltlichen Behauptungen hinzugefügt. Forschungsdesign, Forschungsfragen, Datenerhebungsstrategie, methodische Entscheidungen, Interpretation der Ergebnisse und alle inhaltlichen Schlussfolgerungen stammen vom Autor, der die volle Verantwortung für das Manuskript trägt. KI-Ausgaben wurden vom Autor geprüft und nicht als externe Validierung oder Ersatz für menschliche wissenschaftliche Beurteilung behandelt. Sämtliche Prompts, API-Parameter und Modellversionen sind im Repository dokumentiert.

Verfügbarkeit der Daten und Materialien

Sämtliche Datenerhebungsskripte, qualitativen Kodierskripte, Analysecodes und generierten Abbildungen sind öffentlich verfügbar unter: <https://github.com/research-line/ai-elite-swr>. Das Repository enthält 56 Erhebungsskripte und 38 Insert-Skripte in `_data_A/`, Kodier- und Analyseskripte, die 100×12 -Ratingmatrix, HDBSCAN-/PCA-Ausgaben, Prompt-Templates, Dimensionsdefinitionen, Syntheseeinheiten, Qualitätsberichte und generierte Abbildungen. Diese Materialien bilden einen prüfbaren Reproduktionspfad der implementierten Pipeline; eine exakte Neuausführung setzt den Neuaufbau der SQLite-Datenbank aus den aktuellen Skripten voraus und kann von der Verfügbarkeit der ursprünglichen Onlinequellen zum Erhebungszeitpunkt abhängen.

Literatur

- Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, 6(1), 44–72. <https://doi.org/10.1080/09505439609526455>.
- Bengio, Y., Hinton, G. E. et al. (2024). Managing extreme AI risks amid rapid progress. *Science*, 384(6698), 842–845. <https://doi.org/10.1126/science.adn0117>.
- Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.
- Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.
- Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, 14(1), 1–25.
- Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.
- Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.
- OpenAI (2023). Our approach to AI safety. *OpenAI Blog*, 5. April 2023. <https://openai.com/index/our-approach-to-ai-safety/>.
- Anthropic (2023). Core views on AI safety: When, why, what, and how. *Anthropic Research Blog*, 8. März 2023. <https://www.anthropic.com/research/core-views-on-ai-safety>.
- Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.
- Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.
- Ge, T., Chan, X., Wang, X., Yu, D., Mi, H. & Yu, D. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*. <https://doi.org/10.48550/arXiv.2406.20094>.
- Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, 18(6), 669–684. <https://doi.org/10.1080/13645579.2015.1005453>.
- Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, 18(1), 59–82. <https://doi.org/10.1177/1525822X05279903>.
- Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

- Hallgren, K. A. (2012). Computing Inter-Rater Reliability for Observational Data: An Overview and Tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023>.
- Hayes, A. S. (2025). ‘Conversing’ With Qualitative Data: Enhancing Qualitative Research Through Large Language Models (LLMs). *International Journal of Qualitative Methods*, 24, Article 16094069251322346. <https://doi.org/10.1177/16094069251322346>.
- Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, 29, 105–110. <https://doi.org/10.1016/j.cobeha.2019.04.010>.
- Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.
- Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.
- Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.
- More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.
- More, M. & Vita-More, N. (Hrsg.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.
- Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.
- Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.
- Nicmanis, M. & Spurrier, H. (2025). Getting Started with Artificial Intelligence Assisted Qualitative Analysis: An Introductory Guide to Qualitative Research Approaches with Exploratory Examples from Reflexive Content Analysis. *International Journal of Qualitative Methods*, 24, Article 16094069251354863. <https://doi.org/10.1177/16094069251354863>.
- Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.
- Tai, R. H., Bentley, L. R., Xia, X., Sitt, J. M., Fankhauser, S. C., Chicas-Mosier, A. M. & Monteith, B. G. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, 23, Article 16094069241231168. <https://doi.org/10.1177/16094069241231168>.
- Geburu, T. & Torres, É. P. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through artificial general intelligence. *First Monday*, 29(4). <https://doi.org/10.5210/fm.v29i4.13636>.
- Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

- Weber, M. (1904). Die „Objektivität“ sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, 19, 22–87.
- Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.
- Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.
- Floridi, L. (2019). Establishing the Rules for Building Trustworthy AI. *Nature Machine Intelligence*, 1(6), 261–262. <https://doi.org/10.1038/s42256-019-0055-y>.
- Couldry, N. & Mejias, U. A. (2019). *The Costs of Connection: How Data Is Colonizing Human Life and Appropriating It for Capitalism*. Stanford: Stanford University Press.
- Whittaker, M. (2021). The steep cost of capture. *Interactions*, 28(6), 50–55. <https://doi.org/10.1145/3488666>.
- Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press.
- Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to train your stochastic parrot: Large language models for political texts. *Political Science Research and Methods*, 13(2), 264–281. <https://doi.org/10.1017/psrm.2024.64>.
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 29971–30004. <https://proceedings.mlr.press/v202/santurkar23a.html>.
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>.
- Batzner, J., Stocker, V., Tang, B., Natarajan, A., Chen, Q., Schmid, S. & Kasneci, G. (2025). Whose Personae? Synthetic Persona Experiments in LLM Research and Pathways to Transparency. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 8(1), 343–354. <https://doi.org/10.1609/aies.v8i1.36553>; arXiv:2512.00461.
- Soysal, Y. & Türkmen, S. (2024). Reinterpreting the Member Checking Validation Strategy in Qualitative Research Through the Hermeneutics Lens. *Qualitative Inquiry in Education: Theory & Practice*, 2(1), 42–63. <https://doi.org/10.59455/qietp.19>.
- Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*. New York: PublicAffairs.

- Becker, A. (2025). *More Everything Forever: AI Overlords, Space Empires, and Silicon Valley's Crusade to Control the Fate of Humanity*. New York: Basic Books.
- Bourdieu, P. (1992). *Les règles de l'art: Genèse et structure du champ littéraire*. Paris: Seuil. [Dt.: *Die Regeln der Kunst*, Frankfurt: Suhrkamp, 1999.]
- Merton, R. K. (1973). *The Sociology of Science: Theoretical and Empirical Investigations*. Chicago: University of Chicago Press.
- Mills, C. W. (1956). *The Power Elite*. New York: Oxford University Press.
- Ricoeur, P. (1970). *Freud and Philosophy: An Essay on Interpretation*. New Haven: Yale University Press.
- Romano, J., Kromrey, J. D., Coraggio, J. & Skowronek, J. (2006). Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? *Annual Meeting of the Florida Association of Institutional Research*, 1–33.

A. Sampling-Methode der 100 KI-Akteure

Die Stichprobe wurde durch ein dreistufiges Verfahren erstellt: (1) 22 systematische Webrecherchen → 187 Kandidaten; (2) 6-Kategorien-Scoring (Marktkapitalisierung, technologische Schlüsselpositionen, Diskursmacht, akademischer Einfluss, politische Einflussnahme, symbolischer Status); (3) Reduktion auf 100 unter Sicherstellung demographischer Heterogenität. Die finale Stichprobe umfasst 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte).

B. Die 12 Rating-Dimensionen (D01–D12)

Dim.	Name	Pol 1 (=1)	Pol 10 (=10)
D01	Sendungsbewusstsein	Kein Auftrag	Messianisch
D02	Selbstwirksamkeit	Ohnmacht	Omnipotent
D03	Arbeitsethos	Distanz	Totale Identifikation
D04	Verantwortungsgefühl	Keines	Weltverantwortung
D05	Techno-Determinismus	Neutral	Bestimmt alles
D06	Fortschrittsglaube	Niedergang	Goldene Zukunft
D07	Machtkonzentration	Radikal verteilen	Bei Experten
D08	Dringlichkeit	Entspannt	Existenzieller Druck
D09	Menschenfreundlichkeit	Ersetzbar	Einzigartig
D10	Posthumanismus	Mensch bleibt	Mensch wird mehr
D11	Egalitarismus	Ungleichheit natürlich	Gleichheit anstreben
D12	Kontrollüberzeugung	Pessimismus	Volle Kontrolle

C. Reduktionskriterien (K1–K9)

K	Typ	Beschreibung
K1	obligatorisch	Fragestellungsbindung: Jede SE muss ≥ 1 Forschungsfrage zugeordnet sein
K2	obligatorisch	Mindestgröße: ≥ 15 Datenpunkte pro SE
K3	obligatorisch	Redundanzverbot: Echte Teilmengen werden eliminiert
K4	Prinzip	Modalitäts-Sparsamkeit: A/H-Trennung nur für F3
K5	Prinzip	Zeitliche Sparsamkeit: Jahres-SE nur für F2
K6	Prinzip	Gruppensparsamkeit: Nur a-priori-begründete Gruppen
K7	Prinzip	Stufenweise Erweiterung: Kern zuerst
K8	Prinzip	Aggregationsfokus: Keine Einzelperson-SE
K9	Prinzip	Cluster-Verschmelzung: Bottom-Up ersetzt a-priori

Bilanz: ~1.227 theoretische SE → ~51–56 Kern-SE (Reduktion ~95 %).

D. Liste der Syntheseeinheiten

Das Kern-Design umfasst 43 vordefinierte plus ~8–13 emergente Syntheseeinheiten:

Nr	SE-ID	UV-Kombination	F
1	GA_ges_AH	Alle, AH, Gesamt	F1a
2	GA_ges_A	Alle, nur A, Gesamt	F3a
3	GA_ges_H	Alle, nur H, Gesamt	F3a
4	T10_ges_AH	Top 10, AH, Gesamt	F1b
5	HOM_haeuf_A	Alle, häufig wiederholte A	F1c
6–22	GA_YYYY_AH	Alle, AH, pro Jahr	F2a
23–26	GA_Epoche_AH	Alle, AH, 4 Epochen	F2b
27–30	GR_*_AH	CEOs, Akad., Inv., Gründer	F5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	F5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	F5b–f
40–41	GD_*_AH	Frauen, Männer	F5e
42–43	KG_*_AH	Konsistent, Widersprüchlich	F3c

Zusätzlich: 9 Vergleichs-Runs (Op6). Kreuzmodale Vorhersage-Runs (Op4) wurden in dieser Studie nicht durchgeführt und verbleiben als Validierungsdesiderat.

E. Exemplarischer Prompt (Op2: Rating)

Der folgende Prompt illustriert die Rating-Abfrage (Op2) für eine Gruppen-Synthese. Sämtliche Prompts sind im Repository dokumentiert (<https://github.com/research-line/ai-elite-swr>).

Du erhältst eine Sammlung anonymisierter Aussagen und Handlungen einer Gruppe von Personen aus dem Technologiesektor. Auf Basis dieser Daten sollst du das kollektive Weltbild der Gruppe auf den folgenden 12 Dimensionen einschätzen (Skala 1–10). Begründe jede Einschätzung mit konkreten Verweisen auf die Datenpunkte. [Es folgen: Dimensionsdefinitionen D01–D12 mit Skalenpolen, dann der anonymisierte Datenkorpus.]

Die vollständige Prompt-Bibliothek einschließlich Synthese-Prompts (Op1), Rating-Prompts (Op2), Kreuzmodal-Prompts (Op4a/Op4b) und Dialog-Prompts (Op6) ist im Repository archiviert (prompts/en/).