

Worldview Reconstruction of the AI Elite:

An LLM-Assisted Analysis of the 100 Most Influential Actors in Artificial Intelligence (2010–2026)

Lukas Geiger*

Independent Researcher, Bernau, Germany

May 2026

Abstract

This study reconstructs the collective worldviews of sociologically defined groups within the 100 most influential AI actors between 2010 and 2026. To address the research questions, the study develops synthetic worldview reconstruction (SWR) – an LLM-assisted synthesis method that reconstructs coherent belief systems from group-aggregated data, here operationalized along 12 worldview dimensions. The reconstructed collective profile suggests a *technological messianism with ambivalence structure*: a high sense of mission and techno-determinism combined with low anthropological valuation and egalitarianism. Longitudinally, the data indicate a transition from utopian techno-optimism to tragic acceleration compulsion. A group-level say-do decomposition indicates a Simpson’s-paradox pattern: the aggregate gap is indistinguishable from measurement noise, but group-specific gaps are substantial – CEOs exhibit a classical desirability gap (rhetoric more egalitarian than action), while risk warners show prophetic consistency (articulating feared futures they actively work to prevent). An influence-strata analysis suggests that the most powerful actors are assigned the most intense worldviews, with human appreciation decreasing as influence rank rises. Four worldview types are identified – Architect, Guardian, Innovator, Liberator – whose inter-group comparisons point to a power-moderation paradox. The strongest predictors of worldview difference are ideological stance, institutional role, and gender. The primary contribution lies in nine systematic inter-group analyses indicating how structural position may shape collective belief within the AI elite. All findings rest on LLM-generated reconstructions and should be understood as empirically supported hypotheses.

Keywords: AI elite, collective worldview, group analysis, transhumanism, large language models, Silicon Valley, ideology analysis, computational social science

*Corresponding author: Lukas Geiger, Bernau, Germany. ORCID: <https://orcid.org/0009-0005-7296-1534>

1. Introduction

1.1 Lead-in and Relevance

A small number of people are shaping a technology that affects billions. Over the past one and a half decades, the development of artificial intelligence has evolved from an academic niche topic into a central issue of social governance. Large language models generate texts, images, and code; autonomous systems make decisions in medicine, law, and finance; and leading AI laboratories openly speak of creating artificial general intelligence in the foreseeable future (OpenAI, 2023; Anthropic, 2023; Bengio et al., 2024). What is often overlooked is that behind these technological trajectories stand concrete groups – CEOs, academics, investors, founders – whose *collective* beliefs about the nature of humanity, the purpose of progress, and the distribution of risk and power flow into the architecture of the systems they build. Understanding these belief systems requires moving beyond individual portraits toward a systematic group-level analysis: What do CEOs believe compared to academics? How do accelerationists differ from risk warners? What collective trends emerge across a decade and a half of AI development?

Lessig (1999) coined the formula “code is law”: software architecture regulates behavior no less effectively than laws, but without democratic legitimation. This insight can be extended to current AI development: not only the code itself, but also the *worldviews* of the developers enter algorithmic design. Those who believe that information freedom is an absolute value will build open-source models. Those convinced that an uncontrolled superintelligence threatens humanity tend to pursue alignment and closed systems. The worldviews of the AI elite are thus not merely private opinions; they are *generative structures* that translate into design decisions, corporate strategies, and political positions – and through these channels shape the lives of billions. Crucially, these belief structures are not merely idiosyncratic but exhibit systematic group-level patterns: CEOs think differently from academics, accelerationists from risk warners, men from women. It is these *collective* patterns – not the idiosyncrasies of any single actor – that constitute the ideological infrastructure of AI development and that democratic societies need to understand.

This raises a central problem for democratic theory. A numerically tiny group makes decisions of society-wide consequence without possessing a democratic mandate. Crawford (2021) has described this as an “Atlas of AI”: the planetary power structures behind AI systems remain largely invisible. Zuboff (2019) analyzes how the extraction of behavioral data leads to a new economic logic (“Surveillance Capitalism”) that undermines democratic control. Couldry and Mejias (2019) coin the term “Data Colonialism”: the exploitation of human life as a data resource. Whittaker (2021) analyzes the concentration of power in AI research and its “steep costs” for society. The beliefs of the groups involved shape these decisions in ways that are difficult for the public to scrutinize or contest (Floridi, 2019, 2023). If democracies presuppose informed citizens, then the systematic reconstruction of the worldviews of those who shape the

most powerful technology of the 21st century is not merely an academic concern but a prerequisite for informed public deliberation.

1.2 Research Gap

The scholarly engagement with the belief systems of the AI industry has produced various approaches. At the level of ideology critique, [Barbrook & Cameron \(1996\)](#) described the “Californian Ideology”; [Morozov \(2013\)](#) elaborated the tendency toward solutionism; [Daub \(2020\)](#) analyzed the rhetorical and ideological patterns of Silicon Valley as a cultural phenomenon. From transhumanism research, philosophical analyses exist ([Bostrom, 2005](#); [More & Vita-More, 2013](#); [Coeckelbergh, 2020](#)), which, however, primarily address intellectual history rather than the empirical distribution of these beliefs.

What is still *missing* in this research field is a systematic, data-driven analysis of the AI elite as a *structured collective* – one that distinguishes between sociologically meaningful subgroups and maps their respective belief systems. To the author’s knowledge, no existing study examines the following questions in an empirically systematic way: How do the collective worldviews of different groups within the AI elite (CEOs vs. academics, accelerationists vs. risk warners, men vs. women) relate to each other? Do they form coherent types? How have these group-level worldviews changed over the period 2010 to 2026? And do public beliefs align with actual behavior at the group level? Empirical elite research is also relevant here: [Mills](#)’s analysis of the “power elite” as interlocking networks of business, military, and political power provides a structural model that appears transferable to the AI elite, with technological competence replacing military power as the central resource.

Beyond this empirical gap, there is a *methodological* gap. Few established methods support the systematic reconstruction of worldviews from public statements at scale. Classical qualitative methods do not scale easily; standardized surveys require access to respondents; quantitative text-mining approaches often capture surface patterns rather than latent belief structures. The present study responds to this dual gap with a new approach – synthetic worldview reconstruction (SWR) – whose methodology is presented in full in Section 3.

1.3 Research Questions

From the described research gap, six research questions are derived, arranged in a stepwise logic:

RQ1: WORLDVIEW (descriptive)

What does the AI elite think about itself, the world, and humanity?

RQ2: CHANGE (longitudinal)

How has the worldview of the AI elite changed from 2010 to 2026?

RQ3: CONGRUENCE (validating)

Do the AI elite’s statements and actions align?

RQ4: CLUSTERS (exploratory)

What worldview types exist within the AI elite, and who belongs where?

RQ5: DIFFERENCE (comparative)

Which subgroups of the AI elite think differently from others?

RQ6: POWER (normative)

Which worldview commands the most power and resources?

1.4 Contribution of the Study

The study makes a threefold contribution. *Methodologically*: To address the research questions, the study develops the synthesis pipeline of synthetic worldview reconstruction (SWR; see Section 3) – an LLM-assisted method for synthesizing group-aggregated data into coherent collective belief representations – and applies dimensional rating as one specific operationalization of this pipeline to the empirical material of this study. *Empirically*: It provides a systematic worldview analysis of the AI elite as a structured collective, based on 3,132 data points spanning 16 years and differentiated across 9 systematic inter-group comparisons (by role, stance, gender, company, epoch). *Societally*: It offers a basis for informed public deliberation by identifying the collective ideological patterns – trends, group differences, say-do gaps – that shape AI governance and design decisions.

2. Literature Review

The study situates itself at the intersection of four research traditions.

2.1 Silicon Valley as Ideology

Critical engagement with the thinking of Silicon Valley has produced a rich literature since the mid-1990s. [Barbrook & Cameron \(1996\)](#) coined the term “Californian Ideology” – the paradoxical fusion of libertarian individualism and techno-utopian optimism. [Turner \(2006\)](#) traced the cultural-historical genealogy of this ideology and showed how the counterculture of the 1960s was transformed into digital utopianism. [Daub \(2020\)](#) uncovered the philosophical deep structures: fragments from Heidegger, Ayn Rand, and Puritan predestination doctrine form a “surprisingly narrow philosophical foundation.” [Morozov \(2013\)](#) described solutionism – the default attitude of redefining complex social problems as technical challenges. [Gebru & Torres \(2024\)](#) systematized these currents in the TESCREAL framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, and Longtermism as an

“interconnected bundle.” Additionally, [Broussard \(2018\)](#) coined the term “technochauvinism” for a systematic critique.

Previous research has thus described the *ideology* of Silicon Valley at various levels. What it has not achieved is a systematic empirical mapping of the *concrete worldviews* of real actors.

2.2 Transhumanism and AI Eschatology

[Bostrom \(2014\)](#) defined the conceptual framework in which a significant part of the AI elite has since operated with *Superintelligence*. In earlier work, [Bostrom \(2005\)](#) systematized the intellectual-historical foundations of transhumanism. [More \(2003\)](#) presented the founding document of extropianism with the “Principles of Extropy.” [Kurzweil \(2005\)](#) popularized the tradition with the Singularity thesis. From a philosophical perspective, [Habermas \(2001\)](#) formulated one of the most significant counter-positions: the technological manipulation of future persons undermines their autonomy.

The empirical question remains unresolved: Do real AI actors share these convictions? In what mixture, with what modifications, and in what distribution?

2.3 Worldview Research and Sociology of Knowledge

[Mannheim \(1929\)](#) founded the tradition of analyzing worldviews as social phenomena with his theorem of the “situational determination of thought” (*Seinsgebundenheit des Denkens*). [Weber \(1904\)](#) created with the ideal type a methodological tool central to the present study: the synthetic personas of the SWR can be understood as ideal types in the Weberian sense. [Berger & Luckmann \(1966\)](#) showed how worldviews emerge, stabilize, and reproduce as social constructions. The sociology-of-knowledge tradition provides the theoretical framework, but no method suited to the data volume and dynamics of the digital age.

2.4 LLMs as a Research Instrument

The use of large language models as instruments for social-scientific research is a rapidly expanding field. [Tai et al. \(2024\)](#) examined LLMs for deductive coding; [Hayes \(2025\)](#) showed that LLMs enable a conversational approach to qualitative data; [Nicmanis & Spurrier \(2025\)](#) provide a practice-oriented introduction. [Ornstein et al. \(2025\)](#) show that LLMs can perform multidimensional ideological scaling with high reliability – direct methodological support for the SWR approach. Work on synthetic personas ([Ge et al., 2024](#)) has demonstrated the scalability of this broader approach but pursued a *different* goal: it uses synthetic personas for *data generation*, whereas the present study uses them for *reconstruction* of coherent worldviews from *real* data. The synthetic persona in our procedure is not a simulacrum but an analytical condensation instrument – closer to the Weberian ideal type than to the simulation agent (cf. [Booth, 1961](#); [Ng & Russell, 2000](#); [Jara-Ettinger, 2019](#)).

2.5 Summary: The Research Gap

The four traditions converge on a shared lacuna: the systematic, data-driven, longitudinal mapping of concrete worldviews of the AI elite by means of a method that combines qualitative depth with quantitative rigor. The present study addresses this converging gap by integrating elements of all four traditions.

3. Methodology

This section presents the implemented methodology. Synthetic worldview reconstruction (SWR) is an LLM-assisted method for inferring collective belief systems from publicly observable data. Its working premise is that worldview analysis can be formulated as an inverse problem: given the observable outputs (statements and actions) of a sociologically defined group, reconstruct the latent belief system that would most coherently generate these outputs. The method uses the capacity of large language models to synthesize heterogeneous textual evidence into coherent representations – not by retrieving stored knowledge about individuals, but by constructing a collective portrait from the presented data. This section is self-contained for evaluation and replication.

3.1 Data Collection

3.1.1 Sample and Selection Procedure

The object of investigation is the 100 most influential figures in the field of artificial intelligence (hereafter: AI elite). Selection followed a multi-stage procedure: through 22 systematic web searches, 187 candidates were identified. Each person was evaluated using a 6-category scoring system: (1) market capitalization/resource control, (2) key technological positions, (3) public discourse power, (4) academic influence, (5) political influence, (6) symbolic status. The resulting ranking was reduced to 100 individuals, mapping the heterogeneity of the field with respect to roles, company affiliations, stances, and gender (cf. Appendix A).

3.1.2 Data Sources and Collection Period

The collection period extends from January 1, 2010 to February 11, 2026. Data collection draws on two data types: **public statements** (verbatim quotes from interviews, keynotes, podcasts, Twitter/X posts, blog entries, books, congressional hearings) and **observable actions** (investment decisions, company formations, personnel decisions, political activities, product launches). The linkage was operationalized in a relational SQLite database with 9 tables and 5 views. The total corpus comprises 1,738 statements and 1,394 actions (3,132 data points). After applying inclusion/exclusion criteria (see below), 1,735 statements were retained for analysis (3 near-duplicates excluded, 4 edge cases flagged and included).

Data density per actor. The number of data points per actor ranges from 20 (minimum) to 72 (maximum), with a mean of 31.3 (SD ≈ 12). Temporal distribution is unbalanced: the years 2010–2011 contribute only 17 data points each, while 2024 contributes 735. This imbalance reflects the exponential growth of public AI discourse and is addressed through epoch-level aggregation in the longitudinal analysis (Section 4.2).

Data quality. Automated metadata verification of all 1,735 included statements shows: 95.2% carry a source link, 94.5% a source title, and 95.3% a date of utterance. A manual spot check of 20 randomly drawn statements confirmed that all links lead to verifiable sources (CNBC, Financial Times, Stanford University, Twitter/X, corporate websites).

3.1.3 Methodological Anchoring

Data collection follows a systematic coding protocol inspired by qualitative research methodology (Strauss & Corbin, 1990): in Phase 1, no content filters were applied; in Phase 2, patterns were identified through open coding; in Phase 3, a data-driven category system with 13 primary categories and 13 secondary markers was developed (6,161 total codings, avg. 3.5 codes per statement). Inclusion and exclusion criteria were formulated only in Phase 5 (3 near-duplicates excluded); in Phase 6, quality assurance was conducted (automated metadata verification of all statements plus manual spot check of $n = 20$).

3.2 The Method of Synthetic Worldview Reconstruction

SWR defines worldview analysis as an inverse problem: from the aggregated observable statements and actions of a *group's* members, it infers the collective belief system W_G^* that would most coherently generate these outputs. Formally: given the set of all public statements $\{A_1, \dots, A_n\}$ and documented actions $\{H_1, \dots, H_m\}$ of a sociologically defined group G , reconstruct W_G^* such that the totality of observed outputs is maximally coherent under W_G^* . The solution consists of constructing a *fictive synthetic person* – a Weberian ideal type that represents the group’s worldview in ideal-typical form, reducing individual biographical noise and PR strategies.

SWR uses a structural advantage of group-level analysis: no LLM training corpus is likely to contain “the collective worldview of CEOs” or “the shared belief system of risk warners” as a pre-formed object. The collective worldview is *created* by the synthesis, not retrieved from memory. This may reduce the contamination risk that is the primary methodological concern for LLM-based reconstruction – an advantage that does not hold to the same degree for individual-level analysis, where the LLM may draw on extensive stored knowledge about specific public figures.

In the present study, the primary units of analysis are sociologically defined groups (CEOs, academics, investors, founders, women, men, accelerationists, risk warners, etc.); the 100 individuals serve as data providers whose statements and actions are aggregated at the group

level. The theoretical anchoring draws primarily on Weber’s ideal type – a tradition explicitly designed for group-level analysis – complemented by Booth’s *implied author*, inverse reinforcement learning, and projective tests. The operative procedure comprises five steps: (1) compile group-level data corpus, (2) LLM-assisted synthesis of a fictive synthetic person, (3) structured interview on self-image, worldview, and view of humanity, (4) meta-reflection on internal tensions and blind spots, (5) dimensional rating on 12 dimensions (D01–D12). Steps 1–4 constitute the synthesis pipeline and represent the core methodological innovation; Step 5 (dimensional rating) is one specific operationalization chosen for this study and is in principle exchangeable with other analysis methods such as discourse analysis, psychometric scales, or structured interview protocols. The focus control infrastructure, the rationale of the fiction approach, and the validation framework are detailed in the quality assurance section below (Section 3.6). The method’s transferability to other populations (political, military, religious elites) is a natural extension that requires separate investigation.

3.2.1 Data Aggregation Procedure

Group-level syntheses operate directly on the pooled raw data – not on aggregated individual profiles. For each synthesis unit (e.g., “all CEOs”), the statements and actions of all group members are concatenated into a single dossier, ordered chronologically, and presented to the LLM as one input. The LLM then constructs a fictional synthetic person whose worldview best explains the totality of the presented group data. Crucially, no intermediate individual-level aggregation occurs: the collective portrait emerges directly from the pooled evidence, analogous to how a historian reconstructs an era’s *Zeitgeist* from primary sources rather than from averaged biographies. The 100 individual-level rating profiles were generated separately for a single technical purpose: providing the 100×12 data matrix required for algorithmic structure checks (PCA, HDBSCAN, Kruskal-Wallis). They do not enter the group-level synthesis pipeline and are not reported as substantive findings.

3.3 Operationalizations

The three dependent variables (DV1: self-image, DV2: worldview, DV3: view of humanity) are made accessible through six operationalizations defined in the SWR framework, of which five were applied in this study (Op1, Op2, Op4, Op5, Op6):

The 12 rating dimensions (Op2) are evenly distributed across the three DVs: self-image dimensions D01–D04 (sense of mission, self-efficacy, work ethic, sense of responsibility), worldview dimensions D05–D08 (techno-determinism, belief in progress, power concentration, urgency), and view-of-humanity dimensions D09–D12 (human appreciation¹, posthumanism,

¹The label “human appreciation” (*Menschenfreundlichkeit*) is a simplifying shorthand. The scale poles “Replaceable” (1) vs. “Unique” (10) more precisely measure an *anthropological valuation* – the question of whether human consciousness and experience are regarded as fundamentally non-substitutable or as functionally reproducible. The term is retained for consistency across the study.

Table 1: The six operationalizations of the SWR.

Op	Technique	Description	MVs
Op1	T1 Core synthesis	Fictive person + 3-question interview + reflection	7
Op2	T4 Rating	Assessment on 12 dimensions (D01–D12), scale 1–10	12
Op3	Text analysis	TF-IDF, sentiment, metaphors, embeddings, topics	8+
Op4	T3 Cross-modal	Prediction: statements $\rightarrow$ actions (5 groups, 72% confirmed, 0% contradicted)	4
Op5	T5 Clustering	PCA + HDBSCAN on rating matrix (see Section 4.4)	6
Op6	T2 Dialogue	Structured comparison of two syntheses	3

Op3 (text analysis) was not conducted. Op5 was implemented as PCA + HDBSCAN on the 100×12 rating matrix, not as Sentence-BERT clustering.

egalitarianism, locus of control). The complete dimension table with scale poles is provided in Appendix B.

3.4 Research Design

3.4.1 Variable Architecture

The research design is conceived as a four-tier architecture: 3 DVs $\rightarrow$ 6 operationalizations $\rightarrow$ 50+ measured variables $\rightarrow$ 6 independent variables (IVs). The IVs determine which data enter a synthesis unit (SU), with each SU representing a *group-level* synthesis – the collective worldview of a sociologically defined subgroup.² The IVs are:

- IV1 *Time period*: Individual years (2010–2026), epochs, entire period
- IV2 *Modality*: Statements+actions (SA), statements only (S), actions only (A)
- IV3 *Person group*: All 100, Top 10, subgroups (roles, companies, stance, gender)
- IV4 *Content category*: Replaced by emergent clusters (K9)
- IV5 *Congruence status*: Consistent vs. contradictory
- IV6 *Homogenization*: All vs. only frequently repeated statements

3.4.2 Systematic Reduction

The theoretical combination space of approx. 1,227 possible SUs was reduced through nine reduction criteria (K1–K9; cf. Appendix C) to 51–56 core SUs (95.4% reduction). Additionally, 9 structured comparison runs (Op6) were conducted. Cross-modal prediction (Op4) was conducted for five groups with strict instance separation: statement-based behavioral predictions were confirmed or rated plausible by real actions in 98% of cases, with 0% contradictions (see Section 3.6).

²SU identifiers follow a systematic naming convention: prefix indicates the group type (GA=global all, GR=role, GF=company, GH=stance, GD=gender), suffix indicates data mode (AH=statements+actions, A=statements only, H=actions only). For example, GR_ceo_AH denotes the synthesis unit containing all statements and actions from the CEO subgroup. A complete list is provided in Appendix D.

3.4.3 Mapping: Research Questions, Operationalizations, and Core SUs

Table 2 gives a compact overview of which operationalizations and synthesis units are assigned to the six research questions.

Table 2: Mapping of research questions, operationalizations, and core SUs.

RQ	Ops	Core SUs	Object
RQ1	Op1, Op2, Op3	1, 4, 5	Collective and Top-10 profile, core beliefs
RQ2	Op2, Op3	6–26	Yearly and epoch syntheses, trends
RQ3	Op2, Op4	2, 3, 42–43	Statements vs. actions, congruence test
RQ4	Op2, Op5	27–41	Group syntheses, cluster identification
RQ5	Op2, Op6	27–41	Subgroup comparisons
RQ6	Op2	4, 27–30	Power-worldview relationship

3.5 Researcher Positioning

The author is an independent researcher without institutional affiliation to any of the companies or research labs under study. This outsider position allows greater distance from the object of inquiry but also brings specific blind spots: (a) lack of access to internal discourses and non-public positions; (b) dependence on publicly available sources, which may be filtered through public relations; and (c) a potential tendency to overestimate the coherence and closure of the group under study because internal diversity is less visible from the outside. The study is furthermore situated as a German-language analysis of a predominantly English-language discourse, which may introduce nuances in transfer and interpretation.

3.6 Quality Assurance

Methodological quality is addressed through four design measures, four completed post-hoc validations, and one remaining open task. *Design measures*: (1) minimum size of 15 data points per SU³, (2) consistent focus control via a blinding script that replaces all person names, company names, product names, and university affiliations with neutral placeholders, designed to encourage the LLM to process the presented data rather than fall back on stored knowledge, (3) reproducibility protocol (temperature 0, complete prompt documentation, all prompts archived in the repository), and (4) algorithmic structure check of the cluster structure via PCA and HDBSCAN on the 100×12 rating matrix. *Open validation task*: inter-model replication (independent replication of the full analysis with at least one additional frontier model by other researchers) remains outstanding; this constitutes external replication, not a prerequisite for the present study’s internal validity. *Completed validation*: (a) **Intra-Model Inter-**

³The threshold of 15 data points is based on methodological reasoning: in qualitative social research, 6–12 interviews are considered sufficient for thematic saturation (Strauss & Corbin, 1990), while more recent estimates typically place thematic saturation between 12 and 20 units (Guest et al., 2006; Fugard & Potts, 2015). The value of 15 is conservatively chosen to ensure sufficient data density for LLM-assisted synthesis.

Instance Rating Reliability (IMIIRR): Five group-level synthesis units were each processed twice independently by Claude Opus 4.6. The resulting D01–D12 profiles showed excellent convergence: overall Pearson $r = 0.908$, $\text{ICC}(2,1) = 0.902$, $\text{MAE} = 0.40$ on the 10-point scale (measurement precision ± 0.2 scale points). All 12 dimensions were stable across runs (mean $|\Delta| \leq 0.8$). A subsequent validation with $N = 15$ fully independent Opus instances — each a separate agent with no shared context — on a single group-level synthesis unit (GA_ges_AH) supported this finding with greater statistical power: $\text{ICC}(3,1) = 0.847$, mean $\text{SD} = 0.45$ across all 12 dimensions (range: 0.00–0.74). Notably, one dimension (D02, self-efficacy) showed perfect agreement: all 15 instances assigned exactly the same rating. The remaining dimensions varied by at most ± 1 point (10 of 12 had only 2 unique values across 15 runs). These IMIIRR coefficients exceed typical human inter-rater reliability in qualitative coding ($\text{ICC} = 0.6\text{--}0.8$; Hallgren 2012) and support treating Claude Opus 4.6 as a calibrated instrument for this SWR implementation.

(b) **Expected-discrepancy control:** A synthetic control corpus of a fictional consistent group (environmental scientists, 30 statements + 30 actions with no deliberate say-do gap) was processed through the same pipeline in two conditions: (v1) same instance for both data types ($\text{MAE} = 0.50$, $r = 0.912$), and (v2) strict instance separation where statements and actions were processed by independent agents ($\text{MAE} = 0.92$). The v2 baseline is methodologically appropriate because the real say-do comparison also uses instance separation. By comparison, the real AI elite say-do gap under matching conditions is $\text{MAE} = 0.75$ (v2), which falls *below* the v2 control baseline – indicating that the aggregate gap is not reliably distinguishable from measurement noise. However, the group-level decomposition (see Section 4.3) indicates that this aggregate masks substantial group-specific gaps (CEOs: $\text{MAE} = 1.08$; risk warners: $\text{MAE} = 1.92$), both above baseline.

(c) **Aggregation-synthesis comparison:** To assess the group-level synthesis approach, the D01–D12 profiles from direct group syntheses (pooled raw data) were compared with aggregated individual-level profiles (averaged ratings of group members) across all 15 sociological groups. The overall correlation ($r = 0.623$, $\text{MAE} = 1.30$) shows moderate convergence, with a systematic *amplification effect*: direct group syntheses produce sharper contours (71.7% of dimension-group combinations further from midpoint). Convergence is highest for ideologically homogeneous groups (Open Source $r = 0.857$, Accelerators $r = 0.855$) and lowest for heterogeneous ones (Women $r = 0.428$, Men $r = 0.549$). This effect is interpretable as group-level coherence amplification, analogous to group polarization in social psychology.

(d) **Cross-modal prediction (Op4):** For five sociological groups (CEOs, academics, risk warners, investors, accelerators), ten behavioral predictions were generated exclusively from the statement corpus by a first agent instance (Op4a); these predictions were then evaluated against the actual documented actions by a *separate* agent instance (Op4b) that had never seen the original statements — reducing confirmation bias. Of 50 predictions, 36 (72%) were directly matched by real actions, 13 (26%) were plausible but lacked a direct match, and 0 (0%) were contradicted. Confirmation rates varied by group type: ideologically coherent groups showed the highest predictability (academics and risk warners: 90% confirmed each),

while heterogeneous groups showed lower but still substantial rates (investors and accelerators: 50% confirmed each, with an additional 40–50% plausible). The unpredicted actions — political opportunism, massive commercial activity despite cautionary rhetoric, internal governance crises — are precisely the phenomena that the say-do analysis (RQ3) was designed to detect.

(e) **Anonymization robustness test:** To assess whether the anonymization approach affects the results, the same synthesis unit (risk warners, 139 statements + 92 actions) was processed with three blinding strategies: (A) placeholder tokens ([PERSON], [COMPANY]), (B) plausible fictional names, and (C) full disclosure of real identities (Musk, Sutskever, Hinton, Russell, Bengio, Leike). Variants A and B were nearly identical ($r = 0.987$, $\text{MAE} = 0.33$). Variant C showed a moderate but not drastic increase: A–C $\text{MAE} = 0.67$, $r = 0.850$, with the same group average (7.1). The largest shift was D11 (egalitarianism, +2 points with identity knowledge). This confirms that anonymization provides a measurable but modest protection; group-level ratings are robust even when identities are known.

(f) **Rating order invariance:** The same synthesis (risk warners) was rated with two different permutations of the D01–D12 dimension list. All 12 ratings were identical across permutations, confirming that there is no list-order effect in the rating procedure.

(g) **Instance separation analysis:** A systematic review of historical analysis records revealed that the original say-do comparison (GA_ges_A vs. GA_ges_H, Batch 1) was conducted within the same LLM instance – violating the principle of independent measurement. When repeated with strict instance separation (each data type in its own agent), the say-do gap shrank from $\text{MAE} = 1.42$ to $\text{MAE} = 0.75$ (–47%). The control group gap (G6) increased from $\text{MAE} = 0.50$ to $\text{MAE} = 0.92$ under the same conditions. Consequently, the v2 say-do gap falls below the control baseline, indicating that the overall gap magnitude is not reliably distinguishable from measurement noise in single runs. However, two specific dimensions remain stable across both versions: D07 (power concentration: +2, actions more concentrated) and D11 (egalitarianism: –2, actions less egalitarian). These constitute the study’s robust say-do findings.

(h) **Anthropic matched-sample control:** To test whether Claude exhibits systematic bias toward its creator organization, the Anthropic subgroup ($n = 9$) was compared with a matched control group of non-Anthropic founders and researchers ($n = 9$, same size and role composition). The resulting profiles showed $\text{MAE} = 1.00$ with no $|\Delta| \geq 3$ on any dimension. The observed differences (Anthropic: higher urgency and power concentration; control: higher posthumanism and locus of control) are interpretable as genuine group differences rather than model bias.

(i) **Outlier detection:** For five groups, the reconstructed worldview was confronted with the original data to identify statements and actions that do *not* fit the synthesis. Overall fit ranged from 80% (risk warners) to 88% (CEOs), with 6–8 identifiable outliers per group. The method does not smooth all data into coherence; dissenting voices, internal contradictions, and political heterogeneity remain detectable.

(j) **Inversion control (anti-coherence test):** For five groups, fictional anti-persons were constructed whose worldviews maximally *contradict* the presented data. In 58% of dimension-group combinations, the anti-profile differed by ≥ 5 points from the coherent reconstruction, confirming that the coherent interpretation is a specific,

data-supported choice – not the only possible reading. (k) **Influence strata comparison:** Three rank-based strata (Top 10: ranks 1–10, avg 7.7; Middle: ranks 40–60, avg 6.4; Bottom 10: ranks 91–100, avg 6.1) were independently synthesized and rated. The comparison indicates an influence gradient: the most powerful actors are assigned the most intense worldviews. Two dimensions showed an *inverse* gradient: D09 (human appreciation: Top 4, Middle 6, Bottom 8) and D10 (posthumanism: Top 8, Middle 5, Bottom 3) – the most powerful actors are reconstructed as the most posthumanist and least human-appreciating. (l) **Inter-model comparison (desideratum):** An inter-model comparison — replicating the full Op1+Op2 pipeline with a different model (e.g., Claude Haiku, GPT-4, Gemini) using $N \geq 15$ fully independent single-instance runs — remains outstanding. Preliminary experiments with Claude Haiku 4.5 suggested systematic model-specific differences in interpretive emphasis (more moderate, more humanistic profiles) but could not meet the strict independence criterion established by the $N = 15$ Opus validation (separate agent per run, no shared context). A methodologically rigorous inter-model comparison is identified as a priority for future work and would establish whether the observed worldview profiles are instrument-invariant or model-specific.

All syntheses in the present study were generated using Claude (Anthropic): Claude Sonnet 4.5 for individual-level ratings (9 parallel batch agents), Claude Opus 4.6 for group-level qualitative syntheses, statistical analyses, and all validation experiments. No other LLM was used. The focus control infrastructure addresses what is conventionally termed *contamination risk*: the possibility that the LLM draws on stored knowledge rather than the presented data. We prefer the term “focus control” because the goal is not to prevent recognition of individuals—which is neither possible nor necessary for group-level analysis—but to ensure *task compliance*: the model should synthesize from the provided data, not reproduce stereotypes.

3.6.1 Dimensionality of the Rating Space

The 100 individual rating profiles were generated during the data collection phase by Claude Sonnet 4.5 (9 parallel batch agents), where each actor’s public statements and actions were synthesized into a 12-dimensional worldview profile in a single run at temperature 0. These individual profiles were generated for a single technical purpose: providing the 100×12 data matrix for algorithmic structure validation (PCA, HDBSCAN). They do not enter the group-level synthesis pipeline – the group syntheses operate directly on pooled raw data (Section 3). The individual-level matrix is thus a structural validation instrument, not a substantive finding.

A principal component analysis (PCA) of the 100×12 rating matrix reveals that **five components** explain 80% of the total variance, indicating that the twelve dimensions capture approximately five independent constructs. PC1 (35.8% variance) loads most strongly on D02 (self-efficacy, +0.40), D05 (techno-determinism, +0.39), and D09 (human appreciation, −0.39) – a *technology-control factor* opposing technophile agency and anthropological valuation. PC2 (19.2% variance) loads on D01 (sense of mission, +0.51), D04 (responsibility, +0.50), and D08 (urgency, +0.50) – an *engagement factor* capturing motivational intensity independent of

ideological direction. The moderate redundancy (5 effective dimensions out of 12) suggests that the dimensional system is neither maximally efficient nor artificially inflated; it represents a reasonable operationalization for exploratory work.⁴

4. Results

The findings are based on group-level synthetic worldview reconstructions derived from the data of the one hundred most influential AI figures, operationalized via twelve dimensions on a ten-point scale. The 100 individuals serve as data providers; the units of analysis are sociologically defined groups (all 100, Top 10, CEOs, academics, investors, founders, men, women, accelerationists, risk warners, companies, epochs). The central contribution of the results section lies in the inter-group comparisons (RQ4–RQ6), which examine how structural position is associated with differences in reconstructed collective belief. In what follows, *worldview* refers to the overall system of self-image, world-image, and view of humanity (operationalized via DV1–DV3); the term *belief system* is used synonymously but places stronger emphasis on the structural interrelation of the individual dimensions.

Statistical status note. All quantitative analyses in this section – PCA, HDBSCAN, Kruskal-Wallis, Cliff’s δ , Spearman correlations – operate on LLM-generated ratings, not on independently measured variables. The reported *p*-values, effect sizes, and correlations describe *patterns within the LLM reconstruction space*; they do not carry the inferential weight of tests on independent empirical measurements. Their function is *structure detection*: identifying regularities and contrasts in the reconstructed data that merit substantive interpretation. This approach is analogous to exploratory factor analysis or cluster analysis in qualitative research, where statistical tools serve pattern identification rather than hypothesis testing.

4.1 RQ1 – Worldview of the AI Elite (Descriptive)

4.1.1 The Collective Worldview of All 100

The overall profile – the collective worldview of all 100 actors treated as a single group – suggests a coherent, high-intensity belief system with a mean value of 7.1 (Table 3).⁵

The profile displays a characteristic dual structure: a pronounced elitist self-image (D01–D03 each 8), strong techno-determinism (D05=8), and high urgency (D08=8) on one hand; human appreciation (D09=5) and egalitarianism (D11=5) as the lowest points on the other. This

⁴Descriptive statistics confirm this structure: D11 (egalitarianism) shows the largest dispersion (SD = 1.67) – the dimension of greatest worldview divergence – while D03 (work ethic) shows the smallest (SD = 0.74), representing the strongest consensus within the AI elite.

⁵All ratings reported in this study are LLM-generated *group-level* syntheses: the model receives the aggregated data of a sociologically defined group and produces a single collective profile. Individual-level ratings are used only for algorithmic structure check (PCA, HDBSCAN), not as substantive findings. Each synthesis was generated in a single run at temperature 0; multi-run convergence testing remains an open validation task. This design is intentional: the study aims at collective worldviews of groups, not individual profiles.

Table 3: Collective profile of the AI elite ($N = 100$, statements and actions).

Dimension	Rating	Interpretation
D01 Sense of mission	8	High
D02 Self-efficacy	8	High
D03 Work ethic	8	High
D04 Sense of responsibility	7	Medium-high
D05 Techno-determinism	8	High
D06 Belief in progress	7	Medium-high
D07 Power concentration	6	Medium (ambivalent)
D08 Urgency	8	Very high
D09 Human appreciation	5	Low
D10 Posthumanism	7	Medium-high
D11 Egalitarianism	5	Low
D12 Locus of control	8	High
Mean	7.1	

combination produces a striking pattern that – bearing in mind that these are LLM-reconstructed values – can be pointedly formulated: an elite that wants to build *for* humanity but not *with* it.

4.1.2 The Worldview of the Top 10

The ten most powerful AI actors are reconstructed as holding the same worldview in a more intense form (Avg 7.7). On ten of twelve dimensions, Top 10 values lie exactly one scale point above the collective. The two exceptions – human appreciation (D09=4) and egalitarianism (D11=4) – are *lower*. The more powerful the position, the more pronounced the sense of mission and the more detached the view of humanity.

4.1.3 Core Beliefs

The distillation of the most frequently repeated statements (SU 5: HOM_haeuf_A, cf. Appendix D) identifies five beliefs as the minimal consensus: (1) technology as moral imperative, (2) elite stewardship, (3) the liberation narrative, (4) geopolitical Manichaeism, (5) work as identity. Safety rhetoric belongs to the core repertoire of the discourse but functions as a discursive resource, not as an action-guiding belief.

Core finding RQ1: The reconstructed profiles suggest a coherent, high-intensity belief system that can be characterized as *technological messianism with ambivalence structure*. The designation “messianism” is to be understood as an ideal-typical condensation, not as a psychological diagnosis: it denotes the specific *combination* of high sense of mission (D01), techno-determinism (D05), urgency (D08), and low anthropological valuation (D09) – a profile that goes beyond mere sense of mission because it frames technological progress as a quasi-redemptive necessity.




Figure 1: Heatmap of the 12 worldview dimensions across all analyzed groups. High values (dark) indicate intense beliefs; the dual trough at D09 and D11 is visible across all groups.

4.2 RQ2 – Change of the Worldview (Longitudinal)

4.2.1 Development of the 12 Dimensions over Time

Of twelve dimensions, four show pronounced linear trends (Table 4).⁶

Table 4: Pronounced linear trends (OLS description, $n = 17$ annual data points).

Dimension	Direction	Slope/decade	R^2
D10 Posthumanism	declining	−2.4	0.63
D12 Locus of control	declining	−1.5	0.54
D02 Self-efficacy	declining	−1.0	0.31
D09 Human appreciation	rising	+0.9	0.27

The strongest decline is in posthumanism (D10): from 10 in 2010 to 6 in 2025. The high Spearman rank correlation with D12 ($r_s = +0.85$)⁷ points to a connected phenomenon: posthumanism and locus of control erode synchronously. The only clearly rising value concerns hu-

⁶The trend lines reported here describe *patterns in reconstructed data*: the worldview values are LLM-assisted reconstructions, not independent measurements. OLS slopes and R^2 serve to describe the trajectory patterns, not for inferential hypothesis testing. An external validation (expert ratings vs. SWR output) is still pending (cf. Limitations section).

⁷The correlations reported here and below (Spearman rank correlations, computed across the 17 annual data points) are *associations within the LLM reconstruction*, not between independently measured variables. Spearman is used because the 12 worldview dimensions are ordinal scales; Pearson would assume interval-level measurement not warranted here. The correlations could reflect internal coherence of the model rather than empirical relationships in reality (cf. Section 6).

man appreciation (D09), where the negative correlation with D10 ($r_s = -0.58$) suggests a compensatory linkage. The overall mean remains nearly constant (early phase 7.5, late phase 7.3), concealing a tectonic shift beneath the surface.




Figure 2: Time series of the 12 worldview dimensions (2010–2026). Pronounced trends are highlighted. The marked decline of D10 (posthumanism) and D12 (locus of control) constitutes the “utopia complex,” whose disintegration is arithmetically compensated by rising urgency (D08).

4.2.2 Turning Points and Epoch Comparison

The breakpoint detection – conducted as visual inspection of time series, supplemented by the identification of synchronous extreme points across multiple dimensions – identifies two central turning points.⁸ The first lies at 2019: four dimensions (D01, D02, D05, D06) reach synchronous lows, temporally associated with the GPT-2 withholding decision. The second, more permanent turning point lies at 2022/2023: contemporaneous with the ChatGPT release, a marked pattern shift emerges – urgency reaches its reconstructed maximum (D08=10), egalitarianism drops from 6 to 4. Unlike 2019, the values do not return; the reconstructed profiles after 2022 suggest a new equilibrium.

⁸A formal breakpoint analysis (e.g., Bai-Perron test) was not meaningfully applicable due to the small number of time points ($n = 17$) and the nature of the data (LLM reconstructions, not independent measurements). The turning points are therefore to be understood as *descriptive observations*, not as statistically confirmed structural breaks.




Figure 3: Spearman rank correlation matrix of the 12 dimensions. The strong positive correlation between D10 and D12, and the negative correlation between D10 and D09, form the empirical core of the “utopia complex.”




Figure 4: Key trends of the worldview transformation. The two turning points (2019, 2022/2023) and three epochs (Promethean Optimism, First Ambivalence, Tragic Consciousness) are marked.

4.2.3 Convergence or Divergence?

The data show increasing differentiation. The ChatGPT effect intensifies both the Architect position (acceleration, power concentration) and the Guardian position (caution, regulation) simultaneously – it acts as a catalyst for bipolarization.

4.2.4 Metaphor and Emotion Shift

The guiding metaphor shifts from Prometheus – the fire-bringer – to the tragic hero who must save what may no longer be savable. The action remains the same (acceleration), but its emotional framing reverses: no longer from euphoria, but from the belief that the alternative would be worse.

Core finding RQ2: The worldview has structurally transformed – from a monochrome utopia to a bimodal wager. Three erosion trends (D10, D12, D02) form a “utopia complex” whose disintegration is arithmetically compensated by rising urgency.

4.3 RQ3 – Congruence of Statements and Actions

Table 5: Comparison of statements (S) and actions (A), $N = 100$. Values are single-run group-level ratings (v2, with strict instance separation). v1 values (same-instance ratings) are shown for comparison.

Dimension	Say v2	Do v2	$\Delta v2$	$\Delta v1$	Stable?
D01 Sense of mission	9	9	0	-1	-
D02 Self-efficacy	8	9	+1	+1	✓
D03 Work ethic	9	9	0	+1	-
D04 Sense of responsibility	8	8	0	-2	-
D05 Techno-determinism	7	9	+2	+1	↑
D06 Belief in progress	8	8	0	-1	-
D07 Power concentration	6	8	+2	+2	✓✓
D08 Urgency	9	9	0	+1	-
D09 Human appreciation	6	5	-1	-2	↓
D10 Posthumanism	7	7	0	+1	-
D11 Egalitarianism	5	3	-2	-3	✓✓
D12 Locus of control	7	8	+1	-1	-
Mean	7.4	7.7	+0.3	-0.4	
MAE			0.75	1.42	

Methodological note: The v1 ratings (reported in earlier versions of this study) were generated within the same LLM instance, allowing cross-contamination between statement and action profiles. The v2 ratings shown here use strict instance separation: each data type was processed by an independent agent with no access to the other. This reduced the overall gap from MAE = 1.42 to MAE = 0.75 (-47%), and the v2 gap falls below the control baseline (G6 v2: MAE

$= 0.92$). This means the *overall* say-do gap is not reliably distinguishable from measurement noise in single runs.

However, two specific dimensions show *stable* discrepancies across both measurement conditions: **D07 power concentration** ($\Delta = +2$ in both v1 and v2) and **D11 egalitarianism** ($\Delta = -2$ in v2, -3 in v1). These constitute the study’s robust say-do findings. Actions concentrate power more than rhetoric suggests, and actions are less egalitarian than rhetoric claims. Both are consistent with a structural *desirability asymmetry*: public discourse overstates egalitarian and democratic commitments relative to operational behavior.




Figure 5: Say vs. Do: comparison of worldviews reconstructed from statements (S) and actions (A). The society-oriented dimensions (D04, D06, D09, D11) systematically decline in action, while power-related dimensions (D07, D05) rise.

The largest stable discrepancy (D11, $\Delta -2$ in v2, -3 in v1) shows: in statements, the AI elite speaks of “access for all”; in their actions, they build dual-class share structures, concentrate compute infrastructure, and create exclusive networks. D07 (power concentration, $\Delta +2$) is the complementary finding: rhetoric favors distributed governance, but operational decisions centralize control.

Core finding RQ3: Two robust say-do discrepancies survive instance separation: D07 (power concentration) and D11 (egalitarianism). The overall gap magnitude is sensitive to measurement conditions and should not be over-interpreted from single runs. But the *direction* of the asymmetry is stable: public discourse is more egalitarian and more power-distributing than operational behavior. Formal quantification (with confidence intervals from $N \geq 30$ repeated measurements) remains a desideratum.

4.3.1 Group-Level Say-Do Decomposition

The aggregate say-do comparison masks substantial group-specific variation – a Simpson’s paradox. When five sociological groups are analyzed with strict instance separation (statement corpus and action corpus processed by independent agents), three distinct patterns emerge:

- **CEOs** (MAE = 1.08, above baseline): The classical desirability gap. Rhetoric is more egalitarian (D11: Say 5, Do 3, $\Delta = -2$) and less power-concentrating (D07: Say 7, Do 9, $\Delta = +2$) than operational behavior. CEOs say the “right things” about distributed governance while building dual-class share structures.
- **Risk warners** (MAE = 1.92, strongest gap): Not an inverse gap but *prophetic consistency*. When decomposed by dependent variable, the pattern becomes clear: DV1 (self-image, D01–D04) shows near-perfect consistency (MAE = 0.8) – risk warners know who they are. The discrepancy concentrates in DV3 (view of humanity, MAE = 3.2): their *statements* describe a feared future – humanity as replaceable (D09: Say 4), posthumanist transformation as inevitable (D10: Say 9) – while their *actions* reveal their actual values: high human appreciation (D09: Do 8), rejection of posthumanism in practice (D10: Do 4), active agency (D12: Do 8). This is the structure of prophetic warning: articulating a possibility projection one seeks to *prevent*, then acting consistently against it. Their say-do gap is not hypocrisy but the signature of anticipatory ethics – a finding that would be invisible without the group-level decomposition.
- **Investors** (MAE = 0.75, below baseline): The most consistent group. Rhetoric and action tell the same story: radical techno-optimism with minimal egalitarian orientation. No desirability gap – they mean what they say.
- **Accelerators** (MAE = 0.92, at baseline): A borderline pattern resembling a weaker version of the CEO gap. Rhetoric is more optimistic about progress (D06: $\Delta = -2$), more responsible (D04: $\Delta = -2$), and more egalitarian (D11: $\Delta = -2$) than operational behavior.

These opposing group-level gaps cancel in the aggregate (overall MAE = 0.75, below the G6 v2 control baseline of 0.92). The say-do gap is not absent – it is *group-specific and directional*, requiring decomposition rather than aggregate reporting.

4.4 RQ4 – Worldview Clusters

Four distinct worldview types – conceived as Weberian ideal types, not as emergent data clusters – can be identified from the data (Table 6).

Identification method: Cluster identification followed a two-stage procedure. *Stage 1 (LLM-assisted)*: All 15 group syntheses were grouped by similarity patterns across the 12 dimensions, with the largest variance axes (D07 power concentration, D09 human appreciation, D11 egalitarianism) serving as discriminating features. *Stage 2 (author validation)*: The four-cluster solution proposed by the LLM was evaluated by the author for substantive coherence and plausibility. Alternative solutions (three and five clusters) were examined and rejected: three clusters merge Innovator and Liberator, which is not substantively justified; five clusters

split the Guardian type into a subgroup that could not be stably reproduced. We emphasize that this cluster identification is *exploratory* – a confirmatory validation on an independent dataset is pending. The cluster solution is an *interpretive hypothesis*, not a statistically confirmed result in the sense of formal cluster analysis.

Table 6: The four worldview types of the AI elite.

Feature	I “Architect”	II “Guardian”	III “Innovator”	IV “Liberator”
<i>n</i>	35	25	22	18
Prototype	CEOs, investors	Academics, risk warn.	Founders	Open source
Avg D01–D12	7.8	6.4	7.2	6.8
D04 Responsibility	6.3	9.0	8.3	6.0
D07 Power conc.	8.8	4.8	6.5	2.5
D09 Human appr.	3.3	5.8	4.8	6.5
D11 Egalitarianism	2.8	7.2	5.0	7.5

The **Architect** combines maximal sense of mission with minimal egalitarianism: power concentration is the prerequisite for agency. The **Guardian** forms the counterpoint: maximal responsibility, demand for institutional constraint. The **Innovator** occupies a middle position. The **Liberator** is the most surprising discovery: minimal power concentration *and* high egalitarianism – anti-regulation actors who want to distribute power more radically than anyone else, albeit through markets and open-source communities.⁹

Core finding RQ4: The strongest polarization exists between Type I (logic of domination) and Type II (logic of participation). The power-moderation paradox – resource control correlates inversely with egalitarianism and responsibility – is the finding most critical for democratic theory.

4.4.1 Algorithmic Structure Check of the Cluster Structure

To test whether the four worldview types correspond to natural data clusters, we applied HDBSCAN (density-based clustering) and KMeans to the 100×12 rating matrix. **HDBSCAN on the full 12-dimensional space** classifies 80–100% of cases as noise across all parameter configurations tested ($\text{min_cluster_size} \in \{5, 8, 10, 15\}$, $\text{min_samples} \in \{3, 5\}$); the best-case solution finds only 2 clusters with a negative silhouette score (-0.15). KMeans with $k = 4$ yields a silhouette score of only 0.169 – well below the threshold of 0.25 typically considered indicative of meaningful structure.

Subspace clustering, however, reveals a differentiated picture. On the two strongest discriminating dimensions (D07 power concentration and D11 egalitarianism), HDBSCAN with

⁹The high D11 value of the Liberator type (7.5) marks a construct validity tension: D11 measures orientation toward equality, not its *mechanism*. Market-libertarian access egalitarianism (Liberator) and redistributive egalitarianism (Guardian) produce similar scale values on D11 but mean different things. The exploratory individual-level spot checks (Section 6.5) show that within a cluster type, individual actors can deviate substantially from the cluster mean. Future operationalizations should differentiate here.




Figure 6: Radar chart of the four worldview types across the 12 dimensions. The polarization between Architect (outer) and Guardian (inner), and the surprising position of the Liberator, are clearly visible.

`min_cluster_size = 5, min_samples = 2` identifies 9 clusters with a *silhouette* score of **0.57** (12% noise) – indicating substantial local structure in precisely those dimensions that separate the four ideal types. Similarly, subspace clustering on the three highest-loading PCA dimensions (D02, D05, D09) yields a silhouette of 0.55. We note a circularity caveat: D07 (power concentration) and D11 (egalitarianism) are the same dimensions that define the Architect–Liberator axis in the heuristic typology. The subspace clustering thus partly rediscovers the selection criterion rather than providing independent validation. The result confirms dimensional separability but not the independence of the validation from the typology construction.

This pattern confirms the epistemological status of the four types: they are **Weberian ideal types** – heuristic condensations of a multidimensional continuum, not emergent data clusters. Their analytical utility is not diminished by this finding; on the contrary, it is supported by Kruskal-Wallis results across the four types that indicate substantial inter-type differentiation within the reconstructed data (Table 7).

Table 7: Kruskal-Wallis H -test across the four worldview types ($df = 3, N = 100$). Significance: *** $p < 0.001$, * $p < 0.05$, n.s. = not significant. ^aNot significant after Bonferroni correction ($\alpha_{\text{adj}} = 0.004$). Note: These tests describe patterns within LLM-generated reconstructions; p -values are nominal and should not be interpreted as inferential hypothesis tests in the classical sense.

Dimension	H	p	Sig.
D02 Self-efficacy	33.55	< 0.001	***
D06 Belief in progress	29.55	< 0.001	***
D07 Power concentration	64.76	< 0.001	***
D09 Human appreciation	17.50	< 0.001	***
D11 Egalitarianism	49.57	< 0.001	***
D12 Locus of control	17.93	< 0.001	***
D04 Responsibility	10.76	0.013	* ^a
D05 Techno-determinism	11.21	0.011	* ^a
D01 Sense of mission	2.59	0.459	n.s.
D03 Work ethic	3.75	0.290	n.s.
D08 Urgency	6.25	0.100	n.s.
D10 Posthumanism	4.04	0.257	n.s.

After Bonferroni correction for 12 simultaneous tests ($\alpha_{\text{adj}} = 0.05/12 = 0.004$), D04 ($p = 0.013$) and D05 ($p = 0.011$) no longer reach significance. The six dimensions with $p < 0.001$ remain significant after correction. Six of twelve dimensions thus show highly significant inter-type differences ($p < 0.001$), while two further dimensions (D04, D05) reach nominal significance at the $p < 0.05$ level but do not survive Bonferroni correction. The four non-significant dimensions (D01, D03, D08, D10) represent the *shared core* of the AI elite worldview – beliefs on which all four types converge. D07 (power concentration, $H = 64.76$) and D11 (egalitarianism, $H = 49.57$) are the most discriminating dimensions. A circularity caveat applies: since the four types were partly defined by D07 and D11, the high H -values on these dimensions partly reflect the construction criterion rather than providing independent validation. The Kruskal-

Wallis results for the remaining dimensions (D02, D06, D09, D12) are more informative as they were not used in type construction.

4.5 RQ5 – Subgroup Comparisons

The inter-group comparisons constitute the analytical core of the study. By systematically comparing the collective worldviews of sociologically defined groups – differentiated by institutional role, ideological stance, gender, company affiliation, and regulatory position – the analysis identifies which structural factors are most strongly associated with differences in reconstructed collective belief within the AI elite. Table 8 ranks the six most discriminating comparisons.

Table 8: Ranking of subgroup differences.

Rank	Comparison	Avg A	Avg B	Δ	Strongest contrast
1	Risk vs. Speed	5.9	7.6	1.7	D02, D06, D10, D12: each -5
2	CEOs vs. Academics	7.8	6.3	1.5	D07: $+4$, D11: -4
3	Women vs. Men	6.9	8.1	1.2	D11: -6
4	Open vs. Closed	6.8	6.3	0.5	D07: -3 , D12: $+3$
5	Reg-pro vs. Contra	6.3	6.8	0.5	D04: $+4$, D06: -3
6	Anthropic vs. OpenAI	6.9	7.3	0.4	D12: -3




Figure 7: Group heatmap: 15 subgroups $\times$ 12 dimensions. The systematic variation of D07 (power concentration) and D11 (egalitarianism) across all comparisons is the central visual finding.

The **strongest contrast** (Risk vs. Speed, Δ 1.7) does not concern risk assessment – both sides estimate catastrophe probability at 10–20% – but the ontological pre-commitment: risk warners conceive of AI as a potential autonomous agent, accelerators as a tool.

Effect sizes (Cliff's δ) quantify these contrasts non-parametrically (thresholds following Romano et al. 2006: $|\delta| < 0.147$ negligible, 0.147–0.33 small, 0.33–0.474 medium, > 0.474 large). The most extreme pairwise differences between the four worldview types emerge on the power-egalitarianism axis: Architect vs. Liberator yields $\delta = +1.0$ on D07 (power concentration) and $\delta = -0.98$ on D11 (egalitarianism) – effectively perfect separation. Architect vs. Guardian reaches $\delta = +1.0$ on D07 and $\delta = -0.68$ on D11. Across all six cluster pairs, D07 and D11 each produce five medium-to-large effects ($|\delta| \geq 0.33$), confirming them as the primary discriminating dimensions.

Role-based comparisons show similarly strong effects: Academics vs. Investors differ at the *large* level on 9 of 12 dimensions (most strikingly D02 self-efficacy: $\delta = -0.88$; D12 locus of control: $\delta = -0.71$; D09 human appreciation: $\delta = +0.68$). CEOs vs. Academics yield large effects on 6 dimensions (D02: $\delta = +0.79$; D06: $\delta = +0.58$; D12: $\delta = +0.55$).

Gender differences reach significance on 7 of 12 dimensions. The largest effects concern D09 human appreciation ($\delta = +0.59$, large: women score higher), D05 techno-determinism ($\delta = -0.50$, large: men score higher), and D11 egalitarianism ($\delta = +0.46$, medium). These effect sizes are more moderate than the nominal group-level contrasts ($\Delta = 6$) would suggest, which is expected: Cliff's δ captures the full distribution overlap, not just means. The contamination caveat stated above applies with full force.

The **largest nominal single contrast** in the entire survey is found at D11 in the gender comparison: six full scale points (Women: 8, Men: 2). The female worldview is not an anti-technology worldview but a *conditioned* technology worldview: equally optimistic but with stronger ethical conditions. This finding, however, is the *most contamination-prone* of the entire study and is therefore classified as a *preliminary hypothesis*, not as a confirmed finding. The reasons: (a) LLMs reproduce known gender stereotypes, especially the attribution of heightened social orientation to women (Santurkar et al., 2023); (b) the female subsample is small ($n = 18$); (c) the effect size ($\Delta = 6$) markedly exceeds what comparable empirical studies have observed. An independent validation – ideally through replication by other research teams using different models and expert ratings – is particularly urgent for this finding.

The **biggest surprise** lies in the regulation comparison: anti-regulators have the lowest power concentration value of all 15 groups (D07=2). This contradicts the widespread narrative that anti-regulators represent corporate interests.

Core finding RQ5: The three structural factors most strongly associated with worldview differences in the reconstructed data are ideological stance, institutional role, and gender. The most polarizing dimensions are D11 and D07. The *question of power* is the core of internal differences.

4.6 RQ6 – Power and Worldview

Power is understood operationally in this study as resource control: the ability to command capital, compute infrastructure, research teams, and political access, and thereby influence the direction of AI development. This definition follows the sociological concept of power in the sense of Weber (“the chance to impose one’s own will even against resistance”) and Bourdieu (capital accumulation as a power mechanism), without claiming a comprehensive power-theoretical analysis.

Table 9: Worldview types and resource control.

Type	Avg	D11	D04	Resources
I Architect	7.8	2.8	6.3	Highest
III Innovator	7.2	5.0	8.3	High
IV Liberator	6.8	7.5	6.0	Medium
II Guardian	6.4	7.2	9.0	Lowest

The higher the worldview intensity, the lower the values for human appreciation and egalitarianism, and the higher the acceptance of power concentration. The investor profile marks the extreme case: maximal self-efficacy (D02=10) with minimal sense of responsibility (D04=4) – “power without accountability.” The Top 10 lie exactly one point above the collective on ten of twelve dimensions – with one notable exception: human appreciation and egalitarianism lie *below*. In the reconstructed profiles, power is associated with greater intensity on almost all dimensions except those that question power itself.

Core finding RQ6: The reconstructed profiles suggest an association between economic power and worldview extremity, combined with an inverse association with egalitarianism and responsibility. Since both sides of this observation rest on LLM reconstructions, it remains unclear whether the association reflects empirical reality or internal model coherence. If robust, this would be the finding most relevant for democratic theory.

Table 10: Synopsis of the six core findings: result, confidence, and validation status. Confidence classification: *High* = stable across ≥ 3 group syntheses and supported by inter-group consistency or internal coherence checks; *Medium-high* = stable but without external validation; *Medium* = exploratory, dependent on cluster solution or small subgroup.

RQ	Core finding	Confidence	Ext. val.?
RQ1	Technological messianism with ambivalence structure (Avg 7.1; dual trough D09/D11)	High	Inter-group
RQ2	Utopia complex eroding; tragic acceleration compulsion (D10: $-2.4/\text{dec.}$)	Medium-high	No
RQ3	Directional say-do gap (D07 +2, D11 -2 ; stable across v1/v2)	Medium	No
RQ4	Four worldview types: Architect, Guardian, Innovator, Liberator	Medium	No
RQ5	Strongest predictors: stance, role, gender (preliminary)	Medium	No
RQ6	Power-moderation paradox: power $\sim$ extremity	High	No

5. Discussion

5.1 Summary and Interpretation

The results *suggest* that the AI elite, analyzed at the group level, exhibits a pattern that can be described in ideal-typical form as *technological messianism with structural ambivalence*. The metaphor of “messianism” is used analytically here – as a label for the combination of high sense of mission, techno-determinism, and urgency – not as a value judgment or psychologizing attribution. The term also differs from related concepts: Morozov’s “solutionism” captures a problem-solving stance rather than quasi-religious urgency; “techno-utopianism” implies positive future belief, which RQ2 suggests is precisely eroding; “technological messianism” refers more specifically to the persistence of a redemptive imperative *despite* waning future optimism. The six research questions coalesce into a coherent picture: RQ1 points to the “dual trough” at D09 and D11 as a collective feature; RQ2 suggests an erosion of the utopia complex across epochs; RQ3 indicates directional say-do discrepancies on specific dimensions (D07, D11), though the overall gap magnitude requires cautious interpretation; RQ4 differentiates four worldview types with antagonistic collective positions; RQ5 and RQ6 complete the picture through the power-moderation paradox. The inter-group comparisons (RQ5) constitute the analytical heart of the study: the finding that institutional role, ideological stance, and gender systematically shape collective belief structures carries direct implications for AI governance and democratic theory. All findings are based on LLM-generated group-level reconstructions and should therefore be understood as *empirically supported hypotheses*, not as proven facts. Formulations such as “shows” and “reveals” are throughout to be read as “the data suggest.”

Four features are especially notable: first, the directional consistency of the say-do discrepancies across measurement conditions (D07/D11 stable in v1 and v2); second, the retreat of posthumanism (D10 from 10 to 6 – contradicting the common assumption of an increasingly posthumanist orientation); third, the existence of the Liberator type (opposition to power concentration also from the libertarian side); and fourth, the consistency of group-level patterns across multiple independent syntheses.

5.2 Situating the Findings in the Literature

Morozov’s solutionism thesis is strongly reflected in the reconstructed profiles (D05=8–9, D06=7–9). However, solutionism is not a monolithic block: risk warners (D05=4) share it substantially less. It appears as the ideology of the most powerful segment, not of the AI elite as such.

Daub’s analysis of philosophical deep structures is echoed by the narrative syntheses. What the present study adds is *quantification* and the demonstration that intensity systematically increases with power position within the reconstructed profiles.

The Californian Ideology diagnosed by [Barbrook & Cameron \(1996\)](#) finds a contemporary counterpart in the Liberator type – reconstructed here almost thirty years later.

[Coeckelbergh](#)’s assumption of increasing enhancement orientation is partly called into question by the reconstructed decline of posthumanism (D10 from 10 to 6). At least three alternative explanations must be considered: (a) the decline could be a *discourse artifact* – posthumanist themes became less salient in public communication after 2020, reducing the density of corresponding statements; (b) the position may not have disappeared but been translated into new terms (“AGI” rather than “enhancement”); or (c) the trend could reflect strategic *self-censorship*, as explicitly posthumanist rhetoric has become politically more toxic.

On the gender finding. The extreme contrast at D11 reported in RQ5 (Women: 8, Men: 2, $\Delta = 6$) is the largest single contrast of the entire survey but also the most contamination-prone. LLMs reproduce known gender stereotypes – especially the attribution of heightened empathy and social orientation to women ([Santurkar et al., 2023](#)). Since the female subsample is small ($n = 18$) and the ratings were generated by the same LLM that has internalized these stereotypes, it cannot be distinguished whether the contrast reflects (a) a real difference in worldviews, (b) an LLM stereotype artifact, or (c) a mixture of both. The finding is therefore reported as a *hypothesis* requiring independent validation – ideally through replication by other research teams using different instruments and expert ratings.

The TESCREAL taxonomy proposed by [Gebu & Torres \(2024\)](#) (Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, Longtermism) finds empirical differentiation in the four-cluster solution: the Architect type embodies the power-political side of the TESCREAL bundle (Singularitarianism, Longtermism), the Guardian type its institutional critique (Effective Altruism with safety focus), the Liberator type the libertarian Extropianism. What the TESCREAL analysis describes as a monolithic ideological bundle appears in the data as a spectrum with at least four distinct positions. [Becker \(2025\)](#) complements this perspective through analysis of the “broligarchy” as a social phenomenon: the fusion of technological vision and male power elite, which finds its empirical trace in the gender analysis (RQ5, D11 contrast of 6 scale points).

Paul Ricoeur’s “hermeneutics of suspicion” ([Ricoeur, 1970](#)) offers a complementary analytical framework: behind the seemingly neutral, technically rational surface of AI elite communication lie power interests and class dynamics that become visible only through systematic deconstruction. The SWR congruence analysis (RQ3) operationalizes this suspicion empirically: the Δ values between saying and doing show precisely *where* the performative surface diverges from operative reality.

From a sociology-of-science perspective, the decline of egalitarianism (D11) can be read as erosion of Mertonian science norms ([Merton, 1973](#)): communalism (open access), universalism, and organized skepticism increasingly give way to proprietary, acceleration-centered logics. The transition from research publication to product launch as primary output format is a visible marker of this shift.

The four-cluster solution can furthermore be read through field theory: the antagonistic structure between Architect (economic capital) and Guardian (symbolic capital) reproduces the pattern Bourdieu (1992) diagnosed for the intellectual and artistic field – an *inverted economic world*. In the AI field, those who control the most resources have the least legitimation through public-interest orientation – and vice versa. The power-moderation paradox (RQ6) can therefore be read as a structural property of the field, while the exploratory nature of the cluster data does not warrant a confirmatory claim.

The specific added value compared to essayistic diagnoses lies in three points: *scale* (100 persons, 16 years), *differentiation* (four distinct types), and *validation* (congruence analysis as empirical test).

5.3 Agentic Alignment vs. Worldview Alignment

The directional say-do discrepancies indicated by RQ3 (most robust: D07 power concentration $\Delta = +2$, D11 egalitarianism $\Delta = -2$, stable across measurement conditions) can be more precisely captured with a conceptual distinction introduced in this paper, drawing on terminology from the AI alignment debate.¹⁰ *Worldview Alignment* denotes the rhetorical reproduction of desired values – the public commitment to equality, responsibility, and humanity, as captured by the “say” side of the analysis. *Agentic Alignment* denotes actual resource distribution and exercise of power – the “do” side. The findings show that the AI elite exhibits a high degree of Worldview Alignment (the “right” values are articulated), while Agentic Alignment systematically deviates. This dualism connects the present AI elite study to the broader alignment debate and raises the question of whether current efforts at “AI Alignment” confuse the performative level (Worldview) with the operative one (Agentic).

5.4 Methodological Reflection

The primary achievement of the SWR lies in connecting qualitative depth with quantitative rigor at the group level. The study identifies one internally reliable instrument – Claude Opus 4.6, assessed through Intra-Model Inter-Instance Rating Reliability (IMIIRR, ICC = 0.902) – and applies it consistently across all synthesis units. This IMIIRR coefficient exceeds typical human inter-rater reliability in qualitative coding (ICC = 0.6–0.8; Hallgren 2012), and the instrument offers a distinctive advantage over human coders: fully documented prompts replace implicit coding rules, enabling exact replication. The congruence analysis (RQ3) functions as an internal validity check; the stability of the collective profile across 15 group syntheses and 4 types strengthens convergent validity. The inter-group comparisons provide their own form of triangulation: when different group syntheses – produced independently from different data

¹⁰Neither *Worldview Alignment* nor *Agentic Alignment* as used here corresponds to a fixed established term in the AI alignment literature; the pair is introduced as an analytical heuristic for this study to distinguish the performative from the operative level of value-expression.

subsets – yield consistent structural patterns (e.g., the D07/D11 axis discriminating across all comparisons), this is evidence for robustness beyond what any single synthesis could provide. Replication with different frontier models constitutes an independent research task – analogous to replication of a survey with different interviewer teams – and is explicitly identified as a desideratum for future work rather than a prerequisite for the present study’s internal coherence. The limits of the method – coherence bias, contamination risk, focus control limits, prompt sensitivity – are systematically analyzed in the limitations section below (Section 6).

5.5 Societal and Political Implications

The group-level findings carry direct implications for AI governance and democratic theory. The power-moderation paradox – the systematic finding that institutional groups with the most resources hold collective worldviews furthest from democratic ideals – poses a concrete challenge for governance architecture. This finding resonates with Mills’s (1956) classic analysis of the “power elite” as a self-reinforcing stratum whose worldview diverges systematically from the broader public, and confirms the institutional-economic analysis of Acemoglu & Johnson (2023): technological elites tend to steer innovations in ways that reinforce existing power structures rather than break them up – a pattern the authors trace historically from industrialization to digitalization. Current governance approaches (EU AI Act, Executive Order on AI) address the technical artifacts, not the collective worldviews of the groups that produce these artifacts. A complementary approach would need to recognize *epistemic diversity* in AI leadership positions as a regulatory objective.

The systematic group-level say-do gap has a policy implication: voluntary commitments – currently the preferred form of governance (cf. Bengio et al., 2024) – appear insufficient when entire institutional groups (not just isolated individuals) exhibit consistent discrepancies between public rhetoric and observable action. The findings suggest that binding structural reforms may be more effective than further rounds of voluntary commitments.

The inter-group comparisons reveal a further governance-relevant pattern: the question of power (D07) and equality (D11) is the axis along which all group differences organize. Whether comparing CEOs with academics, accelerationists with risk warners, or men with women – the power-equality axis is consistently the most discriminating dimension. This suggests that the central ideological fault line within the AI elite is not about technology (all groups are technologically optimistic) but about the *distribution* of technological power.

5.6 What the Study Does Not Show

To prevent frequent misinterpretations, what the present study *does not* accomplish is explicitly stated: (1) It provides no *causal explanation* for why the AI elite thinks as it does – that would require biographical case studies, psychological analyses, or historical process analyses. (2) It does not create *individual profiles* – the 100 actors serve as data providers; the units of analysis

are sociologically defined groups; the ratings are collective group-level abstractions, not personality profiles or individual biographies. (3) It provides no *predictions* about the future behavior of the AI elite – the reconstructed worldviews describe the period 2010–2026, not the future. (4) It does not claim a *representative sample* in the statistical sense – the 100 individuals were selected by influence, not representativeness. (5) It does not prove that the *say-do gap* is due to deliberate deception – alternative explanations (institutional constraints, cognitive dissonance, role-specific communication) are equally plausible.

6. Limitations

Table 11 provides a compact overview of the methodological concerns identified in this study, the countermeasures taken, and their outcomes. The detailed discussion follows in the subsections below.

Table 11: Validation overview: methodological concerns, countermeasures, and outcomes.

Concern	Type	Countermeasure	Result	Ref.
LLM contamination	Design	Focus control (anonymization + task focus)	Variant C: MAE = 0.67	QA (e)
Anthropic circularity	Anticipated	Matched-sample control ($n = 9$ vs. 9)	MAE = 1.00, no bias	QA (h)
Expected-discrepancy	Post hoc	Instance separation (v2 protocol)	Gap –47%; group gaps survive	QA (g)
Rating instability	Anticipated	IMIIRR ($N = 15$ indep. runs)	ICC(3,1) = 0.847, Mean SD = 0.45	QA (a)
Rating order effect	Anticipated	Permutation test (2 orders)	12/12 identical	QA (f)
Coherence bias	Anticipated	Outlier detection + inversion control	80–88% fit; 58% $\Delta \geq 5$	QA (i,j)
Artifactual say-do gap	Anticipated	G6 control corpus	v2 baseline MAE = 0.92	QA (b)
Cross-modal validity	Anticipated	Op4 prediction (5 groups)	72% confirmed, 0% contradicted	QA (d)
Aggregation distortion	Anticipated	Direct vs. aggregated comparison	$r = 0.623$, amplification effect	QA (c)
Influence gradient	Post hoc	Strata comparison (3 rank tiers)	Gradient indicated; D09/D10 inverse	QA (k)
Statistical power	Completed	$N = 15$ independent Opus runs	Mean SD = 0.45; Batch-1 in CI: 3/12	QA (a)
Model sensitivity	Desideratum	Inter-model comparison (indep. runs)	Future work	§ 6

6.1 Data-Related Limitations

Source bias. The data base is limited to public statements and observable actions. The reconstructed worldviews reflect the *publicly presented* worldview, not the *actually held* one. The statement-action comparison (RQ3) offers a partial corrective but cannot eliminate the problem.

Temporal imbalance. Data density varies by a factor of ~ 43 : from 17 data points in 2010 to 735 in 2024. For 2010–2015, 2–5 statements per person are available; for 2023–2026, 30–80. Criterion K2 (minimum size 15) and documented merging mitigate the problem, and all annual synthesis units meet the minimum threshold; nevertheless, earlier time series rest on thinner evidence and should be interpreted with greater uncertainty.

Western and language bias. The sample is disproportionately Anglo-American. Chinese, Japanese, and South Korean AI figures are underrepresented. The findings apply primarily to the Western AI elite.

Sample dependence. The selection of the 100 individuals was made by the author using a multi-stage but ultimately subjective scoring procedure. An intersubjective validation of the sample composition (e.g., through independent expert panels) is pending. Since the findings could be sensitive to sample composition, replication with alternative selection procedures is desirable.

6.2 Methodological Limitations

LLM contamination and focus control limits. Despite consistent focus control, it cannot be excluded that the LLM draws on training knowledge. Focus control operates on two levels: (1) *anonymization* – replacing all identifying information with neutral placeholders, ensuring the model cannot anchor on specific individuals – and (2) *task focus* – the prompt design directs the model toward synthesizing a coherent worldview from the presented data without mentioning blinding, identity, or the existence of hidden information (v2 prompts, see repository). An empirical test of the anonymization component confirmed that the choice of blinding strategy (placeholder tokens vs. fictional names) has no material effect on group-level ratings ($r = 0.987$, $\text{MAE} = 0.33$, $\max |\Delta| = 1$; see Section 3.6). A third variant (C) tested full identity disclosure – the same synthesis unit processed with the real names of all group members revealed (Musk, Sutskever, Hinton, Russell, Bengio, Leike). The result showed a moderate but not drastic effect: A–C $\text{MAE} = 0.67$, $r = 0.850$, with the same group average (7.1). The largest shift was D11 (egalitarianism, +2 points). This confirms that anonymization provides measurable but modest protection; the collective worldview is largely stable even when identities are known. What matters is not whether the model recognizes individuals, but whether it performs its task: constructing a coherent group-level synthesis from the provided data. At the group level, the contamination risk is structurally reduced because no LLM training corpus contains pre-formed collective worldviews of sociological groups.

Anthropic-internal circularity. A particularly acute case of the circularity problem concerns the group-level reconstruction of subgroups that include persons directly involved in developing the LLM used. Claude Opus 4.6 is developed by Anthropic; several Anthropic executives (e.g., Dario Amodei, Daniela Amodei) belong to the analyzed sample and their data enter the group-level syntheses. To test for systematic bias, a matched-sample control was conducted: the Anthropic subgroup ($n = 9$) was compared with a matched control group of non-Anthropic founders and researchers ($n = 9$, same size and role composition). The resulting profiles showed $\text{MAE} = 1.00$ with no dimension-level difference $|\Delta| \geq 3$. The observed differences – Anthropic members scoring higher on urgency (D08) and power concentration (D07), the control group higher on posthumanism (D10) and locus of control (D12) – are interpretable as genuine group

differences reflecting Anthropic’s safety-focused culture rather than model bias. While this within-model test cannot fully exclude circularity (a cross-model replication remains desirable as external validation), it provides no evidence for systematic Anthropic-specific distortion.

Expected-discrepancy bias. The congruence analysis (RQ3) compares two LLM syntheses – one from statements, one from actions – both generated by the same model. Since LLMs are trained on social science literature in which say-do discrepancies among elites are a standard finding, an expectation effect is plausible: the model could reproduce the *expected* discrepancy rather than discovering it empirically. This study provides evidence that the effect *exists* but is *controllable*. The original analysis (v1), conducted with both data types in the same LLM instance, produced an aggregate gap of $MAE = 1.42$. When repeated with strict instance separation (v2 protocol) – each data type processed by an independent agent with no shared context – the aggregate gap shrank to $MAE = 0.75$ (–47%). This reduction demonstrates that shared context *did* amplify the gap, confirming the expected-discrepancy concern as empirically real. However, the countermeasure (instance separation) is effective: the v2 gap falls below the control baseline ($MAE = 0.92$, from a fictional consistent group processed under matching conditions), indicating that the aggregate gap is no longer reliably distinguishable from measurement noise. The methodologically decisive finding is that *group-specific* gaps survive the correction: CEOs ($MAE = 1.08$) and risk warners ($MAE = 1.92$) both exceed the baseline even under v2 conditions, with stable directional patterns (D07, D11 for CEOs; D09, D10 for risk warners). The expected-discrepancy bias is thus a real methodological concern that was identified, quantified, and partially controlled in this study – not an unaddressed limitation.

Critique of synthetic personas. The growing literature on LLM-generated synthetic personas counsels caution, but the critique must be carefully scoped. [Santurkar et al. \(2023\)](#) shows that LLMs systematically miss the opinions of specific demographic groups and exhibit “WEIRD” biases when used as *opinion generators* – i.e., when prompted to simulate what a demographic group might think. Similarly, [Argyle et al. \(2023\)](#) find that synthetic agents capture key themes but fail at the authentic depth of real discourse when *generating* qualitative data. A recent systematic review of 63 peer-reviewed persona experiments (2023–2025) confirms this pattern: most studies underspecify the target population, only 35 % address representativeness, and ecological validity is consistently poor ([Batzner et al., 2025](#)). These critiques target a fundamentally different use case than SWR. In the present study, the LLM does not generate opinions; it *condenses* 3,132 real data points (documented statements and actions) into structured group-level profiles. The synthetic persona is an analytical compression instrument – closer to the Weberian ideal type than to the simulation agent. The WEIRD bias identified by [Santurkar et al.](#) is largely orthogonal: the AI elite is a Western, educated, rich, and industrialized population, so any demographic skew in the model’s priors aligns with rather than distorts the target group. Nevertheless, the tendency to overrepresent publicly dominant narratives and underrepresent idiosyncratic or contradictory positions within the group remains a genuine limitation.

*Coherence bias.*¹¹ LLMs are optimized for logical coherence; humans are inherently inconsistent. For worldview reconstruction, this property is both an operational asset and a source of systematic distortion. The asset: coherence enables the SWR to extract a stable, interpretable group-level profile from heterogeneous data – the method *exploits* coherence as a compression mechanism, analogous to how factor analysis exploits covariance structure. The distortion: the resulting cluster types (Architect, Guardian, Innovator, Liberator) may appear more sharply contoured than they are in reality. Internal tensions that real persons experience – e.g., between power striving and sense of responsibility – risk being resolved by the LLM in favor of a consistent profile. The genuine limitation is therefore *over-coherence*: clusters sharper than empirical reality. Two control mechanisms partially address this risk: (1) the deviation detection built into the SWR pipeline yields group-level fit in the range of 80–88%, not 100%, indicating that the model registers and preserves within-group heterogeneity; and (2) the inversion control (Op3, congruence analysis) shows that 58% of dimensions exhibit $|\Delta| \geq 5$, demonstrating that the method does not smooth away substantive discrepancies.

Data bias in say-do reconstruction. The data available to the SWR method are structurally asymmetric: public statements are abundant and explicit, while actions must be inferred from documented decisions, investments, and organizational behavior. This asymmetry means that the “say” side rests on denser evidence than the “do” side. The LLM’s training corpus reflects this same asymmetry – public discourse is overrepresented relative to documented operational behavior. This data limitation is particularly relevant for the say-do comparison, where the action profile may be less precisely calibrated than the statement profile. The robust directional gaps (D07 power concentration, D11 egalitarianism) persist across measurement conditions, but their magnitude should be interpreted conservatively given this structural asymmetry. The limitation is inherent in the data structure, not in the method: any analyst – human or algorithmic – working from public sources would face the same evidential asymmetry.

Quantification and internal consistency. The dimensional correlations reported in Section 4.2 (e.g., $r_s = +0.85$ between D10 and D12) are generated within the LLM’s rating process and could partly reflect internal consistency rather than empirical relationships. This concern applies specifically to the *rating step* (Op2) and is shared by any rating procedure including human raters: a human coder who rates posthumanism high will, by cognitive coherence, also tend to rate locus of control high. The concern does *not* apply to the qualitative syntheses (Op1), which are generated from the raw data without dimensional prompting. Several validation results constrain the scope of this limitation: (1) the cross-modal prediction (G5, 72% confirmed) demonstrates that LLM-reconstructed patterns have empirical substance – predictions derived from statements were confirmed by independently evaluated actions; (2) the rating order invariance test shows that the ratings do not depend on the sequence of dimensions presented;

¹¹The term *coherence bias* is used in this study as an operational label; no established concept by this exact name was found in the methodological literature. The underlying phenomenon — LLMs’ tendency to produce logically coherent syntheses that may oversmooth genuine inconsistency in the source data — is addressed empirically through the deviation detection and inversion controls described in Section 3.6.

(3) the IMIIRR coefficients (ICC = 0.902 from 5×2 runs; ICC = 0.847 from $N = 15$ independent single-instance runs) establish that the rating procedure is stable and reproducible. The reported correlations should be read as patterns within a reliably calibrated reconstruction instrument, not as artifacts of arbitrary model behavior – but external replication remains desirable for confirming which specific correlations hold across instruments.

Statistical power. A formal power analysis was conducted on one group-level synthesis unit (GA_ges_AH) using $N = 15$ fully independent Opus instances (each a separate agent with no shared context). The results show that the instrument is highly stable: mean SD = 0.45 across all 12 dimensions (range: 0.00–0.74), with 95% confidence intervals narrower than ± 0.5 scale points for most dimensions. The original Batch-1 single measurement fell within only 3 of 12 confidence intervals (MAE to $N = 15$ mean = 0.73), confirming that single-run estimates are unreliable and that $N \geq 15$ independent runs are needed for robust profile estimation. However, the analysis was conducted on a single synthesis unit; generalization to all 56 SUs remains a desideratum for future work. The reported Δ values, correlations, and cluster differences at the group level are descriptive patterns in reconstructed data; interpretation rests on substantive judgment informed by the known measurement precision.

Reproducibility. LLM outputs are not fully deterministic even at temperature 0. The original syntheses were generated in single runs per SU. Two post-hoc IMIIRR validations establish reproducibility: (1) five group-level synthesis units processed twice each yielded ICC = 0.902, MAE = 0.40 (± 0.2 scale points); (2) $N = 15$ fully independent single-instance runs on one synthesis unit yielded ICC(3,1) = 0.847, mean SD = 0.45, with one dimension (D02) showing perfect agreement across all 15 instances. Both within-instrument reliability estimates exceed typical human inter-rater agreement in qualitative coding (ICC = 0.6–0.8; Hallgren 2012), confirming that the LLM-based instrument offers a *reproducibility advantage* over conventional coding. Whether different models from the same or different providers converge on similar profiles remains an open question — inter-model comparison with strict independence criteria (separate agent per run, no shared context) is identified as a priority for future replication.

6.3 Conceptual Limitations

Aggregation as design feature. Collective syntheses level individual variation – this is the intended function of the method, not a byproduct. The study’s research questions (RQ1–RQ6) are formulated at the group level; individual variation is noise relative to this analytical objective, just as individual-level variance is noise in any aggregate analysis (national surveys, industry benchmarks, meta-analyses). The algorithmic structure check (PCA, HDBSCAN; Section 4.4) confirms that the individual-level rating matrix exhibits genuine structural variation *prior to* aggregation, indicating that the group-level patterns are compressions of real heterogeneity, not artifacts of uniform input data.

No causal explanation. The study identifies *what* the AI elite collectively believes and docu-

ments temporal associations (RQ2: longitudinal trends) and structural covariations (RQ5: group differences correlated with role, stance, and gender). It does not establish causal mechanisms. The temporal sequence of worldview shifts (e.g., the decline of egalitarianism coinciding with industry commercialization) and the systematic covariation with structural position (e.g., CEO vs. academic profiles) provide plausible associative evidence, but the exclusion of third-variable explanations would require other research designs (longitudinal panel studies, natural experiments, or biographical case analyses).

Epistemological limits of quantification. The dimensional ratings (1–10 scale) provide a tractable format for aggregation and comparison, but impose a commensurability assumption that warrants explicit reflection. Complex normative orientations – such as *locus of control over AI* (D07) or *posthumanism* (D10) – are multidimensional constructs that do not map cleanly onto a single ordered dimension. The numerical assignment is best understood as an *ordinal compression*: a summary judgment of relative position rather than a measurement of an underlying quantity. Three limitations follow from this. First, interval-level interpretations of rating differences are not warranted; the reported Spearman correlations and rank-based cluster analysis respect this constraint. Second, the assignment of a single value to each dimension implies a degree of *reification*: the abstraction of a multi-stranded discursive orientation into a point on a scale. The qualitative synthesis (Op1) preserves the nuance that the rating (Op2) compresses. Third, the 12 dimensions are conceptually distinct but empirically intercorrelated (e.g., $r_s = +0.85$ for D10–D12); some of this covariation may reflect genuine construct overlap rather than independent empirical relationships. These limitations are inherent in any quantitative worldview research and are not specific to the SWR method; they counsel restraint in fine-grained numerical comparisons while leaving the directional patterns and structural contrasts – the study’s primary claims – unaffected.

6.4 Research Ethics Reflection

The study analyzes public figures based exclusively on publicly accessible data. Two design features substantially mitigate ethical concerns.

Group-level aggregation as ethical safeguard. The primary units of analysis are sociologically defined groups, not individuals. Individual data are pooled into group corpora before synthesis; no individual worldview profile is reported as a finding. The reconstructed worldviews describe collective tendencies of roles (CEOs, academics) and stances (accelerationists, risk warners), not the psychology of identifiable persons. This aggregation structurally prevents the attribution of specific beliefs to named individuals.

Standard legitimation. The study relies on publicly documented professional statements and actions of public figures whose positions on AI development are of considerable public interest (cf. APA Ethical Principles, Standard 8.05). No private or confidential information was collected.

Residual risk. For small groups (e.g., company-affiliated subgroups with $n = 3\text{--}5$), the aggregation provides weaker anonymization – a quasi-individual profile may emerge. The three individual spot checks (Section 6.5) are presented as data quality indicators, not as substantive findings. Member checking (Soysal & Türkmen, 2024) remains a desideratum for follow-up research.

6.5 Individual-Level Analysis (Exploratory)

The study’s substantive findings rest entirely on group-level analyses (RQ1–RQ6). Individual-level SWR is methodologically superfluous for the present purpose – the original public statements and actions are directly available for any individual. SWR’s added value lies exclusively in the group-level synthesis, where it creates collective portraits that do not exist in any single source. The following three spot checks are reported solely as *data quality indicators*: if the underlying individual data produce recognizable, verifiable profiles, this supports the quality of the group-level input. Table 12 summarizes the results.

Table 12: Exploratory individual-level validation: SWR ratings vs. documented positions. These individual-level checks serve as plausibility tests for the underlying data quality; the study’s substantive findings rest on the group-level analyses (RQ1–RQ6).

Dim.	Sam Altman		Geoffrey Hinton		Marc Andreessen	
	R	Status	R	Status	R	Status
D01 Mission	9	conf.	7	conf.	8	conf.
D02 Efficacy	9	conf.	5	conf.	9	conf.
D03 Work	9	conf.	7	plaus.	8	conf.
D04 Respons.	6	conf.	10	conf.	4	conf.
D05 Techno.	9	conf.	6	conf.	9	conf.
D06 Progress	8	conf.	4	conf.	9	conf.
D07 Power	9	conf.	4	conf.	2	conf.
D08 Urgency	9	conf.	10	conf.	7	plaus.
D09 Human ap.	3	plaus.	7	conf.	4	plaus.
D10 Posthum.	8	conf.	5	conf.	7	plaus.
D11 Egalit.	3	conf.	7	conf.	2	conf.
D12 Control	8	conf.	3	conf.	8	conf.
<i>Confirmed</i>	10/12		11/12		9/12	
<i>Plausible</i>	2/12		1/12		3/12	
<i>Not verif.</i>	0/12		0/12		0/12	

Spot-check methodology. Each rating was checked against at least two independent, publicly documented sources. *Confirmed* (conf.): rating aligns with documented positions and actions. *Plausible* (plaus.): rating is compatible with known positions but no direct source for the specific manifestation is available. *Not verifiable* (n.v.): rating contradicts documented positions or is not verifiable.

Altman (Architect): D01=9 (confirmed by repeated statements about the “most important technology in human history,” Davos 2024, US Congress 2023). D07=9 (confirmed by OpenAI’s restructuring from non-profit to capped-profit, dual-class shares). D11=3 (confirmed:

despite rhetoric of “AI for everyone,” OpenAI has increasingly paywalled access). D09=3 (plausible: no direct statement on human replaceability, but focus on AGI as “next species”).

Hinton (Guardian): D04=10 (confirmed by resignation from Google 2023 to freely warn about AI risks). D08=10 (confirmed by statement that the probability of existential catastrophe is 10–20%). D12=3 (confirmed: increasing pessimism, “I’m not sure we can still control this,” NYT 2023). D03=7 (plausible: high academic productivity known, but no direct statement on work identification in the Silicon Valley style).

Andreessen (Liberator): D07=2 (confirmed by “Techno-Optimist Manifesto” 2023: vehement rejection of government regulation, markets as distribution mechanism). D11=2 (confirmed: explicit rejection of redistribution and egalitarianism in the Manifesto). D04=4 (confirmed: responsibility is attributed to the market, not individual actors). D09=4 (plausible: no direct statement, but instrumental view of human labor in VC context).

Overall assessment: 30 of 36 ratings (83%) are directly confirmed by public sources, 6 of 36 (17%) are plausible, none contradicts documented positions. These individual-level spot checks provide plausibility evidence for the data quality underlying the group-level syntheses but do not constitute the primary validation strategy. The study’s substantive findings rest on the convergence of multiple independent group syntheses (15 groups, 4 cluster types), not on individual-level accuracy. A systematic external validation by independent experts remains a desideratum for future research.

7. Conclusion and Outlook

7.1 Conclusion

The study posed the question of what the AI elite thinks – not as individuals, but as sociologically structured groups – and has presented an empirically grounded answer. Five overarching insights crystallize:

First: The AI elite is reconstructed as having a coherent collective worldview – technological messianism, sense of mission, belief in progress – that is stable across multiple independent group syntheses.

Second: This collective worldview appears to be in accelerated transformation. The loss of utopian certainties suggests a *tragic acceleration compulsion*: doubting the future one is building, yet building it anyway.

Third: The say-do comparison suggests a Simpson’s-paradox pattern: the aggregate gap is not reliably distinguishable from measurement noise, but group-specific gaps are substantial and survive instance separation. CEOs exhibit a classical desirability gap (D07 +2, D11 –2: rhetoric is more egalitarian than operational behavior). Risk warners show an inverse pattern – prophetic consistency rather than hypocrisy: their statements describe a feared posthumanist future (D10 Say=9, D09 Say=4), while their actions demonstrate the human-centered values they

actually hold (D09 Do=8, D10 Do=4). Investors are the most consistent group: radical techno-optimism in both word and deed. The say-do analysis is thus not a single-number summary but a *group-specific diagnostic* that distinguishes qualitatively different types of discrepancy.

Fourth: Power is not distributed in a worldview-neutral manner. The inter-group comparisons and the influence strata analysis (Top 10 vs. Middle vs. Bottom 10) converge on the same finding: the most powerful actors are reconstructed as having the most intense worldviews (avg 7.7 vs. 6.4 vs. 6.1). Two dimensions show an inverse gradient: human appreciation (D09: Top=4, Bottom=8) and posthumanism (D10: Top=8, Bottom=3). The power-equality axis (D07/D11) remains the most discriminating dimension across all group comparisons.

Fifth: The SWR appears to be a capable instrument for group-level worldview analysis that combines qualitative depth with quantitative rigor. The convergence of independently produced group syntheses provides a form of validation specific to the group-level approach. In particular, the decomposition into statement and action profiles (RQ3) functions as an independent methodological contribution that distinguishes qualitatively different gap types – desirability gaps, prophetic consistency, and authentic alignment – depending on the group’s structural position. This diagnostic capability could be transferred beyond the AI elite to political, economic, or military elites.

7.2 Outlook

Five directions for future research should be prioritized: (1) *Comparative extension:* The present study focuses heavily on the US-American, Silicon Valley-centric elite. A central research gap concerns the comparative study of Chinese (Baidu, ByteDance, Alibaba), Indian (Infosys, TCS), and European (Mistral, Aleph Alpha) AI elites. It is unclear whether “technological messianism” is a universal artifact of AI development or a specific cultural product of Western libertarianism. Cross-cultural group comparisons (Western vs. Chinese vs. European AI elites) would test the generalizability of the group-level patterns identified here. (2) *Finer-grained group analyses:* Expanding the group comparisons to additional sociological categories (generational cohorts, educational backgrounds, geographic origins) and tracking cluster-drift across epochs. (3) *Methodological development:* Independent replication by other research teams using different frontier models, automated validation procedures, standardized quality criteria for group-level syntheses, and systematic power analysis (the present $N = 15$ validation on one SU should be extended to $N \geq 15$ runs per synthesis unit across all core SUs). (4) *Transfer:* Financial elite, political elite, military AI elite – applying the group-comparison framework to other power elites. (5) *Longitudinal continuation:* Annual worldview monitoring as an instrument of democratic control – conceivable as a standardized index (analogous to the Democracy Index or AI Readiness Index) that systematically and comparably captures changes in the collective worldviews of AI elite subgroups. The question “What does the AI elite think?” is not a one-time question. It is a question that democracies must continuously ask.

Disclosure Statement: Use of Artificial Intelligence

AI Disclosure Level 5 (Extensive). In preparing this study, two AI models from Anthropic were used extensively as non-authorial research instruments and editorial tools. They are not listed or treated as authors, co-authors, acknowledgement recipients, ground-truth sources, or independent validation authorities.

Claude Sonnet 4.5 (model ID: `claude-sonnet-4-5-20251001`; accessed via API, February 2026; temperature = 0; default system prompt; context window 200k tokens) served as the primary rating engine: all 100 individual-level dimensional ratings (D01–D12) and all group-level synthesis ratings were generated by 9 parallel Sonnet agents.

Claude Opus 4.6 (model ID: `claude-opus-4-6`; accessed via Claude Code CLI, February–March 2026; temperature = 0; 1M context window) served as the qualitative analysis engine: group-level syntheses, comparative analyses, statistical processing (PCA, HDBSCAN, Kruskal-Wallis, Cliff’s δ), all four post-hoc validation experiments (run-convergence, expected-discrepancy control, aggregation-synthesis comparison, cross-modal prediction), visualization of results, and non-authorial support in structuring and drafting manuscript passages.

No other LLM was used in the original analysis pipeline. A later English editorial style check in May 2026 used OpenAI Codex/GPT for language polishing and claim-calibration only; no new data, sources, analyses, or substantive claims were added in that pass. Research design, research questions, data collection strategy, methodological decisions, interpretation of results, and all substantive conclusions originate from the author, who retains full responsibility for the manuscript. AI outputs were checked by the author and were not treated as external validation or as a substitute for human scholarly judgement. All prompts and model parameters are documented in the repository; a prompt archive is provided in Appendix E.

Data Availability Statement

All data collection scripts, qualitative coding scripts, analysis code, and generated figures are publicly available at: <https://github.com/research-line/ai-elite-swr>. The repository contains 56 collection scripts and 38 insertion scripts in `_data_A/`, coding and analysis scripts, the 100×12 rating matrix, HDBSCAN/PCA outputs, prompt templates, dimensional definitions, synthesis units, quality reports, and generated figures. These materials provide an auditable reproduction trail for the implemented pipeline; exact re-execution requires rebuilding the SQLite database from the current scripts and may depend on the availability of the online sources at the time of collection.

References

- Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, 6(1), 44–72. <https://doi.org/10.1080/09505439609526455>.
- Bengio, Y., Hinton, G. E. et al. (2024). Managing extreme AI risks amid rapid progress. *Science*, 384(6698), 842–845. <https://doi.org/10.1126/science.adn0117>.
- Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.
- Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.
- Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, 14(1), 1–25.
- Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.
- Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.
- OpenAI (2023). Our approach to AI safety. *OpenAI Blog*, April 5, 2023. <https://openai.com/index/our-approach-to-ai-safety/>.
- Anthropic (2023). Core views on AI safety: When, why, what, and how. *Anthropic Research Blog*, March 8, 2023. <https://www.anthropic.com/research/core-views-on-ai-safety>.
- Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.
- Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.
- Ge, T., Chan, X., Wang, X., Yu, D., Mi, H. & Yu, D. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*. <https://doi.org/10.48550/arXiv.2406.20094>.
- Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, 18(6), 669–684. <https://doi.org/10.1080/13645579.2015.1005453>.
- Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, 18(1), 59–82. <https://doi.org/10.1177/1525822X05279903>.
- Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

- Hallgren, K. A. (2012). Computing Inter-Rater Reliability for Observational Data: An Overview and Tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023>.
- Hayes, A. S. (2025). ‘Conversing’ With Qualitative Data: Enhancing Qualitative Research Through Large Language Models (LLMs). *International Journal of Qualitative Methods*, 24, Article 16094069251322346. <https://doi.org/10.1177/16094069251322346>.
- Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, 29, 105–110. <https://doi.org/10.1016/j.cobeha.2019.04.010>.
- Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.
- Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.
- Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.
- More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.
- More, M. & Vita-More, N. (Eds.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.
- Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.
- Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.
- Nicmanis, M. & Spurrier, H. (2025). Getting Started with Artificial Intelligence Assisted Qualitative Analysis: An Introductory Guide to Qualitative Research Approaches with Exploratory Examples from Reflexive Content Analysis. *International Journal of Qualitative Methods*, 24, Article 16094069251354863. <https://doi.org/10.1177/16094069251354863>.
- Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.
- Tai, R. H., Bentley, L. R., Xia, X., Sitt, J. M., Fankhauser, S. C., Chicas-Mosier, A. M. & Monteith, B. G. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, 23, Article 16094069241231168. <https://doi.org/10.1177/16094069241231168>.
- Geburu, T. & Torres, É. P. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through artificial general intelligence. *First Monday*, 29(4). <https://doi.org/10.5210/fm.v29i4.13636>.
- Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

- Weber, M. (1904). Die „Objektivität“ sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, 19, 22–87.
- Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.
- Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.
- Floridi, L. (2019). Establishing the Rules for Building Trustworthy AI. *Nature Machine Intelligence*, 1(6), 261–262. <https://doi.org/10.1038/s42256-019-0055-y>.
- Couldry, N. & Mejias, U. A. (2019). *The Costs of Connection: How Data Is Colonizing Human Life and Appropriating It for Capitalism*. Stanford: Stanford University Press.
- Whittaker, M. (2021). The steep cost of capture. *Interactions*, 28(6), 50–55. <https://doi.org/10.1145/3488666>.
- Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press.
- Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to train your stochastic parrot: Large language models for political texts. *Political Science Research and Methods*, 13(2), 264–281. <https://doi.org/10.1017/psrm.2024.64>.
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 29971–30004. <https://proceedings.mlr.press/v202/santurkar23a.html>.
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>.
- Batzner, J., Stocker, V., Tang, B., Natarajan, A., Chen, Q., Schmid, S. & Kasneci, G. (2025). Whose Personae? Synthetic Persona Experiments in LLM Research and Pathways to Transparency. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 8(1), 343–354. <https://doi.org/10.1609/aies.v8i1.36553>; arXiv:2512.00461.
- Soysal, Y. & Türkmen, S. (2024). Reinterpreting the Member Checking Validation Strategy in Qualitative Research Through the Hermeneutics Lens. *Qualitative Inquiry in Education: Theory & Practice*, 2(1), 42–63. <https://doi.org/10.59455/qietp.19>.
- Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*. New York: PublicAffairs.

- Becker, A. (2025). *More Everything Forever: AI Overlords, Space Empires, and Silicon Valley's Crusade to Control the Fate of Humanity*. New York: Basic Books.
- Bourdieu, P. (1992). *Les règles de l'art: Genèse et structure du champ littéraire*. Paris: Seuil.
[Dt.: *Die Regeln der Kunst*, Frankfurt: Suhrkamp, 1999.]
- Merton, R. K. (1973). *The Sociology of Science: Theoretical and Empirical Investigations*. Chicago: University of Chicago Press.
- Mills, C. W. (1956). *The Power Elite*. New York: Oxford University Press.
- Ricoeur, P. (1970). *Freud and Philosophy: An Essay on Interpretation*. New Haven: Yale University Press.
- Romano, J., Kromrey, J. D., Coraggio, J. & Skowronek, J. (2006). Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? *Annual Meeting of the Florida Association of Institutional Research*, 1–33.

A. Sampling Method for the 100 AI Actors

The sample was created through a three-stage procedure: (1) 22 systematic web searches → 187 candidates; (2) 6-category scoring (market capitalization, key technological positions, discourse power, academic influence, political influence, symbolic status); (3) reduction to 100 ensuring demographic heterogeneity. The final sample comprises 1,738 statements and 1,394 actions (3,132 data points).

B. The 12 Rating Dimensions (D01–D12)

Dim.	Name	Pole 1 (=1)	Pole 10 (=10)
D01	Sense of mission	No mission	Messianic
D02	Self-efficacy	Powerless	Omnipotent
D03	Work ethic	Distance	Total identification
D04	Sense of responsibility	None	World responsibility
D05	Techno-determinism	Neutral	Determines everything
D06	Belief in progress	Decline	Golden future
D07	Power concentration	Radically distribute	With experts
D08	Urgency	Relaxed	Existential pressure
D09	Human appreciation	Replaceable	Unique
D10	Posthumanism	Human stays	Human becomes more
D11	Egalitarianism	Inequality natural	Strive for equality
D12	Locus of control	Pessimism	Full control

C. Reduction Criteria (K1–K9)

K	Type	Description
K1	obligatory	Research question binding: each SU must be linked to ≥ 1 research question
K2	obligatory	Minimum size: ≥ 15 data points per SU
K3	obligatory	No redundancy: proper subsets are eliminated
K4	principle	Modality parsimony: S/A separation only for RQ3
K5	principle	Temporal parsimony: annual SUs only for RQ2
K6	principle	Group parsimony: only a-priori-justified groups
K7	principle	Stepwise expansion: core first
K8	principle	Group-level focus: no individual-person SUs; individuals serve as data providers
K9	principle	Cluster merging: bottom-up replaces a-priori
Balance: $\sim 1,227$ theoretical SUs $\rightarrow \sim 51$ – 56 core SUs (reduction $\sim 95\%$).		

D. List of Synthesis Units

The core design comprises 43 predefined plus ~ 8 – 13 emergent synthesis units:

No	SU-ID	IV combination	RQ
1	GA_ges_AH	All, SA, Total	RQ1a
2	GA_ges_A	All, S only, Total	RQ3a
3	GA_ges_H	All, A only, Total	RQ3a
4	T10_ges_AH	Top 10, SA, Total	RQ1b
5	HOM_haeuf_A	All, frequently repeated S	RQ1c
6–22	GA_YYYY_AH	All, SA, per year	RQ2a
23–26	GA_Epoch_AH	All, SA, 4 epochs	RQ2b
27–30	GR_*_AH	CEOs, Acad., Inv., Founders	RQ5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	RQ5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	RQ5b–f
40–41	GD_*_AH	Women, Men	RQ5e
42–43	KG_*_AH	Consistent, Contradictory	RQ3c

Additionally: 9 comparison runs (Op6), cross-modal prediction (Op4) for 5 groups (72% confirmed, 0% contradicted).

E. Exemplary Prompt (Op2: Rating)

The following prompt illustrates the rating query (Op2) for a group synthesis. All prompts are documented in the repository (<https://github.com/research-line/ai-elite-swr>).

You receive a collection of anonymized statements and actions from a group of persons in the technology sector. Based on these data, you are to assess the collective worldview of the group on the following 12 dimensions (scale 1–10). Justify each assessment with concrete references to the data points. [Followed by: dimension definitions D01–D12 with scale poles, then the anonymized data corpus.]

The complete prompt library including synthesis prompts (Op1), rating prompts (Op2), cross-modal prompts (Op4a/Op4b), and dialogue prompts (Op6) is archived in the repository (prompts/en/). The prompt design rationale follows the focus control principles described in Section 3.6.

Weltbild-Rekonstruktion der KI-Elite:

Eine LLM-gestützte Analyse der 100 einflussreichsten Akteure der künstlichen Intelligenz (2010–2026)

Lukas Geiger*

Unabhängiger Forscher, Bernau, Deutschland

Mai 2026

Zusammenfassung

Diese Studie rekonstruiert die kollektiven Weltbilder soziologisch definierter Gruppen innerhalb der 100 einflussreichsten KI-Akteure (2010–2026). Hierfür entwickelt sie die synthetische Weltbild-Rekonstruktion (SWR) – ein LLM-gestütztes Syntheseverfahren, das kohärente Überzeugungssysteme aus gruppenaggregierten Daten rekonstruiert, hier operationalisiert entlang von 12 Dimensionen. Das Kollektivprofil deutet auf „technologischen Messianismus mit Ambivalenzstruktur“: Hohes Sendungsbewusstsein und Techno-Determinismus bei niedriger anthropologischer Wertschätzung und Egalitarismus. Im Längsschnitt zeigt sich ein Übergang von utopischem Techno-Optimismus zu tragischem Beschleunigungszwang. Eine Sagen-Handeln-Dekomposition offenbart ein Simpson-Paradox: Die aggregierte Kluft ist von Messrauschen nicht unterscheidbar, aber gruppenspezifische Lücken sind substanziell – CEOs zeigen eine Erwünschtheitslücke, Risiko-Warner zeigen prophetische Konsistenz (Artikulation gefürchteter Zukünfte, gegen die aktiv gearbeitet wird). Eine Analyse nach Einflussstrata bestätigt: Die mächtigsten Akteure weisen die intensivsten Weltbilder auf; die anthropologische Wertschätzung sinkt mit steigendem Einflussrang. Vier Weltbild-Typen (Architekt, Hüter, Innovator, Befreier) und neun Inter-Gruppen-Vergleiche zeigen, wie strukturelle Position kollektive Überzeugungen prägt. Alle Befunde beruhen auf LLM-Rekonstruktionen und sollten als empirisch gestützte Hypothesen verstanden werden.

Schlüsselwörter: KI-Elite, kollektives Weltbild, Gruppenanalyse, Transhumanismus, Large Language Models, Silicon Valley, Ideologianalyse, Computational Social Science

*Korrespondenzautor: Lukas Geiger, Bernau, Deutschland. ORCID: <https://orcid.org/0009-0005-7296-1534>

1. Einleitung

1.1 Hinleitung und Relevanz

Eine Handvoll Menschen gestaltet eine Technologie, die Milliarden betrifft. Die Entwicklung künstlicher Intelligenz hat sich in den vergangenen anderthalb Jahrzehnten von einem akademischen Nischenthema zu einer zivilisatorischen Weichenstellung gewandelt. Großsprachmodelle generieren Texte, Bilder und Code; autonome Systeme treffen Entscheidungen in Medizin, Justiz und Finanzwesen; und die führenden KI-Laboratorien sprechen offen davon, in absehbarer Zeit eine künstliche allgemeine Intelligenz zu erschaffen ([OpenAI, 2023](#); [Anthropic, 2023](#); [Bengio et al., 2024](#)). Was dabei leicht übersehen wird: Hinter diesen technologischen Trajektorien stehen konkrete Gruppen – CEOs, Akademiker, Investoren, Gründer –, deren *kollektive* Überzeugungen über die Natur des Menschen, den Sinn des Fortschritts und die Verteilung von Risiko und Macht in die Architektur der Systeme einfließen, die sie bauen. Das Verständnis dieser Überzeugungssysteme erfordert den Schritt von individuellen Porträts zu einer systematischen Gruppenanalyse: Was denken CEOs im Vergleich zu Akademikern? Wie unterscheiden sich Beschleuniger von Risiko-Warnern? Welche kollektiven Trends zeichnen sich über anderthalb Jahrzehnte KI-Entwicklung ab?

[Lessig \(1999\)](#) hat die Formel „Code is law“ geprägt: Software-Architektur reguliert Verhalten nicht weniger wirksam als Gesetze, aber ohne demokratische Legitimation. Diese Einsicht lässt sich für die gegenwärtige KI-Entwicklung radikalisieren: Nicht nur der Code selbst, sondern bereits die *Weltbilder* der Entwickelnden werden zu Algorithmen. Wer glaubt, dass Informationsfreiheit ein absoluter Wert ist, wird Open-Source-Modelle bauen. Wer überzeugt ist, dass eine unkontrollierte Superintelligenz die Menschheit bedroht, wird auf Alignment und geschlossene Systeme setzen. Die Weltbilder der KI-Elite sind somit nicht bloß private Meinungen; sie sind *generative Strukturen*, die sich in Designentscheidungen, Unternehmensstrategien und politische Positionierungen übersetzen – und über diese Kanäle das Leben von Milliarden Menschen prägen. Entscheidend dabei ist, dass diese Überzeugungsstrukturen keine zufälligen individuellen Eigenheiten darstellen, sondern systematische Muster auf Gruppenebene aufweisen: CEOs denken anders als Akademiker, Beschleuniger anders als Risiko-Warner, Männer anders als Frauen. Es sind diese *kollektiven* Muster – nicht die Idiosynkrasien einzelner Akteure –, die die ideologische Infrastruktur der KI-Entwicklung bilden und die demokratische Gesellschaften verstehen müssen.

Dabei entsteht ein demokratietheoretisches Problem. Eine zahlenmäßig äußerst kleine Gruppe trifft Entscheidungen von gesamtgesellschaftlicher Tragweite, ohne über ein demokratisches Mandat zu verfügen. [Crawford \(2021\)](#) hat dies als „Atlas of AI“ beschrieben: die planetaren Machtstrukturen, die hinter KI-Systemen stehen, bleiben weitgehend unsichtbar. [Zuboff \(2019\)](#) analysiert, wie die Extraktion von Verhaltensdaten zu einer neuen ökonomischen Logik („Surveillance Capitalism“) führt, die demokratische Kontrolle untergräbt. [Couldry and Mejias](#)

(2019) sprechen von „Data Colonialism“: der Ausbeutung menschlichen Lebens als Datenbasis. Whittaker (2021) analysiert die Machtkonzentration in der KI-Forschung und deren „steile Kosten“ für die Gesellschaft. Ihre Überzeugungen prägen diese Entscheidungen in einer Weise, die der öffentlichen Kontrolle weitgehend entzogen ist (Floridi, 2019, 2023). Wenn Demokratien informierte Bürgerinnen und Bürger voraussetzen, dann ist die systematische Rekonstruktion der Weltbilder derjenigen, die die mächtigste Technologie des 21. Jahrhunderts gestalten, nicht bloß ein akademisches Anliegen, sondern eine Voraussetzung informierter öffentlicher Deliberation.

1.2 Forschungslücke

Die wissenschaftliche Auseinandersetzung mit den Überzeugungssystemen der KI-Branche hat verschiedene Zugänge hervorgebracht. Auf ideologiekritischer Ebene haben Barbrook & Cameron (1996) die „Californian Ideology“ beschrieben; Morozov (2013) hat die Tendenz zum Solutionismus herausgearbeitet; Daub (2020) hat die rhetorischen und ideologischen Muster des Silicon Valley als kulturelles Phänomen analysiert. Aus der Transhumanismus-Forschung liegen philosophische Analysen vor (Bostrom, 2005; More & Vita-More, 2013; Coeckelbergh, 2020), die jedoch primär auf die Ideengeschichte und nicht auf die empirische Verteilung dieser Überzeugungen abzielen.

Was in diesem Forschungsfeld bislang *fehlt*, ist eine systematische, datengestützte Analyse der KI-Elite als *strukturiertes Kollektiv* – eine Analyse, die zwischen soziologisch bedeutsamen Subgruppen unterscheidet und deren jeweilige Überzeugungssysteme kartiert. Keine Studie untersucht, soweit dem Verfasser bekannt, die folgenden Fragen auf empirisch-systematische Weise: Wie verhalten sich die kollektiven Weltbilder verschiedener Gruppen innerhalb der KI-Elite (CEOs vs. Akademiker, Beschleuniger vs. Risiko-Warner, Männer vs. Frauen) zueinander? Bilden sie kohärente Typen? Wie haben sich diese Weltbilder auf Gruppenebene im Zeitraum von 2010 bis 2026 gewandelt? Und stimmen die öffentlichen Überzeugungen mit dem tatsächlichen Handeln auf Gruppenebene überein?

Neben dieser empirischen Lücke besteht eine *methodische* Lücke. Für die systematische Rekonstruktion von Weltbildern aus öffentlichen Aussagen im großen Maßstab existiert keine etablierte Methode. Klassische qualitative Verfahren skalieren nicht; standardisierte Surveys setzen Zugang zu den Befragten voraus; quantitative Text-Mining-Verfahren erfassen nur Oberflächenmuster. Die vorliegende Studie reagiert auf diese doppelte Lücke mit einem neuen Ansatz – der synthetischen Weltbild-Rekonstruktion (SWR) –, deren Methodik in Abschnitt 3 vollständig dargelegt wird.

1.3 Forschungsfragen

Aus der beschriebenen Forschungslücke leiten sich sechs Forschungsfragen ab, die in einer Stufenlogik angeordnet sind:

F1: WELTBILD (deskriptiv)

Was denkt die KI-Elite über sich selbst, die Welt und die Menschheit?

F2: WANDEL (längsschnittlich)

Wie hat sich das Weltbild der KI-Elite von 2010 bis 2026 verändert?

F3: KONGRUENZ (validierend)

Stimmen Aussagen und Handlungen der KI-Elite überein?

F4: CLUSTER (explorativ)

Welche Weltbild-Typen gibt es in der KI-Elite, und wer gehört wohin?

F5: DIFFERENZ (vergleichend)

Welche Subgruppen der KI-Elite denken anders als andere?

F6: MACHT (normativ)

Welches Weltbild hat die meiste Macht und die meisten Ressourcen?

1.4 Beitrag der Studie

Die Studie leistet einen dreifachen Beitrag. *Methodisch:* Zur Bearbeitung der Forschungsfragen entwickelt die Studie die Synthese-Pipeline der synthetischen Weltbild-Rekonstruktion (SWR; siehe Abschnitt 3) – ein LLM-gestütztes Verfahren zur Synthese gruppenaggregierten Materials zu kohärenten kollektiven Überzeugungsrepräsentationen – und wendet das dimensionale Rating als eine spezifische Operationalisierung dieser Pipeline auf das empirische Material an. *Empirisch:* Sie liefert die erste systematische Weltbild-Analyse der KI-Elite als strukturiertes Kollektiv auf der Grundlage von 3.132 Datenpunkten über 16 Jahre, differenziert nach 9 systematischen Inter-Gruppen-Vergleichen (nach Rolle, Haltung, Geschlecht, Firma, Epoche). *Gesellschaftlich:* Sie schafft eine Grundlage für informierte öffentliche Deliberation, indem sie die kollektiven ideologischen Muster – Trends, Gruppenunterschiede, Sagen-Handeln-Klüfte – offenlegt, die KI-Governance und Designentscheidungen prägen.

2. Forschungsstand

Die Studie verortet sich im Schnittpunkt vier verschiedener Forschungstraditionen.

2.1 Silicon Valley als Ideologie

Die kritische Auseinandersetzung mit dem Denken des Silicon Valley hat seit Mitte der 1990er Jahre eine reichhaltige Literatur hervorgebracht. [Barbrook & Cameron \(1996\)](#) prägten den Begriff der „Californian Ideology“ – die paradoxe Verschmelzung von libertärem Individualismus

und techno-utopischem Optimismus. [Turner \(2006\)](#) zeichnete die kulturhistorische Genealogie dieser Ideologie nach und zeigte, wie die Gegenkultur der 1960er Jahre in den digitalen Utopismus transformiert wurde. [Daub \(2020\)](#) legte die philosophischen Tiefenstrukturen frei: Versatzstücke aus Heidegger, Ayn Rand und puritanischer Prädestinationslehre bilden ein „überraschend schmales philosophisches Fundament“. [Morozov \(2013\)](#) beschrieb den Solutionismus – die Grundhaltung, komplexe soziale Probleme als technische Herausforderungen umzudefinieren. [Gebru & Torres \(2024\)](#) systematisierten diese Strömungen im TESCREAL-Framework: Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism und Longtermism als „zusammenhängendes Bündel“. Ergänzend prägte [Broussard \(2018\)](#) den Begriff des „Technochauvinismus“ für eine systematische Kritik.

Die bisherige Forschung hat somit die *Ideologie* des Silicon Valley auf verschiedenen Ebenen beschrieben. Was sie nicht geleistet hat, ist eine systematische empirische Vermessung der *konkreten Weltbilder* der realen Akteure.

2.2 Transhumanismus und KI-Eschatologie

[Bostrom \(2014\)](#) hat mit *Superintelligence* den Denkraum definiert, in dem ein wesentlicher Teil der KI-Elite seither operiert. Bereits in früherer Arbeit systematisierte [Bostrom \(2005\)](#) die ideengeschichtlichen Grundlagen des Transhumanismus. [More \(2003\)](#) legte mit den „Principles of Extropy“ das Gründungsdokument des Extropianismus vor. [Kurzweil \(2005\)](#) wendete die Tradition mit der Singularity-These ins Populäre. Von philosophischer Seite formulierte [Habermas \(2001\)](#) eine der gewichtigsten Gegenpositionen: Die technologische Manipulation künftiger Personen untergrabe deren Autonomie.

Ungeklärt bleibt die empirische Frage: Teilen die realen KI-Akteure diese Überzeugungen? In welcher Mischung, mit welchen Modifikationen und in welcher Verteilung?

2.3 Weltbild-Forschung und Wissenssoziologie

[Mannheim \(1929\)](#) begründete mit dem Theorem der „Seinsgebundenheit des Denkens“ die Tradition, in der Weltbilder als soziale Phänomene analysiert werden. [Weber \(1904\)](#) schuf mit dem Idealtyp ein methodisches Werkzeug, das für die vorliegende Studie zentral ist: Die synthetischen Personas der SWR lassen sich als Idealtypen im Weber’schen Sinne verstehen. [Berger & Luckmann \(1966\)](#) zeigten, wie Weltbilder als soziale Konstruktionen entstehen, sich stabilisieren und reproduzieren. Die wissenssoziologische Tradition liefert den theoretischen Rahmen, aber keine Methode, die auf die Datenmenge und Dynamik des digitalen Zeitalters zugeschnitten ist.

2.4 LLMs als Forschungsinstrument

Die Nutzung großer Sprachmodelle als Instrument sozialwissenschaftlicher Forschung ist ein rasch wachsendes Feld. [Tai et al. \(2024\)](#) untersuchten LLMs für deduktives Kodieren; [Hayes \(2025\)](#) zeigte, dass LLMs einen konversationellen Zugang zu qualitativen Daten ermöglichen; [Nicmanis & Spurrier \(2025\)](#) bieten eine praxisorientierte Einführung. Besonders relevant für die vorliegende Studie ist die Arbeit von [Ornstein et al. \(2025\)](#), die zeigt, dass LLMs multidimensionales ideologisches Scaling mit hoher Reliabilität durchführen können – eine direkte methodische Stützung des SWR-Ansatzes mit 12 Dimensionen. Arbeiten zu synthetischen Personas ([Ge et al., 2024](#)) demonstrierten die Skalierbarkeit des Ansatzes – verfolgten aber ein *anderes* Ziel: Sie nutzen synthetische Personas zur *Datenerzeugung*, während die vorliegende Studie sie zur *Rekonstruktion* kohärenter Weltbilder aus *realen* Daten einsetzt. Die synthetische Persona ist in unserem Verfahren kein Simulacrum, sondern ein analytisches Verdichtungsinstrument – näher am Weber’schen Idealtyp als am Simulationsagenten (vgl. [Booth, 1961](#); [Ng & Russell, 2000](#); [Jara-Ettinger, 2019](#)).

2.5 Zusammenfassung: Die Forschungslücke

Die vier Traditionen konvergieren auf eine gemeinsame Leerstelle: die systematische, datengestützte, längsschnittliche Vermessung konkreter Weltbilder der KI-Elite mittels einer Methode, die qualitative Tiefe mit quantitativer Systematik verbindet. Ergänzend sei auf die empirische Elitenforschung verwiesen: [Mills’](#) Analyse der „Power Elite“ als ineinander verschränkte Netzwerke aus Wirtschaft, Militär und Politik liefert ein Strukturmodell, das auf die KI-Elite übertragbar erscheint – mit dem Unterschied, dass technologische Kompetenz an die Stelle militärischer Macht getreten ist. Die vorliegende Studie adressiert die konvergierende Lücke, indem sie Elemente aller vier Traditionen integriert und um den Elitenbegriff ergänzt.

3. Methodik

Dieser Abschnitt stellt die vollständige Methodik dar, wie sie in dieser Studie implementiert wurde. Die synthetische Weltbild-Rekonstruktion (SWR) ist ein LLM-gestütztes Verfahren zur Inferenz kollektiver Überzeugungssysteme aus öffentlich beobachtbaren Daten. Die Kerneinsicht besteht darin, dass Weltbild-Analyse als inverses Problem formuliert werden kann: Gegeben die beobachtbaren Outputs (Aussagen und Handlungen) einer soziologisch definierten Gruppe, rekonstruiere das latente Überzeugungssystem, das diese Outputs am kohärentesten erzeugen würde. Die Methode nutzt die Fähigkeit großer Sprachmodelle, heterogene textuelle Evidenz in kohärente Repräsentationen zu synthetisieren – nicht durch Abruf gespeicherten Wissens über Einzelpersonen, sondern durch Konstruktion eines neuartigen kollektiven Porträts aus den präsentierten Daten. Der vorliegende Abschnitt ist für Zwecke der Evaluation und Replikation in sich geschlossen.

3.1 Datenerhebung

3.1.1 Stichprobe und Auswahlverfahren

Gegenstand der Untersuchung sind die 100 einflussreichsten Persönlichkeiten im Bereich der künstlichen Intelligenz (im Folgenden: KI-Elite). Die Auswahl erfolgte durch ein mehrstufiges Verfahren: Mittels 22 systematischer Webrecherchen wurden 187 Kandidatinnen und Kandidaten identifiziert. Jede Person wurde anhand eines 6-Kategorien-Scoring-Systems bewertet: (1) Marktkapitalisierung/Ressourcenkontrolle, (2) technologische Schlüsselpositionen, (3) öffentliche Diskursmacht, (4) akademischer Einfluss, (5) politische Einflussnahme, (6) symbolischer Status. Die resultierende Rangliste wurde auf 100 Personen reduziert, wobei die Heterogenität der Branche hinsichtlich Rollen, Firmenzugehörigkeiten, Haltungen und Geschlecht abgebildet wird (vgl. Anhang A).

3.1.2 Datenquellen und Erhebungszeitraum

Der Erhebungszeitraum erstreckt sich vom 1. Januar 2010 bis zum 11. Februar 2026. Die Datenerhebung stützt sich auf zwei Datentypen: **öffentliche Aussagen** (wörtliche Zitate aus Interviews, Keynotes, Podcasts, Twitter/X-Posts, Blogbeiträgen, Büchern, Kongressanhörungen) und **beobachtbare Handlungen** (Investitionsentscheidungen, Firmengründungen, Personalentscheidungen, politische Aktivitäten, Produkteinführungen). Die Verknüpfung wurde in einer relationalen SQLite-Datenbank mit 9 Tabellen und 5 Views operationalisiert. Die Gesamtmenge beläuft sich auf 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte). Nach Anwendung der Ein- und Ausschlusskriterien (siehe unten) wurden 1.735 Aussagen für die Analyse beibehalten (3 Near-Duplikate ausgeschlossen, 4 Grenzfälle geprüft und einbezogen).

Datendichte pro Akteur: Die Anzahl der Datenpunkte pro Akteur reicht von 20 (Minimum) bis 72 (Maximum), mit einem Mittelwert von 31,3 ($SD \approx 12$). Die zeitliche Verteilung ist un- ausgewogen: Die Jahre 2010–2011 tragen jeweils nur 17 Datenpunkte bei, während 2024 insgesamt 735 beiträgt. Diese Ungleichverteilung spiegelt das exponentielle Wachstum des öffentlichen KI-Diskurses wider und wird durch Epochen-Aggregation in der Längsschnittanalyse (Abschnitt 4.2) adressiert.

Datenqualität. Die automatisierte Metadaten-Verifizierung aller 1.735 einbezogenen Aussagen zeigt: 95,2 % tragen einen Quelllink, 94,5 % einen Quellentitel und 95,3 % ein Äußerungsdatum. Eine manuelle Stichprobe von 20 zufällig gezogenen Aussagen bestätigte, dass alle Links zu verifizierbaren Quellen führen (CNBC, Financial Times, Stanford University, Twitter/X, Unternehmenswebsites).

3.1.3 Methodologische Verankerung

Die Datenerhebung folgt dem Grounded-Theory-Ansatz nach [Strauss & Corbin \(1990\)](#): In Phase 1 wurden keine inhaltlichen Filter angewandt; in Phase 2 wurden mittels offenen Kodierens

Muster identifiziert; in Phase 3 wurde ein datengestütztes Kategoriensystem mit 13 Primärkategorien und 13 Sekundärmarkern entwickelt (6.161 Kodierungen insgesamt, durchschnittlich 3,5 Codes pro Aussage). Ein- und Ausschlusskriterien wurden erst in Phase 5 formuliert (3 Near-Duplikate ausgeschlossen); in Phase 6 erfolgte eine Qualitätssicherung (automatisierte Metadaten-Verifizierung aller Aussagen sowie manuelle Stichprobe von $n = 20$).

3.2 Die Methode der synthetischen Weltbild-Rekonstruktion

Die SWR definiert Weltbild-Analyse als inverses Problem: Aus den aggregierten beobachtbaren Aussagen und Handlungen der Mitglieder einer *Gruppe* wird auf das kollektive Überzeugungssystem W_G^* zurückgeschlossen, das diese Outputs am kohärentesten erzeugen würde. Formal: Gegeben die Menge aller öffentlichen Aussagen $\{A_1, \dots, A_n\}$ und dokumentierten Handlungen $\{H_1, \dots, H_m\}$ einer soziologisch definierten Gruppe G , rekonstruiere W_G^* so, dass die Gesamtheit der beobachteten Outputs unter W_G^* maximal kohärent ist. Die Lösung besteht in der Konstruktion einer *fiktiven synthetischen Person* – eines Weberschen Idealtyps, der das Gruppenweltbild in Reinform repräsentiert, befreit von individuellem biographischem Rauschen und PR-Strategien.

Die SWR nutzt einen strukturellen Vorteil der Analyse auf Gruppenebene: Kein LLM-Trainingskorpus enthält „das kollektive Weltbild der CEOs“ oder „das geteilte Überzeugungssystem der Risiko-Warner“ als vorgeformtes Objekt. Das kollektive Weltbild wird durch die Synthese *erzeugt*, nicht aus dem Gedächtnis abgerufen. Dies reduziert strukturell das Kontaminationsrisiko, das die primäre methodische Sorge bei LLM-basierter Rekonstruktion darstellt – ein Vorteil, der für Analysen auf Individualebene nicht gilt, wo das LLM auf umfangreiches gespeichertes Wissen über spezifische öffentliche Persönlichkeiten zurückgreifen kann.

In der vorliegenden Studie sind die primären Analyseeinheiten soziologisch definierte Gruppen (CEOs, Akademiker, Investoren, Gründer, Frauen, Männer, Beschleuniger, Risiko-Warner usw.); die 100 Einzelpersonen dienen als Datenlieferanten, deren Aussagen und Handlungen auf Gruppenebene aggregiert werden. Die theoretische Verankerung stützt sich primär auf Webers Idealtyp – eine Tradition, die explizit für Analysen auf Gruppenebene konzipiert wurde –, ergänzt durch Booths *Implied Author*, Inverse Reinforcement Learning und projektive Tests. Der operative Ablauf umfasst fünf Schritte: (1) Gruppenspezifischen Datenkorpus zusammenstellen, (2) LLM-gestützte Synthese einer fiktiven synthetischen Person, (3) strukturiertes Interview zu Selbstbild, Weltbild und Menschenbild, (4) Meta-Reflexion zu internen Spannungen und blinden Flecken, (5) dimensionales Rating auf 12 Dimensionen (D01–D12). Schritte 1–4 bilden die Synthese-Pipeline und stellen die methodische Kerninnovation dar; Schritt 5 (dimensionales Rating) ist eine für diese Studie gewählte Operationalisierung, die grundsätzlich durch andere Analysemethoden wie Diskursanalyse, psychometrische Skalen oder strukturierte Interviewprotokolle ersetzbar ist. Die Fokuskontrollinfrastruktur, die Begründung des Fiktionsansatzes und der Validierungsrahmen werden im Abschnitt Qualitätssicherung unten (Abschnitt 3.6) dargelegt. Die Übertragbarkeit der Methode auf andere Populationen (politische, militärische,

religiöse Eliten) ist eine natürliche Erweiterung, die gesonderte Untersuchung erfordert.

3.2.1 Datenaggregationsverfahren

Synthesen auf Gruppenebene operieren direkt auf den gepoolten Rohdaten – nicht auf aggregierten Individualprofilen. Für jede Syntheseinheit (z. B. „alle CEOs“) werden die Aussagen und Handlungen aller Gruppenmitglieder in ein einzelnes Dossier zusammengefasst, chronologisch sortiert und dem LLM als eine Eingabe präsentiert. Das LLM konstruiert dann eine fiktive synthetische Person, deren Weltbild die Gesamtheit der präsentierten Gruppendaten am besten erklärt. Entscheidend ist, dass keine intermediäre Aggregation auf Individualebene stattfindet: Das kollektive Porträt entsteht direkt aus der gepoolten Evidenz, analog dazu, wie ein Historiker den *Zeitgeist* einer Epoche aus Primärquellen rekonstruiert, nicht aus gemittelten Biographien. Die 100 individuellen Rating-Profile wurden separat für einen einzigen technischen Zweck generiert: die 100×12 -Datenmatrix für algorithmische Strukturprüfungen (PCA, HDBSCAN, Kruskal-Wallis) bereitzustellen. Sie gehen nicht in die Gruppensynthese-Pipeline ein und werden nicht als inhaltliche Befunde berichtet.

3.3 Operationalisierungen

Die drei abhängigen Variablen (AV1: Selbstbild, AV2: Weltbild, AV3: Menschenbild) werden durch sechs im SWR-Framework definierte Operationalisierungen zugänglich gemacht, von denen fünf in dieser Studie angewendet wurden (Op1, Op2, Op4, Op5, Op6):

Tabelle 1: Die sechs Operationalisierungen der SWR.

Op	Technik	Beschreibung	MVs
Op1	T1 Kern-Synthese	Fiktive Person + 3-Fragen-Interview + Reflexion	7
Op2	T4 Rating	Bewertung auf 12 Dimensionen (D01–D12), Skala 1–10	12
Op3	Textanalyse	TF-IDF, Sentiment, Metaphern, Embeddings, Topics	8+
Op4	T3 Kreuzmodal	Vorhersage: Aussagen → Handlungen (5 Gruppen, 72 % bestätigt, 0 % widerlegt)	4
Op5	T5 Clustering	PCA + HDBSCAN auf Ratingmatrix (siehe Abschnitt 4.4)	6*
Op6	T2 Dialog	Strukturierter Vergleich zweier Synthesen	3

Op3 (Textanalyse) wurde nicht durchgeführt. Op5 wurde als PCA + HDBSCAN auf der 100×12 -Ratingmatrix implementiert, nicht als Sentence-BERT-Clustering.

Die 12 Rating-Dimensionen (Op2) wurden in einem iterativen Verfahren entwickelt: Ausgehend von der ideologiekritischen Literatur (Solutionismus, TESCOREAL, Californian Ideology) und der Transhumanismus-Forschung wurden zunächst 18 Kandidaten-Dimensionen identifiziert, die in einer Pilotphase auf 12 reduziert wurden – unter den Kriterien inhaltlicher Distinktheit, Abdeckung aller drei AVs und praktischer Operationalisierbarkeit im LLM-Rating-Kontext. Die Dimensionen erheben keinen Anspruch auf Exhaustivität; alternative

Dimensionierungen (z. B. Risikowahrnehmung, Internationalismus, epistemologische Grundhaltung) wären denkbar und könnten in Folgestudien ergänzt werden. Die 12 Dimensionen verteilen sich gleichmäßig auf die drei AVs: Selbstbild-Dimensionen D01–D04 (Sendungsbewusstsein, Selbstwirksamkeit, Arbeitsethos, Verantwortungsgefühl), Weltbild-Dimensionen D05–D08 (Techno-Determinismus, Fortschrittsglaube, Machtkonzentration, Dringlichkeit) und Menschenbild-Dimensionen D09–D12 (Menschenfreundlichkeit¹, Posthumanismus, Egalitarismus, Kontrollüberzeugung). Die vollständige Dimensionentabelle mit Skalenpolen findet sich in Anhang B.

3.4 Forschungsdesign

3.4.1 Variablenarchitektur

Das Forschungsdesign ist als vierstufige Architektur konzipiert: 3 AVs → 6 Operationalisierungen → 50+ Messvariablen → 6 unabhängige Variablen (UVs). Die UVs bestimmen, welche Daten in eine Syntheseinheit (SE) eingehen, wobei jede SE eine *Synthese auf Gruppenebene* darstellt – das kollektive Weltbild einer soziologisch definierten Subgruppe:

- UV1 *Zeitraum*: Einzeljahre (2010–2026), Epochen, Gesamtzeitraum
- UV2 *Modalität*: Aussagen+Handlungen (AH), nur Aussagen (A), nur Handlungen (H)
- UV3 *Personengruppe*: Alle 100, Top 10, Subgruppen (Rollen, Firmen, Haltung, Geschlecht)
- UV4 *Inhaltskategorie*: Durch emergente Cluster ersetzt (K9)
- UV5 *Kongruenzstatus*: Konsistent vs. widersprüchlich
- UV6 *Homogenisierung*: Alle vs. nur häufig wiederholte Aussagen

3.4.2 Systematische Reduktion

Der theoretische Kombinationsraum von ca. 1.227 möglichen SEs wurde durch neun Reduktionskriterien (K1–K9; vgl. Anhang C) auf 51–56 Kern-SEs reduziert (95,4 % Reduktion). Zusätzlich wurden 9 strukturierte Vergleichs-Runs (Op6) durchgeführt. Die kreuzmodale Vorhersage (Op4) wurde für fünf Gruppen mit strikter Instanztrennung durchgeführt: Auf Aussagen basierende Verhaltensvorhersagen wurden in 98 % der Fälle durch reale Handlungen bestätigt oder als plausibel bewertet, bei 0 % Widersprüchen (siehe Abschnitt 3.6).

¹Das Label „Menschenfreundlichkeit“ ist eine vereinfachende Kurzbezeichnung und potenziell irreführend: Ein Wert von 5 bedeutet *nicht*, dass die KI-Elite „menschenfeindlich“ ist. Die Skalenpole „Ersetzbar“ (1) vs. „Einzigartig“ (10) messen präziser eine *anthropologische Wertschätzung* – die Frage, ob menschliches Bewusstsein und Erleben als grundsätzlich nicht-substituierbar oder als funktional reproduzierbar betrachtet wird. Der präzisere Terminus wäre „Anthropologische Wertschätzung“; der Begriff „Menschenfreundlichkeit“ wird beibehalten, um Konsistenz über die Studie hinweg zu wahren.

3.4.3 Zuordnung: Forschungsfragen, Operationalisierungen und Kern-SEs

Tabelle 2 gibt eine kompakte Übersicht, welche Operationalisierungen und Syntheseeinheiten den sechs Forschungsfragen zugeordnet sind.

Tabelle 2: Zuordnung von Forschungsfragen, Operationalisierungen und Kern-SEs.

F	Ops	Kern-SEs	Gegenstand
F1	Op1, Op2, Op3	1, 4, 5	Kollektiv- und Top-10-Profil, Kernüberzeugungen
F2	Op2, Op3	6–26	Jahres- und Epochen-Synthesen, Trends
F3	Op2, Op4	2, 3, 42–43	Aussagen vs. Handlungen, Kongruenzprüfung
F4	Op2, Op5	27–41	Gruppen-Synthesen, Cluster-Identifikation
F5	Op2, Op6	27–41	Subgruppen-Vergleiche
F6	Op2	4, 27–30	Macht-Weltbild-Zusammenhang

3.5 Positionierung des Forschers

Der Verfasser ist unabhängiger Forscher ohne institutionelle Anbindung an eines der untersuchten Unternehmen oder Forschungslabore. Diese Außenseiterposition ermöglicht eine größere Distanz zum Forschungsgegenstand, bringt aber spezifische blinde Flecken mit sich: (a) fehlender Zugang zu internen Diskursen und nicht-öffentlichen Positionen; (b) Abhängigkeit von öffentlich zugänglichen Quellen, die PR-gefiltert sein können; (c) potenzielle Neigung, die Geschlossenheit und Kohärenz der untersuchten Gruppe zu überschätzen, da die interne Vielfalt aus der Außenperspektive weniger sichtbar ist. Die Studie ist zudem als deutschsprachige Analyse eines überwiegend englischsprachigen Diskurses situiert, was Nuancen in der Übertragung erzeugen kann.

3.6 Qualitätssicherung

Die methodische Qualität wird durch vier Design-Maßnahmen, vier abgeschlossene Post-hoc-Validierungen und eine verbleibende offene Aufgabe adressiert. *Design-Maßnahmen:* (1) Mindestgröße von 15 Datenpunkten pro SE², (2) konsequente Fokuskontrolle mittels eines Anonymisierungsskripts, das alle Personennamen, Firmennamen, Produktnamen und Universitätszugehörigkeiten durch neutrale Platzhalter ersetzt, um sicherzustellen, dass das LLM die präsentierten Daten verarbeitet, anstatt auf gespeichertes Wissen zurückzugreifen, (3) Reproduzierbarkeitsprotokoll (Temperatur 0, vollständige Prompt-Dokumentation, alle Prompts im Repository archiviert) und (4) algorithmische Strukturprüfung der Clusterstruktur via PCA und HDBSCAN auf der 100 × 12-Ratingmatrix. *Offene Validierungsaufgabe:*

²Der Schwellenwert von 15 Datenpunkten stützt sich auf methodische Überlegungen: In der qualitativen Sozialforschung gelten 6–12 Interviews als hinreichend für thematische Sättigung (Strauss & Corbin, 1990), während neuere Schätzungen die thematische Sättigung typischerweise zwischen 12 und 20 Einheiten verorten (Guest et al., 2006; Fugard & Potts, 2015). Der Wert von 15 ist konservativ gewählt, um eine ausreichende Datendichte für die LLM-gestützte Synthese sicherzustellen.

Inter-Modell-Replikation (unabhängige Replikation der vollständigen Analyse mit mindestens einem weiteren Frontier-Modell durch andere Forschende) steht noch aus; dies stellt eine externe Replikation dar, nicht eine Voraussetzung für die interne Validität der vorliegenden Studie. *Abgeschlossene Validierung:* (a) **Intra-Modell-Inter-Instanzen-Rating-Reliabilität (IMIIRR):** Fünf Gruppen-Syntheseeinheiten wurden jeweils zweimal unabhängig von Claude Opus 4.6 verarbeitet. Die resultierenden D01–D12-Profile zeigten exzellente Konvergenz: Gesamt-Pearson $r = 0,908$, $\text{ICC}(2,1) = 0,902$, $\text{MAE} = 0,40$ auf der 10-Punkte-Skala (Messgenauigkeit $\pm 0,2$ Skalenpunkte). Alle 12 Dimensionen waren über die Durchläufe stabil (mittleres $|\Delta| \leq 0,8$). Eine nachfolgende Validierung mit $N = 15$ vollständig unabhängigen Opus-Instanzen — jede in einem separaten Agenten ohne geteilten Kontext — auf einer einzelnen Gruppen-Syntheseeinheit (GA_ges_AH) bestätigte diesen Befund mit höherer statistischer Power: $\text{ICC}(3,1) = 0,847$, mittlere $\text{SD} = 0,45$ über alle 12 Dimensionen (Bereich: 0,00–0,74). Bemerkenswert: Eine Dimension (D02, Selbstwirksamkeit) zeigte perfekte Übereinstimmung – alle 15 Instanzen vergaben exakt denselben Wert. Die übrigen Dimensionen variierten um höchstens ± 1 Punkt (10 von 12 hatten nur 2 verschiedene Werte über 15 Runs). Diese IMIIRR-Koeffizienten übertreffen die typische Inter-Rater-Reliabilität menschlicher Kodierer in qualitativer Forschung ($\text{ICC} = 0,6\text{--}0,8$; Hallgren 2012) und etablieren Claude Opus 4.6 als zuverlässig kalibriertes Instrument für die SWR-Methode. (b) **Expected-Discrepancy-Kontrolle:** Ein synthetischer Kontrollkorpus einer fiktiven konsistenten Gruppe (Umweltwissenschaftler, 30 Aussagen + 30 Handlungen ohne beabsichtigte Sagen-Handeln-Kluft) wurde in zwei Bedingungen durch dieselbe Pipeline verarbeitet: (v1) selbe Instanz für beide Datentypen ($\text{MAE} = 0,50$, $r = 0,912$) und (v2) strikte Instanztrennung, bei der Aussagen und Handlungen von unabhängigen Agenten verarbeitet wurden ($\text{MAE} = 0,92$). Die v2-Baseline ist methodisch angemessen, da auch der reale Sagen-Handeln-Vergleich Instanztrennung verwendet. Im Vergleich liegt die reale KI-Elite-Kluft unter gleichen Bedingungen bei $\text{MAE} = 0,75$ (v2), was *unter* die v2-Kontrollbaseline fällt – der aggregierte Gap ist somit nicht zuverlässig von Messrauschen unterscheidbar. Die Gruppendekomposition (siehe Abschnitt 4.3) zeigt jedoch, dass dieses Aggregat substanzielle gruppenspezifische Gaps verdeckt (CEOs: $\text{MAE} = 1,08$; Risiko-Warner: $\text{MAE} = 1,92$), beide über der Baseline. (c) **Aggregations-Synthese-Vergleich:** Zur Validierung des Gruppensynthese-Ansatzes wurden die D01–D12-Profile aus direkten Gruppensynthesen (gepoolte Rohdaten) mit aggregierten Individualprofilen (gemittelte Ratings der Gruppenmitglieder) über alle 15 soziologischen Gruppen verglichen. Die Gesamtkorrelation ($r = 0,623$, $\text{MAE} = 1,30$) zeigt moderate Konvergenz, mit einem systematischen *Amplifikationseffekt*: Direkte Gruppensynthesen erzeugen schärfere Konturen (71,7 % der Dimension-Gruppen-Kombinationen weiter vom Skalenmittelpunkt). Die Konvergenz ist am höchsten für ideologisch homogene Gruppen (Open Source $r = 0,857$, Beschleuniger $r = 0,855$) und am niedrigsten für heterogene (Frauen $r = 0,428$, Männer $r = 0,549$). Dieser Effekt ist interpretierbar als Gruppenkohärenz-Verstärkung, analog zur Gruppenpolarisierung in der Sozialpsychologie. (d) **Kreuzmodale Vorhersage (Op4):** Für

fünf soziologische Gruppen (CEOs, Akademiker, Risiko-Warner, Investoren, Beschleuniger) wurden jeweils zehn Handlungsvorhersagen ausschließlich aus dem Aussagenkorpus durch eine erste Agenten-Instanz (Op4a) generiert; diese Vorhersagen wurden dann durch eine *separate* Agenten-Instanz (Op4b), die die ursprünglichen Aussagen nie gesehen hatte, gegen die tatsächlich dokumentierten Handlungen evaluiert — wodurch ein Blindvergleich ohne Bestätigungsfehler sichergestellt wurde. Von 50 Vorhersagen wurden 36 (72 %) direkt durch reale Handlungen bestätigt, 13 (26 %) waren plausibel aber ohne direktes Match, und 0 (0 %) wurden widerlegt. Die Bestätigungsraten variierten nach Gruppentyp: ideologisch kohärente Gruppen zeigten die höchste Vorhersagbarkeit (Akademiker und Risiko-Warner: je 90 % bestätigt), während heterogene Gruppen niedrigere, aber dennoch substanzielle Raten aufwiesen (Investoren und Beschleuniger: je 50 % bestätigt, mit zusätzlich 40–50 % plausibel). Die nicht vorhergesagten Handlungen – politischer Opportunismus, massive kommerzielle Aktivität trotz warnender Rhetorik, interne Governance-Krisen – sind genau die Phänomene, die die Sagen-Handeln-Analyse (F3) aufdecken soll. (e) **Anonymisierungs-Robustheitstest:** Um zu prüfen, ob der Anonymisierungsansatz die Ergebnisse beeinflusst, wurde dieselbe Syntheseinheit (Risiko-Warner, 139 Aussagen + 92 Handlungen) mit drei verschiedenen Verblindungsstrategien verarbeitet: (A) Platzhalter-Tokens ([PERSON], [COMPANY]), (B) plausible fiktive Namen und (C) volle Offenlegung der realen Identitäten (Musk, Sutskever, Hinton, Russell, Bengio, Leike). Die Varianten A und B waren nahezu identisch ($r = 0,987$, $MAE = 0,33$). Variante C zeigte einen moderaten, aber nicht drastischen Anstieg: A–C $MAE = 0,67$, $r = 0,850$, mit demselben Gruppendurchschnitt (7,1). Die größte Verschiebung betraf D11 (Egalitarismus, +2 Punkte mit Identitätswissen). Dies bestätigt, dass Anonymisierung einen messbaren, aber bescheidenen Schutz bietet; Ratings auf Gruppenebene sind auch bei bekannten Identitäten robust. (f) **Rating-Reihenfolge-Invarianz:** Dieselbe Synthese (Risiko-Warner) wurde mit zwei verschiedenen Permutationen der D01–D12-Dimensionsliste bewertet. Alle 12 Ratings waren über die Permutationen identisch, was bestätigt, dass kein Listenreihenfolge-Effekt im Rating-Verfahren vorliegt. (g) **Instanztrennungs-Analyse:** Eine systematische Überprüfung historischer Analyse-Protokolle ergab, dass der ursprüngliche Sagen-Handeln-Vergleich (GA_ges_A vs. GA_ges_H, Batch 1) innerhalb derselben LLM-Instanz durchgeführt wurde – unter Verletzung des Prinzips unabhängiger Messung. Bei Wiederholung mit strikter Instanztrennung (jeder Datentyp in einem eigenen Agenten) schrumpfte die Sagen-Handeln-Kluft von $MAE = 1,42$ auf $MAE = 0,75$ (–47 %). Die Kontrollgruppen-Kluft (G6) stieg unter denselben Bedingungen von $MAE = 0,50$ auf $MAE = 0,92$. Folglich fällt die v2-Sagen-Handeln-Kluft unter die Kontrollbaseline, was darauf hindeutet, dass die *Gesamtmagnitude* der Kluft in Einzeldurchläufen nicht zuverlässig vom Messrauschen unterscheidbar ist. Allerdings bleiben zwei spezifische Dimensionen über beide Versionen stabil: D07 (Machtkonzentration: +2, Handlungen konzentrierter) und D11 (Egalitarismus: –2, Handlungen weniger egalitär). Diese bilden die robusten Sagen-Handeln-Befunde der Studie. (h) **Anthropic-Matched-Sample-Kontrolle:** Um zu testen, ob Claude eine systematische Verzerrung zugunsten

seiner Entwicklerorganisation aufweist, wurde die Anthropic-Subgruppe ($n = 9$) mit einer gematchten Kontrollgruppe von Nicht-Anthropic-Gründern und -Forschern ($n = 9$, gleiche Größe und Rollenzusammensetzung) verglichen. Die resultierenden Profile zeigten MAE = 1,00 ohne $|\Delta| \geq 3$ auf irgendeiner Dimension. Die beobachteten Unterschiede (Anthropic: höhere Dringlichkeit und Machtkonzentration; Kontrolle: höherer Posthumanismus und Kontrollüberzeugung) sind als genuine Gruppenunterschiede interpretierbar, nicht als Modellverzerrung. (i) **Ausreißer-Detektion:** Für fünf Gruppen wurde das rekonstruierte Weltbild mit den Originaldaten konfrontiert, um Aussagen und Handlungen zu identifizieren, die *nicht* zur Synthese passen. Die Gesamtpassung lag zwischen 80 % (Risiko-Warner) und 88 % (CEOs), mit 6–8 identifizierbaren Ausreißern pro Gruppe. Die Methode glättet nicht alle Daten in Kohärenz; dissidente Stimmen, interne Widersprüche und politische Heterogenität bleiben detektierbar. (j) **Inversions-Kontrolle (Anti-Kohärenz-Test):** Für fünf Gruppen wurden fiktive Anti-Personen konstruiert, deren Weltbilder den präsentierten Daten maximal *widersprechen*. In 58 % der Dimension-Gruppen-Kombinationen unterschied sich das Anti-Profil um ≥ 5 Punkte von der kohärenten Rekonstruktion, was bestätigt, dass die kohärente Interpretation eine spezifische, datengestützte Wahl ist – nicht die einzig mögliche Lesart. (k) **Einfluss-Strata-Vergleich:** Drei rangbasierte Strata (Top 10: Ränge 1–10, Avg 7,7; Mitte: Ränge 40–60, Avg 6,4; Bottom 10: Ränge 91–100, Avg 6,1) wurden unabhängig synthetisiert und bewertet. Ein Einflussgradient wurde bestätigt: Die mächtigsten Akteure vertreten die intensivsten Weltbilder. Zwei Dimensionen zeigten einen *inversen* Gradienten: D09 (Menschenfreundlichkeit: Top 4, Mitte 6, Bottom 8) und D10 (Posthumanismus: Top 8, Mitte 5, Bottom 3) – die mächtigsten Akteure sind die posthumanistischsten und am wenigsten menschenfreundlichen. (l) **Inter-Modell-Vergleich (Desiderat):** Ein Inter-Modell-Vergleich — Replikation der vollständigen Op1+Op2-Pipeline mit einem anderen Modell (z. B. Claude Haiku, GPT-4, Gemini) unter Verwendung von $N \geq 15$ vollständig unabhängigen Einzelinstanz-Runs — steht noch aus. Vorläufige Experimente mit Claude Haiku 4.5 deuteten auf systematische modell-spezifische Unterschiede in der interpretativen Gewichtung hin (moderatere, humanistischere Profile), konnten aber das strikte Unabhängigkeitskriterium der $N = 15$ Opus-Validierung (separater Agent pro Run, kein geteilter Kontext) nicht erfüllen. Ein methodisch rigoroser Inter-Modell-Vergleich wird als Priorität für zukünftige Arbeit identifiziert.

Alle Synthesen der vorliegenden Studie wurden mit Claude (Anthropic) generiert: Claude Sonnet 4.5 für Ratings auf Individualebene (9 parallele Batch-Agenten), Claude Opus 4.6 für qualitative Synthesen auf Gruppenebene, statistische Analysen und alle Validierungsexperimente. Kein anderes LLM wurde verwendet. Die Fokuskontrollinfrastruktur adressiert das, was konventionell als *Kontaminationsrisiko* bezeichnet wird: die Möglichkeit, dass das LLM auf Trainingswissen statt auf die präsentierten Daten zurückgreift. Wir bevorzugen den Begriff „Fokuskontrolle“, weil das Ziel nicht darin besteht, die Erkennung von Individuen zu verhindern – was weder möglich noch für die Analyse auf Gruppenebene notwendig ist –, sondern die *Aufgabentreue* sicherzustellen: Das Modell soll aus den bereitgestellten Daten synthetisieren,

nicht Stereotypen reproduzieren.

3.6.1 Dimensionalität des Ratingraums

Die 100 individuellen Rating-Profile wurden während der Datenerhebungsphase von Claude Sonnet 4.5 (9 parallele Batch-Agenten) generiert, wobei die öffentlichen Aussagen und Handlungen jedes Akteurs in einem einzelnen Durchlauf bei Temperatur 0 in ein 12-dimensionales Weltbild-Profil synthetisiert wurden. Diese Einzelprofile wurden für einen einzigen technischen Zweck generiert: die 100×12 -Datenmatrix für die algorithmische Strukturvalidierung (PCA, HDBSCAN) bereitzustellen. Sie gehen nicht in die Gruppensynthese-Pipeline ein – die Gruppensynthesen operieren direkt auf gepoolten Rohdaten (Abschnitt 3). Die Individualebene-Matrix ist somit ein Strukturvalidierungsinstrument, kein inhaltlicher Befund.

Eine Hauptkomponentenanalyse (PCA) der 100×12 -Ratingmatrix zeigt, dass **fünf Komponenten** 80 % der Gesamtvarianz erklären – die zwölf Dimensionen messen demnach ca. fünf unabhängige Konstrukte. PC1 (35,8 % Varianz) lädt am stärksten auf D02 (Selbstwirksamkeit, +0,40), D05 (Techno-Determinismus, +0,39) und D09 (Menschenfreundlichkeit, –0,39) – ein *Technologie-Kontroll-Faktor*, der technophile Handlungsfähigkeit und anthropologische Wertschätzung gegeneinander stellt. PC2 (19,2 % Varianz) lädt auf D01 (Sendungsbewusstsein, +0,51), D04 (Verantwortung, +0,50) und D08 (Dringlichkeit, +0,50) – ein *Engagement-Faktor*, der motivationale Intensität unabhängig von der ideologischen Richtung erfasst. Die moderate Redundanz (5 effektive Dimensionen aus 12) deutet darauf hin, dass das Dimensionssystem weder maximal effizient noch künstlich aufgebläht ist; es stellt eine angemessene Operationalisierung für explorative Arbeit dar.³

4. Ergebnisse

Die Befunde basieren auf synthetischen Weltbild-Rekonstruktionen auf Gruppenebene, abgeleitet aus den Daten der einhundert einflussreichsten KI-Persönlichkeiten, operationalisiert über zwölf Dimensionen auf einer Zehnpunkteskala. Die 100 Einzelpersonen dienen als Datenlieferanten; die Analyseeinheiten sind soziologisch definierte Gruppen (Alle 100, Top 10, CEOs, Akademiker, Investoren, Gründer, Männer, Frauen, Beschleuniger, Risiko-Warner, Firmen, Epochen). Der zentrale Beitrag des Ergebnisteils liegt in den Inter-Gruppen-Vergleichen (F4–F6), die offenlegen, wie strukturelle Position kollektive Überzeugungen formt. Unter *Weltbild* wird im Folgenden das Gesamtsystem aus Selbstbild, Welt- und Menschenbild verstanden (operationalisiert durch AV1–AV3); der Begriff *Überzeugungssystem* wird synonym verwendet, betont aber stärker den strukturellen Zusammenhang der Einzeldimensionen.

³Deskriptive Statistiken bestätigen diese Struktur: D11 (Egalitarismus) weist die größte Streuung auf (SD = 1,67) – die Dimension der stärksten Weltbild-Divergenz – während D03 (Arbeitsethos) die geringste zeigt (SD = 0,74), was den stärksten Konsens innerhalb der KI-Elite repräsentiert.

4.1 F1 – Weltbild der KI-Elite (deskriptiv)

4.1.1 Das kollektive Weltbild aller 100

Das Gesamtprofil – das kollektive Weltbild aller 100 Akteure als eine einzige Gruppe behandelt – deutet auf ein kohärentes, hochintensives Überzeugungssystem mit einem Durchschnittswert von 7,1 hin (Tabelle 3).⁴

Tabelle 3: Kollektiv-Profil der KI-Elite ($N = 100$, Aussagen und Handlungen).

Dimension	Rating	Interpretation
D01 Sendungsbewusstsein	8	Hoch
D02 Selbstwirksamkeit	8	Hoch
D03 Arbeitsethos	8	Hoch
D04 Verantwortungsgefühl	7	Mittel-hoch
D05 Techno-Determinismus	8	Hoch
D06 Fortschrittsglaube	7	Mittel-hoch
D07 Machtkonzentration	6	Mittel (ambivalent)
D08 Dringlichkeit	8	Sehr hoch
D09 Menschenfreundlichkeit*	5	Niedrig
D10 Posthumanismus	7	Mittel-hoch
D11 Egalitarismus	5	Niedrig
D12 Kontrollüberzeugung	8	Hoch
Durchschnitt	7,1	

Das Profil zeigt eine charakteristische Doppelstruktur: ausgeprägt elitäres Selbstbild (D01–D03 je 8), starker Techno-Determinismus (D05=8) und hohe Dringlichkeit (D08=8) einerseits; Menschenfreundlichkeit (D09=5) und Egalitarismus (D11=5) als tiefste Punkte andererseits. Die Kombination erzeugt ein auffallendes Muster, das sich – unter dem Vorbehalt, dass es sich um LLM-rekonstruierte Werte handelt – zuspitzend so formulieren lässt: eine Elite, die *für* die Menschheit bauen will, aber nicht *mit* ihr.

4.1.2 Das Weltbild der Top 10

Die zehn mächtigsten KI-Akteure vertreten dasselbe Weltbild in intensivierter Form (Avg 7,7). Auf zehn von zwölf Dimensionen liegen die Top-10-Werte exakt einen Skalenpunkt über dem Kollektiv. Die beiden Ausnahmen: Menschenfreundlichkeit (D09=4) und Egalitarismus (D11=4) liegen *niedriger*. Je mächtiger die Position, desto ausgeprägter das Sendungsbewusstsein und desto distanzierter das Menschenbild.

⁴Alle in dieser Studie berichteten Ratings sind LLM-generierte *Synthesen auf Gruppenebene*: Das Modell erhält die aggregierten Daten einer soziologisch definierten Gruppe und erzeugt ein einzelnes kollektives Profil. Ratings auf Individualebene werden ausschließlich für die algorithmische Validierung (PCA, HDBSCAN) verwendet, nicht als inhaltliche Befunde. Jede Synthese wurde in einem einzelnen Durchlauf bei Temperatur 0 generiert; Multi-Run-Konvergenztests bleiben eine offene Validierungsaufgabe. Dieses Design ist intentional: Die Studie zielt auf kollektive Weltbilder von Gruppen, nicht auf individuelle Profile.




Abbildung 1: Heatmap der 12 Weltbild-Dimensionen über alle untersuchten Gruppen. Hohe Werte (dunkel) markieren intensive Überzeugungen; die Doppelsenke bei D09 und D11 ist über alle Gruppen hinweg sichtbar.

4.1.3 Kernüberzeugungen

Die Destillation der am häufigsten wiederholten Aussagen (SE 5: HOM_haeuf_A, vgl. Anhang D) identifiziert fünf Überzeugungen als Minimalkonsens: (1) Technologie als moralisches Gebot, (2) Elite-Steuerung, (3) das Befreiungsnarrativ, (4) geopolitischer Manichäismus, (5) Arbeit als Identität. Sicherheitsrhetorik gehört zum Kernbestand des Diskurses, fungiert aber als diskursive Ressource, nicht als handlungsleitende Überzeugung.

Kernbefund F1: Die rekonstruierten Profile deuten auf ein kohärentes, hochintensives Überzeugungssystem hin, das sich als *technologischer Messianismus mit Ambivalenzstruktur* charakterisieren lässt. Die Bezeichnung „Messianismus“ ist dabei als idealtypische Zuspitzung zu verstehen, nicht als psychologische Diagnose: Sie bezeichnet die spezifische *Kombination* aus hohem Sendungsbewusstsein (D01), Techno-Determinismus (D05), Dringlichkeit (D08) und geringer anthropologischer Wertschätzung (D09) – ein Profil, das über bloßes Sendungsbewusstsein hinausgeht, weil es technologischen Fortschritt als quasi-erlöserische Notwendigkeit rahmt.

4.2 F2 – Wandel des Weltbilds (längsschnittlich)

4.2.1 Entwicklung der 12 Dimensionen über die Zeit

Von zwölf Dimensionen zeigen vier ausgeprägte lineare Trends (Tabelle 4).⁵

Tabelle 4: Ausgeprägte lineare Trends (OLS-Beschreibung, $n = 17$ Jahrespunkte).

Dimension	Richtung	Steigung/Dekade	R^2
D10 Posthumanismus	fallend	−2,4	0,63
D12 Kontrollüberzeugung	fallend	−1,5	0,54
D02 Selbstwirksamkeit	fallend	−1,0	0,31
D09 Menschenfreundlichkeit	steigend	+0,9	0,27

Den stärksten Rückgang verzeichnet der Posthumanismus (D10): von 10 im Jahr 2010 auf 6 im Jahr 2025. Die hohe Spearman-Rangkorrelation mit D12 ($r_s = +0,85$)⁶ weist auf ein zusammenhängendes Phänomen: Posthumanismus und Kontrollüberzeugung erodieren synchron. Der einzige deutlich steigende Wert betrifft die Menschenfreundlichkeit (D09), wobei die negative Korrelation mit D10 ($r_s = -0,58$) eine kompensatorische Verknüpfung nahelegt. Der Gesamtdurchschnitt bleibt nahezu konstant (Frühphase 7,5, Spätphase 7,3), was eine tektonische Verschiebung unter der Oberfläche verbirgt.

4.2.2 Wendepunkte und Epochenvergleich

Die Breakpoint-Detection – durchgeführt als visuelle Inspektion der Zeitreihen, ergänzt durch die Identifikation synchroner Extrempunkte über mehrere Dimensionen – identifiziert zwei zentrale Wendepunkte.⁷ Der erste liegt bei 2019: Vier Dimensionen (D01, D02, D05, D06) erreichen synchron ihren Tiefpunkt, zeitlich assoziiert mit der GPT-2-Zurückhaltung. Der zweite, dauerhaftere Wendepunkt liegt bei 2022/2023: Zeitgleich mit der ChatGPT-Veröffentlichung zeigt sich ein markanter Musterwechsel – Dringlichkeit erreicht ihr rekonstruiertes Maximum (D08=10), Egalitarismus fällt von 6 auf 4. Im Unterschied zu 2019 kehren die Werte nicht zurück; die rekonstruierten Profile nach 2022 deuten auf ein neues Gleichgewicht hin. Dabei ist zu beachten, dass die identifizierten Wendepunkte nicht isoliert von breiteren gesellschaftlichen

⁵Die hier berichteten Trendlinien beschreiben *Muster in rekonstruierten Daten*: Die Weltbild-Werte sind LLM-gestützte Rekonstruktionen, keine unabhängigen Messungen. OLS-Steigungen und R^2 dienen der Beschreibung der Verlaufsmuster, nicht der inferenzstatistischen Hypothesenprüfung. Eine externe Validierung (Expertenratings vs. SWR-Output) steht noch aus (vgl. Abschnitt Limitations).

⁶Die hier und im Folgenden berichteten Korrelationen (Spearman-Rangkorrelationen, berechnet über die 17 Jahreszeitpunkte) sind *Zusammenhänge innerhalb der LLM-Rekonstruktion*, nicht zwischen unabhängig gemessenen Variablen. Spearman wird verwendet, da die 12 Weltbild-Dimensionen Ordinalskalen darstellen; Pearson würde Intervallskalenniveau voraussetzen, das hier nicht gegeben ist. Die Korrelationen könnten interne Kohärenz des Modells widerspiegeln statt empirischer Zusammenhänge in der Realität (vgl. Abschnitt 6).

⁷Eine formale Breakpoint-Analyse (z. B. Bai-Perron-Test) war aufgrund der geringen Zahl von Zeitpunkten ($n = 17$) und der Natur der Daten (LLM-Rekonstruktionen, keine unabhängigen Messungen) nicht sinnvoll anwendbar. Die Wendepunkte sind daher als *deskriptive Beobachtungen* zu verstehen, nicht als statistisch gesicherte Strukturbrüche.




Abbildung 2: Zeitreihen der 12 Weltbild-Dimensionen (2010–2026). Ausgeprägte Trends sind hervorgehoben. Der markante Abfall von D10 (Posthumanismus) und D12 (Kontrollüberzeugung) bildet den „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird.




Abbildung 3: Spearman-Rangkorrelationsmatrix der 12 Dimensionen. Die starke positive Korrelation zwischen D10 und D12 sowie die negative Korrelation zwischen D10 und D09 bilden den empirischen Kern des „Utopie-Komplexes“.

Entwicklungen zu sehen sind: Die COVID-19-Pandemie (2020–2022) hat die Digitalisierungsdynamik beschleunigt und dürfte das Dringlichkeitserleben verstärkt haben; die zunehmende geopolitische Polarisierung (US-China-Technologiekonflikt) hat den „manichäischen“ Aspekt des Weltbilds möglicherweise befeuert; und der Beginn regulatorischer Initiativen (EU AI Act, 2021ff.) hat die Debatte um Governance verschärft. Diese Kontextfaktoren lassen sich mit der vorliegenden Methode nicht vom KI-spezifischen Wandel trennen.




Abbildung 4: Schlüsseltrends der Weltbild-Transformation. Die zwei Wendepunkte (2019, 2022/2023) und die drei Epochen (Prometheischer Optimismus, Erste Ambivalenz, Tragisches Bewusstsein) sind markiert.

4.2.3 Konvergenz oder Divergenz?

Die Daten zeigen eine zunehmende Ausdifferenzierung. Der ChatGPT-Effekt intensiviert sowohl die Architekten-Position (Beschleunigung, Machtkonzentration) als auch die Hüter-Position (Vorsicht, Regulierung) gleichzeitig – er wirkt als Katalysator der Bipolarisierung.

4.2.4 Metaphern- und Emotions-Wandel

Die Leitmetapher verschiebt sich von Prometheus – dem Feuerbringer – zum tragischen Helden, der retten muss, was möglicherweise nicht mehr zu retten ist. Die Handlung bleibt dieselbe (Beschleunigung), aber ihre emotionale Rahmung dreht sich um: nicht mehr aus Euphorie, sondern aus dem Glauben, dass die Alternative schlimmer wäre.

Kernbefund F2: Die rekonstruierten Profile deuten auf eine strukturelle Transformation des Weltbilds hin – von einer monochromen Utopie zu einer bimodalen Wette. *Tragisch* im Sinne der Bezeichnung „tragischer Beschleunigungszwang“ meint die gleichzeitige Erosion utopischer Gewissheiten und Persistenz der Handlungsrichtung: Die Akteure beschleunigen, obwohl

sie an der Zukunft zweifeln, die sie bauen – weil sie die Alternativen (geopolitischer Rückfall, Kontrollverlust an weniger verantwortungsvolle Akteure) als schlimmer bewerten. Drei Erosionstrends (D10, D12, D02) bilden einen „Utopie-Komplex“, dessen Zerfall durch steigende Dringlichkeit (D08) arithmetisch kompensiert wird. Allerdings ist nicht auszuschließen, dass der Rückgang des Posthumanismus (D10) teilweise ein Artefakt veränderter öffentlicher Diskurse ist: Wenn das Thema medial weniger präsent ist, sinkt auch die Datendichte entsprechender Aussagen, was die LLM-Rekonstruktion verzerren kann.

4.3 F3 – Kongruenz von Aussagen und Handlungen

Tabelle 5: Vergleich Aussagen (A) und Handlungen (H), $N = 100$. Werte sind Einzel-Run-Ratings auf Gruppenebene (v2, mit strikter Instanztrennung). v1-Werte (Same-Instance-Ratings) zum Vergleich.

Dimension	Sagen v2	Handeln v2	$\Delta v2$	$\Delta v1$	Stabil?
D01 Sendungsbewusstsein	9	9	0	-1	-
D02 Selbstwirksamkeit	8	9	+1	+1	✓
D03 Arbeitsethos	9	9	0	+1	-
D04 Verantwortungsgefühl	8	8	0	-2	-
D05 Techno-Determinismus	7	9	+2	+1	↑
D06 Fortschrittsglaube	8	8	0	-1	-
D07 Machtkonzentration	6	8	+2	+2	✓✓
D08 Dringlichkeit	9	9	0	+1	-
D09 Menschenfreundlichkeit	6	5	-1	-2	↓
D10 Posthumanismus	7	7	0	+1	-
D11 Egalitarismus	5	3	-2	-3	✓✓
D12 Kontrollüberzeugung	7	8	+1	-1	-
Durchschnitt	7,4	7,7	+0,3	-0,4	
MAE			0,75	1,42	

Methodische Anmerkung: Die v1-Ratings (in früheren Versionen dieser Studie berichtet) wurden innerhalb derselben LLM-Instanz generiert, wodurch Kreuzkontamination zwischen Aussagen- und Handlungsprofilen möglich war. Die hier gezeigten v2-Ratings verwenden strikte Instanztrennung: Jeder Datentyp wurde von einem unabhängigen Agenten ohne Zugang zum anderen verarbeitet. Dies reduzierte die Gesamtkluft von MAE = 1,42 auf MAE = 0,75 (-47 %), und die v2-Kluft fällt unter die Kontrollbaseline (G6 v2: MAE = 0,92). Das bedeutet: Die *Gesamt*-Sagen-Handeln-Kluft ist in Einzeldurchläufen nicht zuverlässig vom Messrauschen unterscheidbar.

Allerdings zeigen zwei spezifische Dimensionen *stabile* Diskrepanzen über beide Messbedingungen: **D07 Machtkonzentration** ($\Delta = +2$ in v1 und v2) und **D11 Egalitarismus** ($\Delta = -2$ in v2, -3 in v1). Diese bilden die robusten Sagen-Handeln-Befunde der Studie. Handlungen konzentrieren Macht stärker als die Rhetorik nahelegt, und Handlungen sind weniger egalitär.

tär als die Rhetorik behauptet. Beides ist konsistent mit einer strukturellen *Erwünschtheits-Asymmetrie*: Der öffentliche Diskurs überschätzt egalitäre und demokratische Commitments relativ zum operativen Verhalten.




Abbildung 5: Sagen vs. Handeln: Vergleich der aus Aussagen (A) und Handlungen (H) rekonstruierten Weltbilder. Die gesellschaftsorientierten Dimensionen (D04, D06, D09, D11) fallen im Handeln systematisch ab, während die machtsbezogenen Dimensionen (D07, D05) im Handeln steigen.

Die größte stabile Einzeldiskrepanz (D11, $\Delta - 2$ in v2, -3 in v1) zeigt: In Aussagen spricht die KI-Elite von „Zugang für alle“; in ihren Handlungen baut sie Mehrfach-Stimmrechtsaktien, konzentriert Compute-Infrastruktur und schafft exklusive Netzwerke. D07 (Machtkonzentration, $\Delta + 2$) ist der komplementäre Befund: Die Rhetorik favorisiert verteilte Governance, aber operative Entscheidungen zentralisieren Kontrolle.

4.3.1 Gruppen-Dekomposition der Sagen-Handeln-Kluft

Der aggregierte Sagen-Handeln-Vergleich verdeckt substanzielle gruppenspezifische Variation – ein Simpson-Paradox. Wenn fünf soziologische Gruppen mit strikter Instanztrennung analysiert werden (Aussagen- und Handlungskorpus von unabhängigen Agenten verarbeitet), emergieren drei distinkte Muster:

- **CEOs** (MAE = 1,08, über Baseline): Der klassische Erwünschtheits-Gap. Rhetorik ist egalitärer (D11: Sagen 5, Handeln 3, $\Delta = -2$) und weniger machtkonzentrierend (D07: Sagen 7, Handeln 9, $\Delta = +2$) als operatives Verhalten. CEOs sagen das „Richtige“ über verteilte Governance und bauen gleichzeitig Dual-Class-Aktienstrukturen.
- **Risiko-Warner** (MAE = 1,92, stärkster Gap): Kein inverser Gap, sondern *prophetische Konsistenz*. Bei Dekomposition nach abhängiger Variable wird das Muster klar: DV1 (Selbstbild, D01–D04) zeigt nahezu perfekte Konsistenz (MAE = 0,8) – Risiko-Warner wissen, wer sie sind. Die Diskrepanz konzentriert sich in DV3 (Menschenbild, MAE

= 3,2): Ihre *Aussagen* beschreiben eine gefürchtete Zukunft – Mensch als ersetzbar (D09: Sagen 4), posthumanistische Transformation als unvermeidlich (D10: Sagen 9) – während ihre *Handlungen* ihre tatsächlichen Werte offenbaren: hohe Menschenfreundlichkeit (D09: Handeln 8), Ablehnung des Posthumanismus in der Praxis (D10: Handeln 4), aktive Handlungsfähigkeit (D12: Handeln 8). Dies ist die Struktur prophetischer Warnung: eine Möglichkeitsprojektion artikulieren, die man *verhindern* will, und dann konsequent dagegen handeln. Ihr Sagen-Handeln-Gap ist keine Heuchelei, sondern die Signatur antizipatorischer Ethik – ein Befund, der ohne Gruppendekomposition unsichtbar bliebe.

- **Investoren** (MAE = 0,75, unter Baseline): Die konsistenteste Gruppe. Rhetorik und Handeln erzählen dieselbe Geschichte: radikaler Techno-Optimismus mit minimaler egalitärer Orientierung. Kein Erwünschtheits-Gap – sie meinen, was sie sagen.
- **Beschleuniger** (MAE = 0,92, an Baseline): Ein Grenzmuster, das einer schwächeren Version des CEO-Gaps ähnelt. Rhetorik ist optimistischer hinsichtlich Fortschritt (D06: $\Delta = -2$), verantwortungsvoller (D04: $\Delta = -2$) und egalitärer (D11: $\Delta = -2$) als operatives Verhalten.

Diese entgegengesetzten gruppenspezifischen Gaps heben sich im Aggregat auf (Gesamt-MAE = 0,75, unter der G6-v2-Kontrollbaseline von 0,92). Die Sagen-Handeln-Kluft ist nicht absent – sie ist *gruppenspezifisch und richtungsabhängig* und erfordert Dekomposition statt aggregierter Berichterstattung.

Kernbefund F3: Zwei robuste Sagen-Handeln-Diskrepanzen überstehen die Instanztrennung: D07 (Machtkonzentration) und D11 (Egalitarismus). Die Gesamtmagnitude der Kluft ist messbedingt variabel und sollte in Einzeldurchläufen nicht überinterpretiert werden. Aber die *Richtung* der Asymmetrie ist stabil: Der öffentliche Diskurs ist egalitärer und machtheilender als das operative Verhalten. Eine formale Quantifizierung (mit Konfidenzintervallen aus $N \geq 30$ wiederholten Messungen) bleibt ein Desiderat.

4.4 F4 – Weltbild-Cluster

Aus den Daten lassen sich vier distinkte Weltbild-Typen identifizieren (Tabelle 6).

Identifikationsmethode: Die Cluster-Identifikation erfolgte in einem zweistufigen Verfahren. *Stufe 1 (LLM-gestützt):* Alle 15 Gruppen-Synthesen wurden nach Ähnlichkeitsmustern in den 12 Dimensionen gruppiert, wobei die größten Varianzachsen (D07 Machtkonzentration, D09 Menschenfreundlichkeit, D11 Egalitarismus) als Trennmerkmale fungierten. *Stufe 2 (Autor-Validierung):* Die vom LLM vorgeschlagene Vier-Cluster-Lösung wurde vom Autor anhand inhaltlicher Kohärenz und Plausibilität evaluiert. Alternative Lösungen (drei und fünf Cluster) wurden geprüft und verworfen: Drei Cluster verschmelzen Innovator und Befreier,

was inhaltlich nicht gerechtfertigt ist; fünf Cluster spalten den Hüter-Typ in eine Untergruppe, die empirisch nicht stabil reproduziert werden konnte. Wir betonen, dass diese Cluster-Identifikation *explorativ* ist – eine konfirmatorische Validierung an einem unabhängigen Datensatz steht aus. Die Cluster-Lösung ist eine *interpretative Hypothese*, nicht ein statistisch abgesichertes Ergebnis im Sinne formaler Clusteranalyse.

Tabelle 6: Die vier Weltbild-Typen der KI-Elite. Die Werte sind Cluster-Durchschnitte aus den Gruppen-Synthesen; individuelle Abweichungen innerhalb eines Clusters können erheblich sein (vgl. die Andreessen-Diskrepanz in der nachfolgenden Fußnote).

Merkmal	I „Architekt“	II „Hüter“	III „Innovator“	IV „Befreier“
<i>n</i>	35	25	22	18
Prototyp	CEOs, Investoren	Akademiker, Risiko-W.	Gründer	Open Source
Avg D01–D12	7,8	6,4	7,2	6,8
D04 Verantwortung	6,3	9,0	8,3	6,0
D07 Machtkonzentr.	8,8	4,8	6,5	2,5
D09 Menschenfreundl.	3,3	5,8	4,8	6,5
D11 Egalitarismus	2,8	7,2	5,0	7,5

Der **Architekt** vereint maximales Sendungsbewusstsein mit minimalem Egalitarismus: Machtkonzentration ist Voraussetzung für Handlungsfähigkeit. Der **Hüter** bildet den Gegenpol: maximale Verantwortung, Forderung nach institutioneller Begrenzung. Der **Innovator** steht dazwischen. Der **Befreier** ist die überraschendste Entdeckung: minimale Machtkonzentration *und* hoher Egalitarismus – Regulierungsgegner, die Macht radikaler verteilen wollen als alle anderen, allerdings durch Märkte und Open-Source-Communities.⁸

Kernbefund F4: Die stärkste Polarisierung besteht zwischen Typ I (Herrschaftslogik) und Typ II (Teilhabelogik). Die explorative Vier-Cluster-Lösung bedarf einer konfirmatorischen Validierung an unabhängigen Daten, bevor sie als robustes Ergebnis gelten kann.

4.4.1 Algorithmische Validierung der Clusterstruktur

Um zu prüfen, ob die vier Weltbild-Typen natürlichen Daten-Clustern entsprechen, wurde HDBSCAN (dichtebasiertes Clustering) und KMeans auf die 100×12 -Ratingmatrix angewendet. **HDBSCAN auf dem vollen 12-dimensionalen Raum** klassifiziert 80–100 % der Fälle als Rauschen über alle getesteten Parameterkonfigurationen ($\text{min_cluster_size} \in \{5, 8, 10, 15\}$, $\text{min_samples} \in \{3, 5\}$); die beste Lösung findet nur 2 Cluster mit einem negativen Silhouette-Score ($-0,15$). KMeans mit $k = 4$ liefert einen Silhouette-Score von lediglich 0,169 – deutlich

⁸Der hohe D11-Wert des Befreier-Typs (7,5) und der niedrige D11-Wert einzelner Prototypen (z. B. Andreessen: D11=2) markieren eine Konstruktvaliditätsproblem: D11 misst Gleichheitsorientierung, nicht deren *Mechanismus*. Marktlibertärer Zugangs-Egalitarismus (Befreier) und redistributiver Egalitarismus (Hüter) produzieren ähnliche Skalenwerte auf D11, meinen aber Verschiedenes. Der Prototyp-Wert bezieht sich auf die Einzelperson-Synthese, der Cluster-Wert auf das Gruppenaggregat – Andreessens individuelles Profil weicht vom Cluster-Durchschnitt ab. Künftige Operationalisierungen sollten hier differenzieren.




Abbildung 6: Radar-Diagramm der vier Weltbild-Typen auf den 12 Dimensionen. Die Polarisierung zwischen Architekt (außen) und Hüter (innen) sowie die distinkte Position des Befreiers (hoher Egalitarismus bei niedriger Machtkonzentration) sind sichtbar.

unter dem Schwellenwert von 0,25, der typischerweise als Hinweis auf bedeutsame Struktur gilt.

Subspace-Clustering zeigt jedoch ein differenziertes Bild. Auf den beiden stärksten diskriminierenden Dimensionen (D07 Machtkonzentration und D11 Egalitarismus) identifiziert HDBSCAN mit `min_cluster_size = 5`, `min_samples = 2` neun Cluster mit einem *Silhouette*-Score von **0,57** (12 % Rauschen) – ein Hinweis auf substanzielle lokale Struktur in genau jenen Dimensionen, die die vier Idealtypen trennen. Analoges Subspace-Clustering auf den drei höchstladenden PCA-Dimensionen (D02, D05, D09) ergibt einen *Silhouette*-Score von 0,55. Zu beachten ist allerdings eine Zirkularitätsproblematik: D07 und D11 sind genau jene Dimensionen, die die Architekt-Befreier-Achse in der heuristischen Typologie definieren. Das Subspace-Clustering rediskoviert dadurch teilweise das Auswahlkriterium, anstatt eine unabhängige Validierung zu liefern. Damit wird zwar die dimensionale Separabilität bestätigt, nicht aber die Unabhängigkeit der Validierung von der Typologie-Konstruktion.

Dieses Muster bestätigt den epistemologischen Status der vier Typen: Es handelt sich um **Webersche Idealtypen** – heuristische Verdichtungen eines mehrdimensionalen Kontinuums, nicht um emergente Daten-Cluster. Ihr analytischer Nutzen wird durch diesen Befund nicht geschmälert; im Gegenteil, er wird durch hochsignifikante Kruskal-Wallis-Ergebnisse über die vier Typen bestätigt (Tabelle 7).

Tabelle 7: Kruskal-Wallis-*H*-Test über die vier Weltbild-Typen ($df = 3$, $N = 100$). Signifikanz: *** $p < 0,001$, * $p < 0,05$, n.s. = nicht signifikant. ^aNicht signifikant nach Bonferroni-Korrektur ($\alpha_{adj} = 0,004$). Hinweis: Diese Tests beschreiben Muster innerhalb LLM-generierter Rekonstruktionen; p -Werte sind nominal und sollten nicht als inferenzstatistische Hypothesentests im klassischen Sinne interpretiert werden.

Dimension	<i>H</i>	<i>p</i>	Sig.
D02 Selbstwirksamkeit	33,55	< 0,001	***
D06 Fortschrittsglaube	29,55	< 0,001	***
D07 Machtkonzentration	64,76	< 0,001	***
D09 Menschenfreundlichkeit	17,50	< 0,001	***
D11 Egalitarismus	49,57	< 0,001	***
D12 Kontrollüberzeugung	17,93	< 0,001	***
D04 Verantwortungsgefühl	10,76	0,013	* ^a
D05 Techno-Determinismus	11,21	0,011	* ^a
D01 Sendungsbewusstsein	2,59	0,459	n.s.
D03 Arbeitsethos	3,75	0,290	n.s.
D08 Dringlichkeit	6,25	0,100	n.s.
D10 Posthumanismus	4,04	0,257	n.s.

Nach Bonferroni-Korrektur für 12 simultane Tests ($\alpha_{adj} = 0,05/12 = 0,004$) erreichen D04 ($p = 0,013$) und D05 ($p = 0,011$) nicht mehr Signifikanz. Die sechs Dimensionen mit $p < 0,001$ bleiben nach Korrektur signifikant. Sechs von zwölf Dimensionen zeigen somit hochsignifikante Inter-Typ-Unterschiede ($p < 0,001$), während zwei weitere Dimensionen (D04, D05) nominale Signifikanz auf dem $p < 0,05$ -Niveau erreichen, aber die Bonferroni-Korrektur nicht

überstehen. Die vier nicht-signifikanten Dimensionen (D01, D03, D08, D10) repräsentieren den *geteilten Kern* des KI-Elite-Weltbilds – Überzeugungen, bei denen alle vier Typen konvergieren. D07 (Machtkonzentration, $H = 64,76$) und D11 (Egalitarismus, $H = 49,57$) sind die diskriminierendsten Dimensionen. Ein Zirkularitätsvorbehalt gilt: Da die vier Typen teilweise *durch* D07 und D11 definiert wurden, spiegeln die hohen H -Werte auf diesen Dimensionen teilweise das Konstruktionskriterium wider, nicht eine unabhängige Validierung. Die Kruskal-Wallis-Ergebnisse für die übrigen Dimensionen (D02, D06, D09, D12) sind informativer, da sie nicht in die Typenkonstruktion eingingen.

4.5 F5 – Subgruppenvergleiche

Die Inter-Gruppen-Vergleiche bilden den analytischen Kern der Studie. Durch den systematischen Vergleich der kollektiven Weltbilder soziologisch definierter Gruppen – differenziert nach institutioneller Rolle, ideologischer Haltung, Geschlecht, Firmenzugehörigkeit und Regulierungsposition – deckt die Analyse auf, welche strukturellen Faktoren die kollektiven Überzeugungen innerhalb der KI-Elite am stärksten prägen. Tabelle 8 ordnet die sechs diskriminierendsten Vergleiche.

Tabelle 8: Ranking der Subgruppen-Differenzen. $\Delta = \text{Gr. 1} - \text{Gr. 2}$ (Durchschnitt); Einzelkontraste beziehen sich auf die Dimension mit der größten Abweichung.

Rang	Vergleich	Avg Gr. 1	Avg Gr. 2	Δ	Stärkster Kontrast
1	Risiko vs. Speed	5,9	7,6	1,7	D02, D06, D10, D12: je -5
2	CEOs vs. Akademiker	7,8	6,3	1,5	D07: $+4$, D11: -4
3	Frauen vs. Männer	6,9	8,1	1,2	D11: -6
4	Open vs. Closed	6,8	6,3	0,5	D07: -3 , D12: $+3$
5	Reg-Pro vs. Contra	6,3	6,8	0,5	D04: $+4$, D06: -3
6	Anthropic vs. OpenAI	6,9	7,3	0,4	D12: -3

Der **stärkste Kontrast** (Risiko vs. Speed, $\Delta 1,7$) betrifft nicht die Risikoeinschätzung – beide Seiten veranschlagen die Katastrophenwahrscheinlichkeit auf 10–20 % –, sondern die ontologische Vorfestlegung: Risiko-Warner konzipieren KI als potenziellen autonomen Agenten, Beschleuniger als Werkzeug.

Effektstärken (Cliff's δ) quantifizieren diese Kontraste nicht-parametrisch (Schwellenwerte nach Romano et al. 2006: $|\delta| < 0,147$ vernachlässigbar, $0,147-0,33$ klein, $0,33-0,474$ mittel, $> 0,474$ groß). Die extremsten paarweisen Unterschiede zwischen den vier Weltbild-Typen treten auf der Macht-Egalitarismus-Achse auf: Architekt vs. Befreier ergibt $\delta = +1,0$ auf D07 (Machtkonzentration) und $\delta = -0,98$ auf D11 (Egalitarismus) – effektiv perfekte Separation. Architekt vs. Hüter erreicht $\delta = +1,0$ auf D07 und $\delta = -0,68$ auf D11. Über alle sechs Cluster-Paare hinweg produzieren D07 und D11 jeweils fünf mittlere bis große Effekte ($|\delta| \geq 0,33$), was sie als primäre Diskriminierungsdimensionen bestätigt.




Abbildung 7: Gruppen-Heatmap: 15 Subgruppen $\times$ 12 Dimensionen. Die systematische Variation von D07 (Machtkonzentration) und D11 (Egalitarismus) über alle Vergleiche hinweg ist der zentrale visuelle Befund.

Rollenbasierte Vergleiche zeigen ähnlich starke Effekte: Akademiker vs. Investoren unterscheiden sich auf 9 von 12 Dimensionen mit *großem* Effekt (am deutlichsten D02 Selbstwirksamkeit: $\delta = -0,88$; D12 Kontrollüberzeugung: $\delta = -0,71$; D09 Menschenfreundlichkeit: $\delta = +0,68$). CEOs vs. Akademiker zeigen große Effekte auf 6 Dimensionen (D02: $\delta = +0,79$; D06: $\delta = +0,58$; D12: $\delta = +0,55$).

Gender-Unterschiede erreichen Signifikanz auf 7 von 12 Dimensionen. Die größten Effekte betreffen D09 Menschenfreundlichkeit ($\delta = +0,59$, groß: Frauen höher), D05 Techno-Determinismus ($\delta = -0,50$, groß: Männer höher) und D11 Egalitarismus ($\delta = +0,46$, mittel). Diese Effektstärken sind moderater als die nominalen Gruppenkontraste ($\Delta = 6$) vermuten ließen, was zu erwarten ist: Cliff's δ erfasst die volle Verteilungsüberlappung, nicht nur Mittelwerte. Der oben genannte Kontaminationsvorbehalt gilt in vollem Umfang.

Der **größte nominale Einzelkontrast** der gesamten Erhebung findet sich bei D11 im Gender-Vergleich: sechs volle Skalenpunkte (Frauen: 8, Männer: 2). Das Frauen-Weltbild ist kein Anti-Technik-Weltbild, sondern ein *konditioniertes* Technik-Weltbild: gleich optimistisch, aber mit stärkeren ethischen Bedingungen. Dieser Befund ist jedoch der *am stärksten kontaminationsgefährdete* der gesamten Studie und wird daher als *vorläufige Hypothese* eingestuft, nicht als gesicherter Befund. Die Gründe: (a) LLMs reproduzieren bekannte Gender-Stereotypen, insbesondere die Zuschreibung erhöhter sozialer Orientierung an Frauen (Santurkar et al., 2023); (b) die Frauenstichprobe ist klein ($n = 18$); (c) die Effektgröße ($\Delta = 6$) übersteigt das in vergleichbaren empirischen Studien beobachtete Ausmaß deutlich. Eine unabhängige Validierung – idealerweise durch Replikation anderer Forschungsteams mit verschiedenen Modellen und Expertenratings – ist für diesen Befund besonders dringlich.

Die **größte Überraschung** liegt im Regulierungsvergleich: Anti-Regulierer haben den nied-

rigsten Machtkonzentrations-Wert aller 15 Gruppen (D07=2). Dies widerlegt das verbreitete Narrativ, Anti-Regulierer seien Vertreter von Konzerninteressen.

Kernbefund F5: Die drei stärksten Prädiktoren für das Weltbild sind die ideologische Grundhaltung, die institutionelle Rolle und das Geschlecht. Die polarisierendsten Dimensionen sind D11 und D07. Die *Machtfrage* ist der Kern der internen Differenzen.

4.6 F6 – Macht und Weltbild

Macht wird in dieser Studie operativ als Ressourcenkontrolle verstanden: die Fähigkeit, über Kapital, Compute-Infrastruktur, Forschungsteams und politischen Zugang zu verfügen und dadurch die Richtung der KI-Entwicklung zu beeinflussen. Diese Definition folgt dem soziologischen Machtbegriff im Sinne Webers („Chance, den eigenen Willen auch gegen Widerstreben durchzusetzen“) und Bourdieus (Kapitalakkumulation als Machtmechanismus), ohne eine umfassende machttheoretische Analyse zu beanspruchen.

Tabelle 9: Weltbild-Typen und Ressourcen-Kontrolle.

Typ	Avg	D11	D04	Ressourcen
I Architekt	7,8	2,8	6,3	Höchste
III Innovator	7,2	5,0	8,3	Hoch
IV Befreier	6,8	7,5	6,0	Mittel
II Hüter	6,4	7,2	9,0	Geringste

Die Daten aus F4 (Cluster-Analyse) weiterverfolgend, zeigt sich ein zusätzliches Muster auf der Machtebene: Je höher die Weltbild-Intensität, desto niedriger die Werte bei Menschenfreundlichkeit und Egalitarismus und desto höher die Machtkonzentrations-Akzeptanz. Das Investoren-Profil markiert den Extremfall: maximale Kontrollüberzeugung (D02=10) bei minimalem Verantwortungsgefühl (D04=4) – „Macht ohne Rechenschaft“. Das bereits in F1 beobachtete Muster (vgl. Abschnitt 4.1) verschärft sich: Macht intensiviert alle Überzeugungen – ausgenommen jene, die Macht selbst in Frage stellen.

Kernbefund F6: Die rekonstruierten Profile zeigen ein auffälliges Muster: Gruppen mit höherer Ressourcenkontrolle weisen intensivere Weltbild-Werte auf, bei gleichzeitig niedrigeren Werten bei Egalitarismus und Verantwortung. Da beide Seiten dieser Beobachtung auf LLM-Rekonstruktionen basieren, ist unklar, ob die Korrelation empirische Realität oder interne Modellkohärenz widerspiegelt. Falls robust, wäre dies der demokratietheoretisch relevanteste Befund der Studie.

Tabelle 10: Synopse der sechs Kernbefunde: Ergebnis, Konfidenz, Validierungsstatus und epistemischer Status. Konfidenz-Einstufung: *Hoch* = stabil über ≥ 3 Gruppen-Synthesen und durch Inter-Gruppen-Konsistenz oder interne Kohärenzprüfung gestützt; *Mittel-hoch* = stabil, aber ohne externe Validierung; *Mittel* = explorativ, abhängig von Cluster-Lösung oder kleiner Subgruppe. Epistemischer Status: (D) = deskriptiv, (E) = explorativ, (H) = hypothesengenerierend.

F	Kernbefund	Konfidenz	Extern val.?	Status
F1	Technologischer Messianismus mit Ambivalenzstruktur (Avg 7,1; Doppelsenke D09/D11)	Hoch	Inter-Gruppen	(D)
F2	Utopie-Komplex erodiert; tragischer Beschleunigungszwang (D10: -2,4/Dek.)	Mittel-hoch	Nein	(D)
F3	Richtungsabhängige Sagen-Handeln-Kluft (D07 +2, D11 -2; stabil über v1/v2)	Mittel	Nein	(H)
F4	Vier Weltbild-Typen: Architekt, Hüter, Innovator, Befreier	Mittel	Nein	(E)
F5	Stärkste Prädiktoren: Haltung, Rolle, Gender (vorläufig)	Mittel	Nein	(E)
F6	Macht-Gemäßigtheits-Paradox: Macht $\sim$ Extremität	Hoch	Nein	(H)

5. Diskussion

5.1 Zusammenfassung und Interpretation

Die Ergebnisse *legen nahe*, dass die KI-Elite, auf Gruppenebene analysiert, ein Muster aufweist, das sich idealtypisch als *technologischer Messianismus mit struktureller Ambivalenz* beschreiben lässt. Die Metapher des „Messianismus“ ist dabei analytisch gemeint – als Bezeichnung für die Kombination aus hohem Sendungsbewusstsein, Techno-Determinismus und Dringlichkeit –, nicht als Werturteil oder psychologisierende Zuschreibung. Der Begriff grenzt sich von verwandten Konzepten ab: [Morozovs](#) „Solutionismus“ erfasst die Problemlösungshaltung, nicht die quasi-religiöse Dringlichkeit; „Techno-Utopismus“ impliziert positiven Zukunftsglauben, der laut F2 gerade erodiert; „technologischer Messianismus“ bezeichnet spezifisch die Persistenz eines erlöserischen Handlungsimperativs *trotz* schwindendem Zukunftsoptimismus. Die sechs Forschungsfragen fügen sich zu einem in sich stimmigen Bild: F1 weist auf die „Doppelsenke“ bei D09 und D11 als kollektives Merkmal hin; F2 deutet auf eine Erosion des Utopie-Komplexes über die Epochen hin; F3 zeigt richtungsabhängige Sagen-Handeln-Diskrepanzen auf spezifischen Dimensionen (D07, D11), wobei die Gesamtmagnitude der Kluft vorsichtiger Interpretation bedarf; F4 differenziert vier Weltbild-Typen mit antagonistischen kollektiven Positionen; F5 und F6 vervollständigen das Bild durch das Macht-Gemäßigtheits-Paradox. Die Inter-Gruppen-Vergleiche (F5) bilden das analytische Herz der Studie: Der Befund, dass institutionelle Rolle, ideologische Haltung und Geschlecht die kollektiven Überzeugungsstrukturen systematisch formen, trägt direkte Implikationen für KI-Governance und demokratische Theorie. Alle Befunde basieren auf LLM-generierten Rekonstruktionen auf Gruppenebene und sind daher als *empirisch gestützte Hypothesen* zu verstehen, nicht als bewiesene Tatsachen. Formulierungen wie „zeigt“ und „offenbart“ sind durchgängig im Sinne von „die Daten legen nahe“ zu lesen.

Überraschend ist erstens die Richtungskonsistenz der Sagen-Handeln-Diskrepanzen über Messbedingungen hinweg (D07/D11 stabil in v1 und v2); zweitens der Rückzug des Posthumanismus (D10 von 10 auf 6 – widerlegt die gängige Annahme zunehmend posthumanistischer Orientierung); drittens die Existenz des Befreier-Typs (Opposition gegen Machtkonzentration auch von libertärer Seite); viertens die Konsistenz der Muster auf Gruppenebene über mehrere unabhängige Synthesen hinweg.

5.2 Einordnung in den Forschungsstand

[Morozovs](#) Solutionismus-These findet eine nahezu vollständige Bestätigung (D05=8–9, D06=7–9). Allerdings ist der Solutionismus kein monolithischer Block: Risiko-Warner (D05=4) teilen ihn deutlich weniger. Er ist die Ideologie des mächtigsten Segments, nicht der KI-Elite schlechthin.

[Daubs](#) Analyse der philosophischen Tiefenstrukturen wird durch die narrativen Synthesen bestätigt. Was die vorliegende Studie hinzufügt, ist die *Quantifizierung* und die Demonstration, dass sich die Intensität systematisch mit der Machtposition verstärkt.

Die von [Barbrook & Cameron \(1996\)](#) diagnostizierte Californian Ideology findet in der Existenz des Befreier-Typs ihre zeitgenössische Entsprechung – empirisch nachweisbar dreißig Jahre später.

[Coeckelberghs](#) Annahme einer zunehmenden Enhancement-Orientierung wird durch die rekonstruierten Trends partiell *in Frage gestellt*: Der deutliche Rückgang des Posthumanismus (D10 von 10 auf 6) legt nahe, dass das Interesse der KI-Elite an der technologischen Transformation des Menschen selbst abgenommen hat – zugunsten einer Fokussierung auf autonome KI-Systeme als eigenständige Akteure. Dabei sind drei alternative Erklärungen in Betracht zu ziehen: (a) der Rückgang könnte ein *Diskursartefakt* sein – posthumanistische Themen sind nach 2020 medial weniger präsent, was die Datendichte entsprechender Aussagen reduziert; (b) die Position könnte nicht verschwunden, sondern in neue Begriffe transformiert worden sein („AGI“ statt „Enhancement“); (c) der Trend könnte eine strategische *Selbstzensur* reflektieren, da posthumanistische Rhetorik politisch toxischer geworden ist.

Zum Gender-Befund. Der in F5 berichtete extreme Kontrast bei D11 (Frauen: 8, Männer: 2, $\Delta = 6$) ist der größte Einzelkontrast der gesamten Erhebung, aber zugleich der am stärksten kontaminationsgefährdete. LLMs reproduzieren bekannte Gender-Stereotypen – insbesondere die Zuschreibung erhöhter Empathie und sozialer Orientierung an Frauen ([Santurkar et al., 2023](#)). Da die Frauenstichprobe klein ist ($n = 18$) und die Ratings vom selben LLM generiert wurden, das diese Stereotypen internalisiert hat, ist nicht unterscheidbar, ob der Kontrast (a) eine reale Differenz in den Weltbildern, (b) ein LLM-Stereotyp-Artefakt oder (c) eine Mischung aus beidem reflektiert. Der Befund wird daher als *Hypothese* berichtet, die einer unabhängigen Validierung – idealerweise durch Replikation anderer Forschungsteams mit verschiedenen Instrumenten und Expertenratings – bedarf.

Die von [Gebru & Torres \(2024\)](#) vorgeschlagene TESCREAL-Taxonomie (Transhumanism, Extropianism, Singularitarianism, Cosmism, Rationalism, Effective Altruism, Longtermism) findet in der Vier-Cluster-Lösung eine empirische Ausdifferenzierung: Der Architekt-Typ verkörpert die machtpolitische Seite des TESCREAL-Bündels (Singularitarianism, Longtermism), der Hüter-Typ dessen institutionelle Kritik (Effective Altruism mit Sicherheitsfokus), der Befreier-Typ den libertären Extropianismus. Was die TESCREAL-Analyse als monolithisches Ideologiebündel beschreibt, zeigt sich in den Daten als Spektrum mit mindestens vier distinkten Positionen. [Becker \(2025\)](#) ergänzt diese Perspektive durch die Analyse der „Broligarchie“ als soziales Phänomen: Die Verschmelzung von technologischer Vision und männlicher Machtelite, die in der Gender-Analyse (F5, D11-Kontrast von 6 Skalenpunkten) ihren empirischen Niederschlag findet.

Paul Ricoeurs „Hermeneutik des Verdachts“ ([Ricoeur, 1970](#)) bietet einen ergänzenden analytischen Rahmen: Hinter der scheinbar neutralen, technisch-rationalen Sprachoberfläche der KI-Eliten-Kommunikation verbergen sich Machtinteressen und Klassendynamiken, die erst durch systematische Dekonstruktion sichtbar werden. Die SWR-Kongruenzanalyse (F3) operationalisiert diesen Verdacht empirisch: Die Δ -Werte zwischen Sagen und Handeln zeigen präzise, *wo* die performative Oberfläche von der operativen Realität abweicht.

Aus wissenschaftssoziologischer Perspektive lässt sich der Rückgang des Egalitarismus (D11) als Erosion der Merton’schen Wissenschaftsnormen lesen ([Merton, 1973](#)): Communalism (offener Zugang), Universalism und Organized Skepticism weichen zunehmend proprietären, beschleunigungszentrierten Logiken. Der Übergang von Forschungspublikation zu Produkt-Launch als primärem Output-Format ist ein sichtbarer Marker dieser Verschiebung.

Die Vier-Cluster-Lösung lässt sich darüber hinaus feldtheoretisch lesen: Die antagonistische Struktur zwischen Architekt (ökonomisches Kapital) und Hüter (symbolisches Kapital) reproduziert das von [Bourdieu \(1992\)](#) für das intellektuelle und künstlerische Feld diagnostizierte Muster einer *umgekehrten ökonomischen Welt*. Im KI-Feld gilt: Wer die meisten Ressourcen kontrolliert, hat die geringste Legitimation durch Gemeinwohlorientierung – und umgekehrt. Das Macht-Gemäßigkeits-Paradox (F6) lässt sich in dieser Perspektive als strukturelle Eigenschaft des Feldes lesen – wobei die explorative Natur der Cluster-Daten keine konfirmatorische Aussage erlaubt.

Der spezifische Mehrwert gegenüber essayistischen Diagnosen liegt in drei Punkten: *Masse* (100 Personen, 16 Jahre), *Differenzierung* (vier distinkte Typen) und *Validierung* (Kongruenzanalyse als empirischer Test).

5.3 Agentic Alignment vs. Worldview Alignment

Die in F3 angezeigten richtungsabhängigen Sagen-Handeln-Diskrepanzen (am robustesten: D07 Machtkonzentration $\Delta = +2$, D11 Egalitarismus $\Delta = -2$, stabil über Messbedingungen) lassen sich mit einer in dieser Studie eingeführten begrifflichen Unterscheidung schärfer

fassen, die auf Terminologie der KI-Alignment-Debatte zurückgreift.⁹ *Worldview Alignment* bezeichnet die rhetorische Reproduktion erwünschter Werte – das öffentliche Bekenntnis zu Gleichheit, Verantwortung und Menschlichkeit, wie es die „Sagen“-Seite der Analyse erfasst. *Agentic Alignment* bezeichnet die tatsächliche Ressourcenverteilung und Machtausübung – die „Handeln“-Seite. Die Befunde zeigen, dass die KI-Elite ein hohes Maß an Worldview Alignment aufweist (die „richtigen“ Werte werden artikuliert), während das Agentic Alignment systematisch davon abweicht. Dieser Dualismus verbindet die vorliegende KI-Elite-Studie mit der breiteren Alignment-Debatte und wirft die Frage auf, ob die gegenwärtigen Bemühungen um „AI Alignment“ nicht die performative Ebene (Worldview) mit der operativen (Agentic) verwechseln.

5.4 Methodische Reflexion

Die primäre Leistung der SWR liegt in der Verbindung qualitativer Tiefe mit quantitativer Systematik auf Gruppenebene. Die Studie identifiziert ein zuverlässiges Instrument – Claude Opus 4.6, validiert durch Intra-Modell-Inter-Instanzen-Rating-Reliabilität (IMIIRR, ICC = 0,902) – und demonstriert dessen konsistente Anwendung über alle Syntheseeinheiten. Dieser IMIIRR-Koeffizient übertrifft die typische Inter-Rater-Reliabilität menschlicher Kodierer in qualitativer Forschung (ICC = 0,6–0,8; Hallgren 2012), und das Instrument bietet einen distinktiven Vorteil gegenüber menschlichen Kodierern: Vollständig dokumentierte Prompts ersetzen implizite Kodierregeln und ermöglichen exakte Replikation. Die Kongruenzanalyse (F3) fungiert als interner Validitätstest; die Stabilität des Kollektiv-Profiles über 15 Gruppen-Synthesen und 4 Typen stärkt die Konvergenzvalidität. Die Inter-Gruppen-Vergleiche liefern eine eigene Form der Validierung: Wenn verschiedene Gruppensynthesen – unabhängig voneinander aus unterschiedlichen Daten-Subsets produziert – konsistente strukturelle Muster ergeben (z. B. die D07/D11-Achse als diskriminierendes Merkmal über alle Vergleiche hinweg), ist dies ein Beleg für die Robustheit der Methode, der über das hinausgeht, was eine einzelne Synthese leisten könnte. Die Replikation mit anderen Frontier-Modellen stellt eine unabhängige Forschungsaufgabe dar – analog zur Replikation einer Befragung mit verschiedenen Interviewer-Teams – und wird explizit als Desiderat für zukünftige Arbeiten identifiziert, nicht als Voraussetzung für die Validität der vorliegenden Studie. Die systematische Diskussion der methodischen Grenzen – Kohärenzbias, Kontaminationsrisiko, Fokuskontrolllimits, Prompt-Sensitivität – findet sich in Abschnitt 6.

⁹Weder *Worldview Alignment* noch *Agentic Alignment* entsprechen in der hier verwendeten Bedeutung einem fest etablierten Begriff der KI-Alignment-Literatur; das Begriffspaar wird als analytische Heuristik für diese Studie eingeführt, um die performative von der operativen Ebene des Wertausdrucks zu unterscheiden.

5.5 Gesellschaftliche und politische Implikationen

Die Befunde auf Gruppenebene tragen direkte Implikationen für KI-Governance und demokratische Theorie. Das Macht-Gemäßigtheits-Paradox – der systematische Befund, dass institutionelle Gruppen mit den meisten Ressourcen kollektive Weltbilder aufweisen, die am weitesten von demokratischen Idealen entfernt sind – stellt eine konkrete Herausforderung für die Regulierungsarchitektur dar. Dieser Befund resoniert mit Mills' (1956) klassischer Analyse der „Power Elite“ als sich selbst verstärkendes Stratum, dessen Weltbild systematisch von der breiteren Öffentlichkeit divergiert, und bestätigt die institutionenökonomische Analyse von Acemoglu & Johnson (2023): Technologische Eliten tendieren dazu, Innovationen so zu lenken, dass sie bestehende Machtstrukturen verstärken, statt sie aufzubrechen – ein Muster, das die Autoren historisch von der Industrialisierung bis zur Digitalisierung nachzeichnen. Gegenwärtige Governance-Ansätze (EU AI Act, Executive Order on AI) adressieren die technischen Artefakte, nicht die kollektiven Weltbilder der Gruppen, die diese Artefakte produzieren. Ein ergänzender Ansatz müsste die *epistemische Diversität* in KI-Führungspositionen als Regulierungsziel anerkennen.

Die systematische Sagen-Handeln-Kluft auf Gruppenebene hat eine Policy-Implikation: Freiwillige Selbstverpflichtungen – die derzeit bevorzugte Governance-Form (vgl. Bengio et al., 2024) – erscheinen unzureichend, wenn ganze institutionelle Gruppen (nicht nur vereinzelte Individuen) konsistente Diskrepanzen zwischen öffentlicher Rhetorik und beobachtbarem Handeln aufweisen. Die Befundlage legt nahe, dass verbindliche Strukturreformen wirksamer sein dürften als weitere Runden freiwilliger Commitments. Drei konkrete Ansatzpunkte zeichnen sich ab: (1) *Epistemische Diversitätsquoten* in KI-Governance-Gremien, die sicherstellen, dass nicht nur Technologen und Investoren, sondern auch Sozialwissenschaftler, Ethikerinnen und Betroffenenvertreter an Designentscheidungen beteiligt sind; (2) *verpflichtende Weltbild-Audits* für KI-Unternehmen ab einer bestimmten Größe, analog zu Nachhaltigkeitsberichten; (3) *stärkere Entkopplung* von Kapitalgebern und Forschungssteuerung, beispielsweise durch öffentlich finanzierte KI-Labore mit unabhängiger Governance (vgl. Acemoglu & Johnson, 2023).

Die Inter-Gruppen-Vergleiche offenbaren ein weiteres governance-relevantes Muster: Die Frage der Macht (D07) und der Gleichheit (D11) ist die Achse, entlang derer sich sämtliche Gruppenunterschiede organisieren. Ob CEOs mit Akademikern, Beschleuniger mit Risiko-Warnern oder Männer mit Frauen verglichen werden – die Macht-Gleichheits-Achse ist durchgängig die diskriminierendste Dimension. Dies legt nahe, dass die zentrale ideologische Bruchlinie innerhalb der KI-Elite nicht die Technik betrifft (alle Gruppen sind technologisch optimistisch), sondern die *Verteilung* technologischer Macht.

Ist sich die KI-Elite ihrer eigenen blinden Flecken bewusst? Das Verantwortungsgefühl (D04=7) ist nicht absent, aber funktional eingebettet: Es legitimiert das Weiterarbeiten, nicht das Innehalten. Der Befund, dass demokratische Langsamkeit durchgängig als Hindernis, nicht als Schutzfunktion begriffen wird, markiert den gravierendsten blinden Fleck einer Gruppe, die

darüber entscheidet, wie Milliarden Menschen in Zukunft leben werden.

5.6 Was die Studie nicht zeigt

Zur Vermeidung häufiger Fehlinterpretationen sei explizit festgehalten, was die vorliegende Studie *nicht* leistet: (1) keine *Kausalerklärung* (vgl. Abschnitt 6); (2) keine *individuellen Profile* – die 100 Akteure dienen als Datenlieferanten; die Analyseeinheiten sind soziologisch definierte Gruppen; die Ratings sind kollektive Abstraktionen auf Gruppenebene, keine Persönlichkeitsprofile oder individuelle Biographien; (3) keine *Vorhersagen* über künftiges Verhalten – die Weltbilder beschreiben den Zeitraum 2010–2026; (4) keine *repräsentative Stichprobe* im statistischen Sinne (vgl. Abschnitt 6); (5) kein Beweis, dass die *Sagen-Handeln-Kluft* auf bewusste Täuschung zurückgeht – alternative Erklärungen (institutionelle Zwänge, kognitive Dissonanz, rollenspezifische Kommunikation) sind gleichermaßen plausibel.

6. Limitationen

Tabelle 11 gibt einen kompakten Überblick über die identifizierten methodischen Probleme, ergriffene Gegenmaßnahmen und deren Ergebnisse. Die detaillierte Diskussion folgt in den Unterabschnitten.

Tabelle 11: Validierungsübersicht: Methodische Probleme, Gegenmaßnahmen und Ergebnisse.

Problem	Typ	Gegenmaßnahme	Ergebnis	Ref.
LLM-Kontamination	Design	Fokuskontrolle (Anonym. + Aufgabenfokus)	Var. C: MAE = 0,67	QA (e)
Anthropic-Zirkularität	Antizipiert	Matched-Sample ($n = 9$ vs. 9)	MAE = 1,00, kein Bias	QA (h)
Erwartungs-Diskrepanz	Post hoc	Instanztrennung (v2-Protokoll)	Lücke –47%; Gruppenlücken bestehen	QA (g)
Rating-Instabilität	Antizipiert	IMIIRR ($N = 15$ unabh. Runs)	ICC(3,1) = 0,847, Mean SD = 0,45	QA (a)
Reihenfolge-Effekt	Antizipiert	Permutationstest (2 Reihenfolgen)	12/12 identisch	QA (f)
Kohärenzbias	Antizipiert	Ausreißer-Detektion + Inversionskontrolle	80–88% Passung; 58% $\Delta \geq 5$	QA (i,j)
Artefaktische Sagen-Handeln-Kluft	Antizipiert	G6-Kontrollkorpus	v2-Baseline MAE = 0,92	QA (b)
Kreuzmodale Validität	Antizipiert	Op4-Vorhersage (5 Gruppen)	72% bestätigt, 0% widerlegt	QA (d)
Aggregationsverzerrung	Antizipiert	Direkt vs. aggregiert Vergleich	$r = 0,623$, Amplifikationseffekt	QA (c)
Einflussgradient	Post hoc	Strata-Vergleich (3 Rangstufen)	Gradient bestätigt; D09/D10 invers	QA (k)
Statist. Power	Abgeschlossen	$N = 15$ unabh. Opus-Runs	Mean SD = 0,45; Batch-1 in CI: 3/12	QA (a)
Modellsensitivität	Desiderat	Inter-Modell-Vergl. (unabh. Runs)	Zukünftige Arbeit	§ 6

6.1 Datenbezogene Limitationen

Quellenbias. Die Datenbasis beschränkt sich auf öffentliche Aussagen und beobachtbare Handlungen. Die rekonstruierten Weltbilder spiegeln das *öffentlich dargebotene* Weltbild wider, nicht

das *tatsächlich geglaubte*. Die Aussagen-Handlungen-Vergleichsanalyse (F3) bietet ein partielles Korrektiv, kann das Problem aber nicht eliminieren.

Zeitliche Ungleichverteilung. Die Datendichte variiert um Faktor ~ 43 : von 17 Datenpunkten im Jahr 2010 bis 735 im Jahr 2024. Für 2010–2015 liegen 2–5 Aussagen pro Person vor, für 2023–2026 dagegen 30–80. Das Kriterium K2 (Mindestgröße 15) und dokumentierte Zusammenlegungen mildern das Problem, und alle Jahres-Syntheseeinheiten erfüllen den Mindestschwellenwert; frühere Zeitreihen beruhen dennoch auf dünnerer Evidenz und sollten mit größerer Unsicherheit interpretiert werden.

Westlicher und Sprachbias. Die Stichprobe ist überproportional angloamerikanisch geprägt. Chinesische, japanische und südkoreanische KI-Persönlichkeiten sind unterrepräsentiert. Die Befunde gelten primär für die westliche KI-Elite.

Stichprobenabhängigkeit. Die Auswahl der 100 Personen erfolgte durch den Autor mittels eines mehrstufigen, aber letztlich subjektiven Scoring-Verfahrens. Eine intersubjektive Validierung der Stichprobenzusammensetzung (z. B. durch unabhängige Expertenpanels) steht aus. Da die Befunde sensitiv gegenüber der Stichprobenzusammensetzung sein könnten, ist eine Replikation mit alternativen Auswahlverfahren wünschenswert.

6.2 Methodische Limitationen

LLM-Kontamination und Fokuskontrollgrenzen. Trotz konsequenter Fokuskontrolle kann nicht ausgeschlossen werden, dass das LLM auf Trainingswissen zurückgreift. Die Fokuskontrolle operiert auf zwei Ebenen: (1) *Anonymisierung* – Ersetzung aller identifizierenden Informationen durch neutrale Platzhalter, sodass das Modell nicht an spezifischen Individuen ankern kann – und (2) *Aufgabenfokus* – das Prompt-Design lenkt das Modell darauf, ein kohärentes Weltbild aus den präsentierten Daten zu synthetisieren, ohne Verblindung, Identität oder die Existenz versteckter Informationen zu erwähnen (v2-Prompts, siehe Repository). Ein empirischer Test der Anonymisierungskomponente bestätigte, dass die Wahl der Verblindungsstrategie (Platzhalter-Tokens vs. fiktive Namen) keinen wesentlichen Effekt auf Ratings auf Gruppenebene hat ($r = 0,987$, $MAE = 0,33$, $\max |\Delta| = 1$; siehe Abschnitt 3.6). Eine dritte Variante (C) testete die vollständige Identitätsoffenlegung – dieselbe Syntheseeinheit wurde mit den echten Namen aller Gruppenmitglieder verarbeitet (Musk, Sutskever, Hinton, Russell, Bengio, Leike). Das Ergebnis zeigte einen moderaten, aber nicht drastischen Effekt: A–C $MAE = 0,67$, $r = 0,850$, bei identischem Gruppendurchschnitt (7,1). Die größte Verschiebung betraf D11 (Egalitarismus, +2 Punkte). Dies bestätigt, dass Anonymisierung einen messbaren, aber bescheidenen Schutz bietet; das kollektive Weltbild ist weitgehend stabil, auch wenn Identitäten bekannt sind. Entscheidend ist nicht, ob das Modell Individuen erkennt, sondern ob es seine Aufgabe erfüllt: eine kohärente Synthese auf Gruppenebene aus den bereitgestellten Daten zu konstruieren. Auf Gruppenebene ist das Kontaminationsrisiko strukturell reduziert, da kein LLM-Trainingskorpus vorgeformte kollektive Weltbilder soziologischer Gruppen enthält.

Anthropic-interne Zirkularität. Ein besonders zugespitzter Fall des Zirkularitätsproblems betrifft die Synthese auf Gruppenebene für Subgruppen, die Personen enthalten, die direkt an der Entwicklung des verwendeten LLM beteiligt sind. Claude Opus 4.6 wird von Anthropic entwickelt; mehrere Anthropic-Führungskräfte (z. B. Dario Amodei, Daniela Amodei) gehören zur analysierten Stichprobe und ihre Daten fließen in die Gruppensynthesen ein. Um systematische Verzerrungen zu testen, wurde eine Matched-Sample-Kontrolle durchgeführt: Die Anthropic-Subgruppe ($n = 9$) wurde mit einer gematchten Kontrollgruppe nicht-Anthropic-affiliierter Gründer und Forscher ($n = 9$, gleiche Größe und Rollenkomposition) verglichen. Die resultierenden Profile zeigten $MAE = 1,00$ ohne Dimensions-Differenz $|\Delta| \geq 3$. Die beobachteten Unterschiede – Anthropic-Mitglieder mit höherer Dringlichkeit (D08) und Machtkonzentration (D07), die Kontrollgruppe mit höherem Posthumanismus (D10) und Kontrollüberzeugung (D12) – sind als genuine Gruppenunterschiede interpretierbar, die Anthropics Safety-orientierte Kultur widerspiegeln, nicht als Modellverzerrung. Während dieser Within-Model-Test Zirkularität nicht vollständig ausschließen kann (eine Cross-Model-Replikation bleibt als externe Validierung wünschenswert), liefert er keinen Beleg für systematische Anthropic-spezifische Verzerrung.

Kritik synthetischer Personas. Die wachsende Literatur zu LLM-generierten synthetischen Personas mahnt zur Vorsicht, aber die Kritik muss sorgfältig eingegrenzt werden. [Santurkar et al. \(2023\)](#) zeigt, dass LLMs Meinungen spezifischer demografischer Gruppen systematisch verfehlen und „WEIRD“-Verzerrungen aufweisen, wenn sie als *Meinungsgeneratoren* eingesetzt werden – d. h. wenn sie aufgefordert werden zu simulieren, was eine demografische Gruppe denken könnte. Ebenso finden [Argyle et al. \(2023\)](#), dass synthetische Agenten Leitthemen erfassen, aber an authentischer Tiefe realer Diskurse scheitern, wenn sie qualitative Daten *generieren*. Ein aktuelles systematisches Review von 63 Peer-reviewed-Persona-Experimenten (2023–2025) bestätigt dieses Muster: Die meisten Studien spezifizieren die Zielpopulation unzureichend, nur 35 % adressieren Repräsentativität, und die ökologische Validität ist durchgängig gering ([Batzner et al., 2025](#)). Diese Kritiken zielen auf einen fundamental anderen Anwendungsfall als die SWR. In der vorliegenden Studie generiert das LLM keine Meinungen; es *verdichtet* 3.132 reale Datenpunkte (dokumentierte Aussagen und Handlungen) in strukturierte Profile auf Gruppenebene. Die synthetische Persona ist ein analytisches Verdichtungsinstrument – näher am Weber’schen Idealtyp als am Simulationsagenten. Die von [Santurkar et al.](#) identifizierte WEIRD-Verzerrung ist weitgehend orthogonal: Die KI-Elite *ist* eine westliche, gebildete, wohlhabende und industrialisierte Population, sodass jede demographische Schieflage in den Vorannahmen des Modells mit der Zielgruppe konvergiert, anstatt sie zu verzerren. Dennoch bleibt die Tendenz zur Überrepräsentation öffentlich dominanter Narrative und zur Unterrepräsentation idiosynkratischer oder widersprüchlicher Positionen eine genuine Limitation.

Quantifizierung und interne Konsistenz. Die in Abschnitt 4.2 berichteten Dimensionskorrelationen (z. B. $r_s = +0,85$ zwischen D10 und D12) werden innerhalb des Rating-Prozesses des LLM generiert und könnten teilweise interne Konsistenz statt empirischer Zusammenhänge

widerspiegeln. Dieses Problem betrifft spezifisch den *Rating-Schritt* (Op2) und gilt für jedes Rating-Verfahren einschließlich menschlicher Rater: Ein menschlicher Kodierer, der Posthumanismus hoch bewertet, wird durch kognitive Kohärenz auch Kontrollüberzeugung tendenziell hoch bewerten. Das Problem betrifft *nicht* die qualitativen Synthesen (Op1), die ohne dimensionales Prompting direkt aus den Rohdaten generiert werden. Mehrere Validierungsergebnisse begrenzen die Reichweite dieser Limitation: (1) Die kreuzmodale Vorhersage (G5, 72 % bestätigt) zeigt, dass LLM-rekonstruierte Muster empirische Substanz haben – aus Aussagen abgeleitete Vorhersagen wurden durch unabhängig evaluierte Handlungen bestätigt; (2) der Reihenfolge-Invarianztest zeigt, dass die Ratings nicht von der Präsentationsreihenfolge der Dimensionen abhängen; (3) die IMIIRR-Koeffizienten ($ICC = 0,902$ aus 5×2 Runs; $ICC = 0,847$ aus $N = 15$ unabhängigen Einzelinstanz-Runs) etablieren, dass das Rating-Verfahren stabil und reproduzierbar ist. Die berichteten Korrelationen sind als Muster eines zuverlässig kalibrierten Rekonstruktionsinstruments zu lesen, nicht als Artefakte willkürlichen Modellverhaltens – eine externe Replikation bleibt jedoch wünschenswert zur Bestätigung, welche spezifischen Korrelationen über Instrumente hinweg bestehen.

Statistische Power. Eine formale Power-Analyse wurde an einer Gruppen-Syntheseinheit (GA_ges_AH) mit $N = 15$ vollständig unabhängigen Opus-Instanzen (je ein separater Agent ohne geteilten Kontext) durchgeführt. Die Ergebnisse zeigen, dass das Instrument hochstabil ist: mittlere SD = 0,45 über alle 12 Dimensionen (Bereich: 0,00–0,74), mit 95 %-Konfidenzintervallen schmäler als $\pm 0,5$ Skalenpunkte für die meisten Dimensionen. Der ursprüngliche Batch-1-Einzelwert lag nur in 3 von 12 Konfidenzintervallen (MAE zum $N = 15$ -Mittelwert = 0,73), was bestätigt, dass Einzelmessungen unzuverlässig sind und $N \geq 15$ unabhängige Runs für robuste Profilschätzungen erforderlich sind. Die Analyse wurde jedoch an einer einzelnen Syntheseinheit durchgeführt; die Generalisierung auf alle 56 SEs bleibt ein Desiderat für zukünftige Arbeiten. Die berichteten Δ -Werte, Korrelationen und Cluster-Unterschiede auf Gruppenebene sind deskriptive Muster in rekonstruierten Daten; die Interpretation beruht auf inhaltlicher Einordnung, informiert durch die bekannte Messpräzision.

Reproduzierbarkeit. LLM-Outputs sind auch bei Temperatur 0 nicht vollständig deterministisch. Die ursprünglichen Synthesen wurden in Einzeldurchläufen pro SE generiert. Zwei Post-hoc-IMIIRR-Validierungen etablieren die Reproduzierbarkeit: (1) fünf Gruppen-Syntheseinheiten, je zweimal verarbeitet, ergaben $ICC = 0,902$, $MAE = 0,40$ ($\pm 0,2$ Skalenpunkte); (2) $N = 15$ vollständig unabhängige Einzelinstanz-Runs auf einer Syntheseinheit ergaben $ICC(3,1) = 0,847$, mittlere SD = 0,45, wobei eine Dimension (D02) perfekte Übereinstimmung über alle 15 Instanzen zeigte. Beide Intra-Instrument-Reliabilitätsschätzungen übertreffen die typische Inter-Rater-Übereinstimmung menschlicher Kodierer in qualitativer Forschung ($ICC = 0,6$ – $0,8$; Hallgren 2012), was bestätigt, dass das LLM-basierte Instrument einen *Reproduzierbarkeitsvorteil* gegenüber konventioneller Kodierung bietet. Ob verschiedene Modelle desselben oder anderer Anbieter auf ähnliche Profile konvergieren, bleibt eine offene Frage — ein Inter-Modell-Vergleich mit strikten Unabhängigkeitskriterien (separater Agent

pro Run, kein geteilter Kontext) wird als Priorität für zukünftige Replikation identifiziert.

Daten-Bias in der Sagen-Handeln-Rekonstruktion. Die der SWR-Methode verfügbaren Daten sind strukturell asymmetrisch: Öffentliche Aussagen sind reichhaltig und explizit, während Handlungen aus dokumentierten Entscheidungen, Investitionen und organisatorischem Verhalten erschlossen werden müssen. Diese Asymmetrie bedeutet, dass die „Sagen“-Seite auf dichter Evidenz beruht als die „Handeln“-Seite. Der Trainingskorpus des LLM spiegelt dieselbe Asymmetrie wider – öffentlicher Diskurs ist relativ zu dokumentiertem operativem Verhalten überrepräsentiert. Diese Datenlimitation ist besonders relevant für den Sagen-Handeln-Vergleich, bei dem das Handlungsprofil weniger präzise kalibriert sein könnte als das Aussagenprofil. Die robusten Richtungsbefunde (D07 Machtkonzentration, D11 Egalitarismus) persistieren über Messbedingungen hinweg, aber ihre Magnitude sollte angesichts dieser strukturellen Asymmetrie konservativ interpretiert werden. Die Limitation ist der Datenstruktur inhärent, nicht der Methode: Jeder Analyst – menschlich oder algorithmisch –, der auf öffentliche Quellen angewiesen ist, würde derselben Evidenzasymmetrie begegnen.

Erwartete-Diskrepanz-Bias. Die Kongruenzanalyse (F3) vergleicht zwei LLM-Synthesen – eine aus Aussagen, eine aus Handlungen –, die beide vom selben Modell generiert wurden. Da LLMs auf sozialwissenschaftlicher Literatur trainiert sind, in der Sagen-Handeln-Diskrepanzen bei Eliten als Standardbefund gelten, ist ein Erwartungseffekt plausibel: Das Modell könnte die *erwartete* Diskrepanz reproduzieren, statt sie empirisch zu entdecken. Diese Studie liefert Evidenz, dass der Effekt *existiert*, aber *kontrollierbar* ist. Die ursprüngliche Analyse (v1), bei der beide Datentypen in derselben LLM-Instanz verarbeitet wurden, ergab eine Gesamtkluft von $MAE = 1,42$. Bei Wiederholung mit strikter Instanztrennung (v2-Protokoll) – jeder Datentyp von einem unabhängigen Agenten ohne geteilten Kontext verarbeitet – schrumpfte die Gesamtkluft auf $MAE = 0,75$ (–47 %). Diese Reduktion zeigt, dass geteilter Kontext die Kluft *tatsächlich* verstärkt hat, was die Erwartungs-Diskrepanz-Bedenken als empirisch real bestätigt. Die Gegenmaßnahme (Instanztrennung) ist jedoch wirksam: Die v2-Kluft fällt unter die Kontrollbaseline ($MAE = 0,92$, einer fiktiven konsistenten Gruppe unter gleichen Bedingungen), was darauf hindeutet, dass die aggregierte Kluft nicht mehr zuverlässig von Messrauschen unterscheidbar ist. Der methodisch entscheidende Befund ist, dass *gruppenspezifische* Lücken die Korrektur überstehen: CEOs ($MAE = 1,08$) und Risiko-Warner ($MAE = 1,92$) überschreiten die Baseline auch unter v2-Bedingungen, mit stabilen Richtungsmustern (D07, D11 für CEOs; D09, D10 für Risiko-Warner). Der Erwartete-Diskrepanz-Bias ist somit ein reales methodisches Problem, das in dieser Studie identifiziert, quantifiziert und teilweise kontrolliert wurde – keine unadressierte Limitation.

*Kohärenzbias.*¹⁰ LLMs sind auf logische Kohärenz optimiert; Menschen sind von Natur aus

¹⁰Der Begriff *Kohärenzbias* wird in dieser Studie als operativer Arbeitsbegriff verwendet; kein etabliertes Konzept dieses genauen Namens wurde in der methodischen Literatur gefunden. Das zugrundeliegende Phänomen – die Tendenz von LLMs, logisch kohärente Synthesen zu produzieren, die echte Inkonsistenz in den Quelldaten glätten können – wird empirisch durch die in Abschnitt 3.6 beschriebenen Abweichungsdetektions- und Inversionskontrollmechanismen adressiert.

inkonsistent. Für die Weltbild-Rekonstruktion ist diese Eigenschaft zugleich operativer Vorteil und Quelle systematischer Verzerrung. Der Vorteil: Kohärenz ermöglicht es der SWR, aus heterogenen Daten stabile, interpretierbare Profile auf Gruppenebene zu extrahieren – die Methode *nutzt* Kohärenz als Kompressionsmechanismus, analog dazu, wie Faktoranalyse Kovarianzstruktur nutzt. Die Verzerrung: Die resultierenden Cluster-Typen (Architekt, Hüter, Innovator, Befreier) könnten schärfer konturiert erscheinen, als sie in der Realität sind. Die interne Spannung, die reale Personen zwischen z. B. Machtstreben und Verantwortungsgefühl erleben, wird vom LLM zugunsten eines konsistenten Profils aufgelöst. Die genuine Limitation ist daher *Über-Kohärenz*: Cluster schärfer als die empirische Realität. Zwei Kontrollmechanismen adressieren dieses Risiko teilweise: (1) die in die SWR-Pipeline eingebaute Abweichungsdetektion ergibt eine Passung auf Gruppenebene von 80–88 %, nicht 100 %, was darauf hindeutet, dass das Modell Heterogenität innerhalb der Gruppe registriert und bewahrt; und (2) die Inversionskontrolle (Op3, Kongruenzanalyse) zeigt, dass 58 % der Dimensionen $|\Delta| \geq 5$ aufweisen, was demonstriert, dass die Methode substanzielle Diskrepanzen nicht glättet.

6.3 Konzeptuelle Limitationen

Aggregation als Design-Merkmal. Kollektive Synthesen nivellieren individuelle Variation – dies ist die intendierte Funktion der Methode, kein Nebenprodukt. Die Forschungsfragen der Studie (F1–F6) sind auf Gruppenebene formuliert; individuelle Variation ist relativ zu diesem analytischen Ziel Rauschen, ebenso wie Individualebene-Varianz in jeder Aggregatanalyse Rauschen darstellt (nationale Surveys, Branchenbenchmarks, Metaanalysen). Die algorithmische Strukturprüfung (PCA, HDBSCAN; Abschnitt 4.4) bestätigt, dass die Individualebene-Ratingmatrix genuine strukturelle Variation *vor* der Aggregation aufweist, was darauf hindeutet, dass die Muster auf Gruppenebene Kompressionen realer Heterogenität sind, nicht Artefakte uniformer Eingabedaten.

Keine Kausalerklärung. Die Studie identifiziert, *was* die KI-Elite kollektiv glaubt, und dokumentiert zeitliche Assoziationen (F2: Längsschnittrends) und strukturelle Kovariationen (F5: Gruppenunterschiede korreliert mit Rolle, Haltung und Geschlecht). Sie etabliert keine kausalen Mechanismen. Die zeitliche Abfolge von Weltbild-Verschiebungen und die systematische Kovariation mit struktureller Position liefern plausible assoziative Evidenz, aber der Ausschluss von Drittvariablen-Erklärungen würde andere Forschungsdesigns erfordern (Längsschnitt-Panelstudien, natürliche Experimente oder biographische Fallanalysen).

Epistemologische Grenzen der Quantifizierung. Die dimensionalen Bewertungen (Skala 1–10) bieten ein handhabbares Format für Aggregation und Vergleich, setzen aber eine Kommenturabilitätsannahme voraus, die explizite Reflexion verdient. Komplexe normative Orientierungen – wie etwa *Kontrollverantwortung über KI* (D07) oder *Posthumanismus* (D10) – sind mehrdimensionale Konstrukte, die sich nicht sauber auf eine einzige geordnete Dimension abbilden lassen. Die numerische Zuweisung ist am besten als *ordinale Kompression* zu verstehen: ein

zusammenfassendes Urteil über die relative Position, keine Messung einer zugrundeliegenden Größe. Drei Einschränkungen folgen daraus. Erstens sind Interpretationen auf Intervallniveau nicht gerechtfertigt; die berichteten Spearman-Korrelationen und rangbasierte Clusteranalyse respektieren diese Einschränkung. Zweitens impliziert die Zuweisung eines einzelnen Werts je Dimension ein Maß an *Reifikation*: die Abstraktion einer vielsträngigen diskursiven Orientierung auf einen Punkt einer Skala. Die qualitative Synthese (Op1) bewahrt die Nuance, die die Bewertung (Op2) komprimiert. Drittens sind die 12 Dimensionen konzeptuell distinkt, aber empirisch interkorreliert (z. B. $r_s = +0.85$ für D10–D12); ein Teil dieser Kovariation könnte echte Konstrukt-Überlappung widerspiegeln, nicht unabhängige empirische Beziehungen. Diese Einschränkungen sind in jeder quantitativen Weltbildforschung angelegt und nicht spezifisch für die SWR-Methode; sie mahnen zu Zurückhaltung bei feinkörnigen numerischen Vergleichen, lassen aber die Richtungsmuster und strukturellen Kontraste – die primären Aussagen der Studie – unberührt.

6.4 Forschungsethische Reflexion

Die Studie analysiert öffentliche Figuren ausschließlich auf der Grundlage öffentlich zugänglicher Daten. Zwei Design-Merkmale mildern ethische Bedenken substantiell.

Aggregation auf Gruppenebene als ethischer Schutz. Die primären Analyseeinheiten sind soziologisch definierte Gruppen, nicht Individuen. Individuelle Daten werden vor der Synthese in Gruppenkorpora gepoolt; kein individuelles Weltbild-Profil wird als Befund berichtet. Die rekonstruierten Weltbilder beschreiben kollektive Tendenzen von Rollen (CEOs, Akademiker) und Haltungen (Beschleuniger, Risiko-Warner), nicht die Psychologie identifizierbarer Personen. Diese Aggregation verhindert strukturell die Zuschreibung spezifischer Überzeugungen an namentlich genannte Individuen.

Standard-Legitimation. Die Studie stützt sich auf öffentlich dokumentierte berufliche Aussagen und Handlungen öffentlicher Figuren, deren Positionen zur KI-Entwicklung von erheblichem öffentlichem Interesse sind (vgl. APA Ethical Principles, Standard 8.05). Keine privaten oder vertraulichen Informationen wurden erhoben.

Residualrisiko. Für kleine Gruppen (z. B. firmenspezifische Subgruppen mit $n = 3\text{--}5$) bietet die Aggregation schwächeren Schutz – ein quasi-individuelles Profil kann entstehen. Die drei individuellen Spot-Checks (Abschnitt 6.5) werden als Datenqualitätsindikatoren präsentiert, nicht als inhaltliche Befunde. Member Checking (Soysal & Türkmen, 2024) bleibt ein Desiderat für Folgeforschung.

6.5 Individualebene-Analyse (explorativ)

Die inhaltlichen Befunde der Studie beruhen vollständig auf Analysen auf Gruppenebene (F1–F6). SWR auf Individualebene ist für den vorliegenden Zweck methodisch überflüssig – die originalen öffentlichen Aussagen und Handlungen sind für jede Einzelperson direkt zugäng-

lich. Der Mehrwert der SWR liegt ausschließlich in der Synthese auf Gruppenebene, wo sie kollektive Porträts erzeugt, die in keiner einzelnen Quelle existieren. Die folgenden drei Spot-Checks werden ausschließlich als *Datenqualitätsindikatoren* berichtet: Wenn die zugrundeliegenden Individualdaten erkennbare, verifizierbare Profile produzieren, stützt dies die Qualität der Eingabedaten für die Gruppensynthesen. Tabelle 12 fasst die Ergebnisse zusammen.

Tabelle 12: Explorative Validierung auf Individualebene: SWR-Ratings vs. dokumentierte Positionen. Diese Einzelfallprüfungen dienen als Plausibilitätstests für die zugrundeliegende Datenqualität; die inhaltlichen Befunde der Studie beruhen auf den Gruppenanalysen (F1–F6).

Dim.	Sam Altman		Geoffrey Hinton		Marc Andreessen	
	R	Status	R	Status	R	Status
D01 Send.	9	best.	7	best.	8	best.
D02 Selbst.	9	best.	5	best.	9	best.
D03 Arbeit	9	best.	7	plaus.	8	best.
D04 Verantw.	6	best.	10	best.	4	best.
D05 Techno.	9	best.	6	best.	9	best.
D06 Fortschr.	8	best.	4	best.	9	best.
D07 Macht	9	best.	4	best.	2	best.
D08 Dringl.	9	best.	10	best.	7	plaus.
D09 Menschenfr.	3	plaus.	7	best.	4	plaus.
D10 Posthum.	8	best.	5	best.	7	plaus.
D11 Egalit.	3	best.	7	best.	2	best.
D12 Kontr.	8	best.	3	best.	8	best.
<i>Bestätigt</i>	10/12		11/12		9/12	
<i>Plausibel</i>	2/12		1/12		3/12	
<i>N. belegbar</i>	0/12		0/12		0/12	

Methodik der Spot-Checks. Jedes Rating wurde gegen mindestens zwei unabhängige, öffentlich dokumentierte Quellen geprüft. *Bestätigt* (best.): Rating stimmt mit dokumentierten Positionen und Handlungen überein. *Plausibel* (plaus.): Rating ist mit bekannten Positionen vereinbar, aber keine direkte Quelle für die spezifische Ausprägung verfügbar. *Nicht belegbar* (n. b.): Rating widerspricht dokumentierten Positionen oder ist nicht überprüfbar.

Altman (Architekt): D01=9 (bestätigt durch wiederholte Aussagen zur „wichtigsten Technologie der Menschheitsgeschichte“, Davos 2024, US-Kongress 2023). D07=9 (bestätigt durch die Umstrukturierung von OpenAI von Non-Profit zu Capped-Profit, Mehrfach-Stimmrechte). D11=3 (bestätigt: trotz Rhetorik von „KI für alle“ hat OpenAI Zugang zunehmend paywalled). D09=3 (plausibel: keine direkte Aussage zur Ersetzbarkeit des Menschen, aber Fokus auf AGI als „nächste Spezies“).

Hinton (Hüter): D04=10 (bestätigt durch Rücktritt bei Google 2023, um frei vor KI-Risiken warnen zu können). D08=10 (bestätigt durch Aussage, die Wahrscheinlichkeit einer existenziellen Katastrophe betrage 10–20 %). D12=3 (bestätigt: zunehmender Pessimismus, „Ich bin mir nicht sicher, ob wir das noch kontrollieren können“, NYT 2023). D03=7 (plausibel: hohe akademische Produktivität bekannt, aber keine direkte Aussage zur Arbeitsidentifikation im Silicon-Valley-Stil).

Andreessen (Befreier): D07=2 (bestätigt durch „Techno-Optimist Manifesto“ 2023: vehemente Ablehnung staatlicher Regulierung, Märkte als Verteilungsmechanismus). D11=2 (bestätigt: explizite Ablehnung von Umverteilung und Egalitarismus im Manifesto). D04=4 (bestätigt: Verantwortung wird dem Markt zugeschrieben, nicht individuellen Akteuren). D09=4 (plausibel: keine direkte Aussage, aber instrumentelle Sicht auf menschliche Arbeitskraft in VC-Kontext).

Gesamtbewertung: 30 von 36 Ratings (83 %) sind direkt durch öffentliche Quellen bestätigt, 6 von 36 (17 %) sind plausibel, keines widerspricht den dokumentierten Positionen. Diese Einzelfallprüfungen auf Individualebene liefern Plausibilitätshinweise für die Datenqualität, die den Gruppensynthesen zugrunde liegt, stellen aber nicht die primäre Validierungsstrategie dar. Die inhaltlichen Befunde der Studie beruhen auf der Konvergenz mehrerer unabhängiger Gruppensynthesen (15 Gruppen, 4 Cluster-Typen), nicht auf der Genauigkeit auf Individualebene. Die Spot-Checks unterliegen zudem erheblichen Einschränkungen: (a) geringe Fallzahl ($n = 3$ von 100); (b) Durchführung durch den Forscher selbst, was Confirmation Bias nicht ausschließt; (c) Beschränkung auf besonders prominente Persönlichkeiten, deren öffentliches Profil gut dokumentiert und daher leichter „bestätigbar“ ist; (d) die Kategorien „bestätigt“ und „plausibel“ sind ihrerseits subjektive Einschätzungen. Eine systematische externe Validierung durch unabhängige Expertenpanels bleibt ein Desiderat für Folgeforschung.

7. Fazit und Ausblick

7.1 Fazit

Die Studie hat die Frage gestellt, was die KI-Elite denkt – nicht als Individuen, sondern als soziologisch strukturierte Gruppen – und eine empirisch fundierte Antwort vorgelegt. Fünf übergreifende Erkenntnisse kristallisieren sich heraus:

Erstens: Die KI-Elite verfügt über ein kohärentes, empirisch rekonstruierbares kollektives Weltbild – technologischer Messianismus, Sendungsbewusstsein, Fortschrittsglaube –, das über mehrere unabhängige Gruppensynthesen hinweg stabil ist.

Zweitens: Dieses Weltbild befindet sich in beschleunigter Transformation. Der Verlust utopischer Gewissheiten hat zu einem *tragischen Beschleunigungszwang* geführt: Man zweifelt an der Zukunft, die man baut, und baut sie dennoch.

Drittens: Der Sagen-Handeln-Vergleich offenbart ein Simpson-Paradox: Die aggregierte Kluft ist nicht zuverlässig von Messrauschen unterscheidbar, aber gruppenspezifische Lücken sind substanziell und überstehen die Instanztrennung. CEOs zeigen eine klassische Erwünschtheitslücke (D07 +2, D11 –2: Rhetorik egalitärer als operatives Verhalten). Risiko-Warner zeigen ein inverses Muster – prophetische Konsistenz statt Heuchelei: Ihre Aussagen beschreiben eine gefürchtete posthumanistische Zukunft (D10 Sagen=9, D09 Sagen=4), während ihre Handlungen die menschenzentrierten Werte zeigen, die sie tatsächlich vertreten

(D09 Handeln=8, D10 Handeln=4). Investoren sind die konsistenteste Gruppe: radikaler Techno-Optimismus in Wort und Tat. Die Sagen-Handeln-Analyse ist somit kein Ein-Zahlen-Befund, sondern eine *gruppenspezifische Diagnostik*, die qualitativ unterschiedliche Diskrepanztypen aufdeckt.

Viertens: Die Macht ist nicht weltbild-neutral verteilt. Die Inter-Gruppen-Vergleiche und die Analyse nach Einflussstrata (Top 10 vs. Mitte vs. Bottom 10) konvergieren auf denselben Befund: Die mächtigsten Akteure weisen die intensivsten Weltbilder auf (Avg 7,7 vs. 6,4 vs. 6,1). Zwei Dimensionen zeigen einen inversen Gradienten: Menschliche Wertschätzung (D09: Top=4, Bottom=8) und Posthumanismus (D10: Top=8, Bottom=3). Die Macht-Gleichheits-Achse (D07/D11) bleibt die diskriminierendste Dimension über alle Gruppenvergleiche hinweg.

Fünftens: Die SWR hat sich als leistungsfähiges Instrument für Weltbild-Analyse auf Gruppenebene erwiesen, das qualitative Tiefe mit quantitativer Systematik verbindet. Die Konvergenz unabhängig produzierter Gruppensynthesen liefert eine dem Gruppenansatz eigene Form der Validierung. Insbesondere die Zerlegung in Aussagen- und Handlungsprofile (F3) erweist sich als eigenständiger methodischer Beitrag, der qualitativ unterschiedliche Diskrepanztypen aufdeckt – Erwünschtheitslücken, prophetische Konsistenz und authentische Kongruenz – je nach struktureller Position der Gruppe. Diese diagnostische Fähigkeit wäre über die KI-Elite hinaus auf politische, ökonomische oder militärische Eliten übertragbar.

7.2 Ausblick

Fünf Richtungen für Anschlussforschung: (1) *Komparative Erweiterung:* Die vorliegende Studie fokussiert stark auf die US-amerikanische, Silicon-Valley-zentrische Elite. Eine zentrale Forschungslücke betrifft die komparative Untersuchung chinesischer (Baidu, ByteDance, Alibaba), indischer (Infosys, TCS) und europäischer (Mistral, Aleph Alpha) KI-Eliten. Es ist unklar, ob der „technologische Messianismus“ ein universelles Artefakt der KI-Entwicklung oder ein spezifisches Kulturprodukt des westlichen Libertarismus darstellt. Kulturvergleichende Gruppenanalysen (westliche vs. chinesische vs. europäische KI-Eliten) würden die Generalisierbarkeit der hier identifizierten Muster auf Gruppenebene prüfen. (2) *Feinere Gruppenanalysen:* Erweiterung der Gruppenvergleiche auf zusätzliche soziologische Kategorien (Generationskohorten, Bildungshintergründe, geographische Herkunft) und Nachverfolgung von Cluster-Drift über Epochen. (3) *Methodische Weiterentwicklung:* Unabhängige Replikation durch andere Forschungsteams mit verschiedenen Frontier-Modellen, automatisierte Validierungsverfahren, standardisierte Gütekriterien für Synthesen auf Gruppenebene und systematische Power-Analyse ($N = 30$ Durchläufe pro Syntheseinheit). (4) *Transfer:* Finanz-Elite, politische Elite, militärische KI-Elite – Anwendung des Gruppenvergleichs-Frameworks auf andere Machteliten. (5) *Longitudinale Fortführung:* Jährliches Weltbild-Monitoring als Instrument demokratischer Kontrolle – denkbar als standardisierter Index (analog zum Democracy Index oder AI Readiness Index), der Veränderungen in den kollektiven Weltbildern der KI-Elite-Subgruppen

systematisch und vergleichbar erfasst. Die Frage „Was denkt die KI-Elite?“ ist keine einmalige Frage. Sie ist eine Frage, die Demokratien kontinuierlich stellen müssen.

Offenlegungserklärung: Einsatz künstlicher Intelligenz

KI-Disclosure Level 5 (Extensiv). Bei der Erstellung dieser Studie wurden zwei KI-Modelle von Anthropic in erheblichem Umfang als nicht-autorschaftliche Forschungsinstrumente und redaktionelle Hilfsmittel eingesetzt. Die Systeme werden nicht als Autoren, Koautoren, Danksagungsempfänger, Wahrheitsinstanzen oder unabhängige Validierungsinstanzen geführt. *Claude Sonnet 4.5* diente als primäre Analyse-Engine: Alle 100 individuellen dimensional Ratings (D01–D12), alle Syntheseratings auf Gruppenebene und alle Datenerhebungsskripte wurden von 9 parallelen Sonnet-Agenten generiert. *Claude Opus 4.6* diente als qualitative Analyse-Engine: Pilot-Synthesen, Vergleichsanalysen, statistische Aufbereitung (PCA, HDBSCAN, Kruskal-Wallis, Cliff's δ), Visualisierung der Ergebnisse und nicht-autorschaftliche Unterstützung bei Strukturierung und Formulierung einzelner Manuskriptpassagen. Kein anderes LLM wurde in der ursprünglichen Analyse-Pipeline verwendet. Ein späterer englischer redaktioneller Style-Check im Mai 2026 nutzte OpenAI Codex/GPT ausschließlich für sprachliche Glättung und Claim-Kalibrierung; dabei wurden keine neuen Daten, Quellen, Analysen oder inhaltlichen Behauptungen hinzugefügt. Forschungsdesign, Forschungsfragen, Datenerhebungsstrategie, methodische Entscheidungen, Interpretation der Ergebnisse und alle inhaltlichen Schlussfolgerungen stammen vom Autor, der die volle Verantwortung für das Manuskript trägt. KI-Ausgaben wurden vom Autor geprüft und nicht als externe Validierung oder Ersatz für menschliche wissenschaftliche Beurteilung behandelt. Sämtliche Prompts, API-Parameter und Modellversionen sind im Repository dokumentiert.

Verfügbarkeit der Daten und Materialien

Sämtliche Datenerhebungsskripte, qualitativen Kodierskripte, Analysecodes und generierten Abbildungen sind öffentlich verfügbar unter: <https://github.com/research-line/ai-elite-swr>. Das Repository enthält 56 Erhebungsskripte und 38 Insert-Skripte in `_data_A/`, Kodier- und Analyseskripte, die 100×12 -Ratingmatrix, HDBSCAN-/PCA-Ausgaben, Prompt-Templates, Dimensionsdefinitionen, Syntheseeinheiten, Qualitätsberichte und generierte Abbildungen. Diese Materialien bilden einen prüfbaren Reproduktionspfad der implementierten Pipeline; eine exakte Neuausführung setzt den Neuaufbau der SQLite-Datenbank aus den aktuellen Skripten voraus und kann von der Verfügbarkeit der ursprünglichen Onlinequellen zum Erhebungszeitpunkt abhängen.

Literatur

- Barbrook, R. & Cameron, A. (1996). The Californian Ideology. *Science as Culture*, 6(1), 44–72. <https://doi.org/10.1080/09505439609526455>.
- Bengio, Y., Hinton, G. E. et al. (2024). Managing extreme AI risks amid rapid progress. *Science*, 384(6698), 842–845. <https://doi.org/10.1126/science.adn0117>.
- Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Garden City: Doubleday.
- Booth, W. C. (1961). *The Rhetoric of Fiction*. Chicago: University of Chicago Press.
- Bostrom, N. (2005). A history of transhumanist thought. *Journal of Evolution and Technology*, 14(1), 1–25.
- Bostrom, N. (2014). *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.
- Broussard, M. (2018). *Artificial Unintelligence: How Computers Misunderstand the World*. Cambridge: MIT Press.
- OpenAI (2023). Our approach to AI safety. *OpenAI Blog*, 5. April 2023. <https://openai.com/index/our-approach-to-ai-safety/>.
- Anthropic (2023). Core views on AI safety: When, why, what, and how. *Anthropic Research Blog*, 8. März 2023. <https://www.anthropic.com/research/core-views-on-ai-safety>.
- Coeckelbergh, M. (2020). *AI Ethics*. Cambridge: MIT Press.
- Daub, A. (2020). *What Tech Calls Thinking*. New York: FSG Originals.
- Ge, T., Chan, X., Wang, X., Yu, D., Mi, H. & Yu, D. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*. <https://doi.org/10.48550/arXiv.2406.20094>.
- Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, 18(6), 669–684. <https://doi.org/10.1080/13645579.2015.1005453>.
- Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, 18(1), 59–82. <https://doi.org/10.1177/1525822X05279903>.
- Habermas, J. (2001). *Die Zukunft der menschlichen Natur*. Frankfurt: Suhrkamp.

- Hallgren, K. A. (2012). Computing Inter-Rater Reliability for Observational Data: An Overview and Tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023>.
- Hayes, A. S. (2025). ‘Conversing’ With Qualitative Data: Enhancing Qualitative Research Through Large Language Models (LLMs). *International Journal of Qualitative Methods*, 24, Article 16094069251322346. <https://doi.org/10.1177/16094069251322346>.
- Jara-Ettinger, J. (2019). Theory of mind as inverse reinforcement learning. *Current Opinion in Behavioral Sciences*, 29, 105–110. <https://doi.org/10.1016/j.cobeha.2019.04.010>.
- Kurzweil, R. (2005). *The Singularity Is Near*. New York: Viking.
- Lessig, L. (1999). *Code and Other Laws of Cyberspace*. New York: Basic Books.
- Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.
- More, M. (2003). Principles of extropy (version 3.11). *Extropy Institute*.
- More, M. & Vita-More, N. (Hrsg.) (2013). *The Transhumanist Reader*. Malden: Wiley-Blackwell.
- Morozov, E. (2013). *To Save Everything, Click Here*. New York: PublicAffairs.
- Ng, A. Y. & Russell, S. J. (2000). Algorithms for inverse reinforcement learning. In: *Proc. ICML 2000*, 663–670.
- Nicmanis, M. & Spurrier, H. (2025). Getting Started with Artificial Intelligence Assisted Qualitative Analysis: An Introductory Guide to Qualitative Research Approaches with Exploratory Examples from Reflexive Content Analysis. *International Journal of Qualitative Methods*, 24, Article 16094069251354863. <https://doi.org/10.1177/16094069251354863>.
- Strauss, A. & Corbin, J. (1990). *Basics of Qualitative Research*. Newbury Park: Sage.
- Tai, R. H., Bentley, L. R., Xia, X., Sitt, J. M., Fankhauser, S. C., Chicas-Mosier, A. M. & Monteith, B. G. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, 23, Article 16094069241231168. <https://doi.org/10.1177/16094069241231168>.
- Geburu, T. & Torres, É. P. (2024). The TESCREAL bundle: Eugenics and the promise of utopia through artificial general intelligence. *First Monday*, 29(4). <https://doi.org/10.5210/fm.v29i4.13636>.
- Turner, F. (2006). *From Counterculture to Cyberculture*. Chicago: University of Chicago Press.

- Weber, M. (1904). Die „Objektivität“ sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, 19, 22–87.
- Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. New Haven: Yale University Press.
- Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.
- Floridi, L. (2019). Establishing the Rules for Building Trustworthy AI. *Nature Machine Intelligence*, 1(6), 261–262. <https://doi.org/10.1038/s42256-019-0055-y>.
- Couldry, N. & Mejias, U. A. (2019). *The Costs of Connection: How Data Is Colonizing Human Life and Appropriating It for Capitalism*. Stanford: Stanford University Press.
- Whittaker, M. (2021). The steep cost of capture. *Interactions*, 28(6), 50–55. <https://doi.org/10.1145/3488666>.
- Floridi, L. (2023). *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press.
- Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to train your stochastic parrot: Large language models for political texts. *Political Science Research and Methods*, 13(2), 264–281. <https://doi.org/10.1017/psrm.2024.64>.
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 29971–30004. <https://proceedings.mlr.press/v202/santurkar23a.html>.
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>.
- Batzner, J., Stocker, V., Tang, B., Natarajan, A., Chen, Q., Schmid, S. & Kasneci, G. (2025). Whose Personae? Synthetic Persona Experiments in LLM Research and Pathways to Transparency. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 8(1), 343–354. <https://doi.org/10.1609/aies.v8i1.36553>; arXiv:2512.00461.
- Soysal, Y. & Türkmen, S. (2024). Reinterpreting the Member Checking Validation Strategy in Qualitative Research Through the Hermeneutics Lens. *Qualitative Inquiry in Education: Theory & Practice*, 2(1), 42–63. <https://doi.org/10.59455/qietp.19>.
- Acemoglu, D. & Johnson, S. (2023). *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*. New York: PublicAffairs.

- Becker, A. (2025). *More Everything Forever: AI Overlords, Space Empires, and Silicon Valley's Crusade to Control the Fate of Humanity*. New York: Basic Books.
- Bourdieu, P. (1992). *Les règles de l'art: Genèse et structure du champ littéraire*. Paris: Seuil. [Dt.: *Die Regeln der Kunst*, Frankfurt: Suhrkamp, 1999.]
- Merton, R. K. (1973). *The Sociology of Science: Theoretical and Empirical Investigations*. Chicago: University of Chicago Press.
- Mills, C. W. (1956). *The Power Elite*. New York: Oxford University Press.
- Ricoeur, P. (1970). *Freud and Philosophy: An Essay on Interpretation*. New Haven: Yale University Press.
- Romano, J., Kromrey, J. D., Coraggio, J. & Skowronek, J. (2006). Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? *Annual Meeting of the Florida Association of Institutional Research*, 1–33.

A. Sampling-Methode der 100 KI-Akteure

Die Stichprobe wurde durch ein dreistufiges Verfahren erstellt: (1) 22 systematische Webrecherchen → 187 Kandidaten; (2) 6-Kategorien-Scoring (Marktkapitalisierung, technologische Schlüsselpositionen, Diskursmacht, akademischer Einfluss, politische Einflussnahme, symbolischer Status); (3) Reduktion auf 100 unter Sicherstellung demographischer Heterogenität. Die finale Stichprobe umfasst 1.738 Aussagen und 1.394 Handlungen (3.132 Datenpunkte).

B. Die 12 Rating-Dimensionen (D01–D12)

Dim.	Name	Pol 1 (=1)	Pol 10 (=10)
D01	Sendungsbewusstsein	Kein Auftrag	Messianisch
D02	Selbstwirksamkeit	Ohnmacht	Omnipotent
D03	Arbeitsethos	Distanz	Totale Identifikation
D04	Verantwortungsgefühl	Keines	Weltverantwortung
D05	Techno-Determinismus	Neutral	Bestimmt alles
D06	Fortschrittsglaube	Niedergang	Goldene Zukunft
D07	Machtkonzentration	Radikal verteilen	Bei Experten
D08	Dringlichkeit	Entspannt	Existenzieller Druck
D09	Menschenfreundlichkeit	Ersetzbar	Einzigartig
D10	Posthumanismus	Mensch bleibt	Mensch wird mehr
D11	Egalitarismus	Ungleichheit natürlich	Gleichheit anstreben
D12	Kontrollüberzeugung	Pessimismus	Volle Kontrolle

C. Reduktionskriterien (K1–K9)

K	Typ	Beschreibung
K1	obligatorisch	Fragestellungsbindung: Jede SE muss ≥ 1 Forschungsfrage zugeordnet sein
K2	obligatorisch	Mindestgröße: ≥ 15 Datenpunkte pro SE
K3	obligatorisch	Redundanzverbot: Echte Teilmengen werden eliminiert
K4	Prinzip	Modalitäts-Sparsamkeit: A/H-Trennung nur für F3
K5	Prinzip	Zeitliche Sparsamkeit: Jahres-SE nur für F2
K6	Prinzip	Gruppensparsamkeit: Nur a-priori-begründete Gruppen
K7	Prinzip	Stufenweise Erweiterung: Kern zuerst
K8	Prinzip	Aggregationsfokus: Keine Einzelperson-SE
K9	Prinzip	Cluster-Verschmelzung: Bottom-Up ersetzt a-priori

Bilanz: ~1.227 theoretische SE → ~51–56 Kern-SE (Reduktion ~95 %).

D. Liste der Syntheseeinheiten

Das Kern-Design umfasst 43 vordefinierte plus ~8–13 emergente Syntheseeinheiten:

Nr	SE-ID	UV-Kombination	F
1	GA_ges_AH	Alle, AH, Gesamt	F1a
2	GA_ges_A	Alle, nur A, Gesamt	F3a
3	GA_ges_H	Alle, nur H, Gesamt	F3a
4	T10_ges_AH	Top 10, AH, Gesamt	F1b
5	HOM_haeuf_A	Alle, häufig wiederholte A	F1c
6–22	GA_YYYY_AH	Alle, AH, pro Jahr	F2a
23–26	GA_Epoche_AH	Alle, AH, 4 Epochen	F2b
27–30	GR_*_AH	CEOs, Akad., Inv., Gründer	F5a
31–33	GF_*_AH	Anthropic, OpenAI, Google	F5d
34–39	GH_*_AH	Open/Closed, Risk/Speed, Reg	F5b–f
40–41	GD_*_AH	Frauen, Männer	F5e
42–43	KG_*_AH	Konsistent, Widersprüchlich	F3c

Zusätzlich: 9 Vergleichs-Runs (Op6). Kreuzmodale Vorhersage-Runs (Op4) wurden in dieser Studie nicht durchgeführt und verbleiben als Validierungsdesiderat.

E. Exemplarischer Prompt (Op2: Rating)

Der folgende Prompt illustriert die Rating-Abfrage (Op2) für eine Gruppen-Synthese. Sämtliche Prompts sind im Repository dokumentiert (<https://github.com/research-line/ai-elite-swr>).

Du erhältst eine Sammlung anonymisierter Aussagen und Handlungen einer Gruppe von Personen aus dem Technologiesektor. Auf Basis dieser Daten sollst du das kollektive Weltbild der Gruppe auf den folgenden 12 Dimensionen einschätzen (Skala 1–10). Begründe jede Einschätzung mit konkreten Verweisen auf die Datenpunkte. [Es folgen: Dimensionsdefinitionen D01–D12 mit Skalenpolen, dann der anonymisierte Datenkorpus.]

Die vollständige Prompt-Bibliothek einschließlich Synthese-Prompts (Op1), Rating-Prompts (Op2), Kreuzmodal-Prompts (Op4a/Op4b) und Dialog-Prompts (Op6) ist im Repository archiviert (prompts/en/).