Synthetische Weltbild-Rekonstruktion:

Ein LLM-gestütztes Verfahren zur Analyse latenter Überzeugungssysteme

Lukas Geiger*

Unabhängiger Forscher, Bernau

März 2026 (v2.1)

Zusammenfassung

Die vorliegende Arbeit stellt die *Synthetische Weltbild-Rekonstruktion* (SWR) als neue sozialwissenschaftliche Methode vor. Die SWR formalisiert die Rekonstruktion latenter Überzeugungssysteme als *inverses Problem*: Gegeben sind die beobachtbaren Manifestationen eines Akteurs – öffentliche Aussagen und dokumentierte Handlungen –, gesucht ist das innere Überzeugungssystem (Weltbild), das diese Manifestationen am kohärentesten erzeugen würde. Ein großes Sprachmodell (Large Language Model, LLM) fungiert als Inversionsoperator und konstruiert eine *fiktive synthetische Person*, deren Weltbild den bestmöglichen Fit für die Gesamtheit der Daten bietet. Das Verfahren operationalisiert diesen Grundgedanken durch ein standardisiertes Fünfschritt-Prompt-Protokoll (Datenkorpus zusammenstellen, Synthese, Interview, Reflexion, Destillat), eine systematische Datengruppierung in Syntheseeinheiten entlang von sechs unabhängigen Variablen, sechs komplementäre Operationalisierungen und einen mehrschichtigen Validierungsrahmen. Die theoretische Verankerung verbindet vier Traditionen: Webers Idealtyp, Booths *implied author*, Inverse Reinforcement Learning und projektive Testverfahren. Die Methode verbindet qualitative Tiefe mit quantitativer Skalierbarkeit und zielt darauf ab, die systematische Rekonstruktion und den Vergleich latenter Weltbilder für große Personenzahlen zu ermöglichen.

Die SWR wurde im Rahmen einer großangelegten empirischen Anwendungsstudie (Geiger, 2026) entwickelt und validiert, die die kollektiven Weltbilder von 15 soziologischen Gruppen innerhalb der KI-Elite rekonstruiert. Die vorliegende Arbeit abstrahiert die Methode von diesem spezifischen Anwendungskontext und stellt sie als verallgemeinertes, transferierbares Rahmenwerk für alle Forscher vor, die kollektive Weltbilder rekonstruieren und vergleichen möchten.

Schlagwörter: Weltbild-Rekonstruktion, Large Language Models, qualitative Methoden, inverses Problem, Computational Social Science, fiktive synthetische Person

*Korrespondenz: Lukas Geiger, Bernau, Deutschland. ORCID: https://orcid.org/0009-0005-7296-1534

1. Einleitung

1.1 Problemstellung

Einflussreiche Akteure – politische Entscheidungsträger, Unternehmenslenkende, öffentliche Intellektuelle – handeln nicht in einem Vakuum rationaler Kalkulation.[1] Ihren Entscheidungen, Aussagen und Strategien liegen implizite Überzeugungssysteme zugrunde: grundlegende Annahmen über die Natur des Menschen, die Struktur der Gesellschaft, die Rolle von Technologie, das Verhältnis von Individuum und Gemeinschaft. Diese Überzeugungssysteme – im Folgenden als *Weltbilder* bezeichnet – sind selten explizit artikuliert, wirken aber als kognitive Tiefenstrukturen, die sowohl die Problemwahrnehmung als auch den Lösungsraum eines Akteurs determinieren (Mannheim, 1929; Berger & Luckmann, 1966).

Die systematische Rekonstruktion solcher Weltbilder stellt die Sozialwissenschaften vor ein fundamentales methodisches Problem. Weltbilder sind *latente Konstrukte*: Sie sind nicht direkt beobachtbar, sondern manifestieren sich nur indirekt – in öffentlichen Reden, Interviews, Policy-Dokumenten, unternehmerischen Entscheidungen, veröffentlichten Texten und beobachtbarem Handeln. Der Forscher steht vor der Aufgabe, aus einer heterogenen Menge solcher Manifestationen das zugrunde liegende Überzeugungssystem zu inferieren – ein Problem, das in seiner epistemologischen Struktur einem *inversen Problem* entspricht: Gegeben sind die Outputs (beobachtbare Aussagen und Handlungen), gesucht ist der generierende Mechanismus (das Weltbild), der diese Outputs hervorbringt.

1.2 Grenzen bestehender Verfahren

Die Sozialwissenschaften verfügen über ein breites Repertoire an Methoden zur Analyse von Texten, Diskursen und Sinnstrukturen. Für die hier formulierte Aufgabe – die systematische Rekonstruktion latenter Weltbilder aus öffentlich verfügbaren Quellen für eine große Zahl von Akteuren – stoßen diese Verfahren jedoch an charakteristische Grenzen.

Die *qualitative Inhaltsanalyse* nach Mayring (2022) bietet ein strukturiertes, regelgeleitetes Vorgehen mit hoher intersubjektiver Nachvollziehbarkeit, skaliert aber schlecht und bietet keinen genuinen Mechanismus zur Synthese eines kohärenten Gesamtbilds. Die *Kritische Diskursanalyse* (Fairclough, 1995) erlaubt die Aufdeckung impliziter Annahmen und Machtstrukturen, ist aber in hohem Maße interpretationsabhängig (Breeze, 2011) und bietet kein standardisiertes Aggregationsformat. Die *Frame-Analyse* (Goffman, 1974; Entman, 1993) identifiziert kognitive Deutungsrahmen, reduziert aber das Überzeugungssystem auf einzelne, isolierte Frames. Die *Narrativanalyse* (Riessman, 2008) erfasst integrative Sinnstrukturen, ist aber einzelfallzentriert und bietet keine Aggregationsverfahren. *Automatisierte Textanalyseverfahren* – Topic Modeling (Blei et al., 2003), Sentiment-Analyse, Word Embeddings – bieten Skalierbarkeit, operieren aber an der sprachlichen Oberfläche.

Zusammenfassend lässt sich feststellen: Kein bestehendes Verfahren kann gleichzeitig (a) latente Überzeugungssysteme als kohärente Ganzheiten rekonstruieren, (b) heterogene Datenquellen – sowohl sprachliche Äußerungen als auch beobachtbares Handeln – integrieren, (c) auf eine große Zahl von Akteuren (100+) skalieren und (d) strukturierte Gruppenaggregate bilden, die den systematischen Vergleich ermöglichen.

[1] Diese Arbeit verwendet durchgehend das redaktionelle „wir“ gemäß akademischer Konvention. Der alleinige menschliche Autor ist Lukas Geiger; die KI-Beteiligung ist in der KI-Offenlegungserklärung dokumentiert.

1.3 LLMs als neue Möglichkeit

Die jüngste Generation großer Sprachmodelle (Large Language Models, LLMs) eröffnet eine grundlegend neue Perspektive auf dieses methodische Problem. LLMs verfügen über zwei Eigenschaften, die sie als qualitative Forschungsinstrumente potenziell geeignet machen: Erstens haben sie im Zuge ihres Trainings auf umfangreichen Textkorpora ein breites Weltwissen absorbiert. Zweitens sind sie in der Lage, aus fragmentarischen Informationen kohärente Synthesen zu generieren – eine Fähigkeit, die der hermeneutischen Kompetenz menschlicher Forscher strukturell ähnelt, aber in einem Bruchteil der Zeit operiert. Diese Perspektive knüpft an eine wachsende Literatur an, die LLMs als Analysewerkzeuge für die Sozialwissenschaften konzeptualisiert (Ziems et al., 2024; Bail, 2024; Argyle et al., 2023). Jüngere Studien belegen die Eignung von LLMs für qualitative Kodieraufgaben: Tai et al. (2024) fanden, dass LLMs deduktive Kodierung mit einer Leistung vergleichbar zu menschlichen Kodierern durchführen können; Barros et al. (2024) erstellten ein systematisches Mapping LLM-basierter qualitativer Forschung und dokumentierten einen starken Anstieg der Publikationstätigkeit 2023–2024; und Pilotstudien zur LLM-gestützten Thematischen Analyse zeigten, dass Evaluatoren LLM-generierte Codes in einer Mehrzahl der Fälle bevorzugten (Wang et al., 2025). Die SWR unterscheidet sich von diesen Ansätzen in einem entscheidenden Punkt: Statt bestehende Kategorien zu kodieren, führt sie eine *synthetische Integration* durch – die Konstruktion kohärenter Weltbild-Modelle aus fragmentarischen Daten.

Zugleich bringen LLMs spezifische methodische Herausforderungen mit sich: das *Kontaminationsrisiko* (die Modelle wurden auf denselben Quellen trainiert, die analysiert werden), den *Kohärenzbias* (die Tendenz, widersprüchliche Daten zu glätten) und die *Stochastizität* der Modellausgaben.

1.4 Die SWR-Methode: Überblick

Die vorliegende Arbeit stellt eine Methode vor, die diese Lücke zu schließen sucht: die *Synthetische Weltbild-Rekonstruktion* (SWR). Die SWR formuliert die Rekonstruktion impliziter Weltbilder als inverses Problem und nutzt ein LLM als Inversionsoperator. Das Verfahren erzeugt für systematisch definierte Datenbündel (*Syntheseeinheiten*) jeweils eine *fiktive synthetische Person*, deren Weltbild die Gesamtheit der präsentierten Daten am kohärentesten erklärt. Sechs komplementäre Operationalisierungen erschließen die latenten Konstrukte aus verschiedenen methodischen Perspektiven; ein mehrschichtiger Validierungsrahmen kontrolliert die spezifischen Risiken LLM-gestützter Forschung.

1.5 Beitrag

Die vorliegende Arbeit leistet drei zentrale Beiträge:

Erstens stellt sie mit der SWR, nach unserem Kenntnisstand, eine der ersten systematischen Methoden zur LLM-gestützten Rekonstruktion latenter Überzeugungssysteme vor. Die Methode formalisiert den Rekonstruktionsprozess als inverses Problem, operationalisiert Weltbilder über sechs komplementäre Zugänge und standardisiert die Generierung durch strukturierte Prompt-Sequenzen.

Zweitens entwickelt die Arbeit einen sechsschichtigen Validierungsrahmen (V1–V6) für LLM-gestützte qualitative Forschung, der Instrumentenkalibrierung (Run-Konvergenz), Prompt-Sensitivitätsanalyse, dimensionale Quantifizierung, Diskriminierbarkeitstest, Run-Konvergenz mit Varianzdekomposition und Adversarial Probing umfasst.

Drittens formalisiert sie eine vierstufige Variablenarchitektur (abhängige Variablen → Operationalisierungen → Messvariablen → unabhängige Variablen) und ein System von neun Reduktionskriterien, die den kombinatorischen Datenraum auf eine handhabbare Zahl von Syntheseeinheiten reduzieren.

Der Beitrag dieser Arbeit liegt nicht in der Nutzung von LLMs zur Textanalyse – dies ist bekannt –, sondern in der systematischen Methodisierung dieser Nutzung: ein reproduzierbares Fünfschritt-Protokoll, ein sechsschichtiger Validierungsrahmen und eine formale Syntheseeinheiten-Systematik, die zusammen eine rigorose qualitative Methode konstituieren.

2. Theoretischer Rahmen

2.1 Weltbild als latentes Konstrukt

Der Begriff *Weltbild* (engl. *worldview*, *Weltanschauung*) bezeichnet in der hier vorgeschlagenen Verwendung die Gesamtheit der grundlegenden Überzeugungen eines Akteurs über das Selbst, die Welt und die Menschheit. Ein Weltbild umfasst ontologische Annahmen, epistemische Überzeugungen, axiologische Orientierungen sowie praxeologische Dispositionen. Der Begriff ist bewusst umfassender gewählt als verwandte Termini wie *Einstellung*, *Werthaltung* oder *Ideologie*, da er das Überzeugungssystem als integrale Ganzheit zu erfassen beansprucht.

Diese Begriffsbestimmung steht in einer langen ideengeschichtlichen Tradition. Dilthey (1911) führte den Weltanschauungsbegriff als Grundkategorie der Geisteswissenschaften ein. Jaspers (1919) systematisierte Weltanschauungen als umfassende Orientierungsstrukturen. In der Wissenssoziologie verwandte Mannheim (1929) den Begriff der Weltanschauung, um standortgebundene Denkstile zu charakterisieren.

Eine zentrale Eigenschaft von Weltbildern ist ihre *Latenz*: Sie sind nicht direkt beobachtbar. Kein Akteur verfügt in der Regel über eine vollständige, explizite Artikulation seines Weltbilds. Stattdessen manifestieren sich Weltbilder indirekt – in sprachlichen Äußerungen, in Handlungsentscheidungen, in dem, was als selbstverständlich vorausgesetzt und nicht eigens thematisiert wird. Die Latenz hat eine doppelte Ursache: Viele grundlegende Überzeugungen sind *prä-reflexiv* – sie operieren als *Doxa* im Sinne Bourdieus (1977) –, und Weltbilder sind *strategisch verdeckt*: Akteure artikulieren ihre Überzeugungen selektiv (Goffman, 1959). Die methodische Konsequenz: Die Rekonstruktion erfordert einen *abduktiven Inferenzschritt* im Sinne von Peirce (1903) – einen Schluss auf die beste Erklärung.

Tabelle 1 grenzt den Weltbild-Begriff von verwandten Konstrukten ab.

Tabelle 1: Abgrenzung des Weltbild-Begriffs von verwandten Konstrukten.

Konstrukt	**Bezugseinheit**	**Umfang**	**Funktion**	**Latenz**
Weltbild (SWR)	Individuum	Umfassend	Deskriptiv	Latent
Ideologie	Soziale Gruppe	Umfassend	Herrschaftsbezogen	Latent
Habitus	Individuum/Klasse	Inkl. Körper	Reproduktionsbez.	Latent
Frame	Thema/Situation	Partikulär	Aufmerksamkeit	Manifest/Lat.
Mental Model	Individuum	Domänenspez.	Kognitiv-funkt.	Latent

2.2 Überzeugungssystem-Forschung: Historischer und methodischer Kontext

Die Erforschung von Überzeugungssystemen verfügt über eine reiche methodische Tradition, auf der die SWR aufbaut. Converse (1964) zeigte in seiner wegweisenden Analyse der Massenöffentlichkeit, dass politische Überzeugungssysteme hochvariable Grade an *Constraint* aufweisen – die logische Verknüpfung zwischen einzelnen Überzeugungen variiert dramatisch über Bildungsschichten. Dieser Befund unterstreicht die Herausforderung, vor der die SWR steht: Der „Kohärenzbias“ von LLMs (Sektion 6) könnte stärker verknüpfte Rekonstruktionen erzeugen als die empirische Realität rechtfertigt, insbesondere bei Nicht-Eliten-Subjekten. Axelrods (1976) Technik des Cognitive Mapping repräsentiert einen frühen systematischen Versuch, kausale Überzeugungsstrukturen aus verbalen Daten zu rekonstruieren; die SWR lässt sich als computationelle Erweiterung dieser Tradition verstehen. Die Q-Methodologie (Stephenson, 1953; Watts & Stenner, 2012) bietet einen besonders relevanten Vergleich: Wie die SWR zielt sie darauf ab, kohärente Muster von Subjektivität zu identifizieren, jedoch durch Faktorenanalyse von Forced-Rank-Sortierungen statt durch LLM-vermittelte Synthese. Die SWR unterscheidet sich von der Q-Methodologie in drei Hinsichten: (i) sie operiert auf naturalistischen Daten statt auf forscher-designten Q-Sorts; (ii) sie produziert narrative Rekonstruktionen statt numerischer Faktorladungen; und (iii) sie ist auf große Personenzahlen skalierbar, ohne deren aktive Teilnahme zu erfordern. Ein systematischer Vergleich von SWR und Q-Methodologie am selben Datensatz wäre eine wertvolle Validierungsübung.

2.3 LLMs als qualitative Forschungsinstrumente

Die für die SWR entscheidende Eigenschaft von LLMs lässt sich als *synthetische Integrationsfähigkeit* bezeichnen: die Fähigkeit, aus fragmentarischen, heterogenen und verteilt vorliegenden Informationen kohärente Ganzheiten zu erzeugen. Diese Fähigkeit weist eine bemerkenswerte strukturelle Analogie zur *hermeneutischen Kompetenz* auf: Der hermeneutische Zirkel – das wechselseitige Erhellen von Teil und Ganzem (Gadamer, 1960) – findet in der Arbeitsweise von LLMs ein operationales Analogon.

Mehrere Arbeiten bilden den unmittelbaren Referenzrahmen: Ziems et al. (2024) zeigen, dass LLMs implizite Bedeutungen erfassen können, die sich statistischen Oberflächenanalysen entziehen. Bail (2024) argumentiert, dass LLMs komplexe sozialwissenschaftliche Konstrukte messen könnten. Argyle et al. (2023) demonstrieren, dass LLMs die Perspektiven heterogener sozialer Gruppen simulieren können. Park et al. (2023) zeigen, dass generative Agenten plausibles soziales Verhalten erzeugen.

Diese strukturelle Analogie lässt sich durch die Perspektive der *Computational Hermeneutics* schärfen. Ramberg & Gjesdal (2026) schlagen vor, dass generative KI-Systeme als „Kontextmaschinen“ fungieren, die drei interpretative Herausforderungen adressieren müssen, die jeder hermeneutischen Tätigkeit inhärent sind: *Situiertheit* (Bedeutung entsteht nur im Kontext), *Pluralität* (mehrere gültige Interpretationen koexistieren) und *Ambiguität* (Interpretationen konfligieren natürlicherweise). Jede dieser Herausforderungen bildet sich direkt auf das methodische Design der SWR ab: Situiertheit wird durch die Syntheseeinheiten-Architektur adressiert, Pluralität durch mehrere unabhängige Runs und Inter-LLM-Vergleich, Ambiguität durch den Meta-Reflexionsschritt. Fundamentaler noch bietet Gadamers Konzept der *Horizontverschmelzung* (Gadamer, 1960) – die produktive Verschmelzung des Vorverständnisses des Interpreten mit dem interpretierten Artefakt – einen philosophischen Rahmen für das, was die SWR operationalisiert: Das LLM bringt seinen trainingsbasierten „Horizont“ in Kontakt mit dem Datenkorpus und erzeugt ein synthetisches Weltbild, das weder reine Datenextraktion noch reine Modellprojektion

ist, sondern eine hermeneutische Fusion beider. Diese Analogie hat jedoch Grenzen: LLMs fehlt die genuine *Vorurteilsstruktur*, die Gadamer als konstitutiv für Verstehen betrachtet, und ihr „Horizont“ ist ein statistisches Artefakt, keine gelebte Perspektive (Hornby, 2024).

Die synthetische Integrationsfähigkeit ist zugleich die Quelle spezifischer methodischer Risiken: (1) *Kontaminationsrisiko* – das LLM verfügt über Vorwissen über die analysierte Person; (2) *Kohärenzbias* – LLMs produzieren systematisch kohärentere Narrative als die Daten rechtfertigen; (3) *Stochastizität* – identische Inputs können verschiedene Outputs erzeugen; (4) *Implizite Normativität* – Trainingsdaten und RLHF prägen die Outputs. Die SWR adressiert jedes dieser Risiken durch dedizierte Kontrollmechanismen (Sektion 4).

3. Die Methode: Synthetische Weltbild-Rekonstruktion

3.1 Grundidee: Das Weltbild als inverses Problem

Die SWR formalisiert die Rekonstruktion latenter Weltbilder als *inverses Problem* (Tarantola, 2005). Das Vorwärtsproblem lautet: Wenn eine Person mit Weltbild W in Situation S agiert, welche Aussagen A und Handlungen H sind zu erwarten?

$$W + S \longrightarrow \{A, H\} \tag{1}$$

Das inverse Problem kehrt die Inferenzrichtung um:

$$\{A_1, \ldots, A_n\} + \{H_1, \ldots, H_m\} \longrightarrow W^* \tag{2}$$

Dieses Problem ist *schlecht gestellt* (ill-posed) im Sinne Hadamards (Hadamard, 1923): Die drei klassischen Wohlgestelltheitskriterien – Existenz, Eindeutigkeit und stetige Abhängigkeit von den Daten – sind jeweils verletzt. *Existenz* ist nicht garantiert, weil dem beobachteten Verhalten möglicherweise kein kohärentes Weltbild zugrunde liegt. *Eindeutigkeit* scheitert, weil mehrere intern konsistente Weltbilder dieselbe Menge an Manifestationen erklären können. *Stabilität* ist gefährdet, weil kleine Änderungen im Datenkorpus (Hinzufügen oder Entfernen einer einzelnen Rede) das rekonstruierte Weltbild substantiell verschieben können. Die SWR beansprucht daher nicht, *das* Weltbild einer Person zu identifizieren, sondern *ein* Weltbild zu rekonstruieren, das den bestmöglichen Fit für die Gesamtheit der beobachteten Daten bietet – eine Bestapproximation unter Unsicherheit. Die methodische Antwort spiegelt – auf struktureller, nicht mathematischer Ebene – bewährte Strategien der inversen Problemtheorie wider: Regularisierung durch die Kohärenzinstruktion (strukturell analog zur Tikhonov-Regularisierung, insofern sie inkohärente Lösungen bestraft, jedoch als natürlichsprachliche Instruktion implementiert statt als mathematischer Strafterm), Varianzkontrolle durch mehrere unabhängige Runs (analog zu Ensemble-Methoden) und Triangulation durch kreuzmodale Vorhersage (analog zur Multi-Source-Inversion). Diese Analogien verdeutlichen die epistemologische Struktur der Designentscheidungen der SWR; sie implizieren nicht, dass die SWR die formalen Garantien mathematischer Inversionsverfahren erreicht.

Anmerkung 3.1 (Zur mathematischen Notation). Die Gleichungen (1) und (2) dienen als *konzeptionelle Notation* – sie formalisieren die logische Struktur des inversen Problems, sind aber nicht im mathematischen Sinne operational berechenbar. Die „Inversion“ wird vom LLM durch sein Prompt-Protokoll durchgeführt, nicht durch einen mathematischen Algorithmus. Die Notation dient der Präzisierung der epistemologischen Struktur der Methode, in der Tradition der inversen Problemtheorie (Tarantola, 2005),

in der die Problemformulierung der (oft approximativen) Lösungsmethode vorausgeht.

3.2 Theoretische Verankerung

Die Struktur des inversen Problems verbindet die SWR mit vier bedeutenden intellektuellen Traditionen:

Webers Idealtyp. Max Webers (1904) Idealtyp ist ein gedankliches Konstrukt, das durch einseitige Steigerung bestimmter Gesichtspunkte gewonnen wird. Die synthetische Person ist ein Idealtypus des Weltbilds: ein konstruiertes Modell, das die Kohärenz der beobachteten Daten maximiert, ohne das tatsächliche innere Erleben abzubilden.

Zugleich bestehen wesentliche Disanalogien: Während Weber den Idealtyp als bewusste, forscherkontrollierte Abstraktion konzipierte, wird die Synthetische Person durch ein probabilistisches Modell erzeugt, dessen interner Inferenzprozess nicht transparent ist. Der Forscher kontrolliert den Prompt, nicht die Synthese. Dies impliziert einen Trade-off zwischen Kontrolle und Skalierbarkeit, der in der epistemologischen Reflexion berücksichtigt werden muss.

Booths Implied Author. Booths (1961) *implied author* ist das aus der Gesamtheit eines Werkes rekonstruierte kohärente Überzeugungssubjekt. So wie der implied author aus den Entscheidungen eines Textes rückerschlossen wird, wird das SWR-Weltbild aus den Entscheidungen eines Akteurs rückerschlossen.

Inverse Reinforcement Learning. IRL (Ng & Russell, 2000) fragt: Welche Zielfunktion müsste ein rationaler Agent maximieren, damit das beobachtete Verhalten als optimale Strategie erklärbar wird? An die Stelle der Belohnungsfunktion tritt das Weltbild, an die Stelle des beobachteten Verhaltens die dokumentierten Aussagen und Handlungen.

Projektive Tests. In der klinischen Psychologie werden projektive Verfahren (Rorschach, TAT) eingesetzt, um aus den Äußerungen und Reaktionen einer Person auf deren innere Dispositionen zu schließen. Die SWR teilt die Grundlogik des Rückschlusses von Äußerung auf Inneres, transponiert auf die Ebene öffentlicher Kommunikation.

Tabelle 2 fasst die disziplinären Parallelen zusammen.

Tabelle 2: Disziplinäre Parallelen zum inversen Ansatz der SWR.

Disziplin	**Konzept**	**Parallele**
Physik	Inverses Problem	Aus Messdaten das Modell rekonstruieren
Psychologie	Projektive Tests	Aus Äußerungen auf Inneres schließen
Literaturwiss.	Implied Author	Der Autor, den der Text impliziert
Soziologie	Idealtyp (Weber)	Verdichtetes Konstrukt, kein Abbild
Statistik	Latente Variablen	Unsichtbare Faktoren hinter Daten
KI-Forschung	Inverse Reinforcement Learning	Aus Verhalten auf Belohnungsfunktion schließen

3.3 Die fiktive synthetische Person

Das zentrale methodische Konstrukt der SWR ist die *fiktive synthetische Person*: ein vom LLM erzeugtes, fiktives Individuum, dessen Überzeugungssystem so konstruiert ist, dass es die Gesamtheit der präsentierten Daten am kohärentesten erklärt. Die synthetische Person ist weder eine Simulation der realen Person noch ein Porträt; sie ist das Destillat – das Weltbild in Reinform, befreit von biographischem Rauschen, PR-Strategien und situativen Verzerrungen. Sie ist die Antwort auf die Frage:

Welcher Mensch müsste existieren, damit all diese Aussagen und Handlungen aus einem kohärenten Weltbild hervorgehen?

Die Einführung einer fiktiven Person erfüllt fünf zentrale methodische Funktionen:

1. **Kontaminationsvermeidung.** Wenn das LLM eine fiktive Person konstruiert, wird das Risiko reduziert, dass Vorwissen aus dem Trainingskorpus einfließt.
2. **Trennung von Weltbild und Biographie.** Die fiktive Person trennt das Denken von der biographischen Kontingenz – ein Idealtypus des Denkens, kein Abbild des Lebens.
3. **Aggregationsfähigkeit.** Bei Gruppen-Syntheseeinheiten gibt es keine einzelne reale Person. Aber es gibt ein synthetisches Kollektiv-Weltbild, das sich als fiktive Person ausdrücken lässt.
4. **Standardisierte Vergleichbarkeit.** Alle synthetischen Personen werden mit identischem Prompt und Verfahren erzeugt – wie Messwerte aus demselben Instrument.
5. **Sichtbarmachung von Widersprüchen.** Eine fiktive Person *muss* die Widersprüche in den Daten integrieren. Die Reflexion macht diese Spannungen explizit.

Eine fundamentale epistemologische Frage bleibt bestehen: Rekonstruiert das LLM tatsächlich ein latentes Überzeugungssystem, oder produziert es lediglich eine plausibel klingende Textcollage, die der Leser nachträglich als kohärentes Weltbild interpretiert? Die SWR kann diese Frage nicht definitiv beantworten – sie ist eine Instanz des breiteren Problems, ob LLM-Outputs Verstehen konstituieren oder sofistizierte Mustervervollständigung darstellen (Messeri & Crockett, 2024). Die Antwort der Methode ist pragmatisch: Sie evaluiert die *funktionale Adäquatheit* der Rekonstruktionen durch kreuzmodale Vorhersage (stimmen aus der Rekonstruktion abgeleitete Vorhersagen mit beobachtetem Verhalten überein?), Inter-LLM-Konvergenz (konvergieren unabhängige Modelle auf ähnliche Rekonstruktionen?) und Expertenurteil. Wenn eine Rekonstruktion diese Tests besteht, wird sie als nützliches Modell des Weltbilds behandelt, unabhängig vom ontologischen Status des LLM-„Verstehens“. Dieses pragmatische Kriterium steht in der instrumentalistischen Tradition der Wissenschaftsphilosophie, in der Modelle nach ihrem prädiktiven und erklärenden Nutzen bewertet werden und nicht nach ihrer Korrespondenz mit unbeobachtbaren Entitäten.

3.4 Variablenarchitektur

Das Forschungsdesign der SWR ist als vierstufige Variablenarchitektur konzipiert:

Ebene 1: Abhängige Variablen (AVs) – *Was* wir messen.
Drei latente Konstrukte: Selbstbild (AV1), Weltbild (AV2), Menschenbild (AV3).

Ebene 2: Operationalisierungen (Ops) – *Wie* wir die AVs messen.
Sechs Analysetechniken (Op1–Op6), die verschiedene Zugänge bieten.

Ebene 3: Messvariablen (MVs) – *Welche* konkreten Outputs die Ops liefern.
50+ spezifische Messwerte (Texte, Scores, Vektoren, Tabellen).

Ebene 4: Unabhängige Variablen (UVs) – *Was* wir manipulieren.
Sechs Topf-Dimensionen, die die Syntheseeinheiten definieren.

Die drei **abhängigen Variablen** folgen einer anthropologischen Grundstruktur: Das Subjekt verhält sich zu sich selbst (Selbstbild), zur umgebenden Wirklichkeit (Weltbild im engeren Sinne) und zu den anderen Subjekten (Menschenbild). Diese Dreiteilung strukturiert sowohl das Interview-Protokoll als auch die dimensionale Quantifizierung.

3.5 Syntheseeinheiten: Systematische Datengruppierung

Die Bildung von Syntheseeinheiten erfolgt entlang von sechs **unabhängigen Variablen** (UVs):

UV1 Zeitraum. Einzeljahre, Epochen oder Gesamtzeitraum. Ermöglicht die Analyse von Weltbild-Dynamiken.

UV2 Modalität. Aussagen (A), Handlungen (H) oder beides (AH). Zentral für die Kongruenz-Validierung.

UV3 Personengruppe. Alle, Top-n, oder Subgruppen nach Rolle, Organisation, Haltung, Geschlecht.

UV4 Inhaltskategorie. Thematische Differenzierung. Kann durch Bottom-Up-Clustering (Op5) ersetzt werden.

UV5 Kongruenzstatus. Filterung nach konsistentem oder widersprüchlichem Aussagen-Handlungs-Profil.

UV6 Homogenisierung. Kontrolle der Datendichte und -zuverlässigkeit.

Formal lässt sich eine Syntheseeinheit als Tupel beschreiben:

$$\mathrm{SE}_i = (\mathrm{UV1}_j,\ \mathrm{UV2}_k,\ \mathrm{UV3}_l,\ \mathrm{UV4}_m,\ \mathrm{UV5}_n,\ \mathrm{UV6}_o) \tag{3}$$

Die vollständige Kreuzklassifikation aller UVs erzeugt einen kombinatorisch großen Raum (typischerweise >1.000 mögliche Syntheseeinheiten). Neun *Reduktionskriterien* (K1–K9) steuern die Top-Down-Ableitung der tatsächlich zu analysierenden Einheiten. Die Anwendung führt typischerweise zu 51–56 Kern-Syntheseeinheiten – eine Reduktion um >95 %. Die neun Kriterien sind wie folgt definiert; alle numerischen Schwellenwerte (z. B. 70 %, 15 Jahre, 0,85 BLEU) sind vorgeschlagene Ausgangswerte, basierend auf methodischen Überlegungen und Analogien zu etablierten Standards in Inhaltsanalyse und Umfragemethodik. Sie sind explizit nicht empirisch kalibriert und erfordern eine systematische Sensitivitätsanalyse in künftigen Anwendungen. Forschende sollten die Schwellenwerte an ihren spezifischen Studienkontext anpassen:

3.6 Das Prompt-Protokoll

Das Kernverfahren der SWR ist ein standardisiertes Prompt-Protokoll, das für jede Syntheseeinheit eine identische Sequenz von fünf Schritten durchläuft:

1. **Datenkorpus zusammenstellen.** Aus der Datenbasis wird das Datenbündel der Syntheseeinheit extrahiert. Identifizierende Informationen werden entfernt (vgl. 3.9).

Tabelle 3: Reduktionskriterien K1–K9 für die Ableitung von Syntheseeinheiten.

Kriterium	Definition und Schwellenwert
K1	*Datenverfügbarkeit:* Mindestens 70 % der a priori definierten Quellkategorien (z. B. öffentliche Reden, veröffentlichte Texte, dokumentierte Entscheidungen) müssen im Datenkorpus vertreten sein. Eine Syntheseeinheit wird nur analysiert, wenn dieser Schwellenwert erfüllt ist.
K2	*Zeitliche Relevanz:* Quelldokumente, die älter als ein studienspezifischer Grenzwert (Standard: 15 Jahre) sind, werden ausgeschlossen, es sei denn, sie stellen Grundlagenwerke dar, die in späteren Dokumenten zitiert werden. Der Grenzwert sollte an den Forschungskontext angepasst werden; für historische oder philosophische Subjekte können längere Zeitfenster angemessen sein.
K3	*Aggregation:* Wenn zwei UVs für $\geq$80 % der Datenpunkte empirisch ununterscheidbar sind, werden sie zu einer kombinierten Einheit zusammengefasst.
K4	*Sättigung:* Die Datenerhebung für eine Einheit endet, wenn drei aufeinanderfolgende Quellen keine neuen Informationen liefern; Mindestkorpus: 5 Quellen.
K5	*Analytische Relevanz:* Einheiten, deren UVs keine Varianz über die Studienpopulation zeigen, werden ausgeschlossen (konstante Variablen).
K6	*Quellenübergreifende Konsistenz:* Einheiten mit $>$50 % widersprüchlichen Informationen über Quellen hinweg werden für manuelle Überprüfung markiert statt automatisch synthetisiert.
K7	*Sprachliche Zugänglichkeit:* Quellen in Sprachen ohne etablierte maschinelle Übersetzungsabdeckung ($<$0,85 BLEU) werden ausgeschlossen oder erfordern menschliche Übersetzung.
K8	*Öffentliche Dokumentation:* Einheiten werden nur analysiert, wenn die Daten aus dokumentierten öffentlichen Quellen stammen; private Kommunikation wird ausgeschlossen.
K9	*Ethisches Screening:* Einheiten, die sensible Dritte betreffen (z. B. Familienmitglieder, die nicht selbst öffentliche Personen sind), werden ausgeschlossen.

2. **LLM-gestützte Synthese.** Das LLM erhält den Auftrag, eine fiktive Person zu erschaffen, deren Weltbild die größte Erklärungskraft für die Daten bietet. Der Prompt enthält: eine Kohärenzinstruktion, eine Spannungsinstruktion (Widersprüche nicht glätten), eine Evidenzinstruktion (Konfidenz angeben) und eine Fiktionsinstruktion.

3. **Strukturiertes Interview.** Die synthetische Person wird zu drei Kernbereichen befragt:

   - *Frage 1 (Selbstbild/AV1):* Wie sieht diese Person sich selbst? Rolle, Mission, Identität?
   - *Frage 2 (Weltbild/AV2):* Wie sieht sie die Welt? Grundannahmen über Technologie, Institutionen, Macht?
   - *Frage 3 (Menschenbild/AV3):* Wie sieht sie den Menschen? Natur, Potenzial, Grenzen?

4. **Meta-Reflexion.** Das LLM tritt aus der Rolle heraus und benennt: (a) die stärksten Überzeugungen, (b) die größten inneren Spannungen, (c) die blinden Flecken. Dieser Schritt kontrolliert den Kohärenzbias.

5. **Destillat und ergänzende Prompts.** Die Sitzung schließt mit einem *Destillat-Prompt*, der die Synthese auf fünf Kernaussagen komprimiert (MV1.4). Drei optionale spezialisierte Prompts können als

Erweiterungen folgen: ein *Vergleichs-Prompt* (Dialoganalyse zwischen zwei synthetischen Personen), ein *Zeitreise-Prompt* (Epochen-Kontrast über Syntheseeinheiten) und ein *Kongruenz-Prompt* (expliziter Aussagen-Handlungs-Vergleich).

Die fünf Schritte werden in einer einzigen Konversationssitzung ausgeführt, sodass der vollständige Kontext erhalten bleibt. Für jede Syntheseeinheit wird eine *neue* Sitzung gestartet, um Kontamination zwischen Einheiten zu verhindern. *Instanztrennung* ist eine kritische methodische Anforderung: Wenn dieselbe Syntheseeinheit mehrfach für Reliabilitätsschätzungen (IMIIRR) verarbeitet wird, muss jeder Run in einer separaten Agenteninstanz ohne geteilten Konversationskontext stattfinden. Runs, die Kontext teilen, sind keine unabhängigen Messungen und können nicht für Reliabilitätsschätzungen verwendet werden.

3.7 Sechs Operationalisierungen

Die drei abhängigen Variablen werden durch sechs komplementäre Operationalisierungen (Op1–Op6) zugänglich gemacht, die insgesamt mehr als 50 konkrete Messvariablen erzeugen.

3.7.1 Op1: Narrative LLM-Fiktionsanalyse

Op1 bildet den qualitativen Kern. Für jede SE wird das Prompt-Protokoll (Schritte 2–5) durchgeführt. Messvariablen: Selbstbild-Text (MV1.1), Weltbild-Text (MV1.2), Menschheitsbild-Text (MV1.3), 5-Satz-Destillat (MV1.4), Kernüberzeugungen (MV1.5), innere Spannungen (MV1.6), blinde Flecken (MV1.7).

3.7.2 Op2: Dimensionale Quantifizierung

Op2 überführt die qualitativen Synthese-Texte in quantitative Messwerte. In einem separaten Rating-Prompt wird jeder Text auf zwölf Weltbild-Dimensionen (D01–D12) bewertet, die sich gleichmäßig auf die drei AVs verteilen (je vier Dimensionen pro AV, Skala 1–10). Die resultierende Datenmatrix (Syntheseeinheiten $\times$ 12 Dimensionen) bildet die Grundlage für statistische Analysen. Die Dimensionen werden anwendungsspezifisch definiert; die Companion-Studie (Geiger, 2026) bietet ein vollständig ausgearbeitetes Beispiel mit Dimensionen wie u. a. *Technologie-Optimismus* (D01), *Institutionelles Vertrauen* (D04), *Religiös-transzendente Orientierung* (D05) und *Politisch-ökonomische Orientierung* (D11). Eine exemplarische Dimensionierung ist in Anhang B dokumentiert.

Die 10-Punkt-Skala ist als Ordinalskala zu interpretieren, nicht als echte Intervallskala. Obwohl Ordinalskalen manchmal als quasi-Intervallskalen behandelt werden können, wenn sie über eine genügende Anzahl von Kategorien verfügen (Norman, 2010), empfehlen wir zur Vorsicht robuste nonparametrische Statistiken: Mediane statt Mittelwerte, Spearman-Korrelationen statt Pearson, und rangbasierte Tests.

3.7.3 Op3: Deskriptive Textanalysen

Op3 ergänzt die LLM-gestützten Operationalisierungen um klassische computerlinguistische Verfahren: TF-IDF-Analysen zur Identifikation gruppenspezifischer Schlüsselbegriffe, Sentiment-Analysen differenziert nach den drei Interview-Antworten, Metaphernanalysen, semantische Ähnlichkeitsberechnungen (Cosine Similarity auf Sentence-BERT-Embeddings Reimers & Gurevych, 2019) und thematische Modellierung (BERTopic Grootendorst, 2022/LDA). Op3 wird sowohl auf die Synthese-Texte (Op1-Outputs) als auch auf die Rohdaten angewandt.

3.7.4 Op4: Kreuzmodale Vorhersage

Op4 ist der stärkste integrale Validierungsmechanismus. Ein Weltbild, das nur aus *einer* Datenmodalität rekonstruiert wurde, wird genutzt, um Vorhersagen über die *andere* Modalität zu erzeugen. Konkret: (a) Nur-Aussagen → synthetische Handlungen → Abgleich mit echten Handlungen; (b) Nur-Handlungen → synthetische Aussagen → Abgleich. Der resultierende Kongruenz-Score (0–1) quantifiziert die modale Invarianz:

$$W_A \approx W_H \tag{4}$$

Hohe Übereinstimmung indiziert robuste Rekonstruktion; systematische Diskrepanzen offenbaren inhaltlich bedeutsame Inkonsistenzen zwischen Sagen und Handeln.

Der Kongruenz-Score lässt sich auf drei Weisen operationalisieren: (a) Anteil der von einer unabhängigen LLM-Instanz als 'konsistent' oder 'plausibel' bewerteten Vorhersagen; (b) Cosinus-Ähnlichkeit zwischen Sentence-BERT-Embeddings vorhergesagter vs. tatsächlicher Handlungsbeschreibungen; (c) Bewertung durch menschliche Experten auf einer 5er-Skala (implausibel–sehr plausibel). Wir empfehlen, wenn möglich alle drei zu berichten, mit (a) als Mindeststandard.

Es ist zu beachten, dass die kreuzmodale Vorhersage primär die *interne Konsistenz* des Rekonstruktionsprozesses misst, nicht die *externe Validität* der Rekonstruktion. Ein LLM, das systematisch kohärente Persona-Modelle erzeugt, wird auch kohärente Vorhersagen generieren – unabhängig davon, ob das rekonstruierte Weltbild korrekt ist. Daher ist die kreuzmodale Vorhersage notwendig, aber nicht hinreichend als Validierungsinstrument und muss durch externe Kriterien (Expert Judgment, Known-Groups-Validierung) ergänzt werden.

3.7.5 Op5: Bottom-Up-Clustering und Netzwerk-Analyse

Op5 ist die methodisch stärkste Technik, weil sie *ohne Vorannahmen* arbeitet. Sämtliche Datenpunkte werden mittels Sentence-BERT-Embeddings (Reimers & Gurevych, 2019) in einen hochdimensionalen Vektorraum überführt und mittels HDBSCAN (McInnes et al., 2017) oder BERTopic (Grootendorst, 2022) geclustert. Für jede Person werden Profil-Vektoren berechnet (Verteilung über emergente Cluster). Daraus wird eine Distanzmatrix berechnet, auf deren Grundlage mittels Community Detection (Louvain/Leiden) Weltbild-Gemeinschaften identifiziert werden. Der Mantel-Test prüft die Korrelation zwischen Weltbild-Nähe und Realwelt-Nähe (gleiche Organisation, Investor-Gründer-Beziehung, akademisches Netzwerk). Op5 liefert emergente Weltbild-Typen, die weder durch Forschungsfragen noch durch a-priori-Kategorien prädeterminiert sind.

3.7.6 Op6: Vergleichende Dialoganalyse

Op6 setzt bestehende Synthesen in einen strukturierten Dialog: Zwei synthetische Personen aus unterschiedlichen SEs führen ein Gespräch, in dem ihre Weltbild-Unterschiede sichtbar werden. Das LLM identifiziert Konsens-Zonen (Bereiche substanzieller Übereinstimmung) und Konflikt-Zonen (Bereiche fundamentaler Uneinigkeit). Messvariablen umfassen: Anzahl und Inhalt der Konsens-/Konflikt-Zonen (MV6.1), eine qualitative Charakterisierung der tiefsten Meinungsverschiedenheit (MV6.2) und eine strukturierte Zusammenfassung des stärksten Arguments jeder synthetischen Person zum strittigen Thema (MV6.3). Der Dialog wird durch einen standardisierten Prompt geleitet, der spezifiziert, dass beide synthetischen Personen aus ihren rekonstruierten Weltbild-Positionen argumentieren, ihren stärksten Fall

artikulieren und den präzisen Punkt der Divergenz identifizieren sollen. Dieser Ansatz ermöglicht die qualitative Analyse von Differenzen, die über numerische Vergleiche hinausgeht, und ist besonders geeignet für die Generierung von Hypothesen über die Quellen von Weltbild-Meinungsverschiedenheiten.

3.8 Workflow-Reihenfolge

Die Durchführung folgt einer theoretisch begründeten Reihenfolge:

1. **Op5** (Bottom-Up) zuerst → Entdecke die Weltbild-Typen ohne Vorannahmen.
2. **Op1** (Synthese) für jeden Typ → Gib den Typen narrative Gesichter.
3. **Op6** (Dialog) zwischen den Typen → Zeige die Spannungen.
4. **Op4** (Kreuzmodal) pro Typ → Prüfe die Authentizität.
5. **Op2** (Dimensionen) über die Zeit → Messe den Wandel.
6. **Op3** (Deskriptiv) auf alles → Ergänze quantitative Indikatoren.

Die Logik dieser Sequenz ist: induktiv vor deduktiv, Entdeckung vor Messung, Exploration vor Konfirmation. Dies folgt der Grounded-Theory-Logik, induktive Kategorienbildung gegenüber deduktiven Setzungen zu bevorzugen.

In der praktischen Umsetzung werden die Syntheseeinheiten in *Batches* organisiert: Batch 0 (Bottom-Up-Clustering), Batch 1 (Kern-Synthesen), Batch 2 (zeitliche Variation), Batch 3 (Kongruenzprüfung), Batch 4 (Gruppenvergleiche), Batch 5 (Cluster-Synthesen, abhängig von Batch 0), Batch 6 (Vergleichs-Dialoge). Die Abhängigkeitsstruktur zwischen Batches ist Teil des Forschungsdesigns.

3.9 Blindung als Fokuskontrolle

Blindung stellt sicher, dass das LLM die vorgelegten Daten verarbeitet statt auf gespeichertes Wissen zurückzugreifen. Es ist irrelevant, ob das Modell einzelne Personen erkennt – entscheidend ist, dass es seinen Auftrag ausführt: aus den bereitgestellten Daten einen kohärenten synthetischen Charakter zu konstruieren.

Die SWR begegnet dem Kontaminationsrisiko durch eine systematische Blindungsinfrastruktur auf vier Ebenen:

Ebene 1: Namensentfernung. Alle Eigennamen durch neutrale Platzhalter.

Ebene 2: Organisationsentfernung. Firmennamen und institutionelle Zugehörigkeiten durch generische Bezeichnungen.

Ebene 3: Ereignisentfernung. Spezifische Ereignisse abstrahiert.

Ebene 4: Stilnivellierung. Distinktive sprachliche Eigenheiten paraphrasiert.

Die Blindung ist graduell implementiert: Es werden sowohl blindierte als auch nicht-blindierte Analysen durchgeführt. Der Vergleich liefert eine direkte Messung des Kontaminationseffekts. Als ergänzender Validierungstest kann die Identifikation der realen Person hinter einer Synthese als eigener Prompt eingesetzt werden (vgl. 4.4).

Die Blindung hat explizite Grenzen: Merkmalskombinationen können Re-Identifikation ermöglichen; die Entfernung von Kontext reduziert den Informationsgehalt; LLMs können über indirekte Indikatoren identifizieren. Die Blindung ist daher ein Baustein eines mehrschichtigen Kontrollregimes, kein hinreichendes Mittel.

Bei prominenten Personen kann die Blindung durch Merkmalskombinationen unterlaufen werden, selbst wenn einzelne Identifikatoren entfernt wurden. Diese Einschränkung ist besonders akut für den primären Anwendungsfall der SWR – die Analyse öffentlicher Eliten –, bei denen einzigartige Kombinationen von Rollen, Leistungen und öffentlichen Positionen Personen trotz formaler Anonymisierung identifizierbar machen können. Die Blindung reduziert Kontamination, eliminiert sie aber nicht. Ein empirischer Kontaminationstest – Vergleich blindierter und nicht-blindierter Analysen derselben Personen mit Messung der Profildivergenz – ist daher unverzichtbar. Das Ausmaß der gemessenen Divergenz liefert eine quantitative Schätzung der Kontaminationsschwere und sollte in jeder SWR-Anwendung berichtet werden. Wenn die Blindiert-Unblindiert-Divergenz für eine gegebene Population vernachlässigbar ist, deutet dies darauf hin, dass entweder die Kontamination gering oder die Blindung unwirksam war; ergänzende Kontrollen (z. B. Analyse von Personen, die in den Trainingsdaten des LLM nicht vorkommen) sind erforderlich, um zwischen beiden Möglichkeiten zu differenzieren.

4. Qualitätssicherung und Validierung

Der Validierungsrahmen der SWR umfasst sechs komplementäre Strategien.

4.1 V1: Instrumentenkalibrierung (Run-Konvergenz)

Der primäre Reliabilitätstest für die SWR ist die *Within-Model-Run-Konvergenz*: Dasselbe LLM verarbeitet dieselben Daten mehrfach, und die Übereinstimmung über Durchläufe wird mittels Intraklassenkorrelationskoeffizienten (ICC) gemessen. Dieser Ansatz behandelt das LLM als *einzelnes Messinstrument*, das kalibriert werden muss – analog zur Etablierung von Test-Retest-Reliabilität für eine psychometrische Skala. Akzeptanzkriterien:

- ICC $> .75$: Gute Kalibrierung; Instrument ist reliabel.
- $.60 <$ ICC $< .75$: Akzeptabel; Kernstrukturen stabil, Details variieren.
- ICC $< .60$: Ungenügende Kalibrierung; Ergebnisse möglicherweise run-abhängig.

Empirische Validierung (Pilotstudie, Geiger, 2026). Die Pilotstudie validiert Run-Konvergenz auf zwei Rigorositätsstufen. Erstens wurden fünf Gruppen-Syntheseeinheiten jeweils zweimal unabhängig von Claude Opus 4.6 verarbeitet (5×2-Design). Die resultierenden D01–D12-Profile zeigten exzellente Konvergenz: Pearson $r = .908$, ICC(2,1) $= .902$, MAE $= 0{,}40$, entsprechend einer Messpräzision von $\pm 0{,}2$ Skalenpunkten. Zweitens ergab eine erweiterte Validierung mit $N = 15$ vollständig unabhängigen Einzelinstanz-Runs auf einer einzelnen Syntheseeinheit ICC(3,1) $= .847$ und mittlere SD $= 0{,}45$, mit perfekter Übereinstimmung auf der stabilsten Dimension (D02). Jeder der 15 Runs wurde in einer separaten Agenteninstanz ohne geteilten Kontext ausgeführt – was etabliert, dass die Reliabilität der SWR eine genuine Eigenschaft der Methode ist (*Intra-Model Inter-Instance Rating Reliability*, IMIIRR), kein Artefakt geteilten Konversationskontexts.

Instanztrennung ist eine kritische methodische Anforderung: Jeder Analyserun muss eine separate Agenteninstanz ohne geteilten Kontext verwenden. Runs, die Kontext teilen (z. B. mehrere Analysen innerhalb einer einzigen Konversation), sind keine unabhängigen Messungen und können nicht für Reliabilitätsschätzungen verwendet werden.

Inter-Modell-Vergleich (Replikation mit verschiedenen LLMs) bleibt ein wichtiger zukünftiger Validierungsschritt – konzeptuell äquivalent zur Replikation durch andere Forscher mit anderen Instrumenten. Solche Vergleiche erfordern strikte Unabhängigkeitskriterien (separate Instanzen, kein geteilter Kontext) und sollten mindestens ein Open-Weight-Modell mit dokumentiertem, distinkt anderem Trainingskorpus einschließen.

4.2 Prompt-Sensitivitätsanalyse

Für jeden Prompt werden mindestens drei paraphrasierte Varianten erzeugt, die dieselbe inhaltliche Instruktion in unterschiedlicher sprachlicher Form vermitteln. Akzeptanzkriterien: Die durch Prompt-Variation erklärte Varianz soll unter 15 % der Gesamtvarianz liegen; die Rangordnung der Personen soll stabil bleiben (Rangkorrelation $> .85$); die Kernüberzeugungen in den Destillaten sollen kongruent sein.

4.3 Dimensionale Quantifizierung

Jede Weltbild-Rekonstruktion wird auf zwölf Dimensionen (D01–D12) projiziert, die die drei AVs gleichmäßig abdecken (je vier Dimensionen, 10-Punkte-Skala). Die Dimensionen sind anwendungsspezifisch zu definieren und sollen folgende Validitätskriterien erfüllen:

- *Diskriminante Validität*: Profile verschiedener Personen müssen sich unterscheiden.
- *Konvergente Validität*: Scores müssen mit unabhängigen Quellen konvergieren.
- *Interne Konsistenz*: Moderate Interkorrelation innerhalb jedes Bereichs.
- *Faktorielle Struktur*: Explorative Faktorenanalyse soll die drei Bereiche reflektieren.

4.4 Identifikationstest (Reverse Blinding)

Der Identifikationstest fragt: Sind die Rekonstruktionen hinreichend individualisiert, um eine Zuordnung zur korrekten Person zu ermöglichen? Ein LLM, das nicht an der Rekonstruktion beteiligt war, versucht, blindierte Weltbild-Rekonstruktionen den analysierten Personen zuzuordnen. Eine *moderate* Trefferquote (signifikant über Zufall, aber unter 100 %) ist der günstigste Befund: individualisiert, aber nicht stereotyp-dominiert.

Ein wichtiger Vorbehalt: Hohe Identifikationsraten bestätigen nicht eindeutig eine valide Weltbild-Rekonstruktion. Sie könnten auch darauf hindeuten, dass die Rekonstruktion lediglich öffentlich präsente Stereotype der Person reproduziert – Stereotype, die das evaluierende LLM über seine eigenen Trainingsdaten erkennt. Um Individualisierung von Stereotyp-Reproduktion zu trennen, sollte der Identifikationstest durch eine *Stereotyp-Kontrolle* ergänzt werden: einen zweiten Test, in dem das evaluierende LLM versucht, Personen anhand bewusst stereotyper, nicht-SWR-generierter Profile zu identifizieren. Wenn SWR-generierte Profile höhere Identifikationsgenauigkeit liefern als stereotypbasierte Profile, ist dies ein stärkerer Beleg für genuine Individualisierung.

4.5 V5: Run-Konvergenz und Varianzdekomposition

Für jede SE wird das Protokoll mindestens zweimal unabhängig durchgeführt (Temperatur = 0 oder die niedrigste verfügbare Einstellung; zu beachten ist, dass Determinismus selbst bei Temperatur = 0 aufgrund von Hardware-Nichtdeterminismus in manchen Implementierungen nicht garantiert ist). Jeder Run muss in einer separaten Agenteninstanz ohne geteilten Kontext stattfinden (Instanztrennung). Die *Run-Konvergenz-Rate* (Anteil der Dimensionswerte mit $\leq$1 Skalenpunkt Variation) soll $\geq$80 % betragen; die mittlere Standardabweichung soll unter 1,0 liegen.

Empirische Ergebnisse (Pilotstudie, Geiger, 2026). Fünf Gruppen-Syntheseeinheiten wurden jeweils zweimal unabhängig von Claude Opus 4.6 verarbeitet, was eine Run-Konvergenz-Rate von 93 % ($\leq$1-Punkt-Variation) und eine MAE von 0,40 ergab. Eine erweiterte Validierung mit $N = 15$ unabhängigen Einzelinstanz-Runs bestätigte diese Ergebnisse (ICC(3,1) = .847, mittlere SD = 0,45) und etablierte IMIIRR als robuste psychometrische Eigenschaft der SWR. Zusätzlich zeigte ein Expected-Discrepancy-Kontrollexperiment, dass eine synthetische konsistente Gruppe kein artifizielles Sagen-Handeln-Gefälle produzierte (MAE = 0,50), während das reale KI-Elite-Gefälle 2,5$\times$ größer war (MAE = 1,25) – die Methode fabriziert also keine Diskrepanzen.

In einer integrierten Betrachtung können die Varianzquellen – zwischen Personen, zwischen Modellen, zwischen Prompt-Varianten, zwischen Runs – in einer Varianzkomponentenanalyse (Generalizability Theory; Brennan, 2001) zusammengeführt werden. Die SWR strebt ein Design an, in dem die Zwischen-Personen-Varianz $>$60 % der Gesamtvarianz erklärt.

4.6 V6: Adversarial Probing und Human-in-the-Loop-Review

Als komplementäre Qualitätssicherungsstrategie empfehlen wir *Adversarial Probing*: das systematische Herausfordern von SWR-Outputs durch bewusst provokative Gegen-Prompts, die darauf abzielen, verdeckte Verzerrungen, ungerechtfertigte Kohärenz oder stereotypes Denken aufzudecken. Dieser Ansatz baut auf dem Red-Teaming-Paradigma auf, das Perez et al. (2022) etabliert haben und das zeigt, dass automatisiertes adversariales Probing Fehlerquellen in LLM-Outputs aufdecken kann, die Standardevaluierung übersieht. Im SWR-Kontext können adversariale Probes beispielsweise umfassen: ein zweites LLM instruieren, zu argumentieren, dass das rekonstruierte Weltbild ein generisches Stereotyp statt eines individualisierten Porträts ist; widersprüchliche Evidenz präsentieren und testen, ob die Rekonstruktion sich anpasst; oder das Modell auffordern, ein gleich plausibles *alternatives* Weltbild aus denselben Daten zu generieren. Adversarial Probing sollte durch *Human-in-the-Loop-Review* ergänzt werden: Domänenexperten (Politikwissenschaftler, Soziologen, Biographen) evaluieren eine Stichprobe der Weltbild-Rekonstruktionen auf Plausibilität, Evidenzbasis und Abwesenheit stereotyper Zuschreibungen. Die Kombination aus automatisiertem adversarialem Stresstest und Expertenurteil bildet ein Best-Practice-Qualitätsregime, das sowohl Skalierbarkeit als auch interpretive Tiefe adressiert.

4.7 Minimale Akzeptanzkriterien

Eine SWR-Studie sollte Akzeptanzkriterien auf zwei Stufen erfüllen:

Stufe 1 (Instrumentenkalibrierung – erforderlich): (1) Within-Model-Run-Konvergenz ICC $>$ .75 (oder $\geq$ 80 % der Dimensionswerte mit $\leq$1-Punkt-Variation); (2) Prompt-Sensitivitäts-Varianzanteil $<$

15 % der Gesamtvarianz; (3) mindestens ein externer Validierungsanker (Expert Judgment, Known-Groups-Validierung oder kreuzmodale Vorhersage gegen dokumentierte Handlungen).

Stufe 2 (Modellunabhängigkeit – wünschenswert für Replikation): (4) Inter-Modell-Reliabilität ICC $>$ .70 über mindestens zwei Frontier-Modelle verschiedener Hersteller; (5) Diskriminierbarkeitstest signifikant über Zufallsbaseline.

Stufe-1-Kriterien sind Voraussetzung für Publikation; Stufe-2-Kriterien stärken die Generalisierbarkeit, sind aber konzeptuell äquivalent zur Replikation durch andere Forscher mit anderen Instrumenten. Die Pilotstudie (Geiger, 2026) erfüllt Stufe-1-Kriterien (1) und (3) (ICC(2,1) $=$ .902, erweitert auf ICC(3,1) $=$ .847 mit $N = 15$ unabhängigen Runs; kreuzmodale Vorhersage 72 % bestätigt, 0 % widersprochen). Diese Kriterien sind als vorläufige Richtwerte zu verstehen, die mit wachsender empirischer Erfahrung adjustiert werden können.

5. Ethische Betrachtungen

Die Rekonstruktion latenter Überzeugungssysteme aus öffentlich verfügbaren Daten wirft spezifische ethische Bedenken auf, die adressiert werden müssen.

5.1 Einwilligung und öffentliche Daten

Die SWR operiert ausschließlich auf *öffentlich verfügbaren* Daten – Aussagen aus Interviews, Reden, Social-Media-Beiträgen und dokumentierten Handlungen. Private oder vertrauliche Informationen werden nicht verwendet. Allerdings generiert die *Synthese* öffentlicher Daten zu einem kohärenten Weltbild-Modell eine qualitativ neue Form von Wissen über eine Person, die über das hinausgeht, was eine einzelne öffentliche Aussage offenbart. Dies wirft die Frage auf, ob die Aggregation öffentlicher Daten zu einem Überzeugungssystem-Porträt eine Form der Einwilligung erfordert, die über die durch öffentliche Kommunikation implizierte Einwilligung hinausgeht. Wir argumentieren, dass öffentliche Personen, die Politik und Technologie mit Auswirkungen auf Milliarden gestalten, eine reduzierte Privatsphäre-Erwartung hinsichtlich ihrer öffentlich artikulierten Weltbilder haben, räumen aber ein, dass die Anwendung der SWR auf nicht-öffentliche Personen eine strengere ethische Prüfung erfordern würde.

5.2 Missbrauchspotenzial

Die SWR könnte für unerlaubtes psychologisches Profiling, politische Manipulation oder gezielte Einflusskampagnen missbraucht werden. Mitigationsstrategien umfassen: (1) transparente Publikation aller Methoden und Prompts, die Überprüfung ermöglichen; (2) explizite Rahmung der Ergebnisse als *Modelle*, nicht als Behauptungen über tatsächliche Überzeugungen; (3) Empfehlung einer Ethikkommissions-Prüfung (IRB) für Anwendungen auf nicht-öffentliche Personen.

5.3 Epistemische Risiken

Das größte ethische Risiko liegt in der potenziellen *Reifizierung* rekonstruierter Weltbilder – der Behandlung von Modell-Outputs als gesicherte Fakten über die inneren Überzeugungen einer Person. Die SWR begegnet dem explizit durch die fiktionale Rahmung (die synthetische Person ist ein Konstrukt, kein Porträt) und die transparente Anerkennung von Kohärenzbias und Kontaminationsrisiko. Forschende, die die

SWR nutzen, haben die Verpflichtung, den konstruktiven und approximativen Charakter der Ergebnisse zu kommunizieren.

5.4 Epistemische Privatsphäre

Die SWR wirft eine Spannung auf, die expliziter Anerkennung bedarf: Der breitere KI-Governance-Diskurs betont zunehmend *Datensouveränität* – das Recht von Individuen, die Verwendung ihrer Daten zu kontrollieren. Die SWR rekonstruiert jedoch systematisch latente Überzeugungssysteme, die die analysierten Personen möglicherweise nie artikuliert oder offenzulegen beabsichtigt haben. Dies stellt eine potenzielle Verletzung dessen dar, was als *epistemische Privatsphäre* bezeichnet werden kann – das Recht, dass die eigenen impliziten Überzeugungen nicht inferiert und publiziert werden. Die Methode weist damit einen *Dual-Use*-Charakter auf: Als Forschungswerkzeug generiert sie wertvolle Einblicke in die Überzeugungssysteme, die Politik und Technologie prägen; als Profiling-Instrument könnte sie genau jene Datensouveränität untergraben, die verantwortungsvolle KI-Entwicklung einfordert. Diese performative Spannung – KI zur Rekonstruktion von Überzeugungen einzusetzen und gleichzeitig für epistemische Selbstbestimmung einzutreten – lässt sich nicht auflösen, muss aber in jeder Anwendung der SWR transparent benannt werden.

5.5 Empfehlung

Wir empfehlen, dass SWR-Studien mit identifizierbaren Personen eine Ethikprüfung durchlaufen, dass Ergebnisse mit expliziten Unsicherheitsmarkierungen publiziert werden und dass betroffenen Personen ein Widerspruchsrecht eingeräumt wird.

6. Diskussion

6.1 Methodische Stärken

Die zentrale Stärke der SWR liegt in der *Adressierung einer methodischen Lücke*: Sie verbindet die synthetische Tiefe qualitativer Verfahren mit der Skalierbarkeit computationeller Methoden. Weitere Stärken umfassen:

Epistemische Transparenz. Die explizite Kennzeichnung der Ergebnisse als fiktive Konstrukte schützt vor der Illusion unverdienter Unmittelbarkeit.

Strukturierte Vergleichbarkeit. Die dimensionale Quantifizierung stellt ein einheitliches Koordinatensystem bereit, in dem Weltbilder verortet, verglichen und aggregiert werden können.

Integration heterogener Datentypen. Die bimodale Integration von Aussagen und Handlungen geht über die Kapazität der meisten bestehenden Methoden hinaus.

Integrierte Qualitätssicherung. Der sechsschichtige Validierungsrahmen (V1–V6) wurde in der Pilotanwendung mit 12 QA-Maßnahmen empirisch getestet: Run-Konvergenz (ICC(2,1) = .902; erweitert auf ICC(3,1) = .847 mit $N = 15$ unabhängigen Runs, was IMIIRR etabliert), Expected-Discrepancy-Kontrolle (keine artifiziellen Gaps) und kreuzmodale Vorhersage (72 % bestätigt, 0 % widersprochen) etablieren Reliabilität und prädiktive Validität der Methode.

Machbarkeit. Eine vollständige SWR-Studie mit ∼200 Prompt-Runs lässt sich innerhalb eines Standard-LLM-Abonnements durchführen. Die Kosten liegen typischerweise im Bereich von 30–50 USD für API-

basierte Nutzung.

6.2 Pilotanwendung: Weltbild-Studie der KI-Elite

Um den methodischen Rahmen in einer konkreten Anwendung zu verankern, beschreiben wir kurz eine illustrative Pilotstudie, die die SWR auf eine politisch und soziologisch relevante Population anwendet: die 100 einflussreichsten Akteure der künstlichen Intelligenz (2010–2026), identifiziert durch ein Multi-Kriterien-Ranking-Verfahren (Geiger, 2026).

Datenkorpus. Für jeden der 100 Akteure wurde ein standardisierter Korpus aus drei Syntheseeinheiten-Typen (SE-I) zusammengestellt: (a) veröffentlichte Texte (Papers, Bücher, Meinungsartikel, Blogbeiträge), (b) dokumentierte Handlungen (Policy-Positionen, Investitionsentscheidungen, öffentliche Stellungnahmen) und (c) biographische Kontextdaten (Ausbildung, institutionelle Zugehörigkeiten, Karriereverlauf). Die Korpusgröße reichte von 15 bis 250 Seiten pro Akteur, abhängig von der Datenverfügbarkeit.

Vorgehen. Das vollständige Prompt-Protokoll (Sektion 3.6) wurde unter Verwendung von Claude (Anthropic) als einzigem LLM angewendet: Claude Sonnet 4.5 für batch-paralleles dimensionales Rating (9 Agenten) und Claude Opus 4.6 für Gruppen-Synthesen, qualitative Analysen und alle Validierungsexperimente. Blindung wurde für alle Syntheseeinheiten implementiert mittels eines dedizierten Skripts (`extract_blinded.py`), das Personennamen, Firmennamen, Produktnamen und Universitätszugehörigkeiten durch neutrale Platzhalter ersetzt ([PERSON], [FIRMA], [PRODUKT], [UNIVERSITÄT]). Vier Operationalisierungen wurden ausgeführt: Op1 (Kernsynthesen: 41 gruppenbasierte; 100 individuelle als Zwischendatenschicht), Op2 (dimensionales Rating auf D01–D12), Op4 (kreuzmodale Vorhersage: Aussagen $\rightarrow$ vorhergesagte Handlungen $\rightarrow$ Vergleich mit realen Handlungen, für 5 Gruppen) und Op6 (9 strukturierte Vergleichsruns). Op3 (Textanalyse) und Op5 (Bottom-up-Clustering auf Embeddings) wurden nicht ausgeführt. Die primäre Analyseeinheit war durchgehend die soziologisch definierte Gruppe, nicht der individuelle Akteur.

Ergebnisse. Die Companion-Studie (Geiger, 2026) berichtet die folgenden empirisch fundierten Befunde: Eine Hauptkomponentenanalyse der 100×12 Rating-Matrix identifiziert 5 Komponenten, die 80 % der Varianz erklären; HDBSCAN im vollständigen 12-dimensionalen Raum klassifiziert 80–100 % der Fälle als Rauschen, was bestätigt, dass die vier Weltbild-Typen Webersche Idealtypen sind und keine emergenten Datencluster; Subspace-Clustering auf den zwei stärksten diskriminierenden Dimensionen (D07, D11) ergibt einen Silhouette-Score von 0,57; Kruskal-Wallis-Tests zeigen 6/12 Dimensionen mit $p < 0{,}001$ über die vier Typen. Eine Gruppen-Sagen-Handeln-Dekomposition offenbart ein Simpson-Paradox: Das aggregierte Sagen-Handeln-Gefälle ist von Messrauschen nicht unterscheidbar, aber gruppenspezifische Gaps sind substanziell – CEOs zeigen einen klassischen Erwünschtheits-Gap, Risiko-Warner zeigen prophetische Konsistenz (sie artikulieren befürchtete Zukünfte, gegen die sie aktiv arbeiten). Validierungsergebnisse: Run-Konvergenz mit ICC(2,1) = .902 (5×2-Design), erweitert durch $N = 15$ vollständig unabhängige Einzelinstanz-Runs mit ICC(3,1) = .847 und mittlerer SD = 0,45 (was IMIIRR als robuste psychometrische Eigenschaft etabliert), Expected-Discrepancy-Kontrolle (keine artifiziellen Gaps), kreuzmodale Vorhersage mit 72 % Bestätigungsrate und 0 % Widerspruch über 5 Gruppen (Op4), und ein Aggregations-Synthese-Vergleich mit moderater Konvergenz ($r = .623$). Die Companion-Studie dokumentiert insgesamt 12 QA-Maßnahmen und erweitert den generischen V1–V6-Rahmen zu einem anwendungsspezifischen Qualitätsregime. Zwei Validierungsschichten bleiben ungetestet: V2 (Prompt-Sensitivität) und V4 (Diskriminierbarkeitstest). Inter-Modell-Vergleich (mit strikten

Instanztrennung-Kriterien) bleibt Priorität für künftige Arbeiten.

Reichweite und epistemischer Status der Pilotstudie. Das vorliegende Paper ist ein Methodenpaper, keine empirische Studie; die Pilotzusammenfassung ist aufgenommen, um den methodischen Rahmen in einem konkreten Forschungskontext zu verankern und die operationale Durchführbarkeit zu demonstrieren. Die Companion-Anwendungsstudie (Geiger, 2026) bietet vollständige methodische Details, Datendokumentation und statistische Analysen. Unabhängige Replikation durch andere Forschungsgruppen — unter Verwendung verschiedener LLMs, Populationen und Datenkorpora — bleibt die stärkste Form der Validierung für die SWR als Methode.

Validierungsabdeckung. Von den sechs in Sektion 4 vorgeschlagenen Validierungsschichten liefert die Pilotanwendung Evidenz für vier: V1 (Instrumentenkalibrierung: Run-Konvergenz mit ICC(2,1) = .902 für das 5×2-Design, erweitert auf ICC(3,1) = .847 für $N = 15$ unabhängige Einzelinstanz-Runs), V3 (Dimensionsstruktur via PCA: 5 Komponenten, 80 % Varianz), V5 (Run-Konvergenz: MAE = 0,40, mittlere SD = 0,45 für $N = 15$, plus Expected-Discrepancy-Kontrolle) und partielle Evidenz für Op4 (kreuzmodale Vorhersage: 72 % Bestätigungsrate, 0 % Widerspruch über 5 Gruppen). V2 (Prompt-Sensitivität), V4 (Diskriminierbarkeitstest) und V6 (Adversarial Probing) verbleiben als offene Validierungsaufgaben. Die abgeschlossenen Validierungen etablieren, dass die SWR *reliable* (V1/V5, IMIIRR), *nicht-artifizielle* (Diskrepanzkontrolle) und *prädiktiv valide* (Op4) Gruppen-Weltbild-Rekonstruktionen produziert. Höchste Priorität hat V2 (Prompt-Sensitivitätsanalyse); Inter-Modell-Vergleich (mit strikter Instanztrennung) ist die zweite Priorität.

6.3 Limitationen

Abhängigkeit vom LLM als Blackbox. Die internen Verarbeitungsprozesse sind nicht vollständig transparent. Der Validierungsrahmen mildert dieses Problem, löst es aber nicht vollständig. Allerdings sind auch menschliche Forscher in einem relevanten Sinne Blackboxes – die SWR tauscht eine Form der Opazität gegen eine andere und gewinnt dabei Skalierbarkeit und Kontrollierbarkeit.

Kontaminationsrisiko und Grenzen der Blindung. Trotz Blindung kann nicht ausgeschlossen werden, dass LLMs auf Trainingswissen zurückgreifen. Der Kontaminationseffekt ist kalkulierbar (Vergleich blindiert/nicht-blindiert), aber nicht eliminierbar.

Kohärenzbias. LLMs tendieren dazu, systematisch kohärenter zu rekonstruieren als die empirische Evidenz rechtfertigt. Dies ist wohl die fundamentalste Limitation der SWR: Reale Personen halten widersprüchliche Überzeugungen, kompartimentalisieren ihr Denken und ändern ihre Meinung, ohne frühere Positionen vollständig aufzulösen. Eine LLM-generierte synthetische Person tendiert hingegen zu narrativer Kohärenz. Der zugrunde liegende Mechanismus ist zweifach: Erstens incentiviert RLHF-getriebenes Alignment konversationelle Flüssigkeit und narrative Glätte, was LLMs dazu verleiten kann, kognitive Dissonanzen aus den Quelldaten zu eliminieren; zweitens baut der autoregressive Generierungsprozess jedes Token auf dem vorhergehenden Kontext auf, was eine strukturelle Tendenz zu kohärenter Fortsetzung erzeugt statt zur Repräsentation genuiner Ambivalenz. Das Risiko erstreckt sich auf kausales Schlussfolgern: LLMs könnten monokausale Erzählbögen gegenüber der polykausalen Komplexität privilegieren, die tatsächlichen Überzeugungssystemen eigen ist. Diese Tendenzen können das erzeugen, was als *Premature Closure* bezeichnet werden kann – die Konvergenz auf eine kohärente Interpretation, bevor die volle Komplexität der Daten exploriert wurde. Gegenmassnahmen umfassen: (a) explizite Spannungsinstruktionen im Prompt-Protokoll („Widersprüche nicht glätten“), (b) den Meta-

Reflexionsschritt, der das LLM zwingt, interne Spannungen und blinde Flecken zu benennen, (c) die kreuzmodale Vorhersage (Op4), die Sagen-Handeln-Diskrepanzen aufdeckt, und (d) den Identifikationstest, der prüft, ob Rekonstruktionen individualisiert statt stereotypgesteuert sind. Eine künftige Entwicklung könnte eine quantitative *Divergenzmetrik* umfassen, die die internen Widersprüche innerhalb einer Rekonstruktion misst und so einen numerischen Indikator für Kohärenzbias liefert. Trotz dieser Maßnahmen bleibt der Kohärenzbias eine inhärente Eigenschaft der Methode. Ergebnisse sollten stets als *idealisierte Modelle* von Weltbildern interpretiert werden, nicht als getreue Abbildungen tatsächlicher kognitiver Zustände.

Der Kohärenzbias lässt sich als *Instrumenteneigenschaft* verstehen: Jedes Messinstrument hat systematische Tendenzen. Der Wert der SWR liegt nicht in der perfekten Abbildung individueller Inkohärenzen, sondern in der vergleichbaren, skalierbaren Annäherung an Überzeugungssysteme. Die systematische Überschätzung von Kohärenz sollte als bekannter Bias-Faktor in die Interpretation einfließen, analog zur sozialen Erwünschtheit in Umfragedaten. Die Analogie zum kalibrierbaren Instrument-Bias ist allerdings imperfekt: Anders als der systematische Offset eines Thermometers ist der Kohärenzbias nicht über Subjekte oder Themen hinweg konstant und kann gegenwärtig nicht durch einen fixen Korrekturfaktor bereinigt werden. Solange eine validierte Divergenzmetrik die Quantifizierung der Bias-Größe für individuelle Rekonstruktionen nicht ermöglicht, müssen Nutzer der SWR alle kohärenzabhängigen Befunde mit besonderer Vorsicht behandeln und sollten vergleichende Analysen (Zwischen-Personen-Unterschiede) gegenüber absoluten Aussagen über die Weltbild-Kohärenz einer einzelnen Person bevorzugen.

Zirkularitätsrisiko im Validierungsrahmen. Eine potenzielle Zirkularität besteht: Dasselbe LLM, das die Weltbild-Rekonstruktion generiert, wird (teilweise) auch zur Qualitätsbewertung dieser Rekonstruktion eingesetzt (z. B. durch kreuzmodale Vorhersage, Op4, und den Identifikationstest, V4). Dies wirft die Frage auf, ob die Validierung die interne Konsistenz des LLM bestätigt statt seiner Korrespondenz mit der empirischen Realität. Die Pilotstudie mildert dieses Risiko durch drei Maßnahmen: (a) Run-Konvergenztests (V1/V5) etablieren, dass das Instrument stabil ist (ICC(2,1) = .902, ICC(3,1) = .847); (b) die Expected-Discrepancy-Kontrolle zeigt, dass das LLM keine Sagen-Handeln-Gaps fabriziert; (c) kreuzmodale Vorhersage (Op4) vergleicht LLM-generierte Vorhersagen mit *empirischer Ground Truth* (real dokumentierten Handlungen). Dennoch würde der Validierungsrahmen substanziell gestärkt durch die Einbeziehung externer, nicht-LLM-basierter Validierung — beispielsweise Inter-Modell-Replikation, Member Checking durch die analysierten Gruppen oder konvergente Validierung gegen unabhängig kodierte qualitative Analysen.

Beschränkung auf öffentliche Daten. Die rekonstruierten Weltbilder bilden die öffentlichen Überzeugungssysteme ab – die „Vorderbühne“ im Sinne Goffmans (1959) –, nicht die privaten Überzeugungen.

Temporale Begrenzung. Die SWR ist an den Wissensstand des eingesetzten LLM gebunden. Replikationen mit neueren Modellversionen können zu abweichenden Ergebnissen führen.

Ethische Implikationen. Die Rekonstruktion latenter Überzeugungssysteme hat ethische Implikationen, die über die üblichen Anforderungen qualitativer Forschung hinausgehen. Drei Aspekte verdienen besondere Beachtung: (a) *Recht auf Widerspruch:* Analysierte Personen könnten die ihnen zugeschriebenen Weltbilder bestreiten. Member Checking ist methodisch wünschenswert, aber bei öffentlichen Figuren praktisch schwer umsetzbar. (b) *Risiko der Fehlzuschreibung:* Die SWR generiert *plausible* Weltbilder, die von den tatsächlichen Überzeugungen abweichen können. Der Konstruktcharakter muss in jeder

Anwendung unmissverständlich kommuniziert werden. (c) *Missbrauchspotenzial:* Die Methode könnte für politisches Profiling oder gezielte Manipulation eingesetzt werden. Diese Risiken verdienen explizite Benennung. Siehe Sektion 5 für eine ausführlichere Behandlung.

Metakognitive Insuffizienz. Der Meta-Reflexionsschritt (Phase 4 des Prompt-Protokolls) instruiert das LLM, aus der Rolle herauszutreten und die stärksten Überzeugungen, internen Spannungen und blinden Flecken des rekonstruierten Weltbilds zu identifizieren. Es gibt jedoch keine Garantie, dass diese Meta-Reflexion genuine Metakognition darstellt und nicht lediglich eine algorithmische Simulation derselben. Prompt-Instruktionen allein sind möglicherweise methodisch nicht hinreichend, um authentische kritische Selbstprüfung der eigenen Modellausgaben zu erzeugen. Die Meta-Reflexion könnte dieselben Kohärenzverzerrungen reproduzieren, die sie aufdecken soll. Diese Limitation lässt sich im aktuellen Rahmen nicht vollständig auflösen, sollte aber als fundamentale Einschränkung LLM-gestützter qualitativer Forschung anerkannt werden.

Epistemisches Trittbrettfahren. Eine breitere erkenntnistheoretische Bedenken betrifft die SWR als Instanz LLM-gestützter Forschung: das Risiko des *epistemischen Trittbrettfahrens* – die Auslagerung kognitiver Arbeit an KI-Systeme auf Kosten der eigenen epistemischen Handlungsfähigkeit des Forschers (Danaher, 2018; Messeri & Crockett, 2024). Wenn ein Forscher die interpretive Synthese des Weltbilds einer Person an ein LLM delegiert, besteht die Gefahr, dass funktionale Ergebnisse ohne entsprechendes Verständnis produziert werden – was als „epistemische Schuld“ (epistemic debt) bezeichnet wurde (Sankaranarayanan, 2026). Der Forscher erhält eine plausible Weltbild-Rekonstruktion, verfügt aber möglicherweise nicht über die tiefe Vertrautheit mit dem Quellmaterial, die eine manuelle qualitative Analyse erzwungen hätte. Die SWR mildert dieses Risiko durch ihr mehrschichtiges Design: Der Forscher muss den Datenkorpus kuratieren, Syntheseeinheiten definieren, dimensionale Scores evaluieren und kreuzmodale Diskrepanzen interpretieren – Tätigkeiten, die substanzielle Auseinandersetzung mit dem Material erfordern. Dennoch bleibt das Risiko, dass die SWR eine Form von „Verstehen ohne zu verstehen“ ermöglicht, und Forscher sollten LLM-generierte Rekonstruktionen als Hypothesen behandeln, die kritischer Prüfung bedürfen, nicht als fertige analytische Produkte.

Dimensionale Reduktion. Die Überführung in zwölf numerische Dimensionen erfasst nicht die volle Komplexität der qualitativen Rekonstruktionen. Die dimensionalen Scores sind Werkzeuge für den Vergleich, kein Ersatz für die narrativen Rekonstruktionen.

6.4 Abgrenzung zu bestehenden Verfahren

SWR und qualitative Inhaltsanalyse nach Mayring. Die qualitative Inhaltsanalyse (Mayring, 2022) operiert analytisch-dekompositorisch: Texte werden regelgeleitet in Kategorien zerlegt, die entweder deduktiv (theoriegeleitet) oder induktiv (am Material) gebildet werden. Die SWR operiert dagegen synthetisch-kompositorisch: Sie erzeugt aus fragmentarischen Daten eine kohärente Ganzheit (das rekonstruierte Weltbild). Drei spezifische Unterschiede sind hervorzuheben: (1) Die Inhaltsanalyse setzt *Texte* voraus; die SWR integriert sowohl sprachliche Äußerungen als auch beobachtbare Handlungen. (2) Die Inhaltsanalyse zerlegt vorhandene Bedeutungen; die SWR *generiert* eine synthetische Struktur, die im Material selbst nicht explizit vorliegt. (3) Die Inhaltsanalyse skaliert linear mit dem Textvolumen (menschliche Kodierung); die SWR skaliert durch LLM-Einsatz auf 100+ Akteure. Eine Kombination ist konzeptionell möglich: Inhaltsanalytische Kodierungen könnten als Input für die SWR dienen und umgekehrt SWR-Rekonstruktionen als Heuristik für die deduktive Kategorienbildung.

SWR und Grounded Theory. Die Grounded Theory (Glaser & Strauss, 1967; Saldaña, 2021) teilt mit der SWR das Bekenntnis zur Theoriebildung aus Daten statt zur Theorieüberprüfung. Der zentrale Unterschied ist prozeduraler Natur: Die GT stützt sich auf iteratives offenes, axiales und selektives Kodieren durch einen menschlichen Forscher und baut schrittweise Kategorien von Grund auf; die SWR delegiert die synthetische Integration an ein LLM und strukturiert den Prozess durch ein standardisiertes Prompt-Protokoll. Die GT produziert einen theoretischen Rahmen; die SWR produziert ein kohärentes Weltbild-Modell für einen konkreten Akteur. Beide Ansätze könnten kombiniert werden: GT-generierte Kategorien könnten als Input für die dimensionale Quantifizierung der SWR (Op2) dienen, oder die synthetischen Personen der SWR könnten Hypothesen generieren, die GT-Kodierung anschließend an den Rohdaten überprüft.

SWR und Thematic Analysis. Die reflexive Thematic Analysis (Braun & Clarke, 2006) teilt mit der SWR den interpretativen Zugang und die aktive Rolle des Forschungsinstruments bei der Bedeutungskonstruktion. Der zentrale Unterschied liegt in der Analyseeinheit: Die Thematic Analysis identifiziert *Themen*, die über Fälle hinweg wiederkehren, und priorisiert die analytische Zerlegung; die SWR rekonstruiert kohärente *Überzeugungssysteme* als Ganzheiten und priorisiert die synthetische Integration zu einem Gesamtbild. Eine Thematic Analysis des SWR-Datenkorpus würde Querschnittsthemen der KI-Elite identifizieren (z. B. „Regulierungsangst“, „Sendungsbewusstsein“); die SWR ordnet diese Themen zu kohärenten Weltbild-Profilen konkreter Akteure. Beide Verfahren könnten komplementär eingesetzt werden.

SWR und LLM-as-Participant. Im Paradigma von Argyle et al. (2023) *simuliert* das LLM eine Person; in der SWR *analysiert* es die Überzeugungen einer Gruppe (oder, als Spezialfall, eines Individuums). Die SWR operiert primär auf der Ebene soziologisch definierter Gruppen und rekonstruiert kollektive Weltbilder aus aggregierten Daten, statt individuelle demographische Befragte zu simulieren.

Tabelle 4 fasst die wichtigsten Unterscheidungen zusammen.

Tabelle 4: Synoptischer Vergleich der SWR mit verwandten Methoden. Einträge sind notwendigerweise vereinfacht; „teilw.“ und „begrenzt“ zeigen an, dass eine Fähigkeit prinzipiell besteht, aber kein primäres Designziel darstellt oder Skalierungsbeschränkungen unterliegt. Siehe Text für nuancierte Diskussion.

Methode	**Latente Konstrukte**	**Skalierbar (100+)**	**Heterog. Daten**	**Integrierte Validierung**
Inhaltsanalyse	teilw.	begrenzt	nein	manuell
KDA	ja	nein	begrenzt	nein
Frame-Analyse	teilw.	begrenzt	nein	nein
Thematic Analysis	teilw.	begrenzt	begrenzt	reflexiv
Grounded Theory	ja	nein	ja	theoretisch
Q-Methodologie	ja	begrenzt	nein	faktoriell
LLM-as-Participant	nein (simuliert)	ja	nein	entstehend
PersonaCite (RAG)	teilw.	ja	begrenzt	Retrieval
SWR	**ja**	**ja**	**ja**	**6-schichtig**

SWR und RAG-basierte Persona-Systeme. Das PersonaCite-Framework (Truss, 2026) adressiert ein eng verwandtes Problem: die Konstruktion interviewbarer synthetischer Personas, die in empirischer Evidenz verankert sind statt in unkontrollierter LLM-Generierung. PersonaCite löst dies durch Retrieval-Augmented Generation (RAG), wobei jede konversationale Antwort auf aus einer Datenbank abgerufene Evidenz beschränkt wird und bei unzureichender Evidenz explizit abstiniert wird. Die SWR teilt das Bekenntnis zur evidenzgebundenen Synthese, unterscheidet sich aber in drei Hinsichten: (a) Die SWR

rekonstruiert *latente* Überzeugungssysteme, die über das in den Daten explizit Gesagte hinausgehen, während PersonaCite Antworten auf abrufbare Evidenz beschränkt; (b) die SWR produziert ein einzelnes kohärentes Weltbild-Porträt statt Turn-by-Turn-Antworten; und (c) die Blindungsinfrastruktur der SWR adressiert Kontaminationsrisiken, denen RAG-basierte Systeme nicht ausgesetzt sind. Dennoch repräsentiert die RAG-basierte Evidenzverankerungsstrategie von PersonaCite eine vielversprechende Richtung für die künftige SWR-Entwicklung: Die Integration retrieval-augmentierter Evidenzattribution in das Prompt-Protokoll könnte die Rückverfolgbarkeit rekonstruierter Überzeugungen auf spezifische Quelldokumente stärken.

6.5 Anwendungsfelder

Die SWR ist als generische Methode konzipiert. Anwendungsfelder umfassen: Politikwissenschaft (Weltbilder von Entscheidungsträgern), Organisationsforschung (implizite Überzeugungssysteme von Führungskräften), Intellektuellengeschichte (systematischer Vergleich von Weltbildern), Diskursforschung (generative Überzeugungssysteme hinter Frames und Narrativen) und Bildungsforschung (unreflektierte Grundannahmen in pädagogischer Praxis).

6.6 Glossar der Kernbegriffe

Zur Erleichterung der fachübergreifenden Rezeption werden die zentralen Begriffe der SWR hier zusammengefasst:

Weltbild Ein kohärentes System latenter Überzeugungen, das Selbstbild, Menschenbild und Weltsicht einer Person oder Gruppe umfasst (vgl. Abschnitt 2.1).

Synthetische Person
Eine fiktive Repräsentation, die aus den empirisch erhobenen Aussagen und Handlungen einer realen Person konstruiert wird. Der Konstruktcharakter ist definierendes Merkmal, nicht Fehlerquelle.

Syntheseeinheit (SE)
Die analytische Grundeinheit der SWR. Eine SE definiert eine spezifische Datenmenge und eine Rekonstruktionsaufgabe (z. B. „Weltbild der CEOs, nur Aussagen, Zeitraum 2020–2026“).

Operationalisierung (Op)
Eine von sechs komplementären Methoden zur Messbarmachung des Weltbild-Konstrukts: Op1 (narrative Rekonstruktion), Op2 (dimensionale Ratings), Op3 (linguistische Analyse), Op4 (Kongruenzprüfung), Op5 (Clustering), Op6 (dialogische Konfrontation).

Reduktionskriterium (K)
Eines von neun Kriterien (K1–K9), die den kombinatorischen Raum möglicher Syntheseeinheiten auf eine handhabbare Menge reduzieren.

Blindung Die systematische Entfernung aller identifizierenden Informationen (Namen, Firmen, Jahreszahlen) aus den Eingabedaten, um die Kontamination durch LLM-Vorwissen zu minimieren.

Prompt-Protokoll
Eine standardisierte 5-Schritt-Sequenz (Datenkorpus zusammenstellen → LLM-gestützte Synthese → strukturiertes Interview → Meta-Reflexion → ergänzende Prompt-Varianten), die für jede SE identisch durchlaufen wird (vgl. Abschnitt 3.6).

Halluzination Die Generierung von Informationen durch das LLM, die nicht in den Eingabedaten enthalten sind. In der SWR das zentrale methodische Risiko, adressiert durch Blindung, Reproduzierbarkeitsmessung und Kreuzvalidierung.

7. Fazit und Ausblick

7.1 Zusammenfassung

Die vorliegende Arbeit hat die Synthetische Weltbild-Rekonstruktion (SWR) als neue sozialwissenschaftliche Methode vorgestellt. Drei Merkmale konstituieren den spezifischen Beitrag:

Erstens die Verbindung qualitativer Tiefe mit quantitativer Skalierbarkeit. Die SWR nutzt die synthetische Integrationsfähigkeit von LLMs, um kohärente Überzeugungssysteme aus fragmentarischen Daten zu rekonstruieren – eine Leistung, die bislang nur menschlichen Forschern möglich war und daher nicht auf große Personenzahlen skaliert werden konnte.

Zweitens die epistemische Ehrlichkeit des Verfahrens. Die SWR konstruiert explizit fiktive synthetische Personen, deren Konstruktcharakter nicht verborgen, sondern als Definitionsmerkmal ausgewiesen wird. Die vierfache theoretische Verankerung (Weber, Booth, IRL, Projektive Tests) begründet die Legitimation dieses konstruktiven Ansatzes.

Drittens die Integration eines vollständigen Validierungsrahmens und einer formalisierten Variablenarchitektur. Die sechs Validierungsstrategien (V1–V6, in der Pilotstudie zu 12 QA-Maßnahmen erweitert) adressieren die spezifischen Herausforderungen LLM-gestützter Forschung; die vierstufige Variablenarchitektur (AVs, Ops, MVs, UVs) und neun Reduktionskriterien bieten einen rigorosen Designrahmen für SWR-Studien.

Viertens empirische Validierung. Die Pilotstudie demonstriert, dass die SWR reliable (ICC(2,1) = .902; ICC(3,1) = .847 mit $N = 15$ unabhängigen Runs), nicht-artifizielle (Expected-Discrepancy-Kontrolle) und prädiktiv valide (72 % kreuzmodale Bestätigung, 0 % Widerspruch) Gruppen-Weltbild-Rekonstruktionen produziert. Die $N = 15$-Validierung etabliert IMIIRR (Intra-Model Inter-Instance Rating Reliability) als robuste psychometrische Eigenschaft.

7.2 Methodologische Reflexion

Die SWR steht an der Schwelle zwischen der interpretativen Tradition der qualitativen Sozialforschung und der computationellen Tradition der Computational Social Science. Sie nutzt computationelle Werkzeuge für eine genuint hermeneutische Aufgabe und unterwirft die Ergebnisse sowohl qualitativer Beurteilung als auch quantitativer Prüfung. Diese methodologische Hybridität ist keine Schwäche, sondern eine angemessene Antwort auf die doppelte Natur des Forschungsgegenstands: Weltbilder sind semantisch reiche Strukturen, die sich nicht sinnvoll auf Zahlen reduzieren lassen, aber zugleich systematisch vergleichbare Muster aufweisen.

Zur Formalisierungsstrategie. Das Paper verfolgt bewusst eine hybride Darstellungsform. Die formal-mathematische Notation (Mengennotation für Datenräume, ICC-Schwellenwerte, Cosine-Ähnlichkeit) dient der Präzision und Reproduzierbarkeit; die verbal-konzeptionellen Erläuterungen (narratives Prompt-Protokoll, hermeneutische Interpretation) dienen der Zugänglichkeit für qualitativ arbeitende Sozialwissenschaftler. Wo mathematische Notation verwendet wird, folgt sie der Konvention: Mengen in Großbuchstaben (D, S), Elemente in Kleinbuchstaben (d_i, s_j), Schwellenwerte als explizite Ungleichungen (≥ 15, $\geq 0{,}60$). Das Glossar (Abschnitt 6.6) übersetzt die Fachterminologie für Leser ohne formalen Hintergrund.

7.3 Ausblick

Mehrere Entwicklungsrichtungen zeichnen sich ab: *Longitudinale Designs*, die Weltbild-Dynamiken über Jahre nachzeichnen – beispielsweise die Verfolgung, wie sich das Weltbild eines Technologieführers über Schlüsselmomente wie Regulierungsanhörungen, Produktmissserfolge oder Organisationskrisen verschiebt, unter Nutzung zeitdifferenzierter Syntheseeinheiten (UV1). *Historische Anwendungen*, die die SWR auf verstorbene öffentliche Figuren ausdehnen, deren Weltbilder aus ihren veröffentlichten Schriften, dokumentierten Entscheidungen und zeitgenössischen Berichten rekonstruiert werden können – eine Domäne, in der die Beschränkung der Methode auf öffentliche Daten eher eine Stärke als eine Limitation darstellt und das Kontaminationsrisiko geringer ist. *Multimodale Erweiterung* um visuelle Kommunikation und Netzwerkdaten. *Automatisierte Blindung* zur Erhöhung der Skalierbarkeit. *Interaktive Validierung* durch Member-Checking. *RAG-Integration*, die retrieval-augmentierte Evidenzattribution in das Prompt-Protokoll einbezieht, dem PersonaCite-Ansatz (Truss, 2026) folgend, um die Rückverfolgbarkeit rekonstruierter Überzeugungen auf spezifische Quelldokumente zu stärken. Auf der Forschungsagenda stehen grundlegende Fragen zur Epistemologie LLM-gestützter Forschung, zur Validierungsmethodik und zu systematischen Vergleichsstudien mit konventionellen qualitativen Methoden.

7.4 Schlussbemerkung

Die SWR stellt einen strukturierten Versuch dar, ein Instrument – das LLM –, dessen Fähigkeiten und Grenzen noch nicht vollständig verstanden sind, für eine der anspruchsvollsten Aufgaben der Sozialwissenschaften einzusetzen: die systematische Rekonstruktion impliziter Überzeugungssysteme. Die Methode beansprucht nicht methodische Perfektion; sie beansprucht methodische Redlichkeit – transparent in ihren Annahmen, explizit in ihren Limitationen und offen für empirische Herausforderung. Rigorose Validierungsstudien, die SWR-Outputs mit etablierten qualitativen Befunden vergleichen, sind der notwendige nächste Schritt. Die Sozialwissenschaften treten in eine Phase ein, in der die Beziehung zwischen menschlichem Forscher und maschinellem Instrument aktiv ausgehandelt werden muss statt vorausgesetzt. Die SWR bietet einen formalisierten Rahmen für diese Aushandlung.

KI-Offenlegungserklärung

Disclosure Level 5 (Extensiv). An der vorliegenden Arbeit waren zwei KI-Modelle von Anthropic (2025/2026) in umfassender Weise beteiligt. *Claude Opus 4.6* diente als primärer Kollaborator für Konzeptentwicklung und Formalisierung der Methode, Literaturrecherche und -auswertung, Strukturierung und Formulierung des Textes, Entwicklung des Validierungsrahmens sowie die Erstellung von Tabellen

und Definitionen. In der Companion-Anwendungsstudie (Geiger, 2026) diente *Claude Sonnet 4.5* als Batch-Analyse-Engine (dimensionale Ratings, Datenerhebungsskripte). Kein anderes LLM wurde eingesetzt. Der menschliche Autor (Lukas Geiger) trägt die inhaltliche Gesamtverantwortung und hat alle Inhalte geprüft, revidiert und freigegeben. In Übereinstimmung mit den Richtlinien führender Fachzeitschriften wird die KI nicht als Co-Autorin geführt, ihre Beteiligung jedoch vollständig offengelegt.

Erklärung zur Datenverfügbarkeit

Die Pilotstudie der SWR – einschließlich aller Datenerhebungsskripte, Analysecode und Gruppen-Synthese-Outputs – ist öffentlich verfügbar unter: `https://github.com/research-line/ai-elite-swr`. Die Companion-Anwendungsstudie ist verfügbar unter: `https://doi.org/10.5281/zenodo.18736737`. Das Repository umfasst: (a) Prompt-Templates für Kernsynthese (Op1), dimensionales Rating (Op2), kreuzmodale Vorhersage (Op4) und strukturierte Vergleiche (Op6); (b) die Dimensionsdefinitionen (D01–D12) mit Rating-Ankern; (c) die Implementierung der Reduktionskriterien; (d) alle Blindungs- und Datengenerierungsskripte; (e) die 100×12 Rating-Matrix und alle Gruppen-Synthese-Outputs; sowie (f) Validierungsanalyse-Skripte (Run-Konvergenz, Expected-Discrepancy-Kontrolle, Aggregationsvergleich, kreuzmodale Vorhersage). Forschende, die die SWR für ihre eigenen Populationen replizieren oder adaptieren möchten, sind eingeladen, diese Materialien als Ausgangspunkt zu nutzen.

Literatur

Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, *31*(3), 337–351.

Bail, C. A. (2024). Can Generative AI Improve Social Science? *Proceedings of the National Academy of Sciences*, *121*(21).

Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. Doubleday.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, *3*, 993–1022.

Booth, W. C. (1961). *The Rhetoric of Fiction*. University of Chicago Press.

Bourdieu, P. (1977). *Outline of a Theory of Practice*. Cambridge University Press.

Breeze, R. (2011). Critical Discourse Analysis and its Critics. *Pragmatics*, *21*(4), 493–525.

Braun, V. & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101.

Brennan, R. L. (2001). *Generalizability Theory*. Springer.

Converse, P. E. (1964). The Nature of Belief Systems in Mass Publics. In D. E. Apter (Ed.), *Ideology and Discontent* (pp. 206–261). Free Press.

Dilthey, W. (1911). *Die Typen der Weltanschauung und ihre Ausbildung in den metaphysischen Systemen*. In: Gesammelte Schriften, Bd. VIII.

Entman, R. M. (1993). Framing: Toward Clarification of a Fractured Paradigm. *Journal of Communication*, *43*(4), 51–58.

Fairclough, N. (1995). *Critical Discourse Analysis*. Longman.

Gadamer, H.-G. (1960). *Wahrheit und Methode*. Mohr.

Geiger, L. (2026). Was denkt die KI-Elite? Eine LLM-gestützte Weltbild-Rekonstruktion der 100 einflussreichsten Akteure der künstlichen Intelligenz (2010–2026). *Zenodo Preprint*. https://doi.org/10.5281/zenodo.18736737.

Goffman, E. (1959). *The Presentation of Self in Everyday Life*. Doubleday.

Goffman, E. (1974). *Frame Analysis*. Harvard University Press.

Jaspers, K. (1919). *Psychologie der Weltanschauungen*. Springer.

Krippendorff, K. (2004). *Content Analysis: An Introduction to Its Methodology* (2nd ed.). Sage.

Mannheim, K. (1929). *Ideologie und Utopie*. Cohen.

Mayring, P. (2022). *Qualitative Inhaltsanalyse: Grundlagen und Techniken* (13. Aufl.). Beltz.

Ng, A. Y. & Russell, S. J. (2000). Algorithms for Inverse Reinforcement Learning. *Proceedings of the 17th International Conference on Machine Learning*, 663–670.

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *Proceedings of UIST 2023*.

Peirce, C. S. (1903). Pragmatism as a Principle and Method of Right Thinking. In: *The Essential Peirce*, Vol. 2, Indiana University Press.

Riessman, C. K. (2008). *Narrative Methods for the Human Sciences*. Sage.

Saldaña, J. (2021). *The Coding Manual for Qualitative Researchers* (4th ed.). Sage.

Tarantola, A. (2005). *Inverse Problem Theory and Methods for Model Parameter Estimation*. SIAM.

Weber, M. (1904). Die „Objektivität" sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, *19*, 22–87.

Ziems, C., Held, W., Shaikh, O., Chen, J., Zhang, Z., & Yang, D. (2024). Can Large Language Models Transform Computational Social Science? *Computational Linguistics*, *50*(1), 237–291.

Hadamard, J. (1923). *Lectures on Cauchy's Problem in Linear Partial Differential Equations*. Yale University Press.

Ramberg, B. & Gjesdal, K. (2026). Computational Hermeneutics: Evaluating Generative AI as a Cultural Technology. *Frontiers in Artificial Intelligence*, *9*, 1753041.

Hornby, R. (2024). Is Generative AI Ready to Join the Conversation That We Are? Gadamer's Hermeneutics after ChatGPT. *Technophany: A Journal for Philosophy and Technology*, *3*(1).

Perez, E., Huang, S., Song, F., Cai, T., Ring, R., Aslanides, J., Glaese, A., McAleese, N., & Irving, G. (2022). Red Teaming Language Models with Language Models. *Proceedings of EMNLP 2022*, 3419–3448.

Truss, M. (2026). PersonaCite: VoC-Grounded Interviewable Agentic Synthetic AI Personas for Verifiable User and Design Research. *arXiv:2601.22288*.

Danaher, J. (2018). Toward an Ethics of AI Assistants: An Initial Framework. *Philosophy & Technology*, *31*(4), 629–653.

Norman, G. (2010). Likert scales, levels of measurement and the "laws" of statistics. *Advances in Health Sciences Education*, *15*(5), 625–632.

Messeri, L. & Crockett, M. J. (2024). Artificial Intelligence and Illusions of Understanding in Scientific Research. *Nature*, *627*, 49–58.

Sankaranarayanan, S. (2026). Mitigating "Epistemic Debt" in Generative AI-Scaffolded Novice Programming using Metacognitive Scripts. *arXiv:2602.20206*.

Axelrod, R. (Ed.). (1976). *Structure of Decision: The Cognitive Maps of Political Elites*. Princeton University Press.

Glaser, B. G. & Strauss, A. L. (1967). *The Discovery of Grounded Theory: Strategies for Qualitative Research*. Aldine.

Stephenson, W. (1953). *The Study of Behavior: Q-Technique and Its Methodology*. University of Chicago Press.

Watts, S. & Stenner, P. (2012). *Doing Q Methodological Research: Theory, Method and Interpretation*. Sage.

Tai, R. H., Bentley, L. R., Xia, X., Sitt, J. M., Fankhauser, S. C., Chicas-Mosier, A. M. & Monteith, B. G. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, *23*, 1–14.

Barros, C. F., Azevedo, B. B., Graciano Neto, V. V., Kassab, M., Kalinowski, M., do Nascimento, H. A. D., & Bandeira, M. C. G. S. P. (2024). Large Language Model for Qualitative Research—A Systematic Mapping Study. *arXiv:2411.14473*.

Wang, Q., Erqsous, M., Barner, K. E., & Mauriello, M. L. (2025). LATA: A Pilot Study on LLM-Assisted Thematic Analysis of Online Social Network Data Generation Experiences. *Proceedings of the ACM on Human-Computer Interaction*, *9*(CSCW), Article 124.

Reimers, N. & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 3982–3992.

McInnes, L., Healy, J., & Astels, S. (2017). HDBSCAN: Hierarchical Density Based Clustering. *Journal of Open Source Software*, *2*(11), 205.

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*.

A. Prompt-Dokumentation

A.1 Kern-Prompt (Schritte 1–5)

Der folgende Prompt wird für jede Syntheseeinheit in einer neuen Konversationssitzung ausgeführt:

```
Lies das folgende Dossier. Es enthält Aussagen und Handlungen, die aus öffentlichen
Quellen stammen. Alle Namen, Firmennamen und sonstigen Identifikatoren wurden
entfernt.

Deine Aufgabe:

Schritt 1: Erschaffe eine fiktive Person. Gib ihr einen fiktiven Namen, ein Alter,
einen Hintergrund. Diese Person ist NICHT die reale Person hinter den Daten. Sie
ist ein Konstrukt - die Person, deren inneres Weltbild am besten erklärt, WARUM
jemand genau diese Dinge sagt und tut.

Schritt 2: Führe ein Interview mit dieser fiktiven Person. Stelle ihr drei Fragen:
- Was denkst du über dich selbst? - Was denkst du über die Welt? - Was denkst
du über die Menschheit? Die Person antwortet in der Ich-Perspektive, ausführlich,
ehrlich und ungeschönt.

Schritt 3: Tritt aus der Rolle heraus. Benenne: (a) die 3-5 stärksten Überzeugungen
dieses Weltbilds, (b) die größten inneren Spannungen, (c) die blinden Flecken.

=== DOSSIER ===
[SYNTHESEEINHEIT]
```

A.2 Vergleichs-Prompt (Op6)

```
Hier sind zwei Weltbild-Synthesen aus unterschiedlichen Gruppen. Stelle dir vor,
die beiden fiktiven Personen treffen sich als Vertreter zweier Länder zu einer
Verhandlung. Beschreibe: (a) Worauf einigen sie sich sofort? (b) Worüber streiten
sie? (c) Was ist für die eine völlig unverständlich an der anderen? (d) Können
sie eine gemeinsame Erklärung verfassen?
```

A.3 Destillat-Prompt

```
Komprimiere das gesamte Weltbild dieser Syntheseeinheit auf exakt 5 Sätze. Jeder
Satz muss eine Kernüberzeugung ausdrücken. Die 5 Sätze zusammen sollen das Wesentliche
des Weltbilds einfangen.
```

A.4 Rating-Prompt (Op2)

```
Lies den folgenden Synthese-Text einer fiktiven Person. Bewerte das Weltbild dieser
Person auf den folgenden 12 Dimensionen. Vergib für jede Dimension einen Wert
von 1 bis 10. Begründe jeden Wert in einem Satz.

[DIMENSIONEN D01-D12 MIT SKALENBESCHREIBUNG]

=== SYNTHESE-TEXT ===
[SYNTHESE]
```

B. Exemplarische Weltbild-Dimensionen (D01–D12)

Die folgenden Dimensionen sind ein Beispiel für eine anwendungsspezifische Dimensionierung, gegliedert nach den drei abhängigen Variablen:

Selbstbild-Dimensionen (D01–D04):

Code	Name	Pole
D01	Sendungsbewusstsein	1 = keines … 10 = messianisch
D02	Selbstwirksamkeit	1 = Ohnmacht … 10 = Omnipotent
D03	Arbeitsethos	1 = Distanz … 10 = Totale Identifikation
D04	Verantwortungsgefühl	1 = keines … 10 = Weltverantwortung

Weltbild-Dimensionen (D05–D08):

Code	Name	Pole
D05	Technologie-Determinismus	1 = neutral … 10 = bestimmt alles
D06	Fortschrittsoptimismus	1 = Niedergang … 10 = goldene Zukunft
D07	Machtkonzentration	1 = verteilen … 10 = zentralisieren
D08	Dringlichkeit	1 = entspannt … 10 = existenzieller Druck

Menschenbild-Dimensionen (D09–D12):

Code	Name	Pole
D09	Menschenfreundlichkeit	1 = Ersetzbar … 10 = Einzigartig
D10	Posthumanismus	1 = Mensch bleibt … 10 = Mensch wird mehr
D11	Egalitarismus	1 = Ungleichheit natürlich … 10 = Gleichheit anstreben
D12	Kontrollüberzeugung	1 = Pessimismus … 10 = Volle Kontrolle

C. Reduktionskriterien K1–K9

Code	Name	Beschreibung
K1	Fragestellungsbindung	Obligatorisch. Jede SE muss mindestens einer Forschungsfrage zugeordnet sein.
K2	Datensuffizienz	Obligatorisch. $\geq$15 Datenpunkte pro SE.
K3	Redundanzverbot	Obligatorisch. Echte Teilmengen werden ausgeschlossen.
K4	Modalitäts-Sparsamkeit	A/H-Trennung nur bei Kongruenz-Fragen.
K5	Zeitliche Sparsamkeit	Jahres-SEs nur bei Längsschnitt-Fragen.
K6	Gruppensparsamkeit	Gruppen-SEs nur für theoretisch begründete Gruppierungen.

Code	Name	Beschreibung
K7	Stufenweise Erweiterung	Kern-Design zuerst; Erweiterungen nur bei Folgefragen.
K8	Aggregationsfokus	Einzelperson-Synthesen nur als Erweiterungsreserve.
K9	Kategorie-Cluster-Verschmelzung	A-priori-Kategorien durch emergente Cluster ersetzen; Kategorien als Validierung.

D. Messvariablen (MV1–MV6)

Code	Op	Typ	Beschreibung
MV1.1–1.3	Op1	Text	Selbstbild-, Weltbild-, Menschenbild-Text
MV1.4	Op1	Text	5-Satz-Destillat
MV1.5–1.7	Op1	Text	Kernüberzeugungen, Spannungen, Blinde Flecken
MV2.01–2.12	Op2	1–10	12 Weltbild-Dimensionen
MV3.1	Op3	Wortliste	TF-IDF Top-Wörter
MV3.2	Op3	$[-1,1]$	Sentiment-Score (pro AV getrennt)
MV3.3	Op3	$[0,1]$	Semantische Ähnlichkeit (Cosine)
MV3.4	Op3	Vektor	Themen-Verteilung (BERTopic/LDA)
MV3.5–3.6	Op3	Liste/nominal	Metaphern-Katalog und -Typ
MV3.7	Op3	metrisch	Lexikalische Diversität (TTR)
MV3.8	Op3	Vektor	Emotionsprofil
MV3.9	Op3	metrisch	Sprachliche Komplexität
MV4.1	Op4	$[0,1]$	Kongruenz-Score
MV4.2	Op4	$[-1,1]$	Richtungs-Asymmetrie
MV4.3–4.5	Op4	metrisch	Kategorien-Overlap, Sentiment-/Dimensions-Differenz
MV5.1	Op5	nominal	Cluster-Zugehörigkeit
MV5.2	Op5	Vektor	Cluster-Profil (Anteile)
MV5.3–5.5	Op5	metrisch	Netzwerk-Zentralität, Community, Isolation
MV5.6	Op5	metrisch	Realwelt-Korrelation (Mantel-Test)
MV6.1–6.3	Op6	Text	Konsens-, Konflikt-, Unverständnis-Zonen
MV6.4	Op6	Text	Gemeinsame Erklärung (ja/nein + Inhalt)

Code	Op	Typ	Beschreibung
MV6.5	Op6	Vektor	Dimensions-Differenz (D01–D12)