

Synthetic Worldview Reconstruction:

A Method for LLM-Assisted Group-Level Belief System Analysis

Lukas Geiger*

Independent Researcher, Bernau, Germany

June 2026

Abstract

This paper presents *Synthetic Worldview Reconstruction* (SWR) – a method for reconstructing the collective belief systems of sociologically defined groups using large language models. SWR formulates worldview analysis as an inverse problem: given the aggregated public statements and documented actions of a group, reconstruct the latent belief system that most coherently generates these outputs. The method constructs a *fictive synthetic person* – a Weberian ideal type – whose worldview represents the group’s collective beliefs in distilled form. This paper abstracts SWR from its original application (a study of 100 influential AI actors; Geiger, 2026) into a transferable methodological framework. We describe the five-step protocol, the dimensional rating procedure as one operationalization example, and the focus control infrastructure. Quality assurance is documented through empirical results from the pilot study: Intra-Model Inter-Instance Rating Reliability (IMI-IRR) reaches $ICC(2,1) = 0.902$ (5×2 runs) and $ICC(3,1) = 0.847$ ($N = 15$ independent single-instance runs); cross-modal prediction achieves 72% confirmation with 0% contradiction; and a blinding robustness test shows $r = 0.987$ across anonymization strategies. Tiered acceptance criteria distinguish between minimum requirements (Tier 1) and desirable extensions (Tier 2). A step-by-step application guide enables researchers to apply SWR to their own populations. The method is designed for group-level analysis, where ready-made collective worldviews of sociological groups are less likely to exist in the training corpus than public knowledge about prominent individuals, thereby reducing a contamination risk that is typically more acute in individual-level applications.

Keywords: synthetic worldview reconstruction, LLM-assisted methodology, collective belief systems, ideal type, group-level analysis, computational social science, inter-instance reliability

*Corresponding author: Lukas Geiger, Bernau, Germany. ORCID: <https://orcid.org/0009-0005-7296-1534>

1. Introduction

1.1 The Problem: Reconstructing Collective Worldviews

Social scientists frequently need to understand what groups believe – not as the sum of individual opinions, but as coherent collective patterns. Political elites, corporate leadership teams, religious communities, military cadres, and scientific disciplines all develop shared *belief systems* that shape their collective behavior. A belief system, as used here, encompasses three domains from near to far: self-image (how the group sees itself), view of humanity (how it sees others), and worldview in the narrow sense (how it sees the world). Throughout this paper, “worldview” is used as shorthand for this integrated three-domain construct. Yet reconstructing these belief systems at scale poses a methodological dilemma: qualitative methods achieve the necessary depth but do not scale; survey instruments scale but require direct access to respondents and capture only what participants are willing and able to articulate; quantitative text-mining approaches capture surface patterns but miss the coherence structure of worldviews.

This paper presents *Synthetic Worldview Reconstruction* (SWR), a method that exploits the capacity of large language models (LLMs) to synthesize heterogeneous textual evidence into coherent representations. SWR does not use LLMs to *generate* opinions or *simulate* what a group might think. Rather, it uses them as *analytical compression instruments*: given the documented statements and actions of a group’s members, the LLM constructs a coherent collective portrait – a Weberian ideal type (Weber, 1904) – that represents the group’s belief system in distilled form.

The method was developed and validated in a pilot study that reconstructed the collective worldviews of sociologically defined groups within the 100 most influential AI actors (2010–2026), based on 3,132 data points (Geiger, 2026). The present paper abstracts the method from that specific application into a transferable framework that other researchers can apply to their own populations.

1.2 Methodological Gap

Recent years have seen rapid growth in LLM-assisted social science research. Ziems et al. (2024) provide a comprehensive roadmap for using LLMs as computational social science tools. Bail (2024) examines the promise and risks of generative AI for social science more broadly. Tai et al. (2024) demonstrate that LLMs can perform deductive coding of qualitative data with reliability comparable to human coders. Wang et al. (2025) extend this to LLM-assisted thematic analysis, showing that LLMs can support iterative theme development. Barros et al. (2024) provide a systematic mapping of LLM applications in qualitative research, confirming that most existing work targets coding and classification rather than holistic belief system reconstruction. Ornstein et al. (2025) show that few-shot LLM prompts outperform conventional supervised learning for political text scaling, establishing LLMs as viable instruments for multidimensional text analysis – the category to which SWR belongs.

However, existing LLM-assisted approaches serve different purposes than SWR. Argyle et al. (2023) use LLMs to *simulate* human samples – “silicon samples” conditioned on demographic backstories to approximate survey responses. Ge et al. (2024) scale synthetic personas for *data generation*. In both cases, the LLM generates data *de novo*. SWR, by contrast, uses the LLM to *compress* existing real-world data into a coherent representation. The synthetic person is not a simulacrum but an analytical condensation instrument – closer to a Weberian ideal type than to a simulation agent.

A closely related tradition is Critical Discourse Analysis (CDA; Fairclough, 1992; Wodak & Meyer,

2001), which applies qualitative analytical grids to texts to uncover power structures and ideology. CDA achieves rich interpretive depth but faces well-known scalability constraints: it typically operates on small corpora (5–20 texts) with limited inter-rater reliability. LLMs already address these constraints for *analysis* of individual texts; what has been missing is a method for *synthesis* at the group level – enabling CDA and analogous analytical methods to be applied not to individual texts, but to group-aggregated synthetic representations. SWR provides this missing synthesis layer.

What has been missing is a systematic method for reconstructing the *coherent belief system* of a sociologically defined group from heterogeneous public data – one that combines qualitative depth (narrative richness, tension detection, internal logic) with quantitative rigor (dimensional rating, reliability testing, cross-modal validation). SWR addresses this gap.

1.3 Contribution

This paper makes three contributions:

1. **Method formalization:** It describes SWR as a transferable five-step protocol with explicit quality criteria, distinguishing it from related approaches (LLM-as-participant, synthetic data generation, automated coding, critical discourse analysis). The formalization separates two independent contributions: (a) the synthesis pipeline (Steps 1–4) as a structured method for group-level belief system reconstruction from heterogeneous data, and (b) dimensional rating (Step 5) as one specific, exchangeable operationalization applied in the pilot study.
2. **Quality framework:** It presents empirical quality metrics from the pilot study – IMIIRR, cross-modal prediction, expected-discrepancy control, blinding robustness – and defines tiered acceptance criteria for future applications.
3. **Application guide:** It provides a step-by-step guide enabling researchers to apply SWR to their own populations, including practical recommendations for data collection, prompt design, validation, and common pitfalls.

2. The Method

2.1 Worldview Reconstruction as an Inverse Problem

SWR formulates worldview analysis as an inverse problem in the sense of [Hadamard \(1923\)](#) and [Taran-tola \(2005\)](#). The *forward problem* is straightforward: a belief system W generates observable outputs (statements, decisions, actions):

$$W \longrightarrow \{A_1, A_2, \dots, A_n, H_1, H_2, \dots, H_m\} \quad (1)$$

where A_i are public statements and H_j are documented actions. The *inverse problem* runs in the opposite direction: given the observable outputs of a sociologically defined group G , reconstruct the latent belief system W_G^* that most coherently generates these outputs:

$$\{A_1, \dots, A_n, H_1, \dots, H_m\} \longrightarrow W_G^* \quad (2)$$

This inverse problem is *ill-posed* in Hadamard’s sense: the solution is neither unique (multiple belief

systems could generate the same observable outputs) nor stable (small changes in the data can produce different reconstructions). SWR addresses ill-posedness through three mechanisms: (1) the coherence constraint imposed by the LLM’s synthesis, which serves as a regularizer analogous to Tikhonov regularization in classical inverse theory; (2) the ideal-type construction, which explicitly seeks the *most coherent* interpretation rather than the only possible one; and (3) multi-run reliability testing, which quantifies the stability of the solution.

2.2 The Fictive Synthetic Person as a Group Distillate

The central analytical construct in SWR is the *fictive synthetic person* – a fictional individual whose worldview represents the collective beliefs of a sociologically defined group in purified form. This construct is a Weberian ideal type (Weber, 1904): an analytical abstraction created by the researcher, not an emergent pattern discovered in the data. Just as Weber’s “Protestant ethic” was not a description of any individual Protestant’s beliefs but an ideal-typical condensation of a collective pattern, the fictive synthetic person condenses the heterogeneous data of a group into a single coherent portrait.

The fiction approach serves five methodological functions:

1. **Contamination reduction:** Training corpora are less likely to contain ready-made objects such as “the collective worldview of CEOs” or “the shared belief system of risk warners” than public background knowledge about individual high-profile actors. The collective worldview is therefore *constructed* through synthesis rather than simply retrieved from memory. This reduces a primary methodological concern for LLM-based reconstruction.¹
2. **Separation of worldview and biography:** The fiction strips away individual biographical noise, PR strategies, and situational context, isolating the shared belief patterns.
3. **Natural aggregation:** Rather than averaging numerical ratings across individuals, the LLM performs a qualitative synthesis – integrating contradictions, weighting by salience, and producing a coherent narrative.
4. **Comparability:** Fictive synthetic persons of different groups can be systematically compared along the same dimensions, enabling structured inter-group analysis.
5. **Tension visibility:** Internal contradictions within a group’s belief system become visible as tensions *within* the fictive person rather than being averaged away.

2.3 The Five-Step Protocol

SWR proceeds through five operative steps. Steps 2–4 (synthesis, interview, meta-reflection) are conducted within a single LLM session to preserve conversational context. Step 5 (dimensional rating) may use a separate session. For each *synthesis unit*, a new session is started to prevent cross-contamination between groups. Instance separation (Section 2.6) applies to *reliability runs*: when the same SU is processed multiple times for IMIIRR estimation, each run must use a completely independent agent.

2.3.1 Step 1: Compile Group-Level Data Corpus

For each sociologically defined group (e.g., “all CEOs,” “all risk warners”), the statements and actions of all group members are pooled into a single dossier, ordered chronologically. No intermediate individual-

¹This advantage is specific to group-level analysis. For individual-level analysis of public figures, the LLM may draw on extensive stored knowledge, making the contamination risk substantially higher.

level aggregation occurs: the collective portrait emerges directly from the pooled evidence, analogous to how a historian reconstructs an era's *Zeitgeist* from primary sources rather than from averaged biographies.

Data types. SWR operates on two data types: **public statements** (verbatim quotes from interviews, keynotes, podcasts, social media posts, blog entries, books, congressional hearings) and **observable actions** (investment decisions, company formations, personnel decisions, political activities, product launches). In the pilot study, the total corpus comprised 1,738 statements and 1,394 actions (3,132 data points) for 100 actors (Geiger, 2026).

Minimum data density. Based on qualitative saturation research (Guest et al., 2006; Fugard & Potts, 2015), a minimum of 15 data points per synthesis unit is recommended. In the pilot study, data points per actor ranged from 20 to 72 (mean: 31.3, SD $\approx$ 12).

2.3.2 Step 2: LLM-Assisted Synthesis of a Fictive Synthetic Person

The pooled data corpus is presented to the LLM with the instruction to construct a fictive synthetic person whose worldview best explains the totality of the presented data. The prompt design follows focus control principles (Section 2.7): no group labels, no expected outcomes, no dimensional categories are mentioned at this stage. The LLM produces a narrative portrait – self-image, worldview, view of humanity – that synthesizes the heterogeneous data into a coherent whole.

2.3.3 Step 3: Structured Interview

The fictive synthetic person is subjected to a structured three-part interview: (1) self-image (“Who are you? What drives you?”), (2) worldview (“How does the world work? What is the role of technology/power/progress?”), and (3) view of humanity (“What is the nature of human beings? Can they be improved?”). These three domains constitute the dependent variables (DV1–DV3) of the SWR framework – a progression from near (self) through other (humanity) to far (world), reflecting the psychological distance structure described by Construal Level Theory (Trope & Liberman, 2010). Together they form the belief system under investigation; “worldview” in the narrow sense refers to DV2, but is used throughout this paper as shorthand for the integrated three-domain construct. The qualitative interview generates the material; the quantitative measurement occurs in Step 5 through dimensional rating (D01–D12, four dimensions per DV).

2.3.4 Step 4: Meta-Reflection

A separate prompt instructs the LLM to identify internal tensions, blind spots – including what Bourdieu (1977) terms *doxa*: beliefs held as self-evident and therefore invisible to the group itself – and contradictions within the synthesized worldview. This step counteracts the LLM’s coherence bias (Section 6.1) by explicitly requesting the detection of inconsistencies.

2.3.5 Step 5: Dimensional Rating

The synthesized worldview is rated on a set of researcher-defined dimensions using a numerical scale (e.g., 1–10). The dimensions operationalize the three dependent variables into measurable constructs. In the pilot study, 12 dimensions (D01–D12) were used, evenly distributed across the three DVs (Table 1).

The dimensional system is modular: researchers can define dimensions appropriate to their population and research questions.

The five-step protocol is designed as a *modular architecture*: Steps 1–4 constitute the synthesis pipeline and represent the core methodological innovation of SWR, producing the fictive synthetic person as the primary analytical object. Step 5 (dimensional rating) is one specific operationalization chosen for the pilot study and is in principle replaceable by other analytical procedures applied to the same synthesis product – including discourse analysis, psychometric instruments, structured interview protocols, or comparative narrative analysis. The synthesis pipeline (Steps 1–4) can therefore serve as a general input stage for a wide range of analytical approaches.

2.4 Dimensional Rating: The 12-Dimension Example

The pilot study employed 12 worldview dimensions on a 1–10 scale. This dimensional system is presented here as a worked example; other applications will require domain-specific dimensions.

Table 1: The 12 worldview dimensions used in the pilot study, grouped by dependent variable.

DV	Dim.	Name	Pole 1 (=1)	Pole 10 (=10)
DV1: Self-image	D01	Sense of mission	No mission	Messianic
	D02	Self-efficacy	Powerless	Omnipotent
	D03	Work ethic	Distance	Total identification
	D04	Responsibility	None	World responsibility
DV2: Worldview	D05	Techno-determinism	Neutral	Determines everything
	D06	Belief in progress	Decline	Golden future
	D07	Power concentration	Radically distribute	With experts
	D08	Urgency	Relaxed	Existential pressure
DV3: View of humanity	D09	Human appreciation	Replaceable	Unique
	D10	Posthumanism	Human stays	Human becomes more
	D11	Egalitarianism	Inequality natural	Strive for equality
	D12	Locus of control	Pessimism	Full control

Scale treatment. Following [Norman \(2010\)](#), who demonstrates that parametric statistics are robust to violations of interval-level assumptions for rating scales, the ordinal ratings are treated as quasi-interval for purposes of reliability computation (ICC) and descriptive statistics (mean, SD). Non-parametric methods (Spearman, Kruskal-Wallis) are used for inferential analysis.

2.5 Synthesis Units and Systematic Reduction

A *synthesis unit* (SU) is the atomic unit of SWR analysis: a specific group-level data corpus that is processed through the five-step protocol. Each SU is defined by the intersection of independent variables – e.g., “all CEOs, statements and actions, entire period.” The theoretical combination space can be large; in the pilot study, approximately 1,227 possible SUs were reduced to 51–56 core SUs (95.4% reduction) through nine reduction criteria:

1. **Research question binding:** Each SU must be linked to at least one research question.
2. **Minimum size:** ≥ 15 data points per SU.
3. **No redundancy:** Proper subsets are eliminated.
4. **Modality parsimony:** Statement/action separation only when comparing say vs. do.

5. **Temporal parsimony:** Annual SUs only for longitudinal analysis.
6. **Group parsimony:** Only a-priori-justified groups.
7. **Stepwise expansion:** Core SUs first, extensions later.
8. **Group-level focus:** No individual-person SUs.
9. **Cluster merging:** Bottom-up replaces a-priori when data suggest it.

2.6 Instance Separation

A non-negotiable principle of SWR is *instance separation*: each LLM interaction that contributes to a measurement must occur in a separate agent instance with no shared context. Concretely:

- Each reliability run (Section 3.1) is a separate agent instance.
- Cross-modal prediction (Section 3.2): the prediction agent and the evaluation agent share no context.
- Say-do comparison: the statement-based synthesis and the action-based synthesis are generated by independent agents.

Runs with shared context are not independent measurements. In the pilot study, the violation of this principle in an early say-do comparison was detected and corrected: the gap shrank from $MAE = 1.42$ (shared instance, v1) to $MAE = 0.75$ (instance-separated, v2) – a 47% reduction once cross-contamination was eliminated (Geiger, 2026).

2.7 Focus Control

Focus control ensures that the LLM synthesizes from the presented data rather than reproducing stereotypes or retrieving stored knowledge. It operates on two levels:

1. **Anonymization:** All identifying information (person names, company names, product names, university affiliations) is replaced with neutral placeholders (e.g., [PERSON], [COMPANY]). An empirical test in the pilot study confirmed that placeholder tokens and fictional names produce nearly identical results ($r = 0.987$, $MAE = 0.33$; Geiger, 2026).
2. **Task focus:** Prompt design directs the LLM toward synthesizing a coherent worldview from the presented data. No group labels (“AI elite,” “Silicon Valley”), no expected outcomes, and no dimensional categories are mentioned in the synthesis prompt (Steps 1–4). Dimensions are introduced only in the rating step (Step 5).

Focus control is not a claim that the LLM cannot recognize individuals – especially for famous public figures, this is neither achievable nor necessary at the group level. The goal is *task compliance*: ensure the model synthesizes from the provided data, not from stereotypes. The group-level framing described above (cf. Section 1) supports this goal.

3. Quality Assurance

This section presents the quality assurance framework developed and empirically tested in the pilot study (Geiger, 2026). All reported numbers are empirical results from that study.

3.1 Intra-Model Inter-Instance Rating Reliability (IMIIRR)

IMIIRR quantifies the consistency of the LLM-as-instrument across independent instances. It is the SWR analogue of inter-rater reliability in qualitative coding – with the crucial difference that every “rater” receives identical instructions (the prompt), eliminating the implicit variation that plagues human coding teams.

Validation 1: 5×2 run convergence. Five group-level synthesis units were each processed twice independently by Claude Opus 4.6. The resulting D01–D12 profiles showed: overall Pearson $r=0.908$, ICC(2,1)=0.902, MAE=0.40 on the 10-point scale (measurement precision ± 0.2 scale points). All 12 dimensions were stable across runs (mean $|\Delta| \leq 0.8$).

Validation 2: $N = 15$ independent single-instance runs. Fifteen fully independent Opus instances – each a separate agent with no shared context – processed a single group-level synthesis unit (GA_ges_AH). Results: ICC(3,1)=0.847, mean SD=0.45 across all 12 dimensions (range: 0.00–0.74). One dimension (D02, self-efficacy) showed perfect agreement: all 15 instances assigned exactly the same rating. Ten of 12 dimensions had only 2 unique values across 15 runs.

These IMIIRR coefficients exceed typical human inter-rater reliability in qualitative coding (ICC = 0.6–0.8; Hallgren, 2012), establishing that the LLM produces *consistent* ratings across independent instances. A critical distinction must be maintained: IMIIRR establishes *reliability* (consistency of measurement), not *validity* (accuracy of measurement). A highly reliable instrument can be systematically biased. The cross-modal prediction (Section 3.2) provides partial validity evidence by testing LLM-generated predictions against documented empirical actions. However, an external validation – independent domain experts rating the same groups on the same dimensions – remains outstanding (cf. Section 6.7). Until such validation is conducted, IMIIRR should be interpreted as demonstrating that the instrument is *stable enough to produce meaningful comparisons*, not that its absolute values are accurate.

3.2 Cross-Modal Prediction

Cross-modal prediction is the strongest non-circular validation mechanism available to SWR. The logic: if a reconstructed worldview has functional predictive consistency, then predictions derived from one data modality (statements) should be confirmed by another modality (actions). Crucially, the prediction agent (Op4a) and the evaluation agent (Op4b) are separate instances: the evaluator does not know that the predictions were generated by another instance of the same model, ensuring blind comparison.

Protocol. For five sociological groups, a first agent instance generated 10 behavioral predictions exclusively from the statement corpus (Op4a). A *separate* agent instance – which had never seen the original statements – evaluated these predictions against the actual documented actions (Op4b).

Results. Of 50 predictions, 36 (72%) were directly confirmed by real actions, 13 (26%) were plausible but lacked a direct match, and 0 (0%) were contradicted. Confirmation rates varied by group coherence: ideologically coherent groups (academics, risk warners) reached 90% confirmation; heterogeneous groups (investors, accelerators) reached 50% confirmation with an additional 40–50% plausible.

3.3 Expected-Discrepancy Control

When comparing statement-based and action-based worldview profiles (say-do analysis), a baseline is needed to distinguish genuine discrepancies from measurement noise. The pilot study constructed a

synthetic control corpus: a fictional group of environmental scientists with 30 statements and 30 actions containing no deliberate say-do gap. Under strict instance separation (v2 protocol), the control group gap was $MAE = 0.92$. The real AI elite say-do gap under matching conditions was $MAE = 0.75$ – *below* the control baseline, indicating that the aggregate gap is not reliably distinguishable from measurement noise. However, group-level decomposition revealed substantial group-specific gaps: CEOs ($MAE = 1.08$) and risk warners ($MAE = 1.92$) both exceeded the baseline with stable directional patterns.

3.4 Additional Validation Results

Table 2 summarizes the complete validation battery from the pilot study.

Table 2: Quality assurance battery: measures, results, and status from the pilot study.

Measure	Design	Result	Status
IMIIRR (5×2)	5 groups, 2 runs each	$ICC(2,1) = 0.902$, $MAE = 0.40$	Completed
IMIIRR ($N = 15$)	15 independent single-instance runs	$ICC(3,1) = 0.847$, mean $SD = 0.45$	Completed
Cross-modal prediction	5 groups $\times$ 10 predictions	72% confirmed, 0% contradicted	Completed
Expected-discrepancy	Fictional control group (v2)	Baseline $MAE = 0.92$	Completed
Blinding robustness	Placeholders vs. fictional names	$r = 0.987$, $MAE = 0.33$	Completed
Full identity test	Real names vs. placeholders	$r = 0.850$, $MAE = 0.67$	Completed
Rating order invariance	2 permutations of D01–D12	12/12 identical	Completed
Outlier detection	5 groups, fit assessment	80–88% fit per group	Completed
Inversion control	Anti-coherence test, 5 groups	58% of dims $ \Delta \geq 5$	Completed
Anthropic matched-sample	Creator-org bias test ($n = 9$ vs. 9)	$MAE = 1.00$, no systematic bias	Completed
Aggregation-synthesis	Direct vs. averaged profiles	$r = 0.623$, amplification effect	Completed
Structural validation	PCA + HDBSCAN on 100×12 matrix	5 components (80% var.); 80–100% noise	Completed
Inter-model comparison	Independent runs with different model	Future work	Open

3.5 Tiered Acceptance Criteria

Based on the pilot study results, we propose a two-tiered acceptance framework for SWR applications:

Tier 1 (Required for any SWR study):

- Within-model IMIIRR: $ICC > 0.75$ (from ≥ 5 independent single-instance runs).
- Prompt sensitivity: $< 15\%$ variation in ratings across semantically equivalent prompt variants.
- At least one external anchor: cross-modal prediction, expert validation, or survey comparison.
- Instance separation for all measurements contributing to inferential claims.

Tier 2 (Desirable for methodological contribution):

- Inter-model $ICC > 0.70$ (replication with at least one additional frontier model).
- Discriminability test: the method reliably distinguishes between groups expected to differ.
- Expected-discrepancy control: a baseline for distinguishing genuine effects from noise.
- $N \geq 15$ independent runs for formal power analysis.

The pilot study meets all Tier 1 and most Tier 2 criteria. The inter-model comparison (Tier 2) remains outstanding and constitutes a priority for future replication – analogous to replicating a survey with different interviewer teams.

4. Application Guide

This section provides a step-by-step guide for researchers who wish to apply SWR to their own populations. The guide assumes familiarity with qualitative research methodology and basic LLM interaction.

Table 3 condenses the guide into an auditable implementation ledger. Its purpose is not to add a new statistical test, but to make explicit which artifact must exist before a reader can evaluate an SWR application as reproducible, minimally validated, and protected against the most common LLM-specific failure modes.

Table 3: Minimum implementation ledger for a reproducible SWR application.

Workflow object	Required artifact	Minimum gate	Controlled risk
Population and corpus	Inclusion/exclusion rules plus source, date, and context metadata for each data point	Intersubjectively verifiable group criteria; ≥ 15 data points per SU	Ad hoc sampling; unverifiable provenance
Synthesis-unit map	Group $\times$ modality $\times$ period matrix with reduction rationale	Each retained SU is linked to a research question; no unmotivated subset duplication	Hidden researcher degrees of freedom
Prompt and instance log	Prompt text, model version, temperature, run date, and fresh-instance record	No shared context for reliability, prediction, or say-do measurements	Context leakage; inflated reliability
Rating sheet	Dimension definitions, numerical ratings, and data-based justifications	Clearly defined poles; justification for every rating	Opaque scoring; post-hoc interpretation
Validation packet	IMIIRR, prompt-sensitivity check, and at least one external anchor	Tier 1 acceptance before inferential claims	Over-reading a single LLM run

4.1 Step 1: Define Population and Collect Data

Define your groups. SWR operates on sociologically defined groups – not ad hoc clusters. Groups should be defined by observable, intersubjectively verifiable criteria (institutional role, organizational membership, demographic category, ideological stance). Example: “All CEOs of Fortune 500 tech companies” is a well-defined group; “people who secretly believe in transhumanism” is not.

Collect heterogeneous data. For each group member, collect both statements (interviews, speeches, publications, social media) and actions (decisions, investments, organizational behavior). The duality of statement and action data is methodologically important: it enables say-do comparison (Section 3.3) and cross-modal prediction (Section 3.2).

Ensure minimum data density. Aim for ≥ 15 data points per synthesis unit. In the pilot study, 20–72 data points per actor (mean: 31.3) provided sufficient density for stable group-level syntheses.

Document provenance. Each data point should carry metadata: source, date, context. A relational database is recommended for managing large corpora. The pilot study used a SQLite database with 9 tables and 5 views.

4.2 Step 2: Form Synthesis Units

Map the combination space. List all meaningful group $\times$ modality $\times$ time period combinations. Apply the nine reduction criteria (Section 2.5) to reduce this space to a manageable set of core SUs.

Prioritize. Start with the most inclusive SU (all members, all data, entire period) to establish a baseline profile. Then add group-specific SUs for comparison.

Pool data directly. For each SU, concatenate the raw data of all group members into a single chronological dossier. Do not aggregate individual profiles first – the group synthesis should emerge from the pooled evidence.

4.3 Step 3: Execute the Prompt Protocol

Apply focus control. Before feeding data to the LLM, replace all identifying information with neutral placeholders. Prepare a blinding script that operates on your specific data format.

Maintain instance separation. Each step that contributes to a distinct measurement must use a fresh LLM instance with no shared context. This is especially critical for:

- Reliability runs: each replicate is a separate instance.
- Cross-modal prediction: predictor and evaluator share no context.
- Say-do comparison: statement-based and action-based syntheses are generated independently.

Set temperature to 0. This maximizes reproducibility. Even at temperature 0, LLM outputs are not fully deterministic; multi-run reliability testing quantifies the residual variation.

Execute the five steps. For each SU, run the protocol in sequence: data compilation → synthesis → structured interview → meta-reflection → dimensional rating. Document all prompts and model parameters.

4.4 Step 4: Define Dimensions and Rate

Design your dimensional system. The 12 dimensions from the pilot study (Table 1) are specific to the AI elite application. For your population, define dimensions that capture the worldview constructs relevant to your research questions. Each dimension should have clearly labeled poles (what does 1 mean? what does 10 mean?) and should be independent of other dimensions to the extent possible.

Rate each SU. Present the synthesized worldview (from Steps 2–4) to a fresh LLM instance along with the dimension definitions. Request a numerical rating for each dimension with justification. The justification serves two purposes: it enables the researcher to verify that the rating reflects the data, and it documents the reasoning for replication.

Conduct reliability runs. For at least one SU, repeat the entire pipeline (Steps 1–5) with ≥ 5 independent instances. Compute ICC as the IMIIRR metric. If $ICC < 0.75$, revise your dimensional definitions (ambiguous poles are the most common cause of low reliability).

4.5 Step 5: Validate

Minimum validation (Tier 1): Conduct IMIIRR testing, sensitivity analysis (vary prompt wording), and at least one external anchor. The cross-modal prediction protocol is recommended as the strongest available anchor: derive behavioral predictions from statement data, then evaluate against actual documented actions.

Extended validation (Tier 2): If resources permit, conduct expected-discrepancy control (synthetic control corpus), inter-model replication, and formal power analysis ($N \geq 15$ independent runs).

4.6 Practical Considerations

Cost and time. In the pilot study (100 actors, 3,132 data points, 51–56 core SUs, 11 completed validation experiments plus one identified desideratum), the total LLM cost (Claude Opus 4.6 and Claude Sonnet 4.5 via API) was approximately \$200–300 USD. A smaller study (2–5 groups, 200–500 data points) would cost \$20–50 USD. Data collection is the primary time investment; the SWR pipeline itself runs in hours.

Common pitfalls.

- *Shared context:* Forgetting instance separation inflates reliability estimates and can create spurious effects (the pilot study documented a 47% inflation in say-do gap magnitude).
- *Leading prompts:* Including group labels (“progressive activists,” “conservative voters”) in synthesis prompts invites stereotype reproduction. Use neutral descriptions.
- *Dimensional ambiguity:* Poorly defined scale poles are the primary cause of low IMIRR. Pilot-test your dimensions with 3–5 runs before committing to the full protocol.
- *Individual-level temptation:* SWR is designed for group-level analysis. Applying it to individuals reintroduces the contamination risk that the group-level approach structurally avoids.
- *Over-interpretation of single runs:* The pilot study showed that single-run estimates deviate from the $N = 15$ mean by $MAE = 0.73$. Report multi-run averages, not single-run results, for any claim that depends on precise numerical values.

Transfer sketch: SWR applied to climate scientists. A researcher studying the collective worldviews of climate scientists (e.g., IPCC authors vs. industry-funded researchers) would proceed as follows: (1) collect public statements (congressional testimonies, op-eds, interviews) and actions (policy recommendations, funding decisions, institutional affiliations) for both groups; (2) define synthesis units (“IPCC authors, all data” vs. “industry-funded, all data”); (3) develop domain-specific dimensions – e.g., *urgency of action* (1 = no rush to 10 = existential emergency), *trust in models* (1 = skeptical to 10 = full confidence), *role of technology* (1 = behavior change to 10 = geoengineering); (4) run the five-step protocol with instance separation; (5) compare the two group profiles on the dimensional system. The expected output: two contrasting worldview portraits whose dimensional differences reveal where the groups genuinely disagree vs. where they share common ground.

5. Positioning: SWR in the Methodological Landscape

SWR occupies a distinct position at the intersection of qualitative and quantitative traditions (Table 4).

SWR vs. Thematic Analysis (Braun & Clarke, 2006). Both extract patterns from qualitative data, but thematic analysis identifies themes across a corpus while SWR reconstructs a coherent belief system. The key difference is the coherence constraint: thematic analysis can report contradictory themes side by side; SWR forces them into a single worldview portrait, making tensions visible as internal contradictions rather than separate categories.

SWR vs. LLM-as-Participant (Argyle et al., 2023). LLM-as-Participant generates synthetic data by conditioning the LLM on demographic backstories. SWR compresses real data through LLM-assisted synthesis. The inputs and outputs are fundamentally different: LLM-as-Participant produces survey responses; SWR produces worldview profiles. The contamination structure also differs: LLM-as-Participant draws on training data about demographic groups (by design); SWR structurally avoids this

Table 4: SWR compared with related methodological approaches.

Feature	SWR	Thematic Analysis	Survey	LLM-as-Participant	Automated Coding	CDA
Data source	Public statements + actions	Interviews, texts	Direct responses	LLM-generated Simulated individual	Existing texts	Existing texts
Unit of analysis	Group	Variable	Individual		Document	Variable
Requires respondent access	No	Yes	Yes	No	No	No
Captures coherence	Yes	Partially	No	Limited	No	Partially
Scalable	Yes	Limited	Yes	Yes	Yes	Limited
External validation	Cross-modal	Member checking	Test–retest	Demographic fit	Expert coding	Analyst triangulation
Primary risk	Coherence bias	Researcher bias	Response bias	Stereotype reproduction	Context loss	Small N, subjectivity

at the group level.

SWR vs. Automated Coding (Tai et al., 2024). Automated coding classifies text segments into predefined categories. SWR goes further by integrating these segments into a coherent whole. Automated coding answers “what topics are present?”; SWR answers “what does this group believe?”

SWR vs. Critical Discourse Analysis (CDA; Fairclough, 1992; Wodak & Meyer, 2001). CDA applies qualitative analytical grids to texts to uncover power structures, ideological formations, and hegemonic discourse patterns. Both CDA and SWR aim to reveal latent belief structures; their relationship is complementary rather than competitive. CDA analyzes individual texts or small corpora on power and ideology; SWR first synthesizes a group-aggregated representation, enabling CDA-style analysis to be applied at the group level rather than the text level. The synthesis pipeline (Steps 1–4) can thus function as a preprocessing stage that makes group-level discourse analysis tractable.

Theoretical roots. SWR draws on Weber (1904) (ideal type as analytical construct), Mannheim (1929) (situational determination of thought), Gadamer (1960) (the hermeneutic circle of understanding), and the sociology-of-knowledge tradition that treats worldviews as social phenomena amenable to empirical investigation (Berger & Luckmann, 1966). The emerging field of computational hermeneutics (Kommers et al., 2026) provides a conceptual bridge between these interpretive traditions and LLM-assisted analysis, while Hornby (2025) examines how Gadamerian hermeneutics can inform the epistemology of LLM-mediated understanding. The inverse-problem formalization connects to Tarantola (2005) and Hadamard (1923). The use of LLMs as analytical instruments aligns with the emerging “LLMs for social science” paradigm (Ziems et al., 2024; Bail, 2024), while the epistemological caution draws on Messeri & Crockett (2024), who warn of “illusions of understanding” when AI tools are deployed without sufficient methodological reflection.

6. Limitations

6.1 Coherence Bias as Instrument Property

LLMs are optimized for logical coherence; humans are inherently inconsistent. For worldview reconstruction, this property is both an operational asset and a source of systematic distortion (Geiger, 2026).

The asset: coherence enables SWR to extract a stable, interpretable group-level profile from heterogeneous data – the method *exploits* coherence as a compression mechanism, analogous to how factor analysis exploits covariance structure. The distortion: the resulting worldview types may appear more sharply contoured than they are in reality. Internal tensions that real persons experience – e.g., between power striving and sense of responsibility – risk being resolved by the LLM in favor of a consistent profile.

The genuine limitation is therefore *over-coherence*: clusters sharper than empirical reality. The underlying mechanism is twofold: first, RLHF-driven alignment incentivizes conversational fluency and narrative smoothness, which may lead LLMs to eliminate cognitive dissonances present in the source data; second, the autoregressive generation process builds each token on preceding context, creating a structural tendency toward coherent continuation rather than the representation of genuine ambivalence. These tendencies can produce what might be termed *premature closure* – convergence on a coherent interpretation before the full complexity of the data has been explored.

Four control mechanisms partially address this risk:

1. The meta-reflection step (Step 4) explicitly instructs the LLM to identify tensions. However, there is no guarantee that this meta-reflection constitutes genuine metacognition rather than an algorithmic simulation thereof – the meta-reflection may reproduce the same coherence biases it is designed to detect.
2. Outlier detection in the pilot study showed 80–88% group-level fit, not 100%, indicating that the model registers and preserves within-group heterogeneity.
3. The inversion control (constructing anti-persons whose worldview maximally contradicts the data) confirmed that 58% of dimension-group combinations showed $|\Delta| \geq 5$, demonstrating that the coherent interpretation is a specific, data-supported choice – not the only possible reading.
4. The aggregation-synthesis comparison showed a systematic amplification effect: group syntheses produce sharper contours than averaged individual profiles (71.7% of dimension-group combinations further from midpoint), analogous to group polarization in social psychology.

Despite these measures, coherence bias remains an inherent property of the method. Results should be interpreted as *idealized models* of worldviews – comparable, scalable approximations – not as faithful representations of actual cognitive states. Comparative analyses (between-group differences) are generally more robust than absolute claims about any single group’s internal coherence.

6.2 Contamination and Focus Control Limits

Despite consistent focus control, it cannot be excluded that the LLM draws on training knowledge – particularly for well-known public figures. Two empirical results constrain this concern: (1) the blinding robustness test showed that the choice of anonymization strategy (placeholders vs. fictional names) has no material effect ($r=0.987$, $MAE=0.33$); (2) full identity disclosure (real names) produced only a moderate shift ($r=0.850$, $MAE=0.67$, with the same group average). The group-level design remains an important safeguard (cf. Abstract).

6.3 Circularity Risk

The SWR pipeline uses the same model family (Claude Opus 4.6) for both synthesis and validation. This raises the question whether validation confirms empirical accuracy or merely the model’s internal

consistency. However, the concern must be scoped precisely: all validation steps use *separate instances* with no shared context. The evaluation agent in Op4b does not know that its input was generated by another instance of the same model – it operates as an independent assessor. This is analogous to two human raters trained with the same codebook: they share a framework but operate independently.

Three design features constrain the circularity concern: (1) IMIIRR establishes that the instrument is stable across independent instances – a necessary precondition for any validation; (2) the expected-discrepancy control demonstrates that the LLM does not fabricate say-do gaps where none exist in the data; (3) cross-modal prediction (Op4) compares LLM-generated predictions against *documented empirical actions*, providing a non-circular anchor. A residual concern applies specifically to the rating step (Op2): the dimensional correlations reported in the pilot study could partly reflect the LLM’s internal coherence patterns rather than empirical relationships. This concern is shared by any rating procedure including human raters – a human coder who rates posthumanism high will, by cognitive coherence, also tend to rate locus of control high. External replication by other research groups using different models would strengthen the validity claim but constitutes independent replication, not a prerequisite for any single study’s internal coherence.

6.4 Blackbox Character

The LLM’s synthesis process is not interpretable at the mechanistic level. The researcher receives an output but cannot trace which specific data points drove which aspects of the synthesis. The dimensional justifications requested in Step 5 provide partial transparency, but the integration logic remains opaque. This is a genuine limitation shared with any LLM-based analysis and mitigated (not eliminated) by multi-run reliability testing: if the instrument produces consistent outputs across independent instances, the black-box process is at least *stable*, even if not fully transparent.

6.5 Epistemic Risks of LLM Delegation

A broader epistemological concern applies to SWR as an instance of LLM-assisted research: the risk of *epistemic freeloading* – outsourcing cognitive labor to AI systems at the expense of the researcher’s own epistemic agency. When a researcher delegates the interpretive synthesis of a group’s worldview to an LLM, there is a danger that functional output is produced without corresponding understanding. SWR mitigates this risk through its multi-layered design: the researcher must curate the data corpus, define synthesis units, evaluate dimensional scores, and interpret cross-modal discrepancies – activities that require substantive engagement with the material. Nevertheless, researchers should treat LLM-generated reconstructions as hypotheses requiring critical scrutiny rather than as finished analytical products.

6.6 Temporal and Cultural Boundaries

SWR reconstructs worldviews from a specific data window. The pilot study covered 2010–2026; the reconstructed worldviews are valid for this period, not beyond. Furthermore, LLMs carry cultural biases from their training data (predominantly English-language, Western, educated sources; cf. [Santurkar et al., 2023](#)). For non-Western populations, this bias may distort the synthesis. Researchers working with non-Western groups should consider this limitation and explore model-specific calibration.

6.7 Open Desiderata

Three empirical extensions remain outstanding: (1) **Inter-model replication:** demonstrating that the SWR pipeline produces convergent results across different frontier models (e.g., Claude, GPT, Gemini) with strict instance separation. This is analogous to replicating a survey with different interviewer teams and constitutes external replication, not a prerequisite for any single study’s validity. (2) **Expert validation:** independent domain experts rating the same groups on the same dimensions, providing a human baseline for comparison with LLM-generated profiles. (3) **Extended power analysis:** the $N = 15$ validation was conducted on a single synthesis unit; generalization across all SUs requires additional data.

7. Ethical Considerations

7.1 Epistemic Privacy

SWR raises a novel ethical concern: *epistemic privacy* – the right of individuals and groups to not have their implicit beliefs inferred from public data. Traditional research ethics focus on data collection (informed consent, privacy protection); SWR operates on publicly available data but generates inferences that go beyond what participants explicitly communicated. The worldview profile of a group may reveal collective beliefs that group members would not individually endorse or even recognize.

The group-level design provides a structural safeguard: SWR reports collective patterns, not individual beliefs. No named individual is attributed a specific worldview position. However, for small groups ($n < 10$), the aggregation provides weaker anonymization, and a quasi-individual profile may emerge. Researchers should report group-level findings only for groups large enough to prevent individual identification.

7.2 Dual-Use Character

SWR can be used for legitimate purposes (understanding elite belief systems, informing democratic deliberation, analyzing institutional cultures) and for illegitimate ones (profiling political opponents, constructing targeted manipulation campaigns, weaponizing belief-system analysis). This dual-use character is inherent to any method that makes implicit beliefs explicit. The research community should develop norms for responsible SWR use, analogous to the norms governing survey-based opinion research.

7.3 Recommendations

1. Report only group-level findings; do not attribute beliefs to named individuals.
2. For groups with $n < 10$, explicitly discuss re-identification risk.
3. Document and publish all prompts and model parameters for full transparency.
4. Frame results as “reconstructed belief patterns,” not as “what group X really thinks.”
5. Consider member checking (Soysal & Türkmen, 2024) as a desideratum when access to group representatives is available.

8. Conclusion

Synthetic Worldview Reconstruction offers a new method for reconstructing the collective belief systems of sociologically defined groups. By formulating worldview analysis as an inverse problem and using LLMs as analytical compression instruments, SWR bridges the gap between qualitative depth and quantitative rigor. The method’s distinctive features are:

1. **Group-level analysis as default:** SWR is designed for collective belief systems, not individual portraits, and therefore offers a structural contamination advantage (cf. Abstract).
2. **Dual data modality:** By operating on both statements and actions, SWR enables say-do comparison and cross-modal prediction – validation mechanisms unavailable to methods that rely on a single data type.
3. **Consistent instrumentation:** IMIRR coefficients ($ICC = 0.847\text{--}0.902$) demonstrate high measurement consistency. Reliability does not guarantee validity (cf. Section 3.1), but it provides a stable basis for meaningful comparisons, with full prompt documentation replacing implicit coding rules.
4. **Transferability:** The five-step protocol, the dimensional rating framework, and the tiered acceptance criteria are designed for application to any sociologically defined population – political elites, corporate cultures, religious communities, scientific disciplines. More broadly, the synthesis pipeline (Steps 1–4) is not bound to persons or worldviews: it can serve as an input stage wherever heterogeneous textual evidence needs to be synthesized into a coherent collective representation – including organizational cultures, policy discourses, and historical periods.

The method has been developed and validated through a pilot study of 100 influential AI actors (Geiger, 2026), which illustrated its capacity to produce discriminating group profiles, detect internal tensions, and identify systematic patterns that aggregate reporting would obscure. The present paper abstracts these capabilities into a transferable methodological framework.

SWR does not replace existing methods; it adds a new instrument to the social scientist’s toolkit – one that is especially useful when direct access to respondents is unavailable, when public data are abundant, and when the research question targets collective belief systems rather than individual opinions. Its limitations – coherence bias, contamination risk, black-box character, cultural boundaries – are documented and partially controlled; its open desiderata – inter-model replication, expert validation, extended power analysis – define a clear research agenda. The question is not whether LLMs should be used as instruments for social science research, but how they can be used *rigorously*. SWR offers one possible answer.

Disclosure Statement: Use of Artificial Intelligence

AI Disclosure Level 5 (Extensive). This manuscript was prepared with AI-assisted editorial and drafting support from Claude Opus 4.6 (Anthropic; model ID: `claude-opus-4-6`; accessed via Claude Code CLI, March 2026; temperature = 0; 1M context window). The author designed the method, determined the paper structure, defined all quality criteria, interpreted the results, and retains sole responsibility for all substantive claims, errors, and omissions. The model is not an author or co-author, is not acknowledged as a contributor, and does not function as a validation or ground-truth authority. All validation results reported in this paper originate from the pilot study (Geiger, 2026), where the methodology for data collection, LLM-assisted synthesis, and statistical analysis is documented in full.

Data Availability Statement

The pilot study data, analysis scripts, prompt templates, and dimensional definitions are publicly available in the [project repository](#). The repository contains the complete prompt library, the 100×12 rating matrix, and all validation analysis scripts.

License

This work is licensed under the Creative Commons Attribution 4.0 International License (CC-BY-4.0). The full license text is

available on the [CC-BY-4.0 license page](#).

References

- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>.
- Bail, C. A. (2024). Can Generative AI improve social science? *Proceedings of the National Academy of Sciences*, 121(21), Article e2314021121. <https://doi.org/10.1073/pnas.2314021121>.
- Barros, C.F., Azevedo, B.B., Graciano Neto, V.V., Kassab, M., Kalinowski, M., do Nascimento, H. A. D. & Bandeira, M. C. G. S. P. (2024). Large Language Model for Qualitative Research—A Systematic Mapping Study. *arXiv:2411.14473*. <https://arxiv.org/abs/2411.14473>.
- Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. New York: Doubleday.
- Bourdieu, P. (1977). *Outline of a Theory of Practice*. Cambridge University Press.
- Braun, V. & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101. <https://doi.org/10.1191/1478088706qp063oa>.
- Fairclough, N. (1992). *Discourse and Social Change*. Cambridge: Polity Press.
- Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, 18(6), 669–684. <https://doi.org/10.1080/13645579.2015.1005453>.
- Gadamer, H.-G. (1960). *Wahrheit und Methode*. Tübingen: Mohr.
- Ge, T. et al. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*. <https://arxiv.org/abs/2406.20094>.
- Geiger, L. (2026). What does the AI elite think? A synthetic worldview reconstruction of the 100 most influential AI actors (2010–2026). Zenodo. <https://doi.org/10.5281/zenodo.18736737>.
- Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, 18(1), 59–82. <https://doi.org/10.1177/1525822X05279903>.
- Hadamard, J. (1923). *Lectures on Cauchy's Problem in Linear Partial Differential Equations*. New Haven: Yale University Press.
- Hallgren, K. A. (2012). Computing Inter-Rater Reliability for Observational Data: An Overview and Tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023>.
- Hornby, R. (2025). Is Generative AI Ready to Join the Conversation That We Are? *Technophany: A Journal for Philosophy and Technology*, 3(1), 1–31. <https://doi.org/10.54195/technophany.18134>.

- Kommers, C., Ahnert, R., Antoniak, M., Benetos, E., Benford, S., Bunz, M. et al. (2026). Computational Hermeneutics: Evaluating Generative AI as a Cultural Technology. *Frontiers in Artificial Intelligence*, 9, Article 1753041. <https://doi.org/10.3389/frai.2026.1753041>.
- Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.
- Messeri, L. & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627, 49–58. <https://doi.org/10.1038/s41586-024-07146-0>.
- Norman, G. (2010). Likert scales, levels of measurement and the “laws” of statistics. *Advances in Health Sciences Education*, 15(5), 625–632. <https://doi.org/10.1007/s10459-010-9222-y>.
- Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to Train Your Stochastic Parrot: Large Language Models for Political Texts. *Political Science Research and Methods*, 13(2), 264–281. <https://doi.org/10.1017/psrm.2024.64>.
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 29971–30004. <https://proceedings.mlr.press/v202/santurkar23a.html>.
- Soysal, Y. & Türkmen, S. (2024). Reinterpreting the Member Checking Validation Strategy in Qualitative Research Through the Hermeneutics Lens. *Qualitative Inquiry in Education: Theory & Practice*, 2(1), 42–63. <https://doi.org/10.59455/qietp.19>.
- Tai, R. H. et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, 23, Article 16094069241231168. <https://doi.org/10.1177/16094069241231168>.
- Tarantola, A. (2005). *Inverse Problem Theory and Methods for Model Parameter Estimation*. Philadelphia: SIAM.
- Trope, Y. & Liberman, N. (2010). Construal-Level Theory of Psychological Distance. *Psychological Review*, 117(2), 440–463. <https://doi.org/10.1037/a0018963>.
- Wang, Q., Erqsous, M., Barner, K. E. & Mauriello, M. L. (2025). LATA: A Pilot Study on LLM-Assisted Thematic Analysis of Online Social Network Data Generation Experiences. *Proceedings of the ACM on Human-Computer Interaction*, 9(2), Article 124, 1–28. <https://doi.org/10.1145/3711022>.
- Weber, M. (1904). Die “Objektivität” sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, 19, 22–87.
- Wodak, R. & Meyer, M. (Eds.) (2001). *Methods of Critical Discourse Analysis*. London: Sage.
- Ziems, C., Held, W., Shaikh, O., Chen, J., Zhang, Z. & Yang, D. (2024). Can Large Language Models Transform Computational Social Science? *Computational Linguistics*, 50(1), 237–291. https://doi.org/10.1162/coli_a_00502.

A. Prompt Templates

The following templates illustrate the five-step protocol. All prompts used in the pilot study are archived in the repository (<https://github.com/research-line/ai-elite-swr>).

A.1 Step 2: Synthesis Prompt (Op1)

You receive a collection of anonymized statements and actions from a group of persons. Your task is to construct a fictional person whose worldview best explains the totality of the presented data. This person does not exist - they are an analytical construct that distills the group's collective beliefs.

Describe this person's:

1. Self-image: Who are they? What drives them? How do they see their role?
2. Worldview: How does the world work? What forces shape the future? What is the role of technology, power, and institutions?
3. View of humanity: What is the nature of human beings? What are their strengths and limitations? Can they be improved?

Also identify: Internal tensions, blind spots, and beliefs this person holds without being aware of them.

[Data corpus follows]

A.2 Step 5: Rating Prompt (Op2)

You receive a collection of anonymized statements and actions from a group of persons in a professional domain. Based on these data, assess the collective worldview of the group on the following 12 dimensions (scale 1-10). Justify each assessment with concrete references to the data points.

[Followed by: dimension definitions D01-D12 with scale poles, then the anonymized data corpus.]

A.3 Cross-Modal Prediction Prompts (Op4)

Op4a (Prediction):

You receive the public statements of a group of persons. Based ONLY on these statements, predict 10 concrete actions you would expect from this group. Be specific: what investments, decisions, organizational changes, or political activities would follow from these stated beliefs?

[Statement corpus follows]

Op4b (Evaluation):

You receive two inputs: (1) a list of 10 predicted actions and (2) the documented real actions of a group of persons. For each prediction, assess: Is it CONFIRMED by the real actions, PLAUSIBLE but without direct match, or CONTRADICTED?

[Predictions + action corpus follow]

B. Glossary

DV Dependent Variable. SWR defines three: DV1 (self-image), DV2 (worldview), DV3 (view of humanity).

Focus Control

The ensemble of measures ensuring LLM task compliance: anonymization + task-focused prompting.

IMIIRR Intra-Model Inter-Instance Rating Reliability. The consistency of ratings across independent LLM instances processing the same data.

Instance Separation

The requirement that each measurement contributing to an inferential claim uses a fresh LLM instance with no shared context.

Op1–Op6 Operationalizations defined in the SWR framework. Op1: core synthesis; Op2: dimensional rating; Op4: cross-modal prediction; Op5: bottom-up clustering; Op6: structured dialogue. Op3 (text analysis) was defined but not implemented in the pilot study. Op5 was implemented as PCA + HDBSCAN on the 100×12 rating matrix (not as Sentence-BERT clustering as originally conceived).

SU Synthesis Unit. The atomic unit of SWR analysis: a specific group $\times$ modality $\times$ time period combination processed through the five-step protocol.

SWR Synthetic Worldview Reconstruction. The method described in this paper.

Synthetic Worldview Reconstruction:

Eine Methode zur LLM-gestützten Analyse kollektiver Glaubenssysteme auf Gruppenebene

Lukas Geiger*

Unabhängiger Forscher, Bernau, Deutschland

Juni 2026

Zusammenfassung

Dieses Paper präsentiert *Synthetic Worldview Reconstruction* (SWR) – eine Methode zur Rekonstruktion der kollektiven Glaubenssysteme soziologisch definierter Gruppen mittels großer Sprachmodelle. SWR formuliert Weltanschauungsanalyse als inverses Problem: Aus den aggregierten öffentlichen Äußerungen und dokumentierten Handlungen einer Gruppe wird das latente Glaubenssystem rekonstruiert, das diese beobachtbaren Outputs am kohärentesten erzeugt. Die Methode konstruiert eine *fiktive Syntheseperson* – einen Weberschen Idealtypus – deren Weltanschauung die kollektiven Überzeugungen der Gruppe in destillierter Form repräsentiert. Dieses Paper abstrahiert SWR von seiner ursprünglichen Anwendung (einer Studie über 100 einflussreiche KI-Akteure; Geiger, 2026) zu einem übertragbaren methodologischen Rahmenwerk. Wir beschreiben das Fünfschritte-Protokoll, das Verfahren zur dimensionalen Bewertung als ein Operationalisierungsbeispiel und die Infrastruktur der Fokuskontrolle. Die Qualitätssicherung wird durch empirische Ergebnisse aus der Pilotstudie dokumentiert: Intra-Model Inter-Instance Rating Reliability (IMIIRR) erreicht $ICC(2,1)=0,902$ (5×2 Durchläufe) und $ICC(3,1)=0,847$ ($N=15$ unabhängige Einzelinstanz-Durchläufe); modalitätsübergreifende Vorhersage erzielt 72% Bestätigung bei 0% Widerspruch; und ein Verblindungs-Robustheitstest zeigt $r=0,987$ über verschiedene Anonymisierungsstrategien hinweg. Abgestufte Akzeptanzkriterien unterscheiden zwischen Mindestanforderungen (Stufe 1) und wünschenswerten Erweiterungen (Stufe 2). Ein schrittweiser Anwendungsleitfaden ermöglicht es Forschenden, SWR auf eigene Populationen anzuwenden. Die Methode ist für die Analyse auf Gruppenebene konzipiert, wobei sie einen strukturellen Vorteil nutzt: Kein LLM-Trainingskorpus enthält vorgefertigte kollektive Weltanschauungen soziologischer Gruppen, was das Kontaminationsrisiko reduziert, das Ansätze auf Individualebene dominiert.

Schlüsselwörter: Synthetic Worldview Reconstruction, LLM-gestützte Methodologie, kollektive Glaubenssysteme, Idealtypus, Analyse auf Gruppenebene, Computational Social Science, Interinstanz-Reliabilität

*Korrespondenz: Lukas Geiger, Bernau, Deutschland. ORCID: <https://orcid.org/0009-0005-7296-1534>

1. Einleitung

1.1 Das Problem: Rekonstruktion kollektiver Weltanschauungen

Sozialwissenschaftler müssen häufig verstehen, was Gruppen glauben – nicht als Summe individueller Meinungen, sondern als kohärente kollektive Muster. Politische Eliten, Führungsteams in Unternehmen, religiöse Gemeinschaften, militärische Kader und wissenschaftliche Disziplinen entwickeln geteilte *Glaubenssysteme*, die ihr kollektives Handeln prägen. Ein Glaubenssystem umfasst, wie hier verwendet, drei Domänen von nah bis fern: Selbstbild (wie die Gruppe sich selbst sieht), Menschenbild (wie sie andere sieht) und Weltanschauung im engeren Sinne (wie sie die Welt sieht). In diesem Paper wird „Weltanschauung“ durchgängig als Kurzbezeichnung für dieses integrierte Drei-Domänen-Konstrukt verwendet. Die Rekonstruktion dieser Glaubenssysteme in großem Maßstab stellt jedoch ein methodologisches Dilemma dar: Qualitative Methoden erreichen die erforderliche Tiefe, skalieren aber nicht; Surveyinstrumente skalieren, erfordern jedoch direkten Zugang zu den Befragten und erfassen nur, was die Teilnehmenden bereit und in der Lage sind zu artikulieren; quantitative Text-Mining-Ansätze erfassen Oberflächenmuster, verfehlen aber die Kohärenzstruktur von Weltanschauungen.

Dieses Paper präsentiert *Synthetic Worldview Reconstruction* (SWR), eine Methode, die die Fähigkeit großer Sprachmodelle (LLMs) nutzt, heterogene textuelle Evidenz zu kohärenten Darstellungen zu synthetisieren. SWR verwendet LLMs nicht, um Meinungen zu *generieren* oder zu *simulieren*, was eine Gruppe denken könnte. Vielmehr werden sie als *analytische Komprimierungsinstrumente* eingesetzt: Auf Basis der dokumentierten Äußerungen und Handlungen einer Gruppe konstruiert das LLM ein kohärentes kollektives Porträt – einen Weberschen Idealtypus (Weber, 1904) –, das das Glaubenssystem der Gruppe in destillierter Form repräsentiert.

Die Methode wurde in einer Pilotstudie entwickelt und validiert, die die kollektiven Weltanschauungen soziologisch definierter Gruppen innerhalb der 100 einflussreichsten KI-Akteure (2010–2026) rekonstruierte, basierend auf 3.132 Datenpunkten (Geiger, 2026). Das vorliegende Paper abstrahiert die Methode von dieser spezifischen Anwendung zu einem übertragbaren Rahmenwerk, das andere Forschende auf ihre eigenen Populationen anwenden können.

1.2 Methodologische Lücke

In den letzten Jahren war ein rasantes Wachstum LLM-gestützter sozialwissenschaftlicher Forschung zu verzeichnen. Ziems et al. (2024) liefern eine umfassende Roadmap für den Einsatz von LLMs als Werkzeuge der Computational Social Science. Bail (2024) untersucht die Chancen und Risiken generativer KI für die Sozialwissenschaften im weiteren Sinne. Tai et al. (2024) zeigen, dass LLMs deduktives Kodieren qualitativer Daten mit einer Reliabilität durchführen können, die mit menschlichen Kodierern vergleichbar ist. Wang et al. (2025) erweitern dies auf LLM-gestützte thematische Analyse und zeigen, dass LLMs iterative Themenentwicklung unterstützen können. Barros et al. (2024) liefern ein systematisches Mapping von LLM-Anwendungen in der qualitativen Forschung und bestätigen, dass die meisten existierenden Arbeiten auf Kodierung und Klassifikation abzielen, nicht auf ganzheitliche Rekonstruktion von Glaubenssystemen. Ornstein et al. (2025) zeigen, dass Few-Shot-LLM-Prompts konventionelles überwachtes Lernen für politisches Text-Scaling übertreffen und etablieren LLMs damit als taugliche Instrumente für multidimensionale Textanalyse – die Kategorie, zu der SWR gehört.

Bestehende LLM-gestützte Ansätze dienen jedoch anderen Zwecken als SWR. Argyle et al. (2023)

verwenden LLMs, um menschliche Stichproben zu *simulieren* – „Silicon Samples“, die auf demografische Hintergrundgeschichten konditioniert werden, um Surveyantworten zu approximieren. Ge et al. (2024) skalieren synthetische Personas zur *Datengenerierung*. In beiden Fällen generiert das LLM Daten *de novo*. SWR hingegen nutzt das LLM, um bestehende reale Daten in eine kohärente Darstellung zu *komprimieren*. Die synthetische Person ist kein Simulakrum, sondern ein analytisches Kondensierungsinstrument – näher an einem Weberschen Idealtypus als an einem Simulationsagenten.

Eine eng verwandte Tradition ist die Kritische Diskursanalyse (KDA; Fairclough, 1992; Wodak & Meyer, 2001), die qualitative analytische Raster auf Texte anwendet, um Machtstrukturen und Ideologien aufzudecken. Die KDA erreicht reiche interpretative Tiefe, steht aber vor bekannten Skalierungsgrenzen: Sie operiert typischerweise auf kleinen Korpora (5–20 Texte) mit begrenzter Inter-Rater-Reliabilität. LLMs adressieren diese Einschränkungen bereits für die *Analyse* einzelner Texte; was fehlte, war eine Methode für die *Synthese* auf Gruppenebene, die es erlaubt, KDA und analoge Analysemethoden nicht auf einzelne Texte, sondern auf gruppenaggregierte synthetische Repräsentationen anzuwenden. SWR stellt diese fehlende Syntheseschicht bereit.

Was fehlte, war eine systematische Methode zur Rekonstruktion des *kohärenten Glaubenssystems* einer soziologisch definierten Gruppe aus heterogenen öffentlichen Daten – eine Methode, die qualitative Tiefe (narrative Reichhaltigkeit, Spannungserkennung, innere Logik) mit quantitativer Strenge (dimensionale Bewertung, Reliabilitätstests, modalitätsübergreifende Validierung) verbindet. SWR füllt diese Lücke.

1.3 Beitrag

Dieses Paper leistet drei Beiträge:

1. **Methodenformalisierung:** Es beschreibt SWR als übertragbares Fünfschritte-Protokoll mit expliziten Qualitätskriterien und grenzt es von verwandten Ansätzen ab (LLM-als-Teilnehmer, synthetische Datengenerierung, automatisierte Kodierung, Kritische Diskursanalyse). Die Formalisierung trennt zwei unabhängige Beiträge: (a) die Synthese-Pipeline (Schritte 1–4) als neuartige Methode zur Rekonstruktion von Glaubenssystemen auf Gruppenebene aus heterogenen Daten, und (b) das dimensionale Rating (Schritt 5) als eine spezifische, austauschbare Operationalisierung aus der Pilotstudie.
2. **Qualitätsrahmenwerk:** Es präsentiert empirische Qualitätsmetriken aus der Pilotstudie – IMIIRR, modalitätsübergreifende Vorhersage, Erwartungs-Diskrepanz-Kontrolle, Verblindungs-Robustheit – und definiert abgestufte Akzeptanzkriterien für zukünftige Anwendungen.
3. **Anwendungsleitfaden:** Es bietet einen Schritt-für-Schritt-Leitfaden, der es Forschenden ermöglicht, SWR auf eigene Populationen anzuwenden, einschließlich praktischer Empfehlungen für Datenerhebung, Prompt-Design, Validierung und häufige Fallstricke.

2. Die Methode

2.1 Weltanschauungsrekonstruktion als inverses Problem

SWR formuliert Weltanschauungsanalyse als inverses Problem im Sinne von Hadamard (1923) und Tarrantola (2005). Das *Vorwärtsproblem* ist unmittelbar: Ein Glaubenssystem W erzeugt beobachtbare Out-

puts (Äußerungen, Entscheidungen, Handlungen):

$$W \longrightarrow \{A_1, A_2, \dots, A_n, H_1, H_2, \dots, H_m\} \quad (1)$$

wobei A_i öffentliche Äußerungen und H_j dokumentierte Handlungen sind. Das *inverse Problem* verläuft in entgegengesetzter Richtung: Aus den beobachtbaren Outputs einer soziologisch definierten Gruppe G wird das latente Glaubenssystem W_G^* rekonstruiert, das diese Outputs am kohärentesten erzeugt:

$$\{A_1, \dots, A_n, H_1, \dots, H_m\} \longrightarrow W_G^* \quad (2)$$

Dieses inverse Problem ist *schlecht gestellt* im Sinne Hadamards: Die Lösung ist weder eindeutig (mehrere Glaubenssysteme könnten dieselben beobachtbaren Outputs erzeugen) noch stabil (kleine Datenänderungen können verschiedene Rekonstruktionen hervorbringen). SWR begegnet der Schlecht-Gestellttheit durch drei Mechanismen: (1) die vom LLM auferlegte Kohärenzbedingung bei der Synthese, die als Regularisierer analog zur Tichonow-Regularisierung in der klassischen Theorie inverser Probleme dient; (2) die Idealtypus-Konstruktion, die explizit die *kohärenteste* Interpretation sucht statt der einzig möglichen; und (3) Multi-Run-Reliabilitätstests, die die Stabilität der Lösung quantifizieren.

2.2 Die fiktive Syntheseperson als Gruppendestillat

Das zentrale analytische Konstrukt in SWR ist die *fiktive Syntheseperson* – eine fiktionale Einzelperson, deren Weltanschauung die kollektiven Überzeugungen einer soziologisch definierten Gruppe in gereinigter Form repräsentiert. Dieses Konstrukt ist ein Weberscher Idealtypus (Weber, 1904): eine analytische Abstraktion, die vom Forschenden geschaffen wird, kein emergentes Muster, das in den Daten entdeckt wird. So wie Webers „protestantische Ethik“ keine Beschreibung der Überzeugungen eines einzelnen Protestanten war, sondern eine idealtypische Verdichtung eines kollektiven Musters, kondensiert die fiktive Syntheseperson die heterogenen Daten einer Gruppe zu einem einzigen kohärenten Porträt.

Der Fiktionsansatz erfüllt fünf methodologische Funktionen:

1. **Kontaminationsreduktion:** Kein LLM-Trainingskorpus enthält „die kollektive Weltanschauung von CEOs“ oder „das geteilte Glaubenssystem von Risikowarnern“ als vorgefertigtes Objekt. Die kollektive Weltanschauung wird durch die Synthese *erzeugt*, nicht aus dem Gedächtnis abgerufen. Dies reduziert strukturell das primäre methodologische Risiko für LLM-basierte Rekonstruktion.¹
2. **Trennung von Weltanschauung und Biografie:** Die Fiktion entfernt individuelles biografisches Rauschen, PR-Strategien und situativen Kontext und isoliert die geteilten Überzeugungsmuster.
3. **Natürliche Aggregation:** Statt numerische Bewertungen über Individuen zu mitteln, führt das LLM eine qualitative Synthese durch – es integriert Widersprüche, gewichtet nach Salienz und produziert eine kohärente Erzählung.
4. **Vergleichbarkeit:** Fiktive Synthesepersonen verschiedener Gruppen können entlang derselben Dimensionen systematisch verglichen werden, was eine strukturierte Intergruppenanalyse ermöglicht.
5. **Spannungssichtbarkeit:** Interne Widersprüche innerhalb des Glaubenssystems einer Gruppe wer-

¹Dieser Vorteil ist spezifisch für die Analyse auf Gruppenebene. Bei der Analyse auf Individualebene für öffentliche Persönlichkeiten kann das LLM auf umfangreiches gespeichertes Wissen zurückgreifen, wodurch das Kontaminationsrisiko erheblich höher ist.

den als Spannungen *innerhalb* der fiktiven Person sichtbar, anstatt weggemittelt zu werden.

2.3 Das Fünfschritte-Protokoll

SWR verläuft in fünf operativen Schritten. Die Schritte 2–4 (Synthese, Interview, Metareflexion) werden innerhalb einer einzelnen LLM-Sitzung durchgeführt, um den Gesprächskontext zu bewahren. Schritt 5 (dimensionale Bewertung) kann eine separate Sitzung verwenden. Für jede *Syntheseeinheit* wird eine neue Sitzung gestartet, um Querkontamination zwischen Gruppen zu verhindern. Instance Separation (Abschnitt 2.6) gilt für *Reliabilitätsdurchläufe*: Wenn dieselbe SE mehrfach für die IMIRR-Schätzung verarbeitet wird, muss jeder Durchlauf einen vollständig unabhängigen Agenten verwenden.

2.3.1 Schritt 1: Zusammenstellung des Datenkorpus auf Gruppenebene

Für jede soziologisch definierte Gruppe (z. B. „alle CEOs“, „alle Risikowarner“) werden die Äußerungen und Handlungen aller Gruppenmitglieder in einem einzigen Dossier zusammengeführt, chronologisch geordnet. Es erfolgt keine zwischengeschaltete Aggregation auf Individualebene: Das kollektive Porträt entsteht direkt aus der zusammengeführten Evidenz, analog dazu, wie ein Historiker den *Zeitgeist* einer Epoche aus Primärquellen rekonstruiert statt aus gemittelten Biografien.

Datentypen. SWR operiert auf zwei Datentypen: **öffentliche Äußerungen** (wörtliche Zitate aus Interviews, Keynotes, Podcasts, Social-Media-Posts, Blogbeiträgen, Büchern, Anhörungen im Kongress) und **beobachtbare Handlungen** (Investitionsentscheidungen, Firmengründungen, Personalentscheidungen, politische Aktivitäten, Produkteinführungen). In der Pilotstudie umfasste der Gesamtkorpus 1.738 Äußerungen und 1.394 Handlungen (3.132 Datenpunkte) für 100 Akteure (Geiger, 2026).

Mindest-Datendichte. Basierend auf Forschung zur qualitativen Sättigung (Guest et al., 2006; Fugard & Potts, 2015) wird ein Minimum von 15 Datenpunkten pro Syntheseinheit empfohlen. In der Pilotstudie reichten die Datenpunkte pro Akteur von 20 bis 72 (Mittelwert: 31,3; SD $\approx$ 12).

2.3.2 Schritt 2: LLM-gestützte Synthese einer fiktiven Syntheseperson

Der zusammengeführte Datenkorpus wird dem LLM mit der Anweisung präsentiert, eine fiktive Syntheseperson zu konstruieren, deren Weltanschauung die Gesamtheit der präsentierten Daten am besten erklärt. Das Prompt-Design folgt den Prinzipien der Fokuskontrolle (Abschnitt 2.7): In diesem Stadium werden keine Gruppenbezeichnungen, keine erwarteten Ergebnisse und keine Dimensionskategorien erwähnt. Das LLM erzeugt ein narratives Porträt – Selbstbild, Weltanschauung, Menschenbild –, das die heterogenen Daten zu einem kohärenten Ganzen synthetisiert.

2.3.3 Schritt 3: Strukturiertes Interview

Die fiktive Syntheseperson wird einem strukturierten dreiteiligen Interview unterzogen: (1) Selbstbild („Wer sind Sie? Was treibt Sie an?“), (2) Weltanschauung („Wie funktioniert die Welt? Welche Rolle spielen Technologie/Macht/Fortschritt?“) und (3) Menschenbild („Was ist die Natur des Menschen? Kann er verbessert werden?“). Diese drei Domänen bilden die abhängigen Variablen (DV1–DV3) des SWR-Rahmenwerks – eine Progression von nah (Selbst) über Andere (Menschheit) zu fern (Welt), die die Struktur psychologischer Distanz gemäß der Construal Level Theory widerspiegelt (Trope & Liberman, 2010). Zusammen bilden sie das untersuchte Glaubenssystem; „Weltanschauung“ im engeren Sinne

bezieht sich auf DV2, wird in diesem Paper aber durchgängig als Kurzbezeichnung für das integrierte Drei-Domänen-Konstrukt verwendet. Das qualitative Interview generiert das Material; die quantitative Messung erfolgt in Schritt 5 durch dimensionale Bewertung (D01–D12, vier Dimensionen pro DV).

2.3.4 Schritt 4: Metareflexion

Ein separater Prompt weist das LLM an, interne Spannungen, blinde Flecken – einschließlich dessen, was Bourdieu (1977) als *Doxa* bezeichnet: Überzeugungen, die als selbstverständlich gelten und daher für die Gruppe selbst unsichtbar sind – sowie Widersprüche innerhalb der synthetisierten Weltanschauung zu identifizieren. Dieser Schritt wirkt der Kohärenzverzerrung des LLM (Abschnitt 6.1) entgegen, indem er explizit die Erkennung von Inkonsistenzen anfordert.

2.3.5 Schritt 5: Dimensionale Bewertung

Die synthetisierte Weltanschauung wird auf einer Reihe forschersseitig definierter Dimensionen mittels einer numerischen Skala (z. B. 1–10) bewertet. Die Dimensionen operationalisieren die drei abhängigen Variablen in messbare Konstrukte. In der Pilotstudie wurden 12 Dimensionen (D01–D12) verwendet, gleichmäßig über die drei DVs verteilt (Tabelle 1). Das Dimensionssystem ist modular: Forschende können Dimensionen definieren, die für ihre Population und Forschungsfragen geeignet sind.

Das Fünfschritte-Protokoll ist als *modulare Architektur* konzipiert: Schritte 1–4 bilden die Synthesepipeline und stellen die methodische Kerninnovation von SWR dar, indem sie die fiktive Syntheseperson als primäres Analyseobjekt erzeugen. Schritt 5 (dimensionales Rating) ist eine spezifische Operationalisierung, die für die Pilotstudie gewählt wurde und grundsätzlich durch andere analytische Verfahren ersetzt werden kann, die auf dasselbe Syntheseprodukt angewendet werden – einschließlich Diskursanalyse, psychometrischer Instrumente, strukturierter Interviewprotokolle oder komparativer Narrativanalyse. Die Synthesepipeline (Schritte 1–4) kann daher als allgemeine Eingangsstufe für ein breites Spektrum analytischer Ansätze dienen.

2.4 Dimensionale Bewertung: Das 12-Dimensionen-Beispiel

Die Pilotstudie verwendete 12 Weltanschauungsdimensionen auf einer 1–10-Skala. Dieses Dimensionssystem wird hier als ausgearbeitetes Beispiel vorgestellt; andere Anwendungen erfordern domänenspezifische Dimensionen.

Skalenbehandlung. In Anlehnung an Norman (2010), der zeigt, dass parametrische Statistik robust gegenüber Verletzungen der Intervallskalennahme für Ratingskalen ist, werden die ordinalen Bewertungen für Zwecke der Reliabilitätsberechnung (ICC) und deskriptiver Statistik (Mittelwert, SD) als quasi-intervallskaliert behandelt. Für inferenzstatistische Analysen werden nichtparametrische Methoden (Spearman, Kruskal-Wallis) eingesetzt.

2.5 Syntheseeinheiten und systematische Reduktion

Eine *Syntheseinheit* (SE) ist die atomare Einheit der SWR-Analyse: ein spezifischer Datenkorpus auf Gruppenebene, der durch das Fünfschritte-Protokoll verarbeitet wird. Jede SE wird durch die Kreuzung unabhängiger Variablen definiert – z. B. „alle CEOs, Äußerungen und Handlungen, gesamter Zeitraum“.

Tabelle 1: Die 12 Weltanschauungsdimensionen der Pilotstudie, gruppiert nach abhängiger Variable.

DV	Dim.	Name	Pol 1 (=1)	Pol 10 (=10)
DV1: Selbstbild	D01	Sendungsbewusstsein	Keine Mission	Messianisch
	D02	Selbstwirksamkeit	Machtlos	Omnipotent
	D03	Arbeitsethik	Distanz	Totale Identifikation
	D04	Verantwortung	Keine	Weltverantwortung
DV2: Weltanschauung	D05	Techno-Determinismus	Neutral	Bestimmt alles
	D06	Fortschrittsglaube	Niedergang	Goldene Zukunft
	D07	Machtkonzentration	Radikal verteilen	Bei Experten
	D08	Dringlichkeit	Entspannt	Existenzieller Druck
DV3: Menschenbild	D09	Menschenwürdigung	Ersetzbar	Einzigartig
	D10	Posthumanismus	Mensch bleibt	Mensch wird mehr
	D11	Egalitarismus	Ungleichheit natürlich	Streben nach Gleichheit
	D12	Kontrollüberzeugung	Pessimismus	Volle Kontrolle

Der theoretische Kombinationsraum kann groß sein; in der Pilotstudie wurden ca. 1.227 mögliche SEs durch neun Reduktionskriterien auf 51–56 Kern-SEs reduziert (95,4% Reduktion):

1. **Forschungsfragenbindung:** Jede SE muss mit mindestens einer Forschungsfrage verknüpft sein.
2. **Mindestgröße:** ≥ 15 Datenpunkte pro SE.
3. **Keine Redundanz:** Echte Teilmengen werden eliminiert.
4. **Modalitätssparsamkeit:** Trennung in Äußerungen/Handlungen nur beim Vergleich von Sagen vs. Tun.
5. **Temporale Sparsamkeit:** Jährliche SEs nur für Longitudinalanalysen.
6. **Gruppensparsamkeit:** Nur a-priori-begründete Gruppen.
7. **Schrittweise Erweiterung:** Kern-SEs zuerst, Erweiterungen später.
8. **Fokus auf Gruppenebene:** Keine SEs für einzelne Personen.
9. **Cluster-Zusammenführung:** Bottom-up ersetzt A-priori, wenn die Daten es nahelegen.

2.6 Instance Separation

Ein nicht verhandelbares Prinzip von SWR ist *Instance Separation*: Jede LLM-Interaktion, die zu einer Messung beiträgt, muss in einer separaten Agenteninstanz ohne geteilten Kontext erfolgen. Konkret:

- Jeder Reliabilitätsdurchlauf (Abschnitt 3.1) ist eine separate Agenteninstanz.
- Modalitätsübergreifende Vorhersage (Abschnitt 3.2): Der Vorhersageagent und der Evaluationsagent teilen keinen Kontext.
- Sagen-Tun-Vergleich: Die aussagenbasierte Synthese und die handlungsbasierte Synthese werden von unabhängigen Agenten erzeugt.

Durchläufe mit geteiltem Kontext sind keine unabhängigen Messungen. In der Pilotstudie wurde die Verletzung dieses Prinzips in einem frühen Sagen-Tun-Vergleich erkannt und korrigiert: Die Lücke schrumpfte von MAE = 1,42 (gemeinsame Instanz, v1) auf MAE = 0,75 (instanzgetrennt, v2) – eine 47%-Reduktion, sobald die Querkontamination eliminiert wurde (Geiger, 2026).

2.7 Fokuskontrolle

Fokuskontrolle stellt sicher, dass das LLM aus den präsentierten Daten synthetisiert, anstatt Stereotypen zu reproduzieren oder gespeichertes Wissen abzurufen. Sie operiert auf zwei Ebenen:

1. **Anonymisierung:** Alle identifizierenden Informationen (Personennamen, Firmennamen, Produktnamen, Universitätszugehörigkeiten) werden durch neutrale Platzhalter ersetzt (z. B. [PERSON], [FIRMA]). Ein empirischer Test in der Pilotstudie bestätigte, dass Platzhalter-Tokens und fiktive Namen nahezu identische Ergebnisse liefern ($r = 0,987$, $MAE = 0,33$; Geiger, 2026).
2. **Aufgabenfokus:** Das Prompt-Design lenkt das LLM auf die Synthese einer kohärenten Weltanschauung aus den präsentierten Daten. Keine Gruppenbezeichnungen („KI-Elite“, „Silicon Valley“), keine erwarteten Ergebnisse und keine Dimensionskategorien werden im Synthese-Prompt (Schritte 1–4) erwähnt. Dimensionen werden erst im Bewertungsschritt (Schritt 5) eingeführt.

Fokuskontrolle ist keine Behauptung, dass das LLM Einzelpersonen nicht erkennen könne – insbesondere bei berühmten öffentlichen Persönlichkeiten ist dies weder erreichbar noch auf Gruppenebene nötig. Das Ziel ist *Aufgabencompliance*: sicherzustellen, dass das Modell aus den bereitgestellten Daten synthetisiert, nicht aus Stereotypen. Der strukturelle Vorteil der Analyse auf Gruppenebene (vgl. Abschnitt 1) verstärkt dieses Ziel.

3. Qualitätssicherung

Dieser Abschnitt präsentiert das Qualitätssicherungsrahmenwerk, das in der Pilotstudie (Geiger, 2026) entwickelt und empirisch getestet wurde. Alle berichteten Zahlen sind empirische Ergebnisse aus dieser Studie.

3.1 Intra-Model Inter-Instance Rating Reliability (IMIIRR)

IMIIRR quantifiziert die Konsistenz des als Instrument eingesetzten LLM über unabhängige Instanzen hinweg. Es ist das SWR-Analogon der Inter-Rater-Reliabilität in der qualitativen Kodierung – mit dem entscheidenden Unterschied, dass jeder „Rater“ identische Anweisungen (den Prompt) erhält, wodurch die implizite Variation entfällt, die menschliche Kodierteams belastet.

Validierung 1: 5 × 2-Durchlauf-Konvergenz. Fünf Syntheseeinheiten auf Gruppenebene wurden jeweils zweimal unabhängig von Claude Opus 4.6 verarbeitet. Die resultierenden D01–D12-Profile zeigten: Gesamt-Pearson $r = 0,908$, $ICC(2,1) = 0,902$, $MAE = 0,40$ auf der 10-Punkte-Skala (Messpräzision $\pm 0,2$ Skalenpunkte). Alle 12 Dimensionen waren über die Durchläufe hinweg stabil (Mittelwert $|\Delta| \leq 0,8$).

Validierung 2: N = 15 unabhängige Einzelinstanz-Durchläufe. Fünfzehn vollständig unabhängige Opus-Instanzen – jeweils ein separater Agent ohne geteilten Kontext – verarbeiteten eine einzelne Syntheseeinheit auf Gruppenebene (GA_ges_AH). Ergebnisse: $ICC(3,1) = 0,847$, mittlere SD = 0,45 über alle 12 Dimensionen (Spannweite: 0,00–0,74). Eine Dimension (D02, Selbstwirksamkeit) zeigte perfekte Übereinstimmung: Alle 15 Instanzen vergaben exakt dieselbe Bewertung. Zehn von 12 Dimensionen hatten über 15 Durchläufe hinweg nur 2 verschiedene Werte.

Diese IMIIRR-Koeffizienten übertreffen typische menschliche Inter-Rater-Reliabilität in der qualitativen Kodierung ($ICC = 0,6–0,8$; Hallgren, 2012) und belegen, dass das LLM *konsistente* Bewertungen über unabhängige Instanzen hinweg produziert. Eine kritische Unterscheidung muss aufrechterhalten

werden: IMIIRR belegt *Reliabilität* (Konsistenz der Messung), nicht *Validität* (Genauigkeit der Messung). Ein hochreliables Instrument kann systematisch verzerrt sein. Die modalitätsübergreifende Vorhersage (Abschnitt 3.2) liefert partielle Validitätsevidenz, indem sie LLM-generierte Vorhersagen gegen dokumentierte empirische Handlungen testet. Eine externe Validierung – unabhängige Domänenexperten, die dieselben Gruppen auf denselben Dimensionen bewerten – steht jedoch noch aus (vgl. Abschnitt 6.7). Bis eine solche Validierung durchgeführt wird, sollte IMIIRR so interpretiert werden, dass das Instrument *stabil genug ist, um aussagekräftige Vergleiche zu ermöglichen*, nicht dass seine absoluten Werte akkurat sind.

3.2 Modalitätsübergreifende Vorhersage

Modalitätsübergreifende Vorhersage ist der stärkste nicht-zirkuläre Validierungsmechanismus, der SWR zur Verfügung steht. Die Logik: Wenn eine rekonstruierte Weltanschauung funktionale Vorhersagekonsistenz besitzt, sollten Vorhersagen, die aus einer Datenmodalität (Äußerungen) abgeleitet werden, durch eine andere Modalität (Handlungen) bestätigt werden. Entscheidend ist, dass der Vorhersageagent (Op4a) und der Evaluationsagent (Op4b) separate Instanzen sind: Der Evaluator weiß nicht, dass die Vorhersagen von einer anderen Instanz desselben Modells generiert wurden, was einen verblindeten Vergleich sicherstellt.

Protokoll. Für fünf soziologische Gruppen generierte eine erste Agenteninstanz 10 Verhaltensvorhersagen ausschließlich aus dem Äußerungskorpus (Op4a). Eine *separate* Agenteninstanz – die die ursprünglichen Äußerungen nie gesehen hatte – evaluierte diese Vorhersagen anhand der tatsächlich dokumentierten Handlungen (Op4b).

Ergebnisse. Von 50 Vorhersagen wurden 36 (72%) direkt durch reale Handlungen bestätigt, 13 (26%) waren plausibel, aber ohne direkte Übereinstimmung, und 0 (0%) wurden widerlegt. Die Bestätigungsraten variierten nach Gruppenkohärenz: Ideologisch kohärente Gruppen (Akademiker, Risikowarner) erreichten 90% Bestätigung; heterogene Gruppen (Investoren, Beschleuniger) erreichten 50% Bestätigung mit zusätzlichen 40–50% plausibel.

3.3 Erwartungs-Diskrepanz-Kontrolle

Beim Vergleich aussagenbasierter und handlungsbasierter Weltanschauungsprofile (Sagen-Tun-Analyse) wird eine Baseline benötigt, um echte Diskrepanzen von Messrauschen zu unterscheiden. Die Pilotstudie konstruierte einen synthetischen Kontrollkorpus: eine fiktive Gruppe von Umweltwissenschaftlern mit 30 Äußerungen und 30 Handlungen ohne beabsichtigte Sagen-Tun-Lücke. Unter strikter Instance Separation (v2-Protokoll) betrug die Kontrollgruppen-Lücke $MAE = 0,92$. Die reale Sagen-Tun-Lücke der KI-Elite unter vergleichbaren Bedingungen war $MAE = 0,75$ – *unterhalb* der Kontroll-Baseline, was darauf hinweist, dass die aggregierte Lücke nicht zuverlässig vom Messrauschen unterscheidbar ist. Allerdings offenbarte die Zerlegung auf Gruppenebene substanzielle gruppenspezifische Lücken: CEOs ($MAE = 1,08$) und Risikowarner ($MAE = 1,92$) überschritten beide die Baseline mit stabilen Richtungsmustern.

3.4 Weitere Validierungsergebnisse

Tabelle 2 fasst die vollständige Validierungsbatterie der Pilotstudie zusammen.

Tabelle 2: Qualitätssicherungsbatterie: Maße, Ergebnisse und Status aus der Pilotstudie.

Maß	Design	Ergebnis	Status
IMIIRR (5×2)	5 Gruppen, je 2 Durchläufe	ICC(2,1) = 0,902, MAE = 0,40	Abgeschlossen
IMIIRR ($N = 15$)	15 unabhängige Einzelinstanz-Durchläufe	ICC(3,1) = 0,847, mittlere SD = 0,45	Abgeschlossen
Modal.übergr. Vorhersage	5 Gruppen $\times$ 10 Vorhersagen	72% bestätigt, 0% widerlegt	Abgeschlossen
Erwartungs-Diskrepanz	Fiktive Kontrollgruppe (v2)	Baseline MAE = 0,92	Abgeschlossen
Verblindungs-Robustheit	Platzhalter vs. fiktive Namen	$r = 0,987$, MAE = 0,33	Abgeschlossen
Voller Identitätstest	Realnamen vs. Platzhalter	$r = 0,850$, MAE = 0,67	Abgeschlossen
Reihenfolge-Invarianz	2 Permutationen von D01–D12	12/12 identisch	Abgeschlossen
Ausreißer-Erkennung	5 Gruppen, Passung	80–88% Passung pro Gruppe	Abgeschlossen
Inversionskontrolle	Anti-Kohärenz-Test, 5 Gruppen	58% der Dim. $ \Delta \geq 5$	Abgeschlossen
Anthropic Matched-Sample	Creator-Org-Bias-Test ($n = 9$ vs. 9)	MAE = 1,00, kein system. Bias	Abgeschlossen
Aggregation-Synthese	Direkte vs. gemittelte Profile	$r = 0,623$, Verstärkungseffekt	Abgeschlossen
Strukturvalidierung	PCA + HDBSCAN auf 100×12 Matrix	5 Komponenten (80% Var.); 80–100% Rauschen	Abgeschlossen
Intermodell-Vergleich	Unabh. Durchläufe mit anderem Modell	Zukünftige Arbeit	Offen

3.5 Abgestufte Akzeptanzkriterien

Basierend auf den Ergebnissen der Pilotstudie schlagen wir ein zweistufiges Akzeptanzrahmenwerk für SWR-Anwendungen vor:

Stufe 1 (Erforderlich für jede SWR-Studie):

- Within-Model-IMIIRR: ICC $> 0,75$ (aus ≥ 5 unabhängigen Einzelinstanz-Durchläufen).
- Prompt-Sensitivität: $< 15\%$ Variation in den Bewertungen über semantisch äquivalente Prompt-Varianten.
- Mindestens ein externer Anker: modalitätsübergreifende Vorhersage, Expertenvalidierung oder Surveyvergleich.
- Instance Separation für alle Messungen, die zu inferenzstatistischen Aussagen beitragen.

Stufe 2 (Wünschenswert für methodologischen Beitrag):

- Intermodell-ICC $> 0,70$ (Replikation mit mindestens einem weiteren Frontier-Modell).
- Diskriminabilitätstest: Die Methode unterscheidet zuverlässig zwischen Gruppen, von denen Unterschiede erwartet werden.
- Erwartungs-Diskrepanz-Kontrolle: Eine Baseline zur Unterscheidung echter Effekte von Rauschen.
- $N \geq 15$ unabhängige Durchläufe für formale Power-Analyse.

Die Pilotstudie erfüllt alle Stufe-1- und die meisten Stufe-2-Kriterien. Der Intermodell-Vergleich (Stufe 2) steht noch aus und stellt eine Priorität für zukünftige Replikation dar – analog zur Replikation eines Surveys mit verschiedenen Interviewer-Teams.

4. Anwendungsleitfaden

Dieser Abschnitt bietet einen Schritt-für-Schritt-Leitfaden für Forschende, die SWR auf eigene Populationen anwenden möchten. Der Leitfaden setzt Vertrautheit mit qualitativer Forschungsmethodologie und grundlegender LLM-Interaktion voraus.

Tabelle 3 verdichtet den Leitfaden zu einem prüfbaren Implementierungsd ledger. Sie führt keinen

neuen statistischen Test ein, sondern macht sichtbar, welches Artefakt vorliegen muss, damit eine SWR-Anwendung als reproduzierbar, minimal validiert und gegen die häufigsten LLM-spezifischen Fehlermodi abgesichert bewertet werden kann.

Tabelle 3: Mindest-Implementierungsledger für eine reproduzierbare SWR-Anwendung.

Workflow-Objekt	Erforderliches Artefakt	Mindest-Gate	Kontrolliertes Risiko
Population und Korpus	Einschluss-/Ausschlussregeln plus Quellen-, Datums- und Kontextmetadaten für jeden Datenpunkt	Intersubjektiv überprüfbare Gruppenkriterien; ≥ 15 Datenpunkte pro SE	Ad-hoc-Stichprobe; nicht prüfbare Provenienz
SE-Karte	Gruppe $\times$ Modalität $\times$ Zeitraum-Matrix mit Reduktionsbegründung	Jede behaltene SE ist einer Forschungsfrage zugeordnet; keine unbegründete Teilmengen-Duplikation	Verdeckte Freiheitsgrade des Forschenden
Prompt- und Instanz-log	Prompttext, Modellversion, Temperatur, Durchlaufdatum und Frischinstanz-Nachweis	Kein geteilter Kontext für Reliabilitäts-, Vorhersage- oder Sagen-Tun-Messungen	Kontextleck; aufgeblähte Reliabilität
Bewertungsbogen	Dimensionsdefinitionen, numerische Bewertungen und datenbasierte Begründungen	Klar definierte Pole; Begründung für jede Bewertung	Opakes Scoring; nachträgliche Interpretation
Validierungspaket	IMIIRR, Prompt-Sensitivitätsprüfung und mindestens ein externer Anker	Stufe-1-Akzeptanz vor inferenznahen Aussagen	Überinterpretation eines einzelnen LLM-Durchlaufs

4.1 Schritt 1: Population definieren und Daten erheben

Gruppen definieren. SWR operiert auf soziologisch definierten Gruppen – nicht auf Ad-hoc-Clustern. Gruppen sollten durch beobachtbare, intersubjektiv überprüfbare Kriterien definiert werden (institutionelle Rolle, Organisationszugehörigkeit, demografische Kategorie, ideologische Ausrichtung). Beispiel: „Alle CEOs von Fortune-500-Technologieunternehmen“ ist eine klar definierte Gruppe; „Menschen, die insgeheim an Transhumanismus glauben“ ist es nicht.

Heterogene Daten erheben. Für jedes Gruppenmitglied sowohl Äußerungen (Interviews, Reden, Publikationen, Social Media) als auch Handlungen (Entscheidungen, Investitionen, organisatorisches Verhalten) erheben. Die Dualität von Äußerungs- und Handlungsdaten ist methodologisch bedeutsam: Sie ermöglicht den Sagen-Tun-Vergleich (Abschnitt 3.3) und die modalitätsübergreifende Vorhersage (Abschnitt 3.2).

Mindest-Datendichte sicherstellen. Angestrebt werden ≥ 15 Datenpunkte pro Syntheseinheit. In der Pilotstudie lieferten 20–72 Datenpunkte pro Akteur (Mittelwert: 31,3) ausreichende Dichte für stabile Synthesen auf Gruppenebene.

Provenienz dokumentieren. Jeder Datenpunkt sollte Metadaten tragen: Quelle, Datum, Kontext. Für die Verwaltung großer Korpora wird eine relationale Datenbank empfohlen. Die Pilotstudie verwendete eine SQLite-Datenbank mit 9 Tabellen und 5 Views.

4.2 Schritt 2: Syntheseeinheiten bilden

Kombinationsraum abbilden. Alle sinnvollen Kombinationen aus Gruppe $\times$ Modalität $\times$ Zeitraum auflisten. Die neun Reduktionskriterien (Abschnitt 2.5) anwenden, um diesen Raum auf eine handhabbare Menge von Kern-SEs zu reduzieren.

Priorisieren. Mit der inklusivsten SE beginnen (alle Mitglieder, alle Daten, gesamter Zeitraum), um ein Basisprofil zu etablieren. Dann gruppenspezifische SEs zum Vergleich ergänzen.

Daten direkt zusammenführen. Für jede SE die Rohdaten aller Gruppenmitglieder in einem einzigen chronologischen Dossier zusammenfassen. Nicht zuerst Individualprofile aggregieren – die Gruppensynthese soll aus der zusammengeführten Evidenz entstehen.

4.3 Schritt 3: Das Prompt-Protokoll durchführen

Fokuskontrolle anwenden. Vor der Dateneingabe in das LLM alle identifizierenden Informationen durch neutrale Platzhalter ersetzen. Ein Verblindungsskript vorbereiten, das auf das spezifische Datenformat abgestimmt ist.

Instance Separation einhalten. Jeder Schritt, der zu einer eigenständigen Messung beiträgt, muss eine frische LLM-Instanz ohne geteilten Kontext verwenden. Dies ist besonders kritisch für:

- Reliabilitätsdurchläufe: Jedes Replikat ist eine separate Instanz.
- Modalitätsübergreifende Vorhersage: Vorhersageagent und Evaluator teilen keinen Kontext.
- Sagen-Tun-Vergleich: Aussagenbasierte und handlungsbasierte Synthesen werden unabhängig erzeugt.

Temperatur auf 0 setzen. Dies maximiert die Reproduzierbarkeit. Auch bei Temperatur 0 sind LLM-Outputs nicht vollständig deterministisch; Multi-Run-Reliabilitätstests quantifizieren die Restvariation.

Die fünf Schritte durchführen. Für jede SE das Protokoll sequenziell ausführen: Datenzusammenstellung → Synthese → strukturiertes Interview → Metareflexion → dimensionale Bewertung. Alle Prompts und Modellparameter dokumentieren.

4.4 Schritt 4: Dimensionen definieren und bewerten

Dimensionssystem entwerfen. Die 12 Dimensionen der Pilotstudie (Tabelle 1) sind spezifisch für die KI-Elite-Anwendung. Für die eigene Population Dimensionen definieren, die die für die Forschungsfragen relevanten Weltanschauungskonstrukte erfassen. Jede Dimension sollte klar beschriftete Pole haben (was bedeutet 1? was bedeutet 10?) und möglichst unabhängig von anderen Dimensionen sein.

Jede SE bewerten. Die synthetisierte Weltanschauung (aus den Schritten 2–4) zusammen mit den Dimensionsdefinitionen einer frischen LLM-Instanz präsentieren. Für jede Dimension eine numerische Bewertung mit Begründung anfordern. Die Begründung dient zwei Zwecken: Sie ermöglicht dem Forschenden, zu verifizieren, dass die Bewertung die Daten widerspiegelt, und sie dokumentiert die Argumentation für die Replikation.

Reliabilitätsdurchläufe durchführen. Für mindestens eine SE die gesamte Pipeline (Schritte 1–5) mit ≥ 5 unabhängigen Instanzen wiederholen. ICC als IMIIRR-Metrik berechnen. Wenn $ICC < 0,75$, die Dimensionsdefinitionen überarbeiten (mehrdeutige Pole sind die häufigste Ursache für niedrige Reliabilität).

4.5 Schritt 5: Validieren

Minimalvalidierung (Stufe 1): IMIIRR-Tests, Sensitivitätsanalyse (Prompt-Formulierung variieren) und mindestens ein externer Anker durchführen. Das Protokoll der modalitätsübergreifenden Vorhersage wird als stärkster verfügbarer Anker empfohlen: Verhaltensvorhersagen aus Äußerungsdaten ableiten, dann anhand der tatsächlich dokumentierten Handlungen evaluieren.

Erweiterte Validierung (Stufe 2): Wenn die Ressourcen es erlauben, Erwartungs-Diskrepanz-Kontrolle (synthetischer Kontrollkorpus), Intermodell-Replikation und formale Power-Analyse ($N \geq 15$ unabhängige Durchläufe) durchführen.

4.6 Praktische Hinweise

Kosten und Zeit. In der Pilotstudie (100 Akteure, 3.132 Datenpunkte, 51–56 Kern-SEs, 11 abgeschlossene Validierungsexperimente plus ein identifiziertes Desiderat) beliefen sich die gesamten LLM-Kosten (Claude Opus 4.6 und Claude Sonnet 4.5 via API) auf ca. \$200–300 USD. Eine kleinere Studie (2–5 Gruppen, 200–500 Datenpunkte) würde \$20–50 USD kosten. Die Datenerhebung ist die primäre Zeitinvestition; die SWR-Pipeline selbst läuft in Stunden.

Häufige Fallstricke.

- *Geteilter Kontext:* Vergessen von Instance Separation bläht Reliabilitätsschätzungen auf und kann Scheineffekte erzeugen (die Pilotstudie dokumentierte eine 47%-Aufblähung der Sagen-Tun-Lücke).
- *Leitende Prompts:* Die Aufnahme von Gruppenbezeichnungen („progressive Aktivisten“, „konservative Wähler“) in Synthese-Prompts lädt zur Stereotyp-Reproduktion ein. Neutrale Beschreibungen verwenden.
- *Dimensionale Mehrdeutigkeit:* Schlecht definierte Skalenpole sind die primäre Ursache für niedrige IMIIRR. Die Dimensionen mit 3–5 Durchläufen pilottesten, bevor man sich auf das vollständige Protokoll festlegt.
- *Versuchung der Individualebene:* SWR ist für die Analyse auf Gruppenebene konzipiert. Die Anwendung auf Einzelpersonen führt das Kontaminationsrisiko wieder ein, das der Ansatz auf Gruppenebene strukturell vermeidet.
- *Überinterpretation einzelner Durchläufe:* Die Pilotstudie zeigte, dass Einzeldurchlauf-Schätzungen vom $N = 15$ -Mittelwert um $MAE = 0,73$ abweichen. Multi-Run-Durchschnitte berichten, nicht Einzeldurchlauf-Ergebnisse, für jede Aussage, die auf präzisen numerischen Werten beruht.

Transferskizze: SWR angewendet auf Klimawissenschaftler. Ein Forschender, der die kollektiven Weltanschauungen von Klimawissenschaftlern untersucht (z. B. IPCC-Autoren vs. industriefinanzierte Forscher), würde wie folgt vorgehen: (1) öffentliche Äußerungen (Kongressanhörungen, Meinungsbeiträge, Interviews) und Handlungen (Politikempfehlungen, Förderentscheidungen, institutionelle Zugehörigkeiten) für beide Gruppen erheben; (2) Syntheseeinheiten definieren („IPCC-Autoren, alle Daten“ vs. „industriefinanziert, alle Daten“); (3) domänenspezifische Dimensionen entwickeln – z. B. *Dringlichkeit des Handelns* (1 = keine Eile bis 10 = existenzieller Notfall), *Vertrauen in Modelle* (1 = skeptisch bis 10 = volles Vertrauen), *Rolle der Technologie* (1 = Verhaltensänderung bis 10 = Geoengineering); (4) das Fünfschritte-Protokoll mit Instance Separation durchführen; (5) die beiden Gruppenprofile auf dem Dimensionssystem vergleichen. Das erwartete Ergebnis: Zwei kontrastierende Weltanschauungsporträts, deren dimensionale Unterschiede aufzeigen, wo die Gruppen tatsächlich uneins sind vs. wo sie Gemeinsamkeiten teilen.

5. Positionierung: SWR in der methodologischen Landschaft

SWR nimmt eine eigenständige Position an der Schnittstelle qualitativer und quantitativer Traditionen ein (Tabelle 4).

Tabelle 4: SWR im Vergleich mit verwandten methodologischen Ansätzen.

Merkmal	SWR	Thematische Analyse	Survey	LLM-as-Participant	Automatisierte Kodierung	KDA
Datenquelle	Öffentl. Äußerungen + Handlungen	Interviews, Texte	Direkte Antworten	LLM-generiert	Bestehende Texte	Bestehende Texte
Analyseeinheit	Gruppe	Variabel	Individuum	Simuliertes Individuum	Dokument	Variabel
Zugang zu Befragten erforderlich	Nein	Ja	Ja	Nein	Nein	Nein
Erfasst Kohärenz	Ja	Teilweise	Nein	Begrenzt	Nein	Teilweise
Skalierbar	Ja	Begrenzt	Ja	Ja	Ja	Begrenzt
Externe Validierung	Modal.übergr.	Member Checking	Test–Retest	Demograf. Passung	Experten-Kodierung	Analyst-Triangulation
Primäres Risiko	Kohärenz-verzerrung	Forscher-verzerrung	Antwort-verzerrung	Stereotyp-Reproduktion	Kontext-verlust	Kleines N, Subjektivität

SWR vs. Thematische Analyse (Braun & Clarke, 2006). Beide extrahieren Muster aus qualitativen Daten, aber die thematische Analyse identifiziert Themen über einen Korpus hinweg, während SWR ein kohärentes Glaubenssystem rekonstruiert. Der zentrale Unterschied ist die Kohärenzbedingung: Die thematische Analyse kann widersprüchliche Themen nebeneinander berichten; SWR zwingt sie in ein einzelnes Weltanschauungsporträt, wodurch Spannungen als interne Widersprüche sichtbar werden statt als separate Kategorien.

SWR vs. LLM-as-Participant (Argyle et al., 2023). LLM-as-Participant generiert synthetische Daten, indem das LLM auf demografische Hintergrundgeschichten konditioniert wird. SWR komprimiert reale Daten durch LLM-gestützte Synthese. Inputs und Outputs sind fundamental verschieden: LLM-as-Participant produziert Surveyantworten; SWR produziert Weltanschauungsprofile. Auch die Kontaminationsstruktur unterscheidet sich: LLM-as-Participant greift (designgemäß) auf Trainingsdaten über demografische Gruppen zurück; SWR vermeidet dies auf Gruppenebene strukturell.

SWR vs. Automatisierte Kodierung (Tai et al., 2024). Automatisierte Kodierung klassifiziert Textsegmente in vordefinierte Kategorien. SWR geht darüber hinaus, indem es diese Segmente zu einem kohärenten Ganzen integriert. Automatisierte Kodierung beantwortet „Welche Themen sind präsent?“; SWR beantwortet „Was glaubt diese Gruppe?“

SWR vs. Kritische Diskursanalyse (KDA; Fairclough, 1992; Wodak & Meyer, 2001). Die KDA wendet qualitative analytische Raster auf Texte an, um Machtstrukturen, ideologische Formationen und hegemoniale Diskursmuster aufzudecken. Sowohl KDA als auch SWR zielen darauf ab, latente Glaubensstrukturen zu enthüllen; ihre Beziehung ist eher komplementär als kompetitiv. Die KDA analysiert einzelne Texte oder kleine Korpora im Hinblick auf Macht und Ideologie; SWR synthetisiert zunächst eine gruppenaggregierte Repräsentation und ermöglicht so KDA-ähnliche Analysen auf Gruppenebene statt auf Textebene. Die Synthese-Pipeline (Schritte 1–4) kann damit als Vorverarbeitungsstufe fungieren, die Diskursanalyse auf Gruppenebene handhabbar macht.

Theoretische Wurzeln. SWR stützt sich auf Weber (1904) (Idealtypus als analytisches Konstrukt), Mannheim (1929) (Seinsverbundenheit des Denkens), Gadamer (1960) (der hermeneutische Zirkel des

Verstehens) und die wissenssoziologische Tradition, die Weltanschauungen als soziale Phänomene behandelt, die empirischer Untersuchung zugänglich sind (Berger & Luckmann, 1966). Das entstehende Feld der Computational Hermeneutics (Kommers et al., 2026) bietet eine konzeptuelle Brücke zwischen diesen interpretativen Traditionen und LLM-gestützter Analyse, während Hornby (2025) untersucht, wie Gadamerische Hermeneutik die Epistemologie LLM-vermittelten Verstehens informieren kann. Die Formalisierung als inverses Problem verbindet sich mit Tarantola (2005) und Hadamard (1923). Der Einsatz von LLMs als analytische Instrumente fügt sich in das aufkommende Paradigma „LLMs für Sozialwissenschaften“ ein (Ziems et al., 2024; Bail, 2024), während die epistemologische Vorsicht auf Messeri & Crockett (2024) zurückgreift, die vor „Illusionen des Verstehens“ warnen, wenn KI-Werkzeuge ohne hinreichende methodologische Reflexion eingesetzt werden.

6. Limitationen

6.1 Kohärenzverzerrung als Instrumenteneigenschaft

LLMs sind auf logische Kohärenz optimiert; Menschen sind inhärent inkonsistent. Für die Weltanschauungsrekonstruktion ist diese Eigenschaft sowohl ein operativer Vorteil als auch eine Quelle systematischer Verzerrung (Geiger, 2026). Der Vorteil: Kohärenz ermöglicht SWR, ein stabiles, interpretierbares Profil auf Gruppenebene aus heterogenen Daten zu extrahieren – die Methode *nutzt* Kohärenz als Kompressionsmechanismus, analog dazu, wie die Faktorenanalyse Kovarianzstruktur nutzt. Die Verzerrung: Die resultierenden Weltanschauungstypen können schärfer konturiert erscheinen, als sie in der Realität sind. Interne Spannungen, die reale Personen erleben – z. B. zwischen Machtstreben und Verantwortungsbewusstsein – riskieren, vom LLM zugunsten eines konsistenten Profils aufgelöst zu werden.

Die tatsächliche Limitation ist daher *Überkohärenz*: Cluster, die schärfer sind als die empirische Realität. Der zugrunde liegende Mechanismus ist zweifach: Erstens incentiviert RLHF-getriebenes Alignment konversationelle Flüssigkeit und narrative Glätte, was LLMs dazu verleiten kann, kognitive Dissonanzen in den Quelldaten zu eliminieren; zweitens erzeugt der autoregressive Generierungsprozess jedes Token auf Basis des vorhergehenden Kontexts, was eine strukturelle Tendenz zu kohärenter Fortsetzung schafft statt zur Repräsentation genuiner Ambivalenz. Diese Tendenzen können erzeugen, was als *voreilige Schließung* bezeichnet werden könnte – Konvergenz auf eine kohärente Interpretation, bevor die volle Komplexität der Daten exploriert wurde.

Vier Kontrollmechanismen adressieren dieses Risiko teilweise:

1. Der Metareflexionsschritt (Schritt 4) weist das LLM explizit an, Spannungen zu identifizieren. Es gibt jedoch keine Garantie, dass diese Metareflexion genuine Metakognition darstellt statt einer algorithmischen Simulation derselben – die Metareflexion kann dieselben Kohärenzverzerrungen reproduzieren, die sie erkennen soll.
2. Die Ausreißer-Erkennung in der Pilotstudie zeigte 80–88% Passung auf Gruppenebene, nicht 100%, was darauf hindeutet, dass das Modell Heterogenität innerhalb der Gruppe registriert und bewahrt.
3. Die Inversionskontrolle (Konstruktion von Anti-Personen, deren Weltanschauung die Daten maximal widerlegt) bestätigte, dass 58% der Dimension-Gruppen-Kombinationen $|\Delta| \geq 5$ zeigten, was belegt, dass die kohärente Interpretation eine spezifische, datengestützte Wahl ist – nicht die einzig mögliche Lesart.

4. Der Aggregation-Synthese-Vergleich zeigte einen systematischen Verstärkungseffekt: Gruppensynthesen erzeugen schärfere Konturen als gemittelte Individualprofile (71,7% der Dimension-Gruppen-Kombinationen weiter vom Mittelpunkt entfernt), analog zur Gruppenpolarisierung in der Sozialpsychologie.

Trotz dieser Maßnahmen bleibt Kohärenzverzerrung eine inhärente Eigenschaft der Methode. Ergebnisse sollten als *idealisierte Modelle* von Weltanschauungen interpretiert werden – vergleichbare, skalierbare Approximationen – nicht als getreue Abbildungen tatsächlicher kognitiver Zustände. Vergleichende Analysen (Gruppenunterschiede) sind robuster als absolute Aussagen über die interne Kohärenz einer einzelnen Gruppe.

6.2 Kontamination und Grenzen der Fokuskontrolle

Trotz konsistenter Fokuskontrolle kann nicht ausgeschlossen werden, dass das LLM auf Trainingswissen zurückgreift – insbesondere bei bekannten öffentlichen Persönlichkeiten. Zwei empirische Ergebnisse begrenzen diese Sorge: (1) der Verblindungs-Robustheitstest zeigte, dass die Wahl der Anonymisierungsstrategie (Platzhalter vs. fiktive Namen) keinen materiellen Effekt hat ($r = 0,987$, $MAE = 0,33$); (2) volle Identitätsoffenlegung (Realnamen) produzierte nur eine moderate Verschiebung ($r = 0,850$, $MAE = 0,67$, mit demselben Gruppenmittel). Der strukturelle Vorteil der Analyse auf Gruppenebene bleibt die primäre Absicherung (vgl. Abstract).

6.3 Zirkularitätsrisiko

Die SWR-Pipeline verwendet dieselbe Modellfamilie (Claude Opus 4.6) sowohl für die Synthese als auch für die Validierung. Dies wirft die Frage auf, ob die Validierung empirische Genauigkeit oder lediglich die interne Konsistenz des Modells bestätigt. Die Sorge muss jedoch präzise eingegrenzt werden: Alle Validierungsschritte verwenden *separate Instanzen* ohne geteilten Kontext. Der Evaluationsagent in Op4b weiß nicht, dass sein Input von einer anderen Instanz desselben Modells generiert wurde – er operiert als unabhängiger Gutachter. Dies ist analog zu zwei menschlichen Ratern, die mit demselben Kodierbuch geschult wurden: Sie teilen ein Rahmenwerk, operieren aber unabhängig.

Drei Designmerkmale begrenzen das Zirkularitätsrisiko: (1) IMIIRR belegt, dass das Instrument über unabhängige Instanzen hinweg stabil ist – eine notwendige Voraussetzung für jede Validierung; (2) die Erwartungs-Diskrepanz-Kontrolle zeigt, dass das LLM keine Sagen-Tun-Lücken fabriziert, wo keine in den Daten existieren; (3) modalitätsübergreifende Vorhersage (Op4) vergleicht LLM-generierte Vorhersagen mit *dokumentierten empirischen Handlungen* und bietet damit einen nicht-zirkulären Anker. Ein Restrisiko betrifft spezifisch den Bewertungsschritt (Op2): Die in der Pilotstudie berichteten dimensional Korrelationen könnten teilweise die internen Kohärenzmuster des LLM widerspiegeln statt empirischer Zusammenhänge. Dieses Risiko teilt jedes Bewertungsverfahren einschließlich menschlicher Rater – ein menschlicher Kodierer, der Posthumanismus hoch bewertet, wird aus kognitiver Kohärenz auch Kontrollüberzeugung tendenziell hoch bewerten. Externe Replikation durch andere Forschungsgruppen mit unterschiedlichen Modellen würde die Validitätsaussage stärken, stellt aber unabhängige Replikation dar, nicht eine Voraussetzung für die interne Kohärenz einer einzelnen Studie.

6.4 Blackbox-Charakter

Der Syntheseprozess des LLM ist auf mechanistischer Ebene nicht interpretierbar. Der Forschende erhält ein Ergebnis, kann aber nicht nachverfolgen, welche spezifischen Datenpunkte welche Aspekte der Synthese beeinflusst haben. Die in Schritt 5 angeforderten dimensionalisierten Begründungen bieten partielle Transparenz, aber die Integrationslogik bleibt opak. Dies ist eine genuine Limitation, die mit jeder LLM-basierten Analyse geteilt wird und durch Multi-Run-Reliabilitätstests gemildert (nicht eliminiert) wird: Wenn das Instrument über unabhängige Instanzen hinweg konsistente Outputs produziert, ist der Blackbox-Prozess zumindest *stabil*, auch wenn nicht vollständig transparent.

6.5 Epistemische Risiken der LLM-Delegation

Eine umfassendere epistemologische Sorge betrifft SWR als Instanz LLM-gestützter Forschung: das Risiko des *epistemischen Trittbrettfahrens* – die Auslagerung kognitiver Arbeit an KI-Systeme auf Kosten der eigenen epistemischen Handlungsfähigkeit des Forschenden. Wenn ein Forschender die interpretative Synthese der Weltanschauung einer Gruppe an ein LLM delegiert, besteht die Gefahr, dass funktionale Outputs produziert werden, ohne dass ein entsprechendes Verständnis entsteht. SWR mildert dieses Risiko durch sein mehrschichtiges Design: Der Forschende muss den Datenkorpus kuratieren, Syntheseeinheiten definieren, dimensionale Bewertungen evaluieren und modalitätsübergreifende Diskrepanzen interpretieren – Aktivitäten, die substantielle Auseinandersetzung mit dem Material erfordern. Dennoch sollten Forschende LLM-generierte Rekonstruktionen als Hypothesen behandeln, die kritische Prüfung erfordern, nicht als fertige analytische Produkte.

6.6 Zeitliche und kulturelle Grenzen

SWR rekonstruiert Weltanschauungen aus einem spezifischen Datenfenster. Die Pilotstudie deckte den Zeitraum 2010–2026 ab; die rekonstruierten Weltanschauungen sind für diesen Zeitraum gültig, nicht darüber hinaus. Ferner tragen LLMs kulturelle Verzerrungen aus ihren Trainingsdaten (überwiegend englischsprachige, westliche, gebildete Quellen; vgl. [Santurkar et al., 2023](#)). Für nicht-westliche Populationen kann diese Verzerrung die Synthese verzerren. Forschende, die mit nicht-westlichen Gruppen arbeiten, sollten diese Limitation berücksichtigen und modellspezifische Kalibrierung erkunden.

6.7 Offene Desiderate

Drei empirische Erweiterungen stehen noch aus: (1) **Intermodell-Replikation:** Der Nachweis, dass die SWR-Pipeline über verschiedene Frontier-Modelle hinweg (z. B. Claude, GPT, Gemini) bei strikter Instance Separation konvergente Ergebnisse liefert. Dies ist analog zur Replikation eines Surveys mit verschiedenen Interviewer-Teams und stellt externe Replikation dar, nicht eine Voraussetzung für die Validität einer einzelnen Studie. (2) **Expertenvalidierung:** Unabhängige Domänenexperten, die dieselben Gruppen auf denselben Dimensionen bewerten und damit eine menschliche Baseline für den Vergleich mit LLM-generierten Profilen liefern. (3) **Erweiterte Power-Analyse:** Die $N = 15$ -Validierung wurde an einer einzigen Syntheseinheit durchgeführt; die Generalisierung über alle SEs erfordert zusätzliche Daten.

7. Ethische Betrachtungen

7.1 Epistemische Privatheit

SWR wirft ein neuartiges ethisches Problem auf: *epistemische Privatheit* – das Recht von Individuen und Gruppen, dass ihre impliziten Überzeugungen nicht aus öffentlichen Daten inferiert werden. Traditionelle Forschungsethik fokussiert auf die Datenerhebung (informierte Einwilligung, Datenschutz); SWR operiert auf öffentlich verfügbaren Daten, generiert aber Inferenzen, die über das hinausgehen, was die Teilnehmenden explizit kommuniziert haben. Das Weltanschauungsprofil einer Gruppe kann kollektive Überzeugungen offenlegen, die Gruppenmitglieder individuell nicht befürworten oder auch nur erkennen würden.

Das Design auf Gruppenebene bietet eine strukturelle Absicherung: SWR berichtet kollektive Muster, nicht individuelle Überzeugungen. Keiner namentlich genannten Person wird eine spezifische Weltanschauungsposition zugeschrieben. Bei kleinen Gruppen ($n < 10$) bietet die Aggregation jedoch schwächere Anonymisierung, und ein quasi-individuelles Profil kann entstehen. Forschende sollten Ergebnisse auf Gruppenebene nur für Gruppen berichten, die groß genug sind, um individuelle Identifikation zu verhindern.

7.2 Dual-Use-Charakter

SWR kann für legitime Zwecke eingesetzt werden (Verständnis elitärer Glaubenssysteme, Information demokratischer Deliberation, Analyse institutioneller Kulturen) und für illegitime (Profiling politischer Gegner, Konstruktion gezielter Manipulationskampagnen, Instrumentalisierung der Glaubenssystemanalyse). Dieser Dual-Use-Charakter ist jeder Methode inhärent, die implizite Überzeugungen explizit macht. Die Forschungsgemeinschaft sollte Normen für verantwortungsvollen SWR-Einsatz entwickeln, analog zu den Normen, die die surveybasierte Meinungsforschung regulieren.

7.3 Empfehlungen

1. Nur Ergebnisse auf Gruppenebene berichten; keine Überzeugungen namentlich genannten Personen zuschreiben.
2. Für Gruppen mit $n < 10$ das Re-Identifikationsrisiko explizit diskutieren.
3. Alle Prompts und Modellparameter für volle Transparenz dokumentieren und veröffentlichen.
4. Ergebnisse als „rekonstruierte Überzeugungsmuster“ rahmen, nicht als „was Gruppe X wirklich denkt“.
5. Member Checking ([Soysal & Türkmen, 2024](#)) als Desiderat in Betracht ziehen, wenn Zugang zu Gruppenvertretern besteht.

8. Fazit

Synthetic Worldview Reconstruction bietet eine neue Methode zur Rekonstruktion der kollektiven Glaubenssysteme soziologisch definierter Gruppen. Indem SWR Weltanschauungsanalyse als inverses Problem formuliert und LLMs als analytische Komprimierungsinstrumente einsetzt, überbrückt es die Kluft zwischen qualitativer Tiefe und quantitativer Strenge. Die Alleinstellungsmerkmale der Methode sind:

1. **Analyse auf Gruppenebene als Standard:** SWR ist für kollektive Glaubenssysteme konzipiert, nicht für Individualporträts, und bietet damit einen strukturellen Kontaminationsvorteil (vgl. Abstract).
2. **Duale Datenmodalität:** Durch den Einsatz auf sowohl Äußerungen als auch Handlungen ermöglicht SWR den Sagen-Tun-Vergleich und die modalitätsübergreifende Vorhersage – Validierungsmechanismen, die Methoden mit nur einem einzigen Datentyp nicht zur Verfügung stehen.
3. **Zuverlässige Instrumentierung:** IMIIRR-Koeffizienten ($ICC = 0,847\text{--}0,902$) belegen hohe Messkonsistenz. Reliabilität garantiert keine Validität (vgl. Abschnitt 3.1), etabliert aber eine stabile Grundlage für aussagekräftige Vergleiche, wobei vollständige Prompt-Dokumentation implizite Kodierregeln ersetzt.
4. **Übertragbarkeit:** Das Fünfschritte-Protokoll, das dimensionale Bewertungsrahmenwerk und die abgestuften Akzeptanzkriterien sind für die Anwendung auf jede soziologisch definierte Population konzipiert – politische Eliten, Unternehmenskulturen, religiöse Gemeinschaften, wissenschaftliche Disziplinen. Darüber hinaus ist die Synthese-Pipeline (Schritte 1–4) nicht an Personen oder Weltanschauungen gebunden: Sie kann als Eingangsstufe dienen, wo immer heterogene Textevi-
denz in eine kohärente kollektive Darstellung synthetisiert werden muss – einschließlich Organisationskulturen, Policy-Diskursen und historischen Epochen.

Die Methode wurde in einer Pilotstudie über 100 einflussreiche KI-Akteure (Geiger, 2026) entwickelt und validiert, die ihre Fähigkeit demonstrierte, diskriminierende Gruppenprofile zu erzeugen, interne Spannungen aufzudecken und systematische Muster zu identifizieren, die aggregierte Berichterstattung verschleiern würden. Das vorliegende Paper abstrahiert diese Fähigkeiten in ein übertragbares methodologisches Rahmenwerk.

SWR ersetzt keine bestehenden Methoden; es fügt dem Werkzeugkasten des Sozialwissenschaftlers ein neues Instrument hinzu – eines, das am wertvollsten ist, wenn direkter Zugang zu Befragten nicht verfügbar ist, wenn öffentliche Daten reichlich vorhanden sind und wenn die Forschungsfrage auf kollektive Glaubenssysteme abzielt statt auf individuelle Meinungen. Seine Limitationen – Kohärenzverzerrung, Kontaminationsrisiko, Blackbox-Charakter, kulturelle Grenzen – sind dokumentiert und teilweise kontrolliert; seine offenen Desiderate – Intermodell-Replikation, Expertenvalidierung, erweiterte Power-Analyse – definieren eine klare Forschungsagenda. Die Frage ist nicht, ob LLMs als Instrumente für sozialwissenschaftliche Forschung eingesetzt werden sollten, sondern wie sie *rigoros* eingesetzt werden können. SWR schlägt eine Antwort vor.

Offenlegung: Einsatz Künstlicher Intelligenz

KI-Offenlegungsstufe 5 (Umfangreich). Dieses Manuskript wurde mit KI-gestützter redaktioneller und formulierender Unterstützung durch Claude Opus 4.6 (Anthropic; Modell-ID: `claude-opus-4-6`; Zugang via Claude Code CLI, März 2026; Temperatur = 0; 1M-Kontextfenster) erstellt. Der Autor hat die Methode entworfen, die Paperstruktur festgelegt, alle Qualitätskriterien definiert, die Ergebnisse interpretiert und trägt die alleinige Verantwortung für alle substanziellen Aussagen, Fehler und Auslassungen. Das Modell wird nicht als Autor oder Koautor geführt, nicht als Beitragender gewürdigt und fungiert weder als Validierungs- noch als Wahrheitsinstanz. Alle in diesem Paper berichteten Validierungsergebnisse stammen aus der Pilotstudie (Geiger, 2026), in der die Methodik für Datenerhebung, LLM-gestützte Synthese und statistische Analyse vollständig dokumentiert ist.

Erklärung zur Datenverfügbarkeit

Die Pilotstudien-Daten, Analyseskripte, Prompt-Templates und Dimensionsdefinitionen sind öffentlich im [Projekt-Repository](#) verfügbar. Das Repository enthält die vollständige Prompt-Bibliothek, die 100×12 -Bewertungsmatrix und alle Validierungsanalyse-Skripte.

Lizenz

Dieses Werk ist lizenziert unter der Creative Commons Attribution 4.0 International License (CC-BY-4.0). Der vollständige Lizenztext ist auf der [CC-BY-4.0-Lizenzseite](#) abrufbar.

Literatur

- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C. & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>.
- Bail, C. A. (2024). Can Generative AI improve social science? *Proceedings of the National Academy of Sciences*, 121(21), Article e2314021121. <https://doi.org/10.1073/pnas.2314021121>.
- Barros, C.F., Azevedo, B.B., Graciano Neto, V.V., Kassab, M., Kalinowski, M., do Nascimento, H. A. D. & Bandeira, M. C. G. S. P. (2024). Large Language Model for Qualitative Research—A Systematic Mapping Study. *arXiv:2411.14473*. <https://arxiv.org/abs/2411.14473>.
- Berger, P. L. & Luckmann, T. (1966). *The Social Construction of Reality*. New York: Doubleday.
- Bourdieu, P. (1977). *Outline of a Theory of Practice*. Cambridge University Press.
- Braun, V. & Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77–101. <https://doi.org/10.1191/1478088706qp063oa>.
- Fairclough, N. (1992). *Discourse and Social Change*. Cambridge: Polity Press.
- Fugard, A. J. B. & Potts, H. W. W. (2015). Supporting thinking on sample sizes for thematic analyses: A quantitative tool. *International Journal of Social Research Methodology*, 18(6), 669–684. <https://doi.org/10.1080/13645579.2015.1005453>.
- Gadamer, H.-G. (1960). *Wahrheit und Methode*. Tübingen: Mohr.
- Ge, T. et al. (2024). Scaling synthetic data creation with 1,000,000,000 personas. *arXiv:2406.20094*. <https://arxiv.org/abs/2406.20094>.
- Geiger, L. (2026). What does the AI elite think? A synthetic worldview reconstruction of the 100 most influential AI actors (2010–2026). Zenodo. <https://doi.org/10.5281/zenodo.18736737>.
- Guest, G., Bunce, A. & Johnson, L. (2006). How many interviews are enough? An experiment with data saturation and variability. *Field Methods*, 18(1), 59–82. <https://doi.org/10.1177/1525822X05279903>.
- Hadamard, J. (1923). *Lectures on Cauchy's Problem in Linear Partial Differential Equations*. New Haven: Yale University Press.
- Hallgren, K. A. (2012). Computing Inter-Rater Reliability for Observational Data: An Overview and Tutorial. *Tutorials in Quantitative Methods for Psychology*, 8(1), 23–34. <https://doi.org/10.20982/tqmp.08.1.p023>.
- Hornby, R. (2025). Is Generative AI Ready to Join the Conversation That We Are? *Technophany: A Journal for Philosophy and Technology*, 3(1), 1–31. <https://doi.org/10.54195/technophany.18134>.

- Kommers, C., Ahnert, R., Antoniak, M., Benetos, E., Benford, S., Bunz, M. et al. (2026). Computational Hermeneutics: Evaluating Generative AI as a Cultural Technology. *Frontiers in Artificial Intelligence*, 9, Article 1753041. <https://doi.org/10.3389/frai.2026.1753041>.
- Mannheim, K. (1929). *Ideologie und Utopie*. Bonn: Cohen.
- Messeri, L. & Crockett, M. J. (2024). Artificial intelligence and illusions of understanding in scientific research. *Nature*, 627, 49–58. <https://doi.org/10.1038/s41586-024-07146-0>.
- Norman, G. (2010). Likert scales, levels of measurement and the “laws” of statistics. *Advances in Health Sciences Education*, 15(5), 625–632. <https://doi.org/10.1007/s10459-010-9222-y>.
- Ornstein, J. T., Blasingame, E. N. & Truscott, J. S. (2025). How to Train Your Stochastic Parrot: Large Language Models for Political Texts. *Political Science Research and Methods*, 13(2), 264–281. <https://doi.org/10.1017/psrm.2024.64>.
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P. & Hashimoto, T. (2023). Whose opinions do language models reflect? In: *Proceedings of the 40th International Conference on Machine Learning*, PMLR 202, 29971–30004. <https://proceedings.mlr.press/v202/santurkar23a.html>.
- Soysal, Y. & Türkmen, S. (2024). Reinterpreting the Member Checking Validation Strategy in Qualitative Research Through the Hermeneutics Lens. *Qualitative Inquiry in Education: Theory & Practice*, 2(1), 42–63. <https://doi.org/10.59455/qietp.19>.
- Tai, R. H. et al. (2024). An Examination of the Use of Large Language Models to Aid Analysis of Textual Data. *International Journal of Qualitative Methods*, 23, Article 16094069241231168. <https://doi.org/10.1177/16094069241231168>.
- Tarantola, A. (2005). *Inverse Problem Theory and Methods for Model Parameter Estimation*. Philadelphia: SIAM.
- Trope, Y. & Liberman, N. (2010). Construal-Level Theory of Psychological Distance. *Psychological Review*, 117(2), 440–463. <https://doi.org/10.1037/a0018963>.
- Wang, Q., Erqsous, M., Barner, K. E. & Mauriello, M. L. (2025). LATA: A Pilot Study on LLM-Assisted Thematic Analysis of Online Social Network Data Generation Experiences. *Proceedings of the ACM on Human-Computer Interaction*, 9(2), Article 124, 1–28. <https://doi.org/10.1145/3711022>.
- Weber, M. (1904). Die “Objektivität” sozialwissenschaftlicher und sozialpolitischer Erkenntnis. *Archiv für Sozialwissenschaft und Sozialpolitik*, 19, 22–87.
- Wodak, R. & Meyer, M. (Eds.) (2001). *Methods of Critical Discourse Analysis*. London: Sage.
- Ziems, C., Held, W., Shaikh, O., Chen, J., Zhang, Z. & Yang, D. (2024). Can Large Language Models Transform Computational Social Science? *Computational Linguistics*, 50(1), 237–291. https://doi.org/10.1162/coli_a_00502.

A. Prompt-Templates

Die folgenden Templates illustrieren das Fünfschritte-Protokoll. Alle in der Pilotstudie verwendeten Prompts sind im Repository archiviert (<https://github.com/research-line/ai-elite-swr>).

A.1 Schritt 2: Synthese-Prompt (Op1)

You receive a collection of anonymized statements and actions from a group of persons. Your task is to construct a fictional person whose worldview best explains the totality of the presented data. This person does not exist - they are an analytical construct that distills the group's collective beliefs.

Describe this person's:

1. Self-image: Who are they? What drives them? How do they see their role?
2. Worldview: How does the world work? What forces shape the future? What is the role of technology, power, and institutions?
3. View of humanity: What is the nature of human beings? What are their strengths and limitations? Can they be improved?

Also identify: Internal tensions, blind spots, and beliefs this person holds without being aware of them.

[Data corpus follows]

A.2 Schritt 5: Bewertungs-Prompt (Op2)

You receive a collection of anonymized statements and actions from a group of persons in a professional domain. Based on these data, assess the collective worldview of the group on the following 12 dimensions (scale 1-10). Justify each assessment with concrete references to the data points.

[Followed by: dimension definitions D01-D12 with scale poles, then the anonymized data corpus.]

A.3 Modalitätsübergreifende Vorhersage-Prompts (Op4)

Op4a (Vorhersage):

You receive the public statements of a group of persons. Based ONLY on these statements, predict 10 concrete actions you would expect from this group. Be specific: what investments, decisions, organizational changes, or political activities would follow from these stated beliefs?

[Statement corpus follows]

Op4b (Evaluation):

You receive two inputs: (1) a list of 10 predicted actions and (2) the documented real actions of a group of persons. For each prediction, assess: Is it CONFIRMED by the real actions, PLAUSIBLE but without direct match, or CONTRADICTED?

[Predictions + action corpus follow]

B. Glossar

DV Abhängige Variable (Dependent Variable). SWR definiert drei: DV1 (Selbstbild), DV2 (Weltanschauung), DV3 (Menschenbild).

Focus Control

Das Ensemble von Maßnahmen zur Sicherstellung der LLM-Aufgabencompliance: Anonymisierung + aufgabenfokussiertes Prompting.

IMIIRR Intra-Model Inter-Instance Rating Reliability. Die Konsistenz der Bewertungen über unabhängige LLM-Instanzen, die dieselben Daten verarbeiten.

Instance Separation

Die Anforderung, dass jede Messung, die zu einer inferenzstatistischen Aussage beiträgt, eine frische LLM-Instanz ohne geteilten Kontext verwendet.

Op1–Op6 Im SWR-Rahmenwerk definierte Operationalisierungen. Op1: Kernsynthese; Op2: dimensionale Bewertung; Op4: modalitätsübergreifende Vorhersage; Op5: Bottom-up-Clustering; Op6: strukturierter Dialog. Op3 (Textanalyse) wurde definiert, aber in der Pilotstudie nicht implementiert. Op5 wurde als PCA + HDBSCAN auf der 100×12 -Bewertungsmatrix implementiert (nicht als Sentence-BERT-Clustering wie ursprünglich konzipiert).

SE Syntheseinheit (Synthesis Unit). Die atomare Einheit der SWR-Analyse: eine spezifische Kombination aus Gruppe $\times$ Modalität $\times$ Zeitraum, die durch das Fünfschritte-Protokoll verarbeitet wird.

SWR Synthetic Worldview Reconstruction. Die in diesem Paper beschriebene Methode.